



Universidad de Santiago de Chile
Facultad de Ciencia
Departamento de Matemática y Ciencia de la Computación
Ingeniería Estadística

Seminario de Tesis

Creación y validación de un índice de congestión con datos del Hospital de Urgencia Asistencia Pública (HUAP).

Daniela Carrasco Montecino

Profesor Guía:
Felipe Elorrieta L.

Comisión Evaluadora:
Pamela Toro N.
Claudio Vargas R.

Santiago de Chile
Octubre, 2015

Resumen

La congestión ha sido un problema que se presenta por lo menos hace dos décadas en nuestro país, principalmente en invierno. Dicho fenómeno también es presenciado en países desarrollados, donde ya se ha estudiado más a fondo esta problemática. En Chile, el fenómeno aún no es analizado en su totalidad, lo que lleva a generarnos diversos cuestionamientos sobre la congestión y sus posibles causas. Es por esto que surge como motivación principal el crear y validar un índice de congestión que permita estimar la probabilidad de que un paciente no sea atendido en el Servicio de Urgencia de la ex Posta Central.

Para cumplir este objetivo se crearon dos índices para explicar la congestión, uno basado en los estudios previos llamado EDWIN y otro creado a partir de la técnica de componentes principales. Con el fin de validarlos respecto a su capacidad de explicar que los pacientes se vayan sin ser atendidos se utiliza un algoritmo de clasificación supervisada llamado Adaboost.M1. La clasificación se realizará respecto a la variable el paciente es o no atendido y para ello se utilizan variables obtenidas del Servicio de Urgencia de la ex Posta Central. Con esta información se crean 3 modelos uno sin índice, otro con el índice de Componentes Principales y otro con el índice EDWIN.

Finalmente, los resultados de los tres modelos, muestran que, al crear un índice a partir de componentes principales, se pierde un poco de capacidad predictiva respecto a usar las variables originales, pero se obtiene un índice con sentido y que es el más importante al momento de explicar que un paciente sea o no atendido. Un caso contrario es el índice EDWIN, el cual no resulta importante al momento de explicar la variable respuesta, pero que mantiene la mejor clasificación obtenida con el modelo más predictor dentro de los tres realizados.

Índice general

1. Introducción	5
1.1. Motivación	5
1.2. Planteamiento del Problema	7
1.3. Objetivos	8
1.3.1. Objetivo General	8
1.3.2. Objetivos Específicos	8
1.4. Metodología	9
1.4.1. Descripción de la Base de Datos	9
2. Marco Teórico	10
2.1. Definiciones	10
2.2. Indices de Congestión	12
2.3. Real-time Emergency Analysis of Demand Indicators (READI)	12
2.4. Emergency Department Work Index Score (EDWIN)	13
2.5. Técnicas de Reducción de Dimensiones	14
2.5.1. Análisis de Componentes Principales (ACP)	14
2.5.2. Cálculo de los Componentes Principales	14
2.5.3. Proceso de extracción	15
2.5.4. Propiedades de los Componentes	16
2.5.5. Número de los Componentes Principales	18
2.6. Algoritmos de Clasificación	18
2.6.1. Boosting	18
2.6.2. Validación Cruzada (Cross-Validation)	20
2.6.3. Medidas de Evaluación o Performance	23
3. Creación de índices de congestión	25
3.1. Creación de índice de congestión EDWIN	25

3.2. Creación de un índice de Componentes Principales (CP)	26
4. Análisis Descriptivo de la Base de Datos	28
4.1. Descripción Base de Datos	28
4.1.1. Descripción de Variables	28
4.2. Variables Cuantitativas	30
4.3. Variables Cualitativas	31
4.4. Análisis Tiempos de Espera	34
4.5. Análisis del tiempo de espera durante los días de la semana y meses del año . . .	39
4.6. Análisis del índice de congestión con Componentes Principales	41
4.7. Análisis del índice de congestión EDWIN	46
5. Aplicación Algoritmo de Clasificación	50
5.1. Implementación Adaboost.M1	51
5.2. Validación cruzada 10- Fold Cros-Validation	51
5.3. Importance Plot	51
5.4. Matriz de confusión	54
5.4.1. Validación: Medidas de Performance	54
6. Conclusiones	56
7. Anexos	60
7.1. Tablas y Gráficos	60

Índice de Ilustraciones

2.1. Validación cruzada de K=4 iteraciones.	22
3.1. Proporción de variabilidad explicada por cada componente.	27
4.1. Box plot Espera - Área	34
4.2. Box plot Espera - Categoría	35
4.3. Box plot Espera - Día de la semana	36
4.4. Box plot Espera - LBBS	37
4.5. Box plot Espera - Previsión	38
4.6. Serie temporal semanal.	39
4.7. Serie temporal mensual.	40
4.8. Box plot Componente Principal - LBBS.	41
4.9. Box plot Componente Principal - Área.	42
4.10. Box plot Componente Principal - Categoría.	43
4.11. Box plot Componente Principal - Día de la semana.	44
4.12. Box plot Componente Principal - Previsión.	45
4.13. Box plot EDWIN - LBBS.	46
4.14. Box plot EDWIN - Área.	47
4.15. Box plot EDWIN - Día de la semana.	48
4.16. Box plot EDWIN - Mes.	49
5.1. Importance plot primer modelo.	52
5.2. Importance plot segundo modelo.	53
5.3. Importance plot tercer modelo.	53

Índice de Tablas

2.1. Caso general para matriz de confusión	23
3.1. Frecuencias Índice EDWIN.	26
3.2. Matriz de rotación Componentes principales	26
3.3. Proporción de Varianza explicada por cada componente	27
4.1. Estadísticos variables cuantitativas.	30
4.2. Estadísticos variables cuantitativas post corte de percentiles.	30
4.3. Frecuencias Grupos Etarios.	31
4.4. Frecuencias Sexo.	31
4.5. Frecuencias Área.	32
4.6. Frecuencias Categoría.	32
4.7. Frecuencias Día de la semana.	32
4.8. Frecuencias Previsión de salud.	33
5.1. Matriz de clasificación primer modelo	54
5.2. Matriz de clasificación segundo modelo	54
5.3. Matriz de clasificación tercer modelo	54
5.4. Resumen para Medidas de Performance para tres modelos propuestos.	55
7.1. Frecuencias GES.	60
7.2. Frecuencias Nacionalidad.	60
7.3. Frecuencias Comuna.	60
7.4. Frecuencias Remitido.	61
7.5. Frecuencias Causa Urgencia.	62

Capítulo 1

Introducción

1.1. Motivación

La congestión en los Servicios de Urgencia es un fenómeno que se inició en las urgencias en nuestro país hace más de dos décadas, en un principio sólo en la estación invernal debido al aumento de consultas por enfermedades respiratorias, pero que a lo largo del tiempo se ha extendido al resto del año, convirtiéndose en algunas urgencias en un problema permanente. Es por esto que no es de extrañar que esta situación aparezca de manera frecuente en noticiarios que muestran la demora de los pacientes en ser atendidos o incluso la muerte de más de alguno que esperaba atención.

El fenómeno tiene una dimensión internacional y ya ha sido analizado en países como Estados Unidos, Australia, España, entre otros. Inicialmente, en EEUU se pensó que sus causas radicaban en el incremento por la demanda por parte de pacientes sin seguro médico, pacientes con VIH, y otros cuya atención no estaba justificada. Sin embargo, en una revisión en el 2003, ya se consideraba la dificultad de evacuar los pacientes hospitalizados en camillas del servicio de urgencia hacia los servicios hospitalarios como la causa principal. Este fenómeno fue llamado bloqueo de acceso y se reconoce como el factor más causante de la congestión.

Asplin et al lograron establecer adecuadamente el marco conceptual de la congestión en la urgencia (overcrowding en inglés). Las causas de la congestión pueden depender de incrementos en la demanda (input), dificultades en los procesos propios de la unidad de emergencia (throughput), o en el traslado oportuno de los pacientes hospitalizados en la urgencia a los servicios del hospital (output). Las soluciones que se han ido implementando a lo largo del tiempo tienen un paralelo con lo que se piensa que las originó: creación de SAPU como una manera de satisfacer

la demanda de atenciones de baja complejidad, entre otras. Últimamente, con la creación de unidades de gestión de camas el énfasis se ha puesto en el output de los Servicios de Urgencia. Se ha generado un consenso que para solucionar el problema es necesario poner el foco en el Hospital y no en el Servicio de Urgencia.

La medición adecuada de la congestión ha sido un tema recurrente en la literatura. Se han implementado a lo varios índices a nivel mundial, como el NEDOCS y el EDWIN. [8]

En la literatura se mencionan una serie de consecuencias del bloqueo de acceso y la congestión de los Servicios de Urgencia que comprometen la calidad de atención: aumento del tiempo de espera para controlar el dolor, aumento en la letalidad de algunas patologías, retraso en la administración de algunos medicamentos, aumento en la probabilidad de error en la administración de un fármaco, desvío de ambulancias, carga laboral excesiva del personal médico y el incremento de los pacientes que se van sin recibir atención médica. Es ahí donde nos enfocaremos para analizar esta problemática en la ex Posta Central, ya que se dispone de información histórica de pacientes que se retiran antes de recibir asistencia médica; estudiaremos las causas y consecuencias a través de interrogantes como:

- ¿Cuántas personas se van del Servicio de Urgencia sin recibir atención?
- ¿Qué características en común presentan dichas personas que no fueron atendidas?
- ¿Cuánto influye la hora y el día o la estación del año en los tiempos de atención?

También es interesante estudiar la dinámica de la atención y de qué dependen éstos para poder relacionarlos con esos pacientes que no son atendidos. Cuánto influye el triage en la atención (clasificación que se le da al nivel de gravedad con la que llega un paciente al Servicio de Urgencia.) Dada la naturaleza de la información disponible, la metodología que se utilizará serán técnicas de Minería de Datos, ya que se quiere extraer información de un conjunto de datos y transformarla en una estructura comprensible para su uso posterior en las Ciencias Médicas, siendo éste un método diferente para estudiar grandes volúmenes de información en el ámbito de la Salud Pública.

1.2. Planteamiento del Problema

Cuando se habla de importancia de la salud se refiere al valor que ésta tiene para que una persona pueda llevar una buena calidad de vida en todos sus diversos aspectos. Si falla, sea de manera leve, moderada o grave, ya no se está en condiciones óptimas para desempeñar cualquier función. Es por esto que resulta sumamente importante tomar medidas respecto a los pacientes que no están siendo atendidos para poder asegurar calidad en el servicio de este recinto de asistencia hospitalaria. Por lo tanto es necesario, verificar cuáles son las características temporales, espaciales o de la persona que implican en que un paciente no sea atendido. Para esto se utilizará una técnica de Minería de Datos.

Boosting: Método que tiene como propiedad obtener un clasificador fuerte a partir de un método de construcción de clasificadores débiles. El funcionamiento de Boosting se basa en asignar un peso a cada ejemplo (inicialmente el mismo para todos). En cada iteración se construye un clasificador base (también denominada débil), teniendo en cuenta la distribución de pesos. Entonces los pesos de cada ejemplo se reajustan, en función de si el clasificador base lo clasificó erróneamente. A la hora de clasificar, el resultado se obtiene mediante voto ponderado de los clasificadores base, lo que puede resultar útil a la hora de ver qué factores influyen de manera más potente al momento de determinar qué variables son las más influyentes cuando un paciente decide retirarse sin ser atendido o que al ser atendido se determine dejarlo hospitalizado o no. También tiene relevancia el que este método puede servir como punto de partida para otros métodos de clasificación.

Este algoritmo será utilizado, debido a que en general son los que otorgan mejores resultados en términos de la predicción de clases en un problema de clasificación binario.

1.3. Objetivos

1.3.1. Objetivo General

Validar un índice de congestión a partir de la metodología Data Mining para estimar la probabilidad de que un paciente con ciertas características no sea atendido en el Servicio de Urgencia.

1.3.2. Objetivos Específicos

- Realizar un estudio respecto a los modelos de Data Mining utilizados en este tipo de problemas de clasificación
- Crear un índice de congestión a partir de la técnica de Componentes Principales.
- Crear un segundo índice de congestión a partir de la literatura disponible.
- Implementar el algoritmo Adaboost.M1 para clasificar pacientes atendidos y no atendidos en el Servicio de Urgencia.
- Validar alguno de los dos índices creados para explicar la congestión en el Servicio de Urgencia
- Evaluar el modelo de clasificación utilizado a partir de un conjunto de medidas de performance.
- Demostrar que la congestión en el Servicio de Urgencia (SU) influye en que las personas se van sin recibir atención y en cómo se atiende a los pacientes que reciben asistencia.

1.4. Metodología

1.4.1. Descripción de la Base de Datos

Se dispone de información otorgada por profesionales de la ex Posta Central con más de 150.000 consultas en el Servicio de Urgencia durante el año 2014 y 2015. Contiene alrededor de 38 variables del tipo demográficas, distintos tiempos de espera y principalmente información médica de los pacientes.

Etapas de Desarrollo

- Realizar un estudio respecto a los modelos de Data Mining utilizados en este tipo de problemas.
- Crear un índice de congestión con alto poder de predicción para utilizarlo como variable explicativa del modelo de clasificación de los pacientes atendidos.
- Demostrar que la congestión influye en que las personas se retiran sin ser atendidas y en cómo se atiende a los pacientes que deciden esperar.
- Realizar un análisis descriptivo a la base de datos a través de gráficos y estadísticos descriptivos para crear variables con alto poder predictivo para las variables que pretenden estudiar principalmente el comportamiento de los pacientes que se van de la Urgencia sin ser atendidos.
- Estudiar y ejecutar modelos a través de los algoritmos: Adaboost.M1 utilizando dos softwares estadísticos: *SAS* y *RGui* para predecir el comportamiento de los pacientes que no fueron atendidos en el Servicio de Urgencia.
- Elegir el mejor modelo a partir de medidas de performance como la curva de *ROC* y *F – Measure*, entre otras.
- Concluir e interpretar en base al mejor modelo calculado.

Capítulo 2

Marco Teórico

2.1. Definiciones

Urgencia médica: Cualquier condición de salud que requiera de atención médica en el lugar más próximo y con la disponibilidad adecuada para tratar el problema por el que el paciente consulta. Muchas veces, lo que el paciente cree es una urgencia en realidad no lo es y su problema podría ser resuelto en la atención primaria de salud.

Servicio de Urgencia: Centro asistencial perteneciente a todo hospital o clínica dónde se atienden requerimientos inmediatos de pacientes con distintos niveles de gravedad.

Triage: Palabra de origen francés que significa clasificar, seleccionar o elegir. Representa la evaluación rápida de los pacientes y su ubicación en la lista de espera para la atención médica. Por desgracia, muchas personas insisten en ser atendidas de inmediato por orden de llegada y no de gravedad de sus síntomas.

El sistema de Triage divide los estados de gravedad en varias categorías incluyendo desde estados críticos a situaciones menos urgentes. Existe una clasificación a nivel mundial para decidir en qué categoría está un paciente, sin embargo, cada centro asistencial evaluará de acuerdo a las áreas y recursos disponibles principalmente.

La aplicación de la priorización es de responsabilidad del equipo de enfermería del Servicio de Urgencia. Así, cuando un paciente ingresa es recibido por una enfermera o enfermero, quien controla signos vitales y aplica un cuestionario que apunta determinar el grado de urgencia. Las categorías son las siguientes:

- Triage 1 (paciente c1): El paciente debe ser evaluado y atendido de manera inmediata dado que su condición representa un serio riesgo para su vida. Se aplica en casos de paro cardiorrespiratorio, apnea, quemaduras de la vía aérea, insuficiencia respiratoria severa, estatus convulsivo, intoxicaciones y hemorragias severas, entre otros.
- Triage 2 (paciente c2): El paciente debe ser evaluado y atendido en segundo orden de prioridad. Se aplica en pacientes con dolor severo, particularmente si se trata de personas mayores o factores de riesgo asociados como diabetes, cardiopatías o hipertensión arterial. También en personas con compromiso respiratorio, dolor de cabeza intenso y de comienzo súbito, compromiso de conciencia, trauma ocular, entre otros.
- Triage 3 (paciente c3): El paciente puede esperar un tiempo razonable para ser atendido. Se aplica en personas cuya condición no implica un riesgo inmediato para su vida. Se aplica en pacientes con crisis hipertensiva sin otros factores de riesgo cardiovascular significativos, hemorragias recientes, pero que no están activas en el momento; niños con saturación de oxígeno entre 90 % – 95 %, convulsiones en paciente epiléptico, TEC, fractura de cadera o alguna extremidad, heridas abrasivas extensas, entre otros.
- Triage 4 (paciente c4): En esta categoría caben todos los consultantes que no están en las categorías anteriores y que, además de la atención médica, requieren de un procedimiento diagnóstico o terapéutico para su resolución. Por ejemplo, pacientes adultos con cuadros gastrointestinales, torsiones de tobillo, dolor de espalda, cuadros respiratorios simples o pacientes pediátricos con cuadros bronquiales obstructivos simples, aspiración de cuerpo extraño sin dificultad respiratoria, diarreas simples, etc.
- Triage 5 (paciente c5): Son pacientes que requieren sólo de la intervención del médico para el diagnóstico y resolución de su condición de salud y que podrían haberla requerido en una consulta ambulatoria. Por ejemplo, pacientes adultos con estados gripales, amigdalitis, picaduras de insectos, cuadros de angustia o requerimiento de recetas médicas por enfermedades crónicas.

De acuerdo con esta clasificación, se inicia el proceso mismo de atención. El Triage supone también una reevaluación y asistencia continua así como la recategorización si el plazo máximo de espera es superado por la demanda de atención. [9]

2.2. Indices de Congestión

La congestión en el Servicio de Urgencia (SU) se estudia de manera frecuente en diversos países incluyendo Chile, sin embargo, no existe una medición estándar para calcularla. Pero, estudiando la literatura al respecto es posible encontrar algunos índices que podrían adaptarse a este estudio en Chile.

2.3. Real-time Emergency Analysis of Demand Indicators (READI)

Índice que mediante el uso de puntuaciones, fue propuesto en un principio para poder predecir la demanda de pacientes del SU. Utiliza para su cálculo la cantidad de camas disponibles en el servicio, la gravedad de los pacientes al llegar al SU, la productividad de los médicos, y una medición de la demanda total.[13]

Se calcula como:

$$DV = (BR + PR) \times AR$$

Donde,

$$BR = \frac{(N + A_a - A_b)}{B_d} \quad (2.1)$$

$$AR = \frac{\sum t_i \cdot n_i}{N} \quad (2.2)$$

$$PR = \frac{V_a}{\sum V_i} \quad (2.3)$$

- N : Número de pacientes en el SU
- A_a : Llegadas predichas
- A_b : Salidas predichas
- B_d : Cantidad de camas disponibles
- t_i : Categoría del triage
- n_i : Cantidad de pacientes por categoría del triage
- V_a : Pacientes que llegan por hora

- V_i : Pacientes vistos por hora por cada médico.

Luego, considerando estas tres proporciones se calcula la demanda total para el SU. Teniéndose un $DV > 7$ indicaría en su predicción la presencia de sobrecongestión en el SU.

2.4. Emergency Department Work Index Score (EDWIN)

Al igual que el índice READI, es utilizado para el análisis en tiempo real de la cantidad/demanda de trabajo en el Servicio de Urgencia. [14]

Se calcula como:

$$\frac{\sum n_i t_i}{N_a (B_T - B_A)} \quad (2.4)$$

Donde,

- n_i = Número de pacientes en el SU agrupados por la categoría i según el triage (Índice de gravedad de Emergencia)
- t_i = Categoría del triage.
- N_a = Cantidad de médicos de turno atendiendo en el SU.
- B_T = Numero de camas de tratamiento en el SU.
- B_A = Número de pacientes ingresados en espera para una cama hospitalaria.

La actividad en el SU, utilizando este índice, puede ser clasificada en tres intervalos:

- $EDWIN < 1.5$ significará que el SU se encuentra bajo control
- $1.5 \leq EDWIN < 2$ significará que el SU se encuentra ocupado
- $EDWIN > 2$ significará que el SU se encuentra colapsado.

2.5. Técnicas de Reducción de Dimensiones

2.5.1. Análisis de Componentes Principales (ACP)

El análisis de componentes principales (ACP) es una técnica descriptiva que disminuye la dimensionalidad de las variables adecuadas multidimensionalmente.

Para estudiar las relaciones que se presentan entre p variables correlacionadas, se puede transformar el conjunto original de variables en otro conjunto de nuevas variables incorrelacionadas entre sí, llamando a este nuevo conjunto de componentes principales.

Las nuevas variables son combinaciones lineales de las anteriores y se van construyendo según el orden de importancia en cuanto a la variabilidad total que recogen de la muestra.

De manera ideal se buscan $r < p$ variables que sean combinaciones lineales de las p -variables originales y que estén incorrelacionadas recogiendo la mayor parte de la información.

Si las variables originales están incorrelacionadas desde un comienzo, entonces no tiene sentido realizar un análisis ACP.

El ACP es una técnica matemática que no requiere la suposición de normalidad multivariante, aunque si se cumpliera se puede dar una interpretación mejor o más profunda de las componentes principales.

2.5.2. Cálculo de los Componentes Principales

Sea $(X_1, X_2, \dots, X_p)$ una serie de variables, medidas sobre un objeto o sujeto. A partir de ellas se trata de calcular un nuevo conjunto de variables $(Y_1, Y_2, \dots, Y_p)$ incorrelacionadas entre sí y cuyas varianzas vayan decreciendo progresivamente.

Cada Y_j es una combinación lineal de las variables originales X_i , es decir:

$$Y_j = a_{j1}x_1 + \dots + a_{jp}x_p = \mathbf{a}_j' \mathbf{x} \quad (2.5)$$

Donde, $\mathbf{a}_j' = (a_{1j} \ a_{2j} \ \dots \ a_{pj})$

Para maximizar la varianza , una forma simple es aumentando los coeficientes $\mathbf{a}'_j$. Para mantener la ortogonalidad de la transformación se impone que el módulo del vector $\mathbf{a}'_j$ sea 1, es decir:

$$\mathbf{a}'_j \cdot \mathbf{a}_j = \sum_{k=1}^n a_{jk}^2 = 1 \quad (2.6)$$

Entonces, el primer componente se calcula eligiendo $\mathbf{a}_1$ de modo que Y_1 tenga la mayor varianza posible. El segundo componente principal se calcula obteniendo $\mathbf{a}_2$ de modo que la variable obtenida Y_2 esté incorrelacionada. De la misma forma se eligen el resto de los componentes principales incorrelacionados entre sí, de modo que las variables aleatorias obtenidas vayan teniendo menor varianza.

2.5.3. Proceso de extracción

Consiste en una primera etapa, elegir $\mathbf{a}_1$ de modo que maximice la varianza de Y_1 , sujeto a la restricción $\mathbf{a}'_1 \mathbf{a}_1 = 1$ y $V(y_1) = \mathbf{a}_1 \Sigma \mathbf{a}_1$. Utilizando multiplicadores de Lagrange, se obtiene un sistema lineal de ecuaciones en donde el determinante debe ser igual a cero.

$$(\Sigma - \lambda I) \mathbf{a}_1 = 0 \quad \text{entonces} \quad |\Sigma - \lambda I| = 0$$

Σ : Matriz de varianza - covarianza.

De este modo, α es un valor propio de la matriz Σ . Esta matriz es de orden p , y si es definida positiva, tendrá p valores propios distintos:

$$\lambda_1, \lambda_2, \dots, \lambda_p$$

tal que $\lambda_1 > \lambda_2 > \dots > \lambda_p$.

De $(\Sigma - \lambda I) \mathbf{a}_1 = 0$ también se obtiene que $\Sigma \mathbf{a}_1 = \lambda I \mathbf{a}_1$ entonces:

$$V(Y_1) = \mathbf{a}'_1 \Sigma \mathbf{a}_1 = \mathbf{a}'_1 \lambda I \mathbf{a}_1 = \lambda \mathbf{a}'_1 \mathbf{a}_1 = \lambda$$

Luego, para maximizar la varianza de Y_1 se tiene que tomar el mayor valor propio, λ_1 , y su correspondiente vector propio $\mathbf{a}'_1$.

En la siguiente etapa, se tiene que el segundo componente principal es $Y_2 = \mathbf{a}_2' \mathbf{X}$, el que se obtiene mediante un argumento similar al anterior, pero que además requiere que Y_2 esté incorrelacionada con Y_1 . Para ello se necesita que $Cov(Y_2, Y_1) = 0$, obteniéndose la siguiente función objetivo:

$$L(a_2) = \mathbf{a}_2' \Sigma \mathbf{a}_2 - \lambda(\mathbf{a}_2' \mathbf{a}_2 - 1) - \delta(\mathbf{a}_2' \mathbf{a}_1)$$

Usando multiplicadores de Lagrange se obtiene que $(\Sigma - \lambda I) \mathbf{a}_2 = 0$

Se elige λ como el mayor valor propio de la matriz Σ con su vector propio $\mathbf{a}_2'$

Usando la misma metodología se puede extender que al j - ésimo componente le corresponderá el j - ésimo valor propio ordenado por magnitud.

Entonces, todos los componentes principales pueden ser expresados como el producto de una matriz formada por los vectores propios, multiplicada por el vector $\mathbf{X}$ que contiene las variables originales.

$$\mathbf{Y} = A \cdot \mathbf{X}, \text{ con } A' A = I \quad \text{y donde} \quad V(Y_p) = \lambda_p$$

Calcular los componentes principales equivale a aplicar una transformación ortogonal A a las variables X para obtener unas nuevas variables Y que sean incorrelacionadas entre sí.

2.5.4. Propiedades de los Componentes

Los componentes principales son nuevas variables con las siguientes propiedades:

- Conservan la variabilidad inicial: La suma de las varianzas de los componentes es igual a la suma de las varianzas de las variables originales, y la varianza generalizada de los componentes es igual a la original.

La matriz de covarianzas Y será:

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

$$\Lambda = V(\mathbf{Y}) = V(A\mathbf{X}) = A'V(\mathbf{X})A = A'\Lambda A, \text{ o bien } \Sigma = A'\Lambda A$$

$$tr(\Sigma) = Var(Y_1) + \dots + Var(Y_p) = \lambda_1 + \dots + \lambda_p = tr(\Lambda)$$

Esto permite hablar de porcentaje de varianza total que recoge cada componente principal y que está dado por:

$$\frac{\lambda_i}{\sum_{i=1}^p \lambda_i} = \frac{\lambda_i}{\sum_{i=1}^p V(x_i)} \cdot 100\%$$

En la práctica, al tener en principio p - variables se queda con un número mucho menor de componentes que recogen un porcentaje amplio de la variabilidad total.

- Las covarianzas entre cada componente principal y las variables X vienen dadas por el producto de las coordenadas del vector propio que define el componente por su valor propio.
- La correlación entre un componente principal y una variable X es proporcional al coeficiente de esa variable en la definición del componente, y el coeficiente de proporcionalidad es el cociente entre la desviación típica del componente y la desviación típica de la variable:

$$Corr(Y_j, X_i) = a_{ji} \frac{\sqrt{\lambda_j}}{S_x}$$

- Las r componentes principales ($r < p$) proporcionan la predicción lineal óptima con r variables del conjunto de variables X .
- Si se estandarizan los componentes principales, dividiendo cada uno por su desviación típica, se obtiene la estandarización multivariante de los datos originales.

Habitualmente se calculan las componentes principales sobre las variables originales estandarizadas, es decir, con media 0 y varianza 1. Esto equivale a tomar las componentes principales no de la matriz de covarianza si no de la matriz de correlaciones. Así las componentes principales son vectores propios de la matriz de correlaciones, y son diferentes a los de la matriz de covarianza.

Actuando sobre la matriz de correlaciones, se da igual importancia a todas las variables originales, $\sum_{i=1}^p p$.

2.5.5. Número de los Componentes Principales

Existen distintos criterios para determinar el número $r - p$ de componentes principales:

1. Criterio del porcentaje: El número r de componentes principales se toma de modo que:

$$P_r = \frac{\sum_{i=1}^r \lambda_i}{\sum_{j=1}^p \lambda_j}$$

Donde, P_r : Porcentaje de varianza acumulado

2. Criterio de Kaiser: Consiste en obtener los componentes principales a partir de la matriz de correlaciones, con lo cual los componentes principales con varianza inferior a 1 explican menos variabilidad que una variable observada. El criterio de Kaiser implica retener las primeras r componentes tal que $\lambda_r \geq 1$
3. Test de Esfericidad: Basado en la distribución Normal Multivariante, tal que :

$$H_0 : \lambda_1 > \lambda_2 > \dots > \lambda_r > \lambda_{r+1} = \lambda_{r+2} = \dots = \lambda_p$$

Cuyo estadístico $-2 \log \lambda_k \sim \chi_q^2$, busca no rechazar H_0 . Se conoce como Teste de Barlett.[10]

2.6. Algoritmos de Clasificación

2.6.1. Boosting

Boosting es un método poderoso que en inglés significa impulsar, potenciar o estimular el rendimiento. Sirve para clasificar observaciones [1], teniendo como objetivo maximizar el uso de un clasificador para mejorar su precisión. Utiliza el clasificador repetidamente sobre la muestra de entrenamiento, dándole mayor peso ($W_b(i)$) a las observaciones que están mal clasificadas.

Se comenzó a estudiar a través de *PAC* (Probably Approximately Correct), pasando por estudios de Schapire y Freund; Friedman, Hastie, y Tibshirani hasta llegar al algoritmo Adaboost, propuesto por Freund y Schapire en 1996. Se aplica a problemas de respuesta binaria

funcionando de manera muy práctica.

El algoritmo funciona de la siguiente manera:

Dada una muestra de entrenamiento $T_n = \{(x_1, y_1), \dots, (x_i, y_i), \dots, (x_n, y_n)\}$ donde cada X_i pertenece a un conjunto de un espacio X y las variables respuestas Y_i corresponden al otro conjunto Y . El Adaboost parte ejecutando el clasificador débil a través de una cierta cantidad de ejecuciones $t = 1, \dots, T$, manteniendo una distribución de pesos sobre la muestra de entrenamiento. [4] La distribución de dicho evento se denota como $D_t(i)$ con i que considera la cantidad de instancias x y el número de las ejecuciones realizadas. Se inicia con el mismo peso para cada clasificador $W_i = 1/N$, [2] pero que aumentará en las observaciones mal clasificadas para así obligar al algoritmo inicial a enfocarse en los ejemplos más complicados en sucesivas ejecuciones.

El clasificador que se pretende mejorar deberá encontrar una hipótesis $h_t : X \rightarrow Y$ que tenga coherencia con la distribución D_t .

Para analizar la precisión de dicha hipótesis, se calcula su error como:

$$\epsilon_t = Pr_{i \sim D_t} [h_t(x_i) \neq y_i] = \sum_{i: h_t(x_i) \neq y_i} D_t(i) \quad (2.7)$$

Error que se mide en función de la distribución de los pesos de los casos mal clasificados $D_t(i)$. Para optimizar el rendimiento de este algoritmo se necesita que sea capaz de usar los pesos de alguna manera interna. De lo contrario, se puede hacer un muestreo de los datos de entrenamiento con la función D_t para así otorgarle mayor probabilidad de aparecer en la muestra a los casos que tengan un mayor peso, o bien que puedan aparecer repetidos. [3]

Al obtener la hipótesis h_t generada por el clasificador base, el algoritmo Adaboost elige un parámetro α_t que medirá el error asociado a esta hipótesis. El valor de α_t será cada vez mayor si el error ϵ_t es cada vez menor.

La distribución D_t se actualizará en cada iteración con el objetivo de darle mayor peso a los casos mal clasificados por la hipótesis ya mencionada y darle menor peso a las observaciones correctamente clasificadas. Con esto se pretende en sucesivos pasos poder obtener clasificadores

que se preocupen de los casos más difíciles.

Como output (salida) del algoritmo ejecutado se obtiene un voto ponderado de las T hipótesis del clasificador débil que tiene como peso asignado a la hipótesis h_t el valor de α_t .

Presenta **ventajas**, como:

- Rapidez y simpleza al ejecutarlo
- Resulta fácil al programarlo
- No necesita ajustar sus parámetros, excepto el número de ejecuciones T
- No requiere un conocimiento previo del clasificador débil
- Tiene ciertas garantías teóricas.

Y a su vez también tiene **desventajas**:

- El desempeño en un dato particular depende de los datos y del clasificador que es débil ya que presenta sensibilidad a datos incompletos y falla con hipótesis débiles.
- Es en particular susceptible al ruido.

2.6.2. Validación Cruzada (Cross-Validation)

Técnica utilizada para evaluar algunos análisis estadísticos y garantizar que los resultados obtenidos sean independientes de la división entre los datos de entrenamiento y prueba. Consiste en repetir y calcular la media aritmética obtenida de las medidas de evaluación sobre diferentes particiones. Se utiliza para estimar que tan preciso es un modelo que se llevará a la práctica.

Proviene de la mejora del método de retención o *holdout method*. Este consiste en dividir en dos conjuntos complementarios los datos de muestra, realizar el análisis de un subconjunto (denominado datos de entrenamiento o *training set*), y validar el análisis en el otro subconjunto (datos de prueba o *test set*), de forma que la función de aproximación sólo se ajusta con el conjunto de datos de entrenamiento y a partir de aquí calcula los valores de salida para el conjunto de datos de prueba (valores que no ha analizado antes).

Como ventaja, presentar gran rapidez al momento de ejecutarlo, sin embargo, este método no es bastante preciso debido a la variación de los resultados obtenidos para diferentes datos de

entrenamiento. La evaluación puede depender en gran medida de cómo es la división entre el training y el test set, por ende puede ser significativamente diferente en función de cómo realice esta división. Debido a estas carencias es que nace el concepto de validación cruzada.

Suponemos que tenemos un modelo con uno o más parámetros de ajuste desconocidos y un conjunto de datos de entrenamiento a analizar. El proceso de ajuste optimiza los parámetros del modelo para que éste ajuste a los datos de entrenamiento tan bien como pueda. Si tomamos una muestra independiente como dato de prueba (validación), del mismo grupo que los datos de entrenamiento, normalmente el modelo no se ajustará a los datos de prueba igual de bien que los datos de entrenamiento. Esto se denomina sobreajuste y acostumbra a pasar cuando el tamaño de los datos de entrenamiento es pequeño o cuando el número de parámetros del modelo es grande. La validación cruzada es una manera de predecir el ajuste de un modelo a un hipotético conjunto de datos de prueba cuando no se dispone del conjunto explícito de datos de prueba.

Validación cruzada de K iteraciones

En la validación cruzada de K iteraciones (K-fold cross-validation) los datos de muestra se dividen en K subconjuntos. Uno de los subconjuntos se utiliza como datos de prueba y el resto (K-1) como datos de entrenamiento. El proceso de validación cruzada es repetido durante k iteraciones, con cada uno de los posibles subconjuntos de datos de prueba. Finalmente, se estima la media aritmética de los resultados de cada iteración para obtener un único resultado. Este método es muy preciso, ya que se evalúa a partir de K combinaciones de datos de entrenamiento y de prueba, pero aún así tiene una desventaja; es lento desde el punto de vista computacional. En la práctica, la elección del número de iteraciones depende de la medida del conjunto de datos. Lo más usual es utilizar la validación cruzada de 10 iteraciones (10-fold cross-validation). [7]

Error de la validación cruzada de K iteraciones

En cada una de las K iteraciones de esta validación se realiza un cálculo de error. El resultado final se obtiene a partir de calcular la media aritmética de los K valores de errores obtenidos, según:

$$E = \frac{1}{K} \sum_{i=1}^K E_i$$

Es decir, se suman los K valores de error se divide entre el valor de K.




Figura 2.1: Validación cruzada de $K=4$ iteraciones.

Medidas de ajuste

El objetivo de la validación cruzada consiste en estimar el nivel de ajuste de un modelo a un cierto conjunto de datos de prueba independientes de las utilizadas para entrenar el modelo. Estas medidas pueden ser utilizadas para estimar cualquier medida cuantitativa de ajuste apropiada para los datos y el modelo. Por ejemplo, en un modelo de clasificación binaria, cada muestra se prevé como correcta o incorrecta, de forma que en este caso se puede utilizar la tasa de error de clasificación para resumir el ajuste del modelo. Así mismo, se podrían utilizar otras medidas como el valor predictivo positivo. Cuando el valor a predecir se distribuye de forma continua se puede calcular el error utilizando medidas como el error cuadrático medio o la desviación de la media cuadrada.[5]

Limitaciones de la validación cruzada

La validación cruzada sólo produce resultados significativos si el conjunto de validación y prueba de conjunto se han extraído de la misma población y que se lleve a cabo correctamente, la validación será casi imparcial. Sin embargo, existen diversas maneras en que la validación cruzada puede ser mal utilizada. Si se abusa y posteriormente se lleva a cabo un estudio real de validación, es probable que los errores de predicción en la validación real sean mucho peores de lo esperado sobre la base de resultados de la validación cruzada.

Algunas formas en que la validación cruzada puede ser mal utilizada:

- Mediante el uso de validación cruzada para evaluar varios modelos, y sólo indicando los resultados para el modelo con los mejores resultados.

- Al realizar un análisis inicial para identificar las características más informativas utilizando el conjunto de datos completo, si la selección de característica o el ajuste del modelo lo requiere por el propio procedimiento de modelado, esto debe repetirse en cada conjunto de entrenamiento. Si se utiliza la validación cruzada para decidir qué características se van a utilizar, se deberá realizar un proceso interno de validación cruzada para llevar a cabo la selección de características en cada conjunto de entrenamiento.
- Al permitir que algunos de los datos de entrenamiento esté también incluido en el conjunto de prueba, esto puede suceder debido a “hermanamiento” en el conjunto de datos, con lo que varias muestras exactamente idénticas o casi idénticas pueden estar presentes en el conjunto de datos. [6]

2.6.3. Medidas de Evaluación o Performance

Las medidas de performance utilizadas generalmente para evaluar la calidad de un modelo, se basan en un tabla de contingencia que describe los casos predichos acertados y erróneos. Esta tabla se denomina matriz de clasificación o confusión, la cual contiene información sobre las clasificaciones reales y las predichas por el modelo en ejecución. Para un ejemplo de clase binaria, se representa como:

		Clase Real	
		0	1
Clase Predicha	0	True Negative	False Negative
	1	False Positive	True Positive
Totales		$N = FP + TN$	$P = TP + FN$

Cuadro 2.1: Caso general para matriz de confusión

Mediante la tabla anterior (Cuadro 2.1) es que se definen algunas métricas. En este trabajo, se utilizarán las siguientes:

- Precisión: Valor predictivo positivo. Se calcula como:

$$Precision = \frac{TP}{TP + FP}$$

- Recall: Tasa de Verdaderos Positivos. Se calcula como:

$$Recall = \frac{TP}{P}$$

- F-Measure: Media armónica entre la Precisión y el Recall. Se usa cuando es se desea englobar estos dos indicadores. Se calcula como:

$$F - 1 = \frac{1}{\alpha \cdot \frac{1}{precision} + (1 - \alpha) \frac{1}{recall}}$$

- Área bajo la curva (Auc): Indica la probabilidad de que un clasificador ordenará o puntuará una clasificación positiva elegida aleatoriamente más alta que una negativa. Esta área posee toma valores entre 0,5 y 1, donde 1 representa un valor diagnóstico perfecto y 0,5 es una prueba sin capacidad discriminadora diagnóstica. [11]

Capítulo 3

Creación de índices de congestión

3.1. Creación de índice de congestión EDWIN

Se calculó este índice mediante la siguiente fórmula:

$$\frac{\sum n_i t_i}{N_a (B_T - B_A)} \quad (3.1)$$

Donde,

- n_i = Número de pacientes en el SU agrupados por la categoría i según el triage (Índice de gravedad de Emergencia)
- t_i = Categoría del triage.
- N_a = Cantidad de médicos de turno atendiendo en el SU.
- B_T = Numero de camas de tratamiento en el SU.
- B_A = Número de pacientes ingresados en espera para una cama hospitalaria.

Es importante mencionar que en la literatura existen por lo menos cuatro índices propuestos, sin embargo, sólo se pudo estimar el índice EDWIN con algunas modificaciones. [12]

La variable N_a que corresponde a la cantidad de médicos de turno atendiendo se utilizó según dos tramos horarios:

$$N_a = \begin{cases} 5 & \text{si } 08,00 \leq hora < 02,00 \\ 2 & \text{si } 02,00 \leq hora < 08,00 \end{cases}$$

Para obtener el número de camas $B_T = 46$ camas disponibles, según la información otorgada.

Finalmente, al calcular este índice se obtuvo lo siguiente:

Rangos	Estado	Casos
$EDWIN < 1.5$	Bajo control	25.577
$1.5 \leq EDWIN < 2$	Ocupado	24.515
$EDWIN \geq 2$	Colapsado	23.438

Cuadro 3.1: Frecuencias Índice EDWIN.

Al interpretar los resultados obtenidos en el Cuadro 3.1, es posible ver que las frecuencias entre los 3 estados del SU es similar, obteniéndose que el 34 % de las veces se encuentra Bajo Control, el 33 % está Ocupado y el 32 % restante el Servicio se encuentra Colapsado.

3.2. Creación de un índice de Componentes Principales (CP)

Paralelamente al índice EDWIN, se creó un índice para modelar la variable respuesta LBBS, a través de la técnica de componentes principales, que tiene como objetivo realizar una combinación lineal de las cuatro variables que contienen información de los tiempos en la Urgencia.

Las variables utilizadas fueron:

Tiempo Urgencias, Tiempo Atención, Tiempo Atención Alta, Espera en min

Al ejecutar los códigos respectivos en *RGui*, se obtuvo la siguiente matriz de rotación:

Rotation	PC1	PC2	PC3	PC4
Tpo. Urgencias	0.5452	-0.3908	0.7413	-0.0169
Tpo. Atención	0.5758	0.3233	-0.2368	0.7125
Tpo. Atención Alta	0.2000	-0.7984	-0.5677	0.0119
Espera en min	0.5753	0.3243	-0.2683	-0.7013

Cuadro 3.2: Matriz de rotación Componentes principales

De donde fue posible obtener el primer componente formado por la combinación lineal de cada PC:

$$Z = 0.5452 \cdot \text{TiempoUrgencias} + 0.5758 \cdot \text{TiempoAtencion} + 0.2000 \cdot \text{TiempoAtencionAlta} \\ + 0.5753 \cdot \text{Espera en min}$$

A partir de la siguiente tabla se obtuvo la proporción de varianza explicada por cada componente:

Importancia del componente	PC1	PC2	PC3	PC4
Desviación Estándar	1.6021	1.1765	0.21508	0.05455
Proporción de Varianza	0.6417	0.3460	0.01156	0.00074
Proporción Acumulada	0.6417	0.9877	0.99926	1

Cuadro 3.3: Proporción de Varianza explicada por cada componente

Gráficamente, el componente principal obtenido fue:




Figura 3.1: Proporción de variabilidad explicada por cada componente.

En la Figura 3.1 es posible ver la proporción de variabilidad explicada por cada componente. Como es de notar, el primer componente explica el 64 % de la variabilidad total y éste se puede interpretar como una variable netamente de tiempo, ya que las 4 variables que lo forman aportan pesos positivos a él, aportando de mayor manera las variables Tiempo Atención y Espera en minutos. Para este estudio, de los cuatro componentes creados, nos quedamos con el primero, ya que agrupa bien y explica más del 50 % de la varianza de los datos.

Capítulo 4

Análisis Descriptivo de la Base de Datos

Este capítulo tiene como objetivo analizar los datos de manera exploratoria para introducir en la aplicación a desarrollar.

4.1. Descripción Base de Datos

Se dispone de 73.530 registros correspondientes a los ingresos de pacientes en la ex Posta Central desde Junio del 2014 hasta Junio de 2015. La base contiene distintas variables demográficas como: edad, sexo, comuna, nacionalidad y previsión de salud. Diversas fechas y tiempos de ingreso, categorización, atención y egreso del Servicio de Urgencia y, variables relacionadas con la urgencia como: área de atención, diagnóstico, código del diagnóstico, categorización, causa de urgencia, GES, remitido y LBBS (Variable dicotómica que tomar valor 1 si la persona no fue atendida y 0 si el paciente fue atendido) también fue necesario calcular una variable que permita obtener la Espera en minutos -desde que un paciente es categorizado según su gravedad hasta que es atendido en urgencia-.

4.1.1. Descripción de Variables

Las variables utilizadas se definen como:

- **Grupo etario:** Intervalo correspondiente a la edad del paciente.
- **Sexo:** Género del paciente; Masculino o Femenino.

- **Área:** Área a la que es derivado cada paciente, según su diagnóstico; Dental, Adulto o Traumatología.
- **Fecha de ingreso:** Fecha de ingreso del paciente al sistema.
- **Hora de ingreso:** Hora de ingreso del paciente.
- **Fecha de categorización:** Fecha de categorización para cada paciente.
- **Hora de categorización:** Hora de categorización para el paciente.
- **Fecha de egreso:** Fecha en que el paciente es dado de alta.
- **Hora de egreso:** Hora de salida del servicio de urgencia.
- **Tiempo en urgencia:** Es el tiempo total que permanece un paciente en el servicio de urgencia. Se calcula como la diferencia entre la Hora de egreso y la Hora de ingreso.
- **Tiempo de atención:** Es el tiempo transcurrido entre la Hora de ingreso y la Hora de atención.
- **Código de diagnóstico:** Corresponde a una nomenclatura universal para codificar cada diagnóstico.
- **Descripción del diagnóstico:** Es la descripción a cada enfermedad, según el diagnóstico que presente un paciente.
- **GES:** Explica si la enfermedad es considerada como patología GES o no.
- **Causa urgencia:** Explica el por qué la persona se dirigió al centro asistencial.
- **Categoría:** Es la clasificación que recibe cada paciente según su gravedad a través de la toma de signo vitales como el pulso, glicemia, saturación, entre otros. Se le asigna: *c1*, *c2*, *c3*, *c4* y *c5*. Donde *c1* y *c2*, son pacientes que generalmente están en riesgo vital, por ende, tienen prioridad de ser atendidos.
- **Día de la semana:** Día de la semana en que el paciente recurre al Servicio de Urgencia.
- **Previsión:** Previsión de salud del paciente; Fonasa A, B, C o D, Isapre o Particular.
- **Nacionalidad:** Nacionalidad del paciente: Chileno, Latinoamérica u Otra nacionalidad.
- **Comuna:** Comuna donde vive el paciente.
- **Remitido:** Lugar que envía al paciente a urgencia.

- **LBBS:** Variable que indica si el paciente se retira antes de ser atendido en la urgencia.
- **Espera en minutos:** Corresponde a la cantidad de minutos de espera que tiene un paciente en el intervalo de tiempo desde que es categorizado según su gravedad hasta que es atendido en el Servicio de Urgencia.

4.2. Variables Cuantitativas

Variable	Media	Dev. Std	Varianza	Mín	Máx	Per 1	Per 99
Años	42.60	18.53	343.63	15	99	15	88
Día ingreso	15.60	8.80	77.52	1	31	1	31
Mes ingreso	5.53	3.32	11.08	1	12	1	12
Año ingreso	2014	0.47	0.22	2014	2015	2014	2015
Hora ingreso	13.55	5.82	33.95	0	23	0	23
Minutos ingreso	29.52	17.35	301.27	0	59	0	59
Hora	1.39	2.93	8.63	0	23	0	15
Minutos	24.84	16.89	285.30	0	59	0	59
Espera en minutos	108.26	179.04	32056.62	0	1439.0	1	950
Mes	5.53	3.32	11.08	1	12	1	12
Hora categorizada	13.15	6.15	37.91	0	23	0	23

Cuadro 4.1: Estadísticos variables cuantitativas.

El Cuadro 4.1 muestra los estadísticos de sumariación para las variables cuantitativas. Entre todas las medidas obtenidas, se utiliza como criterio de corte el Percentil 1 y el Percentil 99 (eliminando sólo el 1 % de los registros) para la variable *Espera en minutos*, lo que permitirá eliminar datos atípicos y así poder visualizar de mejor manera los futuros gráficos pertinentes según el tipo de variable.

Variable	Media	Dev. Std	Varianza	Mín	Máx	Per 1	Per 99
Años	42.60	18.53	343.61	15	99	15	88
Día ingreso	15.60	8.80	77.57	1	31	1	31
Mes ingreso	5.53	3.33	11.11	1	12	1	12
Año ingreso	2014	0.47	0.22	2014	2015	2014	2015
Hora ingreso	13.56	5.81	33.83	0	23	0	23
Minutos ingreso	29.52	17.35	301.20	0	59	0	59
Hora	1.30	2.67	7.13	0	23	0	13
Minutos	24.78	16.86	284.39	0	59	0	59
Espera en minutos	96.91	138.37	19147.06	0	950	1	714
Mes	5.53	3.33	11.09	1	12	1	12
Hora categorizada	13.16	6.15	37.82	0	23	0	23

Cuadro 4.2: Estadísticos variables cuantitativas post corte de percentiles.

Al realizar el filtro con el criterio de los Percentiles 1 y 99, se obtiene el Cuadro 4.2 donde se muestran las estadísticas de resumen a utilizar. En promedio, los pacientes que asisten al Servicio de Urgencia tienen 43 años. La espera en minutos para que un paciente sea atendido varía desde 0 hasta 950, con una espera promedio de 96,91 minutos con una variación de 138,37 aproximadamente.

4.3. Variables Cualitativas

Grupos Etarios	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
15 - 19	11.473	7,03	11.473	7,03
20 - 24	19.883	12,18	31.356	19,21
25 - 29	20.206	12,38	51.562	31,59
30 - 34	15.753	9,65	67.315	41,24
35 - 39	13.096	8,02	80.411	49,26
40 - 44	13.167	8,07	93.578	57,33
45 - 49	13.336	8,17	106.914	65,50
50 - 54	13.839	8,48	120.753	73,98
55 - 59	10.798	6,62	131.551	80,59
60 - 64	8.163	5,00	139.714	85,59
65 - 69	7.082	4,34	146.796	89,93
70 - 74	5.492	3,36	152.288	93,30
75 - 79	4.168	2,55	156.456	95,85
80 y más	6.776	4,15	163.232	100,00

Cuadro 4.3: Frecuencias Grupos Etarios.

El Cuadro 4.3 muestra que la mayoría de las personas que asisten a este centro asistencial tienen edades que fluctúan entre los 20 y 29 años y, que los pacientes que menos consultan en urgencia tienen entre 70 y 79 años.

Sexo	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Femenino	78.679	48,18	78.679	48,18
Masculino	84.630	51,82	163.309	100,00

Cuadro 4.4: Frecuencias Sexo.

El Cuadro 4.4 muestra que de los pacientes, el 51,82 % son hombres, mientras que el 48,12 % restantes son mujeres, por lo que se puede notar que los hombres asisten con mayor frecuencia al Servicio de Urgencia.

Área	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Adulto	87.869	53,81	87.869	53,81
Dental	58.774	35,99	146.643	89,79
Trauma	16.666	10,21	163.309	100,00

Cuadro 4.5: Frecuencias Área.

En el Cuadro 4.5 se muestran las frecuencias para el área de atención según el diagnóstico del paciente. El área adulto es el que concentra la mayor cantidad de atenciones con un 53,81 % del total.

El Cuadro 7.1 (ver Anexo I) muestra que la gran mayoría de las atenciones son consideradas como patología GES (Garantías Explícitas en Salud), lo que constituye un conjunto de beneficios garantizados por Ley para las personas afiliadas a Fonasa e Isapres.

Categoría	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
C1	796	0,49	796	0,49
C2	6.430	3,94	7.226	4,42
C3	99.559	60,96	106.785	65,39
C4	51.368	31,45	158.153	96,84
C5	5.156	3,16	163.309	100,00

Cuadro 4.6: Frecuencias Categoría.

El Cuadro 4.6 muestra las 5 categorías dentro de la Urgencia. La mayoría de los pacientes es categorizado como C3, es decir, es un paciente que asiste a urgencia sin mayor gravedad, en cambio, sólo el 0,49 % del total asiste a la urgencia realmente por alguna consulta de extremada urgencia.

Día de la semana	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Lunes	27.777	16,70	71.307	43,66
Martes	24.655	15,10	95.962	58,76
Miércoles	23.346	14,30	119.308	73,06
Jueves	23.209	14,21	44.030	26,96
Viernes	22.389	13,71	163.309	100,00
Sábado	21.612	13,23	140.920	86,29
Domingo	20.821	12,75	20.821	12,75

Cuadro 4.7: Frecuencias Día de la semana.

El cuadro 4.7 muestra los días la semana, donde los pacientes recurren al centro asistencial. Es posible ver que el día que más requerimientos hay es el día Lunes, manteniéndose relativamente constante hasta el día Viernes y bajando de manera notoria la cantidad de consultas, los días Domingo.

El cuadro 7.2 (ver Anexo II) muestra la nacionalidad de los pacientes, donde el 91,99 % de ellos son de nacionalidad Chilena.

Previsión de salud	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
FONASA A	28.666	17,55	28.666	17,55
FONASA B	61.807	37,85	90.473	55,40
FONASA C	24.967	15,29	115.440	70,69
FONASA D	31.829	19,49	147.269	90,18
ISAPRE	4.094	2,51	151.363	92,69
Particular	11.946	7,31	163.309	100,00

Cuadro 4.8: Frecuencias Previsión de salud.

El cuadro 4.8 muestra que la mayoría de los pacientes tiene previsión de salud Fonasa tipo A y la minoría tiene Isapre. También hay un pequeño porcentaje que se atiende de manera particular.

El cuadro 7.3 (ver Anexo III) muestra la comuna residente de los pacientes que asisten a la posta central. Siendo las personas de la comuna de Santiago las que asisten con mayor frecuencia a este recinto hospitalario.

El cuadro 7.4 (ver Anexo IV) muestra las frecuencias para la variable Remitido, la que indica de dónde fue remitido el paciente. La mayoría de los consultantes asistió de manera voluntaria a la atención de urgencia (89,71 %).

El cuadro 7.5 (ver Anexo V) muestra las frecuencias para la variable Causa Urgencia. La mayor causa de urgencia la presenta Enfermedad común con un 75,20 %.

4.4. Análisis Tiempos de Espera

Para estudiar la *Espera en minutos* dentro del Servicio de Urgencia, se analizará esta variable respecto a la información disponible en la base de datos.




Figura 4.1: Box plot Espera - Área

Según la Figura 4.1, para el área Adulto: el 1 %, el 50 % y el 99 % de los pacientes tienen tiempos de espera de atención que no superan los 0, 86 y 802 minutos respectivamente. Siendo esta área la que presenta los mayores tiempos de espera en el servicio de urgencia.

Lo más importante de este gráfico es que la espera en el área adulto es más alta que en las otras dos áreas, ya que es donde se concentra en esta área se concentra la mayor cantidad de pacientes, porque es el área que abarca casi todas las especialidades de este SU.




Figura 4.2: Box plot Espera - Categoría

Según la Figura 4.2, para la categoría C1: el 50 % y el 99 % de los pacientes tienen tiempos de espera de atención que no superan los 4 y 208 minutos respectivamente. Por otro lado, el 99 % de los pacientes categorizados como C4 no espera más de 577 minutos para ser atendidos. La categoría C4 es la que presenta mayor tiempo de espera promedio con 159 minutos. Las categorías C4 y C5 son las que presentan mayores tiempos de espera, esto se debe a que son pacientes que asisten por problemas de salud que no son de riesgo vital, dándose siempre mayor prioridad y por ende menos espera a los pacientes más graves.

Al ser una variable que presenta bastante heterogeneidad entre sus categorías, podría ser influyente al momento de estudiar las variables relacionadas con el tiempo.




Figura 4.3: Box plot Espera - Día de la semana

Según la Figura 4.3, es posible ver que el tiempo de espera según los días de la semana a simple vista se ven homogéneos, sin embargo, los días lunes y martes es cuando los pacientes esperan mayor cantidad de tiempo para ser atendidos, los días miércoles, jueves, viernes y sábado los tiempos de espera son similares, disminuyendo de manera notoria los días domingo, esto debido a que ese día presenta menos consultas de urgencia, por ende, menos tiempo de espera.




Figura 4.4: Box plot Espera - LBBS

Según la Figura 4.4, para la categoría 0 de esta variable, los pacientes esperaron 79 minutos para ser atendidos y para la categoría 1 esperan en promedio 312 minutos, como es de notar existe un gran diferencia entre la espera de un paciente que es atendido y de un paciente que se retira sin recibir asistencia médica. EL 99% de las personas no esperó más de 566 minutos en la categoría 0 y 913 minutos en la categoría 1.00

Esta variable presenta gran variabilidad en sus categorías, por lo que podría ser un buen predictor para las de tiempos.




Figura 4.5: Box plot Espera - Previsión

En la Figura 4.5 es posible observar que la mayor cantidad de personas que consulta en este centro asistencial tiene Fonasa tipo B correspondiendo al 37,8% de los pacientes. Las personas que están más dispuestas a esperar tienen Fonasa A y B, lo que tiene bastante sentido, ya que estos pacientes sólo pueden atenderse en consultorios y hospitales públicos. Por el contrario, las personas que asisten de manera particular y con Isapre están dispuestos a esperar menor cantidad de tiempo para recibir atención de urgencia, sin embargo, los tiempos de espera según previsión de salud son bastante similares en cada categoría, aunque los pacientes que tienen Isapre esperan menos tiempo, esto puede deberse a que si una persona espera mucho tiempo y no es atendida, puede trasladarse a un centro que tenga menor congestión.

4.5. Análisis del tiempo de espera durante los días de la semana y meses del año

Para analizar los datos de este Servicio de Urgencia; se obtuvo dos series temporales que entregan el tiempo de espera a lo largo de los días de la semana y de los meses del año.




Figura 4.6: Serie temporal semanal.

En la Figura 4.6, se observa que los intervalos horarios que presentan mayor espera son de madrugada, es decir, de 00.00 a 05.00 hrs. Disminuyen en el transcurso de la mañana y se mantienen altos durante el horario de trabajo para el común de las personas. Luego, de 20.00 a 23.00 hrs aproximadamente se presenta un nuevo aumento en el tiempo de espera. Esto es similar de Lunes a Viernes, ya que el fin de semana, la espera es mayor durante la medianoche debido al aumento de consultas por accidentes de tránsito, entre otros accidentes.

El día lunes tiene mayor espera a lo largo del día. El día sábado presenta la menor cantidad de espera, debido a una menor congestión intrahospitalaria, ya que por lo general los fines de semana hay menos consultas de urgencia.




Figura 4.7: Serie temporal mensual.

En la figura 4.7, es posible ver que la mayoría de los meses tiene tiempos de espera similares, sin embargo, el mes de Julio se escapa notoriamente, teniendo los mayores tiempos de espera a distintas horas del día. Esto se debe a que es un mes de invierno, en donde se registran la mayor cantidad de consultas por enfermedades respiratorias. El comportamiento es similar al de los días de la semana, porque la espera es mayor en la madrugada, disminuye considerablemente entre las 05 y 10 hrs, para luego aumentar y mantenerse constante durante el horario de oficina, luego vuelve a descender después de las 20.00 hrs.

4.6. Análisis del índice de congestión con Componentes Principales




Figura 4.8: Box plot Componente Principal - LBBS.

En la Figura 4.8 es posible observar que el componente principal influye de distinta manera en la variable respuesta LBBS (0 si un paciente es atendido y 1 si se retira antes de recibir atención.)

La caja que corresponde a la respuesta 0 presenta más dispersión en la distribución de sus datos, al ser más alargada su caja y los bigotes, pero también es más simétrica con respecto a la distribución de cuando los pacientes se van sin ser atendidos. Además, para esta nueva variable, componente principal, que corresponde a la combinación lineal de las variables que miden tiempo en el Servicio de Urgencia, es posible interpretar que los pacientes que se van sin ser atendidos, esperan mayor cantidad de tiempo que los pacientes que sí se atienden. Lo más interesante de este gráfico es que se puede ver que para la categoría 0 (pacientes atendidos) están los valores menores del índice. Por el contrario, para la categoría 1 hay mayor combinación lineal de las variables de tiempo, es decir, mayor espera, lo que comprueba que los pacientes que más tiempo están esperando para ser atendidos son los que finalmente deciden irse sin recibir atención dado el alto nivel de congestión en el SU, situación que ayuda a validar este índice para explicar la congestión.




Figura 4.9: Box plot Componente Principal - Área.

En la Figura 4.9 se presenta un diagrama de cajas para el componente principal versus el el área, donde se observa que la distribución para cada caja es simétrica. Para el área Adulto, el componente presenta sus valores más grandes y por ende, para el área traumatológica se obtienen los menores valores para él. Esto tiene bastante sentido, ya que en el área Adulto es donde se concentran la mayoría de las patologías que atiende este SU, por lo tanto, es donde las personas tendrán que esperar mayor cantidad de tiempo para ser atendidas. Es necesario recordar que el componente principal representa la combinación lineal de las cuatro variables relacionadas con unidades de tiempo dentro de la base de datos analizada.




Figura 4.10: Box plot Componente Principal - Categoría.

En la Figura 4.10 se observa que para las categorías del triage, las distribuciones son más bien simétricas, excepto para la categoría *C1*. Con respecto a la combinación lineal de los tiempos de espera, se visualiza claramente que para las categorías *C1* y *C2* los pacientes esperan menor cantidad de tiempo para ser atendidos, esto debido a que son pacientes más graves. Por el contrario, para tres categorías restantes, la combinación lineal de los tiempos de espera va aumentando a medida que la gravedad de los pacientes es menor. Esto tiene bastante sentido, ya que es de conocimiento general, que el orden de atención en el SU no es por orden de llegada sino que por gravedad del paciente.




Figura 4.11: Box plot Componente Principal - Día de la semana.

En la Figura 4.11 se demuestra que para las distribuciones entre los días de la semana son más bien asimétricas. Desde el día lunes hasta el miércoles se presentan la mayor cantidad de combinación lineal de tiempos de espera, disminuyendo los días jueves y viernes hasta llegar al día domingo donde se presentan los menores tiempos de espera




Figura 4.12: Box plot Componente Principal - Previsión.

En la Figura 4.12 se observa un comportamiento similar al visto en el Box plot de la variable respuesta - *Espera_min*, ya que los pacientes que tienen Fonasa esperan mayor cantidad de tiempo que un paciente que tiene Isapre. Esto se debe a que una persona que tiene Isapre puede atenderse en otro centro asistencial, no sólo en un Hospital Público como es el caso de las personas con Fonasa tipo A. Como se dijo anteriormente, este gráfico resume de manera adecuada un comportamiento visto en un box plot anterior.

4.7. Análisis del índice de congestión EDWIN




Figura 4.13: Box plot EDWIN - LBBS.

En la Figura 4.13 es posible ver que al estudiar el índice de congestión EDWIN sobre la variable respuesta LBBS, para el valor 0 y 1 la distribución de los datos es bastante simétrica, no presentando diferencias significativas entre sus cuartiles, medianas y medias aritméticas. Lo que podría significar que el índice no estaría separando de manera correcta a los pacientes atendidos y no atendidos, porque no existe diferencia significativa entre una respuesta y la otra, lo que debiese manifestarse como mayor al momento de saber que un paciente no se atiende.

Para ambos casos, el índice muestra que el 75 % de los pacientes que van a este Servicio de Urgencia, se les asigna un índice menor o igual al valor 2, lo que indicaría que estos pacientes se retiran o a su vez, son atendidos, cuando el Servicio no se encuentra aún congestionado, sino que ocupado.




Figura 4.14: Box plot EDWIN - Área.

En la Figura 4.14 es posible ver que para el Área de atención, se presentan distribuciones bastante simétricas, lo que no es de esperar. Sabemos que el área adulta abarca la mayor cantidad de especialidades que tiene este SU, por lo que indicar que este índice no separaría de manera correcta a los pacientes que se atienden y los que son atendidos, produce aún más contradicción al momento de compararlo con los resultados obtenidos por el componente principal, el que si se acercaría más a la situación real de la urgencia.




Figura 4.15: Box plot EDWIN - Día de la semana.

En la Figura 4.15 es posible ver la situación que se presenta en los días de la semana. Donde observamos que las distribuciones para ellos son más bien simétricas. Situación que realmente no sería así, ya que se dijo anteriormente, que los días lunes en promedio son los que presentan mayores consultas y por ende, mayores tiempos de espera. Este índice tampoco separaría de manera correcta las muestras para su variable respuesta.




Figura 4.16: Box plot EDWIN - Mes.

En la Figura 4.16 es posible ver, al igual que en la Figura 4.17, que según los meses del año no se presentan grandes diferencias al momento de medir la congestión. Situación un poco contradictoria, ya que es sabido que en los meses de invierno aumentan las consultas y por ello los tiempo de espera, debido a epidemias respiratorias. Para este caso, el índice EDWIN no estaría siendo tan representativo.

Capítulo 5

Aplicación Algoritmo de Clasificación

Para poder realizar la aplicación, se utilizarán las dos bases de datos facilitadas por el área informática del Hospital de Urgencia Asistencia Pública a lo largo de todo el estudio, siguiendo los pasos que se detallan a continuación:

Luego de realizar el análisis descriptivo de la información disponible, fue necesario crear una variable para asignar el número camas según día, mes, año y horas disponibles. Se creó a partir de la base de censos que se realizan cuatro veces al día en el sector de hospitalizados en la Urgencia. Este censo se lleva a cabo a las 01.00, 07.00, 13.00 y 19.00 durante todos los días del año y en él se cuentan a todas las personas que se encuentran hospitalizadas en dicha unidad del Hospital en el momento del censo. Entonces, para poder asignarle a cada paciente de los 73.530 la cantidad de camas que había ocupadas al momento de su atención en la posta, se realizó un cruce a través de un algoritmo recursivo, lo que permitió la asignación correcta de la cantidad de camas a cada uno de los pacientes.

Al obtener la nueva variable, fue posible introducirla al cálculo del índice propuesto en la literatura disponible: EDWIN.

5.1. Implementación Adaboost.M1

Para realizar la clasificación de los modelos a estimar se utilizó algoritmo Adaboost.M1 (caso particular del método Boosting) con función de pérdida exponencial. Este es un algoritmo que tiene como función convertir un clasificador débil en otro considerablemente más fuerte. La implementación del algoritmo es a partir de la paquete *Adabag* en *RGui*, donde el clasificador base es el algoritmo CART. El algoritmo CART es un método utilizado para construir un clasificador de forma recursiva y que se representa como un árbol, lo que convertirá al clasificador débil en uno fuerte.

De la implementación del algoritmo Adaboost.M1 se obtiene tres modelos, donde la respuesta es binaria y corresponde a 0 si el paciente si se atiende en el Servicio de Urgencia y 1 si se va antes de recibir atención.

5.2. Validación cruzada 10- Fold Cros-Validation

El método de validación utilizado en el conjunto para inducir el clasificador final es el método de validación cruzada o Cross-Validation (ver capítulo 2.6.2). Funciona particionando la data en K subconjuntos iguales de los cuales K-1 corresponderán a la muestra de entrenamiento y el restante a la muestra de prueba. Este proceso se repite K veces sobre las combinaciones de los K-1 subconjuntos para entrenar y el restante para testear o probar. En esta investigación se utilizó un K=10.

5.3. Importance Plot

En primer lugar, se realiza un gráfico de la importancia que aporta cada variable a los respectivos modelos, a través del Importance Plot, realizado para cada uno de los tres modelos estimados.

El importance plot mide la importancia relativa de cada variable en el problema de clasificación. Para obtener este gráfico se utiliza la ganancia del índice de Gini dado por una variable en un árbol y, en el caso del Boosting, el peso de este árbol.

El índice de Gini es el coeficiente de Gini expresado en porcentaje (multiplicado por 100). Su fórmula es:

$$G = \left| 1 - \sum_{k=1}^{n-1} (X_{k+1} - X_k)(Y_{k+1} + Y_k) \right| \quad (5.1)$$

Donde,

G = coeficiente de Gini.

X = Proporción acumulada de las variables independientes.

Y = Proporción acumulada de la variable dependiente.

Importances Plots




Figura 5.1: Importance plot primer modelo.

En la Figura 5.1 se muestra que la variable que mejor explica la respuesta LBBS es el Componente Principal, con un índice de Gini superior a 80, siendo la variable que supera con creces el aporte que cualquiera de ellas hace a alguno de los tres modelos. Esta variable cumple el propósito esperado, porque es altamente predictiva, además es una combinación lineal de las cuatro variables más importantes al momento de estudiar la congestión y por ende, si un paciente espera hasta ser atendido o no. Las variables que menor importancia tienen al momento de explicar la respuesta binaria de un paciente que se atiende o no son: Mes de ingreso, día ingreso, año ingreso, sexo, nacionalidad, Hora categorización, día de la semana y minutos ingreso.




Figura 5.2: Importance plot segundo modelo.

En la Figura 5.2 se observa que las variables relacionadas con el tiempo son las más influyentes al momento de predecir si un paciente se atiende o no en el SU. Tiempo Atención, Tiempo Urgencias, Categoría, Espera en min y Tiempo Atención son las que tienen un mayor índice de Gini para este modelo. Por otra parte, las variables que menos aportarían al modelo son área, sexo, día ingreso, previsión, entre otras.




Figura 5.3: Importance plot tercer modelo.

En la Figura 5.3 se presenta el Importance Plot para el modelo que tiene incorporado el índice EDWIN, en este gráfico se observa que las variables que más aportan al momento de predecir la respuesta son: Tiempo atención alta, Tiempo Urgencia, Tiempo Atención y Espera en minutos. Las variables menos influyentes son: Minutos ingreso, Hora categorización, Mes, Previsión de salud, Nacionalidad, día de ingreso y el índice EDWIN.

5.4. Matriz de confusión

También es posible interpretar de este algoritmo, para los tres modelos mencionados anteriormente, la matriz de confusión que entrega cada uno de ellos:

classfinal		
pred	0	1
0	81 %	9 %
1	3 %	7 %

Cuadro 5.1: Matriz de clasificación primer modelo

classfinal		
pred	0	1
0	83 %	6 %
1	1 %	10 %

Cuadro 5.2: Matriz de clasificación segundo modelo

classfinal		
pred	0	1
0	83 %	6 %
1	1 %	10 %

Cuadro 5.3: Matriz de clasificación tercer modelo

De los 3 modelos estimados, al observar sus matrices de confusión; los modelos con variables de tiempo y con el índice EDWIN clasifican de mejor manera los verdaderos positivos y negativos (en el mismo porcentaje) en cambio, el modelo que contiene el Componente Principal clasifica de peor manera las respuestas 0 o 1 en cada caso.

5.4.1. Validación: Medidas de Performance

Finalmente, para validar este algoritmo de clasificación se calculan las medidas de performance (definidas en detalle en el capítulo 2.6.3) que se muestran a continuación:

Medidas	con CP	con Var. de Tpo.	con EDWIN
α	0.0668	0.5351	0.5370
Auc	0.8532	0.9180	0.9180
Precisión	0.2586	0.8986	0.8941
Recall	0.9189	0.5838	0.5832
F-Measure.	0.403	0.7078	0.7060

Cuadro 5.4: Resumen para Medidas de Performance para tres modelos propuestos.

De los tres modelos estimados mediante el algoritmo Adaboost.M1 para predecir si un paciente fue atendido o no en el Servicio de Urgencia, se obtuvo que los dos mejores fueron el modelo que contiene las variables de tiempo por separado (modelo dos) y el modelo con el índice de congestión EDWIN, porque tiene la medida $F = 0,7$, también se observa que la medida de *Precisión* es muy alta con un valor de 0,89 para ambos modelos, valor que aumenta al haber pocos casos falsos positivos. (Cuadro 5.4)

El área bajo la curva *Auc* abarca más del 90 % para ambos modelos. Todas estas características presentadas, permiten validar el modelo dos y tres como los más óptimos al momento de predecir si un paciente es atendido o no en el Servicio de Urgencia.

Capítulo 6

Conclusiones

En este seminario de tesis fue posible analizar un problema típico de Salud Pública en Chile, como lo es la congestión en el Servicio de Urgencia de la ex Posta Central, con técnicas de Minería de Datos a través de la implementación del método iterativo Boosting, utilizando el algoritmo Adaboost.M1.

Con el fin de estudiar el nivel de congestión, se crearon dos índices para estudiar esta problemática en el SU: el índice EDWIN, ya propuesto en la literatura se creó mediante aproximaciones de la fórmula general, ya que no se disponía de las mismas variables que éste incorpora al momento de calcularlo. Con él, fue posible evidenciar que en el SU existe una proporción similar de casos para cuando la urgencia está Bajo control, Ocupada o Colapsada, aún cuando el servicio se encuentre en su mayor parte ocupado. Se espera que el cálculo e interpretación de este índice sirva como referencia para estudios futuros, donde sería interesante crear un índice particular para esta Urgencia, con medidas que realmente lo representen y que sean influyentes para representar el problema de la congestión, además de que permitan y ayuden a las autoridades tomar medidas al respecto para combatir de manera eficaz dicha problemática.

Por otra parte, el índice creado a partir de componentes principales, fue creado mediante la combinación lineal de las cuatro variables. Aquí es donde se centró la investigación, ya que este índice demostró de manera descriptiva y dentro del algoritmo, su gran capacidad para aportar al momento de predecir la variable respuesta LBBS. Fue posible validarlo de doble manera, ya que logró aportar la mayor información en el modelo de clasificación que se utilizó, explicando con creces la variable respuesta, además al momento de validarlo con las medidas de performance, también entregó valores aceptables para su validación. Además, sirvió a modo de comparación con el índice EDWIN, siendo bastante más representativo e influyente que este índice propuesto

en la literatura anglosajona.

Al haber ejecutado los tres modelos con el algoritmo Adaboost.M1, se validó como mejor modelo el que contenía las variables de tiempo por separado, ya que con él se obtuvo mayores valores para las medidas de performance, entre ellas la medida F , comprobando así, que este segundo modelo con todas las variables que lo formaron predijo y explicó de mejor manera la respuesta binaria que entrega información sobre un paciente al momento de atenderse o no en el Servicio de Urgencia.

Bibliografía

- [1] Alfaro, A. Gamez, E., et al (2014), *Applies Multiclass AdaBoost.M1, SAMME and Bagging*.
- [2] Elorrieta F. (2015). *Apuntes curso Seminario II: Data Mining*. Universidad de Santiago de Chile, Santiago, Chile
- [3] Freund, Y. & Schapire, R. (1999). *A Short Introduction to Boosting*. Taylor Journal of Japanese Society for Artificial Intelligence.
- [4] Friedman, Hastie & Tibshirani. (2009). *SLDM III Cross-validation and bootstrap* .
- [5] Friedman, Hastie & Tibshirani (2008) *The Elements of Statistical Learning Data Mining, Inference and Prediction*. Preface to the Second Edition.
- [6] Gutierrez, R. (2000). *Intelligent Sensor Systems*. Wright State University.
- [7] Joanneum, H. (2005) *Cross-Validation Explained*. Institute for Genomics and Bioinformatics.
- [8] Melissa L. McCarthy, MS, ScD Dominik Aronsky, MD, PhD Ian D. Jones, MD James R. Miner, MD Roger A. Band, MD Jill M. Baren, MD, MS Jeffrey S. Desmond, MD Kevin M. Baumlin, MD Ru Ding, MS Robert Shesser, MD, MPH (2008). *The Emergency Department Occupancy Rate: A Simple Measure of Emergency Department Crowding*. The American College of Emergency Physicians.
- [9] Miquel R., (2010). *Flujo de pacientes en el Servicio de Urgencia : estudio sobre el congestionamiento y bloqueo de acceso*. Universidad de Santiago de Chile, Santiago, Chile
- [10] Peña, D. (2002) *Análisis de Datos Multivariantes*, Componentes Principales.
- [11] Sing, T., Sander O., Beerenwinkel N. and Lengauer T.,(2015). *Visualizing the Performance of Scoring Classifiers*.

- [12] Spencer S. Jones, MStat, Todd L. Allen, MD, Thomas J. Flottemesch, PhD, Shari J. Welch, MD. (2006). *An Independent Evaluation of Four Quantitative Emergency Department Crowding Scales*. The Society for Academic Emergency Medicine.
- [13] Steven J. Weiss, MD, Amy A. Ernst, MD, Todd G. Nick, PhD (2006). *Comparison of the National Emergency Department Overcrowding Scale and the Emergency Department Work Index for Quantifying Emergency Department Crowding*.
- [14] Timothy J. Reeder, MD, MPH, Deeanna L. Burleson, RN, MSN, Herbert G. Garrison, MD, MPH (2003). *The Overcrowded Emergency Department: A Comparison of Staff Perceptions*. ACADEMIC EMERGENCY MEDICINE 2003; 10:1059–1064.

Capítulo 7

Anexos

7.1. Tablas y Gráficos

1. Anexo I: Tabla de frecuencias GES

GES	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Sí	13.613	99,99	13.615	100,00
No	2	0,01	2	0,01

Cuadro 7.1: Frecuencias GES.

2. Anexo II: Tabla de frecuencias Nacionalidad

Nacionalidad	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Chileno	150.164	91,99	150.164	91,99
Latinoamericano	11.621	7,12	161.785	99,11
Otro	1.447	0,89	163.232	100,00

Cuadro 7.2: Frecuencias Nacionalidad.

3. Anexo III: Tabla de frecuencias Comuna

Comuna	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Cerrillos	6.353	3,89	6.353	3,89
Estación Central	20.186	12,36	26.539	16,25
Maipú	15.786	9,67	42.325	25,92
Otros servicios	3.837	2,35	46.162	28,27
SSMN	22.043	13,50	68.205	41,76
SSMO	30.065	18,41	98.270	60,17
SSMS	6.400	3,92	104.670	64,09
SSMSO	9.938	6,09	114.608	70,18
Santiago	48.701	29,82	163.309	100,00

Cuadro 7.3: Frecuencias Comuna.

4. Anexo IV: Tabla de frecuencias Remitido

Remitido	Frecuencia	Porcentaje	Frec. acumulada	Porcentaje acumulado
Atención Primaria	6.162	3,77	6.162	3,77
Carabineros	2.225	1,36	8.387	5,14
Hospital	2.218	1,36	10.605	6,49
Otro centro	2.910	1,78	13.515	8,28
SAMU 1	2.056	1,26	15.571	9,53
SAMU 2	826	0,51	16.397	10,04
SAMU 3-4	412	0,25	168.809	10,29
Voluntario	146500	89,71	163.309	100,00

Cuadro 7.4: Frecuencias Remitido.

5. Anexo V: Tabla de frecuencias Causa Urgencias

Causa Urgencia	Frecuencia	Porcentaje	Frec. acumulada	% acumulado
Abuso sexual	61	0,04	61	0,04
Accidente Deportivo Federado	4	0,00	65	0,04
Accidente Escolar	1.402	0,86	1.467	0,90
Accidente Masivo o Espectáculo Público	59	0,04	1.526	0,93
Accidente animal peligroso	1.161	0,71	2.687	1,65
Accidente casual	13.710	8,40	16.397	10,04
Accidente de Tránsito	4.744	2,90	21.141	12,95
Accidente de Trabajo	437	0,27	21.578	13,21
Agresión	2.829	1,73	24.407	14,95
Caída vía pública	1.007	0,62	25.414	15,56
Constatación Lesiones	3.376	2,07	28.790	17,63
Control dental	7.957	4,87	36.747	22,50
Control paciente extra sistema	10	0,01	36.757	22,51
Control quemados	48	0,03	36.805	22,54
Control trauma	2.710	1,66	39.515	24,20
Enfermedad común	122.810	75,20	162.325	99,40
Enfermedad profesional	142	0,09	162.467	99,48
Estupro	7	0,00	162.474	99,49
Evento 1	21	0,01	162.495	99,50
Evento 2	4	0,00	162.499	99,50
Intento de suicidio	131	0,08	162.630	99,58
Intoxicación	607	0,37	163.237	99,96
Orden judicial	22	0,01	163.259	99,97
Otra violencia de género	34	0,02	163.293	99,99
Salud laboral	9	0,01	163.302	100,00
Violación	7	00,00	163.309	100,00

Cuadro 7.5: Frecuencias Causa Urgencia.