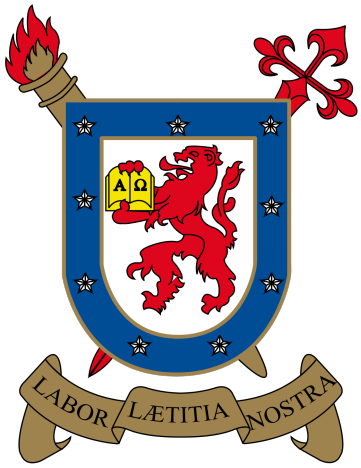
UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE CIENCIA
DEPARTAMENTO DE MATEMÁTICA Y CIENCIA DE LA COMPUTACIÓN



Extracción de características desde estimaciones en línea del Modelo Autorregresivo Irregular(iAR)

Trabajo de titulación presentado a la facultad de ciencia en cumplimiento de los requisitos exigidos para optar al título de Ingeniero Matemático de la Universidad de Santiago de Chile.

Estudiante: Juan Carlos Cornejo Toledo

Profesor guía: Dr. Felipe Elorrieta

Miembros de la comisión:

Galina García

Francisco Plaza Vega

Santiago - Chile

Octubre 2024

Resumen

Las curvas de luz, que describen las variaciones en el brillo de objetos astronómicos, son fundamentales para su estudio y clasificación. En este trabajo, utilizamos estas mediciones para generar características con el objetivo de estudiar su relevancia para la clasificación de subclases de dos tipos de objetos astronómicos: estocásticos y transientes, que incluyen cinco y cuatro subclases, respectivamente. La clasificación en este trabajo se basa en el esquema utilizado por el broker astronómico ALeRCE (Automatic Learning for the Rapid Classification of Events). Las curvas de luz de los objetos se observan en dos bandas, g y r, que representan series temporales con intervalos de tiempo irregulares.

La construcción y el cálculo de las características se llevan a cabo mediante tres métodos de estimación en línea del parámetro ϕ asociado al modelo iAR: iAR Online Newton Step (iAR-ONS), iAR Online Gradient Descent (iAR-OGD) e iAR Online Bayesian Regression (iAR-OBR). A partir de estas estimaciones, se definen diversas fórmulas estadísticas que permiten calcular un total de 27 características.

Para evaluar la relevancia de las características, se aplican clasificadores como Random Forest y Gradient Boosting, de los cuales se obtienen los valores de importancia para las características mediante métricas como la impureza de Gini, la entropía o el error cuadrático medio. En el caso de los objetos estocásticos, destacan dos características derivadas del método iAR-OGD: la desviación estándar y la varianza de la estimación, particularmente en la banda r, donde la importancia promedio de una es superior en un 23.8 % a la característica de referencia, y la otra en un 18.1 %. Para los objetos transientes, la varianza y la kurtosis derivada de la estimación del método iAR-OGD también muestra una importancia superior, con incrementos del 30.1 % y 38.1 % en las bandas g y r, respectivamente, en comparación con la característica de referencia.

En conclusión, se identifican características relevantes para ambos tipos de objetos, destacando que el método de estimación en línea que resultó ser más efectivo para obtener estas características fue el iAR-OGD.

Indice

1. Introducción **1**

1.1. Objetivos . . . 3

1.1.1. Objetivo General . . . 3

1.1.2. Objetivos Específicos . . . 3

2. Preliminares **4**

2.1. Curva de luz . . . 4

2.2. Clasificador de curvas de luz . . . 5

2.3. Teoría de Series de tiempo . . . 7

2.3.1. Serie de tiempo . . . 7

2.3.2. Proceso Estocástico . . . 8

2.3.3. Estacionariedad (débil y fuerte) . . . 8

2.3.4. Función de Autocovarianza . . . 9

2.3.5. Función de Autocorrelación . . . 9

2.3.6. Ruido Blanco (Discreto) . . . 10

2.3.7. Modelo AR . . . 10

2.3.8. Modelo MA . . . 12

2.3.9. Modelo ARMA . . . 13

2.3.10. Modelo Autorregresivo irregular (iAR) . . . 14

2.4. Métodos de estimación del parametro ϕ asociado al Modelo iAR . . . 16

2.4.1. Método de estimación por Máxima Verosimilitud . . . 16

2.4.2. Espacio de estados . . . 17

2.4.3. Filtro de Kalman . . . 18

2.4.4. Métodos de estimación online para el modelo iAR . . . 19

2.5. Técnicas de análisis y modelación estadística: . . . 21

2.5.1. Random Forest (RF) . . . 22
2.5.2. Gradient Boosting . . . 23
2.5.3. Matriz de confusión . . . 24
2.5.4. Métricas de evaluación . . . 24
2.5.5. Curva ROC . . . 26

3. Extracción de características para Series de Tiempo Astronómicas 27
3.1. Datos . . . 27
3.2. Extracción de Datos . . . 31
3.3. Limpieza de Datos . . . 32
3.4. Características . . . 34
3.5. Diagrama de Flujo para la extracción de características para curvas de luz astrónomicas . . . 39

4. Resultados 40
4.1. Resultados para las subclases de objetos Estocásticos: . . . 41
4.2. Resultados para las subclases de objetos Transientes . . . 50

5. Conclusiones 57
5.1. Discusión . . . 57
5.2. Conclusión . . . 58
5.3. Trabajos Futuros . . . 59

6. Bibliografía 60

7. Anexos 62
7.1. Tablas completas de resultados . . . 62
7.2. Códigos Python para extracción de curvas de Luz . . . 64
7.3. Función creada en Python para generar los gráficos de cajas de las Figuras 3.4.1 y 3.4.2 . . . 66

Capítulo 1

Introducción

Con el avance de la tecnología, la astronomía ha entrado en una nueva era dominada por el Big Data, lo que ha transformado nuestra comprensión del universo mediante la recopilación y análisis de enormes volúmenes de información. Este progreso ha impulsado el desarrollo de telescopios de última generación y la implementación de proyectos astronómicos a gran escala, capaces de realizar estudios de campo amplio que superan las limitaciones de las observaciones focalizadas. Un ejemplo destacado de una instalación dedicada a la captura y procesamiento de datos astronómicos es el Zwicky Transient Facility (ZTF), cuyo funcionamiento ha sido descrito por *Masci et al. (2019)* [13] y *Patterson et al. (2019)* [15].

Uno de los conjuntos de datos más valiosos que se recopilan son las curvas de luz, que representan las variaciones temporales del brillo de objetos astronómicos. Estas curvas son fundamentales para estudiar y clasificar distintos tipos de objetos, como lo muestra *Sánchez-Sáez et al. (2021)* [1], quienes desarrollaron su propia taxonomía junto con un clasificador que utiliza el broker astronómico ALeRCE (Automatic Learning for the Rapid Classification of Events), que también será la taxonomía empleada en este trabajo. Cada categoría de objetos astronómicos contiene subclases con características distintivas, y una clasificación precisa de estas subclases es crucial para profundizar en el entendimiento de los fenómenos espaciales.

El análisis de las curvas de luz a menudo se lleva a cabo mediante modelos estadísticos. Sin embargo, los modelos actuales pueden no capturar todas las complejidades de estas señales. Por ello, es esencial identificar nuevas características que puedan mejorar la precisión sin afectar la velocidad de ejecución de los modelos de clasificación existentes.

En este trabajo, utilizamos el modelo Irregular Autoregressive (iAR), introducido por *Eyheramendy et al. (2018)* [8]. Este modelo presenta un parámetro a estimar ϕ, que podría contener información valiosa para entrenar modelos de machine learning para la clasificación de tipos de objetos astronómicos. Los métodos que se utilizarán para estimar el parámetro ϕ del modelo iAR son los siguientes: iAR Online Newton Step (iAR-ONS), iAR Online Gradient Descent (iAR-OGD) e iAR Online Bayesian Regression (iAR-OBR). Estos métodos son detallados por *Elorrieta et al. (2022)* [7] y dan como resultado una sucesión de estimaciones para el parámetro ϕ. A medida que se avanza en la sucesión, los valores del parámetro tienden al resultado obtenido mediante el método de estimación de máxima verosimilitud, descrito por *Elorrieta et al. (2019)* [6].

La sucesión obtenida a partir de las tres formas de estimación en línea del parámetro ϕ para cada curva de luz, se utilizará para definir nuevas características obtenibles mediante fórmulas calculables basadas en dicha sucesión. El objetivo es evaluar el potencial de estas características para mejorar la clasificación de distintos tipos de objetos astronómicos. Esta evaluación se realizará utilizando herramientas de machine learning, que permitirán determinar la relevancia de estas nuevas características en el proceso de clasificación.

1.1. Objetivos

1.1.1. Objetivo General

- Definir y estudiar nuevas características para la clasificación de objetos astronómicos, obtenidas de la estimación del parámetro ϕ del modelo Irregular Autoregressive (iAR) mediante métodos de estimación en línea, y evaluar su relevancia en los modelos de clasificación existentes.

1.1.2. Objetivos Específicos

- Desarrollar una introducción a la teoría de series de tiempo y algunos modelos desarrollados para estas, dando a conocer sus propiedades más importantes.
- Calcular estimaciones al parámetro ϕ del modelo iAR para un conjunto de curvas de luz reales, utilizando tres técnicas distintas de estimación en línea: iAR-OBR, iAR-OGD e iAR-ONS.
- Definir características de rápida computación a partir de las sucesiones de valores obtenidos mediante las estimaciones en línea del modelo iAR para cada objeto.
- Utilizar clasificadores y técnicas estadísticas para evaluar el desempeño de las características definidas en la clasificación de objetos astronómicos.

Capítulo 2

Preliminares

2.1. Curva de luz

Una curva de luz es una representación gráfica que muestra cómo varía el brillo de un objeto astronómico con el tiempo. A medida que los telescopios capturan imágenes de alta precisión mediante dispositivos como cámaras de carga acoplada (CCD), que son sensores altamente sensibles a la luz y están diseñados para captar señales extremadamente débiles provenientes de cuerpos celestes lejanos. Gracias a ellos, es posible obtener información fotométrica detallada, que incluye la magnitud del brillo del objeto en el instante de tiempo que se realiza la observación.

Para construir una curva de luz, se grafican estos datos de brillo corregido (magnitud) en función del tiempo. La magnitud corregida se calcula utilizando la fórmula:

$$mag_{corr} = -2{,}5 \log_{10} \left(10^{-0{,}4 m_{ref}} + \text{sgn} \cdot 10^{-0{,}4 m_{diff}}\right) \tag{2.1}$$

donde:

- m_{ref} es la magnitud de referencia, que representa el brillo del objeto astronómico en condiciones de referencia estandarizadas.
- m_{diff} es la magnitud de diferencia, que mide el cambio en el brillo del objeto en comparación con la magnitud de referencia.

- sgn es el signo de la alerta, que indica si el brillo del objeto ha aumentado o disminuido en comparación con la magnitud de referencia.

2.2. Clasificador de curvas de luz

En astronomía, la clasificación de objetos es esencial para organizar y comprender la vasta cantidad de datos generados por observaciones telescópicas. Al categorizar objetos astronómicos según sus características físicas y patrones de variabilidad, los investigadores pueden identificar, estudiar y comparar distintos tipos de fenómenos de manera más eficiente.

El esquema de clasificación utilizado por el broker astronómico ALeRCE (Automatic Learning for the Rapid Classification of Events), descrito por *J. Sánchez-Sáez et al. (2021)* [1], será elegido como referencia en este trabajo. Este esquema consiste en un clasificador del tipo bosque aleatorio, que se puede ver en la Figura 2.2.1, emplea cuatro modelos de clasificación y abarca un total de 15 clases, todas ellas balanceadas. La taxonomía de estas clases se organiza jerárquicamente según las propiedades físicas de los objetos y las características de variabilidad empírica de las curvas de luz.

La clasificación utilizada por ALeRCE se organiza en tres grupos principales:

- **Transientes**: Fenómenos astronómicos que ocurren en escalas de tiempo relativamente cortas y que tienden a aparecer, evolucionar y desaparecer rápidamente.
    - Ejemplos: Supernovas de tipo Ia (SN Ia), Supernovas de tipo Ibc (SN Ibc), Supernovas de tipo II (SN II), Supernovas superluminosas (SLSN).
- **Estocásticos**: Objetos cuya emisión de luz varía de manera impredecible, sin seguir un patrón determinista claro.
    - Ejemplos: Novas o variables cataclísmicas (Nova/Cataclysmic variable), Blazars, Objetos cuasi-estelares (QSO), Objetos estelares jóvenes (YSO).

- **Periódicos**: Objetos que muestran variabilidad en su emisión de luz en intervalos de tiempo regulares, siguiendo ciclos o patrones repetitivos.
    - Ejemplos: Estrellas variables de largo período (LPV), Cefeidas, Estrellas RR Lyrae, Delta Scuti, Binarias eclipsantes.

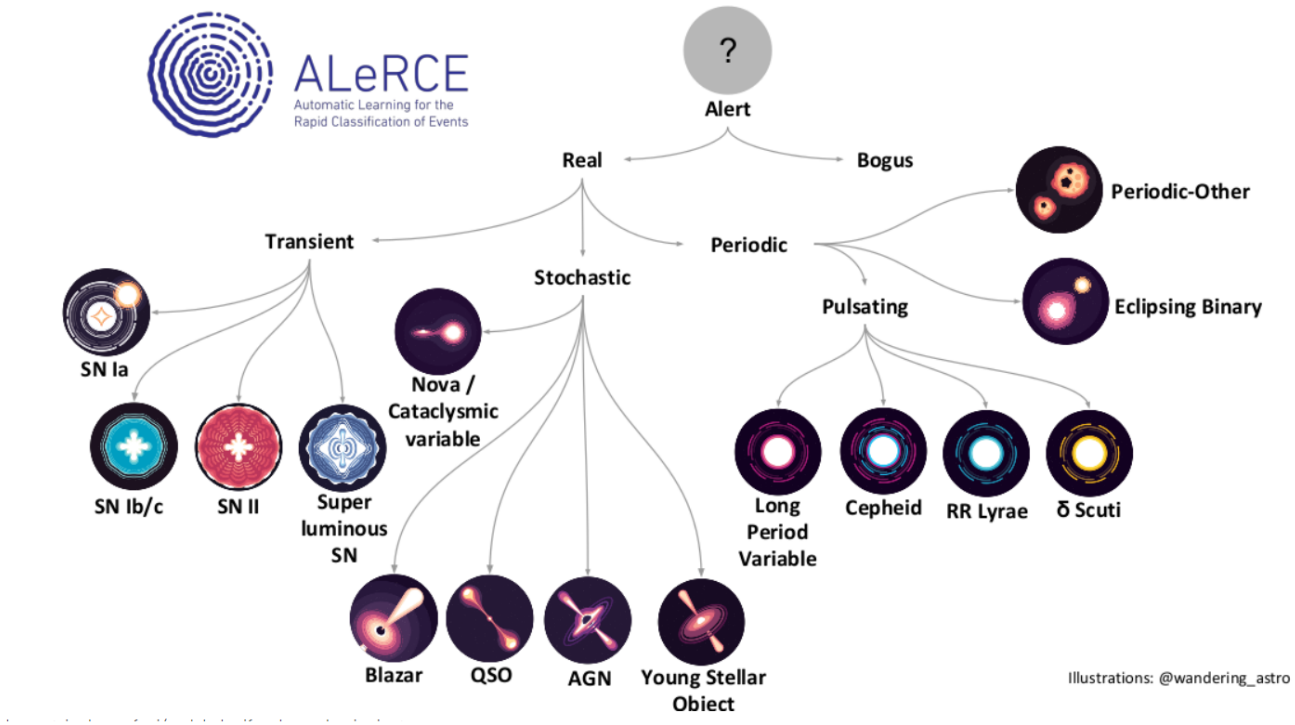


Figura 2.2.1: Árbol de taxonomía utilizado por ALeRCE en su clasificador. Imagen tomada de *P. Sanchez-Saez*, 2021.

Observación: En nuestro trabajo solo estudiaremos las clases de objetos Estocástico y Transiente.

2.3. Teoría de Series de tiempo

La teoría de series de tiempo se centra en el análisis de datos recolectados en secuencias temporales, donde los datos son recogidos en intervalos regulares o irregulares de tiempo. El objetivo principal de este campo es modelar la estructura temporal de los datos, identificando patrones que permitan predecir comportamientos futuros o entender las dinámicas subyacentes en el fenómeno estudiado.

En esta sección se presentarán algunos de los conceptos fundamentales y propiedades más importantes de esta teoría, utilizando como referencia el libro de *Box, G. E. P. et al. (2015)* [3]."

2.3.1. Serie de tiempo

Una serie de tiempo se puede ver como cualquier conjunto de datos donde los valores se miden en distintos puntos en el tiempo. Muchas series temporales son medidas uniformemente con una frecuencia específica, por ejemplo, las mediciones climáticas por hora, los recuentos diarios de visitas a sitios web o las ventas totales mensuales. Dichas series también pueden estar espaciadas irregularmente, por ejemplo, los datos con marca de tiempo (timestamp) en el registro de eventos (logs) de un sistema informático o un historial de llamadas de emergencia al 911.

Definición: Una serie de tiempo es un proceso estocástico $\{Y_t,\ t \in T\}$, T subconjunto de $\mathbb{R}$ ordenado crecientemente, y sí además este subconjunto T cumple que para cada $t_i, t_j \in T$, existe $c \in \mathbb{R}$ tal que $|t_i - t_j| = c$, entonces decimos que la serie de tiempo es regularmente espaciada, en caso contrario, irregularmente espaciada.

2.3.2. Proceso Estocástico

Un concepto clave en el análisis de series de tiempo es el de los procesos estocásticos, ya que las series de tiempo se pueden definir como una forma particular de estos procesos.

Definición: Un proceso estocástico es una colección de variables aleatorias $\{X_t,\ t \in T\}$, ordenadas por un índice t, que generalmente se asocia con el tiempo. En este contexto, para cada instante t, existe una variable aleatoria distinta representada por X_t, lo que implica que un proceso estocástico puede interpretarse como una sucesión de variables aleatorias cuyas características pueden cambiar a lo largo del tiempo. Los posibles valores que puede tomar la variable aleatoria se denominan estados, y el conjunto de estos estados puede ser discreto o continuo. De igual manera, el tiempo puede ser una variable discreta o continua. En el caso de tiempo discreto, los cambios de estado podrían ocurrir a intervalos regulares, como cada día, mes, o año. En el caso de tiempo continuo, los cambios pueden suceder en cualquier instante. Dependiendo de la naturaleza del conjunto de índices T y del tipo de variable aleatoria X_t, se pueden clasificar los procesos estocásticos en diferentes categorías, como lo son el movimiento browniano o proceso de Wiener.

2.3.3. Estacionariedad (débil y fuerte)

La estacionariedad es una propiedad central en el análisis de series de tiempo, y es altamente deseada en muchos casos.

Definición: Un proceso estocástico (o serie temporal) es estrictamente estacionario si la distribución conjunta de $(Y_{t_1}, ..., Y_{t_k})$ es idéntica a la de $(Y_{t_1+t}, ..., Y_{t_k+t})$ para todo t, donde k es un número entero positivo arbitrario y $(t_1, ..., t_k)$ es una colección de k números enteros positivos. En otras palabras, la estacionariedad estricta requiere que la distribución conjunta de $(Y_{t_1}, ..., Y_{t_k})$ sea invariante bajo un cambio de tiempo. Esta es una condición fuerte, ya que comprobarla requiere disponer de las distribuciones conjuntas para cualquier selección de variables del proceso. Una propiedad más débil, pero más aplicable en la práctica, es la estacionariedad en sentido débil o de segundo orden, que implica la estabilidad de la media, la varianza, y la estructura de covarianza

a lo largo del tiempo.

Definición: Un proceso $\{Y_t\}$ es estacionario en sentido débil si cumple las siguientes condiciones para todo t:

1. Tiene una media constante, $E(Y_t) = \mu$.
2. Tiene una varianza constante y finita, $Var(Y_t) = \sigma^2$.
3. Existe una función $\gamma(k)$ tal que $\gamma(k) = Cov(Y_t, Y_{t\pm k})$ para algún t y k.

Esto significa que el valor de la covarianza entre dos períodos depende únicamente de la distancia o retraso entre esos dos períodos de tiempo, y no del momento en el cual se calculó la covarianza.

2.3.4. Función de Autocovarianza

Definición: Sea $\{Y_t\}$ una serie de tiempo estacionaria. La función de autocovarianza de $\{Y_t\}$ se define como:

$$\gamma(k) = Cov(Y_t, Y_{t\pm k})$$

donde k es el retraso (lag) de la serie, es decir, el período que separa dos observaciones.

2.3.5. Función de Autocorrelación

Definición: Sea $\{Y_t\}$ una serie de tiempo estacionaria. La función de autocorrelación de $\{Y_t\}$ se define como:

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}$$

donde k es el retraso (lag) de la serie, es decir, el período que separa dos observaciones.

2.3.6. Ruido Blanco (Discreto)

En este trabajo utilizaremos el proceso de ruido blanco en su versión discreta. Aunque también existe una definición para tiempo continuo, no será necesario abordarla en este documento.

Definición: Un proceso estocástico de tiempo discreto $\{\epsilon_n, n \in \mathbb{N}_0\}$ se denomina proceso de ruido blanco (RB) discreto si cumple las siguientes propiedades:

1. $E(\epsilon_n) = \mu$ para todo $n \in \mathbb{N}$.
2. $Var(\epsilon_n) = \sigma^2$.
3. $Cov(\epsilon_n, \epsilon_{n+k}) = 0$ para $k \neq 0$.

Usualmente se considera el caso $E(\epsilon_n) = 0$, lo que se conoce como ruido blanco centrado. La notación utilizada será $\epsilon_n \sim RB(0, \sigma^2)$.

El ruido blanco se puede interpretar como una sucesión de valores que no se relacionan entre sí, oscilando en torno a cero dentro de un margen constante.

2.3.7. Modelo AR

El modelo autorregresivo de tiempo discreto del orden p, $AR(p)$, es fundamental en la teoría de series de tiempo regularmente espaciadas, basado en la idea de representar la influencia de datos pasados en el presente (y, por consiguiente, en el futuro).

Definición: Sea un proceso estocástico $\{Y_t\}$. Se dice que es autorregresivo de orden p ($AR(p)$) si:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t, \qquad t \in \mathbb{N},\ p \geq 1$$

donde $\epsilon_t \sim RB$, $Cov(\epsilon_t, Y_{t-j}) = 0$ para todo $j > 0$, y los coeficientes $\phi_1, \phi_2, \ldots, \phi_p$ son fijos.

La ecuación se puede reescribir de manera más compacta como:

$$\Phi_p(B)Y_t = \epsilon_t$$

donde B se define como el operador de rezago, es decir, $BY_t = Y_{t-1}$, y $\Phi_p()$ es el polinomio característico de orden p, definido como:

$$\Phi_p(z) = 1 - \phi_1 z - \phi_2 z^2 - \cdots - \phi_p z^p$$

Para ilustrar el comportamiento del modelo, consideremos el caso más simple, $p = 1$ ($AR(1)$). Sea Y_t un proceso autorregresivo de orden 1, $AR(1)$, es decir:

$$Y_t = \phi Y_{t-1} + \epsilon_t$$

y supongamos la estacionariedad del proceso. Entonces:

(1) $E(Y_t) = 0$

(2) $Var(Y_t) = \frac{\sigma_\epsilon^2}{1-\phi^2}$

(3) $\gamma(k) = \phi^{|k|}\gamma(0)$, con $\gamma(0) = \frac{\sigma_\epsilon^2}{1-\phi^2}$

(4) $\rho(k) = \phi^{|k|}$

La propiedad (2) indica que la condición para la estacionariedad del modelo $AR(1)$ es que $|\phi| < 1$. Ahora veremos una proposición que asegura la estacionariedad para cualquier orden del modelo AR.

Proposición: La condición necesaria y suficiente para que un proceso $AR(p)$ sea estacionario es que las raíces de su polinomio característico estén fuera del círculo unidad del plano complejo.

2.3.8. Modelo MA

Otro modelo sumamente importante en la teoría de series de tiempo es el modelo de medias móviles, basado en la idea de que la variable de salida depende linealmente del valor actual y varios de los términos estocásticos anteriores.

Definición: Un proceso estocástico $\{Y_t\}$, $t \in T$, se dice que es de medias móviles de orden q ($MA(q)$) si:

$$Y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}, \qquad t \in \mathbb{N},\ q \geq 1$$

donde $\epsilon_t \sim RB$ y los coeficientes $\theta_1, \theta_2, \ldots, \theta_q$ son fijos. De manera similar al modelo anterior, la ecuación se puede reescribir de manera más compacta como:

$$Y_t = \Theta_q(B)\epsilon_t$$

donde $\Theta_q()$ es el polinomio de medias móviles de orden q, definido como:

$$\Theta_q(z) = 1 + \theta_1 z + \theta_2 z^2 + \cdots + \theta_q z^q$$

veamos cómo se comporta el modelo de medias móviles más simple, es decir, el $MA(1)$, que tiene la siguiente forma:

$$Y_t = \epsilon_t + \theta_1 \epsilon_{t-1}$$

Este proceso es estacionario y cumple las siguientes propiedades:

(1) $E(Y_t) = 0$

(2) $Var(Y_t) = \sigma_\epsilon^2(1 + \theta^2)$

(3)

$$\gamma(k) = \begin{cases} \sigma_\epsilon^2(1+\theta^2) & \text{si } k = 0 \\ \theta\sigma_\epsilon^2 & \text{si } k = 1 \\ 0 & \text{en otro caso} \end{cases}$$

(4)

$$\rho(k) = \begin{cases} 1 & \text{si } k = 0 \\ \frac{\theta}{1+\theta^2} & \text{si } k = 1 \\ 0 & \text{en otro caso} \end{cases}$$

2.3.9. Modelo ARMA

El modelo autorregresivo de medias móviles de tiempo discreto de orden p y q, $ARMA(p,q)$, es un modelo mixto que incluye componentes autorregresivas y de medias móviles.

Definición: Sea Y_t un proceso estocástico. Se dice que sigue un proceso $ARMA(p,q)$ si cumple:

$$Y_t - \phi_1 Y_{t-1} - \ldots - \phi_p Y_{t-p} = \epsilon_t - \theta_1\epsilon_{t-1} - \ldots - \theta_q\epsilon_{t-q}, \quad t \in \mathbb{N},\ p,q \geq 1$$

donde $\epsilon_t \sim \text{RB}(0,\sigma_\epsilon^2)$, con coeficientes $\phi_1,\ldots,\phi_p$ y $\theta_1,\ldots,\theta_q$ fijos. También es posible reescribir el modelo en una forma más compacta.

$$\Phi_p(B)Y_t = \Theta_q(B)\epsilon_t$$

donde B es el operador de rezago y $\Phi_p(B)$ y $\Theta_q(B)$ son los polinomios característicos definidos como:

$$\Phi_p(z) = 1 - \phi_1 z - \phi_2 z^2 - \ldots - \phi_p z^p$$

$$\Theta_q(z) = 1 - \theta_1 z - \theta_2 z^2 - \ldots - \theta_q z^q$$

Consideremos el modelo $ARMA(1,1)$ como un caso específico. Sea Y_t un proceso $ARMA(1,1)$, es decir:

$$Y_t - \phi Y_{t-1} = \epsilon_t - \theta \epsilon_{t-1}$$

Entonces, bajo la condición de estacionariedad, se cumple que:

- (1) $E(Y_t) = 0$
- (2) $\text{Var}(Y_t) = \frac{(1-2\phi\theta+\theta^2)}{(1-\phi^2)}\sigma_\epsilon^2$
- (3) $\gamma(k) = \phi^{k-1}\gamma(1)$ donde $\gamma(1) = \frac{\sigma_\epsilon^2(\phi+\theta)(1+\phi\theta)}{1-\phi^2}$
- (4) $\rho(k) = \phi^{k-1}\rho(1)$ donde $\rho(1) = \frac{(\phi+\theta)(1+\phi\theta)}{1+2\phi\theta+\theta^2}$

Al igual que en el modelo $AR(1)$, la condición de estacionariedad es $|\phi| < 1$.

2.3.10. Modelo Autorregresivo irregular (iAR)

Eyheramendy S. et al. (2018) [8] introdujeron este modelo, el cual es una extensión de los modelos autorregresivos (AR), diseñado para modelar series temporales irregularmente espaciadas.

Definición: Sea y_{t_j} una observación en el tiempo t_j y consideremos una sucesión creciente de observaciones de tiempo $\{t_j\}$ para $j = 1, \ldots, n$. Definimos el proceso iAR de la siguiente forma:

$$Y_{t_j} = \phi^{t_j - t_{j-1}} Y_{t_{j-1}} + \sigma\sqrt{1 - \phi^{2(t_j - t_{j-1})}}\epsilon_{t_j} \qquad (\star)$$

donde ϵ_{t_j} son variables aleatorias de media cero y varianza unitaria.

Notemos que si $t_j - t_{j-1} = 1$ para todo j, entonces $(\star)$ se reduce a:

$$Y_{t_j} = \phi Y_{t_{j-1}} + \sigma\sqrt{1 - \phi^2}\epsilon_{t_j} \qquad j = 2, \ldots, n$$

Este caso corresponde a un modelo autorregresivo de orden 1 ($AR(1)$) para datos regularmente espaciados. Por lo tanto, el modelo iAR puede considerarse una extensión del modelo AR para series temporales con intervalos de tiempo irregulares.

Observaciones:

- (1) $E(Y_{t_j}) = 0$ para todo Y_{t_j}
- (2) $\text{Var}(Y_{t_j}) = \sigma^2$ para todo Y_{t_j}
- (3) $\text{Cov}(Y_{t_k}, Y_{t_j}) = E(Y_{t_k} Y_{t_j}) = \sigma^2 \phi^{t_k - t_j}$ para $k \geq j$
- (4) Usando (3), la función de autocovarianza para toda pareja de observaciones $s < t$ es:

$$\gamma(t-s) = E(Y_t Y_s) = \sigma^2 \phi^{t-s}$$

- (5) La función de autocorrelación es:

$$\rho(t-s) = \frac{\gamma(t-s)}{\gamma(0)} = \phi^{t-s}$$

Dadas estas observaciones, podemos decir que la sucesión $\{Y_{t_j}\}$ corresponde a un proceso de segundo orden o proceso débilmente estacionario.

Ahora, veremos un teorema que asegura, bajo ciertos supuestos, la estacionariedad del proceso, una propiedad deseada en muchos modelos.

Teorema Consideremos el proceso definido por la ecuación ($\star$) y supongamos que el ruido del modelo está representado por una sucesión de variables aleatorias i.i.d. con media cero y varianza unitaria. Además, asumamos que $t_j - t_{j-1} \geq C \log(n)$ en el límite cuando $n \to \infty$, donde $0 < \phi < 1$ y C es una constante positiva que cumple $C \log(\phi^2) < -1$. Entonces, existe una solución para el proceso definido en la ecuación ($\star$), y la sucesión $\{Y_{t_j}\}$ es estacionaria.

2.4. Métodos de estimación del parametro ϕ asociado al Modelo iAR

La estimación precisa del parámetro ϕ es fundamental para la caracterización del modelo iAR, ya que este parámetro determina la dinámica del proceso estocástico subyacente. En esta sección, se presentan dos enfoques principales para la estimación de ϕ, por el método de máxima verosimilitud y los métodos de estimación online.

2.4.1. Método de estimación por Máxima Verosimilitud

El estimador de máxima verosimilitud es un método estadístico para estimar los parámetros ϕ de un modelo probabilístico a partir de un conjunto de datos observados $Y = \{Y_1, Y_2, \ldots, Y_n\}$. La función de verosimilitud $L(\theta \mid Y)$ mide la probabilidad de observar los datos dados los parámetros θ.

$$L(\phi \mid Y) = P(Y \mid \phi) = \prod_{i=1}^{n} P(Y_i \mid \phi)$$

La función del estimador de máxima verosimilitud consiste en encontrar el valor de ϕ que maximiza la función de verosimilitud. Esto es equivalente a maximizar el logaritmo natural de la función de verosimilitud, dado que el logaritmo natural es una función creciente:

$$l(\phi) = ln(L(\phi \mid Y)) = ln(\prod_{i=1}^{n} P(Y_i \mid \phi)) = \sum_{i=1}^{n} ln(P(Y_i \mid \phi))$$

Algunas propiedades que hacen interesante este método son las siguientes:

- **Consistencia:** A medida que el tamaño de la muestra n tiende a infinito, el estimador de máxima verosimilitud converge en probabilidad al verdadero valor del parámetro ϕ. .
- **Eficiencia asintótica:** Para muestras grandes, el estimador de máxima verosimilitud alcanza la varianza mínima posible.

2.4.2. Espacio de estados

Una representación de espacio de estados lineal se representa matemáticamente en términos de variables de estado y ecuaciones que describen la evolución de dichas variables en el tiempo. El modelo se define mediante dos ecuaciones principales:

- **Ecuación de estado:** Describe cómo evoluciona el estado del sistema en función de su estado actual y la entrada. Se expresa como:

$$X_{t+1} = F_t X_t + V_t$$

  donde:

  - X_t es el vector $v-$dimensional de estado en el tiempo.
  - F_t es la matriz $v \times v$ de transición de estado.
  - V_t es el ruido de proceso y $V_t \sim RB(0, Q_t)$.

- **Ecuación de observación:** Relaciona el estado del sistema con las observaciones realizadas. Se expresa como:

$$Y_t = GX_t + W_t$$

  donde:

  - Y_t es el vector $w-$dimensional de observaciones en el tiempo t.
  - G es la matriz $w \times v$ de observación.
  - W_t es el ruido de medición y $W_t \sim RB(0, R_t)$.

Además, V_t y W_t no están correlacionados.

2.4.3. Filtro de Kalman

Introducido por *Kalman, R. E.* (1960) [11], el filtro de Kalman es un estimador recursivo utilizado para estimar el estado de un sistema lineal en un espacio de estado a partir de observaciones ruidosas e incompletas. Este método combina información previa sobre el estado del sistema, su modelo dinámico y las observaciones, ajustando continuamente la estimación en función de la confianza en las predicciones y las mediciones. Su principal ventaja es que minimiza el error cuadrático medio, proporcionando una estimación óptima del estado y la covarianza asociada.

Fase de predicción

En esta fase, se predice el estado siguiente del sistema y su covarianza asociada, basándose en el modelo dinámico. Esto se hace mediante las siguientes ecuaciones:

- **Predicción del estado**:

$$\hat{X}_{t|t-1} = \phi \hat{X}_{t-1|t-1}$$

  donde $\hat{X}_{t|t-1}$ es el estado predicho en el tiempo t basado en la información del tiempo $t-1$, y ϕ es el coeficiente de transición del estado.

- **Predicción de la covarianza**:

$$P_{t|t-1} = \phi^2 P_{t-1|t-1} + Q$$

  donde $P_{t|t-1}$ es la covarianza predicha del estado y Q es la varianza del ruido del proceso.

Fase de actualización

En esta fase, la predicción se ajusta utilizando la nueva observación, lo que permite obtener una estimación más precisa del estado actual y reducir la covarianza asociada. Las ecuaciones involucradas son:

- **Ganancia de Kalman**:

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + R}$$

  donde K_t es la ganancia de Kalman, y R es la varianza del ruido de medición.

- **Actualización del estado**:

$$\hat{X}_{t|t} = \hat{X}_{t|t-1} + K_t(Y_t - \hat{X}_{t|t-1})$$

donde $\hat{X}_{t|t}$ es la estimación actualizada del estado y Y_t es la nueva observación.

- **Actualización de la covarianza**:

$$P_{t|t} = (1 - K_t)P_{t|t-1}$$

donde $P_{t|t}$ es la covarianza actualizada del estado.

2.4.4. Métodos de estimación online para el modelo iAR

En varias disciplinas, es común tener flujos de datos actualizados de forma recurrente, lo que ha llevado al desarrollo de métodos que permiten analizar los datos de manera óptima a medida que la información llega. Los algoritmos de estimación online procesan los datos nuevos sin necesidad de almacenarlos ni reprocesarlos, lo que ahorra tiempo y espacio. Este enfoque es particularmente valioso en contextos con grandes volúmenes de datos, que seguirán creciendo en el futuro.

Ejemplo de cómo funcionan los métodos de estimación online. Supongamos a partir de un conjunto de datos observados $Y = \{y_1, y_2, \ldots, y_n\}$ en los instantes de tiempo $T = \{t_1, t_2, \ldots, t_n\}$. Entonces el resultado al aplicar uno de estos tres métodos de estimación online, será $\hat{\phi}$, que se ve de la siguiente forma:

$$\hat{\phi}(x_1, ..., x_n) = (\hat{\phi}_1(x_1), ..., \hat{\phi}_i(x_1, ..., x_i), ..., \hat{\phi}_n(x_1, ..., x_n)) \tag{2.2}$$

donde $x_i = (t_i, y_i)$ y $\hat{\phi}_i$ es el i-ésimo cálculo del algoritmo que utiliza el método de estimación online, los algoritmos de los tres método online se pueden ver en detalle en Algoritmo 1,2 y 3.

A continuación, se presenta el algoritmo detrás de los tres métodos de estimación online del parámetro ϕ del modelo iAR, los cuales son: iAR Online Newton Step (iAR-ONS), iAR Online Gradient Descent (iAR-OGD) e iAR Online Bayesian Regression (iAR-OBR). Estos métodos han sido detallados en *Elorrieta et al. (2022)* y se implementan de la siguiente manera:

1) iAR Online Newton Step (iAR-ONS)

Algoritmo 1: iAR Online Newton Step (iAR-ONS)

Input: valores iniciales ϕ_1; tasa de aprendizaje η; $A_1 = \eta$

Output: $\phi_2, \ldots, \phi_N$

for $j = 2$ **to** N **do**

$\hat{y}_{t_j} = \phi_{j-1}^{t_j - t_{j-1}} \cdot y_{t_{j-1}}$

Observar y_{t_j} y obtener la función de perdida $\text{ł}_j(\phi_{j-1})$

Hacer $\nabla_j = \nabla l_j(\phi_{j-1})$; Actualizar $A_{j+1} = A_j + \nabla_j \nabla_j$;

Actualizar parametro $\phi_j = \phi_{j-1} - \frac{1}{\eta} A_{j+1}^{-1} \nabla_j$

end

Donde: $l_j(\phi_{j-1}) = (y_{t_j} - \hat{y}_{t_j})^2$

2) iAR Online Gradient Descent (iAR-OGD)

Algoritmo 2: iAR Online Gradient Descent (iAR-OGD)

Input: valores iniciales ϕ_1; tasa de aprendizaje η

Output: $\phi_2, \ldots, \phi_N$

for $j = 2$ **to** N **do**

$\hat{y}_{t_j} = \phi_{j-1}^{t_j - t_{j-1}} \cdot y_{t_{j-1}}$

Observar y_{t_j} y obtener la función de perdida $\text{ł}_j(\phi_{j-1})$

Hacer $\nabla_j = \nabla l_j(\phi_{j-1})$

Actualizar parametro $\phi_j = \phi_{j-1} - \frac{1}{\eta} \nabla_j$

end

Donde: $l_j(\phi_{j-1}) = (y_{t_j} - \hat{y}_{t_j})^2$

3) iAR Online Bayesian Regression (iAR-OBR)

Algoritmo 3: iAR Online Bayesian Regression (iAR-OBR)

Input: valores iniciales ϕ_1, P_1

for $j = 2$ **to** N **do**

$\hat{y}_{t_j} = \phi_{j-1}^{t_j - t_{j-1}} \cdot y_{t_{j-1}}$

Observar y_{t_j}

Hacer $S_j = y_{t_{j-1}} P_{j-1} y_{t_{j-1}}^t + \sigma^2(1 - \phi_{j-1}^{2(t_j - t_{j-1})})$;

y $K_j = P_{j-1} y_{t_{j-1}}^t S_j^{-1}$

Actualizar $\phi_j = \phi_{j-1} + K_j[y_{t_j} - \hat{y}_{t_j}]$

y $P_j = P_{j-1} - K_j S_j K_j^t$;

end

2.5. Técnicas de análisis y modelación estadística:

Se mostraran algoritmos de ML disponibles en la literatura que estén diseñados para clasificar. En particular, trabajamos con el paquete de Python sk-learn *(Pedregosa, F. et al. 2011)* [16]. El sk-learn incluye implementaciones de varios algoritmos bastantes conocidos, los escogidos para este trabajo fueron los de Random Forest y Gradient Boosting, además de las métricas y curvas que nos ayudarán a analizar la relevancia de las características.

En las siguientes secciones describimos el algoritmo Random Forest (RF) y Gradient Bosting (GB), que serán fundamentales en la sección de resultados para este trabajo.

2.5.1. Random Forest (RF)

Para comprender el funcionamiento del modelo de Random Forest, es esencial comenzar explicando los árboles de decisión. Un árbol de decisión es un algoritmo predictivo que organiza los datos en una estructura jerárquica de particiones sucesivas, basadas en un criterio predefinido, como un valor de corte de una característica o descriptor *(Rokach y Maimon 2008)*[17]. Cada nodo en el árbol representa una decisión basada en una característica, y cada rama define los posibles caminos resultantes de dichas decisiones. Las hojas del árbol representan las predicciones finales, que suelen estar asociadas a clases específicas en problemas de clasificación.

Random Forest es un algoritmo que amplía el enfoque de los árboles de decisión mediante la construcción de múltiples árboles, cada uno entrenado con una submuestra aleatoria de datos, seleccionada con reemplazo, es decir, utilizando la técnica de bootstrap *(Breiman 2001)*[4]. Además, en cada nodo del árbol, se selecciona aleatoriamente un subconjunto de características en lugar de utilizar todo el conjunto disponible, lo que introduce una diversidad adicional en el modelo.

La predicción final de Random Forest se obtiene promediando las predicciones de cada árbol individual, lo que se traduce en una clasificación basada en la mayoría de votos o en un promedio de probabilidades de clasificación (P_{RF}) para cada clase. Esta estrategia no solo mejora la robustez del modelo frente al sobreajuste, sino que también proporciona una estimación de la importancia de las características, basada en la frecuencia con la que cada característica es seleccionada para dividir los datos en los diferentes árboles del bosque.

Finalmente, en el Algoritmo 4 se presenta un esquema que ilustra de manera simplificada el funcionamiento del modelo Random Forest.

Algoritmo 4: Random Forest (RF)

Input: Datos de entrenamiento (x_{ij}, y_i), $i = 1, ..., N$, $j = 1, ..., P$

Output: Conjunto de árboles $C_b(X_i)$, para $b = 1, ..., B$

for $b = 1$ **to** B **do**

Crear una muestra de arranque T_b del conjunto de entrenamiento T_n (muestreo con reemplazo);

Hacer crecer un árbol aleatorio a partir de T_b repitiendo los siguientes pasos en cada nodo terminal:

a. Seleccionar aleatoriamente m variables de las P variables originales;

b. Escoger la mejor variable de división entre las m seleccionadas, evaluando el criterio de partición (p.ej., ganancia de información o impureza de Gini);

c. Dividir el nodo en dos nodos hijos;

end

return *Conjunto de árboles* $C_b(X_i)$ *para* $b = 1, ..., B$

2.5.2. Gradient Boosting

Gradient Boosting *(GBoost; Friedman 2001)* [10] es un algoritmo de aprendizaje automático que combina múltiples modelos de predicción débiles, como los árboles de decisión, para crear una clasificación más robusta y precisa. El enfoque de GBoost se basa en construir estos modelos de manera secuencial, donde cada uno intenta corregir los errores cometidos por el modelo anterior. A través de este proceso iterativo, el algoritmo minimiza una función de pérdida utilizando técnicas de optimización por gradiente, lo que permite mejorar gradualmente el desempeño global del modelo.

2.5.3. Matriz de confusión

Una matriz de confusión es una tabla frecuentemente utilizada para describir el rendimiento de un modelo de clasificación supervisado. Su objetivo principal es mostrar, en una misma tabla, las clases reales y las predicciones del modelo. Aunque la matriz de confusión es relativamente simple de interpretar, permite calcular varias métricas de calidad del modelo a partir de sus valores.

Tabla 2.1: Valores de construcción de la Matriz de Confusión

Clase Real	**Predicción Positiva**	**Predicción Negativa**
Positivo	Verdaderos Positivos (TP)	Falsos Negativos (FN)
Negativo	Falsos Positivos (FP)	Verdaderos Negativos (TN)

2.5.4. Métricas de evaluación

Tres métricas diferentes: precisión, recuperación y puntuación F_1. Para una clase individual, estas puntuaciones se definen de la siguiente manera:

$$Precision_i = \frac{TP_i}{TP_i + FP_i}, \tag{2.3}$$

$$Recall_i = \frac{TP_i}{TP_i + FN_i}, \tag{2.4}$$

$$F_{\alpha_i} = \frac{(\alpha^2 + 1) Precision_i Recall_i}{\alpha^2 Precision_i + Recall_i} \tag{2.5}$$

Donde TP_i es el número de verdaderos positivos, FP_i es el número de falsos positivos y FN_i es el número de falsos negativos para una clase i dada. Podemos también calcular los promedios de estos valores, donde daremos igual importancia a todas las clases:

Es común en la ecuación (3) utilizar el valor como métrica cuando se hace $\alpha = 1$ y quedaría de la siguiente forma la expresión:

$$F_{1_i} = 2\frac{Precision_i Recall_i}{Precision_i + Recall_i} \tag{2.6}$$

De igual forma se definen las mismas métricas para el caso de multiclases:

$$Precision_{macro} = \frac{1}{n_{cl}} \sum_{i=1}^{n_{cl}} Precision_i, \tag{2.7}$$

$$Recall_{macro} = \frac{1}{n_{cl}} \sum_{i=1}^{n_{cl}} Recall_i, \tag{2.8}$$

$$F_{1macro} = \frac{1}{n_{cl}} \sum_{i=1}^{n_{cl}} F1_i \tag{2.9}$$

Donde n_{cl} es el número total de clases existentes.

2.5.5. Curva ROC

La curva Receiver Operating Characteristic (ROC) es una herramienta gráfica para evaluar el rendimiento de modelos de clasificación binaria, mostrando la relación entre la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR) a diferentes umbrales de decisión. La TPR se define como:

$$\text{TPR} = \frac{\text{Verdaderos Positivos}}{\text{Verdaderos Positivos} + \text{Falsos Negativos}}$$

y la FPR se define como:

$$\text{FPR} = \frac{\text{Falsos Positivos}}{\text{Falsos Positivos} + \text{Verdaderos Negativos}}$$

En la clasificación múltiple, se utiliza un enfoque como uno contra todo para calcular curvas ROC para cada clase, tratándola como positiva frente al resto. La métrica área bajo la curva (AUC) ROC se utiliza para evaluar el rendimiento global, donde un AUC de 1 indica clasificación perfecta y 0.5 indica rendimiento aleatorio. Comparar las AUC de diferentes clases ayuda a identificar áreas de mejora en el modelo.

Capítulo 3

Extracción de características para Series de Tiempo Astronómicas

En este capítulo se describe el proceso de definición de las diferentes características utilizadas en el análisis, partiendo desde la obtención y tratamiento de los datos de los distintos tipos de objetos astronómicos. El objetivo es detallar el procedimiento que se sigue para calcular las características asociadas a un conjunto de objetos astronómicos, con el propósito de luego analizar la relevancia que presentan para la clasificación de los objetos astronómicos.

3.1. Datos

Los datos utilizados en este informe fueron extraídos del Broker ALeRCE, el cual recibe alertas del programa astronómico Zwicky Transient Facility (ZTF). El flujo de trabajo de ZTF se describe en detalle por *Masci et al. (2019)* [13] y *Patterson et al. (2019)* [15]. Este sistema proporciona fotometría en las bandas g y r, lo que permite obtener dos curvas de luz para cada objeto: una en la banda g y otra en la banda r. ALeRCE clasifica estas señales utilizando su propio modelo, etiquetando cada objeto con su clase más probable, según el clasificador integrado, descrito por *Sánchez-Sáez et al. (2021)* [1]. La clasificación resultante por ALeRCE es nuestra referencia para conocer la subclase a la que pertenecen los objetos astronómicos.

Las clases de objetos consideradas en este trabajo incluyen los objetos de tipo estocástico y transientes, cada uno con sus respectivas subclases: cinco subclases para los objetos estocásticos y cuatro para los transientes. En las Figuras 3.1.1 y 3.1.2 se muestran ejemplos de curvas de luz asociadas a objetos astronómicos pertenecientes a cada subclase. Se puede observar que las curvas de luz en las bandas g y r presentan trayectorias similares y generalmente los valores de intensidad de luz en la banda g son más altos a los presentes en la banda r.

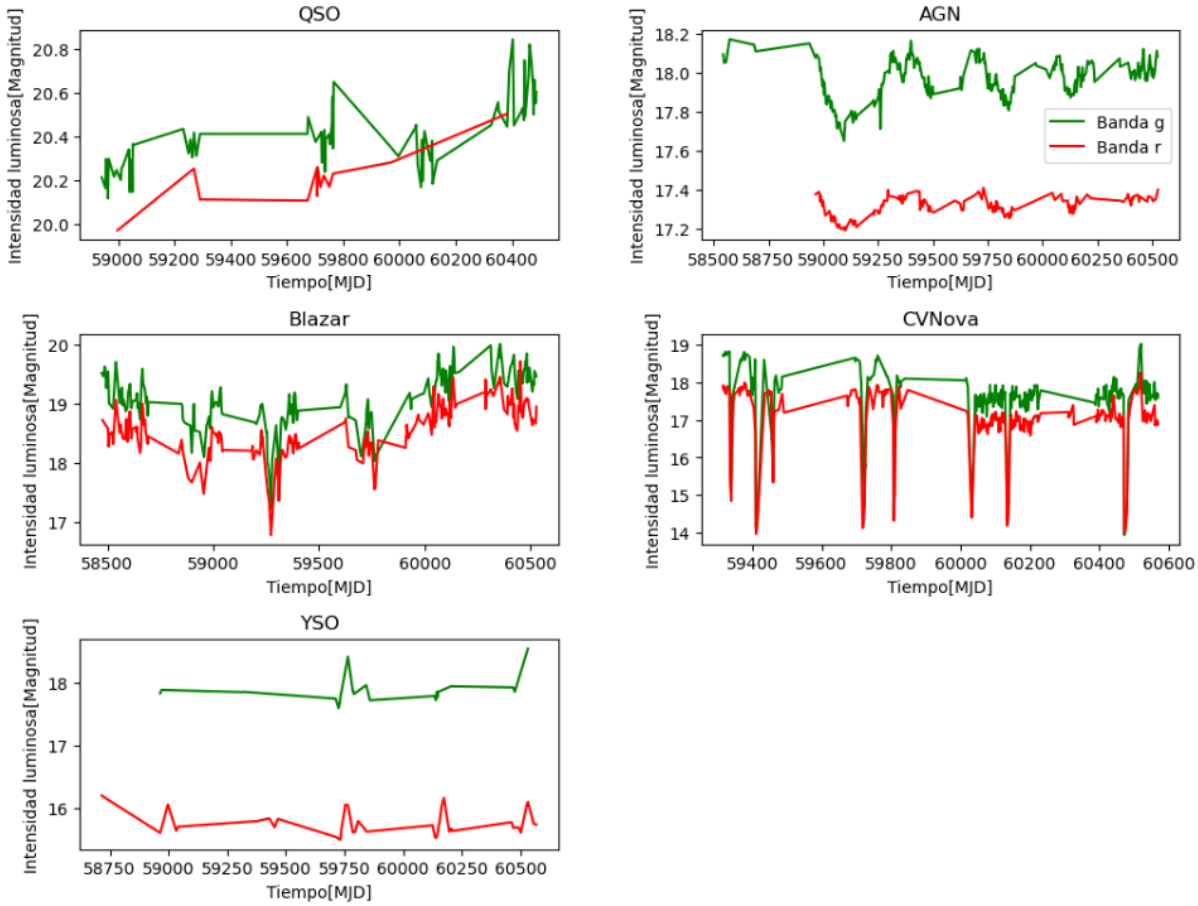


Figura 3.1.1: Gráficos con ejemplos de la curva de luz en las bandas g y r para las diferentes clases de objetos pertenecientes a la categoría de Estocásticos.

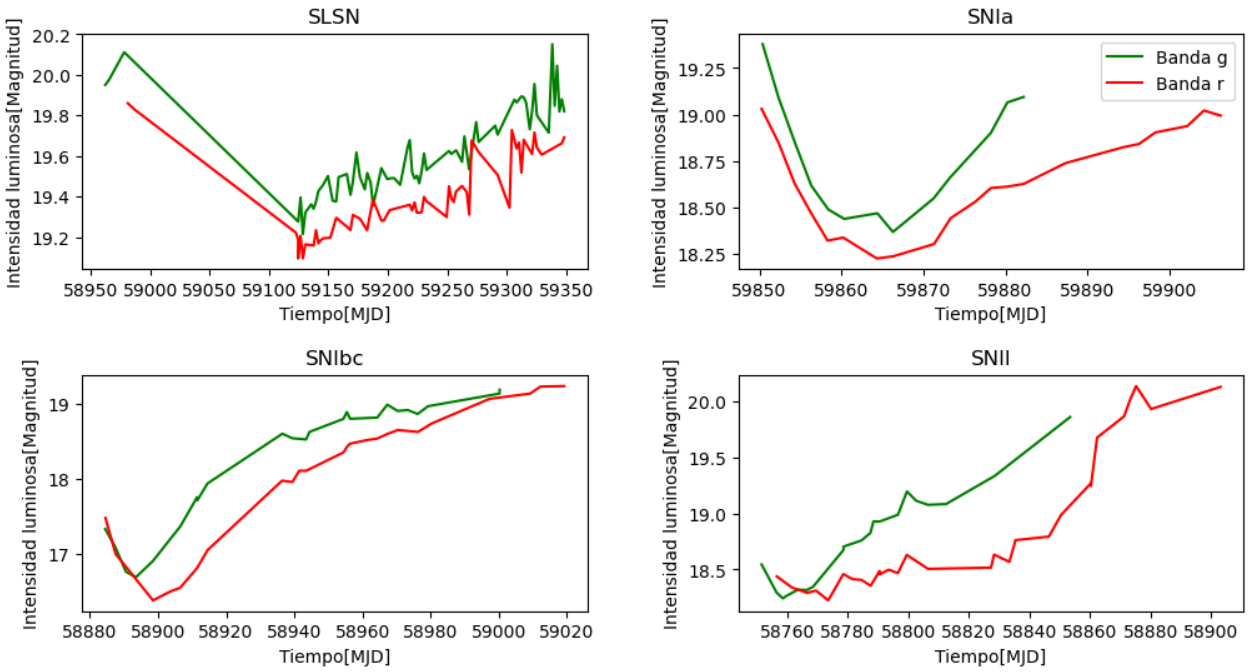


Figura 3.1.2: Gráficos con ejemplos de la curva de luz en las bandas g y r para las diferentes clases de objetos pertenecientes a la categoría de Transientes.

Además, en las Figuras 3.1.3 y 3.1.4 se presentan ejemplos de las estimaciones del parámetro ϕ utilizando los tres métodos de estimación en línea: iAR-OND, iAR-OGD e iAR-OBR, aplicados a la curva de luz de un objeto representativo de cada subclase. Cada método genera una secuencia de valores estimados para ϕ, donde se observa que a medida que avanzan las iteraciones, el cálculo del parámetro incorpora más información de la curva de luz. Así, los valores de ϕ correspondientes a iteraciones más tardías reflejan un análisis más completo de la serie temporal del objeto.

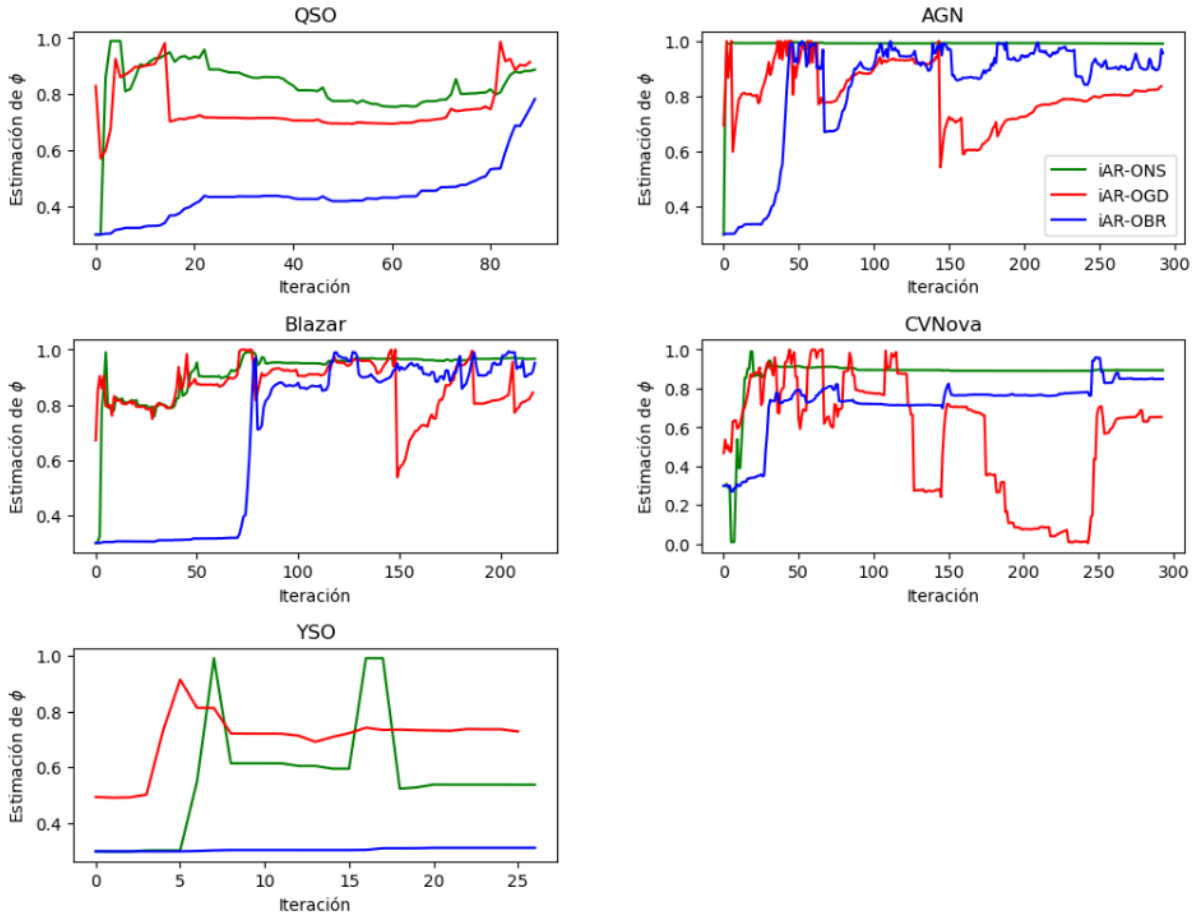


Figura 3.1.3: Gráficos con ejemplos de las estimaciones del parámetro ϕ utilizando los 3 métodos de estimación online iAR-OND, iAR-OGD, iAR-OBR sobre curva de luz para las diferentes clases de objetos pertenecientes a la categoría de Estocásticos.

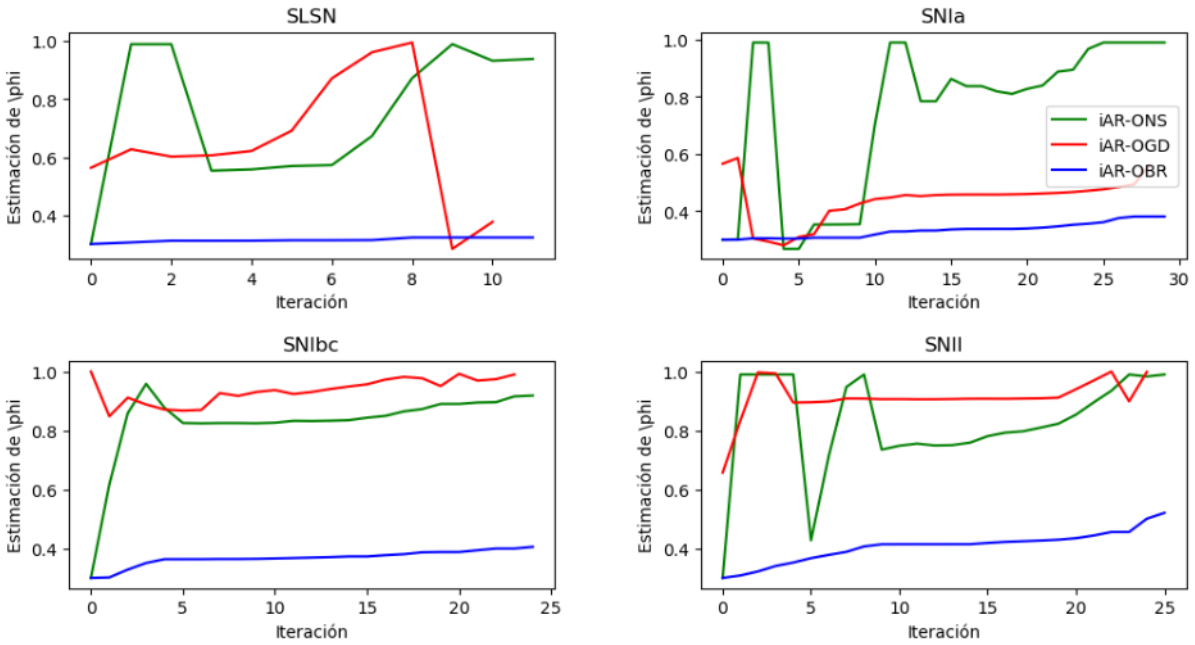


Figura 3.1.4: Gráficos con ejemplos de las estimaciones del parámetro ϕ utilizando los tres métodos de estimación online iAR-OND, iAR-OGD, iAR-OBR sobre curva de luz para las diferentes clases de objetos pertenecientes a la categoría de Transientes.

3.2. Extracción de Datos

La información a utilizar para cada objeto astronómico incluye la curva de luz en ambas bandas y su clasificación según el clasificador de ALeRCE. La metodología para la extracción de esta información se detalla a continuación:

- Se utiliza el ZTF Explorer de ALeRCE[2] como fuente de información para obtener los IDs de los objetos astronómicos pertenecientes a las distintas subclases, tales como AGN, Blazar, entre otras. Los IDs se almacenan en un documento de texto, separados por comas.

- Se emplea Python para importar los IDs de los objetos en cada subclase desde los documentos de texto, convirtiéndolos en listas. La decesiión de usar python es porque la librería de ALeRCE se encuentra disponible en este lenguaje.

- Utilizando la librería `alerce.core` y los IDs previamente importados, se procede a importar los metadatos de cada objeto desde la base de datos que maneja ALeRCE.

- Una vez importado el dataframe de metadatos, se tiene que aplicar un filtro fid=1 o fid=2, dependiendo de la banda que queremos observar (1=g; 2=r). Se encuentran las variables mjd y magpsf_corr. La primera, mjd, representa el tiempo expresado en Modified Julian Date (MJD), mientras que la segunda, magpsf_corr, indica la intensidad de brillo del objeto, ajustada a la función PSF (Point Spread Function), que describe cómo se dispersa la luz de un objeto puntual a través del sistema óptico. Esta última se presenta como una magnitud en escala logarítmica, careciendo de unidad física.

En el Anexo se puede consultar el código utilizado para este procedimiento aplicado a la subclase QSO, para las demás subclases se sigue de forma análoga.

Para este estudio, se buscará una muestra equilibrada de 600 objetos para la clase de estocásticos y 600 para la clase de transitorios. Se decide utilizar muestras equilibradas para evitar la necesidad de modelos que manejan muestras desequilibradas, lo que facilita el análisis y mejora la interpretación de los resultados. Como los estocásticos se dividen en 5 subclases, buscaremos 120 objetos para cada subclase, mientras que los transitorios se agrupan en 4 subclases, cada una con 150 objetos.

3.3. Limpieza de Datos

Para asegurar la calidad de los datos utilizados en este estudio, se implementó un riguroso proceso de limpieza de las curvas de luz. Primero, se abordó la presencia de valores nulos, optando por eliminarlos para evitar que cualquier interpolación comprometa la integridad de la información. Luego, se identificaron casos en los que existían múltiples mediciones de la intensidad lumínica para un mismo instante temporal. En estos casos, se decidió conservar únicamente la primera medición registrada, descartando las demás.

Además, se estableció un criterio sobre las curvas de luz: se incluyeron sólo aquellas con al menos 10 observaciones en la banda g o r. Esta condición fue definida para asegurar que los métodos de estimación en línea tuvieran suficientes puntos de datos para generar resultados confiables. Con menos de 10 observaciones, tanto el valor inicial como la tasa de aprendizaje de cada método podrían influir excesivamente en las estimaciones.

Por último, se decidió no eliminar los datos atípicos dentro de las curvas de luz, debido a que los objetos transientes suelen presentar un volumen limitado de datos. Se priorizó la preservación de la mayor cantidad de observaciones posible para representar fielmente la naturaleza de estos objetos. El número de objetos eliminados por no cumplir con los criterios establecidos se presenta en la Figura 3.3.1.

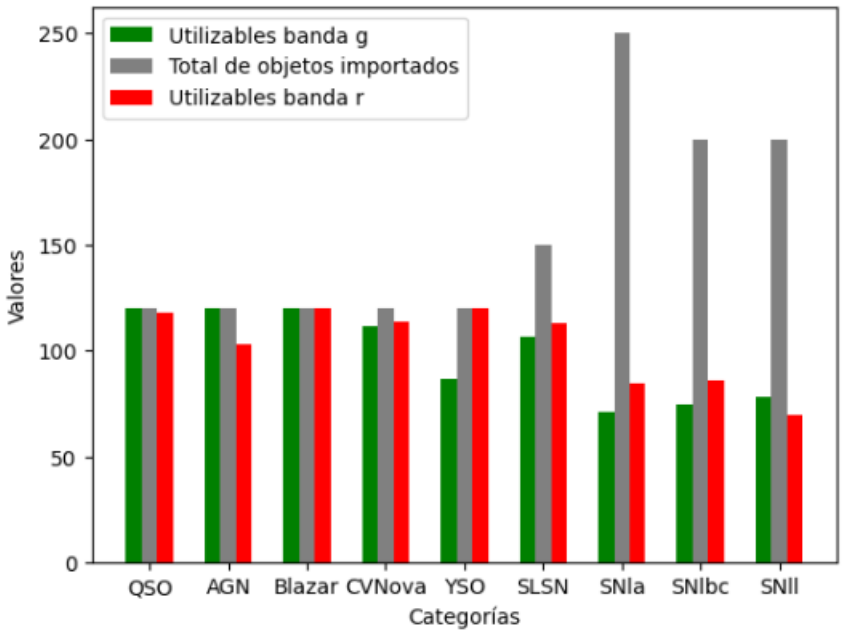


Figura 3.3.1: Gráfico de barras que compara la cantidad de objetos en tres categorías.

La primera barra, en color gris, representa el número total de objetos importados inicialmente. La segunda barra, en color verde, muestra los objetos que cumplen con los criterios de filtrado para ser utilizados en la banda g. Finalmente, la barra en color rojo indica los objetos que cumplen el filtro para la banda r.

Observación: En ciertas clases, la cantidad de objetos importados supera la de otras, siendo particularmente notable en el caso de los SNIa. Esta diferencia se debe a que, tras el proceso de limpieza de datos, este tipo de objetos mostró, en general, un número limitado de observaciones. Para lograr una muestra equilibrada, fue necesario aumentar el número de objetos importados en aquellas clases que, tras la limpieza, quedaron con menos datos. Esto permitió acercarnos a un conjunto más equilibrado.

3.4. Características

En esta etapa, se definieron un total 28 características basadas en las estimaciones del parámetro ϕ del modelo iAR, estas estimaciones son obtenidas mediante distintos métodos de estimación aplicados a las curvas de luz de objetos astronómicos.

El proceso comenzó calculando la primera característica, que corresponde al valor de ϕ estimado por máxima verosimilitud, utilizando la función $IARloglik(y, sT, \delta)$ de la librería iAR. Donde y representa la intensidad lumínica del objeto y sT el tiempo entre observaciones. Esta característica no es nueva, ya se emplea en el clasificador original de ALeRCE y se hace mención a su alta relevancia, entonces se utilizará más adelante en los resultados para comparar las otras características con ella.

Luego, se definieron 27 características adicionales a partir de las sucesiones generadas al estimar el parámetro ϕ utilizando los tres métodos online revisados en preliminares, estos son iAR-ONS, iAR-OBR e iAR-OGD. Las características se diseñaron como fórmulas, en general estadísticas, como la media, desviación estándar, kurtosis, entre otras, cuyos cálculos son prácticamente inmediatos, la razón de esto se debe al alto volumen de datos astronómicos que se capturan diariamente. Todas las características se presentan en la Tabla 3.1.

Tabla 3.1: Lista de características definidas para estudiar en este trabajo.

Característica	**Descripción**	**Referencia**
1) $\phi_complet_serie$	Estimación de máxima verosimilitud del parámetro ϕ del modelo iAR sobre la curva de luz	Eyheramendy et al. (2018)[8]
2) ϕ_end_ONS	Valor de la última posición en la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo

Característica	Descripción	Referencia
3) ϕ_end_OBR	Valor de la última posición en la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
4) ϕ_end_OGD	Valor de la última posición en la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
5) $Media_Phis_ONS$	Media de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo
6) $Media_Phis_OBR$	Media de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
7) $Media_Phis_OGD$	Media de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
8) $Desv_S_Phis_ONS$	Desviación estándar de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo
9) $Desv_S_Phis_OBR$	Desviación estándar de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo

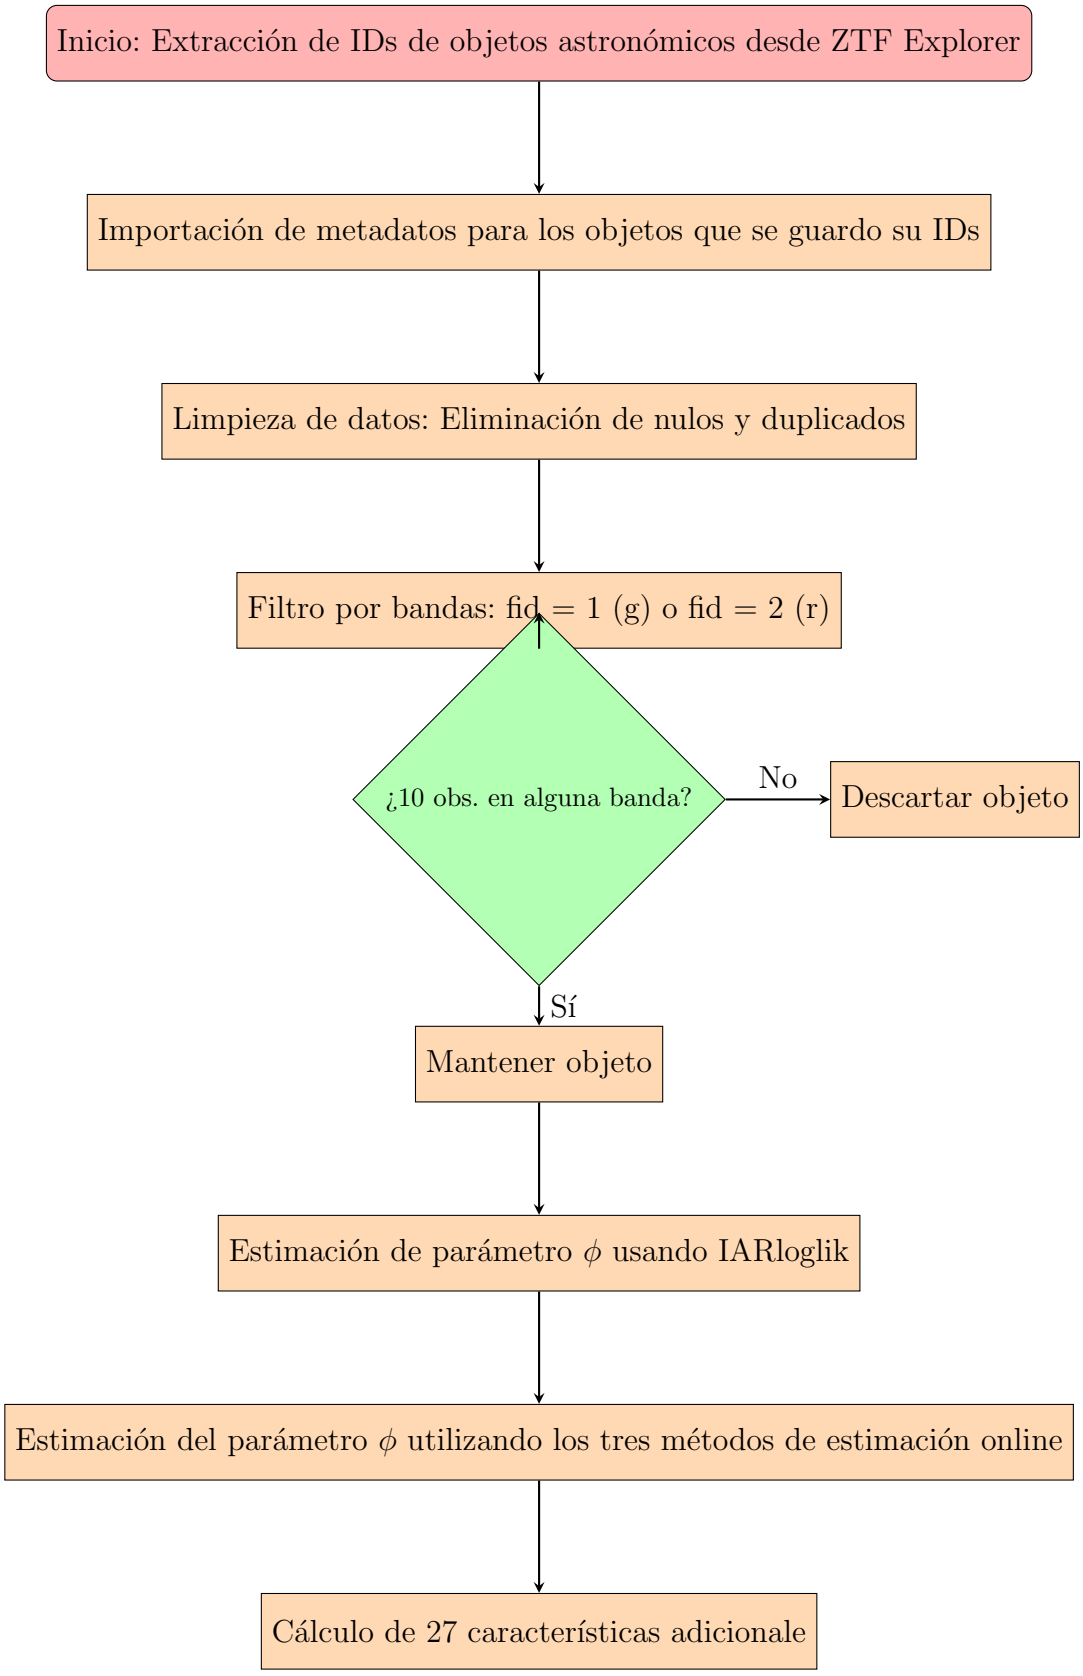
Característica	**Descripción**	**Referencia**
10) $Desv_S_Phis_OGD$	Desviación estándar de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
11) Var_Phis_ONS	Varianza de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo
12) Var_Phis_OBR	Varianza de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
13) Var_Phis_OGD	Varianza de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
14) $Kurt_Phis_ONS$	Curtosis de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo
15) $Kurt_Phis_OBR$	Curtosis de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
16) $Kurt_Phis_OGD$	Curtosis de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
17) $Asim_Phis_ONS$	Asimetría de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo

Característica	Descripción	Referencia
18) $Asim_Phis_OBR$	Asimetría de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
19) $Asim_Phis_OGD$	Asimetría de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
20) $Amp_max_Phis_ONS$	Amplitud máxima entre los valores consecutivos de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo
21) $Amp_max_Phis_OBR$	Amplitud máxima entre los valores consecutivos de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
22) $Amp_max_Phis_OGD$	Amplitud máxima entre los valores consecutivos de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo
23) $Dif_Phis_tiempo_ONS$	Diferencia entre el último y penúltimo valor de la sucesión resultante de estimar ϕ usando el método de estimación online ONS dividida en la diferencia entre el último y penúltimo instante de tiempo de la curva de luz	Este trabajo

Característica	Descripción	Referencia
24) $Dif_Phis_tiempo_OBR$	Diferencia entre el último y penúltimo valor de la sucesión resultante de estimar ϕ usando el método de estimación online ONS dividida en la diferencia entre el último y penúltimo instante de tiempo de la curva de luz	Este trabajo
25) $Dif_Phis_tiempo_OGD$	Diferencia entre el último y penúltimo valor de la sucesión resultante de estimar ϕ usando el método de estimación online ONS dividida en la diferencia entre el último y penúltimo instante de tiempo de la curva de luz	Este trabajo
26) ACF_Phis_ONS	Autocorrelación evaluada en el lag 1 de la sucesión resultante de estimar ϕ usando el método de estimación online ONS	Este trabajo
27) ACF_Phis_OBR	Autocorrelación evaluada en el lag 1 de la sucesión resultante de estimar ϕ usando el método de estimación online OBR	Este trabajo
28) ACF_Phis_OGD	Autocorrelación evaluada en el lag 1 de la sucesión resultante de estimar ϕ usando el método de estimación online OGD	Este trabajo

s

3.5. Diagrama de Flujo para la extracción de características para curvas de luz astrónomicas



Capítulo 4

Resultados

En este capítulo se presentan los resultados organizados en dos secciones principales, ya que el análisis se desarrolla para dos tipos de objetos astronómicos: estocásticos y transientes, cada uno tiene asociado unas subclases específicas (5 para los estocásticos y 4 para los transientes). Los procedimientos de análisis son similares, dado que el objetivo en ambos casos es el mismo.

Se incluyen técnicas de machine learning como boxplots, clasificadores, métricas de evaluación. Además se analiza la importancia que presentan las características con que se entrena un modelo.

Es fundamental resaltar el rol de la característica $(\phi_complet_serie)(1)$ en este capítulo, ya que se utilizará como medida de referencia para evaluar el rendimiento de las demás características.

4.1. Resultados para las subclases de objetos Estocásticos:

En esta sección, nos enfocamos únicamente en las subclases de objetos estocásticos, que recordando de los preliminares existen cinco distintas, estas son: AGN, Blazar, CVNova, QSO y YSO.

Para visualizar la distribución de las características y detectar posibles diferencias entre subclases, destacando valores atípicos y la dispersión de los datos, se emplearon gráficos de caja (boxplot). Estos gráficos permiten visualizar la distribución de los valores de las características para cada subclase. El código empleado para generar dichos gráficos se encuentra disponible en el Anexo.

La Figura 4.1.1 muestra cuatro gráficos de caja correspondientes a las características $\phi_end_ONS(2)$, $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$ y $Media_Phis_OGD(7)$ calculadas en la banda r, la selección de estas características obedece a que presentan comportamientos diferenciados que resultan particularmente interesantes para su análisis. A partir de la figura, se observa una clara separación en los valores de $\phi_end_ONS(10)$ y $Var_Phis_OGD(13)$ para la subclase Blazar indica que estas características podrían captar aspectos específicos del comportamiento de estas subclase de objeto, que nos podría ayudar a clasificarlo correctamente. Aunque menos marcado, los QSO presentan un rango de valores para la característica $\phi_end_ONS(2)$ que apenas se intercepta con el de las otras subclases. Este comportamiento sugiere que dichas características podrían ser útiles para diferenciar estas dos subclases entre las otras.

En cuanto a las subclases AGN, CVNova y YSO, no se detectan patrones claramente diferenciados en las características al observar los gráficos.

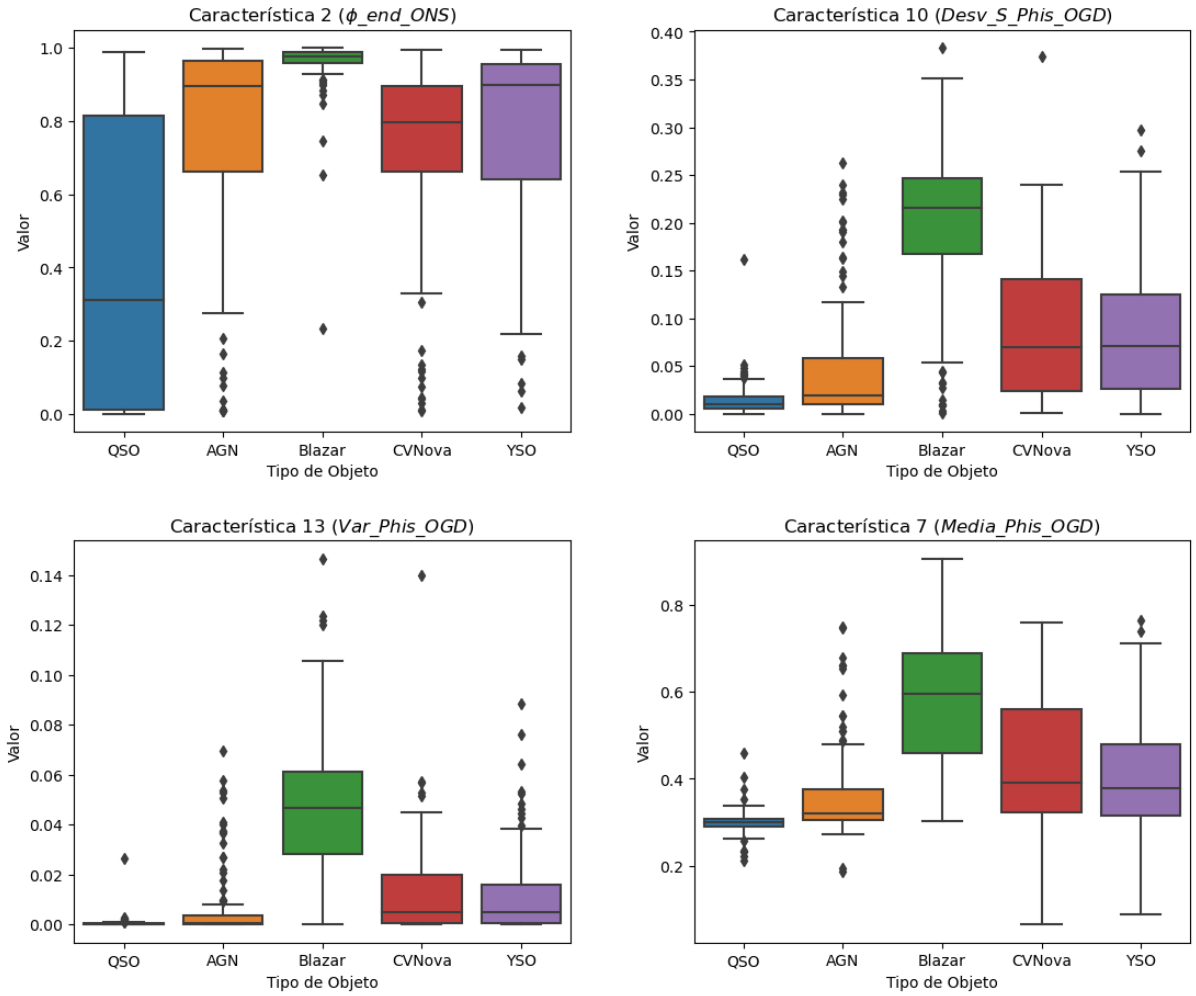


Figura 4.1.1: Gráficos de caja generados con los valores de las características $\phi_end_ONS(2)$, $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$ y $Media_Phis_OGD(7)$ calculados en la banda r, segmentados por las cinco subclases de los objetos estocásticos.

A continuación, se presentan los valores de las métricas de evaluación previamente definidas: $Precision_{macro}$, $Recall_{macro}$ y F_{1macro}. Estas métricas permiten evaluar el rendimiento de los clasificadores Random Forest (RF) y Gradient Boosting (GB) utilizando las características calculadas en ambas bandas (r y g) para entrenar el modelo. El proceso de ajuste de los clasificadores consistió en generar 20 conjuntos distintos de entrenamiento y prueba, empleando el 80 % del conjunto de datos importados como conjunto de entrenamiento, y el 20 % restante como conjunto de prueba. Además, se garantizó que los datos del conjunto de prueba no se utilizaran en el entrenamiento de los modelos. Los resultados obtenidos se muestran en la Tabla 4.1.

Tabla 4.1: Tabla de valores macro promediados obtenidas por los clasificador RF y GB en el conjunto de prueba, para clasificar las subclases de los objetos de tipo estocásticos

Banda	**Clasificador**	$Precision_{macro}$	$Recall_{macro}$	F_{1macro}
g	Random Forest	$0,49 \pm 0,04$	$0,49 \pm 0,038$	$0,46 \pm 0$,042
g	Gradient Boosting	$0,48 \pm 0,041$	$0,49 \pm 0,047$	$0,47 \pm 0$,042
r	Random Forest	$0,58 \pm 0,039$	$0,58 \pm 0,032$	$0,57 \pm 0$,035
r	Gradient Boosting	$0,57 \pm 0,036$	$0,57 \pm 0,027$	$0,57 \pm 0$,027

Observación: Los valores de la tabla corresponden a la media y desviación estándar obtenidas a partir de los 20 modelos entrenados.

De la Tabla 4.1 se observa que ambos clasificadores (Random Forest y Gradient Boosting) presentan un rendimiento similar en las tres métricas de evaluación ($Precision_{macro}$, $Recall_{macro}$ y F_{1macro}). Sin embargo, se presenta una diferencia en el rendimiento entre las bandas, la banda r muestra mejores resultados, lo que sugiere que las características definidas en esta banda presentan una mayor calidad para la clasificación de las subclases de objetos estocásticos.

Igualmente cabe destacar que las precisiones obtenidas, especialmente en la banda g, resultan relativamente bajas. A pesar de esto, es importante aclarar que el enfoque de este estudio no está en crear un clasificador de buenos resultados. El objetivo es analizar las características que mejor discriminan entre las subclases de objetos estocásticos. Por lo tanto, el valor de las métricas, si bien proporciona información útil sobre la calidad de los modelos, no es el principal indicador que se persigue. Más bien, los clasificadores aquí empleados sirven como una herramienta para investigar la relevancia y la capacidad de las características definidas en este trabajo.

Se presentan las importancias de las características, calculadas utilizando la función $clf.feature_importances_$. Esta función se basa en métricas como la impureza de Gini, la entropía y el error cuadrático medio, que son fundamentales para evaluar la relevancia de cada característica en el modelo. Para el clasificador Random Forest (RF),

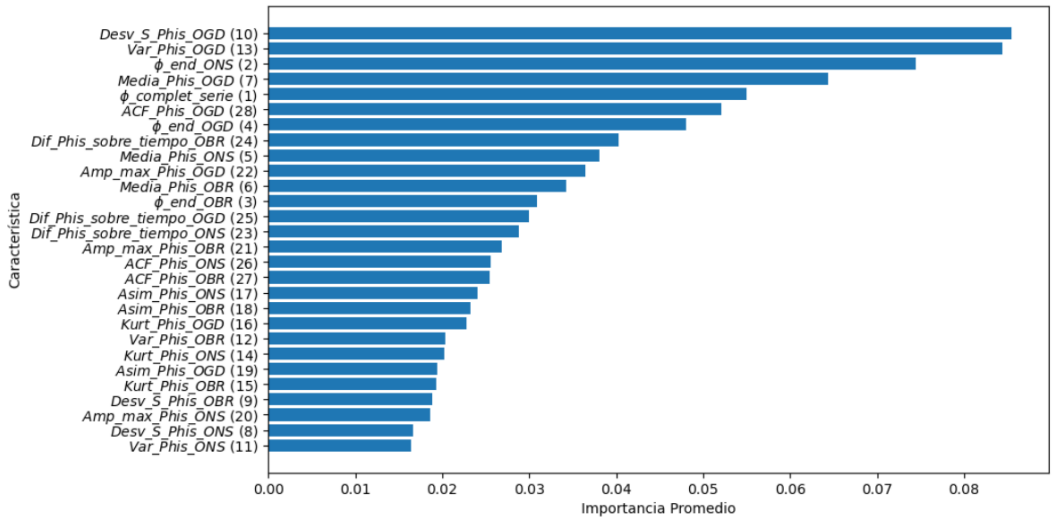
la importancia de las características se estima al evaluar la reducción de impureza en los nodos de los árboles de decisión, lo que indica cómo cada característica mejora la segmentación de los datos. En el caso de Gradient Boosting (GB), la importancia se determina mediante la mejora incremental que cada característica aporta a la reducción de la función de pérdida a lo largo de las iteraciones del modelo. Estas métricas reflejan el impacto de las características en el rendimiento general del modelo.

En la Figura 4.1.2, se muestran todas las características ordenadas según su nivel de importancia promedio calculada en la banda r para ambos modelos, seleccionada debido a que mostró los mejores resultados en la Tabla 4.1. Los valores de importancia se obtuvieron aplicando la función en cada uno de los 20 modelos de Random Forest y Gradient Boosting, y posteriormente se calculó el promedio simple de los valores, los cuales se presentan en los gráficos para cada característica.

En el análisis de la importancia de características para el clasificador Random Forest, se evidencia que las dos características más destacadas, $Desv_S_Phis_OGD(10)$ y $Var_Phis_OGD(13)$, presentan un nivel de importancia promedio muy similar, lo que sugiere que ambas contribuyen de manera significativa a la clasificación de los objetos estocásticos. A partir de este punto, se observa una disminución gradual en la importancia de las características, culminando en $ACF_Phis_OGD(28)$, donde se registra un descenso notable en la importancia de las restantes.

Para el caso del modelo Gradient Boosting, se identifica que las cuatro características principales ($\phi_end_ONS(2)$, $Desv_S_Phis_OGD(10)$, $\phi_complet_serie(1)$ y $Var_Phis_OGD(13)$) exhiben una importancia similar. Esto indica que, al igual que en el modelo anterior, estas características juegan un papel crucial en el rendimiento del clasificador. Posteriormente, se presenta un primer escalón en la importancia que incluye las características $ACF_Phis_OGD(28)$, $Media_Phis_OGD(7)$ y $Dif_Phis_sobre_tiempo_OBR(24)$, las cuales también son consideradas relevantes. Sin embargo, más allá de este grupo, la importancia de las características restantes disminuye de manera significativa, lo que sugiere que su contribución a la clasificación es limitada.

(a) Clasificador RF



(b) Clasificador GB

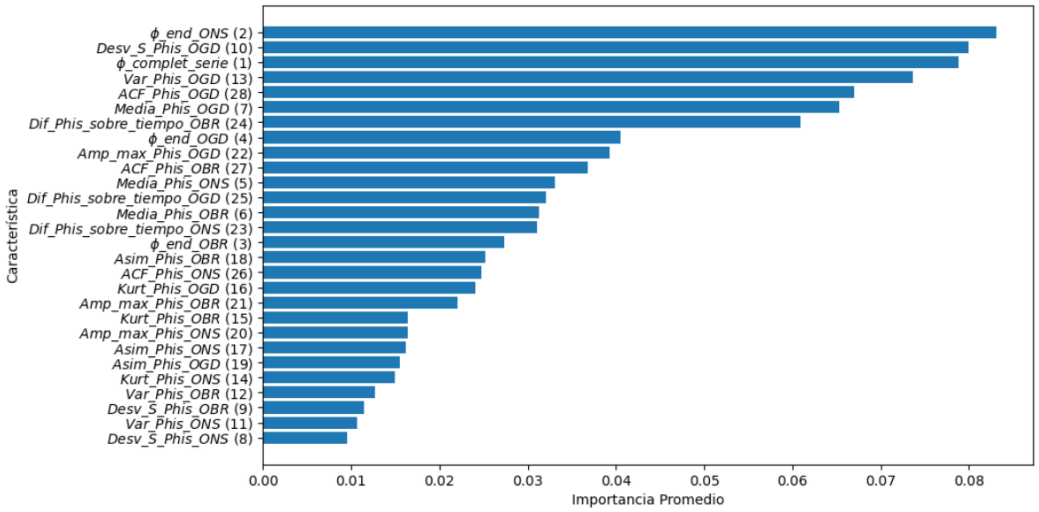


Figura 4.1.2: Gráficos de barras generados con los valores de importancia promedio para las características definidas, resultantes de 20 aplicaciones del clasificador RF y GB en la banda r.

Adicionalmente en la Tabla 4.2 se presenta un resumen de las seis características que obtuvieron los mayores puntajes de importancia promedio para cada modelo y cada banda de un total de veintocho.

	Random Forest	Importancia promedio	**Gradient Boosting**	Importancia promedio
Banda g	$Desv_S_Phis_OGD(10)$	0.08	$\phi_complet_serie(1)$	0.0869
	$\phi_end_ONS(2)$	0.0758	$\phi_end_ONS(2)$	0.0738
	$Var_Phis_OGD(13)$	0.0719	$Var_Phis_OGD(13)$	0.0712
	$\phi_complet_serie(1)$	0.0659	$Desv_S_Phis_OGD(10)$	0.0693
	$Amp_max_Phis_OGD(22)$	0.0462	$Amp_max_Phis_OGD(22)$	0.0435
	$ACF_Phis_OGD(28)$	0.0431	$Amp_max_Phis_OBR(21)$	0.0408
Banda r	$Desv_S_Phis_OGD(10)$	0.0855	$\phi_end_ONS(2)$	0.0831
	$Var_Phis_OGD(13)$	0.0844	$Desv_S_Phis_OGD(10)$	0.0799
	$\phi_end_ONS(2)$	0.0744	$\phi_complet_serie(1)$	0.0788
	$Media_Phis_OGD(7)$	0.0644	$Var_Phis_OGD(13)$	0.0735
	$\phi_complet_serie(1)$	0.0549	$ACF_Phis_OGD(28)$	0.0669
	$ACF_Phis_OGD(28)$	0.0521	$Media_Phis_OGD(7)$	0.0652

Tabla 4.2: Seis características con más alto valor de importancia promedio en cada banda y para cada modelo, ordenadas de mayor a menor valor de importancia.

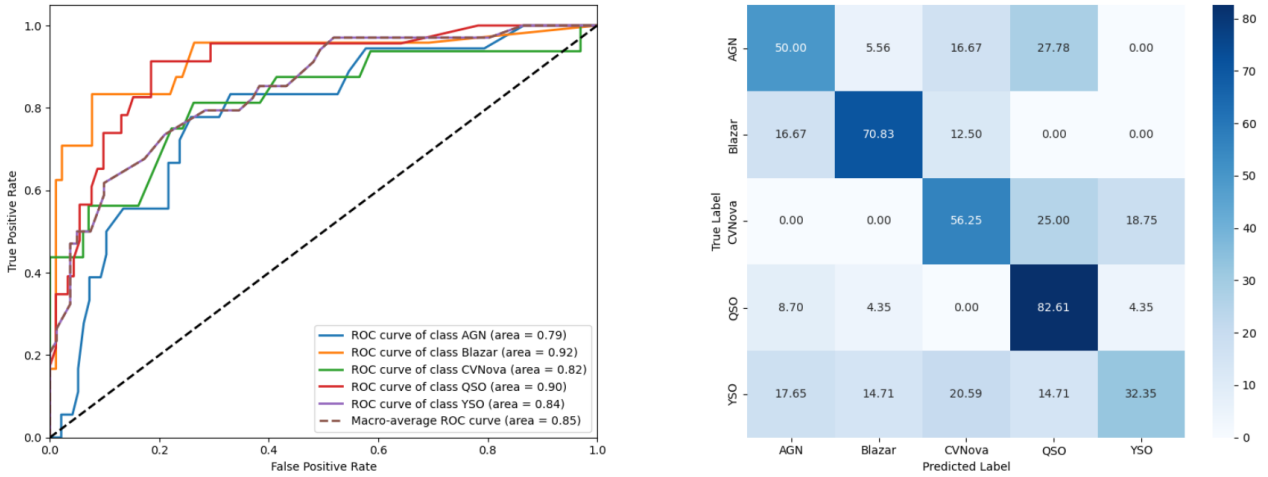
Se observa que varias características se repiten en la banda g para ambos modelos, destacándose las características $Desv_S_Phis_OGD(10)$, $\phi_end_ONS(2)$, $Var_Phis_OGD(13)$ y nuestra característica de referencia $\phi_complet_serie(1)$. Es importante señalar que la característica $Amp_max_Phis_OGD(22)$ se descarta, dado que su valor de importancia promedio se reduce casi a la mitad en comparación con la característica que ocupa el primer puesto en cada modelo. Al promediar los valores de importancia promedio que se obtienen en cada modelo para las características destacadas que se repiten en ambos, se obtienen valores de 0.0746, 0.0748, 0.0715, y 0.0764 para las características 10, 2, 13 y 1, respectivamente. Este resultado muestra que la característica $\phi_complet_serie(1)$, utilizada como referencia, sigue siendo la más importante en la banda g, aunque las características 10, 2 y 13, derivadas de los métodos iAR-OGD y iAR-ONS, presentan un desempeño similar, lo que sugiere que aportan información relevante para la clasificación en la banda g.

Para la banda r, se observan resultados similares, lo que era de esperar, ya que la curva de luz en las bandas g y r presentan comportamientos parecidos pero desfasados. Las características $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$, $\phi_end_ONS(2)$ y $\phi_complet_serie(1)$ se repiten entre las mejores. Aunque podría considerarse incluir las características $Media_Phis_OGD(7)$ o $ACF_Phis_OGD(28)$, se opta por descartarlas, ya que se busca más calidad que cantidad. Los valores promediadaos de la importancia promedio entre cada modelo para estas características en la banda r muestran que las características 10, 13, 2 y 1 tienen valores de 0.0827, 0.0789, 0.0787, y 0.0668, respectivamente. Aquí, las características 10, 13 y 2 superan a la característica de referencia en un 23.8 %, 18.1 % y 17.8 % respectivamente.

A continuación, utilizaremos la matriz de confusión junto con las curvas ROC, como herramienta para analizar las subclases de objetos que mostraron mejores resultados para nuestras características. La matriz de confusión se construyó promediando los porcentajes de aciertos de las 20 ejecuciones realizadas para cada modelo, y los valores resultantes se colocaron en cada casilla utilizando la función *confusionmatrix* de Python. Las curvas ROC, por su parte, corresponden a un caso particular de una de las 20 ejecuciones del modelo, generadas con la función *roccurve* del paquete Scikit-learn.

En la figura 4.1.3 se presenta la matriz de confusión y las curvas ROC para ambos clasificadores utilizando los datos de la banda r. Se observa que la fracción de verdaderos positivos en la matriz de confusión presenta variaciones significativas, siendo los QSO y Blazar las subclases con mejores resultados, seguidos por los CVNova. En contraste, las subclases AGN y, de manera más notable, YSO, muestran valores significativamente más bajos en comparación con las otras subclases. Es importante mencionar que, al igual que los resultados de las métricas del clasificador, los valores en la matriz de confusión son en general bajos; sin embargo, la razón de presentar este gráfico es para comparar los resultados entre las distintas clases.

(a) Clasificador RF



(b) Clasificador GB

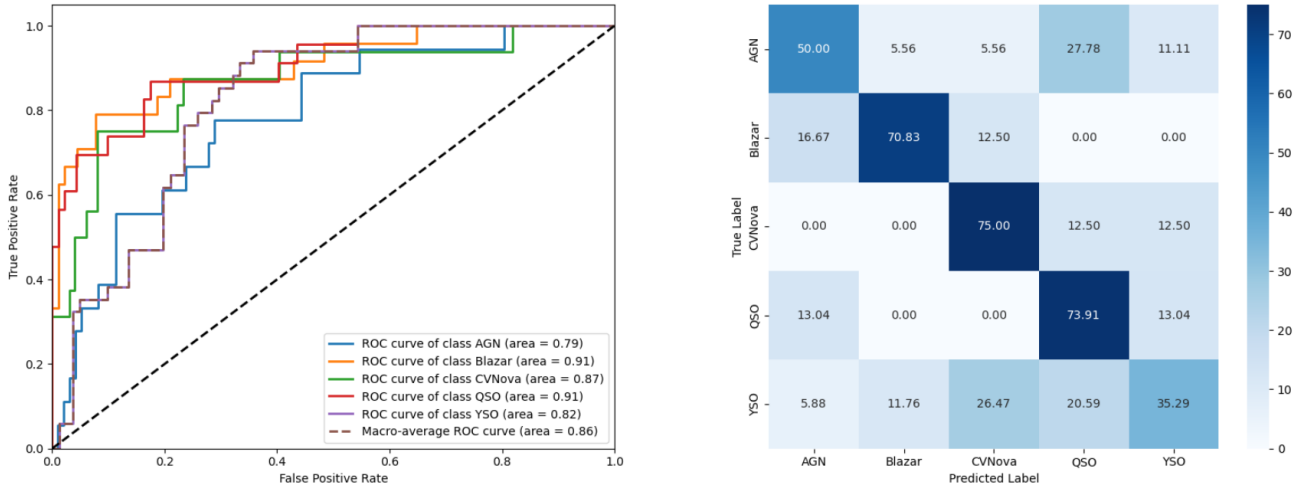


Figura 4.1.3: Gráficos de la curva ROC y matriz de confusión en los clasificadores RF y GB para la banda r

Para finalizar, se presentarán los resultados obtenidos al aplicar el clasificador con mejor desempeño, en este caso, el algoritmo Random Forest, a las dos subclases de objetos que mostraron el mejor rendimiento según la matriz de confusión: QSO y Blazar. En la Tabla 4.3 se muestran las métricas macro promediadas del clasificador, considerando únicamente estas dos subclases.

Tabla 4.3: Valores macro promediadas obtenidas por el clasificador RF utilizando las características $\phi_complet_serie(1)$, $\phi_end_ONS(2)$, $Media_Phis_OGD(7)$, $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$ y $ACF_Phis_OGD(28)$ en el conjunto de prueba utilizando las clases de objetos de tipo Blazar y QSO.

$Precision_{macro}$	$Recall_{macro}$	F_{1macro}
$0,97 \pm 0,021$	$0,97 \pm 0,021$	$0,97 \pm 0{,}02$

El clasificador presenta resultados muy precisos para distinguir entre los objetos de tipo Blazar y QSO, con una $Precision_{macro}$ de $0,97$. Además, en el Anexo se pueden consultar el gráfico de barras que indica el valor de las importancias promedio de las seis características utilizadas, junto con la matriz de confusión promedio.

Conclusión Resultados subclases Estocásticas

Las características $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$, $\phi_end_ONS(2)$ y $\phi_complet_serie(1)$ mostraron consistencia en ambas bandas, g y r. En particular, en la banda r, las características $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$, $\phi_end_ONS(2)$ superaron a la característica de referencia $\phi_complet_serie(1)$ en un $23.8\,\%$, $18.1\,\%$ y $17.8\,\%$ respectivamente. Este hallazgo resalta la relevancia de estas características en el análisis, demostrando un mejor desempeño que nuestra característica de referencia.

En cuanto a las subclases de objetos estocásticos, los Blazar y QSO obtuvieron los mejores resultados al utilizar las características definidas, alcanzando una precisión macro promedio de 0,97 al clasificar estos objetos con el modelo Random Forest utilizando las seis características de mayor importancia en la banda r.

4.2. Resultados para las subclases de objetos Transientes

En esta sección, nos enfocamos exclusivamente en las subclases de objetos transientes, de las cuales, como se mencionó en los preliminares, existen cuatro: SLSN, SNIa, SNIbc y SNII. Los resultados se presentan de manera análoga a los obtenidos para las subclases de objetos estocásticos.

Comenzamos mostrando gráficos de caja para algunas características seleccionadas, en las cuales se observan ciertos comportamientos que podrían resultar de interés.

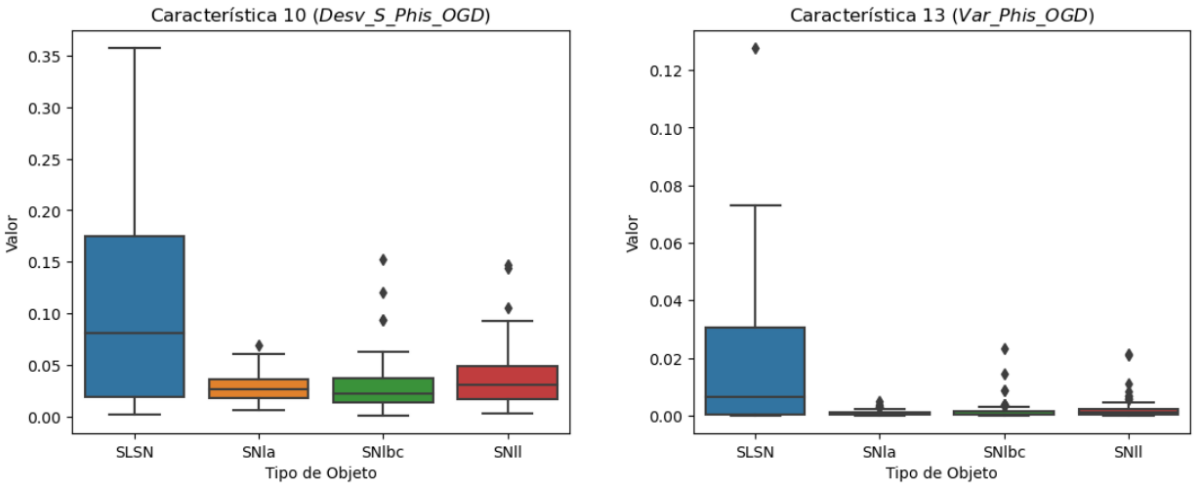


Figura 4.2.1: Gráficos de caja de los valores de las características $Desv_S_Phis_OGD(10)$ y $Var_Phis_OGD(13)$ calculados en la banda g, agrupados por cada subclase que presentan los objetos transientes.

En la Figura 4.2.1 se observan dos gráficos de caja correspondientes a las características $Desv_S_Phis_OGD(10)$ y $Var_Phis_OGD(13)$ calculadas en la banda g. La selección de estas características fue un desafío, ya que no se detectaron diferencias claras y consistentes entre todas las subclases.

No obstante, las características $Kurt_Phis_OGD(16)$ y $Var_Phis_OGD(13)$ muestran una distribución algo diferente para la subclase SLSN en comparación con las demás, lo que sugiere la relevancia de estas características para dicha subclase. Para las otras subclases, no se encontraron patrones suficientemente diferenciadores.

A continuación, se presentan los resultados obtenidos al evaluar los clasificadores Random Forest (RF) y Gradient Boosting (GB) en las subclases de objetos transientes, utilizando las métricas de evaluación ya mencionadas.

Los resultados en la Tabla 4.4 indican que ambos clasificadores tienen un rendimiento similar, aunque se observa una ligera ventaja al utilizar las características extraídas de la banda g. Esto sugiere que dicha banda podría contener más información relevante para la clasificación de subclases en comparación con la banda r. Sin embargo, la diferencia de rendimiento no es tan pronunciada como en el caso de los objetos estocásticos.

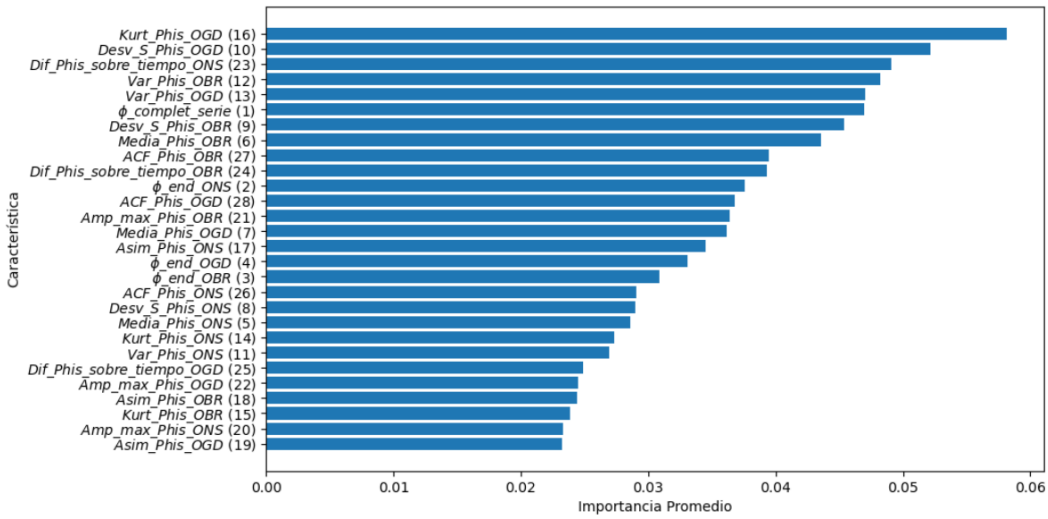
Tabla 4.4: Valores macro promediadas obtenidas para el clasificador RF y GB en el conjunto de prueba utilizando las subclases de los objetos de tipo estocástico.

Banda	**Clasificador**	$Precision_{macro}$	$Recall_{macro}$	F_{1macro}
g	Random Forest	$0,67 \pm 0,060$	$0,67 \pm 0,060$	$0,66 \pm 0{,}062$
g	Gradient Boosting	$0,65 \pm 0,055$	$0,65 \pm 0,049$	$0,64 \pm 0{,}051$
r	Random Forest	$0,61 \pm 0,039$	$0,59 \pm 0,044$	$0,58 \pm 0{,}039$
r	Gradient Boosting	$0,61 \pm 0,051$	$0,59 \pm 0,051$	$0,58 \pm 0{,}048$

Aunque las diferencias no son significativas, los mejores resultados se obtienen en la banda g, lo que sugiere que contiene características más relevantes. Por ello, en la siguiente sección se presentarán los resultados del análisis de importancia de características en la banda g para ambos clasificadores, RF y GB, con el objetivo de entender mejor cuáles contribuyen más a la clasificación de las subclases.

La Figura 4.2.2 muestra las características ordenadas por su nivel de importancia promedio en la banda g para ambos modelos.

(a) Clasificador RF



(b) Clasificador GB

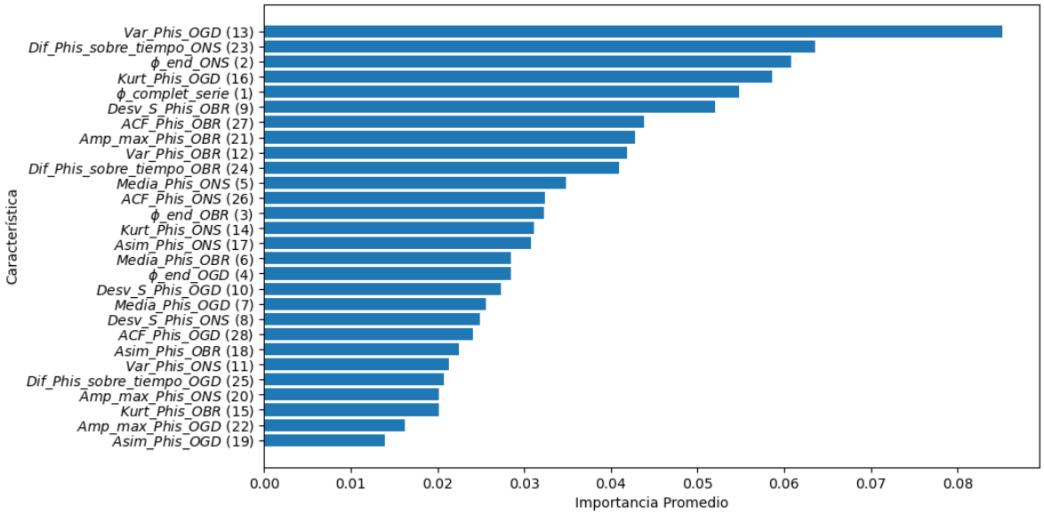


Figura 4.2.2: Gráficos de barras del valor de importancia promedio de las características definidas, resultantes de 20 aplicaciones del clasificador RF y GB en la banda g.

En el gráfico del modelo Random Forest (RF), se observa que la característica $Kurt_Phis_OGD(16)$ destaca por tener la mayor importancia promedio, superando al resto. A continuación, se encuentra $Desv_S_Phis_OGD(10)$, seguida de un grupo de características con una relevancia similar: $Dif_Phis_tiempo_ONS(23)$, $Var_Phis_OBR(12)$, $Var_Phis_OGD(13)$ y $\phi_complet_serie(1)$. A partir de este punto, la importancia de las demás características disminuye de manera notable.

Por otro lado, el modelo Gradient Boosting (GB) muestra un comportamiento distinto. En este caso, $Var_Phis_OGD(13)$ es la característica más importante con mucha diferencia, seguida de un grupo compuesto por $Dif_Phis_tiempo_ONS(23)$, $\phi_end_ONS(2)$, $Kurt_Phis_OGD(16)$, $\phi_complet_serie(1)$ y $Desv_S_Phis_OBR(9)$. Tras este grupo, la importancia de las demás características disminuye abruptamente.

En la Tabla 4.5 se presenta un resumen de las seis características con más alto valor de importancia promedio para cada modelo, tanto en la banda g como en la r, lo que ayuda a llegar a conclusiones más claras.

	Random Forest	Importancia promedio	**Gradient Boosting**	Importancia promedio
Banda g	$Kurt_Phis_OGD(16)$	0.0582	$Var_Phis_OGD(13)$	0.0852
	$Desv_S_Phis_OGD(10)$	0.0522	$Dif_Phis_tiempo_ONS(23)$	0.0636
	$Dif_Phis_tiempo_ONS(23)$	0.049	$\phi_end_ONS(2)$	0.0608
	$Var_Phis_OBR(12)$	0.0483	$Kurt_Phis_OGD(16)$	0.0586
	$Var_Phis_OGD(13)$	0.0471	$\phi_complet_serie(1)$	0.0548
	$\phi_complet_serie(1)$	0.0469	$Desv_S_Phis_OBR(9)$	0.0409
Banda r	$Kurt_Phis_OGD(16)$	0.0641	$Kurt_Phis_OGD(16)$	0.0721
	$ACF_Phis_OGD(28)$	0.0485	$ACF_Phis_OGD(28)$	0.0627
	$Dif_Phis_tiempo_ONS(23)$	0.0484	$Asim_Phis_OGD(19)$	0.0614
	$Asim_Phis_OGD(19)$	0.0468	$\phi_complet_serie(1)$	0.0551
	$\phi_complet_serie(1)$	0.0436	$\phi_end_ONS(2)$	0.0522
	$Media_Phis_OGD(7)$	0.0433	$Dif_Phis_tiempo_ONS(23)$	0.0503

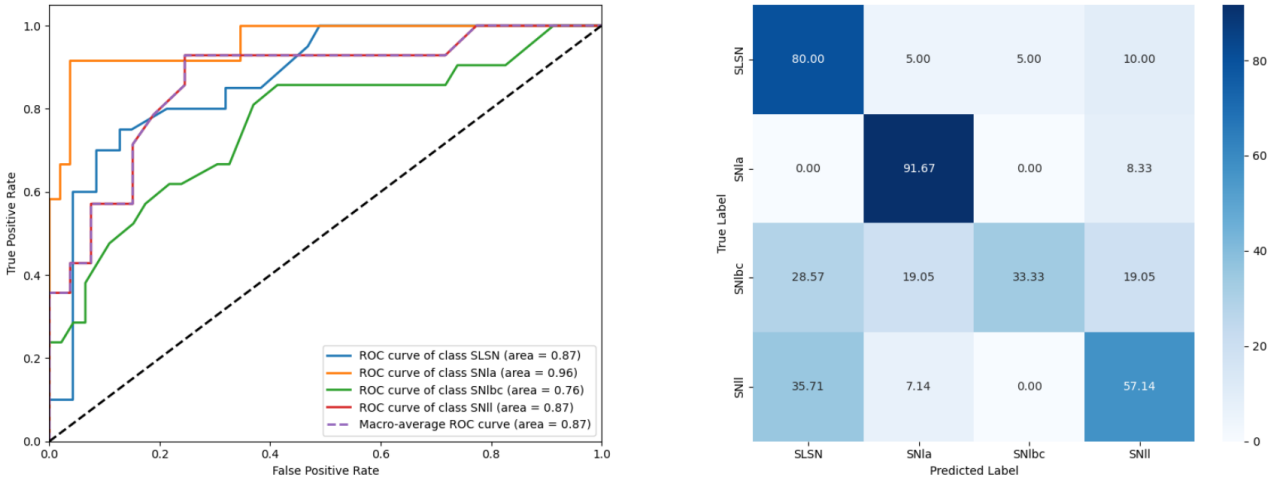
Tabla 4.5: Seis Características ordenadas de mayor a menor valor de importancia en cada modelo y banda para los objetos de tipo estocásticos.

A partir de los resultados presentados en la tabla de importancia de características para las subclases transientes en la banda g, se identifican como recurrentes en ambos modelos (Random Forest y Gradient Boosting) las siguientes características: $Kurt_Phis_OGD(16)$, $Var_Phis_OGD(13)$, $Dif_Phis_tiempo_ONS(23)$ y $\phi_complet_serie(1)$. Al promediar los valores de importancia promedio que se obtienen en cada modelo para las características destacadas que se repiten en ambos, se obtienen valores de 0.0584, 0.0661, 0.0563 y 0.0508 para las características 16,13,23,1. En términos porcentuales, $Kurt_Phis_OGD(16)$, $Var_Phis_OGD(13)$ y $Dif_Phis_tiempo_ONS(23)$ superan por un 15 %, 30.1 % y 10.83 % a los valores promediados que presenta la característica de referencia, respectivamente. Estos resultados subrayan la importancia destacada de $Var_Phis_OGD(13)$.

En la banda r, se observa un patrón similar, destacándose nuevamente $Kurt_Phis_OGD(16)$, junto con $ACF_Phis_OGD(28)$, $Asim_Phis_OGD(19)$ y $\phi_complet_serie(1)$ como características recurrentes en ambos modelos. Al promediar los valores de importancia promedio que se obtienen en cada modelo para las características destacadas que se repiten en ambos, se obtienen valores de 0.0681, 0.0556, 0.0541 y 0.0493 para las características 16, 28, 19, 1. Comparando con la característica de referencia, $Kurt_Phis_OGD(16)$ es un 38.1 % más importante, mientras que $ACF_Phis_OGD(28)$ y $Asim_Phis_OGD(19)$ muestran una importancia adicional del 12.8 % y 9.7 % respectivamente. Estos resultados consolidan a $Kurt_Phis_OGD(16)$ como la característica más relevante en la banda r.

Finalmente, utilizamos la matriz de confusión junto con las curvas ROC para analizar las subclases de objetos que mostraron mejores resultados en función de las características seleccionadas.

(a) Clasificador RF



(b) Clasificador GB

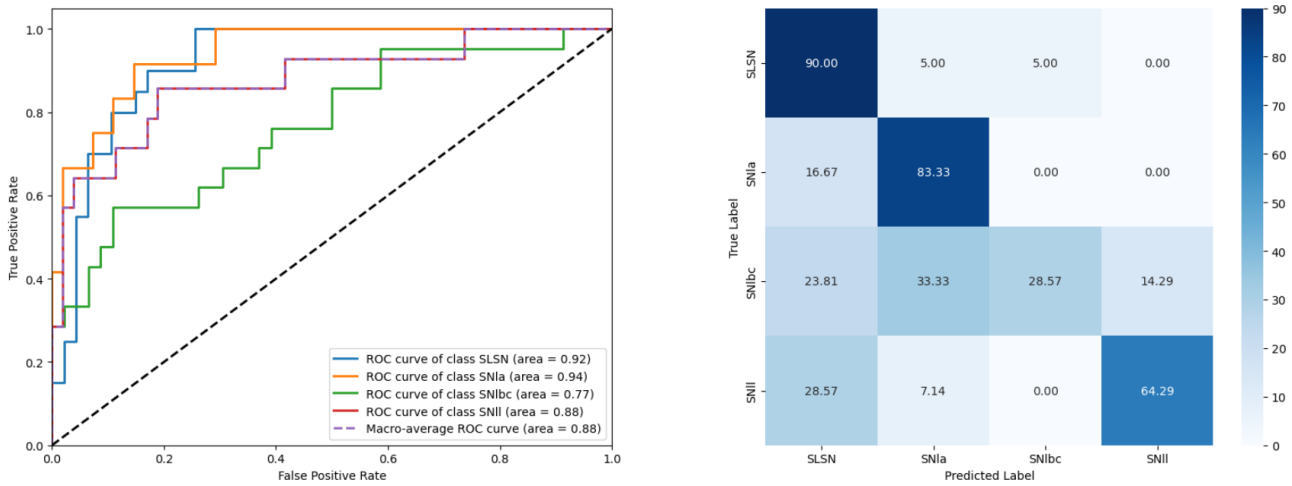


Figura 4.2.3: Gráficos de la curva ROC y matriz de confusión en los clasificadores RF y GB para la banda g

En la Figura 4.2.3 se presenta la matriz de confusión y las curvas ROC para cada tipo de objetos utilizando la banda g. Tanto la matriz de confusión como las curvas ROC se construyen de la misma manera explicada para los objetos estocásticos, pero aplicadas esta vez a las subclases transientes.

Se observa que las subclases transientes con los mejores resultados de clasificación utilizando las características definidas en los clasificadores Random Forest (RF) y Gradient Boosting (GB) fueron los SLSN y SNIa, seguidos por los SNII, mientras que SNIbc mostró un desempeño considerablemente inferior.

Conclusión de Resultados subclases Transientes

En cuanto a la importancia de las características, en la banda g, $Var_Phis_OGD(13)$ fue la más relevante, con un 30,01 % de mayor importancia en comparación con la característica de referencia $\phi_complet_serie(1)$. Características como $Kurt_Phis_OGD(16)$ y $Dif_Phis_tiempo_ONS(23)$ también tuvieron importancia similar, superando a la característica de referencia con un 15 % y 10,83 %, respectivamente. En la banda r, $Kurt_Phis_OGD(16)$ fue la que obtuvo mejores resultados, destacándose con un 38,1 % por encima de la característica de referencia, mientras que $ACF_Phis_OGD(28)$ y $Asim_Phis_OGD(19)$ la superaron en un 12,8 % y 9,7 %, respectivamente. Estos resultados muestran la relevancia que presentan estas características, al presentar una importancia por encima de la característica de referencia.

En cuanto a las subclases de objetos transientes, los SLSN y SNIl obtuvieron los mejores resultados al utilizar las caracteríisticas definidas, le siguen los de la subclase SNIl, por otro lado los SNIbc son los que obtuvieron peores resultados.

Capítulo 5

Conclusiones

5.1. Discusión

Los resultados obtenidos en este estudio subrayan la relevancia de las características derivadas del método iAR-OGD para la clasificación tanto de subclases estocásticas como de subclases transientes. En particular, se observó que el método iAR-OGD destacó en ambas bandas, g y r, logrando identificar características significativas para ambos tipos de objetos, lo que resalta su versatilidad.

Para las subclases estocásticas, las características mostraron una mayor importancia relativa en comparación con las subclases transientes. El valor más alto de importancia en estas subclases fue de aproximadamente 0.0827, que ocurre en la banda r, donde la característica 10 superó a la característica de referencia $\phi_c omplet_s erie(1)$ en un 23.8 %, siendo la más relevante dentro de este grupo. Mientras que para las subclases transientes, las características más importantes en cada banda presentaron un valor promedio de importancia inferior (alrededor de 0,6), el porcentaje con el que superan a la característica de referencia fue mayor. Las características más destacadas lograron incrementos del 30.1 % en la banda g y del 38.1 % en la banda r respecto a la referencia, lo que demuestra su efectividad en la clasificación de estos objetos, aunque con una menor importancia en los modelos.

Finalmente, es importante señalar que los datos utilizados para este trabajo, en especial para los objetos estocásticos, mostraron en su mayoría probabilidades de

pertenencia cercanas al 100 %, lo que refuerza la solidez de las clasificaciones en este grupo. En contraste, para algunas subclases transientes, como SNla y SNll, se observaron probabilidades de pertenencia más bajas, producto de que estas subclases de objetos no son tan abundantes como los otros, lo que limita la disponibilidad de muestras de observaciones de curvas de luz para ellos.

5.2. Conclusión

Los resultados de este estudio subrayan la efectividad de las características definidas para la clasificación de subclases estocásticas y transientes, destacando especialmente su desempeño en la banda r. Las características derivadas del modelo iAR-OGD, como $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$ y $\phi_end_ONS(2)$, demostraron una notable consistencia, superando a la característica de referencia $\phi_complet_serie(1)$ con incrementos significativos del 23.8 %, 18.1 % y 17.8 %, respectivamente, en la banda r. Este hallazgo resalta la importancia de estas características y su impacto positivo en el rendimiento de los modelos de clasificación.

La aplicación de seis características clave, que incluyen $Desv_S_Phis_OGD(10)$, $Var_Phis_OGD(13)$, $\phi_end_ONS(2)$, $\phi_complet_serie(1)$, $Media_Phis_OGD(7)$ y $Amp_max_Phis_OGD$, permitió alcanzar métricas sobresalientes, como $precision_{macro}$, $Recall_{macro}$ y F_{1macro}, con un promedio de 0,97 al clasificar entre Blazar y QSO utilizando el modelo Random Forest. Esto evidencia la capacidad de estas características para diferenciar eficazmente entre estos dos tipos de subclases.

Para las subclases transientes, $Var_Phis_OGD(13)$ y $Kurt_Phis_OGD(16)$ obtuvieron los mejores resultados en las bandas g y r, respectivamente. En la banda g, $Var_Phis_OGD(13)$ mostró un incremento del 38.1 % en comparación con la característica de referencia, mientras que en la banda r, $Kurt_Phis_OGD(16)$ superó la referencia en un 38.1 %. Estos resultados indican que estas características, también derivadas del modelo iAR-OGD, son fundamentales para la discriminación precisa entre las subclases transientes.

En conclusión, el método de estimación online iAR-OGD demuestra una notable capacidad para generar características relevantes que permiten ajustar clasificadores efectivos para objetos astronómicos, tanto de tipo transiente como estocástico, fortaleciendo así el análisis y clasificación en el ámbito de la astrofísica.

5.3. Trabajos Futuros

El trabajo realizado en esta tesis abre nuevas oportunidades para investigaciones futuras. Uno de los aspectos más interesantes sería evaluar el desempeño del clasificador de ALeRCE al incorporar las características que han demostrado buenos resultados en este estudio, sumándolas a su conjunto original de características.

Asimismo, sería valioso realizar un procedimiento similar al de este trabajo, pero utilizando otros modelos para series de tiempo con intervalos irregulares, como el modelo Modelo Autorregresivo Irregular Continuo (CIAR). Este análisis no solo mejoraría nuestra comprensión de la interacción entre las características y el rendimiento de los modelos, sino que también podría conducir a la mejora de clasificación para objetos estocásticos y astronómicos.

Capítulo 6

Bibliografía

[1] P. Sánchez-Sáez et al. «Alert Classification for the ALeRCE Broker System: The Light Curve Classifier». En: (2021).

[2] Alerce Project. *Explorador ZTF de Alerce*. URL: https://alerce.online/.

[3] G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung. *Time Series Analysis: Forecasting and Control*. 5th. John Wiley & Sons, Inc., 2015.

[4] L. Breiman. «Random forests». En: *Machine Learning* 45 (2001), págs. 5-32.

[5] P. Brockwell y R. Davis. *Introduction to Time Series and Forecasting*. New York: Springer-Verlag, 2002.

[6] F. Elorrieta, S. Eyheramendy y W. Palma. «Discrete-time autoregressive model for unequally spaced time-series observations». En: (2019).

[7] F. Elorrieta, L. Osses, M. Cáceres, S. Eyheramendy, W. Palma y E. Barientes. «Online estimation methods for irregular autoregressive models». En: (2022).

[8] Elorrieta F. Eyheramendy S. y Palma W. «An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves». En: (2018).

[9] Castillo-Navarrete E. et al. Förster F. Cabrera-Vives G. «The automatic learning for the rapid classification of events (ALeRCE) alert broker». En: (2020).

[10] J. H. Friedman. «Greedy Function Approximation: A Gradient Boosting Machine». En: *Annals of Statistics* 29.5 (2001), págs. 1189-1232.

[11] R. E. Kalman. *A New Approach to Linear Filtering and Prediction Problems*. Vol. 82. 1. J. Basic Eng., 1960, págs. 35-45.

[12] G. Lindgren, H. Rootzén y M. Sandsten. *Stationary Stochastic Processes for Scientists and Engineers*. Chapman y Hall, 2013.

[13] F. J. Masci, R. R. Laher, B. Rusholme et al. «The Zwicky Transient Facility: Data Processing, Products, and Archive». En: *Publications of the Astronomical Society of the Pacific* 131.995 (2019), pág. 018003.

[14] E. Parzen. «Time series analysis of irregularly observed data». En: *Proceedings of a Symposium Held at Texas*. Lecture Notes in Statistics. New York: Springer-Verlag, 1984.

[15] M. T. Patterson et al. «The Zwicky Transient Facility Alert Distribution System». En: *Publications of the Astronomical Society of the Pacific* 131.995 (2019), pág. 018001.

[16] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot y E. Duchesnay. «Scikit-learn: Machine learning in Python». En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830.

[17] L. Rokach y O.Z. Maimon. *Minería de datos con árboles de decisión: teoría y aplicaciones*. Singapore: World Scientific, 2008.

Capítulo 7

Anexos

7.1. Tablas completas de resultados

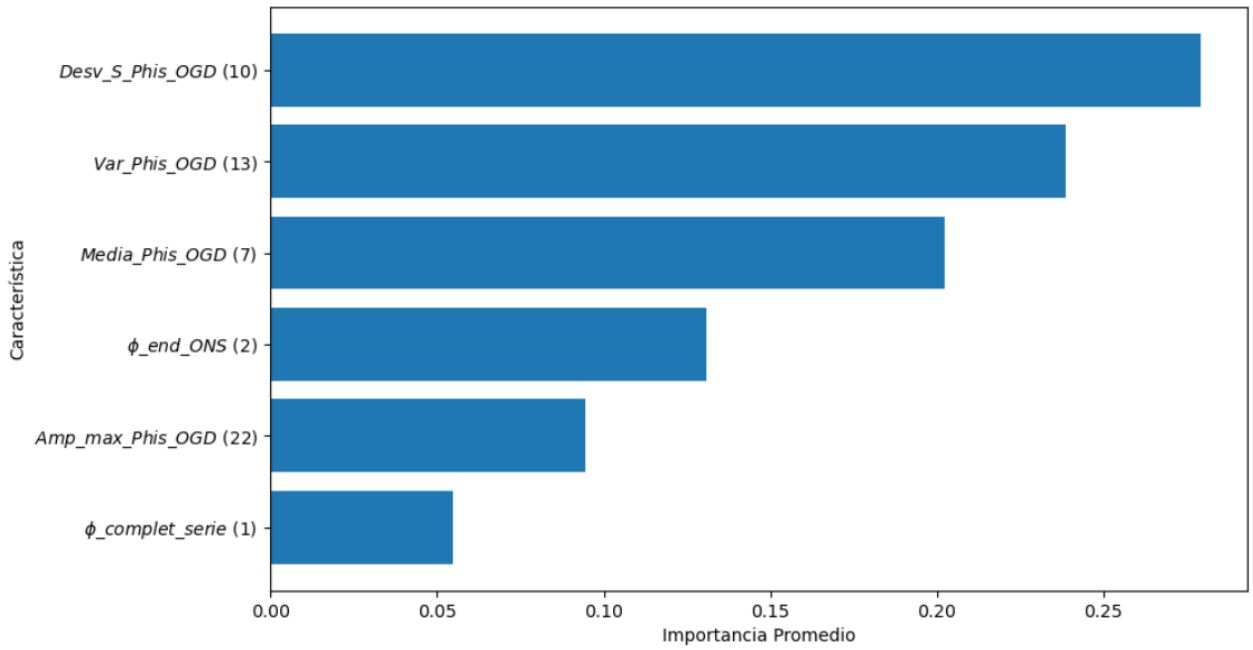


Figura 7.1.1: Gráfico de barras con la importancía de las características para el clasificador RF utilizando las caracteristicas 1,2,7,10,13 y 28, en el conjunto de prueba utilizando las clases de objetos de tipo Blazar y QSO.

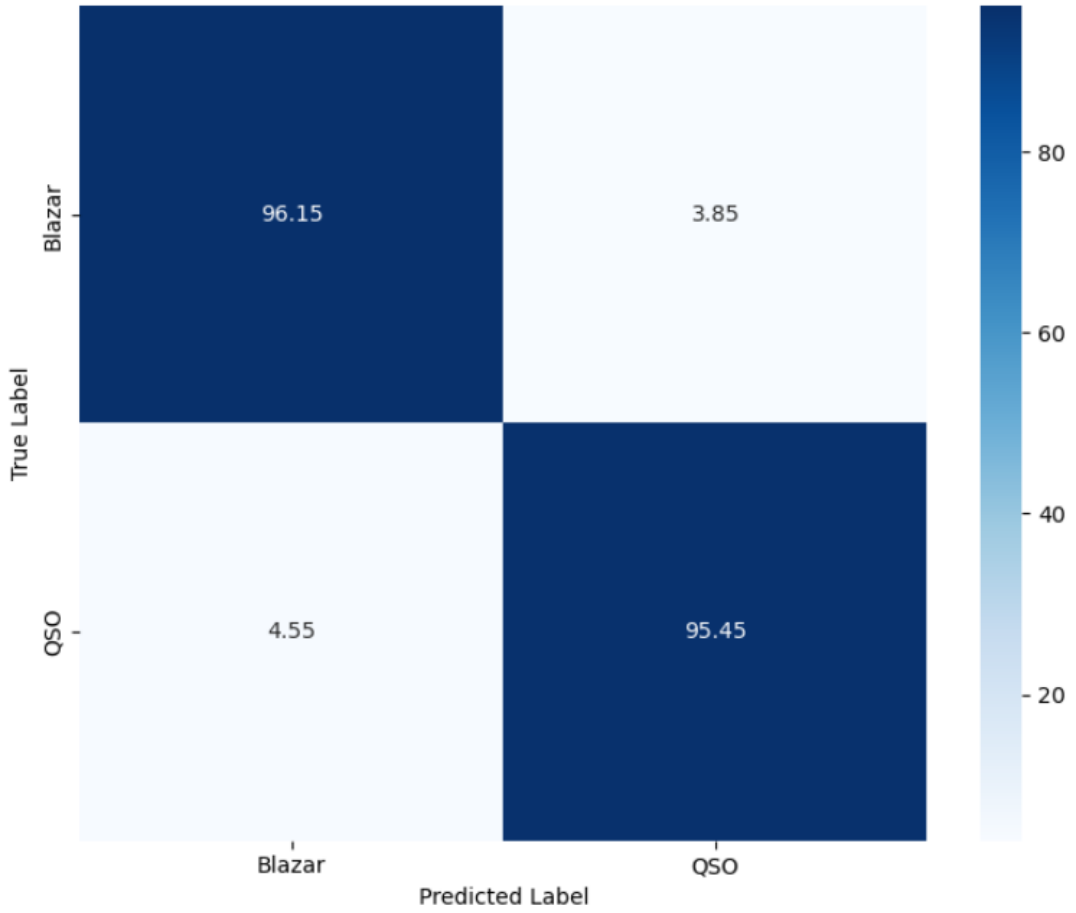


Figura 7.1.2: Matriz de confusión con la importancía de las características para el clasificador RF utilizando las caracteristicas 1,2,7,10,13 y 28, en el conjunto de prueba utilizando las clases de objetos de tipo Blazar y QSO.

7.2. Códigos Python para extracción de curvas de Luz

```
ruta1= 'C:/Users/Juanco/Desktop/tesis/Objetos astronomicos/
   Estocasticos/QSO.txt'
ID_QSO = []
# Llenamos la lista ID_QSO con los nombres en el documento de
   texto que incluye estos objetos.
with open(ruta1, 'r') as file:
    for linea in file:
        ID_QSO.extend([elemento.strip() for elemento in linea.
           strip().split(',') if elemento.strip()])

# Utilizamos la funcion alerce.query_lightcurve para importar los
    metadatos de cada objeto astronomico en la lista ID_QSO
lightcurve_QSO = []
for idd in ID_QSO:
    lightcurve_QSO.append(alerce.query_lightcurve(idd, format="
       pandas"))
```

```
# Funcion que retorna la curva de luz, como dos diccionarios, el primero incluye los datos de intensidad de brillo
# y el segundo el tiempo.
def curva_luz(lightcurve, ID, fid=2):
    intensidad_luz = {}
    tiempo = {}
    aux1 = []
    aux2 = []
    for j in range(len(lightcurve)):
        aux = lightcurve[j]
        for i in range(len(aux['detections'][0])):
            if aux['detections'][0][i]['fid'] == fid:  # Corresponde al filtro (1=g; 2=r)
                if aux['detections'][0][i]['magpsf_corr'] == None:  # No agregamos los valores NULL
                    pass
                else:
                    aux1.append(aux['detections'][0][i]['magpsf_corr'])
                    aux2.append(aux['detections'][0][i]['mjd'])

        intensidad_luz[ID[j]] = aux1
        tiempo[ID[j]] = aux2
        aux1 = []
        aux2 = []

    return intensidad_luz, tiempo

# Ejemplo de uso de la funcion definida para importar las curvas de luz de la subclase QSO para el filtro g.
aux = curva_luz(lightcurve_QSO, ID_QSO, fid=1)
intensidad_luz_QSO = aux[0]
tiempo_QSO = aux[1]
```

7.3. Función creada en Python para generar los gráficos de cajas de las Figuras 3.4.1 y 3.4.2

```
def grafico_cajas(DF_CARACT,sel_caract=np.arange(1,29),
   titulo_grafico=None):
    Nombre_caract = [r'$\phi\_complet\_serie$',r'$\phi\_end\_ONS$
       ',r'$\phi\_end\_OBR$',r'$\phi\_end\_OGD$',r'$Media\_Phis\
       _ONS$',r'$Media\_Phis\_OBR$',r'$Media\_Phis\_OGD$',r'$Desv
       \_S\_Phis\_ONS$',r'$Desv\_S\_Phis\_OBR$',r'$Desv\_S\_Phis\
       _OGD$',r'$Var\_Phis\_ONS$',r'$Var\_Phis\_OBR$',r'$Var\
       _Phis\_OGD$',r'$Kurt\_Phis\_ONS$',r'$Kurt\_Phis\_OBR$',r'
       $Kurt\_Phis\_OGD$',r'$Asim\_Phis\_ONS$',r'$Asim\_Phis\
       _OBR$',r'$Asim\_Phis\_OGD$',r'$Amp\_max\_Phis\_ONS$',r'
       $Amp\_max\_Phis\_OBR$',r'$Amp\_max\_Phis\_OGD$',r'$Dif\
       _Phis\_sobre\_tiempo\_ONS$',r'$Dif\_Phis\_sobre\_tiempo\
       _OBR$',r'$Dif\_Phis\_sobre\_tiempo\_OGD$',r'$ACF\_Phis\
       _ONS$',r'$ACF\_Phis\_OBR$',r'$ACF\_Phis\_OGD$']
    aux_caract_selec=DF_CARACT.columns.tolist()[0:-1]

    caract_selec=[]
    Nombre_caract_selec=[]
    for i in sel_caract:
        caract_selec.append(aux_caract_selec[i-1])
        Nombre_caract_selec.append(Nombre_caract[i-1])

    num_vars=len(caract_selec)
    tipo_objeto = 'Tipo'
    n_cols = 2
    n_filas = (num_vars + n_cols - 1) // n_cols
    fig, axs = plt.subplots(n_filas, n_cols, figsize=(12, (math.
       ceil(len(caract_selec)/2))*5))
    fig.tight_layout(pad=5.0)
```

```
    # Crear un boxplot para cada caracter stica
    for i, caract in enumerate(caract_selec):
        fila = i // n_cols
        col = i % n_cols
        numero_caract=re.findall(r'\d+', caract_selec[i])[0]
        sns.boxplot(ax=axs[fila, col], x=tipo_objeto, y=caract,
           data=DF_CARACT)
        axs[fila, col].set_title(f'Caracter stica {numero_caract
           } ({Nombre_caract_selec[i]})')
        axs[fila, col].set_xlabel('Tipo de Objeto')
        axs[fila, col].set_ylabel(r'Valor')

    # Apagar los subplots que no se utilizan
    for i in range(num_vars, n_filas*n_cols):
        fila = i // n_cols
        col = i % n_cols
        axs[fila, col].axis('off')

    # Guardar el gr fico si se proporciona un path
    if titulo_grafico:
        fig.savefig(titulo_grafico, bbox_inches='tight')  #
           Guarda el gr fico en el path especificado

    plt.show()

#Ejemplo de uso para obtener como resultado el gr fico de cajas
   de las caracter sticas 2, 10, 13 y 7 de las subclases
   estocasticas
grafico_cajas(Caract_est_2,sel_caract=[2,10,13,7])
```