

**UNIVERSIDAD DE SANTIAGO DE
CHILE
FACULTAD DE CIENCIA
DEPARTAMENTO DE MATEMÁTICAS Y
CIENCIA DE LA COMPUTACIÓN**



**Evaluación de métodos de estimación bayesiana para
clasificación logística con efectos temporales**

Nathaly Saray Garrido Neira

Profesor Guía: Felipe Elorrieta López
= Comisión: Andrés Iturriaga Jofre
Víctor Salinas Torres

**Trabajo de Titulación presentado en conformidad a los requisitos para
obtener el grado de Ingeniera Estadística**

**Santiago - Chile
2023**

2023, Nathaly Saray Garrido Neira
Derechos de autor

Índice de Contenidos

Agradecimientos	3
Resumen	5
1. Introducción	7
1.1. Formulación del Problema	8
1.1.1. Objetivo General	8
1.1.2. Objetivos Específicos	8
1.2. Metodología	9
2. Marco Teórico	11
2.1. Procesos Estocásticos	11
2.1.1. Procesos Estacionarios	11
2.1.1.1. Función de Autocovarianzas	11
2.1.1.2. Proceso Estocástico Estrictamente Estacionario	11
2.1.1.3. Proceso Estocástico Débilmente Estacionario	12
Ruido Blanco (RB)	12
2.1.2. Procesos Markovianos	12
2.1.2.1. Cadena de Markov	12
2.2. Series de Tiempo	12
2.2.1. Procesos Autorregresivos (AR(p))	13
2.3. Estadística Bayesiana	13
2.3.1. Teorema de Bayes	14
Teorema de Bayes para variables aleatorias	14
2.3.2. Bayesiana v/s Clásica	14
2.3.3. Función A Priori($\pi(\theta)$)	14
2.3.3.1. Clasificación Función a priori	15
2.3.4. Función A Posteriori	15
2.3.5. Función Predictiva A Priori	16
2.3.6. Función Máxima A Posteriori (MAP)	16
2.3.7. Markov Chain Monte Carlo (MCMC)	16
2.3.7.1. Convergencia	16
2.3.7.1.1 La cadena explora el espacio de estados:	17
2.3.7.1.2 La media muestral de la cadena ha convergido:	17
2.3.7.1.3 Autocorrelación de los valores:	18
2.3.7.1.4 Tamaño Efectivo(ES)	18
2.3.7.1.5 Diagnostico de Gelman	18
2.3.8. Tiempo de ejecución	19
2.3.8.1. Método Hamiltoniano (HMC)	19
2.4. Métodos de Clasificación	20

2.4.1. Regresión Logística	20
2.4.1.1. Análisis de factores de riesgo	21
2.4.1.2. Análisis de clasificación	22
2.4.1.2.1 Sensibilidad y Especificidad	22
2.4.1.2.2 Curva de ROC	22
2.4.2. Modelos Logit y Probit	23
Mínimos cuadrados no lineales	23
Máxima Verosimilitud	23
2.4.2.1. Logit	23
2.4.2.2. Probit	24
2.4.3. Clasificación de Series de Tiempo	24
2.5. Librerías en R	24
2.5.1. JAGS	24
2.5.2. STAN	24
2.5.3. Diferencias entre STAN y JAGS	25
3. Estimación Modelo Logístico Clásico	27
3.1. Estimación A Posteriori	27
3.2. Estimación con Datos Simulados	30
3.2.1. JAGS	33
3.2.1.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas	33
3.2.1.1.1 Parámetros Iniciales	33
3.2.1.1.2 Análisis de Convergencia	33
3.2.1.1.3 Estimación Final	36
3.2.1.1.4 Parámetros Finales	38
3.2.1.1.5 Curva ROC y Análisis de Sensibilidad y Especificidad	38
3.2.1.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma	39
3.2.1.2.1 Parámetros Iniciales	39
3.2.1.2.2 Análisis de Convergencia	40
3.2.1.2.3 Estimación Final	44
3.2.1.2.4 Parámetros Finales	48
3.2.1.2.5 Curva ROC y Análisis de Sensibilidad y Especificidad	49
3.2.1.3. Estimación III: Todas las variables y observaciones simuladas, dos cade- nas, sin saltos y varianzas distribuyen Gamma Inversa	50
3.2.1.3.1 Parámetros Iniciales	50
3.2.1.3.2 Análisis de Convergencia	50
3.2.1.3.3 Estimación Final	55
3.2.1.3.4 Parámetros Finales	59
3.2.1.3.5 Curva ROC y Análisis de Sensibilidad y Especificidad	60
3.2.2. STAN	60
3.2.2.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas	60
3.2.2.1.1 Parámetros Iniciales	61
3.2.2.1.2 Análisis de Convergencia	61
3.2.2.1.3 Estimación Final	64
3.2.2.1.4 Parámetros Finales	66
3.2.2.1.5 Curva ROC y Análisis de Sensibilidad y Especificidad	66

3.2.2.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma.	67
3.2.2.2.1 Parámetros Iniciales	67
3.2.2.2.2 Análisis de Convergencia	67
3.2.2.2.3 Estimación Final	72
3.2.2.2.4 Parámetros Finales	76
3.2.2.2.5 Curva ROC y Análisis de Sensibilidad y Especificidad	77
3.2.2.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos sus varianzas distribuyen Gamma Inversa.	78
3.2.2.3.1 Parámetros Iniciales	78
3.2.2.3.2 Análisis de Convergencia	78
3.2.2.3.3 Estimación Final	83
3.2.2.3.4 Parámetros Finales	87
3.2.2.3.5 Curva ROC y Análisis de Sensibilidad y Especificidad	88
3.2.3. Resumen	88
3.3. Estimación con Datos Reales	90
3.3.1. Análisis descriptivo	92
3.3.1.1. Medidas de Tendencia y Dispersión	92
3.3.1.2. Boxplots	94
3.3.1.3. Boxplots según variable binaria rrl	94
3.3.1.4. Correlaciones	96
3.3.2. Estimación Analítica	96
3.3.3. JAGS	96
3.3.3.1. Estimación I: Eliminación de variables, una cadena, sin salto y sin outliers	96
Parámetros I	96
Análisis de Convergencia	97
Curva ROC y Análisis de Sensibilidad y Especificidad	102
3.3.3.2. Estimación II: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma.	102
Parámetros V	103
Análisis de Convergencia	103
Curva ROC y Análisis de Sensibilidad y Especificidad	108
3.3.3.3. Estimación III: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma Inversa.	108
Parámetros VI	109
Análisis de Convergencia	109
Curva ROC y Análisis de Sensibilidad y Especificidad	114
3.3.4. STAN	115
3.3.4.1. Estimación I: Eliminación de variables, una cadena, sin salto y sin outliers.	115
Parámetros I	115
Análisis de Convergencia	115
Curva ROC y Análisis de Sensibilidad y Especificidad	118
3.3.4.2. Estimación II: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma.	118
Parámetros II	119
Análisis de Convergencia	119
Curva ROC y Análisis de Sensibilidad y Especificidad	124
3.3.4.3. Estimación III: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma Inversa.	124
Parámetros III	125

Análisis de Convergencia	125
Curva ROC y Análisis de Sensibilidad y Especificidad	130
3.3.5. Resumen	131
4. Estimación Modelo Logístico con Componentes de Tiempo	133
5. Conclusiones	135
Referencias Bibliográficas	137
Anexos	139
1. Apéndice 1: Resultados Datos Simulados	141
1.1. Estimación con Datos Simulados, JAGS	141
1.1.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas.	141
1.1.1.1. Intervalos Parámetros Iniciales	141
1.1.1.2. Tabla Sensibilidad y Especificidad	141
1.1.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma.	142
1.1.2.1. Intervalos Parámetros Iniciales	142
1.1.2.2. Tabla Sensibilidad y Especificidad	143
1.1.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma Inversa.	143
1.1.3.1. Intervalos Parámetros Iniciales	143
1.1.3.2. Tabla Sensibilidad y Especificidad	144
1.2. Estimación con Datos Simulados, Stan	144
1.2.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas.	144
1.2.1.1. Intervalos Parámetros Iniciales	144
1.2.1.2. Tabla Sensibilidad y Especificidad	145
1.2.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma.	145
1.2.2.1. Intervalos Parámetros Iniciales	145
1.2.2.2. Tabla Sensibilidad y Especificidad	146
1.2.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma Inversa.	147
1.2.3.1. Intervalos Parámetros Iniciales	147
1.2.3.2. Tabla Sensibilidad y Especificidad	147
2. Apéndice 2: Resultados Datos Reales	149
2.1. Correlaciones	149
2.2. Modelo GLM	150
2.2.1. Parámetros	150
2.2.2. Curva ROC y Análisis de Sensibilidad y Especificidad	151
2.3. Estimación Analítica	152
2.3.1. JAGS	152
2.3.1.1. Estimación Analítica I: Todas las variables, todas las observaciones, una cadena y sin salto	152
Parámetros I	152
Análisis de convergencia	153

Curva ROC y Análisis de Sensibilidad y Especificidad	156
2.3.1.2. Estimación Analítica II: Todas las variables, una cadena, sin salto y sin outliers	157
Parámetros II	157
Análisis de Convergencia	158
Curva ROC y Análisis de Sensibilidad y Especificidad	161
2.3.1.3. Estimación Analítica III: Todas las variables, una cadena, sin salto y sin outliers	162
Parámetros III	162
Análisis de Convergencia	163
Curva ROC y Análisis de Sensibilidad y Especificidad	167
2.3.2. STAN	168
2.3.2.1. Estimación Analítica I: Todas las variables, una cadena, todas las observaciones y sin salto	168
Parámetros I	168
Análisis de Convergencia	169
Curva ROC y Análisis de Sensibilidad y Especificidad	173
2.3.2.2. Estimación Analítica II: Todas las variables, una cadena, sin salto y sin outliers.	174
Parámetros II	174
Análisis de Convergencia	175
Curva ROC y Análisis de Sensibilidad y Especificidad	179
2.3.2.3. Estimación Analítica III: Todas las variables, una cadena, sin salto y sin outliers, intento 2.	180
Parámetros III	180
Análisis de Convergencia	180
Curva ROC y Análisis de Sensibilidad y Especificidad	184
2.3.3. Resumen	185
2.4. Estimación Datos Reales	185
2.4.1. JAGS	185
2.4.1.1. Estimación I: Todas las variables, todas las observaciones, una cadena y sin salto	185
2.4.1.1.1 Intervalos Parámetros	185
2.4.1.1.2 Tabla Sensibilidad y Especificidad	186
2.4.1.2. Estimación II: Todas las variables, una cadena, sin salto y sin outliers . .	186
2.4.1.2.1 Intervalos Parámetros	186
2.4.1.2.2 Tabla Sensibilidad y Especificidad	187
2.4.1.3. Estimación III: Todas las variables, una cadena, sin salto y sin outliers .	188
2.4.1.3.1 Intervalos Parámetros	188
2.4.1.3.2 Tabla Sensibilidad y Especificidad	189
2.4.2. STAN	189
2.4.2.1. Estimación I: Todas las variables, todas las observaciones, una cadena y sin salto	189
2.4.2.1.1 Intervalos Parámetros	189
2.4.2.1.2 Tabla Sensibilidad y Especificidad	190
2.4.2.2. Estimación II: Todas las variables, una cadena, sin salto y sin outliers . .	190
2.4.2.2.1 Intervalos Parámetros	191
2.4.2.2.2 Tabla Sensibilidad y Especificidad	191
2.4.2.3. Estimación III: Todas las variables, una cadena, sin salto y sin outliers .	192
2.4.2.3.1 Intervalos Parámetros	192

2.4.2.3.2 Tabla Sensibilidad y Especificidad	193
3. Apéndice 3: Código	195
4. Código	197

Índice de Figuras

1.	Esquema General	9
1.	Ejemplos de estacionaridad.[15]	17
2.	Ejemplo comparación de medias[15]	17
3.	Ejemplo comparación de correlaciones.[15]	18
4.	Ejemplo Diagnostico de Gelman	19
5.	Tiempo Estimación I, Jags.	19
1.	Esquema Datos Simulados	31
2.	Funciones a posteriori parámetros iniciales Estimación I Datos Simulados, JAGS. . .	34
3.	Gráficas de autocorrelación de los parámetros iniciales Estimación I Datos Simulados, JAGS.H	35
4.	Funciones a posteriori parámetros finales Estimación I Datos Simulados,JAGS. . . .	36
5.	Gráficas de autocorrelación parámetros finales Estimación I Datos Simulados, JAGS. .	37
6.	Curva Roc Modelo I con Datos Simulados	39
7.	Funciones a posteriori parámetros iniciales Estimación II Datos Simulados, JAGS. .	40
8.	Funciones a posteriori σ^2 , Estimación II Datos Simulados, JAGS.	41
9.	Gráficas de autocorrelación parámetros iniciales Estimación II Datos Simulados, JAGS. .	42
10.	Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación II Datos Simulados, JAGS.	43
11.	Funciones a posteriori parámetros finales Estimación II Datos Simulados, JAGS. . .	44
12.	Funciones a posteriori σ^2 , Estimación II Datos Simulados, JAGS	45
13.	Gráficas de autocorrelación parámetros finales Estimación II Datos Simulados, JAGS. .	46
14.	Gráficas de autocorrelación parámetros finales σ^2 , Estimación II Datos Simulados, JAGS.	47
15.	Curva Roc Modelo II con Datos Simulados	49
16.	Funciones a posteriori parámetros iniciales Estimación III Datos Simulados, JAGS. .	51
17.	Funciones a posteriori σ^2 , Estimación III Datos Simulados, JAGS.	52
18.	Gráficas de autocorrelación parámetros iniciales Estimación III Datos Simulados, JAGS.	53
19.	Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación III Datos Simulados, JAGS.	54
20.	Funciones a posteriori parámetros finales Estimación III Datos Simulados, JAGS. .	55
21.	Funciones a posteriori σ^2 , Estimación III Datos Simulados, JAGS.	56
22.	Gráficas de autocorrelación parámetros finales Estimación III Datos Simulados, JAGS. .	57
23.	Gráficas de autocorrelación parámetros finales σ^2 , Estimación III Datos Simulados, JAGS.	58
24.	Curva Roc Modelo III con Datos Simulados	60
25.	Funciones a posteriori parámetros iniciales Estimación I Datos Simulados, STAN. .	62
26.	Gráficas de autocorrelación parámetros iniciales Estimación I Datos Simulados, STAN.H	63

27.	Funciones a posteriori parámetros finales Estimación I Datos Simulados, Stan. . . .	64
28.	Gráficas de autocorrelación parámetros finales Estimación I Datos Simulados, Stan.	65
29.	Curva Roc Modelo I con Datos Simulados	67
30.	Funciones a posteriori parámetros iniciales Estimación II Datos Simulados, Stan. . .	68
31.	Funciones a posteriori σ^2 , Estimación II Datos Simulados, Stan.	69
32.	Gráficas de autocorrelación parámetros iniciales Estimación II Datos Simulados, Stan.	70
33.	Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación II Datos Simulados, Stan.	71
34.	Funciones a posteriori parámetros finales Estimación II Datos Simulados, Stan. . . .	72
35.	Funciones a posteriori σ^2 , Estimación II Datos Simulados, Stan.	73
36.	Gráficas de autocorrelación parámetros finales Estimación II Datos Simulados, Stan.	74
37.	Gráficas de autocorrelación parámetros finales σ^2 , Estimación II Datos Simulados, Stan.	75
38.	Curva Roc Modelo II con Datos Simulados	77
39.	Funciones a posteriori parámetros iniciales Estimación III Datos Simulados, Stan. .	79
40.	Funciones a posteriori σ^2 , Estimación III Datos Simulados, JAGS.	80
41.	Gráficas de autocorrelación parámetros iniciales Estimación III Datos Simulados, Stan.	81
42.	Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación III Datos Simulados, Stan.	82
43.	Funciones a posteriori parámetros finales Estimación III Datos Simulados, Stan. . .	83
44.	Funciones a posteriori σ^2 , Estimación III Datos Simulados, Stan.	84
45.	Gráficas de autocorrelación parámetros finales Estimación III Datos Simulados, Stan.	85
46.	Gráficas de autocorrelación parámetros finales σ^2 , Estimación III Datos Simulados, Stan.	86
47.	Curva Roc Modelo III con Datos Simulados	88
48.	Esquema Datos Reales	91
49.	Boxplots de las variables cuantitativas.. . . .	94
50.	Boxplot.	95
51.	Boxplot.	95
52.	Correlaciones de los Datos Reales.	96
53.	Funciones a posteriori Estimación Datos reales I, JAGS.	98
54.	Funciones a posteriori σ^2 Estimación Datos reales I, JAGS.	99
55.	Funciones de autocorrelación Estimación Datos reales I, JAGS.. . . .	100
56.	Funciones de autocorrelación σ^2 Estimación Datos reales I, JAGS.	101
57.	Curva ROC modelo para Estimación Datos reales I, JAGS	102
58.	Funciones a posteriori Estimación Datos reales II, JAGS.	104
59.	Funciones a posteriori σ^2 Estimación Datos reales II, JAGS.	105
60.	Funciones de autocorrelación Estimación Datos reales II, JAGS.	106
61.	Funciones de autocorrelación σ^2 Estimación Datos reales II, JAGS.	107
62.	Curva ROC modelo para Estimación Datos reales II, JAGS.	108
63.	Funciones a posteriori Estimación Datos reales III, JAGS.	110
64.	Funciones a posteriori σ^2 Estimación Datos reales III, JAGS.	111
65.	Funciones de autocorrelación Estimación Datos reales III, JAGS.	112
66.	Funciones de autocorrelación σ^2 Estimación Datos reales III, JAGS.	113
67.	Tamaño Efectivo Estimación III Datos Reales, Jags.	114
68.	Curva ROC modelo para Estimación Datos reales III, JAGS	114
69.	Funciones a posteriori Estimación Datos reales I, Stan.	116
70.	Funciones de autocorrelación Estimación Datos reales I, Stan.	117
71.	Curva ROC modelo para Estimación Datos reales I, Stan	118
72.	Funciones a posteriori Estimación Datos reales II, Stan.	120

73.	Funciones a posteriori σ^2 Estimación Datos reales II, Stan.	121
74.	Funciones de autocorrelación Estimación Datos reales II, Stan.	122
75.	Funciones de autocorrelación σ^2 Estimación Datos reales V, Stan.	123
76.	Curva ROC modelo para Estimación Datos reales II, Stan	124
77.	Funciones a posteriori Estimación Datos reales III, Stan.	126
78.	Funciones a posteriori σ^2 Estimación Datos reales III, Stan.	127
79.	Funciones de autocorrelación Estimación Datos reales III, Stan.	128
80.	Funciones de autocorrelación σ^2 Estimación Datos reales III, Stan.	129
81.	Curva ROC modelo para Estimación Datos reales III, Stan	130
1.	Esquema Observados v/s Predichos	142
2.	Esquema Observados v/s Predichos	143
3.	Esquema Observados v/s Predichos	144
4.	Esquema Observados v/s Predichos	145
5.	Esquema Observados v/s Predichos	146
6.	Esquema Observados v/s Predichos	148
1.	Correlaciones de los Datos Reales.	149
2.	Correlaciones de los Datos Reales.	150
3.	Modelo de Teoría clásica.	150
4.	Curva ROC modelo GLM para Datos Reales	151
5.	Esquema Observados v/s Predichos	151
6.	Funciones a posteriori Estimación Analítica Datos reales I, JAGS.	154
7.	Funciones de autocorrelación Estimación Analítica Datos reales I, JAGS.	155
8.	Curva ROC modelo para Estimación Analíticas Datos reales I, JAGS	156
9.	Esquema Observados v/s Predichos Estimación Analítica Datos reales I, JAGS . . .	157
10.	Funciones a posteriori Estimación Analítica Datos reales II, JAGS.	159
11.	Funciones de autocorrelación Estimación Analítica Datos reales II, JAGS.	160
12.	Curva ROC modelo para Estimación Analítica Datos reales II, JAGS	161
13.	Esquema Observados v/s Predichos Estimación Datos reales II, JAGS	162
14.	Funciones a posteriori Estimación Analítica Datos reales III, JAGS.	164
15.	Funciones de autocorrelación Estimación Analítica Datos reales III, JAGS.	166
16.	Curva ROC modelo para Estimación Analítica Datos reales III, JAGS	167
17.	Esquema Observados v/s Predichos Estimación Analítica Datos reales III, JAGS . .	168
18.	Funciones a posteriori Estimación Analítica Datos reales I, Stan.	170
19.	Funciones de autocorrelación Estimación Analítica Datos reales I, Stan.	172
20.	Curva ROC modelo para Estimación Analítica Datos reales I, Stan	173
21.	Esquema Observados v/s Predichos Estimación Datos reales I, Stan	173
22.	Funciones a posteriori Estimación Analítica Datos reales II, Stan.	176
23.	Funciones de autocorrelación Estimación Analítica Datos reales II, Stan.	178
24.	Curva ROC modelo para Estimación Analítica Datos reales II, Stan	179
25.	Esquema Observados v/s Predichos Estimación Analítica Datos reales II, Stan . . .	179
26.	Funciones a posteriori Estimación Analítica Datos reales III, Stan.	181
27.	Funciones de autocorrelación Estimación Analítica Datos reales III, Stan.	183
28.	Curva ROC modelo para Estimación Analítica Datos reales III, Stan	184
29.	Esquema Observados v/s Predichos Estimación Datos reales III, Stan	185
30.	Esquema Observados v/s Predichos Estimación Datos reales I, JAGS	186
31.	Esquema Observados v/s Predichos Estimación Datos reales II, JAGS.	188
32.	Esquema Observados v/s Predichos Estimación Datos reales III, JAGS	189
33.	Esquema Observados v/s Predichos Estimación Datos reales I, Stan	190
34.	Esquema Observados v/s Predichos Estimación Datos reales II, Stan	192

35.	Esquema Observados v/s Predichos Estimación Datos reales III, Stan	193
-----	--	-----

Índice de Tablas

1.	Diferencia entre las teorías estadísticas	14
2.	Diferencia entre Stan y JAGS.	26
1.	Parámetros iniciales Estimación I Datos Simulados,JAGS.	33
2.	Tamaño Efectivo Estimación I, Jags.	35
3.	Diagnóstico de Gelman Estimación I, Jags	36
4.	Tamaño Efectivo Estimación I Final, Jags.	37
5.	Diagnóstico de Gelman Estimación I Final, Jags	37
6.	Tiempo Estimación I, Jags.	38
7.	Parámetros finales Estimación I Datos Simulados,JAGS.	38
8.	Intervalos de colas iguales	38
9.	Intervalo de más alta prob. cadena 1	38
10.	Intervalo de más alta prob. cadena 2	38
11.	Parámetros iniciales Estimación II Datos Simulados, JAGS.	39
12.	Tamaño Efectivo Estimación II, Jags.	43
13.	Diagnóstico de Gelman Estimación II, Jags	44
14.	Tamaño Efectivo Estimación II final, Jags.	47
15.	Diagnóstico de Gelman Estimación II Final, Jags	48
16.	Tiempo Estimación II , Jags.	48
17.	Parámetros finales Estimación II Datos Simulados, JAGS.	48
18.	Intervalos de colas iguales	48
19.	Intervalo de más alta prob. cadena 1	48
20.	Intervalo de más alta prob. cadena 2	49
21.	Parámetros iniciales Estimación III Datos Simulados, JAGS.	50
22.	Tamaño Efectivo Estimación III, Jags.	54
23.	Diagnóstico de Gelman Estimación III, Jags	55
24.	Tamaño Efectivo Estimación III final, Jags.	58
25.	Diagnóstico de Gelman Estimación III Final, Jags	59
26.	Tiempo Estimación III, Jags.	59
27.	Parámetros finales Estimación III Datos Simulados, JAGS.	59
28.	Intervalos de colas iguales	59
29.	Intervalo de más alta prob. cadena 1	59
30.	Intervalo de más alta prob. cadena 2	60
31.	Parámetros iniciales Estimación I Datos Simulados, STAN.	61
32.	Tamaño Efectivo Estimación I, Stan.	63
33.	Diagnóstico de Gelman Estimación I, Stan	63
34.	Tamaño Efectivo Estimación I final, Stan.	65
35.	Diagnóstico de Gelman Estimación I Final, Stan	65
36.	Tiempo Estimación I, Stan.	66

37.	Parámetros finales Estimación I Datos Simulados, Stan.	66
38.	Intervalo de colas iguales	66
39.	Intervalo más alta prob. Cadena 1	66
40.	Intervalo más alta prob. Cadena 2	66
41.	Parámetros iniciales Estimación II Datos Simulados, Stan.	67
42.	Tamaño Efectivo Estimación II, Stan.	71
43.	Diagnóstico de Gelman Estimación II, Stan	72
44.	Tamaño Efectivo Estimación final II, Stan.	75
45.	Diagnóstico de Gelman Estimación II Final, Stan	76
46.	Tiempo Estimación II, Stan.	76
47.	Parámetros finales Estimación II Datos Simulados, Stan.	76
48.	Intervalo de colas iguales	76
49.	Intervalo más alta prob. Cadena 1	76
50.	Intervalo más alta prob. Cadena 2	77
51.	Parámetros iniciales Estimación III Datos Simulados, Stan.	78
52.	Tamaño Efectivo Estimación III , Stan.	82
53.	Diagnóstico de Gelman Estimación III, Stan	83
54.	Tamaño Efectivo Estimación III final, Stan.	86
55.	Diagnóstico de Gelman Estimación III Final, Stan	87
56.	Tiempo Estimación III, Stan.	87
57.	Parámetros finales Estimación III Datos Simulados, Stan.	87
58.	Intervalo de colas iguales	87
59.	Intervalo más alta prob. Cadena 1	87
60.	Intervalo más alta prob. Cadena 2	88
61.	Tabla Resumen Datos Simulados JAGS	89
62.	Tabla Resumen Datos Simulados Stan	89
63.	Medidas Descriptivas Datos Reales	92
64.	Parámetros Estimación Datos reales I, JAGS	97
65.	Tamaño Efectivo Estimación I Datos Reales, Jags.	102
66.	Tiempo Estimación I, Jags.	102
67.	Parámetros Estimación Datos reales II, JAGS	103
68.	Tamaño Efectivo Estimación II Datos Reales, Jags.	107
69.	Tamaño Efectivo Estimación II Datos Reales, Jags.	108
70.	Tiempo Estimación II, Jags.	108
71.	Parámetros Estimación Datos reales III, JAGS	109
72.	Tamaño Efectivo Estimación II Datos Reales, Jags.	114
73.	Tamaño Efectivo Estimación II Datos Reales, Jags.	114
74.	Tiempo Estimación III, Jags.	114
75.	Parámetros Estimación Datos reales I, Stan	115
76.	Tamaño Efectivo Estimación I Datos Reales, Stan.	118
77.	Tiempo Estimación I, Stan.	118
78.	Parámetros Estimación Datos reales II, Stan	119
79.	Tamaño Efectivo Estimación II Datos Reales, Jags.	124
80.	Tamaño Efectivo Estimación II Datos Reales, Stan.	124
81.	Tiempo Estimación II, Stan.	124
82.	Parámetros Estimación Datos reales III, Stan	125
83.	Tamaño Efectivo Estimación III Datos Reales, Stan.	130
84.	Tamaño Efectivo Estimación III Datos Reales, Stan.	130
85.	Tiempo Estimación III, Stan.	130
86.	Tabla Resumen Datos Reales JAGS	131

87.	Tabla Resumen Datos Reales Stan	131
1.	Intervalos de colas iguales	141
2.	Intervalo de más alta prob. cadena 1	141
3.	Intervalo de más alta prob. cadena 2	141
4.	Sensibilidad y Especificidad Datos Simulados JAGS	141
5.	Intervalos de colas iguales	142
6.	Intervalo de más alta prob. cadena 1	142
7.	Intervalo de más alta prob. cadena 2	142
8.	Sensibilidad y Especificidad Datos Simulados JAGS	143
9.	Intervalos de colas iguales	143
10.	Intervalo de más alta prob. cadena 1	143
11.	Intervalo de más alta prob. cadena 2	144
12.	Sensibilidad y Especificidad Datos Simulados JAGS	144
13.	Intervalo de colas iguales	145
14.	Intervalo más alta prob. Cadena 1	145
15.	Intervalo más alta prob. Cadena 2	145
16.	Sensibilidad y Especificidad Datos Simulados STAN	145
17.	Intervalo de colas iguales	146
18.	Intervalo más alta prob. Cadena 1	146
19.	Intervalo más alta prob. Cadena 2	146
20.	Sensibilidad y Especificidad Datos Simulados Stan	146
21.	Intervalo de colas iguales	147
22.	Intervalo más alta prob. Cadena 1	147
23.	Intervalo más alta prob. Cadena 2	147
24.	Sensibilidad y Especificidad Datos Simulados Stan	147
1.	Sensibilidad y Especificidad glm	151
2.	Parámetros Estimación Analítica Datos reales I, JAGS	152
3.	Intervalos de colas iguales	152
4.	Intervalos más alta prob	152
5.	Sensibilidad y Especificidad Datos Reales Estimación Analítica I	156
6.	Parámetros Estimación Analítica Datos reales II, JAGS	157
7.	Intervalos de colas iguales	158
8.	Intervalos más alta prob	158
9.	Sensibilidad y Especificidad Datos Reales Estimación Analítica II	161
10.	Parámetros Estimación Analítica Datos reales III, JAGS	162
11.	Intervalos de colas iguales	163
12.	Intervalos más alta prob	163
13.	Sensibilidad y Especificidad Datos Reales Estimación Analítica III	167
15.	Intervalos de colas iguales	168
16.	Intervalos más alta prob	168
14.	Parámetros Estimación Analítica Datos reales I, Stan	169
17.	Sensibilidad y Especificidad Estimación Datos reales I, Stan	173
18.	Parámetros Estimación Analítica Datos reales II, Stan	174
19.	Intervalos de colas iguales	174
20.	Intervalos más alta prob	174
21.	Sensibilidad y Especificidad Estimación Analítica Datos reales II, Stan	179
22.	Parámetros Estimación Analítica Datos reales III, Stan	180
23.	Intervalos de colas iguales	180
24.	Intervalos más alta prob	180

25.	Sensibilidad y Especificidad Estimación Analítica Datos reales III, Stan	184
26.	Intervalos de colas iguales	186
27.	Intervalos más alta prob	186
28.	Sensibilidad y Especificidad Datos Reales Estimación I	186
29.	Intervalos de colas iguales	187
30.	Intervalos más alta prob	187
31.	Sensibilidad y Especificidad Datos Reales Estimación II	187
32.	Intervalos de colas iguales	188
33.	Intervalos más alta prob	188
34.	Sensibilidad y Especificidad Estimación Datos reales III, JAGS	189
35.	Intervalos de colas iguales	189
36.	Intervalos más alta prob	189
37.	Sensibilidad y Especificidad Estimación Datos reales I, Stan	190
38.	Intervalos de colas iguales	191
39.	Intervalos más alta prob	191
40.	Sensibilidad y Especificidad Estimación Datos reales II, Stan	191
41.	Intervalos de colas iguales	192
42.	Intervalos más alta prob	192
43.	Sensibilidad y Especificidad Estimación Datos reales VI, Stan	193

A mi madre, padre, familia y amigos por acompañarme a través de todo este proceso.

Agradecimientos

¡Muchas gracias a todos!

A través de los años en que estuve estudiando esta carrera se me presentaron momentos en los que necesite apoyo de otras persona, sacar este título no es solo un logro para mi, por lo tanto me gustaría agradecer a muchas personas una por una , pero lamentablemente no creo que me alcancen las paginas para eso, por lo tanto agradeceré a algunas personas que deben estar si o si en estas palabras.

En primera instancia quiero agradecer a mis padres, Luis Alberto Garrido Cancino y a Cecilia del Carmen Neira Escobar, que siempre trataron de apoyarme a pesar de no tener idea lo que estaba haciendo o estudiando y tuvieron que aguantarme después de noches enteras sin dormir por estar estudiando o haciendo algún trabajo. Gracias por su apoyo incondicional. También a mis hermanos Cristian y Luis, que me vieron atravesar todo este proceso, así como a mi sobrina Pascal quien me alegro mis momentos desde que era una bebé.

A mi Mami Rosa, que siempre me trataba de dar animo y me decía que siguiera estudiando, que trataba de entender lo cansada que yo podía estar pero que tenia que seguir adelante, la que se alegraba cuando llegaba con una buena nota. Además también agradecer a los que ya partieron, que su existencia en mi vida ayudo demasiado a ser quien soy hoy.

A mi familia en general, a la que tuve que dejar un poco de lado por mis obligaciones, que me perdonaron el faltar a cumpleaños, aniversarios y fechas importantes. A los niños de mi familia, con los cuales siempre podía despejarme o distraerme para tener ese pequeño momento de paz y alegría que ellos me daban. A los miembros que siempre se preocuparon por mi y me daban animo en los momento donde el cansancio y el estrés pasaban la cuenta y creía que ya no podía más con todo.

A mi perrito Simba, con el cual compartí más momentos que nadie mientras estudiaba o trabajaba en algo, incluso mientras escribo esto el esta acostado en mis pies, con el cual desde que llego a mi vida nunca me sentí sola.

A mi pololo Bayron, quien estuvo días y noches enteras estudiando conmigo o simplemente acompañándome o ayudándome, ya sea de manera presencial o por videollamada, gracias por tu apoyo incondicional desde que llegaste a mi vida.

A mis amigos de adolescencia que estuvieron antes y después de este largo proceso, más a mis mejores amigos que siempre estuvieron presente, aun cuando el tiempo no daba juntarse, siempre estuvieron presentes de alguna forma.

A todos y cada uno de los amigos que fui haciendo este camino, gente con la que fui compartiendo clases, estudio, momentos de estrés, tristeza, recreamiento (las fiestas y actividades de la

carrera) y también la alegría de ver a todos ir avanzando y lograr los propósitos de cada uno. Hice muchos amigos a los que de verdad siento muy cercanos a mi, les agradezco cada uno de los momentos en los que estuvieron presentes, a través de conversas, juegos, noches de conversación y juegos en pandemia. De verdad creo que sin ellos no hubiera podido atravesar este proceso. Me gustaría escribir sus nombres, pero por fortuna para mi, estos son demasiados y de verdad espero que sepan quienes son y lo importante que son para mi.

Resumen

A través del modelo logístico con componentes de tiempo se busca proponer un clasificador bayesiano, con el cual se pueda realizar el trabajo de clasificar modelos de series de tiempo.

En primera instancia se realizaran simulaciones o estimaciones para las funciones a posteriori deseadas y obtener con esto los parámetros de los modelos logísticos clásicos, esto se realizará para dos conjuntos de datos: unos de estos simulados con los parámetros a estimar ya conocidos con un total de tres variables(una a predecir y o dos predictoras) y 10000 observaciones, el otro conjunto con datos reales obtenidos y utilizados en el estudio “A Machine Learned Classifier for RR Lyrae in the VVV Survey”,(F.E. et al,2016), el cual se constituye de trece variables(una a predecir y 12 predictoras) y un total de 18809 observaciones.

Para cada conjunto de datos se realizará el análisis a través de 3 tipos de variaciones entre estas utilizando así varianza de los parámetros fija, con una distribución Gamma y una distribución Gamma Inversa.

Estas simulaciones se realizara a través de los métodos MCMC y HMC, los cuales son utilizados en las librerías o programas rjags o jags y en rstan o STAN respectivamente, con el fin de también poder comparar la metodologías y resultados de las simulaciones, para así proponer un mejor modelo el cual se deseara estudiar en futuras investigaciones y que si contenga los componentes de tiempo deseados.

Al realizar una estimación para el conjunto definido y conformado por datos simulados, se obtuvo que el mejor modelo o estimación es a través de la librería Stan con la variación de la varianza con distribución gamma inversa. Para el conjunto de datos reales se obtuvo que la mejor librería es JAGS con la variación de la varianza con distribución gamma inversa

Finalmente se propone un modelo para futuras investigaciones.

Palabras Clave: Hiperparámetros, Estimación Bayesiana, Convergencia, Estacionariedad, Media constante, Autocorrelación, Tamaño efectivo, Tiempo ejecución, MCMC, HMC, Índice de Gelman, Modelo Propuesto.

Capítulo 1

Introducción

Hoy en día, con las grandes cantidades de datos existentes y la variedad de metodologías para el manejo de estos, conocidas como técnicas de Machine Learning, donde se definen los métodos de aprendizaje o clasificación supervisada. Los que a través de algoritmos, identifican patrones en datos masivos y elabora predicciones. Cabe destacar que en la actualidad estos tienen un gran uso y valoración.

Una aplicación constante es el poder agrupar las de serie de tiempo, de forma que de esta manera se puedan clasificar e inferir conductas de las series de tiempo a través de estos grupos en diversos contextos (H. Borchani 2012), la clasificación esta compuesta en primera instancia por el aprendizaje de un modelo de clasificación para un conjunto de datos y en segunda instancia el clasificar las nuevas instancias o datos.

Para lo anteriormente mencionado, se encuentran disponible gran cantidad de clasificadores propuestos con anterioridad tales como Redes Neuronales Recurrente, Random Forest y otros usados en artículos (F.Elorrieta et al. 2016)(P.Sánchez-Sáez et al. 2021). Los que se caracterizan por estar basados en características de las series de tiempo.

Comúnmente el gran problema existente entre estos clasificadores es el que la serie tiene que pasar por un desglose, caracterización o calculo de estadísticas de forma que en base a estas variables construidas a partir de la serie de tiempo se pueda realizar el agrupamiento de estas, lo que en si puede generar una estimación pero no tomando la serie de tiempo como tal. Cosa que las redes neuronales recurrentes si realizan por si mismas.

Como fue ejemplificado (Gang chen 2016), las redes neuronales sirven como clasificadores de una serie de tiempo, tomando la serie o todas sus características en si, esto en el caso recurrente, ya que considerando la definición de red recurrente existente (I. Bonet Cruz et al 2007), “las redes neuronales recurrentes son aquellas que cada neurona puede estar conectada a cualquier otra y sus conexiones recurrentes son variables...”.

Además de que estas pueden servir para comparar o predecir estos modelos, lo anteriormente mencionado se puede ver ejemplificado y comparado en artículos publicados (R. K. Agrawal et al 2013) , (J. J. Montaña 2011),(F. J. Diaz 2019).

Considerando lo anterior, se espera implementar un clasificador bajo el contexto bayesiano, de tipo recurrente para series irregularmente observadas en el tiempo. Lo anterior implica que no se podrán clasificar modelos del tipo ARIMA, ya que estos son de carácter regular, esto se realiza

a diferencia del clasificador Naive Bayes (también clasificador bayesiano) (C. Olmos 2019). Todo lo anterior con la idea de poder clasificar series de tiempo irregulares en el tiempo tales como estrellas de tipo pulsante, datos reales, provenientes de ALeRCE (Automatic Learning for the Rapid Classification and Events)(F. Förster et al. 2021) el cual es un broker dirigido por Chile. Ya que el problema a abordar es de clasificación, la variable respuesta comúnmente suele seguir una distribución Bernoulli, se buscará así el encontrar la función a Posteriori de la función del problema planteado, comúnmente suele tener la naturaleza de una función binaria.

Para todo lo anteriormente mencionado, se propone la ya conocida Regresión logística, la cual se considera un método de clasificación binaria, con la presencia de componentes temporales, la cual presentaría las características para con esta poder definir el clasificador, pero para esto en primera instancia, se debe analizar la estimación a través de la Regresión Logística clásica con el fin de analizar el comportamiento de esta, su uso en ciertas formas de estimación, en metodologías de estimación(MCMC y HMC) y metodologías para analizar si es posible considerar esta para definir un clasificador al incorporarle componentes temporales.

Para esto se consideran dos conjuntos de datos, uno simulado y el otro de datos reales, con los cuales se estimarán a través de 3 variaciones cada uno: varianza de los parámetros fija, varianza con distribución Gamma y varianza con distribución con Gamma Inversa. Todo esto con el fin de analizar la convergencia de las estimaciones del modelo, su clasificación con el fin de utilizar todo esto para postular un modelo y librería(asociado a un método de estimación) al cual se le planea incorporar los componentes temporales.

El modelo propuesto se implementara en el software R (R Foundation for Statistical Computing), con las librerías Stan (Stan 2022) y JAGS , con el fin de poder definir tanto la función como el generar y encontrar las funciones a posteriori que optimicen tanto el trabajo como la calidad del clasificador. Además de lo ya dicho, también es de interés el poder comparar ambas librerías en este proceso

1.1. Formulación del Problema

1.1.1. Objetivo General

Evaluar métodos de estimación bayesiana en una regresión logística con efectos temporales

1.1.2. Objetivos Específicos

- Analizar la regresión logística a través de dos conjuntos de datos distintos, uno de estos simulados y el otro datos reales (con las observaciones correspondientes a un tipo de estrella pulsante) con el fin de analizar el comportamiento de la simulación de este hecha en el software R, esto a través de las librerías STAN y JAGS.
- Comparar la simulación y estimación de datos, a través de las metodologías MCMC y HMC utilizando las librerías STAN y JAGS.
- Analizar convergencia de las estimaciones.
- Comparar performance de las estimaciones.
- Comparar los tiempos de estimación con ambas librerías.

- Aplicar e interpretar del clasificador en datos astronómicos, con las observaciones correspondientes a un tipo de estrella pulsante.
- Proponer un clasificador bayesiano basandose en la regresión logística con componentes temporales que reciba como entrada(**input**) las series de tiempo completas y que retorne(**output**) una clase binaria.

1.2. Metodología

Se procederá a seguir el siguiente esquema, en el cual se muestra el procedimiento implementado para esta sección:




Figura 1: Esquema General

Una interpretación general resumida para lo realizado en este trabajo es la siguiente:

- En primera instancia se procedió a realizar el análisis del modelo a través de 3 variaciones: la varianza de los parámetros con varianzas fijas, con distribución Gamma y con distribución Gamma Inversa, esto a través de dos conjuntos de datos (Simulados y Reales) y con las librerías JAGS y Stan con el fin de comparar cual de estas estimaciones es la más recomendada.
- Para lo anterior se procedió a generar 2 cadenas para cada estimación y cada una de las estimaciones a través de las librerías JAGS y Stan.
- Las comparaciones de estas estimaciones se realizaron en función de lo definido con anterioridad en el marco teórico, estos fueron: convergencia, performance, tamaño de iteraciones y tiempo de ejecución de la estimación.
- Todo lo anteriormente realizado fue con el fin de elegir tanto como una forma de estimación como de una librería para así en un futuro recomendar el modelo agregándole componentes de tiempo

Esto y mas se muestra a continuación.

Capítulo 2

Marco Teórico

En este capítulo se presentarán conceptos previos, los cuales serán de ayuda para poder entender las características y alcances de este proyecto en concreto.

2.1. Procesos Estocásticos

La teoría de estos, se centra en el estudio y modelización de sistemas que evolucionan a través del tiempo o del espacio, esto según leyes no deterministas (de carácter aleatorio). Esta evolución es mediante sucesiones o colecciones de variables aleatorias *v.a.*, y de esta manera, se puede estudiar como cambia o evoluciona una *v.a.* a medida que pasa el tiempo.

Se definen tal que, dado el espacio de probabilidad $(\Omega, \mathcal{A}, \mathbb{P})$ de modo que para $\forall t \in T \subset \mathbb{R}$ fijo

$$X_t : (\Omega, \mathcal{A}, \mathbb{P}) \longrightarrow (\mathbb{R}, \mathcal{B}) \quad (1)$$

$$w \longrightarrow X_t(w) \in \mathbb{R} \quad (2)$$

con, X_t *v.a.* y $\forall w \in \Omega$ fijo, $X_t(w)$ es una función del tiempo. Las propiedades probabilísticas de las *v.a.* son importantes para poder identificar y clasificar un proceso estocástico, los cuales se pueden clasificar de varias maneras, dos de las cuales son:

- Procesos Estacionarios.
- Procesos Markovianos.

2.1.1. Procesos Estacionarios

2.1.1.1. Función de Autocovarianzas

Dado $\{X_t$ tal que $t \in T$ se define la función de autocovarianza de un proceso estocástico como:

$$\gamma(r, s) = \text{Cov}(X_r, X_s) = \mathbb{E}[(X_r - \mathbb{E}(X_r)) * (X_s - \mathbb{E}(X_s))] \text{ donde } s \in T$$

2.1.1.2. Proceso Estocástico Estrictamente Estacionario

Se define como estrictamente estacionario o también como estacionario de sentido fuerte[1], a un proceso $\{X_t$ tal que $\mathbb{E}(X_t^2) < \infty \quad \forall t \in T\}$, si $\forall n \in \mathbb{N}, \forall h \in T$ y para todo $t_1, t_2, \dots, t_n \in T$ las *v.a.* $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ tienen la misma distribución conjunta que $(X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$,

representado de otra manera es:

$$F(X_{k+1}, X_{k+2}, \dots, X_{k+n}) = F(X_1, X_2, \dots, X_n) \quad \forall n, k \in \mathbb{Z} \quad (3)$$

2.1.1.3. Proceso Estocástico Débilmente Estacionario

Se define como débilmente estacionario o también conocido como de segundo orden a un proceso $\{X_t$ tal que $\mathbb{E}(X_t^2) < \infty \forall t \in T$, si cumple que:

- $\mathbb{E}[X_t] = \mu = cte < \infty \quad \forall t \in T$
- $\mathbb{V}[X_t] = \sigma^2 = cte < \infty \quad \forall t \in T$
- $\exists \gamma(\cdot)$ tal que $Cov(X_t, X_s) = \gamma_{(t-s)} \quad \forall t, s \in T$

Nota:

Un P.E. Estricto $\Rightarrow$ P.E. Débil, pero no al contrario, en general P.E. Débil $\nRightarrow$ P.E. Estricto.

Ruido Blanco (RB)

Un proceso estocástico débilmente estacionario se dice ruido blanco si,

- $\mathbb{E}[X_t] = 0 \quad \forall t \in T$
- $\mathbb{V}[X_t] = \sigma^2 \quad \forall t \in T$
- $Cov(X_t, X_s) = 0 \quad \forall t, s \in T$

2.1.2. Procesos Markovianos

La principal característica que define estos procesos es que la distribución de X_{n+1} sólo depende de la distribución de X_n y no de las anteriores $(X_{n-1}, X_{n-2}, \dots)$, esto quiere decir, que el estado futuro del proceso, sólo depende del estado presente y no del resto de estados pasados, lo anterior se conoce como **Propiedad de Markov**, lo cual se puede representar como:

$$\mathbb{P}(X_{t_n} \leq x_n | X_{t_1} \leq x_1, \dots, X_{t_{n-1}} \leq x_{n-1}) = \mathbb{P}(X_{t_n} \leq x_n | X_{t_1} \leq x_1)$$

en el caso en el que el conjunto de posibles valores que pueden tomar las *v.a.* (conocido como **conjunto de estados**, el cual puede discreto o continuo), es discreto, se escribe como:

$$\mathbb{P}(X_{t_n} = x_n | X_{t_1} = x_1, \dots, X_{t_{n-1}} = x_{n-1}) = \mathbb{P}(X_{t_n} = x_n | X_{t_1} = x_1)$$

2.1.2.1. Cadena de Markov

Es un proceso estocástico a tiempo discreto $\{X_n : n = 0, 1, \dots\}$, con espacio de estados discretos, y que satisface la propiedad de Markov, esto es, que $\forall n \geq 0$, y para cualquier estado $x_0, \dots, x_{n+1}$, se cumple que:

$$\mathbb{P}(x_{n+1} | x_0, \dots, x_n) = \mathbb{P}(x_{n+1} | x_n) \quad (4)$$

2.2. Series de Tiempo

Se conoce como **Serie cronológica o de tiempo**[1] a un conjunto de observaciones ordenadas en periodos constantes de tiempo estrictamente crecientes (fenómenos naturales o sociales) de la

forma $\{\mathbf{X}_t : t \in T\}$ donde $\mathbf{X}_t$ representa el valor de la variable $\mathbf{X}$ en el tiempo t .

Los datos se pueden comportar de diferentes maneras a través del tiempo: puede que se presente una tendencia, estacionalidad o simplemente no presenten una forma definida.

El análisis de las series temporales permite encontrar un patrón de comportamiento de éstas, lo cual permite ajustar modelos matemáticos con el objetivo de realizar *predicciones* para examinar su comportamiento a futuro, *retropredicciones* para examinar su comportamiento pasado e *imputaciones* para agregar posibles valores que no se encuentren presente dentro de ella.

2.2.1. Procesos Autorregresivos (AR(p))

Es una representación lineal de un proceso aleatorio, en el que la variable de interés depende de sus observaciones pasadas o valores anteriores, un proceso estocástico X_t , $t \in T$ se dice autoregresivo de orden p (AR(p)) si:

$$X_t - \phi_1 X_{t-1} - \phi_2 X_{t-2} - \dots - \phi_p X_{t-p} = \epsilon_t \text{ donde } p \geq 1 \text{ y } \epsilon_t \sim RB \quad (5)$$

2.3. Estadística Bayesiana

La escuela estadística posee gran potencial para resolver problema que no se pueden solucionar de otras maneras además de que permite incorporar de manera más natural información útil para la resolución del problema.

”Se basa en la probabilidad subjetiva, trabaja con la actualización de la evidencia considerando los conocimientos adquiridos previos a una investigación, más la evidencia obtenida con esta... La evidencia del estudio se mide con el factor Bayes. La conjunción de las probabilidades a priori de las hipótesis con el factor Bayes permite calcular la probabilidad a posteriori de cada una. La hipótesis con mayor grado de certidumbre en su actualización es la aceptada para la toma de la decisión.”[2].

La aproximación bayesiana en si, es una gran herramienta para los casos en que la recolección de información sobre una muestra, ya sea para poder responder preguntas sobre las características de una o varias poblaciones, sea muy difícil de conseguir. Para esto se cuenta con:

- Información sobre un parámetro el cual se asocia a una distribución de probabilidad (Función a priori).
- Los parámetros se consideran como variables aleatorias, lo cual no pasa en la estadística clásica.

Dentro de lo anterior se tiene que la información a priori de la muestra puede provenir ya sea de:

- Estudios previos
- Información subjetiva de expertos(conocido como elicitación)

Para más información sobre esto revisar [4].

El nombre «bayesiana» proviene del uso frecuente que se hace del teorema de Bayes durante el proceso de inferencia, el cual ha sido derivado del trabajo realizado por el matemático Thomas Bayes(1702-1761):

2.3.1. Teorema de Bayes

Sean los eventos $B_1, \dots, B_k$ particiones del espacio S tal que $\mathbb{P}r(B_j) > 0$ para $j = 1, \dots, k$, y sea A un evento tal que $\mathbb{P}r(A) > 0$ [3]. Entonces,

$$\mathbb{P}r(B_i|A) = \frac{\mathbb{P}r(B_i)\mathbb{P}r(A|B_i)}{\sum_{j=1}^k \mathbb{P}r(B_j)\mathbb{P}r(A|B_j)} \quad (6)$$

Para lo anteriormente mencionado se utiliza la definición de Probabilidad condicional.

$$P(B_i|A) = \frac{\mathbb{P}r(B_i \cap A)}{\mathbb{P}r(A)}$$

Teorema de Bayes para variables aleatorias

Sean X y θ variables aleatorias con función de densidad de probabilidad (fdp) $f(X|\theta)$ y $\xi(\theta)$ tal que:

$$\pi(\theta|X) = \frac{f(X|\theta)\xi(\theta)}{\int_{\Theta} f(X|\theta)\xi(\theta)d\theta} \quad (7)$$

donde,

- X : Datos(vector o matriz).
- θ : Parámetro desconocido(vector o matriz).
- $f(x_1, \dots, x_n|\theta)$: Función de verosimilitud de los datos dado el parámetro θ (desconocido).
- $\xi(\theta)$: Distribución a priori de θ .

2.3.2. Bayesiana v/s Clásica

A continuación se presenta una comparación entre ambas teorías:

Tabla 1: Diferencia entre las teorías estadísticas

Diferencias entre la teoría clásica y la teoría bayesiana		
<i>Característica</i>	<i>Teoría clásica</i>	<i>Teoría bayesiana</i>
Parámetros de interés	Constantes desconocidas	Variables aleatorias
Distribución a priori	No existe	Existe y es explícita
Modelo muestral	Se asume	Se asume
Distribución a posteriori	No existe	Existe y se deriva
Razonamiento	Inductivo	Deductivo

2.3.3. Función A Priori($\pi(\theta)$)

Como ya se mencionó con anterioridad, definida como una función aditiva no negativa, es la información sobre un parámetro, el cual se asocia a una distribución de probabilidad, ya que esta se considera una variable aleatoria. El mayor inconveniente de esta es el cómo se determina esta función.

2.3.3.1. Clasificación Función a priori

Estas pueden clasificar de varias maneras:

- **Su suma o integral:**
 - **Propia:** Suman o integran hasta uno, a todos los posibles valores del parámetro, esto quiere decir que cumple la condición de función de densidad de probabilidad.
 - **Impropia:** Suma o integra un valor diferente a uno.
- **Su conocimiento**
 - **Informativa:** Cuando se tiene un conocimiento o justificación para la selección de esta.
 - **No informativa:** Cuando se tiene una ignorancia o conocimiento limitado sobre el parámetro de interés.
- **Familiaridad en la distribución:**
 - **Conjugada:** Si la distribución a posteriori es igual a la distribución a priori, excepto en sus hiperparámetros, después de que se actualice su información mediante la información muestral.
 - **No conjugado:** Si la distribución a posteriori es distinta a la distribución a priori, después de que se actualice su información mediante la información muestral.

Una de las mayores dificultades existentes en la estadística bayesiana es la obtención o identificación, la selección y la justificación de la distribución a priori, para esto, una buena forma de identificarlas es el contestar las siguientes preguntas:

- ¿Qué clase de de distribución a priori se debe utilizar?
- ¿Qué tipo de datos están disponibles para la selección del modelo a priori?
- ¿Cómo se puede cuantificar la información subjetiva?
- ¿Cómo ajustamos la distribución a priori con los datos subjetivos disponibles?

2.3.4. Función A Posteriori

En sí, la inferencia bayesiana, después de que se realiza la actualización de la información, se deriva en la función a posteriori, para esto se utiliza el teorema de bayes, ecuación (7) en el punto, tal que:

$$\pi(\tilde{\theta}|x) = \frac{f(x_1, \dots, x_n|\theta)\xi(\theta)}{\int_{\Theta} f(x_1, \dots, x_n|\theta)\xi(\theta)d\theta} \quad (8)$$

Normalmente, en la practica el denominador no necesita ser calculado en general, dado esto la ecuación 8 se modifica a:

$$\pi(\tilde{\theta}|x) \propto f(x_1, \dots, x_n|\theta)\xi(\theta) \quad (9)$$

lo cual, se puede expandir a medida que se van sumando parámetros, en este caso, como variables aleatorias, dado que el teorema de bayes realiza una especie de “actualización” de $\xi(\theta)$ a

$\xi(\theta|x_1, \dots, x_n)$, por ejemplo:

$$\xi(\theta|x_1) \propto f(x_1|\theta)\xi(\theta), \quad (10)$$

$$\xi(\theta|x_1, x_2) \propto f(x_1|\theta)f(x_2|\theta)\xi(\theta), \quad (11)$$

$$\propto f(x_2|\theta)\xi(\theta|x_1) \quad (12)$$

esto ya que, a través de bayes, nos podemos dar cuenta de que la naturaleza de θ se ve modificada a medida de que nuevos datos son adquiridos o tomados en cuenta.

2.3.5. Función Predictiva A Priori

Se utiliza para determinar la calidad de la función a priori elicitada y además entrega información, información útil para análisis posteriores.

Sea $\xi(\theta)$ la distribución a priori sobre θ y se conoce la distribución que genera los datos, sea $f(y|\theta)$, entonces la función predictiva a priori se define como:

$$p(y) = \int f(y|\theta)\xi(\theta)d\theta \quad (13)$$

Si estos datos obtenidos con esta distribución se acomodan a lo que se cree que debe ser, entonces, se puede pensar que la a priori sirve y se puede utilizar en el proceso posterior.

2.3.6. Función Máxima A Posteriori (MAP)

También conocido como estimador máximo a posteriori se define como:

$$\hat{\theta}_{MAP} = \arg \max_{\theta \in \Theta} \pi(\theta|x_1, \dots, x_n)$$

2.3.7. Markov Chain Monte Carlo (MCMC)

Son métodos de Monte Carlo basados en cadenas de Markov, permiten la estimación de parámetros como medias, varianzas, valores esperados y la exploración de la distribución a posteriori de los modelos bayesianos.[3]

Un proceso de Monte Carlo se refiere a una simulación que muestrea muchos valores aleatorios de una distribución a posteriori de interés. La idea de estos métodos consiste en[15]:

- Simular una cadena de Markov, $\theta_1, \theta_2, \dots$, cuya distribución estacionaria sea $\pi(\tilde{\theta}|x)$, donde cada valor simulado(θ_t), depende únicamente de su predecesor (θ_{t-1}).
- Si el algoritmo se implementa correctamente, la convergencia de la cadena está garantizada independientemente de cuáles sean los valores iniciales.
- Es necesario simular la cadena para un número elevado de iteraciones para aproximarse a la distribución estacionaria. Los primeros valores simulados, (iteraciones de burn-in), se eliminan porque no están en el estado estacionario.

2.3.7.1. Convergencia

Cuando un MCMC ha alcanzado un conjunto estable de muestras de una distribución a posteriori estacionaria, se dice que esta no ha convergido, de este modo también es posible que existan modelos que no converjan, por ejemplo, una distribución propuesta mal ajustada puede hacer que

la caminata nunca abandone un área pequeña de la distribución de destino. Es de esperarse que exista un alto grado de autocorrelación entre las muestras, lo cual da lugar a pasos muy pequeños en la caminata y una convergencia lenta o nula.

Esta es una característica peligrosa de los algoritmos MCMC: no existe una prueba método para garantizar se exista la convergencia y con esto se tiene que la distribución a posteriori inferida puede ser incorrecta y también así sus parámetros estimados[16], lo que quiere decir, que se puede revisar si converge de una manera **aproximada hacia la distribución deseada** ya que no hay manera de confirmar que lo inferido es exactamente correcto, para esto es recomendado analizar si:

2.3.7.1.1. La cadena explora el espacio de estados:

Para esto se grafican los valores simulados en relación al tiempo y dado esto analizar si existen desviaciones en la estacionaridad de la serie.




Figura 1: Ejemplos de estacionaridad.[15]

En la figura 1.a se presenta una buena exploración de los datos, al contrario, en la figura 1.b se presenta un mal comportamiento en la exploración de los datos de la cadena, estos ejemplos se presentan en las referencias[15].

2.3.7.1.2. La media muestral de la cadena ha convergido:

Para esto se grafican los valores de la media muestral en función del tiempo.




Figura 2: Ejemplo comparación de medias[15]

En la figura 2, se puede interpretar como que pareciera que tras 2000 iteraciones las medias han convergido, por lo que es una buena opción hacer burnin o quemar las primeras 3000 iteraciones.

2.3.7.1.3. Autocorrelación de los valores:

Para esto se grafican las funciones de autocorrelación de los valores simulados. Generalmente los valores estimados para los parámetros se encuentran correlacionados positivamente, ya que se simulan valores de una cadena de Markov.




Figura 3: Ejemplo comparación de correlaciones.[15]

En la figura 3, en 3.a se puede apreciar que la autorrelación se acaba en el período 9 y en 3.b se acaba en el período 4, esto se puede interpretar como que se puede almacenar el valor simulado cada 9 y 4 iteraciones respectivamente, esto con el fin de tener una muestra de valores aproximadamente independiente.

2.3.7.1.4. Tamaño Efectivo(ES)

Una vez que tenemos una muestra representativa de la distribución posterior, nuestro objetivo es asegurarnos de que la muestra es lo suficientemente grande para producir estimaciones estables y precisas de la distribución. El **tamaño efectivo** de muestra, si las simulaciones fueran independientes sería el número total de simulaciones; sin embargo, las simulaciones de MCMC suelen estar correlacionadas, el tamaño efectivo nos dice que tamaño de muestra de observaciones independientes nos daría la misma información que las simulaciones de la cadena.

$$ES = \frac{N}{1 + 2 \sum_{k=1}^{\infty} ACF(k)} \quad (14)$$

2.3.7.1.5. Diagnostico de Gelman

Gelman propone una prueba de convergencia basada en 2 o más cadenas paralelas, cada una partiendo de diferentes valores iniciales que están sobre-dispersos con respecto a la verdadera distribución posterior.

Su método se basa en una comparación entre las varianzas dentro y entre cadenas para cada variable, esta comparación se utiliza para estimar el factor por el cual el parámetro de la escala de la distribución posterior marginal de cada variable pudo ser reducido si la cadena fue funcionada al infinito. Se obtienen mejores resultados para los parámetros cuyas densidades posteriores marginales son aproximadamente normales. Por lo tanto, Coda transforma cualquier variable especificada para ser positiva o restringida al rango (0,1) a las escalas logarítmicas o logit, respectivamente, antes de calcular este diagnóstico.

Se muestran los cuantiles asociados al 50 % y al 97,5 %, estos cuantiles se estiman a partir de

la segunda mitad de cada cadena solamente. Si ambos cuantiles son aproximadamente 1.0, la convergencia eficaz se puede diagnosticar es decir las muestras a partir de la segunda mitad que cada cadena se puede asumir para haber surgido de la distribución inmóvil. Por ejemplo:

```
GELMAN AND RUBIN 50% AND 97.5% SHRINK FACTORS:
=====

Iterations used = 1:200
Thinning interval = 1
Sample size per chain = 200
```

VARIABLE	Point est.	97.5% quantile
alpha	1.02	1.02
beta	1.00	1.00
sigma	1.04	1.12

Figura 4: Ejemplo Diagnostico de Gelman

Lo cual se puede entender como que las 100 iteraciones (las mostradas en el ejemplo) eran suficientes para alcanzar la convergencia para Alpha, Beta y Sigma, y que las muestras 101-200 de ambas cadenas se pueden asumir para presentarse de las distribuciones posteriores marginales para cada variable.

2.3.8. Tiempo de ejecución

Se puede obtener el tiempo de ejecución del proceso como tal utilizando en este caso la función `system.time` integrada en R. La cual se puede interpretar como el “tiempo de CPU del usuario” proporciona el tiempo de CPU empleado por el proceso actual (es decir, la sesión R actual) y el “tiempo de CPU del sistema” proporciona el tiempo de CPU empleado por el kernel (el sistema operativo) en nombre del proceso actual. Lo anterior, en conjunto viene dado en el resultado `elapsed`, como por ejemplo en la salida obtenida en la estimación I para datos simulados en jags, con la configuración final. La cantidad de tiempo, en segundo, utilizado para esta estimación es:

```
      user   system elapsed
16389.16    22.89 16466.23
```

Figura 5: Tiempo Estimación I, Jags.

Lo cual dice que el proceso demora en total 16466 segundos en total.

2.3.8.1. Método Hamiltoniano (HMC)

Este método, también conocido como Monte Carlo Hamiltoniano, es un método de Metropolis, el cual se encuentra definido en las referencias [15], el cual se puede aplicar en espacios continuos de estados, hace uso de la información del gradiente para así reducir el comportamiento de paseo aleatorio en la serie de tiempo. [17]

Sirve para evaluar rápidamente no sólo $E(x)$ si no también su gradiente con respecto a x , si el

sistema cumple que su probabilidad esta escrita de la forma,

$$\mathbb{P}(x) = \frac{e^{-E(x)}}{Z}$$

El gradiente indica que dirección se debe seguir para encontrar estados de mayor probabilidad.

En este método, el espacio de estado $\mathbf{x}$ es aumentado mediante *variables momento* $\mathbf{p}$, para esto existen dos tipos de propuestas:

- La primera propuesta, aleatoriza la variable momento dejando el estado de $\mathbf{x}$ inalterado.
- La segunda propuesta, cambia $\mathbf{x}$ y $\mathbf{p}$ usando dinámica hamiltoniana simulada.

El hamiltoniano viene dado por:

$$H(\mathbf{x}, \mathbf{p}) = E(x) + K(p)$$

donde $K(p)$ es una energía cinética dada por $K(p) = p^T p / 2$.

Las dos propuestas se utilizan para así poder crear muestras de la densidad conjunta (asintóticamente)

$$P_H(\mathbf{x}, \mathbf{p}) = \frac{1}{Z_H} \exp[-H(\mathbf{x}, \mathbf{p})] = \frac{1}{Z_H} \exp[-E(\mathbf{x})] \exp[-K(\mathbf{p})]$$

Esta densidad es separable, así que la **distribución marginal** de x es la distribución deseada $\exp[-E(\mathbf{x})]/Z$, por lo que, simplemente descartando las variables momento se obtiene una secuencia de muestras $\{\mathbf{x}^{(t)}\}$ las cuales provienen asintoticamente de $P(\mathbf{x})$.

Detalles:

La primera propuesta, es una actualización similar a las muestreo de Gibbs, el cual se encuentra en las referencias [15], ya que, extrae nuevos momentos a partir de la densidad gaussiana $\exp[-K(\mathbf{p})]/Z_K$, esta propuesta siempre es aceptada. En la segunda propuesta, la variable de momento determina hacia donde se dirige el estado de $\mathbf{x}$, y el gradiente de $E(\mathbf{x})$ determina el como cambia el momento $\mathbf{p}$, todo esto según las ecuaciones,

$$\mathbf{x} = \mathbf{p} \quad \mathbf{p} = -\frac{\partial E(\mathbf{x})}{\partial \mathbf{x}}$$

2.4. Métodos de Clasificación

2.4.1. Regresión Logística

La regresión logística se utiliza para estudiar el efecto de múltiples variables explicativas sobre una variable de respuesta dicotómica, la cual denota la presencia o ausencia del evento en estudio, es decir,

$$Y = \begin{cases} 1 & \text{presencia del evento de estudio.} \\ 0 & \text{ausencia del evento de estudio.} \end{cases}$$

Por ende la variable de respuesta $Y \sim \text{Bernoulli}(p)$ y en consecuencia la probabilidad de ocurrencia del evento ($Y=1$) a través de un modelo de regresión lineal es:

$$\mathbb{P}(Y = 1 \mid \vec{X}) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p = \pi$$

Es de interés construir un modelo capaz de explicar la relación entre la probabilidad de la respuesta π y el vector de variables independientes $\vec{X} = (X_1, X_2, \dots, X_p)$, de modo que:

$$\eta = \sum_{j=0}^p X_j \beta_j \quad \text{con } X_0 = 1 \text{ y } \eta = \text{predictor lineal.}$$

Se define la función de enlace canónica conocida como logit:

$$\text{logit}(\pi) = \log\left(\frac{\pi}{1-\pi}\right)$$

Y así:

$$\log\left(\frac{\pi}{1-\pi}\right) = \eta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

Despejando π se obtiene el modelo de regresión logística:

$$\pi = \frac{\exp(\eta)}{1 + \exp(\eta)} = \frac{\exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)}{1 + \exp(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)}$$

Una vez definido el modelo de regresión logística se debe estimar sus parámetros, esto se puede realizar mediante la función logit y el uso de métodos numéricos tales como Newton Raphson u otros. Ya que se conoce la estimación de los parámetros es importante la interpretación de estos.

2.4.1.1. Análisis de factores de riesgo

Se define el término Odds como el riesgo relativo de pertenecer al grupo de interés ($Y=1$). Es decir, el cociente entre la probabilidad de éxito frente a la probabilidad de fallar, bajo los mismos valores en las variables predictoras, esto es:

$$\text{odds} = \frac{\mathbb{P}(Y = 1 \mid X)}{1 - \mathbb{P}(Y = 1 \mid X)} = \exp(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)$$

Además, se definen los OR (Odds Ratio), los cuales miden cómo se modifica el *odds* cuando una de las variables explicativas cambia su valor en una unidad, para el caso en que X sea una variable categórica, este mide cómo se modifica el odds cuando dicha variable cambia de categoría con respecto a la de referencia. Se interpreta como el riesgo de presentar el evento de estudio.

$$OR(X_j) = \exp(\beta_j)$$

Los OR pueden ser interpretados según su valor:

- $OR > 1$: Se interpreta como un factor de riesgo, es decir, que el evento de éxito es más frecuente en el perfil con $X_j + 1$ que en el perfil con X_j , o en el caso en que X_j es una variable categórica, se tiene que el evento de éxito es más frecuente en la categoría que no es de referencia.
- $OR = 1$: Se interpreta como que los cambios en X_j no afectan en la variable Y .
- $OR < 1$: Se interpreta como un factor protector, es decir, que el evento de éxito es más frecuente en el perfil con X_j que en el perfil con $X_j + 1$, o en el caso en que X_j es una variable categórica, se tiene que el evento de éxito es más frecuente en la categoría de referencia.

2.4.1.2. Análisis de clasificación

2.4.1.2.1. Sensibilidad y Especificidad

Una vez realizadas las estimaciones de las probabilidades de todas las observaciones de la muestra, es posible realizar una clasificación de acuerdo a estas. Para poder realizar la clasificación es necesario definir un punto de corte π_0 . Luego, para comparar la efectividad de un modelo en la clasificación de observaciones, se construye una tabla de doble entrada entre los valores observados de Y (0 y 1) y los predichos por el modelo $\hat{Y}$ (0 y 1):

	$\hat{Y} = 1$	$\hat{Y} = 0$	Suma
$Y=1$	VP	FN	VP+FN
$Y=0$	FP	VN	FP+VN
Suma	VP+FP	FN+VN	Total

Donde:

- VP: Verdaderos positivos. Corresponde a la cantidad de observaciones que presentan el evento que efectivamente fueron clasificadas con la presencia del evento.
- FN: Falsos negativos. Corresponde a la cantidad de observaciones que presentan el evento y que fueron mal clasificadas.
- VN: Verdaderos negativos. Corresponde a la cantidad de observaciones que no presentan el evento que fueron bien clasificadas.
- FP: Falsos positivos. Corresponde a la cantidad de observaciones que no presentan el evento que fueron mal clasificadas.

Luego de obtener estos resultados es posible plantear los siguientes conceptos:

- Sensibilidad: Proporción de individuos u objetos que poseen el evento ($Y=1$) que fueron correctamente clasificados.

$$\mathbb{P}(\hat{Y} = 1|Y = 1) = \frac{VP}{VP + FN}$$

- Especificidad: Corresponde a la proporción de individuos u objetos clasificados como negativos cuando realmente lo eran.

$$\mathbb{P}(\hat{Y} = 0|Y = 0) = \frac{VN}{FP + VN}$$

- Accuracy: Cuán precisamente un modelo de regresión logística puede predecir la clase correcta para una serie de observaciones. En otras palabras, se trata de la proporción de predicciones correctas que hace el modelo entre todas las predicciones que realiza.

2.4.1.2.2. Curva de ROC

Al ir eligiendo distintos valores de π_0 para calcular la sensibilidad y especificidad, se forma la gráfica de la curva ROC, en donde el eje X corresponde a 1-especificidad (falsos positivos) y el eje Y a la sensibilidad (verdaderos positivos). La curva ROC ofrece un mejor resumen de la capacidad predictiva que una tabla de clasificación, porque presenta la potencia predictiva para todos los posibles valores de referencia.

Además, cuanto mayor sea el área bajo la curva ROC (AUC) mayor será la potencia de la clasificación hecha por el modelo. Se puede tomar en cuenta el siguiente criterio:

- $0,5 \leq AUC < 0,7$: Capacidad de discriminación baja
- $0,7 \leq AUC < 0,9$: Capacidad de discriminación media
- $0,9 \leq AUC < 1$: Capacidad de discriminación alta.

2.4.2. Modelos Logit y Probit

Estos son modelos econométricos no lineales que se utilizan cuando la variable dependiente es binaria o dummy, es decir, esta solo puede tomar dos valores.

Utilizan una función que asume únicamente valores entre cero y uno, estas funciones, no son lineales y corresponden a la distribuciones acumuladas.

Los métodos para estimar estos modelos es a través de los siguientes:

Mínimos cuadrados no lineales

Este estimador selecciona los valores que minimizan la suma de residuales al cuadrado,

$$\min_{\beta_0, \dots, \beta_k} \sum_{i=1}^n [y_i - G(\beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki})]^2$$

el cual en muestras grande es consistente y distribuye normal.

Máxima Verosimilitud

Selecciona a los valores que maximizan el logaritmo de la verosimilitud,

$$\log L(\beta_0, \dots, \beta_k; y_1, \dots, y_n | x_1, \dots, x_n) = \sum_{i=1}^n [y_i \log G(x_i \beta) + (1 - y_i) \log(1 - G(x_i \beta))]$$

el cual en muestras grandes es consistente, distribuye normal y es el mas eficiente en comparación con el método mínimos cuadrados no lineales, ya que en este método la varianza más pequeña.

Para los efectos de estos modelos, se puede revisar el articulo online [5]

2.4.2.1. Logit

En el modelo logit, la probabilidad de éxito se evalúa en la función $G(Z) = \Lambda(Z)$, donde:

$$\mathbb{P}(y = 1 | x) = \Lambda(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) \quad (15)$$

$$\Lambda(z) = \frac{\exp(z)}{1 + \exp(z)} \quad (16)$$

La función $\Lambda(z)$ es la distribución logística, la cuál denotaremos por p_i y servirá para poder estimar los parámetros en un modelo con la variable binaria.

Se puede notar que p_i no esta linealmente relacionado con z_i , lo cual quiere decir que no se pueden estimar los parámetros a través de MCO pero si se puede linealizar haciendo lo siguiente: p_i es la probabilidad de éxito, entonces, la probabilidad de fracaso es:

$$1 - p_i = \frac{1}{1 + \exp(z_i)}$$

de lo anterior se tiene que:

$$\frac{p_i}{1 - p_i} = \frac{1 - \exp(z_i)}{1 + \exp(z_i)} = \exp(z_i) \quad (17)$$

2.4.2.2. Probit

En el modelo probit, la probabilidad de éxito se evalúa en la función $G(Z) = \Phi(Z)$, donde:

$$\mathbb{P}(y = 1|x) = \Phi(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k) \quad (18)$$

$$\Phi(z) = \int_{-\infty}^z \left(\frac{1}{2\phi}\right)^{\frac{1}{2}} \exp\left\{-\frac{u^2}{2}\right\} du \quad (19)$$

Por lo que se puede observar, la función $\Phi(z)$ corresponde a la distribución normal acumulada.

2.4.3. Clasificación de Series de Tiempo

Una aplicación constante para poder agrupar e inferir sobre las conductas de las series de tiempo es clasificarlas, de forma que de esta manera se puedan clasificar e inferir conductas de las series de tiempo a través de estos grupos en diversos contextos [7], esto se realiza en primera instancia por el aprendizaje de un modelo de clasificación para un conjunto de datos y en segunda instancia el clasificar las nuevas instancias o datos.

Se encuentran disponible gran cantidad de clasificadores propuestos con anterioridad tales como Random Forest y otros definidos y usados en artículos [8][9], los que se caracterizan por estar basados en características de las series de tiempo.

Las redes neuronales también sirven para poder clasificar una serie de tiempo[10], tomando la serie o todas sus características en si, esto en el caso recurrente, ya que considerando la definición de red recurrente existente dada por I. Bonet Cruz et al [11], “las redes neuronales recurrentes son aquellas que cada neurona puede estar conectada a cualquier otra y sus conexiones recurrentes son variables...”.

2.5. Librerías en R

2.5.1. JAGS

Es un programa para generar muestras de una distribución a posteriori de los parámetros de un modelo, para esto usa Markov Chain Monte Carlo(MCMC), ya definido en la sección 3.7 . [12][13]

2.5.2. STAN

Es un programa para generar muestras de una distribución posterior de los parámetros de un modelo, el nombre del programa hace referencia a Stanislaw Ulam (1904-1984) que fue pionero en los métodos de Monte Carlo. A diferencia de JAGS y BUGS, los pasos de la cadena de Markov se generan con un método llamado Monte Carlo Hamiltoniano (HMC), ya definido en 3.7.2 .

HMC es computacionalmente más costoso que Metrópolis o Gibbs, sin embargo, sus propuestas suelen ser más eficientes, y por consiguiente no necesita muestras tan grandes. En particular

cuando se ajustan modelos grandes y complejos (por ejemplo, con variables con correlación alta) HMC supera a otros. [14]

2.5.3. Diferencias entre STAN y JAGS

“Stan” y “JAGS” son ambos lenguajes de modelado probabilístico y entornos de inferencia bayesiana utilizados para ajustar modelos estadísticos complejos. Ambos son muy populares en la comunidad de estadística y ciencia de datos.

JAGS es una adaptación de BUGS, semejante a WinBUGS y OpenBUGS, en la cual un modelo establece exclusivamente relaciones entre variables. Por otro lado, Stan es un programa donde un modelo se divide en partes claramente definidas, y el orden de las declaraciones influye en su ejecución. También existen publicaciones en las cuales realizan comparaciones entre estas y otras librerías [18]. Algunas comparaciones generales entre Stan y JAGS:

- **Flexibilidad:** Stan es conocido por su capacidad para ajustar modelos estadísticos altamente complejos y personalizados, gracias a su lenguaje de modelado más expresivo y flexible. Por otro lado, JAGS tiene un lenguaje más limitado y puede ser menos adecuado para ciertos modelos complejos.
- **Eficiencia computacional:** En general, Stan es más rápido en el cálculo de las inferencias y tiene mejores algoritmos de muestreo. Esto se debe en parte a su enfoque en el muestreo de Hamiltonian Monte Carlo (HMC) y su optimización para aprovechar las capacidades de cómputo de la GPU. JAGS, por otro lado, utiliza el muestreo de Markov Chain Monte Carlo (MCMC), que puede ser más lento para ciertos tipos de modelos.
- **Facilidad de uso:** JAGS es a menudo el preferido por su facilidad de uso, especialmente para usuarios que están comenzando con el análisis bayesiano. Su lenguaje se asemeja al lenguaje de programación BUGS (Bayesian inference Using Gibbs Sampling), que es más intuitivo para muchos estadísticos. Stan puede tener una curva de aprendizaje más empinada debido a su lenguaje más sofisticado y a la necesidad de especificar modelos de manera más detallada.
- **Plataforma:** Tanto Stan como JAGS son plataformas de código abierto y multiplataforma, lo que significa que se pueden ejecutar en diferentes sistemas operativos.

Tabla 2: Diferencia entre Stan y JAGS.

Diferencias entre Stan y JAGS		
	<i>JAGS</i>	<i>Stan</i>
Inferencia	Bayesiana(MCMC) Automático sin opciones	Bayesiana(HMC) Automático con opciones para tasa de aceptación
Parámetros Discretos	Uso directo	Incompatible, debe ser analizado marginalmente.
Ventajas Generales	Fácil de usar, afinado, parámetros discretos.	Escala bien con dimensionalidad, complejidad posterior, apto para modelos jerárquicos especialmente la forma no centrada.
Desventajas Generales	Pocas alternativas para reducir el tiempo de ejecución cuando es restringido	Sin parámetros discretos, lenguajes de modelado mas difíciles.

Capítulo 3

Estimación Modelo Logístico Clásico

3.1. Estimación A Posteriori

En primera instancia, se calculará la función a posteriori más básica del modelo logístico con el fin de obtener resultados que serán base para lo que se desarrollara más adelante, para esto se utiliza el modelo logístico simple definido de la siguiente manera:

$$\begin{aligned} Y_i | P_i &\sim \text{Ber}(P_i) \\ \text{Logit}(P_j) &\sim \beta_0 + \beta_1 X_i \\ \beta_j &\sim N(0, \sigma_j^2) \end{aligned}$$

para esto se calcula función de verosimilitud del modelo definido en esta parte,

$$L(P_i | y_1, \dots, y_n) = \prod_{i=1}^n P_i^{y_i} (1 - P_i)^{1-y_i}$$

ahora se sabe que,

$$\begin{aligned} \text{Logit}(P_i) &= \beta_0 + \beta_1 X_i \\ \text{Logit}(P_i) &= \text{Log}\left(\frac{P_i}{1 - P_i}\right) \end{aligned}$$

lo cual implica,

$$\begin{aligned}
 &\Rightarrow \text{Log}\left(\frac{P_i}{1-P_i}\right) = \beta_0 + \beta_1 X_i \\
 &\Rightarrow \frac{P_i}{1-P_i} = e^{\beta_0 + \beta_1 X_i} \\
 &\Rightarrow P_i = e^{\beta_0 + \beta_1 X_i} (1 - P_i) \\
 &\Rightarrow P_i = e^{\beta_0 + \beta_1 X_i} - P_i e^{\beta_0 + \beta_1 X_i} \\
 &\Rightarrow P_i + P_i e^{\beta_0 + \beta_1 X_i} = e^{\beta_0 + \beta_1 X_i} \\
 &\Rightarrow P_i (1 + e^{\beta_0 + \beta_1 X_i}) = e^{\beta_0 + \beta_1 X_i} \\
 &\Rightarrow P_i = \frac{e^{\beta_0 + \beta_1 X_i}}{1 + e^{\beta_0 + \beta_1 X_i}}
 \end{aligned}$$

reemplazando en lo anterior,

$$\begin{aligned}
 L(\beta_0, \beta_1 | Y, X) &= \prod_{i=1}^n \left(\frac{e^{(\beta_0 + \beta_1)}}{1 + e^{(\beta_0 + \beta_1)}} \right)^{y_i} \left(1 - \frac{e^{(\beta_0 + \beta_1)}}{1 + e^{(\beta_0 + \beta_1)}} \right)^{1-y_i} \\
 &\quad \prod_{i=1}^n \left(\frac{e^{(\beta_0 + \beta_1)}}{1 + e^{(\beta_0 + \beta_1)}} \right)^{y_i} \left(\frac{1 + \cancel{e^{(\beta_0 + \beta_1)}} - e^{(\beta_0 + \beta_1)}}{1 + e^{(\beta_0 + \beta_1)}} \right)^{1-y_i} \\
 &\quad \prod_{i=1}^n \left(\frac{e^{(\beta_0 + \beta_1)}}{1 + e^{(\beta_0 + \beta_1)}} \right)^{y_i} \left(\frac{1}{1 + e^{(\beta_0 + \beta_1)}} \right)^{1-y_i}
 \end{aligned}$$

lo que no se puede operar directamente, ahora las a priori utilizadas,

$$\Pi(\beta_0, \beta_1) \underset{\text{indep a priori}}{=} \Pi(\beta_0) \Pi(\beta_1)$$

Recordemos que:

$$\begin{aligned}
 \Pi(\beta_j) &= \frac{1}{\sqrt{2\pi\sigma_j^2}} \exp \left\{ \frac{-\beta_j^2}{2\sigma_j^2} \right\} \\
 &\propto \exp \left\{ \frac{-\beta_j^2}{2\sigma_j^2} \right\} \mathcal{K}_{\mathbb{R}^2}(\beta_j)
 \end{aligned}$$

luego:

$$\begin{aligned}
 \Pi(\beta_0, \beta_1) &\propto \exp \left\{ \frac{-\beta_0^2}{2\sigma_0^2} \right\} \exp \left\{ \frac{-\beta_1^2}{2\sigma_1^2} \right\} \mathcal{K}_{\mathbb{R}^2}(\beta_0, \beta_1) \\
 &= \exp \left\{ \frac{-(\sigma_1^2 \beta_0^2 + \sigma_0^2 \beta_1^2)}{2\sigma_0^2 \sigma_1^2} \right\} \mathcal{K}_{\mathbb{R}^2}(\beta_0, \beta_1)
 \end{aligned}$$

ahora, usando la definición de función a posteriori y reemplazando en ella, se obtiene que:

$$\Pi(\beta_0, \beta_1 | Y, X) \propto L(\beta_0, \beta_1 | Y, X) \Pi(\beta_0) \Pi(\beta_1) \quad (1)$$

$$= \left[\prod_{i=1}^n \left(\frac{e^{(\beta_0 + \beta_1)}}{1 + e^{(\beta_0 + \beta_1)}} \right)^{y_i} \left(\frac{1}{1 + e^{(\beta_0 + \beta_1)}} \right)^{1-y_i} \right] \exp \left\{ \frac{-(\sigma_1^2 \beta_0^2 + \sigma_0^2 \beta_1^2)}{2\sigma_0^2 \sigma_1^2} \right\} \mathcal{K}_{\mathbb{R}^2(\beta_0, \beta_1)}$$

en la cual a simple vista se puede apreciar que no posee una forma cerrada, en otras palabras, no se ve que se parezca a ninguna de las familias de distribuciones conocidas.

3.2. Estimación con Datos Simulados

En esta sección se implementará una simulación para el modelo propuesto, pero sin considerar ninguna componente de tiempo, por lo que el modelo quedara definido como:

$$Y_i|P_i \sim Ber(P_i) \quad (2)$$

$$Logit(P_j) \sim \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} \quad (3)$$

$$\beta_j \sim N(0, \sigma_j^2) \quad (4)$$

con el fin de observar como se comporta la simulación de estos datos para el modelo logístico con 2 variables independiente (sin ninguna componente temporal). Todo esto a través de las interfaces de JAGS y STAN en R.

Para lo anterior se procede a programar esta estimación a través de 3 variables simuladas, llamadas « y, x_1 y x_2 », con « y » como la variable a predecir y con « x_1 y x_2 » como las variables predictoras del modelo definido en el punto anterior. Estas variables se simularon a través del código anexado, con 10000 observaciones y siguiendo las siguientes distribuciones:

$$Y \sim Ber(P_i)$$

$$z = 1 + 2X_1 + 3X_3 \text{ esto es, } \beta_0 = 1, \beta_1 = 2, \beta_2 = 3$$

$$P_i = \frac{1}{1 + \exp(-z)}$$

$$X_1 \sim N(0, \sigma_{x_1}^2)$$

$$X_2 \sim N(0, \sigma_{x_2}^2)$$

Se procederá a seguir el siguiente esquema, en el cual se muestra el procedimiento implementado para esta sección:




Figura 1: Esquema Datos Simulados

Una interpretación resumida para lo realizado en este conjunto de datos es la siguiente:

- En primera instancia se procedió a realizar el análisis del modelo a través de 3 variaciones: la varianza de los parámetros con varianzas fijas, con distribución Gamma y con distribución Gamma Inversa, esto con el fin de comparar cual de estas estimaciones es la más recomendada.
- Para lo anterior se procedió a generar 2 cadenas para cada estimación y cada una de las estimaciones a través de las librerías JAGS y Stan.
- Se analizaron las convergencias de las estimaciones y con ellas obtener las configuraciones con la cual se aseguraría la convergencia de estas, con las cuales se procedió a realizar la estimación final de los parámetros para cada librería y cada estimación.
- Las comparaciones de estas estimaciones se realizaron en función de lo definido con anterioridad en el marco teórico, estos fueron: convergencia, performance, tamaño de iteraciones y tiempo de ejecución de la estimación.
- Todo lo anteriormente realizado fue con el fin de elegir tanto como una forma de estimación como de una librería para así en un futuro recomendar el modelo agregándole componentes de tiempo

Lo recién descrito y mas realizado a lo largo de este trabajo se muestra a continuación, cabe destacar que se realizaron breves cambios a lo dicho a través de lo que fue para cada uno de los conjuntos de datos a medida que estos se fueron analizando.

3.2.1. JAGS

Se estima el modelo ya mencionado a través de los siguientes modelos con la librería JAGS:

3.2.1.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas

Este modelo se ejecutó con dos cadenas, con el fin de poder comparar entre la convergencia, tomando todas las variables mencionadas, « y , x_1 y x_2 » y con un número de 10000 iteraciones, sin ningún salto entre ellas, estimándose así las funciones a posteriori de los parámetros, los cuales se estimaran teniendo una varianza fija con un valor de 1.000.000 .

3.2.1.1.1. Parámetros Iniciales

La simulación de los datos generó los siguientes parámetros iniciales:

Tabla 1: Parámetros iniciales Estimación I Datos Simulados, JAGS.

Parámetros	Media	SD	Naive SE
β_0	1.005	0.036	0.0003
β_1	1.967	0.049	0.0003
β_2	3.030	0.064	0.0004

3.2.1.1.2. Análisis de Convergencia

Como se especificó en el capítulo 2.3.7.1, no existe un método en específico para comprobar si existe o no una convergencia, pero en este caso se utilizarán los criterios ya mencionados para analizar una posible convergencia aproximada a la posterior.

En primera instancia, analizaremos los gráficos de las funciones a posteriori de los parámetros,




(a) Función a posteriori de β_0 (b) Función a posteriori de β_1 (c) Función a posteriori de β_2

Figura 2: Funciones a posteriori parámetros iniciales Estimación I Datos Simulados, JAGS.

de estos gráficos se puede asegurar de manera a priori, que los parámetros $\beta_0, \beta_1, \beta_2$, cumplen con la estacionariedad, además de que se observan medias y varianzas constantes, esto implica que no se ve a simple vista que se deban quemar datos, pero para efectos prácticos esto se hará desde las 2000 observaciones.




(a) Gráficas de autocorrelación de β_0 (b) Gráficas de autocorrelación de β_1 (c) Gráficas de autocorrelación de β_2

Figura 3: Gráficas de autocorrelación de los parámetros iniciales Estimación I
Datos Simulados, JAGS.H

Se puede apreciar, de manera a priori, que tanto para los parámetros β_0 , β_1 que la autocorrelación de los datos se termina en el período 6 y β_2 en el periodo 7.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 2: Tamaño Efectivo Estimación I, Jags.

	β_0	β_1	β_2
=	6976.914	4596.104	4603.883

y su diagnóstico de Gelman es:


Tabla 3: Diagnóstico de Gelman Estimación I, Jags

	point est.	upper c.i.
β_0	1	1.00
β_1	1	1.01
β_2	1	1.00


esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones.

3.2.1.1.3. Estimación Final


De las conclusiones anteriores se decide de manera a priori, para ver los efectos prácticos de la implementación, finalmente, quemar las primeras 2000 observaciones y realizar un salto cada 7 observaciones, con lo cual se obtuvieron las siguientes gráficas y parámetros:



(a) Funciones a posteriori de β_0



(b) Funciones a posteriori de β_1



(c) Funciones a posteriori de β_2

Figura 4: Funciones a posteriori parámetros finales Estimación I Datos Simulados, JAGS.




(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 5: Gráficas de autocorrelación parámetros finales Estimación I Datos Simulados, JAGS.

De lo anterior, se puede observar que según el criterio que se definió en esta investigación, la a posteriori para los parámetros β_0 , β_1 y β_2 converge aproximadamente hacia la función a posteriori deseada.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 4: Tamaño Efectivo Estimación I Final, Jags.

	β_0	β_1	β_2
=	19180.69	18278.95	18163.68

y su diagnostico de Gelman es:

Tabla 5: Diagnóstico de Gelman Estimación I Final, Jags

	point est.	upper c.i.
= β_0	1.00	1.00
β_1	1.00	1.00
β_2	1.00	1.00

esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergieron a lo deseado. La cantidad de tiempo, en segundo, utilizado para esta estimación es:

Tabla 6: Tiempo Estimación I, Jags.

	user	system	elapsed
=	16389.16	22.89	16466.23

Lo cual dice que el proceso demoró 16466 segundos en total.

3.2.1.1.4. Parámetros Finales

De lo anterior, se puede también calcular los betas estimados y sus intervalos de confianza asociados:

Tabla 7: Parámetros finales Estimación I Datos Simulados, JAGS.

	Parámetros	Media	SD	Naive SE
=	β_0	1.005	0.036	0.0003
	β_1	1.967	0.049	0.0003
	β_2	3.030	0.064	0.0004

Tabla 8: Intervalos de colas iguales

	Parámetros	0.025	0.975
=	β_0	0.934	1.076
	β_1	1.872	2.063
	β_2	2.906	3.158

Tabla 9: Intervalo de más alta prob. cadena 1

	Parámetros	Lower	Upper
=	β_0	0.933	1.073
	β_1	1.872	2.063
	β_2	2.904	3.154

Tabla 10: Intervalo de más alta prob. cadena 2

	Parámetros	Lower	Upper
=	β_0	0.933	1.077
	β_1	1.871	2.063
	β_2	2.901	3.154

de lo cual se puede observar que los parámetros estimados estiman correctamente los datos como fueron simulados.

3.2.1.1.5. Curva ROC y Análisis de Sensibilidad y Especificidad

Ahora, se analiza la calidad del modelo con los betas estimados, para predecir la variable respuesta, esto se puede ver a través de la ya definida Curva Roc y también a través del análisis de Sensibilidad y Especificidad.

En primera instancia se analizará la curva ROC:




Figura 6: Curva Roc Modelo I con Datos Simulados

Se puede apreciar que el mejor punto de corte es de 0,5 con un AUC igual a 0,803; esto se utilizara para clasificar las observaciones, lo cual entrega lo siguiente:
por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{3084}{4019} = 0,77$
- Especificidad $\frac{5014}{5981} = 0,84$

Además el modelo es capaz de clasificar correctamente en un 81 % ($\frac{3084+5014}{10000} = \frac{8098}{10000} = 0,81$).

3.2.1.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma

Este modelo se ejecutó con dos cadenas, con el fin de poder comparar entre la convergencia, con un número de 10000 iteraciones y sin ningún salto entre ellas, estimándose así las funciones a posteriori de los parámetros, los cuales se estimaran, en este caso, teniendo una varianza con una distribución Gamma con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim \text{Gamma}(0,01; 0,01)$.

3.2.1.2.1. Parámetros Iniciales


La simulación de los datos generó los siguientes parámetros iniciales:

Tabla 11: Parámetros iniciales Estimación II Datos Simulados, JAGS.


Parámetros	Media	SD	Naive SE
β_0	1.003	0.037	0.0003
β_1	1.964	0.049	0.0003
β_2	3.027	0.065	0.0005
σ_0^2	6.334	13.281	0.094
σ_1^2	12.180	19.318	0.137
σ_2^2	21.743	33.034	0.234

3.2.1.2.2. Análisis de Convergencia


En primera instancia, analizaremos los gráficos de las funciones a posteriori de los parámetros,



(a) Función a posteriori de β_0






(b) Función a posteriori de β_1



(c) Función a posteriori de β_2

Figura 7: Funciones a posteriori parámetros iniciales Estimación II Datos Simulados, JAGS.

(a) Función a posteriori de σ_0^2 (b) Función a posteriori de σ_1^2 (c) Función a posteriori de σ_2^2 Figura 8: Funciones a posteriori σ^2 , Estimación II Datos Simulados, JAGS.

de estos gráficos se puede asegurar de manera a priori, que los parámetros $\beta_0, \beta_1, \beta_2$, cumplen con la estacionariedad, además de que se observan medias y varianzas constantes, esto implica que no se ve a simple vista que se deban quemar datos, pero para efectos prácticos esto se hará desde las 2000 observaciones.




(a) Gráficas de autocorrelación de β_0 (b) Gráficas de autocorrelación de β_1 (c) Gráficas de autocorrelación de β_2

Figura 9: Gráficas de autocorrelación parámetros iniciales Estimación II Datos Simulados, JAGS.




(a) Función a posteriori de σ_0^2 (b) Función a posteriori de σ_1^2 (c) Función a posteriori de σ_2^2

Figura 10: Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación II Datos Simulados, JAGS.

Se puede apreciar, de manera a priori, que para el parámetros β_0 su autocorrelación termina en el período 6 y para los parámetros β_1 y β_2 en el período 9.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 12: Tamaño Efectivo Estimación II, Jags.

	β_0	β_1	β_2	σ_0	σ_1	σ_2
=	6591.61	4614.1	4415.13	269.46	1030.37	940.65

y su diagnostico de Gelman es:


Tabla 13: Diagnóstico de Gelman Estimación II, Jags

	point est.	upper c.i.
β_0	1.00	1.01
β_1	1.00	1.01
β_2	1.00	1.00
σ_0	1.02	1.03
σ_1	1.00	1.00
σ_2	1.03	1.05


esto quiere decir, que los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2$ y σ_2^2 convergen con las 10000 iteraciones.

3.2.1.2.3. Estimación Final


De las conclusiones anteriores se decide, finalmente, quemar las primeras 2000 observaciones y realizar un salto cada 9 observaciones, con lo cual se obtuvieron las siguientes gráficas y parámetros:



(a) Funciones a posteriori de β_0






(b) Funciones a posteriori de β_1



(c) Funciones a posteriori de β_2

Figura 11: Funciones a posteriori parámetros finales Estimación II Datos Simulados, JAGS.

(a) Funciones a posteriori de σ_0^2 (b) Funciones a posteriori de σ_1^2 (c) Funciones a posteriori de σ_2^2 Figura 12: Funciones a posteriori σ^2 , Estimación II Datos Simulados, JAGS




(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 13: Gráficas de autocorrelación parámetros finales Estimación II Datos Simulados, JAGS.




(a) Gráficas de autocorrelación final de σ_0^2 (b) Gráficas de autocorrelación final de σ_1^2 (c) Gráficas de autocorrelación final de σ_2^2

Figura 14: Gráficas de autocorrelación parámetros finales σ^2 , Estimación II Datos Simulados, JAGS.

De lo anterior, se puede observar que según el criterio que se definió en esta investigación, la a posteriori para los parámetros β_0 , β_1 y β_2 converge aproximadamente hacia la función a posteriori deseada.

La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 14: Tamaño Efectivo Estimación II final, Jags.

	β_0	β_1	β_2	σ_0	σ_1	σ_2
=	19526.2	19088.79	19019.25	1030.37	940.65	

y su diagnostico de Gelman es:

Tabla 15: Diagnóstico de Gelman Estimación II Final, Jags

	point est.	upper c.i.
β_0	1.00	1.00
β_1	1.00	1.00
β_2	1.00	1.00
σ_0	1.02	1.02
σ_1	1.04	1.05
σ_2	1.00	1.00

esto quiere decir, que los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2$ y σ_2^2 convergen con las 10000 iteraciones. Además, la cantidad de tiempo, en segundo, utilizado para esta estimación es:

Tabla 16: Tiempo Estimación II , Jags.

	user	system	elapsed
=	21591.73	17.92	21639.78

Lo cual dice que el proceso demoró 21639 segundos en total.

3.2.1.2.4. Parámetros Finales

De lo anterior, se puede también calcular los betas estimados y sus intervalos de confianza asociados:

Tabla 17: Parámetros finales Estimación II Datos Simulados, JAGS.

	Parámetros	Media	SD	Naive SE
	β_0	1.002	0.036	0.0003
	β_1	1.963	0.049	0.0003
	β_2	3.024	0.065	0.0005
	σ_0^2	6.603	14.903	0.105
	σ_1^2	14.182	26.904	0.190
	σ_2^2	21.775	32.811	0.232

Tabla 18: Intervalos de colas iguales

	Parámetros	0.025	0.975
	β_0	0.931	1.074
	β_1	1.87	2.061
	β_2	2.899	3.152
	σ_0^2	0.187	51.550
	σ_1^2	0.714	86.312
	σ_2^2	1.611	117.526

Tabla 19: Intervalo de más alta prob. cadena 1

	Parámetros	Lower	Upper
	β_0	0.929	1.073
	β_1	1.869	2.061
	β_2	2.9	3.151
	σ_0^2	0.064	31.388
	σ_1^2	0.223	57.803
	σ_2^2	0.672	82.903

Tabla 20: Intervalo de más alta prob.
cadena 2

Parámetros	Lower	Upper
β_0	0.931	1.072
β_1	1.869	2.063
β_2	2.897	3.15
σ_0^2	0.059	30.1
σ_1^2	0.194	57.645
σ_2^2	0.737	78.114

de lo cual se puede observar que los parámetros estimados estiman correctamente los datos como fueron simulados.

3.2.1.2.5. Curva ROC y Análisis de Sensibilidad y Especificidad

Ahora, se analiza la calidad del modelo con los betas estimados, para predecir la variable respuesta, esto se puede ver a través de la ya definida Curva Roc y también a través del análisis de Sensibilidad y Especificidad.

En primera instancia se analizara la curva ROC:




Figura 15: Curva Roc Modelo II con Datos Simulados

Se puede apreciar que el mejor punto de corte es de 0,5 con un AUC igual a 0,805; esto se utilizara para clasificar las observaciones, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{3048}{4019} = 0,76$
- Especificidad $\frac{5093}{5981} = 0,85$

Además el modelo es capaz de clasificar correctamente en un 81 % ($\frac{3048+5093}{10000} = \frac{8141}{10000} = 0,81$).

3.2.1.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma Inversa

Este modelo se ejecutó con dos cadenas, con el fin de poder comparar entre la convergencia, con un número de 10000 iteraciones y sin ningún salto entre ellas, estimándose así las funciones a posteriori de los parámetros, los cuales se estimaran, en este caso, teniendo una varianza con una distribución Gamma Inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim InvGamma(0,01; 0,01)$.

3.2.1.3.1. Parámetros Iniciales

La simulación de los datos generó los siguientes parámetros iniciales:

Tabla 21: Parámetros iniciales Estimación III Datos Simulados, JAGS.

Parámetros	Media	SD	Naive SE
β_0	1.003	0.037	0.0003
β_1	1.964	0.049	0.0003
β_2	3.027	0.065	0.0005
σ_0^2	1.004	1.434	0.010
σ_1^2	0.262	0.368	0.003
σ_2^2	0.110	0.156	0.001

3.2.1.3.2. Análisis de Convergencia

En primera instancia, analizaremos los gráficos de las funciones a posteriori de los parámetros,







(a) Función a posteriori de β_0 (b) Función a posteriori de β_1 (c) Función a posteriori de β_2

Figura 16: Funciones a posteriori parámetros iniciales Estimación III Datos Simulados, JAGS.

(a) Función a posteriori de σ_0^2 (b) Función a posteriori de σ_1^2 (c) Función a posteriori de σ_2^2 Figura 17: Funciones a posteriori σ^2 , Estimación III Datos Simulados, JAGS.

de estos gráficos se puede asegurar de manera a priori, que los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2, \sigma_2^2$ cumplen con la estacionariedad, además de que se observan medias y varianzas constantes, esto implica que no se ve a simple vista que se deban quemar datos, pero para efectos prácticos esto se hará desde las 2000 observaciones.




(a) Gráficas de autocorrelación de β_0 (b) Gráficas de autocorrelación de β_1 (c) Gráficas de autocorrelación de β_2

Figura 18: Gráficas de autocorrelación parámetros iniciales Estimación III Datos Simulados, JAGS.




(a) Gráficas de autocorrelación de σ_0^2 (b) Gráficas de autocorrelación de σ_1^2 (c) Gráficas de autocorrelación de σ_2^2

Figura 19: Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación III Datos Simulados, JAGS.

Se puede apreciar, de manera a priori, que tanto para los parámetros β_0 y β_1 que autocorrelación de los datos se termina en el período 7 y para el parámetro β_2 en el período 9.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 22: Tamaño Efectivo Estimación III, Jags.

	β_0	β_1	β_2	σ_0	σ_1	σ_2
=	6757.12	4715.864	4657.56	20000.0	20000.0	20022.38

y su diagnostico de Gelman es:

Tabla 23: Diagnóstico de Gelman Estimación III, Jags

	point est.	upper c.i.
β_0	1.00	1.00
β_1	1.00	1.00
$= \beta_2$	1.00	1.00
σ_0	1.00	1.00
σ_1	1.00	1.00
σ_2	1.00	1.00

esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones.

3.2.1.3.3. Estimación Final

De las conclusiones anteriores se decide, finalmente, quemar las primeras 2000 observaciones y realizar un salto cada 9 observaciones, con lo cual se obtuvieron las siguientes gráficas y parámetros:







(a) Funciones a posteriori de β_0 (b) Funciones a posteriori de β_1 (c) Funciones a posteriori de β_2

Figura 20: Funciones a posteriori parámetros finales Estimación III Datos Simulados, JAGS.

(a) Funciones a posteriori de σ_0^2 (b) Funciones a posteriori de σ_1^2 (c) Funciones a posteriori de σ_2^2 Figura 21: Funciones a posteriori σ^2 , Estimación III Datos Simulados, JAGS.



(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 22: Gráficas de autocorrelación parámetros finales Estimación III Datos Simulados, JAGS.




(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 23: Gráficas de autocorrelación parámetros finales σ^2 , Estimación III Datos Simulados, JAGS.

De lo anterior, se puede observar que según el criterio que se definió en esta investigación, la a posteriori para los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2$ y σ_2^2 converge aproximadamente hacia la función a posteriori deseada.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 24: Tamaño Efectivo Estimación III final, Jags.

	β_0	β_1	β_2	σ_0	σ_1	σ_2
=	20000.00	19550.57	20000.00	20000.00	20000.00	20000.00

y su diagnostico de Gelman es:

Tabla 25: Diagnóstico de Gelman Estimación III Final, Jags

	point est.	upper c.i.
β_0	1.00	1.00
β_1	1.00	1.00
β_2	1.00	1.00
σ_0	1.00	1.00
σ_1	1.00	1.00
σ_2	1.00	1.00

esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones. Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 26: Tiempo Estimación III, Jags.

	user	system	elapsed
=	21403.69	22.16	21529.56

Lo cual dice que el proceso demoró 21529 segundos en total.

3.2.1.3.4. Parámetros Finales

De lo anterior, se puede también calcular los betas estimados y sus intervalos de confianza asociados:

Tabla 27: Parámetros finales Estimación III Datos Simulados, JAGS.

	Parámetros	Media	SD	Naive SE
=	β_0	0.631	0.029	0.0002
	β_1	1.253	0.035	0.0002
	β_2	1.917	0.041	0.0003
	σ_0^2	2.411	3.337	0.024
	σ_1^2	0.645	0.919	0.006
	σ_2^2	0.278	0.388	0.003

Tabla 28: Intervalos de colas iguales

	Parámetros	0.025	0.975
=	β_0	0.575	0.687
	β_1	1.186	1.321
	β_2	1.837	1.998
	σ_0^2	0.003	11.755
	σ_1^2	0.001	3.216
	σ_2^2	0.0003	1.368

Tabla 29: Intervalo de más alta prob. cadena 1

	Parámetros	Lower	Upper
=	β_0	0.576	0.687
	β_1	1.188	1.321
	β_2	1.837	1.998
	σ_0^2	2.348e-10	9.201
	σ_1^2	4.872e-09	2.415
	σ_2^2	5.058e-09	1.056

Tabla 30: Intervalo de más alta prob.
cadena 2

Parámetros	Lower	Upper
β_0	0.575	0.687
β_1	1.187	1.324
β_2	1.838	1.996
σ_0^2	1.765e-08	8.995
σ_1^2	1.995e-07	2.439
σ_2^2	1.406e-08	1.054

de lo cual se puede observar que los parámetros estimados estiman correctamente los datos como fueron simulados.

3.2.1.3.5. Curva ROC y Análisis de Sensibilidad y Especificidad

En primera instancia se analizara la curva ROC:




Figura 24: Curva Roc Modelo III con Datos Simulados

Se puede apreciar que el mejor punto de corte es de 0,5 con un AUC igual a 0,756; esto se utilizara para clasificar las observaciones, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{2904}{4019} = 0,72$
- Especificidad $\frac{4719}{5981} = 0,79$

Además el modelo es capaz de clasificar correctamente en un 76 % ($\frac{2904+4719}{10000} = \frac{7623}{10000} = 0,76$).

3.2.2. STAN

3.2.2.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas

Este modelo se ejecutó inicialmente con dos cadenas, con el fin de analizar la convergencia, con un número de 11500 iteraciones ya que en este caso hay una cantidad de quema automática para

poder generar la cadena, la cual en este caso se selecciono una quema de 1500 iteraciones (15 % de los datos requerida por la librería para una correcta ejecución), y así tener la misma cantidad de iteraciones que de datos simulados, esto sin salto entre las observaciones y así estimándose las funciones a posteriori de los parámetros, los cuales se estimaran teniendo una varianza fija con un valor de 1.000.000 .

3.2.2.1.1. Parámetros Iniciales

Tabla 31: Parámetros iniciales Estimación I Datos Simulados, STAN.

Parámetros	Media	SD	Naive SE
β_0	1.004	0.037	0.0003
β_1	1.966	0.049	0.0003
β_2	3.029	0.064	0.0004

3.2.2.1.2. Análisis de Convergencia

Como se especificó en el capítulo 2.3.7.1, no existe un método en específico para comprobar si existe o no una convergencia, pero en este caso se utilizarán los criterios ya mencionados para analizar una posible convergencia aproximada a la posterior.

En primera instancia, analizaremos los gráficos de las funciones a posteriori de los parámetros,




(a) Función a posteriori de β_0 (b) Función a posteriori de β_1 (c) Función a posteriori de β_2

Figura 25: Funciones a posteriori parámetros iniciales Estimación I Datos Simulados, STAN.

de estos gráficos se puede asegurar de manera a priori, que los parámetros $\beta_0, \beta_1, \beta_2$, cumplen con la estacionariedad, además de que se observan medias y varianzas constantes, esto implica que no se ve a simple vista que se deban quemar datos, pero para efectos prácticos esto se hará desde las 2000 observaciones.




(a) Gráficas de autocorrelación de β_0 (b) Gráficas de autocorrelación de β_1 (c) Gráficas de autocorrelación de β_2

Figura 26: Gráficas de autocorrelación parámetros iniciales Estimación I Datos Simulados, STAN.H

Se puede apreciar, de manera a priori, que tanto para los parámetros β_0 y β_1 que autocorrelación de los datos se termina en el período 4 y para el parámetro β_2 en el período 3.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 32: Tamaño Efectivo Estimación I, Stan.

	β_0	β_1	β_2	lp_
=	19398.43	19319.79	19239.74	18966.14

y su diagnostico de Gelman es:


Tabla 33: Diagnóstico de Gelman Estimación I, Stan

	point est.	upper c.i.
β_0	1.00	1.01
= β_1	1.00	1.01
β_2	1.00	1.01
lp	1.00	1.00


esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones.

3.2.2.1.3. Estimación Final


De las conclusiones anteriores se decide, finalmente, quemar las primeras 2000 observaciones y realizar un salto cada 4 observaciones, con lo cual se obtuvieron las siguientes gráficas y parámetros:



(a) Funciones a posteriori de β_0



(b) Funciones a posteriori de β_1



(c) Funciones a posteriori de β_2

Figura 27: Funciones a posteriori parámetros finales Estimación I Datos Simulados, Stan.




(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 28: Gráficas de autocorrelación parámetros finales Estimación I Datos Simulados, Stan.

De lo anterior, se puede observar que según el criterio que se definió en esta investigación, la a posteriori para los parámetros β_0 , β_1 y β_2 converge aproximadamente hacia la función a posteriori deseada.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 34: Tamaño Efectivo Estimación I final, Stan.

	β_0	β_1	β_2	lp_{-}
=	19398.43	19319.79	19239.74	18966.14

y su diagnostico de Gelman es:

Tabla 35: Diagnóstico de Gelman Estimación I Final, Stan

	point est.	upper c.i.
β_0	1.00	1.01
= β_1	1.00	1.01
β_2	1.00	1.01
lp	1.00	1.00

esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones.

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 36: Tiempo Estimación I, Stan.

	user	system	elapsed
=	963.50	0.35	1024.67

Lo cual dice que el proceso demoró 1024 segundos en total.

3.2.2.1.4. Parámetros Finales

De lo anterior, se puede también calcular los betas estimados y sus intervalos de confianza asociados:

Tabla 37: Parámetros finales Estimación I Datos Simulados, Stan.

	Parámetros	Media	SD	Naive SE
=	β_0	1.005	0.037	0.0003
	β_1	1.967	0.049	0.0003
	β_2	3.030	0.065	0.0004

Tabla 38: Intervalo de colas iguales

	Parámetros	0.025	0.975
=	β_0	0.933	1.076
	β_1	1.872	2.065
	β_2	2.903	3.159

Tabla 39: Intervalo más alta prob. Cadena 1

	Parámetros	lower	upper
=	β_0	0.935	1.079
	β_1	1.872	2.064
	β_2	2.901	3.157

Tabla 40: Intervalo más alta prob. Cadena 2

	Parámetros	lower	upper
=	β_0	0.932	1.074
	β_1	1.873	2.065
	β_2	2.905	3.160

de lo cual se puede observar que los parámetros estimados estiman correctamente los datos como fueron simulados.

3.2.2.1.5. Curva ROC y Análisis de Sensibilidad y Especificidad

Ahora, se analiza la calidad del modelo con los betas estimados, para predecir la variable respuesta, esto se puede ver a través de la ya definida Curva Roc y también a través del análisis de Sensibilidad y Especificidad. En primera instancia se analizará la curva ROC:




Figura 29: Curva Roc Modelo I con Datos Simulados

Se puede apreciar que el mejor punto de corte es de 0,5 con un AUC igual a 0,686, esto se utilizara para clasificar las observaciones, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{2057}{4019} = 0,51$
- Especificidad $\frac{5141}{5981} = 0,86$

Además el modelo es capaz de clasificar correctamente en un 72 % ($\frac{2057+5141}{10000} = \frac{7198}{10000} = 0,72$).

3.2.2.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma.

Este modelo se ejecutó solo una dos cadenas, con el fin de poder comparar la convergencia, con un número de 10000 iteraciones y sin ningún salto entre ellas, estimándose así las funciones a posteriori de los parámetros, los cuales se estimaran, en este caso, teniendo una varianza con una distribución Gamma Inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim \text{Gamma}(0,01; 0,01)$.

3.2.2.2.1. Parámetros Iniciales

Tabla 41: Parámetros iniciales Estimación II Datos Simulados, Stan.

Parámetros	Media	SD	Naive SE
β_0	1.002	0.037	0.0003
β_1	1.963	0.049	0.0003
β_2	3.024	0.064	0.0004
σ_0^2	7.053	17.984	0.127
σ_1^2	14.180	26.638	0.188
σ_2^2	21.844	32.984	0.233

3.2.2.2.2. Análisis de Convergencia

En primera instancia, analizaremos los gráficos de las funciones a posteriori de los parámetros,







(a) Función a posteriori de β_0 (b) Función a posteriori de β_1 (c) Función a posteriori de β_2

Figura 30: Funciones a posteriori parámetros iniciales Estimación II Datos Simulados, Stan.

(a) Función a posteriori de σ_0^2 (b) Función a posteriori de σ_1^2 (c) Función a posteriori de σ_2^2 Figura 31: Funciones a posteriori σ^2 , Estimación II Datos Simulados, Stan.

de estos gráficos se puede asegurar de manera a priori, que los parámetros $\beta_0, \beta_1, \beta_2$, cumplen con la estacionariedad, además de que se observan medias y varianzas constantes, esto implica que no se ve a simple vista que se deban quemar datos, pero para efectos prácticos esto se hará desde las 2000 observaciones.




(a) Gráficas de autocorrelación de β_0 (b) Gráficas de autocorrelación de β_1 (c) Gráficas de autocorrelación de β_2

Figura 32: Gráficas de autocorrelación parámetros iniciales Estimación II Datos Simulados, Stan.




(a) Gráficas de autocorrelación de σ_0^2 (b) Gráficas de autocorrelación de σ_1^2 (c) Gráficas de autocorrelación de σ_2^2

Figura 33: Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación II Datos Simulados, Stan.

Se puede apreciar, de manera a priori, que tanto para los parámetros β_0 y β_1 y β_2 su autocorrelación se termina en el período 2.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 42: Tamaño Efectivo Estimación II, Stan.

	β_0	β_1	β_2	σ_0	σ_1	σ_2	lp_{-}
=	18230.56	15186.25	14677.1	13425.32	14315.63	14556.98	9854.57

y su diagnostico de Gelman es:

Tabla 43: Diagnóstico de Gelman Estimación II, Stan

	point est.	upper c.i.
β_0	1.00	1.00
β_1	1.00	1.00
β_2	1.00	1.00
σ_0^2	1.01	1.01
σ_1^2	1.02	1.02
σ_2^2	1.00	1.00
lp	1.00	1.00

esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones.

3.2.2.2.3. Estimación Final

De las conclusiones anteriores se decide, finalmente, quemar las primeras 2000 observaciones y realizar un salto cada 2 observaciones, con lo cual se obtuvieron las siguientes gráficas y parámetros:







(a) Funciones a posteriori de β_0 (b) Funciones a posteriori de β_1 (c) Funciones a posteriori de β_2

Figura 34: Funciones a posteriori parámetros finales Estimación II Datos Simulados, Stan.

(a) Funciones a posteriori de σ_0^2 (b) Funciones a posteriori de σ_1^2 (c) Funciones a posteriori de σ_2^2 Figura 35: Funciones a posteriori σ^2 , Estimación II Datos Simulados, Stan







(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 36: Gráficas de autocorrelación parámetros finales Estimación II Datos Simulados, Stan.

(a) Gráficas de autocorrelación final de σ_0^2 (b) Gráficas de autocorrelación final de σ_1^2 (c) Gráficas de autocorrelación final de σ_2^2 Figura 37: Gráficas de autocorrelación parámetros finales σ^2 , Estimación II Datos Simulados, Stan.

De lo anterior, se puede observar que según el criterio que se definió en esta investigación, la a posteriori para los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2, \sigma_2^2$ converge aproximadamente hacia la función a posteriori deseada.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 44: Tamaño Efectivo Estimación final II, Stan.

	β_0	β_1	β_2	σ_0	σ_1	σ_2	lp_{-}
=	33222.90	27857.26	26822.36	26827.67	27889.87	29681.23	19521.14

y su diagnostico de Gelman es:

Tabla 45: Diagnóstico de Gelman Estimación II Final, Stan

	point est.	upper c.i.
β_0	1.00	1.01
β_1	1.00	1.00
β_2	1.00	1.00
σ_0^2	1.00	1.00
σ_1^2	1.00	1.00
σ_2^2	1.00	1.00
lp	1.00	1.00

esto quiere decir, que los parámetros β_0 , β_1 y β_2 convergen con las 10000 iteraciones. Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 46: Tiempo Estimación II, Stan.

	user	system	elapsed
=	2354.99	1.02	2418.57

Lo cual dice que el proceso demora en total 2418 segundos en total.

3.2.2.2.4. Parámetros Finales

De lo anterior, se pueden también calcular los betas estimados y sus intervalos de confianza asociados:

Tabla 47: Parámetros finales Estimación II Datos Simulados, Stan.

	Parámetros	Media	SD	Naive SE
=	β_0	1.002	0.037	0.0003
	β_1	1.964	0.05	0.0003
	β_2	3.025	0.065	0.0004
	σ_0^2	7.234	19.109	0.135
	σ_1^2	13.739	25.415	0.18
	σ_2^2	21.925	34.242	0.242

Tabla 48: Intervalo de colas iguales

	Parámetros	0.025	0.975
=	β_0	0.930	1.075
	β_1	1.867	2.063
	β_2	2.9	3.154
	σ_0^2	0.189	55.158
	σ_1^2	0.697	84.159
	σ_2^2	1.584	116.191

Tabla 49: Intervalo más alta prob. Cadena 1

	Parámetros	lower	upper
=	β_0	0.934	1.078
	β_1	1.867	2.062
	β_2	2.904	3.16
	σ_0^2	0.067	32.374
	σ_1^2	0.217	55.831
	σ_2^2	0.549	78.879

Tabla 50: Intervalo más alta prob.
Cadena 2

Parámetros	lower	upper
β_0	0.928	1.071
β_1	1.865	2.060
β_2	2.902	3.153
σ_0^2	0.073	31.658
σ_1^2	0.251	55.295
σ_2^2	0.627	81.955

de lo cual se puede observar que los parámetros estimados estiman correctamente los datos como fueron simulados.

3.2.2.2.5. Curva ROC y Análisis de Sensibilidad y Especificidad

Ahora, se analiza la calidad del modelo con los betas estimados, para predecir la variable respuesta, esto se puede ver a través de la ya definida Curva Roc y también a través del análisis de Sensibilidad y Especificidad. En primera instancia se analizara la curva ROC:




Figura 38: Curva Roc Modelo II con Datos Simulados

Se puede apreciar que el mejor punto de corte es de 0,5 con un AUC igual a 0,799, esto se utilizara para clasificar las observaciones, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{3057}{4019} = 0,76$
- Especificidad $\frac{5012}{5981} = 0,84$

Además el modelo es capaz de clasificar correctamente en un 81 % ($\frac{3057+5012}{10000} = \frac{8069}{10000} = 0,81$).

3.2.2.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos sus varianzas distribuyen Gamma Inversa.

Este modelo se ejecutó solo una dos cadenas, con el fin de poder comparar la convergencia, con un número de 10000 iteraciones y sin ningún salto entre ellas, estimándose así las funciones a posteriori de los parámetros, los cuales se estimaran, en este caso, teniendo una varianza con una distribución Gamma Inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim InvGamma(0,01; 0,01)$.

3.2.2.3.1. Parámetros Iniciales

Tabla 51: Parámetros iniciales Estimación III Datos Simulados, Stan.

Parámetros	Media	SD	Naive SE
β_0	1.003	0.037	0.0003
β_1	1.964	0.05	0.0004
β_2	3.026	0.066	0.0005
σ_0^2	9710	610000	4314
σ_1^2	157600	20480000	1448000
σ_2^2	4569000	487600000	3448000

3.2.2.3.2. Análisis de Convergencia

En primera instancia, analizaremos los gráficos de las funciones a posteriori de los parámetros,







(a) Función a posteriori de β_0 (b) Función a posteriori de β_1 (c) Función a posteriori de β_2

Figura 39: Funciones a posteriori parámetros iniciales Estimación III Datos Simulados, Stan.

(a) Función a posteriori de σ_0^2 (b) Función a posteriori de σ_1^2 (c) Función a posteriori de σ_2^2 Figura 40: Funciones a posteriori σ^2 , Estimación III Datos Simulados, JAGS.

de estos gráficos se puede asegurar de manera a priori, que los parámetros $\beta_0, \beta_1, \beta_2$, cumplen con la estacionaridad, además de que se observan medias y varianzas constantes, esto implica que no se ve a simple vista que se deban quemar datos, pero para efectos prácticos esto se hará desde las 2000 observaciones.




(a) Gráficas de autocorrelación de β_0 (b) Gráficas de autocorrelación de β_1 (c) Gráficas de autocorrelación de β_2

Figura 41: Gráficas de autocorrelación parámetros iniciales Estimación III Datos Simulados, Stan.




(a) Gráficas de autocorrelación de σ_0^2 (b) Gráficas de autocorrelación de σ_1^2 (c) Gráficas de autocorrelación de σ_2^2

Figura 42: Gráficas de autocorrelación parámetros iniciales σ^2 , Estimación III
Datos Simulados, Stan.

Se puede apreciar, de manera a priori, que tanto para los parámetros β_0 , β_1 y β_2 que su autocorrelación se termina en el período 5.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 52: Tamaño Efectivo Estimación III , Stan.

	β_0	β_1	β_2	σ_0	σ_1	σ_2	$lp_$
=	10863.20	9936.66	8200.37	11270.76	19584.95	11456.112	6124.42

y su diagnostico de Gelman es:

Tabla 53: Diagnóstico de Gelman Estimación III, Stan

	point est.	upper c.i.
β_0	1.00	1.00
β_1	1.00	1.00
β_2	1.00	1.00
σ_0^2	1.29	1.30
σ_1^2	1.29	1.30
σ_2^2	1.29	1.30
lp	1.00	1.00

esto quiere decir, que los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2$ y σ_2^2 convergen con las 10000 iteraciones.

3.2.2.3.3. Estimación Final

De las conclusiones anteriores se decide, finalmente, quemar las primeras 2000 observaciones y realizar un salto cada 5 observaciones, con lo cual se obtuvieron las siguientes gráficas y parámetros:







(a) Funciones a posteriori de β_0 (b) Funciones a posteriori de β_1 (c) Funciones a posteriori de β_2

Figura 43: Funciones a posteriori parámetros finales Estimación III Datos Simulados, Stan.

(a) Funciones a posteriori de σ_0^2 (b) Funciones a posteriori de σ_1^2 (c) Funciones a posteriori de σ_2^2 Figura 44: Funciones a posteriori σ^2 , Estimación III Datos Simulados, Stan.




(a) Gráficas de autocorrelación final de β_0 (b) Gráficas de autocorrelación final de β_1 (c) Gráficas de autocorrelación final de β_2

Figura 45: Gráficas de autocorrelación parámetros finales Estimación III Datos Simulados, Stan.




(a) Gráficas de autocorrelación final de σ_0^2 (b) Gráficas de autocorrelación final de σ_1^2 (c) Gráficas de autocorrelación final de σ_2^2

Figura 46: Gráficas de autocorrelación parámetros finales σ^2 , Estimación III Datos Simulados, Stan.

De lo anterior, se puede observar que según el criterio que se definió en esta investigación, la a posteriori para los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2$ y σ_2^2 converge aproximadamente hacia la función a posteriori deseada.

la cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 54: Tamaño Efectivo Estimación III final, Stan.

	β_0	β_1	β_2	σ_0	σ_1	σ_2	lp_{-}
=	23829.49	19473.08	19353.55	10302.7	16816.03	12569.30	11080.56

y su diagnóstico de Gelman es:

Tabla 55: Diagnóstico de Gelman Estimación III Final, Stan

	point est.	upper c.i.
β_0	1.00	1.00
β_1	1.00	1.00
β_2	1.00	1.00
σ_0^2	1.28	1.29
σ_1^2	1.20	1.20
σ_2^2	1.28	1.28
lp	1.00	1.00

esto quiere decir, que los parámetros $\beta_0, \beta_1, \beta_2, \sigma_0^2, \sigma_1^2$ y σ_2^2 convergen con las 10000 iteraciones. Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 56: Tiempo Estimación III, Stan.

	user	system	elapsed
=	957.53	2.58	1093.70

Lo cual dice que el proceso demoro 1093 segundos en total.

3.2.2.3.4. Parámetros Finales

De lo anterior, se pueden también calcular los betas estimados y sus intervalos de confianza asociados:

Tabla 57: Parámetros finales Estimación III Datos Simulados, Stan.

Parámetros	Media	SD	Naive SE
β_0	1.003	0.036	0.0003
β_1	1.964	0.05	0.0004
β_2	3.026	0.065	0.0005
σ_0^2	266968.824	34070000	240900
σ_1^2	86797.296	5577000	39440
σ_2^2	41782.081	3593000	2.5410

Tabla 58: Intervalo de colas iguales

Parámetros	0.025	0.975
β_0	0.932	1.075
β_1	1.868	2.062
β_2	2.9	3.155
σ_0^2	0.2	872.428
σ_1^2	0.765	3621.763
σ_2^2	1.833	7622.790

Tabla 59: Intervalo más alta prob. Cadena 1

Parámetros	lower	upper
β_0	0.93	1.074
β_1	1.867	2.061
β_2	2.899	3.154
σ_0^2	0.054	293.064
σ_1^2	0.283	928.255
σ_2^2	0.560	2364.916

Tabla 60: Intervalo más alta prob.
Cadena 2

Parámetros	lower	upper
β_0	0.93	1.075
β_1	1.870	2.064
β_2	2.898	3.152
σ_0^2	0.073	170.659
σ_1^2	0.234	1056.883
σ_2^2	0.619	1917.193

de lo cual se puede observar que los parámetros estimados estiman correctamente los datos como fueron simulados.

3.2.2.3.5. Curva ROC y Análisis de Sensibilidad y Especificidad

Ahora, se analiza la calidad del modelo con los betas estimados, para predecir la variable respuesta, esto se puede ver a través de la ya definida Curva Roc y también a través del análisis de Sensibilidad y Especificidad. En primera instancia se analizara la curva ROC:




Figura 47: Curva Roc Modelo III con Datos Simulados

Se puede apreciar que el mejor punto de corte es de 0,5 con un AUC igual a 0,807, esto se utilizara para clasificar las observaciones, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{3089}{4019} = 0,77$
- Especificidad $\frac{5062}{5981} = 0,85$

Además el modelo es capaz de clasificar correctamente en un 82 % ($\frac{3089+5062}{10000} = \frac{8151}{10000} = 0,82$).

3.2.3. Resumen

A continuación se presentan una tabla comparativa para cada librería cual se resumen las métricas y los supuestos de las estimaciones:

- ☒ indica que todos los parámetros cumplen el supuesto.
- ☒ indica que al menos 1 parámetro no cumplen el supuesto.

Además se define lo siguiente como:

- Est I: Estimación I (Todas las variables y observaciones simuladas, dos cadenas, sin saltos sus varianzas con valor fijo.).
- Est II: Estimación II (Todas las variables y observaciones simuladas, dos cadenas, sin saltos sus varianzas distribuyen Gamma).
- Est III: Estimación III (Todas las variables y observaciones simuladas, dos cadenas, sin saltos sus varianzas distribuyen Gamma Inversa).

Tabla 61: Tabla Resumen Datos Simulados JAGS

JAGS	AUC	Sens.	Espe.	Acur.	Estac.	Media cste	Autocorr.	Parám	Gelman	Tiempo	Tamaño Min
Est I	0.803	0.77	0.84	0.81	☒	☒	☒	☒	☒	16466.23	19180
Est II	0.805	0.76	0.85	0.81	☒	☒	☒	☒	☒	21639.78	19526
Est III	0.756	0.72	0.79	0.76	☒	☒	☒	☒	☒	21529.56	20000

Tabla 62: Tabla Resumen Datos Simulados Stan

STAN	AUC	Sens.	Espe.	Acur.	Estac.	Media cste	Autocorr.	Parám	Gelman	Tiempo	Tamaño Min
Est I	0.686	0.51	0.86	0.72	☒	☒	☒	☒	☒	1024.67	19398
Est II	0.799	0.76	0.84	0.81	☒	☒	☒	☒	☒	2418.57	33222
Est III	0.807	0.77	0.85	0.82	☒	☒	☒	☒	☒	1093.7	23829

Por lo que lo se decide la mejor estimación es la tercera , la cual se ejecutó con dos cadenas, con un número de 10000 iteraciones y sin ningún salto entre ellas, estimándose así las funciones a posteriori de los parámetros, los cuales se estimaran, en este caso, teniendo una varianza con una distribución Gamma Inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim InvGamma(0,01; 0,01)$ en la librería STAN.

3.3. Estimación con Datos Reales

En este caso, se realiza la estimación de los parámetros definidos en la sección 3.2, pero a través de datos reales, para esto se tiene información del comportamiento temporal del brillo de estrellas variables observadas en la vía láctea gracias al estudio astronómico VVV[8].

Esta base de datos contiene 18.809 observaciones y 13 variables. El detalle de las variables disponibles en la base de datos es el siguiente:

- **rrl**: Variable Binaria (1: La estrella es del tipo RR-Lyrae, 0: La estrella no es del tipo RR-Lyrae)
- **A.1.1.**: Amplitud estimada de la estrella variable con el período y 1er componente de un modelo armónico.
- **A.1.2.**: Amplitud estimada de la estrella variable con el período y 2do componente de un modelo armónico.
- **A.1.3.**: Amplitud estimada de la estrella variable con el período y 3er componente de un modelo armónico.
- **PH.1.2.**: Fase estimada de la estrella variable con el período y 2do componente de un modelo armonico.
- **PH.1.3.**: Fase estimada de la estrella variable con el período y 3er componente de un modelo armonico.
- **PH.1.4.**: Fase estimada de la estrella variable con el período y 4to componente de un modelo armonico.
- **f1**: Frecuencia (1/período) del brillo temporal de la estrella variable.
- **P1**: Peak en el periodograma de la frecuencia estimada (f1).
- **s**: Asimetría del brillo temporal de la estrella variable.
- **p2p s2p**: Suma de las diferencias al cuadrado entre pares de observaciones sucesivas en el brillo temporal de la estrella variable doblada en 2 veces el período dividido por los valores en bruto.
- **p2p spfom**: Mediana de las diferencias absolutas pares de observaciones sucesivas en el brillo temporal de la estrella variable doblada en 2 veces el período dividido por los valores en bruto.
- **R1**: Relación entre la fase transcurrida hasta alcanzar el primer mínimo y el segundo máximo del brillo temporal de la estrella variable.

Se procederá a seguir el siguiente esquema, en el cual se muestra el procedimiento implementado para esta sección:




Figura 48: Esquema Datos Reales

Una interpretación resumida para lo realizado en este conjunto de datos es la siguiente:

- Se procedió a realizar un análisis descriptivo, tanto de presencia de outliers como de correlaciones para el conjunto de datos especificados con anterioridad, con el fin de poder realizar conclusiones con respecto a los datos y variables presente en el conjunto de datos.
- En primera instancia se procedió a generar las estimaciones del modelo especificado con una varianza de los parámetros de valor fijo, esto con pequeñas variaciones para poder analizar si las conclusiones obtenidas con respecto al punto anterior son o no significativas, para esto se analizó la estimación con todos los datos existentes, luego de ello, se realizó la estimación de estos sin considerar un pequeño grupo de outliers y luego un pequeño grupo mayor al anterior, concluyéndose así que si se realizaba una mejor estimación computacionalmente. Cabe destacar que todas las estimaciones se realizaron a través de la librería Jags como así también la librería JAGS.
- Luego de lo anterior se procedió a generar la estimación incluyendo en este caso la eliminación de 2 variables, las cuales se encontraban altamente correlacionada con otra presente la cual se decidió dejar, lo cual concluyó que si se realizaba una mejor estimación en términos de convergencia.
- Luego de las conclusiones anteriores y las decisiones de eliminar outliers y variables, se decidió mantener estos cambios y trabajar con ese conjunto de datos mas reducido. Con lo anterior se procedió a realizar el análisis del modelo a través de 3 variaciones: la varianza de los parámetros con varianzas fijas, con distribución Gamma y con distribución Gamma Inversa, esto con el fin de comparar cual de estas estimaciones es la mas recomendada.
- Las comparaciones de estas estimaciones se realizaron en funcion de lo definido con anterioridad en el marco teórico, estos fueron: convergencia, performance, tamaño de iteraciones y tiempo de ejecución de la estimación. Así también en el proceso se recomendó una configuración final para la estimación con la cual se aseguraría la convergencia de esta.
- Todo lo anteriormente realizado fue con el fin de elegir tanto como una forma de estimación como de una librería para así en un futuro recomendar el modelo agregándole componentes de tiempo

Esto y mas se muestra a continuación:

3.3.1. Análisis descriptivo

En primera instancia se realizo un un breve análisis descriptivo de los datos, con el objetivo de observar el comportamiento de las variables, el cual se presenta a continuación:

3.3.1.1. Medidas de Tendencia y Dispersión

Tabla 63: Medidas Descriptivas Datos Reales

	rrl	A.1.1.	A.1.2.	A.1.3.	PH.1.2.	PH.1.3.	PH.1.4.
Min.	0	-0,024	-0,025	-0,013	-1,46	-1,903	-1,793
1st Qu.	0	-0,024	-0,025	-0,013	-0,826	-0,739	-0,85
Median	0	-0,024	-0,025	-0,013	-0,357	-0,018	-0,022
Mean	0,121	0	0	0	0	0	0
3rd Qu.	0	-0,024	-0,025	-0,013	0,879	0,845	0,832
Max.	1	109,699	87,124	134,114	2,023	1,606	1,827

	f1	P1	s	p2p s2p	p2p spfom	R1
Min.	-1.399	-2.275	-10.298	-2.028	-2.284	-0.838
1st Qu.	-0,731	-0,803	-0,65	-0,675	-0,621	-0,403
Median	-0,057	-0,092	-0,006	0,131	0,013	-0,182
Mean	0	0	0	0	0	0
3rd Qu.	1,008	0,779	0,644	0,714	0,571	0,059
Max.	2,26	2,2	10,265	34,559	15,189	18,007

3.3.1.2. Boxplots

En las siguientes imágenes se pueden apreciar el como se comporta la distribución de las variables:




Figura 49: Boxplots de las variables cuantitativas..

Se pueden observar que existen grandes cantidades de outliers presentes en las variables “A.1.1”, “A.1.2”, “A.1.3”, “s”, “p2p_s2p”, “p2p_spfom” y “R1”.

3.3.1.3. Boxplots según variable binaria rrl

En las siguientes imágenes se pueden apreciar el como se distribuyen las variables, esto según la clasificación 0 o 1 de la variable **rrl**:




Figura 50: Boxplot.




Figura 51: Boxplot.

Se pueden observar al igual que en la sección anterior y así también corroborar el que existen grandes cantidades de outliers presentes en las variables “A.1.1”, “A.1.2”, “A.1.3”, “s”, “p2p_s2p”, “p2p_2pfom” y “R1”.

3.3.1.4. Correlaciones

En las siguientes imágenes se pueden apreciar las correlaciones entre las variables de estudio:




Figura 52: Correlaciones de los Datos Reales.

De lo anterior se puede observar que las variables “A.1.1.” y “A.1.2.” poseen una correlación de 0,98, esto es altamente correlacionadas, así mismo se puede observar esto también entre las variables “A.1.1” y “A.1.3.”, y entre las variables “A.1.1” y “A.1.3.” las cuales se encuentran altamente correlacionadas con un 0,9 y un 0,74 respectivamente. También se observa el que existe una alta correlación entre las variables “P1” y “p2p_spfom” con un valor de 0,8.

3.3.2. Estimación Analítica

En esta sección se referencia al anexo en el punto 2.3, ya que en este se muestran los modelos utilizados y descritos en la metodología 3.3, en los cuales se fue comparando lo anteriormente dicho sobre la eliminación de observaciones 3.3.1.2. y de variables 3.3.1.3. .

3.3.3. JAGS

3.3.3.1. Estimación I: Eliminación de variables, una cadena, sin salto y sin outliers

Este modelo se ejecutó solo una vez con una cadena pero a diferencia de los otros modelos en este caso se decidieron eliminar las variables “A.1.1” y “A.1.2”, esto ya que al observar tanto en los intervalos de más alta probabilidad como en los de colas iguales, estos contenían el 0, por lo que se podía apreciar que no eran significativos para el modelo, esto además de que estas variables se encontraban altamente correlacionadas con la variable “A.1.3”, por lo tanto esto es que contiene solamente 10 variables predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior (valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas.

Parámetros I

Los parámetros estimados iniciales para el modelo son:

Tabla 64: Parámetros Estimación Datos reales I, JAGS

Parámetros	Media	SD	Naive SE
β_0	-18.517	4.340	0.032
β_1	-842.588	320.002	2.334
β_2	-2.857	0.152	0.001
β_3	0.786	0.043	0.0003
β_4	-0.438	0.046	0.0003
β_5	-0.209	0.048	0.0003
β_6	0.355	0.100	0.0007
β_7	0.835	0.058	0.0004
β_8	-1.569	0.055	0.0004
β_9	-0.310	0.101	0.0007
β_{10}	-3.276	0.200	0.001

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:





(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{10}$

Figura 53: Funciones a posteriori Estimación Datos reales I, JAGS.

(a) Funciones a posteriori de $\sigma_0, \dots, \sigma_5$ (b) Funciones a posteriori de $\sigma_5, \dots, \sigma_{10}$ Figura 54: Funciones a posteriori σ^2 Estimación Datos reales I, JAGS.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.





(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{10}$

Figura 55: Funciones de autocorrelación Estimación Datos reales I, JAGS..

(a) Funciones autocorrelación de $\sigma_0, \dots, \sigma_5$ (b) Funciones autocorrelación de $\sigma_5, \dots, \sigma_{10}$ Figura 56: Funciones de autocorrelación σ^2 Estimación Datos reales I, JAGS.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones. La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 65: Tamaño Efectivo Estimación I Datos Reales, Jags.

=	β_0	β_1	β_2	β_3	β_4	β_5	β_6	β_7	β_8	β_9	β_{10}
	1.96	1.97	405.04	5187.42	6539.60	3921.62	603.21	1148.03	1911.29	723.576	1396.30

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 66: Tiempo Estimación I, Jags.

=	user	system	elapsed
	12430.06	0.16	12431.13

Lo cual dice que el proceso demoró 12431 segundos en total.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 57: Curva ROC modelo para Estimación Datos reales I, JAGS

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,806, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15736}{16523} = 0,95$
- Especificidad $\frac{1505}{2279} = 0,66$

Además el modelo es capaz de clasificar correctamente en un 92 % ($\frac{15736+1505}{18802} = \frac{17241}{18802} = 0,92$).

3.3.3.2. Estimación II: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma.

Este modelo se ejecutó solo una vez con una cadena, sin las variables “A.1.1” y “A.1.2”, al igual que en la estimación anterior, por lo tanto esto es que contiene solamente 10 variables predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior (valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas. Además de esto, en este caso las varianzas de los betas estimados siguen una distribución gamma con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim \text{Gamma}(0,01; 0,01)$.

Parámetros V

Los parámetros obtenidos con la simulación son los siguientes

Tabla 67: Parámetros Estimación Datos reales II, JAGS

Parámetros	Media	SD	Naive SE
β_0	-7.102	0.184	1.345e-03
β_1	-0.003	0.048	3.490e-04
β_2	-2.850	0.155	1.130e-03
β_3	0.788	0.043	3.110e-04
β_4	-0.424	0.047	3.402e-04
β_5	-0.164	0.054	3.906e-04
β_6	0.494	0.114	8.319e-04
β_7	0.859	0.056	4.100e-04
β_8	-1.571	0.055	4.031e-04
β_9	-0.16	0.120	8.754e-04
β_{10}	-3.281	0.208	1.515e-03
σ_0^2	16.185	8.896	6.488e-02
σ_1^2	0.002	0.009	6.749e-05
σ_2^2	21.400	32.130	2.343e-01
σ_3^2	3.413	6.767	4.935e-02
σ_4^2	4.63	11.624	8.477e-02
σ_5^2	0.46	1.166	8.504e-03
σ_6^2	5.305	17.139	1.250e-01
σ_7^2	8.091	21.191	1.545e-01
σ_8^2	10.046	18.008	1.313e-01
σ_9^2	0.108	0.133	9.669e-04
σ_{10}^2	24.815	35.667	2.601e-01

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:





(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{10}$

Figura 58: Funciones a posteriori Estimación Datos reales II, JAGS.

(a) Funciones a posteriori de $\sigma_0, \dots, \sigma_5$ (b) Funciones a posteriori de $\sigma_5, \dots, \sigma_{10}$ Figura 59: Funciones a posteriori σ^2 Estimación Datos reales II, JAGS.





(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{10}$

Figura 60: Funciones de autocorrelación Estimación Datos reales II, JAGS.

(a) Funciones autocorrelación de $\sigma_0, \dots, \sigma_5$ (b) Funciones autocorrelación de $\sigma_5, \dots, \sigma_{10}$ Figura 61: Funciones de autocorrelación σ^2 Estimación Datos reales II, JAGS.

La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 68: Tamaño Efectivo Estimación II Datos Reales, Jags.

	β_0	β_1	β_2	β_3	β_4	β_5	β_6	β_7	β_8	β_9	β_{10}
=	2.39	1.57	393.65	5227.41	5846.38	4808.72	585.64	1329.42	2149.29	671.46	1296.72

Tabla 69: Tamaño Efectivo Estimación II Datos Reales, Jags.

	σ_0	σ_1	σ_2	σ_3	σ_4	σ_5	σ_6	σ_7	σ_8	σ_9	σ_{10}
=	1161.49	1603.67	18802.00	18802.00	17423.33	16191.67	4102.22	18802.00	18966.10	3759.25	17518.994

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 70: Tiempo Estimación II, Jags.

	user	system	elapsed
=	61883.18	7.78	62099.92

Lo cual dice que el proceso demoró 62099 segundos en total.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 62: Curva ROC modelo para Estimación Datos reales II, JAGS.

Donde se puede apreciar que el mejor punto de corte es de un 0,5 dando así un un AUC igual 0,629 , por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{7872}{16523} = 0,47$
- Especificidad $\frac{1781}{2279} = 0,21$

Además el modelo es capaz de clasificar correctamente en un 51 % ($\frac{7872+1781}{18802} = \frac{9653}{18802} = 0,51$).

3.3.3.3. Estimación III: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma Inversa.

Este modelo se ejecutó solo una vez con una cadena, sin las variables “A.1.1” y “A.1.2”, al igual que en la estimación anterior, por lo tanto esto es que contiene solamente 10 variables predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior (valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas. Además de esto, en este caso las varianzas de los betas estimados siguen una distribución gamma inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim InvGamma(0,01; 0,01)$.

Parámetros VI

Tabla 71: Parámetros Estimación Datos reales III, JAGS

Parámetros	Media	SD	Naive SE
β_0	-7.047	0.181	0.001
β_1	0.0003	0.010	7.460e-05
β_2	-2.817	0.15	0.001
β_3	0.787	0.043	3.162e-04
β_4	-0.422	0.047	3.399e-04
β_5	-0.163	0.056	4.098e-04
β_6	0.442	0.142	0.0001
β_7	0.855	0.056	4.064e-04
β_8	-1.564	0.056	4.078e-04
β_9	-0.218	0.157	0.001
β_{10}	-3.24	0.22	0.002
σ_0^2	16.338	9.369	0.068
σ_1^2	0.0002	0.002	1.393e-05
σ_2^2	20.856	31.013	0.226
σ_3^2	3.851	7.326	0.053
σ_4^2	1.813	4.484	0.033
σ_5^2	0.249	0.451	0.003
σ_6^2	2.024	4.998	0.036
σ_7^2	4.766	10.168	0.074
σ_8^2	9.387	16.437	0.12
σ_9^2	0.319	0.691	0.005
σ_{10}^2	22.959	32.486	0.237

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:





(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{10}$

Figura 63: Funciones a posteriori Estimación Datos reales III, JAGS.

(a) Funciones a posteriori de $\sigma_0, \dots, \sigma_5$ (b) Funciones a posteriori de $\sigma_5, \dots, \sigma_{10}$ Figura 64: Funciones a posteriori σ^2 Estimación Datos reales III, JAGS.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.





(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{10}$

Figura 65: Funciones de autocorrelación Estimación Datos reales III, JAGS.

(a) Funciones autocorrelación de $\sigma_0, \dots, \sigma_5$ (b) Funciones autocorrelación de $\sigma_5, \dots, \sigma_{10}$ Figura 66: Funciones de autocorrelación σ^2 Estimación Datos reales III, JAGS.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones. La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

beta[1]	beta[2]	beta[3]	beta[4]	beta[5]	beta[6]	beta[7]	beta[8]
1.566	393.645	5227.413	5846.380	4808.723	585.638	1329.417	2149.293
beta[9]	beta[10]	beta0	sig2[1]	sig2[2]	sig2[3]	sig2[4]	sig2[5]
671.462	1296.718	2.389	1603.670	18802.000	18802.000	17423.334	16191.669
sig2[6]	sig2[7]	sig2[8]	sig2[9]	sig2[10]	sig20		
4102.221	18802.000	18966.101	3759.254	17518.994	1161.490		

Figura 67: Tamaño Efectivo Estimación III Datos Reales, Jags.

Tabla 72: Tamaño Efectivo Estimación II Datos Reales, Jags.

β_0	β_1	β_2	β_3	β_4	β_5	β_6	β_7	β_8	β_9	β_{10}
2.39	1.57	393.65	5227.41	5846.38	4808.72	585.64	1329.42	2149.29	671.46	1296.72

Tabla 73: Tamaño Efectivo Estimación II Datos Reales, Jags.

σ_0	σ_1	σ_2	σ_3	σ_4	σ_5	σ_6	σ_7	σ_8	σ_9	σ_{10}
1161.49	1603.67	18802.00	17423.33	16191.67	4102.22	18802.00	18966.10	3759.25	17518.994	

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 74: Tiempo Estimación III, Jags.

user	system	elapsed
18918.27	0.26	18922.50

Lo cual dice que el proceso demora en 18922 segundos en total.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 68: Curva ROC modelo para Estimación Datos reales III, JAGS

Donde se puede apreciar que el mejor punto de corte es de un 0,5 dando así un un AUC igual 0,805, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15754}{16523} = 0,95$

- Especificidad $\frac{1498}{2279} = 0,65$

Además el modelo es capaz de clasificar correctamente en un 92 % ($\frac{15754+1498}{18802} = \frac{17252}{18802} = 0,92$).

3.3.4. STAN

3.3.4.1. Estimación I: Eliminación de variables, una cadena, sin salto y sin outliers.

Este modelo se ejecutó solo una vez con una cadena pero a diferencia de los otros modelos en este caso se decidieron eliminar las variables “A.1.1” y “A.1.2”, esto ya que al observar tanto en los intervalos de más alta probabilidad como en los de colas iguales, estos contenían el 0, por lo que se podía apreciar que no eran significativos para el modelo, esto además de que estas variables se encontraban altamente correlacionadas con la variable “A.1.3”, por lo tanto esto es que contiene solamente 10 variables predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior (valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas.

Parámetros I

Los parámetros obtenidos con la simulación son los siguientes

Tabla 75: Parámetros Estimación Datos reales I, Stan

Parámetros	Media	se_mean	SD
β_0	-36.703	9.351	14.890
β_1	-2181.332	688.566	1096.450
β_2	-2.867	0.002	0.155
β_3	0.784	0.000	0.043
β_4	-0.450	0.004	0.048
β_5	-0.230	0.010	0.052
β_6	0.333	0.009	0.099
β_7	0.811	0.011	0.061
β_8	-1.577	0.000	0.056
β_9	-0.314	0.001	0.099
β_{10}	-3.350	0.022	0.214

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:



(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{11}$

Figura 69: Funciones a posteriori Estimación Datos reales I, Stan.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.



(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_5, \dots, \beta_{11}$

Figura 70: Funciones de autocorrelación Estimación Datos reales I, Stan.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones. La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 76: Tamaño Efectivo Estimación I Datos Reales, Stan.

=	β_0	β_1	β_2	β_3	β_4	β_5	β_6	β_7	β_8	β_9	β_{10}	lp_
	1.95	1.90	10103.90	23220.00	2532.38	379.18	2379.02	501.96	10202.16	13152.89	1721.51	4.86

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 77: Tiempo Estimación I, Stan.

=	user	system	elapsed
	13118.30	0.48	13176.00

Lo cual dice que el proceso demoró 13176 segundos en total.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 71: Curva ROC modelo para Estimación Datos reales I, Stan

Donde se puede apreciar que el mejor punto de corte es de un 0,5 dando así un un AUC igual 0,814, por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15763}{16523} = 0,95$
- Especificidad $\frac{1536}{2279} = 0,67$

Además el modelo es capaz de clasificar correctamente en un 92 % ($\frac{15763+1536}{18802} = \frac{18042}{18802} = 0,92$).

3.3.4.2. Estimación II: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma.

Este modelo se ejecutó solo una vez con una cadena, sin las variables “A.1.1” y “A.1.2”, al igual que en la estimación anterior, por lo tanto esto es que contiene solamente 10 variables predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior (valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas. Además de esto, en este caso las varianzas de los betas estimados siguen una distribución gamma con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim \text{Gamma}(0,01; 0,01)$.

Parámetros II

Los parámetros obtenidos con la simulación son los siguientes:

Tabla 78: Parámetros Estimación Datos reales II, Stan

Parámetros	Media	se_mean	SD
β_0	-7.072	0.002	0.184
β_1	-0.929	0.105	2.806
β_2	-2.838	0.001	0.152
β_3	0.786	0.000	0.043
β_4	-0.419	0.000	0.047
β_5	-0.167	0.000	0.051
β_6	0.389	0.001	0.108
β_7	0.864	0.001	0.057
β_8	-1.562	0.001	0.055
β_9	-0.286	0.002	9.114
β_{10}	-3.194	0.002	0.203
σ_0	50.325	0.445	49.445
σ_1	7.407	0.809	28.368
σ_2	20.303	0.302	32.078
σ_3	5.760	0.188	17.523
σ_4	3.332	0.205	11.969
σ_5	1.478	0.279	7.962
σ_6	2.764	0.115	10.927
σ_7	6.334	0.188	18.450
σ_8	10.862	0.225	22.736
σ_9	2.168	0.108	10.770
σ_{10}	22.972	0.386	33.918

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:





(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{10}$

Figura 72: Funciones a posteriori Estimación Datos reales II, Stan.

(a) Funciones a posteriori de $\sigma_0, \dots, \sigma_5$ (b) Funciones a posteriori de $\sigma_5, \dots, \sigma_{10}$ Figura 73: Funciones a posteriori σ^2 Estimación Datos reales II, Stan.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.





(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{10}$

Figura 74: Funciones de autocorrelación Estimación Datos reales II, Stan.

(a) Funciones autocorrelación de $\sigma_0, \dots, \sigma_5$ (b) Funciones autocorrelación de $\sigma_5, \dots, \sigma_{10}$ Figura 75: Funciones de autocorrelación σ^2 Estimación Datos reales V, Stan.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones.

La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 79: Tamaño Efectivo Estimación II Datos Reales, Jags.

=	β_0	β_1	β_2	β_3	β_4	β_5	β_6	β_7	β_8	β_9	β_{10}
	7599.62	663.80	13568.01	11886.29	14566.65	11564.26	8175.49	11505.01	9094.18	5601.07	12209.29

Tabla 80: Tamaño Efectivo Estimación II Datos Reales, Stan.

=	σ_0	σ_1	σ_2	σ_3	σ_4	σ_5	σ_6	σ_7	σ_8	σ_9	σ_{10}	lp_
	13653.56	1103.85	11625.17	9069.67	7036.54	1560.16	9063.58	9590.04	10195.02	9988.14	8812.20	2024.41

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 81: Tiempo Estimación II, Stan.

=	user	system	elapsed
	25210.66	1.44	25298.20

Lo cual dice que el proceso demoró 25298 segundos en total.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 76: Curva ROC modelo para Estimación Datos reales II, Stan

Donde se puede apreciar que el mejor punto de corte es de un 0,5 dando así un un AUC igual 0,805 , por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15738}{16523} = 0,95$
- Especificidad $\frac{1500}{2279} = 0,67$

Además el modelo es capaz de clasificar correctamente en un 91 % ($\frac{15738+1500}{18802} = \frac{17238}{18802} = 0,91$).

3.3.4.3. Estimación III: Eliminación de variables, una cadena, sin salto, sin outliers y distribución Gamma Inversa.

Este modelo se ejecutó solo una vez con una cadena, sin las variables “A.1.1” y “A.1.2”, al igual que en la estimación anterior, por lo tanto esto es que contiene solamente 10 variables

predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior (valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas. Además de esto, en este caso las varianzas de los betas estimados siguen una distribución gamma inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim \text{InvGamma}(0,01; 0,01)$.

Parámetros III

Los parámetros obtenidos con la simulación son los siguientes:

Tabla 82: Parámetros Estimación Datos reales III, Stan

Parámetros	Media	se_mean	SD
β_0	-28.366	8.211	13.039
β_1	-1569.732	604.967	960.598
β_2	-2.849	0.001	0.151
β_3	0.782	0.000	0.043
β_4	-0.439	0.004	0.048
β_5	-0.212	0.011	0.052
β_6	0.339	0.011	0.103
β_7	0.818	0.014	0.063
β_8	-1.573	0.001	0.056
β_9	-0.308	0.001	0.104
β_{10}	-3.304	0.032	0.211
σ_0	2.090e+07	1.501e+07	1.36e+09
σ_1	2.765e+10	1.042e+10	1.146e+12
σ_2	3784563	3698416	4.832e+08
σ_3	10634.840	7804.359	1.056e+06
σ_4	14617.190	10666.48	1.416e+06
σ_5	1192.847	982.78300	9.434e+04
σ_6	10940.220	6992.187	7.318e+05
σ_7	6065.761	4001.774	3.896e+05
σ_8	21012.140	8653.378	9.586e+05
σ_9	6384.867	4527.063	6.052e+05
σ_{10}	106667000	1.065738e+08	1.39e+10

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:





(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{10}$

Figura 77: Funciones a posteriori Estimación Datos reales III, Stan.

(a) Funciones a posteriori de $\sigma_0, \dots, \sigma_5$ (b) Funciones a posteriori de $\sigma_5, \dots, \sigma_{10}$ Figura 78: Funciones a posteriori σ^2 Estimación Datos reales III, Stan.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.





(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{10}$

Figura 79: Funciones de autocorrelación Estimación Datos reales III, Stan.

(a) Funciones autocorrelación de $\sigma_0, \dots, \sigma_5$ (b) Funciones autocorrelación de $\sigma_5, \dots, \sigma_{10}$ Figura 80: Funciones de autocorrelación σ^2 Estimación Datos reales III, Stan.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones. La cantidad de observaciones independientes para asegurar la convergencia de cada parámetro o los tamaños efectivos son:

Tabla 83: Tamaño Efectivo Estimación III Datos Reales, Stan.

=	β_0	β_1	β_2	β_3	β_4	β_5	β_6	β_7	β_8	β_9	β_{10}
	0.99	0.94	18402.98	18287.88	2344.58	340.53	1985.30	261.21	7830.12	19397.79	899.25

Tabla 84: Tamaño Efectivo Estimación III Datos Reales, Stan.

=	σ_0	σ_1	σ_2	σ_3	σ_4	σ_5	σ_6	σ_7	σ_8	σ_9	σ_{10}	lp_
	8270.85	12000.95	17244.47	18404.83	17600.63	9175.37	10715.56	9576.54	12172.34	18049.89	17070.69	6.041

Además, la cantidad de tiempo, en segundos, utilizado para esta estimación es:

Tabla 85: Tiempo Estimación III, Stan.

=	user	system	elapsed
	39340.88	2.86	39522.27

Lo cual dice que el proceso demoró 39522 segundos en total.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 81: Curva ROC modelo para Estimación Datos reales III, Stan

Donde se puede apreciar que el mejor punto de corte es de un 0,5 dando así un un AUC igual 0,742 , por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15738}{16523} = 0,95$
- Especificidad $\frac{1500}{2279} = 0,67$

Además el modelo es capaz de clasificar correctamente en un 92 % ($\frac{15738+1500}{18802} = \frac{17238}{18802} = 0,92$).

3.3.5. Resumen

A continuación se presentan una tabla comparativa para cada librería cual se resumen las métricas y los supuestos de las estimaciones:

- ☒ indica que menos de 3 parámetros cumplen el supuesto.
- ☐ indica que 3 o más parámetros no cumplen el supuesto.

Además se define lo siguiente como:

- Est I: Estimación I (Eliminación de variables, una cadena, sin salto y sin outliers).
- Est II: Estimación II (Eliminación de variables, una cadena, sin salto ,sin outliers y distribución Gamma).
- Est III: Estimación III (Eliminación de variables, una cadena, sin salto ,sin outliers y distribución Gamma Inversa).

Tabla 86: Tabla Resumen Datos Reales JAGS

JAGS	AUC	Sens.	Espe.	Acur.	Estaci.	Media converge	Autocorr.	Tiempo	Tamaño Min.
Est I	0.806	0.95	0.66	0.92	☐	☐	☐	12431	6539
Est II	0.629	0.47	0.21	0.51	☒	☒	☐	62099	6539
Est III	0.805	0.95	0.65	0.92	☒	☒	☒	18922	5846

Tabla 87: Tabla Resumen Datos Reales Stan

STAN	AUC	Sens.	Espe.	Acur.	Estaci.	Media converge	Autocorr.	Tiempo	Tamaño Min.
Est I	0.814	0.95	0.67	0.92	☒	☒	☒	13176	13152
Est II	0.805	0.95	0.67	0.91	☒	☒	☒	25298	13653
Est III	0.742	0.95	0.67	0.92	☒	☒	☒	39522	19397

Por lo que lo se decide la mejor estimación es la tercera, la cual se ejecutó solo una vez con una cadena, sin las variables “A.1.1” y “A.1.2”, al igual que en la estimación anterior, por lo tanto esto es que contiene solamente 10 variables predictoras y manteniéndose la eliminación de outliers definido en la estimación anterior(valores mayores o iguales a 20), por lo que solo se cuenta con 18802 observaciones y se ejecuta sin saltos entre las cadenas. Además de esto, en este caso las varianzas de los betas estimados siguen una distribución gamma inversa con parámetros 0,01 y 0,01 o bien $\sigma_{\beta_j}^2 \sim InvGamma(0,01; 0,01)$ en la librería JAGS.

Capítulo 4

Estimación Modelo Logístico con Componentes de Tiempo

En este capítulo se define y propone el modelo logístico a utilizar como el siguiente:

$$Y_i|P_{it} \sim Ber(P_{it}) \quad (1)$$

$$Logit(P_{it}) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_t + \epsilon_{it} + Z_{it} \quad (2)$$

esto es, un modelo logístico clásico al que se le incorporaron componentes de tiempo ,de manera tal tal que las a priori consideradas para esto son,

$$\beta_j \sim N(0, \sigma_{\beta_j}^2)$$

$$\epsilon_{it} \sim N(0, \sigma_{\epsilon_{it}}^2)$$

$$\phi_i \sim U(-1, 1)$$

$$\frac{1}{\sigma_{\beta_j}^2} \sim Gamma(0,1, 0,1)$$

La idea es en un siguiente paso analizar este modelo, el cual se definió con los cambios estudiados anteriormente y poder implementarlo.

Capítulo 5

Conclusiones

- En primera instancia, se recomienda utilizar variables que no estén muy correlacionadas entre ellas para que los parámetros converjan.
- Se recomienda la eliminación de outliers de las variables que se utilizan para la simulación y que podrían afectar en si la simulación de las cadena y así mismo en la convergencia de estas.
- Se recomiendan estimaciones en las que las varianzas no sean con valores fijos, la simulación se realiza igualmente de ambas maneras, tanto fijas como en varianzas con distribución, pero a diferencia de la simulación con varianzas fijas, al darle una distribución a las varianzas es más fácil que estas se puedan mover en un rango, lo cual se podría simular dando valores grande a los varianzas con un valor fijo.
- Se obtuvo que el mejor modelo para las simulaciones definidas contiene las varianzas de los parámetros estimados con distribución Gamma Inversa con parámetros(0,01;0,01)
- En temas computacionales, al realizarse los mismos modelos tanto en la librería Stan como en Jags, estas se pudieron comparar en los tiempos de ejecución de estas. Se pudo concluir, que la librería Stan es más eficiente a la hora de ejecutar, esto se concluye ya que se obtienen mejores estimaciones y un mucho menor tiempo de ejecución.
- Ambas librerías tienen distintas maneras de programar y definir los procesos, y personalmente es más cómodo trabajar con la librería Stan.
- Se plantea el analizar el modelo propuesto con los componentes de tiempo para ver si estos pueden o no converger.

Referencias Bibliográficas

- [1] MORETTIN,P.A. y TOLOI,C.M.C.(2018) , «*Análise de Séries Temporais*», Universidad de California , Berkley .
- [2] MARIO ENRIQUE RENDÓN-MACÍAS, ALBERTO RIOJAS-GARZA,DANIELA CONTRERAS-ESTRADA y JOSÉ DARÍO MARTÍNEZ-EZQUERRO(2018), «*Bayesian analysis. Basic and practical concepts for its interpretation and use*», Revista alergia México versión On-line ISSN 2448-9190.
URL: <https://revistaalergia.mx/ojs/index.php/ram/article/view/512>.
- [3] DEGROOT, M.H, y SCHERVISH(2012) , «*Probability and Statistics*» ,4ta Edición, Carnegie Mellon University .
- [4] JUAN CARLOS CORREA MORALES y CARLOS JAVIER BARRERA CAUSIL(2018) ,«*Introducción a la Estadística Bayesiana*, 1ra Edición, Instituto Tecnológico Metropolitano, Colombia.
- [5] »SALVADOR PADILLA(2020), “ *Modelos Logit y Probit* ”, URL:<https://economipedia.com>.
- [6] »S. EYHERAMENDY, F. ELORRIETA Y W. PALMA(2018), “An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves”, <https://academic.oup.com/mnras/article/481/4/4311/5094606#122173275>.
- [7] »HANEN BORCHANI(2012), “Multi-dimensional classification using Bayesian networks for stationary and evolving streaming data”, Universidad Politécnica de Madrid (España).
- [8] »FELIPE ELORRIETA, SUSANA EYHERAMENDY, ANDRÉS JORDÁN, ISTVÁN DÉKÁNY, MÁRCIO CATELAN, RODOLFO ANGELONI, JAVIER ALONSO-GARCÍA, RODRIGO CONTRERAS-RAMOS, FELIPE GRAN, GERGELY HAJDU, NÉSTOR ESPINOZA, ROBERTO K. SAITO y DANTE MINNITI(2016), “A Machine Learned Classifier for RR Lyrae in the VVV Survey”, *Astronomy & Astrophysics manuscript no. 28700*.
- [9] »P. SÁNCHEZ-SÁEZ, I. REYES, C. VALENZUELA, F. FÖRSTER, S. EYHERAMENDY, F. ELORRIETA, F. E. BAUER, G. CABRERA-VIVES, P. A. ESTÉVEZ, M. CATELAN, G. PIGNATA, P. HUIJSE, D. DE CICCO, P. ARÉVALO, R. CARRASCO-DAVIS, J. ABRIL, R. KURTEV, J. BORISSOVA, J. ARREDONDO,E. CASTILLO-NAVARRETE, D. RODRIGUEZ, D. RUZ-MIERES, A. MOYA, L. SABATINI-GACITÚA, C. SEPÚLVEDA-COBO y E. CAMACHO-IÑIGUEZ(2021), “Alert Classification for the ALeRCE Broker System: The Light Curve Classifier”, *The Astronomical Journal*, 161:141 (31pp).
- [10] »GANG CHEN(2016), “A gentle tutorial of recurrent neural network with error backpropagation”, *arXiv preprint arXiv:1610.02583*.
- [11] »ISIS BONET CRUZ, SAIN SALAZAR MARTINEZ, ABDEL RODRIGUEZ ABED, GRAU ABALO(2007) y MARIA M. GARCIA LORENZO , “Recurrent neural network for sequences analysis”, *REV/STA CUBANA DE CIENC/AS /NFORMA'TICAS*.
- [12] »[HTTPS://CRAN.R-PROJECT.ORG/WEB/PACKAGES/RJAGS/RJAGS.PDF](https://cran.r-project.org/web/packages/rjags/rjags.pdf), “Reference manual Rjags”

- [13] »[HTTPS://MCMC-JAGS.SOURCEFORGE.IO](https://mcmc-jags.sourceforge.io), “Rjags Page”
- [14] »[HTTPS://MC-STAN.ORG/](https://mc-stan.org/), “Stan”.
- [15] »CONCHI AUSÍN(2012), “Apuntes: Métodos de cadenas de Markov Monte Carlo”, Universidad Carlos III de Madrid.
- [16] »[HTTPS://WWW.PUBLICHEALTH.COLUMBIA.EDU/RESEARCH/POPULATION-HEALTH-METHODS/MARKOV-CHAIN-MONTE-CARLO](https://www.publichealth.columbia.edu/research/population-health-methods/markov-chain-monte-carlo), “Markov Chain Monte Carlo”, Columbia.
- [17] »[HTTPS://BIBLUS.US.ES/BIBING/PROYECTOS/ABREPROY/10930/FICHERO/VOLUMEN1%252Fcapitulo10.PDF](https://biblus.us.es/bibing/proyectos/abreproy/10930/fichero/volumen1%252Fcapitulo10.pdf), Universidad pública en Sevilla, España.
- [18] »MARIO BERAHA1, DANIELE FALCO y ALESSANDRA GUGLIELMI (2021), “JAGS, NIMBLE, Stan: a detailed comparison among Bayesian MCMC software”, *Department of Mathematics, Politecnico di Milano y Department of Computer Science, Universit'a di Bologna*.

Anexos

Anexo 1

Apéndice 1: Resultados Datos Simulados

1.1. Estimación con Datos Simulados, JAGS

1.1.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas.

1.1.1.1. Intervalos Parámetros Iniciales

Tabla 1: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	0.935	1.076
β_1	1.871	2.064
β_2	2.907	3.155

Tabla 2: Intervalo de más alta prob. cadena 1

Parámetros	Lower	Upper
β_0	0.934	1.073
β_1	1.875	2.069
β_2	2.904	3.149

Tabla 3: Intervalo de más alta prob. cadena 2

Parámetros	Lower	Upper
β_0	0.936	1.077
β_1	1.865	2.056
β_2	2.900	3.149

1.1.1.2. Tabla Sensibilidad y Especificidad

Tabla 4: Sensibilidad y Especificidad Datos Simulados JAGS

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	3084	935	4019
Y=1	967	5014	5981
	4051	5949	10000




Figura 1: Esquema Observados v/s Predichos

1.1.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma.

1.1.2.1. Intervalos Parámetros Iniciales

Tabla 5: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	0.932	1.076
β_1	1.87	2.061
β_2	2.898	3.155
σ_0^2	0.195	53.504
σ_1^2	0.678	72.145
σ_2^2	1.623	116.464

Tabla 6: Intervalo de más alta prob. cadena 1

Parámetros	Lower	Upper
β_0	0.931	1.074
β_1	1.868	2.057
β_2	2.896	3.152
σ_0^2	0.059	32.508
σ_1^2	0.267	56.137
σ_2^2	0.618	94.882

Tabla 7: Intervalo de más alta prob. cadena 2

Parámetros	Lower	Upper
β_0	0.935	1.078
β_1	1.869	2.061
β_2	2.901	3.157
σ_0^2	0.061	34.339
σ_1^2	0.309	40.268
σ_2^2	0.571	72.011

1.1.2.2. Tabla Sensibilidad y Especificidad

Tabla 8: Sensibilidad y Especificidad Datos Simulados JAGS

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	3084	935	4019
Y=1	967	5014	5981
	4051	5949	10000

lo cual también se puede ver representado en el siguiente esquema,




Figura 2: Esquema Observados v/s Predichos

1.1.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma Inversa.

1.1.3.1. Intervalos Parámetros Iniciales

Tabla 9: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	0.931	1.076
β_1	1.87	2.061
β_2	2.901	3.154
σ_0^2	0.001	5.001
σ_1^2	0.0003	1.293
σ_2^2	0.0001	0.557

Tabla 10: Intervalo de más alta prob. cadena 1

Parámetros	Lower	Upper
β_0	0.932	1.075
β_1	1.868	2.061
β_2	2.902	3.155
σ_0^2	8.752e-09	3.877
σ_1^2	4.988e-12	1.005
σ_2^2	1.042e-08	0.425

Tabla 11: Intervalo de más alta prob. cadena 2

Parámetros	Lower	Upper
β_0	0.93	1.076
β_1	1.867	2.058
β_2	2.898	3.15
σ_0^2	2.587e-08	3.808
σ_1^2	1.552e-09	0.991
σ_2^2	4.439e-10	0.416

1.1.3.2. Tabla Sensibilidad y Especificidad

Tabla 12: Sensibilidad y Especificidad Datos Simulados JAGS

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	2904	1115	4019
Y=1	1262	4719	5981
	4166	5834	10000

lo cual también se puede ver representado en el siguiente esquema,




Figura 3: Esquema Observados v/s Predichos

1.2. Estimación con Datos Simulados, Stan

1.2.1. Estimación I: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas fijas.

1.2.1.1. Intervalos Parámetros Iniciales

Tabla 13: Intervalo de colas iguales

Parámetros	0.025	0.975
β_0	0.933	1.076
β_1	1.871	2.063
β_2	2.904	3.156

Tabla 14: Intervalo más alta prob. Cadena 1

Parámetros	lower	upper
β_0	0.934	1.074
β_1	1.873	2.066
β_2	2.907	3.156

Tabla 15: Intervalo más alta prob. Cadena 2

Parámetros	lower	upper
β_0	0.934	1.078
β_1	1.868	2.060
β_2	2.901	3.154

1.2.1.2. Tabla Sensibilidad y Especificidad

Tabla 16: Sensibilidad y Especificidad Datos Simulados STAN

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	2057	1962	4019
Y=1	840	5141	5981
	2897	7103	10000

lo cual también se puede ver representado en el siguiente esquema,




Figura 4: Esquema Observados v/s Predichos

1.2.2. Estimación II: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma.

1.2.2.1. Intervalos Parámetros Iniciales

Tabla 17: Intervalo de colas iguales

Parámetros	0.025	0.975
β_0	0.930	1.074
β_1	1.866	2.059
β_2	2.899	3.151
σ_0^2	0.194	51.642
σ_1^2	0.695	87.506
σ_2^2	1.577	113.775

Tabla 18: Intervalo más alta prob. Cadena 1

Parámetros	lower	upper
β_0	0.929	1.071
β_1	1.864	2.054
β_2	2.897	3.147
σ_0^2	0.048	32.002
σ_1^2	0.231	59.654
σ_2^2	0.571	83.692

Tabla 19: Intervalo más alta prob. Cadena 2

Parámetros	lower	upper
β_0	0.932	1.075
β_1	1.867	2.063
β_2	2.903	3.154
σ_0^2	0.063	29.87
σ_1^2	0.259	55.951
σ_2^2	0.675	80.272

1.2.2.2. Tabla Sensibilidad y Especificidad

Tabla 20: Sensibilidad y Especificidad Datos Simulados Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	3057	962	4019
Y=1	969	5012	5974
	4026	5974	10000

lo cual también se puede ver representado en el siguiente esquema,




Figura 5: Esquema Observados v/s Predichos

1.2.3. Estimación III: Todas las variables y observaciones simuladas, dos cadenas, sin saltos y varianzas distribuyen Gamma Inversa.

1.2.3.1. Intervalos Parámetros Iniciales

Tabla 21: Intervalo de colas iguales

Parámetros	0.025	0.975
β_0	0.931	1.075
β_1	1.869	2.062
β_2	2.9	3.157
σ_0^2	0.201	1046.549
σ_1^2	0.738	3409.337
σ_2^2	1.819	7739.986

Tabla 22: Intervalo más alta prob. Cadena 1

Parámetros	lower	upper
β_0	0.93	1.073
β_1	1.871	2.059
β_2	2.902	3.16
σ_0^2	0.076	226.737
σ_1^2	0.289	898.298
σ_2^2	0.685	1674.851

Tabla 23: Intervalo más alta prob. Cadena 2

Parámetros	lower	upper
β_0	0.929	1.073
β_1	1.863	2.06
β_2	2.891	3.151
σ_0^2	0.063	268.655
σ_1^2	0.305	694.459
σ_2^2	0.354	2174.831

1.2.3.2. Tabla Sensibilidad y Especificidad

Tabla 24: Sensibilidad y Especificidad Datos Simulados Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	3089	930	4019
Y=1	919	5062	5981
	4008	5992	10000

lo cual también se puede ver representado en el siguiente esquema,




Figura 6: Esquema Observados v/s Predichos

Anexo 2

Apéndice 2: Resultados Datos Reales

2.1. Correlaciones




Figura 1: Correlaciones de los Datos Reales.




Figura 2: Correlaciones de los Datos Reales.

2.2. Modelo GLM

Se estiman los parámetros a través de un modelo logístico de la teoría clásica con glm

2.2.1. Parámetros

```
Call:
glm(formula = data1$rr1 ~ ., family = "binomial", data = data1)

Coefficients:
            Estimate Std. Error      z value Pr(>|z|)
(Intercept) -2.189e+15  4.893e+05 -4.473e+09 <2e-16 ***
A.1.1.       4.399e+14  2.705e+06  1.627e+08 <2e-16 ***
A.1.2.      -2.836e+14  1.868e+06 -1.518e+08 <2e-16 ***
A.1.3.      -1.175e+14  1.323e+06 -8.883e+07 <2e-16 ***
PH.1.2.     -9.371e+14  5.404e+05 -1.734e+09 <2e-16 ***
PH.1.3.       8.721e+13  4.969e+05  1.755e+08 <2e-16 ***
PH.1.4.     -1.893e+14  4.988e+05 -3.795e+08 <2e-16 ***
f1           -5.122e+13  5.045e+05 -1.015e+08 <2e-16 ***
P1           -6.250e+13  7.905e+05 -7.906e+07 <2e-16 ***
s             2.418e+14  5.705e+05  4.238e+08 <2e-16 ***
p2p_s2p      -4.104e+14  5.765e+05 -7.118e+08 <2e-16 ***
p2p_spfom    -2.293e+14  7.689e+05 -2.983e+08 <2e-16 ***
R1           -2.469e+14  5.202e+05 -4.746e+08 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 13890  on 18808  degrees of freedom
Residual deviance: 128892  on 18796  degrees of freedom
AIC: 128918

Number of Fisher Scoring iterations: 25
```

Figura 3: Modelo de Teoría clásica.

Se puede apreciar que todas las variables utilizadas en el modelo son significativas pero que al mismo tiempo el modelo no converge de manera efectiva.

2.2.2. Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 4: Curva ROC modelo GLM para Datos Reales

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,619 , lo cual entrega lo siguiente:

Tabla 1: Sensibilidad y Especificidad glm

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	16470	60	16530
Y=1	1728	551	2279
	18198	611	18809

lo cual también se puede ver representado en el siguiente esquema,




Figura 5: Esquema Observados v/s Predichos

por lo que los valores de sensibilidad y especificidad son 0,99 y 0,24 respectivamente.

2.3. Estimación Analítica

2.3.1. JAGS

2.3.1.1. Estimación Analítica I: Todas las variables, todas las observaciones, una cadena y sin salto

Este modelo se ejecutó solo una vez (una cadena), con un número de 18809 iteraciones para las 13 variables predictoras, la cual corresponde a la cantidad de datos reales con los que se está trabajando, sin ningún salto entre las observaciones, estimándose así las funciones a posteriori de los parámetros.

Parámetros I

Los parámetros obtenidos con la simulación son los siguientes

Tabla 2: Parámetros Estimación Analítica Datos reales I, JAGS

Parámetros	Media	SD	Naive SE
β_0	-17.565	4.701	0.034
β_1	38.759	74.956	0.547
β_2	-105.435	41.939	0.306
β_3	-647.222	397.153	2.896
β_4	-2.85	0.159	0.001
β_5	0.786	0.043	0.0003
β_6	-0.437	0.046	0.0003
β_7	-0.205	0.049	0.0003
β_8	0.362	0.097	0.0007
β_9	0.84	0.059	0.0004
β_{10}	-1.569	0.056	0.0004
β_{11}	-0.305	0.101	0.0007
β_{12}	-3.266	0.205	0.001

Tabla 3: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-25.614	-9.504
β_1	-60.827	220.166
β_2	-187.696	-39.446
β_3	-1358.769	-37.24
β_4	-3.165	-2.54
β_5	0.705	0.872
β_6	-0.529	-0.346
β_7	-0.300	-0.108
β_8	0.173	0.561
β_9	0.724	0.953
β_{10}	-1.679	-1.461
β_{11}	-0.503	-0.105
β_{12}	-3.67	-2.863

Tabla 4: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-24.946	-9.202
β_1	-58.069	222.572
β_2	-189.187	-41.316
β_3	-1242.912	-7.411
β_4	-3.175	-2.549
β_5	0.703	0.87
β_6	-0.527	-0.345
β_7	-0.301	-0.109
β_8	0.17	0.557
β_9	0.726	0.955
β_{10}	-1.677	-1.46
β_{11}	-0.508	-0.112
β_{12}	-3.659	-2.854

Análisis de convergencia

Como se especificó en el capítulo 2.3.7.1, no existe un método en específico para comprobar si existe o no una convergencia, pero en este caso se utilizarán los criterios ya mencionados para analizar una posible convergencia aproximada a la posterior.




(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{11}$ (c) Funciones a posteriori de β_{12}

Figura 6: Funciones a posteriori Estimación Analítica Datos reales I, JAGS.

De lo anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.




(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_5, \dots, \beta_{11}$ (c) Funciones autocorrelación de β_{12}

Figura 7: Funciones de autocorrelación Estimación Analítica Datos reales I, JAGS.

Se puede observar que para algunos betas existe una baja autocorrelación (β_5, β_6 y β_7) y que para los demás existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones. Por lo que se decide quemar las primeras 5000 iteraciones y almacenar con un salto en el período 45.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 8: Curva ROC modelo para Estimación Analítica Datos reales I, JAGS

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,807, lo cual entrega lo siguiente:

Tabla 5: Sensibilidad y Especificidad Datos Reales Estimación Analítica I

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	15750	777	16527
Y=1	772	1507	2279
	16522	2284	18806

lo cual también se puede ver representado en el siguiente esquema,




Figura 9: Esquema Observados v/s Predichos Estimación Analítica Datos reales I, JAGS

por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15750}{16527} = 0,95$
- Especificidad $\frac{4993}{5981} = 0,66$

Además el modelo es capaz de clasificar correctamente en un 91 % ($\frac{15750+1507}{18806} = \frac{17257}{18806} = 0,91$).

2.3.1.2. Estimación Analítica II: Todas las variables, una cadena, sin salto y sin outliers

Este modelo se ejecutó solo una vez con una cadena, con las 12 variables predictoras, con un número de 18806, se eliminaron 3 observaciones consideradas outliers tomando como referencia los valores mayor o igual a 40 en las variables “A.1.1”, “A.1.2” y “A.1.3.” y sin ningún salto entre los valores generados.

Parámetros II

Los parámetros obtenidos con la simulación son los siguientes

Tabla 6: Parámetros Estimación Analítica Datos reales II, JAGS

Parámetros	Media	SD	Naive SE
β_0	-16.946	3.908	0.029
β_1	179.121	97.638	0.712
β_2	-220.976	121.204	0.884
β_3	-637.922	229.789	1.676
β_4	-2.849	0.154	0.001
β_5	0.787	0.043	0.0003
β_6	-0.436	0.047	0.0003
β_7	-0.206	0.049	0.0003
β_8	0.356	0.094	0.0007
β_9	0.838	0.057	0.0004
β_{10}	-1.568	0.055	0.0004
β_{11}	-0.311	0.098	0.0007
β_{12}	-3.268	0.207	0.002

Tabla 7: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-23.157	-9.225
β_1	-3.866	305.866
β_2	-354.515	3.019
β_3	-997.984	-106.592
β_4	-3.143	-2.551
β_5	0.704	0.872
β_6	-0.527	-0.345
β_7	-0.301	-0.109
β_8	0.168	0.542
β_9	0.727	0.952
β_{10}	-1.675	-1.462
β_{11}	-0.505	-0.121
β_{12}	-3.680	-2.864

Tabla 8: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-24.946	-9.202
β_1	-58.069	222.572
β_2	-189.187	-41.316
β_3	-1242.912	-7.411
β_4	-3.175	-2.549
β_5	0.703	0.87
β_6	-0.527	-0.345
β_7	-0.301	-0.109
β_8	0.17	0.557
β_9	0.726	0.955
β_{10}	-1.677	-1.46
β_{11}	-0.508	-0.112
β_{12}	-3.659	-2.854

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:




(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_6, \dots, \beta_{11}$ (c) Funciones a posteriori de β_{12}

Figura 10: Funciones a posteriori Estimación Analítica Datos reales II, JAGS.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.




(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_5, \dots, \beta_{11}$ (c) Funciones autocorrelación de β_{12}

Figura 11: Funciones de autocorrelación Estimación Analítica Datos reales II, JAGS.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 12: Curva ROC modelo para Estimación Analítica Datos reales II, JAGS

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,807, lo cual entrega lo siguiente:

Tabla 9: Sensibilidad y Especificidad Datos Reales Estimación Analítica II

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	15750	777	16527
Y=1	772	1507	2279
	16522	2284	18806

lo cual también se puede ver representado en el siguiente esquema,




Figura 13: Esquema Observados v/s Predichos Estimación Datos reales II, JAGS

por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15750}{16527} = 0,95$
- Especificidad $\frac{4993}{5981} = 0,66$

Además el modelo es capaz de clasificar correctamente en un 91 % ($\frac{15750+1507}{18806} = \frac{17257}{18806} = 0,91$).

2.3.1.3. Estimación Analítica III: Todas las variables, una cadena, sin salto y sin outliers

Este modelo se ejecutó solo una vez con una cadena, con las 12 variables predictoras, con un número de 18802, se eliminaron 7 observaciones consideradas outliers tomando como referencia los valores mayor o igual a 20 en las variables “A.1.1”, “A.1.2” y “A.1.3.” y sin ningún salto entre los valores generados.

Parámetros III

Los parámetros estimados iniciales para el modelo son:

Tabla 10: Parámetros Estimación Analítica Datos reales III, JAGS

Parámetros	Media	SD	Naive SE
β_0	-22.665	6.963	0.051
β_1	148.993	131.252	0.957
β_2	-183.065	108.628	0.792
β_3	-1074.276	449.024	3.275
β_4	-2.868	0.153	0.001
β_5	0.785	0.042	0.0003
β_6	-0.441	0.047	0.0003
β_7	-0.214	0.049	0.0004
β_8	0.354	0.099	0.0007
β_9	0.83	0.058	0.0004
β_{10}	-1.571	0.055	0.0004
β_{11}	-0.308	0.103	0.0007
β_{12}	-3.294	0.199	0.001

Tabla 11: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-33.868	-10.062
β_1	-30.4511	378.208
β_2	-380.812	-20.907
β_3	-1857.146	-230.46
β_4	-3.178	-2.57
β_5	0.703	0.87
β_6	-0.532	-0.35
β_7	-0.31	-0.119
β_8	0.155	0.544
β_9	0.717	0.946
β_{10}	-1.679	-1.463
β_{11}	-0.512	-0.109
β_{12}	-3.698	-2.908

Tabla 12: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-24.946	-9.202
β_1	-58.069	222.572
β_2	-189.187	-41.316
β_3	-1242.912	-7.411
β_4	-3.175	-2.549
β_5	0.703	0.87
β_6	-0.527	-0.345
β_7	-0.301	-0.109
β_8	0.17	0.557
β_9	0.726	0.955
β_{10}	-1.677	-1.46
β_{11}	-0.508	-0.112
β_{12}	-3.659	-2.854

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:




(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_6, \dots, \beta_{11}$ (c) Funciones a posteriori de β_{12}

Figura 14: Funciones a posteriori Estimación Analítica Datos reales III, JAGS.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.




(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_5, \dots, \beta_{11}$ (c) Funciones autocorrelación de β_{12}

Figura 15: Funciones de autocorrelación Estimación Analítica Datos reales III, JAGS.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 16: Curva ROC modelo para Estimación Analítica Datos reales III, JAGS

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,808, lo cual entrega lo siguiente:

Tabla 13: Sensibilidad y Especificidad Datos Reales Estimación Analítica III

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
$Y=0$	15765	767	16523
$Y=1$	768	1511	2279
	16524	2278	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 17: Esquema Observados v/s Predichos Estimación Analítica Datos reales III, JAGS

por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15765}{16523} = 0,95$
- Especificidad $\frac{1511}{2279} = 0,66$

Además el modelo es capaz de clasificar correctamente en un 91 % ($\frac{15765+1511}{18802} = \frac{17276}{18802} = 0,91$).

2.3.2. STAN

2.3.2.1. Estimación Analítica I: Todas las variables, una cadena, todas las observaciones y sin salto

Este modelo se ejecutó solo una vez (una cadena), con un número de 18809 iteraciones para las 13 variables predictoras, la cual corresponde a la cantidad de datos reales con los que se está trabajando, sin ningún salto entre las observaciones, estimándose así las funciones a posteriori de los parámetros.

Parámetros I

Los parámetros obtenidos con la simulación son los siguientes

Tabla 15: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-190.013	-23.628
β_1	-803.971	219.657
β_2	-5237.987	-395.159
β_3	-3112.008	-141.980
β_4	-3.181	-2.565
β_5	0.698	0.867
β_6	-0.557	-0.370
β_7	-0.357	-0.154
β_8	0.101	0.496
β_9	0.665	0.906
β_{10}	-1.693	-1.476
β_{11}	-0.524	-0.128
β_{12}	-3.854	-3.007

Tabla 16: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-190.140	-23.762
β_1	-804.993	217.260
β_2	-5238.116	-394.989
β_3	-3198.757	-395.739
β_4	-3.158	-2.547
β_5	0.697	0.865
β_6	-0.559	-0.373
β_7	-0.356	-0.154
β_8	0.105	0.5
β_9	0.659	0.898
β_{10}	-1.694	-1.477
β_{11}	-0.524	-0.129
β_{12}	-3.861	-3.018

Tabla 14: Parámetros Estimación Analítica Datos reales I, Stan

Parámetros	Media	se_mean	SD
β_0	-120.014	26.821	45.376
β_1	-320.028	130.025	306.755
β_2	-3053.601	875.604	1402.639
β_3	-2122.597	438.714	768.682
β_4	-2.8655	0.001	0.157
β_5	0.780	0.000	0.043
β_6	-0.463	0.003	0.048
β_7	-0.256	0.008	0.052
β_8	0.297	0.010	0.100
β_9	0.783	0.007	0.061
β_{10}	-1.584	0.001	0.056
β_{11}	-0.323	0.001	0.101
β_{12}	-3.431	0.022	0.216

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:




(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{11}$ (c) Funciones a posteriori de β_{12}

Figura 18: Funciones a posteriori Estimación Analítica Datos reales I, Stan.

De lo anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante.




(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{11}$ (c) Funciones autocorrelación de β_{12}

Figura 19: Funciones de autocorrelación Estimación Analítica Datos reales I, Stan.

Se puede observar que para algunos betas existe una baja autocorrelación (β_5 , β_6 y β_7) y que para los demás existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones. Por lo que se decide quemar las primeras 5000 iteraciones y almacenar con un salto en el período 45.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 20: Curva ROC modelo para Estimación Analítica Datos reales I, Stan

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,74 , lo cual entrega lo siguiente:

Tabla 17: Sensibilidad y Especificidad Estimación Datos reales I, Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	8107	8423	16523
Y=1	22	2257	2279
	8129	10680	18809

lo cual también se puede ver representado en el siguiente esquema,




Figura 21: Esquema Observados v/s Predichos Estimación Datos reales I, Stan

por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{8107}{16523} = 0,49$
- Especificidad $\frac{22}{2279} = 0,99$

Además el modelo es capaz de clasificar correctamente en un 55 % ($\frac{8107+2257}{18809} = \frac{10364}{18809} = 0,55$).

2.3.2.2. Estimación Analítica II: Todas las variables, una cadena, sin salto y sin outliers.

Este modelo se ejecutó solo una vez con una cadena, con las 12 variables predictoras, con un número de 18806, se eliminaron 3 observaciones consideradas outliers tomando como referencia los valores mayor o igual a 40 en las variables “A.1.1”, “A.1.2” y “A.1.3.” y sin ningún salto entre los valores generados.

Parámetros II

Con las especificaciones obtenidas anteriormente se obtuvieron los siguientes parámetros con la simulación:

Tabla 18: Parámetros Estimación Analítica Datos reales II, Stan

Parámetros	Media	se_mean	SD
β_0	-120.014	26.821	45.376
β_1	-320.028	130.025	306.755
β_2	-3053.601	875.604	1402.639
β_3	-2122.597	438.714	768.682
β_4	-2.8655	0.001	0.157
β_5	0.780	0.000	0.043
β_6	-0.463	0.003	0.048
β_7	-0.256	0.008	0.052
β_8	0.297	0.010	0.100
β_9	0.783	0.007	0.061
β_{10}	-1.584	0.001	0.056
β_{11}	-0.323	0.001	0.101
β_{12}	-3.431	0.022	0.216

Tabla 19: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-190.013	-23.628
β_1	-803.971	219.657
β_2	-5237.987	-395.159
β_3	-3112.008	-141.980
β_4	-3.181	-2.565
β_5	0.698	0.867
β_6	-0.557	-0.370
β_7	-0.357	-0.154
β_8	0.101	0.496
β_9	0.665	0.906
β_{10}	-1.693	-1.476
β_{11}	-0.524	-0.128
β_{12}	-3.854	-3.007

Tabla 20: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-184.379	-43.454
β_1	-1446.886	-106.779
β_2	-4216.531	-917.734
β_3	-3617.156	-620.43
β_4	-3.191	-2.564
β_5	0.697	0.865
β_6	-0.558	-0.371
β_7	-0.360	-0.161
β_8	0.087	0.483
β_9	0.663	0.899
β_{10}	-1.694	-1.477
β_{11}	-0.529	-0.132
β_{12}	-3.866	-3.022

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:




(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{11}$ (c) Funciones a posteriori de β_{12}

Figura 22: Funciones a posteriori Estimación Analítica Datos reales II, Stan.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede

observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.




(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{11}$ (c) Funciones autocorrelación de β_{12}

Figura 23: Funciones de autocorrelación Estimación Analítica Datos reales II, Stan.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 24: Curva ROC modelo para Estimación Analítica Datos reales II, Stan

Donde se puede apreciar que el mejor punto de corte es de un 0,5 con un AUC igual 0,74 , lo cual entrega lo siguiente:

Tabla 21: Sensibilidad y Especificidad Estimación Analítica Datos reales II, Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	8106	8421	16527
Y=1	22	2257	2279
	8128	10678	18806

lo cual también se puede ver representado en el siguiente esquema,




Figura 25: Esquema Observados v/s Predichos Estimación Analítica Datos reales II, Stan

por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{8106}{16527} = 0,49$
- Especificidad $\frac{2257}{2279} = 0,99$

Además el modelo es capaz de clasificar correctamente en un 55 % ($\frac{8106+2257}{18806} = \frac{10364}{18809} = 0,55$).

2.3.2.3. Estimación Analítica III: Todas las variables, una cadena, sin salto y sin outliers, intento 2.

Parámetros III

Los parámetros obtenidos con la simulación son los siguientes

Tabla 22: Parámetros Estimación Analítica Datos reales III, Stan

Parámetros	Media	se_mean	SD
β_0	-104.746	23.551	40.018
β_1	-169.115	57.406	198.306
β_2	-2224.822	692.793	1162.008
β_3	-2793.250	464.758	875.288
β_4	-2.865	0.001	0.157
β_5	0.780	0.000	0.043
β_6	-0.463	0.003	0.047
β_7	-0.256	0.008	0.051
β_8	0.297	0.009	0.100
β_9	0.782	0.007	0.061
β_{10}	-1.584	0.00	0.056
β_{11}	-0.324	0.001	0.102
β_{12}	-3.430	0.022	0.213

Tabla 23: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-155.171	-24.588
β_1	-535.578	197.889
β_2	-3954.270	-162.120
β_3	-3755.633	-563.070
β_4	-3.175	-2.565
β_5	0.696	0.866
β_6	-0.554	-0.371
β_7	-0.354	-0.154
β_8	0.100	0.492
β_9	0.665	0.904
β_{10}	-1.695	-1.477
β_{11}	-0.523	-0.126
β_{12}	-3.856	-3.015

Tabla 24: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-156.880	-31.379
β_1	-529.044	204.031
β_2	-3974.652	-259.323
β_3	-3840.356	-1094.228
β_4	-3.181	-2.571
β_5	0.694	0.864
β_6	-0.553	-0.370
β_7	-0.355	-0.155
β_8	0.1	0.491
β_9	0.666	0.905
β_{10}	-1.692	-1.475
β_{11}	-0.524	-0.127
β_{12}	-3.859	-3.019

Análisis de Convergencia

Al analizar la convergencia se obtuvo que:



(a) Funciones a posteriori de $\beta_0, \dots, \beta_5$ (b) Funciones a posteriori de $\beta_5, \dots, \beta_{11}$ (c) Funciones a posteriori de β_{12}

Figura 26: Funciones a posteriori Estimación Analítica Datos reales III, Stan.

Se puede observar, al igual que en la estimación anterior, se ve que no existe gran estacionaridad en los datos para los betas $\beta_0, \beta_1, \beta_2$ y β_3 , en cambio, para los demás betas se puede observar una buena estacionaridad y media constante, por lo que se decide quemar desde la observación 5000 hacia atrás.




(a) Funciones autocorrelación de $\beta_0, \dots, \beta_5$ (b) Funciones autocorrelación de $\beta_6, \dots, \beta_{11}$ (c) Funciones autocorrelación de β_{12}

Figura 27: Funciones de autocorrelación Estimación Analítica Datos reales III, Stan.

Se puede observar que para algunos betas existe una baja autocorrelación y que para los demás ($\beta_0, \beta_1, \beta_2$ y β_3) existe una gran autocorrelación. A simple vista se decide realizar un salto en el lag 45 a la hora de almacenar las iteraciones.

Curva ROC y Análisis de Sensibilidad y Especificidad

Se analiza la calidad del modelo para predecir la variable respuesta para los betas estimados, esto a través de curva ROC y Análisis de Especificidad y Sensibilidad, para esto, en primera instancia se analiza la curva ROC:




Figura 28: Curva ROC modelo para Estimación Analítica Datos reales III, Stan

Donde se puede apreciar que el mejor punto de corte es de un 0,5 dando así un AUC igual 0,803, lo cual entrega lo siguiente:

Tabla 25: Sensibilidad y Especificidad Estimación Analítica Datos reales III, Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	15763	760	16523
Y=1	795	1484	2279
	16558	2244	18806

lo cual también se puede ver representado en el siguiente esquema,




Figura 29: Esquema Observados v/s Predichos Estimación Datos reales III, Stan

por lo que los valores de sensibilidad y especificidad son:

- Sensibilidad $\frac{15763}{16523} = 0,95$
- Especificidad $\frac{1484}{2279} = 0,65$

Además el modelo es capaz de clasificar correctamente en un 91 % ($\frac{15763+1484}{18802} = \frac{17247}{18802} = 0,91$).

2.3.3. Resumen

A continuación se presentan una tabla comparativa para cada librería cual se resumen las métricas y los supuestos de las estimaciones:

- ☒ indica que menos de 2 parámetros no cumplen el supuesto.
- ☒ indica que más de 3 parámetros no cumplen el supuesto.

	JAGS	AUC	Sens.	Espe.	Acur.	Estacionaridad	Media converge	Autocorr.
=	Est I	0.807	0.95	0.66	0.91	☒	☒	☒
	Est II	0.807	0.95	0.66	0.91	☒	☒	☒

	STAN	AUC	Sens.	Espe.	Acur.	Estacionaridad	Media converge	Autocorr.
=	Est I	0.740	0.49	0.99	0.55	☒	☒	☒
	Est II	0.740	0.49	0.99	0.55	☒	☒	☒

2.4. Estimación Datos Reales

2.4.1. JAGS

2.4.1.1. Estimación I: Todas las variables, todas las observaciones, una cadena y sin salto

2.4.1.1.1. Intervalos Parámetros

Tabla 26: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-25.080	-11.759
β_1	-1329.669	-337.79
β_2	-3.149	-2.56
β_3	0.7026	0.873
β_4	-0.53	-0.347
β_5	-0.302	-0.112
β_6	0.160	0.555
β_7	0.723	0.950
β_8	-1.677	-1.462
β_9	-0.506	-0.112
β_{10}	-3.68	-2.894

Tabla 27: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-25.137	-11.839
β_1	-1343.205	-354.958
β_2	-3.147	-2.559
β_3	0.700	0.87
β_4	-0.533	-0.350
β_5	-0.304	-0.114
β_6	0.159	0.553
β_7	0.726	0.953
β_8	-1.676	-1.461
β_9	-0.500	-0.108
β_{10}	-3.663	-2.881

2.4.1.1.2. Tabla Sensibilidad y Especificidad

Tabla 28: Sensibilidad y Especificidad Datos Reales Estimación I

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	15736	787	16523
Y=1	774	1505	2279
	16510	2292	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 30: Esquema Observados v/s Predichos Estimación Datos reales I, JAGS

2.4.1.2. Estimación II: Todas las variables, una cadena, sin salto y sin outliers

2.4.1.2.1. Intervalos Parámetros

Tabla 29: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-7.464	-6.740
β_1	-0.083	0.061
β_2	-3.160	-2.542
β_3	0.706	0.873
β_4	-0.52	-0.332
β_5	-0.264	-0.051
β_6	0.281	0.701
β_7	0.749	0.971
β_8	-1.681	-1.463
β_9	-0.364	3.104e-06
β_{10}	-3.694	-2.875
σ_0^2	5.177	38.96
σ_1^2	4.112e-57	0.036
σ_2^2	1.425	116.6
σ_3^2	0.116	24.07
σ_4^2	0.033	47.71
σ_5^2	0.002	4.674
σ_6^2	0.035	63.88
σ_7^2	0.143	71.95
σ_8^2	0.448	63.49
σ_9^2	1.466e-60	0.403
σ_{10}^2	1.839	12.25

Tabla 30: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-7.446	-6.723
β_1	-5.439	1.112
β_2	-3.142	-2.547
β_3	0.701	0.869
β_4	-0.51	-0.326
β_5	-0.267	-0.068
β_6	0.179	0.608
β_7	0.753	0.974
β_8	-1.672	-1.457
β_9	-0.519	-0.057
β_{10}	-3.597	-2.802
σ_0^2	3.639	148.552
σ_1^2	4.417e-05	40.347
σ_2^2	0.397	77.477
σ_3^2	0.040	25.684
σ_4^2	0.01	16.335
σ_5^2	6.767e-05	6.648
σ_6^2	6.916e-05	11.726
σ_7^2	0.042	28.023
σ_8^2	0.163	45.858
σ_9^2	5.878e-05	8.150
σ_{10}^2	0.421	80.681

2.4.1.2.2. Tabla Sensibilidad y Especificidad

Tabla 31: Sensibilidad y Especificidad Datos Reales Estimación II

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	7872	8651	16523
Y=1	498	1781	2279
	8370	10432	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 31: Esquema Observados v/s Predichos Estimación Datos reales II, JAGS.

2.4.1.3. Estimación III: Todas las variables, una cadena, sin salto y sin outliers

2.4.1.3.1. Intervalos Parámetros

Tabla 32: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-7.411	-6.717
β_1	-0.004	0.003
β_2	-3.124	-2.536
β_3	0.7027	0.873
β_4	-0.51342	-0.330
β_5	-0.2665	-0.022
β_6	0.1819	0.069
β_7	0.7470	0.966
β_8	-1.674	-1.456
β_9	-0.4974	1.937e-06
β_{10}	-3.668	-2.819
σ_0^2	5.099	0.404
σ_1^2	1.601e-70	4.489e-04
σ_2^2	1.410	108.5
σ_3^2	0.1172	27.17
σ_4^2	0.033	15.04
σ_5^2	8.090e-04	1.661
σ_6^2	0.019	17.78
σ_7^2	0.135	37.55
σ_8^2	0.453	57.57
σ_9^2	1.006e-27	2.356
σ_{10}^2	1.806	119.8

Tabla 33: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-7.412	-6.718
β_1	-0.004	0.003
β_2	-3.12	-2.532
β_3	0.699	0.87
β_4	-0.515	-0.332
β_5	-0.283	-0.058
β_6	0.202	0.705
β_7	0.744	0.963
β_8	-1.672	-1.454
β_9	-0.460	0.003
β_{10}	-3.660	-2.813
σ_0^2	3.509	34.616
σ_1^2	7.003e-84	5.329e-05
σ_2^2	0.472	82.624
σ_3^2	0.03	18.523
σ_4^2	0.009	9.074
σ_5^2	2.129e-11	1.399
σ_6^2	2.413e-07	9.678
σ_7^2	0.045	23.742
σ_8^2	0.153	40.026
σ_9^2	9.844e-40	1.564
σ_{10}^2	0.62	85.607

2.4.1.3.2. Tabla Sensibilidad y Especificidad

Tabla 34: Sensibilidad y Especificidad Estimación Datos reales III, JAGS

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
$Y=0$	15754	769	16523
$Y=1$	781	1498	2279
	16535	2267	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 32: Esquema Observados v/s Predichos Estimación Datos reales III, JAGS

2.4.2. STAN

2.4.2.1. Estimación I: Todas las variables, todas las observaciones, una cadena y sin salto

2.4.2.1.1. Intervalos Parámetros

Tabla 35: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-57.481	-9.566
β_1	-3709.187	-181.897
β_2	-3.176	-2.571
β_3	0.699	0.871
β_4	-0.542	-0.356
β_5	-0.331	-0.128
β_6	0.137	0.525
β_7	0.692	0.932
β_8	-1.688	-1.467
β_9	-0.511	-0.121
β_{10}	-3.772	-2.934

Tabla 36: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-57.951	-11.094
β_1	-3743.775	-299.517
β_2	-3.176	-2.571
β_3	0.697	0.869
β_4	-0.542	-0.356
β_5	-0.33	-0.127
β_6	0.136	0.524
β_7	0.693	0.932
β_8	-1.685	-1.465
β_9	-0.516	-0.127
β_{10}	-3.777	-2.940

2.4.2.1.2. Tabla Sensibilidad y Especificidad

Tabla 37: Sensibilidad y Especificidad Estimación Datos reales I, Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
$Y=0$	15753	770	16523
$Y=1$	743	1536	2279
	16496	2306	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 33: Esquema Observados v/s Predichos Estimación Datos reales I, Stan

2.4.2.2. Estimación II: Todas las variables, una cadena, sin salto y sin outliers

2.4.2.2.1. Intervalos Parámetros

Tabla 38: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-7.446	-6.723
β_1	-8.740	0.522
β_2	-3.141	-2.546
β_3	0.703	0.872
β_4	-0.511	-0.327
β_5	-0.265	-0.065
β_6	0.177	0.607
β_7	0.753	0.973
β_8	-1.671	-1.457
β_9	-0.507	-0.042
β_{10}	-3.590	-2.793
σ_0	7.590	185.328
σ_1	0.000	75.231
σ_2	1.363	110.292
σ_3	0.119	46.292
σ_4	0.033	27.844
σ_5	0.003	16.965
σ_6	0.019	24.436
σ_7	0.142	49.765
σ_8	0.451	71.486
σ_9	0.003	18.930
σ_{10}	1.776	113.222

Tabla 39: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-7.446	-6.723
β_1	-5.439	1.112
β_2	-3.142	-2.547
β_3	0.701	0.869
β_4	-0.51	-0.326
β_5	-0.267	-0.068
β_6	0.179	0.608
β_7	0.753	0.974
β_8	-1.672	-1.457
β_9	-0.519	-0.057
β_{10}	-3.597	-2.802
σ_0	3.639	148.552
σ_1	4.417e-05	40.347
σ_2	0.397	77.477
σ_3	0.040	25.684
σ_4	0.010	16.334
σ_5	6.767e-05	6.648
σ_6	6.916e-05	11.726
σ_7	0.042	28.023
σ_8	0.163	45.858
σ_9	5.878e-05	8.150
σ_{10}	0.421	80.681

2.4.2.2.2. Tabla Sensibilidad y Especificidad

Tabla 40: Sensibilidad y Especificidad Estimación Datos reales II, Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
Y=0	15738	785	16523
Y=1	779	1500	2279
	16517	2285	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 34: Esquema Observados v/s Predichos Estimación Datos reales II, Stan

2.4.2.3. Estimación III: Todas las variables, una cadena, sin salto y sin outliers

2.4.2.3.1. Intervalos Parámetros

Tabla 41: Intervalos de colas iguales

Parámetros	0.025	0.975
β_0	-43.393	-6.968
β_1	-2675.506	-0.028
β_2	-3.149	-2.558
β_3	0.699	0.865
β_4	-0.532	-0.346
β_5	-0.314	-0.11
β_6	0.137	0.539
β_7	0.697	0.943
β_8	-1.683	-1.466
β_9	-0.512	-0.108
β_{10}	-3.716	-2.892
σ_0	24.357	794676.8
σ_1	0.197	2.233e+09
σ_2	1.593	9191.996
σ_3	0.125	533.100
σ_4	0.040	188.013
σ_5	0.011	57.457
σ_6	0.019	150.639
σ_7	0.131	517.184
σ_8	0.494	2204.187
σ_9	0.016	96.233
σ_{10}	2.058	10339.05

Tabla 42: Intervalos más alta prob

Parámetros	Lower	Upper
β_0	-43.106	-6.82
β_1	-2647.973	1.236
β_2	-3.156	-2.567
β_3	0.7	0.866
β_4	-0.533	-0.347
β_5	-0.313	-0.108
β_6	0.137	0.538
β_7	0.695	0.940
β_8	-1.680	-1.463
β_9	-0.511	-0.107
β_{10}	-3.717	-2.894
σ_0	3.216	191641.4
σ_1	0.002	5.692e+08
σ_2	0.497	2201.105
σ_3	0.047	143.932
σ_4	0.018	48.258
σ_5	0.003	14.520
σ_6	0.003	32.924
σ_7	0.040	14.511
σ_8	0.159	570.350
σ_9	0.003	27.389
σ_{10}	0.697	2497.127

2.4.2.3.2. Tabla Sensibilidad y Especificidad

Tabla 43: Sensibilidad y Especificidad Estimación Datos reales VI, Stan

VS	$\hat{Y} = 0$	$\hat{Y} = 1$	Total
$Y=0$	8165	8358	16523
$Y=1$	22	2257	2279
	8187	10615	18802

lo cual también se puede ver representado en el siguiente esquema,




Figura 35: Esquema Observados v/s Predichos Estimación Datos reales III, Stan

Anexo 3

Apéndice 3: Código

Anexo 4

Código

```

1 #####LIBRERIAS#####
2 library(rjags)
3 library(rstan)
4
5 library(corrplot)
6 library(PerformanceAnalytics)
7 library(ggplot2)
8 library(patchwork)
9 library(grDevices)
10 library(Hmisc)
11 library(vcd)
12 library(pROC)
13 library(Hmisc)
14 library(psych)
15 library(dplyr)
16
17 #####
18 #####ANALISIS DESCRIPTIVO#####
19 #####DATOS SIMULADOS#####
20 # Cargar los datos
21 data<-LogisticData
22 data<-na.omit(data)
23
24 #####Análisis descriptivo#####
25 summary(data)
26
27 correlacion<-round(cor(data), 1)
28 corrplot(correlacion, method="number", type="upper")
29
30 chart.Correlation(data, histogram = T)
31
32 Mat_R<-rcorr(as.matrix(data))
33 corrplot(Mat_R$r,p.mat = Mat_R$r,type="upper",bg= "pink",tl.col="red",tl.srt = 20,
34         pch.col = "blue",insig = "p-value",sig.level = -1,col = terrain.colors(300))
35 #####Boxplot simples#####
36 ggplot(data , aes(x = "", y = data$`"y"`)) +
37   geom_boxplot(outlier.shape = NA) +

```

```

38 geom_jitter(colour = 2)
39 ggplot(data, aes(x = "", y = data$`x1``)) +
40   geom_boxplot(outlier.shape = NA) +
41   geom_jitter(colour = 2)
42 ggplot(data, aes(x = "", y = data$`x2``)) +
43   geom_boxplot(outlier.shape = NA) +
44   geom_jitter(colour = 2)                                add =
45   ↪ TRUE)
46 #####DATOS REALES#####
47 #Cargar datos
48 data1 <- TrainingVVV_RRL2
49 data<-na.omit(data1)
50 #####Análisis descriptivo#####
51 summary(data1)
52
53 corPlot(data1[, 2:13],
54         upper = FALSE,main = "Gráfico de correlación Datos Reales")
55
56 correlacion<-round(cor(data1), 1)
57 corplot(correlacion, method="number", type="upper")
58
59 chart.Correlation(data1, histogram = T)
60
61 Mat_R<-rcorr(as.matrix(data1))
62 corplot(Mat_R$r,p.mat = Mat_R$r,type="upper",bg= "pink",tl.col="red",tl.srt = 20,
63         pch.col = "black",insig = "p-value",sig.level = -1,col = terrain.colors(300))
64 #####Boxplot simples#####
65 df<-data
66 data1<-data
67 ggplot(df, aes(x = "", y = data1$rrl)) +
68   geom_boxplot(outlier.shape = NA) +
69   geom_jitter(colour = 2)
70
71 p1<-ggplot(data = df, aes(y = df$A.1.1.)) +
72   geom_boxplot() +
73   scale_x_discrete() +
74   labs(title = "A.1.1.",
75        x = " ") +
76   coord_flip()
77
78 p1<-ggplot(df, aes(x = "", y = data1$A.1.1.)) +
79   geom_boxplot(outlier.shape = NA) +
80   geom_jitter(colour = 2)
81
82 p2<-ggplot(df, aes(x = "", y = data1$A.1.2.)) +
83   geom_boxplot(outlier.shape = NA) +
84   geom_jitter(colour = 2)
85
86 p3<-ggplot(df, aes(x = "", y = data1$A.1.3.)) +
87   geom_boxplot(outlier.shape = NA) +
88   geom_jitter(colour = 2)
89
90 p4<-ggplot(df, aes(x = "", y = data1$PH.1.2.)) +
91   geom_boxplot(outlier.shape = NA) +
92   geom_jitter(colour = 2)
93
94 p5<-ggplot(df, aes(x = "", y = data1$PH.1.3.)) +
95   geom_boxplot(outlier.shape = NA) +
96   geom_jitter(colour = 2)

```

```

92 p6<-ggplot(df, aes(x = "", y = data1$PH.1.4.)) +
93   geom_boxplot(outlier.shape = NA) +
94   geom_jitter(colour = 2)
95 p7<-ggplot(df, aes(x = "", y = data1$f1)) +
96   geom_boxplot(outlier.shape = NA) +
97   geom_jitter(colour = 2)
98 p8<-ggplot(df, aes(x = "", y = data1$P1)) +
99   geom_boxplot(outlier.shape = NA) +
100  geom_jitter(colour = 2)
101 p9<-ggplot(df, aes(x = "", y = data1$s)) +
102   geom_boxplot(outlier.shape = NA) +
103   geom_jitter(colour = 2)
104 p10<-ggplot(df, aes(x = "", y = data1$p2p_s2p)) +
105   geom_boxplot(outlier.shape = NA) +
106   geom_jitter(colour = 2)
107 p11<-ggplot(df, aes(x = "", y = data1$p2p_spfom)) +
108   geom_boxplot(outlier.shape = NA) +
109   geom_jitter(colour = 2)
110 p12<-ggplot(df, aes(x = "", y = data1$R1)) +
111   geom_boxplot(outlier.shape = NA) +
112   geom_jitter(colour = 2)
113 (p1 | p2 | p3 ) / (p4 | p5 | p6)
114 (p7 | p8 | p9 ) / (p10 | p11 | p12)
115
116 Conf3x2 = matrix(c(1:3), nrow=3, byrow=TRUE)
117 layout(Conf3x2)
118 layout.show(3)
119 boxplot(data1$A.1.1., data1$A.1.2., data1$A.1.3.,data1$PH.1.2.,data1$PH.1.3.,data1$PH
    ↪ .1.4.,
120   main = " ",
121   at = c(1,2,3,4,5,6),
122   names = c("A.1.1", "A.1.2", "A.1.3","PH.1.2","PH.1.3","PH.1.4."),
123   las = 2,
124   col = c("lightpink"),
125   border = "lightpink4",
126   horizontal = FALSE,
127   notch = TRUE)
128 boxplot(data1$PH.1.2.,data1$PH.1.3.,data1$PH.1.4.,
129   main = " ",
130   at = c(1,2,3),
131   names = c("PH.1.2","PH.1.3","PH.1.4."),
132   las = 2,
133   col = c("lightpink"),
134   border = "lightpink4",
135   horizontal = FALSE,
136   notch = TRUE)
137 boxplot(data1$f1,data1$P1,data1$s,data1$p2p_s2p,data1$p2p_spfom,data1$R1,
138   main = "",
139   at = c(1,2,3,4,5,6),
140   names = c("f1", "P1.", "s", "p2p_s2p", "p2p_spfom", "R1"),
141   las = 2,
142   col = c("lightpink"),
143   border = "lightpink4",
144   horizontal = FALSE,
145   notch = TRUE)

```

```

146 #####Boxplot con binaria#####
147 Conf3x2 = matrix(c(1:6), nrow=2, byrow=TRUE)
148 layout(Conf3x2)
149 layout.show(6)
150 boxplot(data1$A.1.1. ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "A
    ↪ .1.1",ylab = "rrl");stripchart(data1$A.1.1. ~ data1$rrl, data = data1,
151                                     method = "jitter"
    ↪ ,
152                                     pch = 19,
153                                     col = 2:4,
154                                     vertical = FALSE
    ↪ ,
155                                     add = TRUE)
156 boxplot(data1$A.1.2. ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "A
    ↪ .1.2",ylab = "rrl");stripchart(data1$A.1.2. ~ data1$rrl, data = data1,
157                                     method = "jitter"
    ↪ ,
158                                     pch = 19,
159                                     col = 2:4,
160                                     vertical = FALSE
    ↪ ,
161                                     add = TRUE)
162 boxplot(data1$A.1.3. ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "A
    ↪ .1.3",ylab = "rrl");stripchart(data1$A.1.2. ~ data1$rrl, data = data1,
163                                     method = "jitter"
    ↪ ,
164                                     pch = 19,
165                                     col = 2:4,
166                                     vertical = FALSE
    ↪ ,
167                                     add = TRUE)
168 boxplot(data1$PH.1.2. ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "
    ↪ P.1.2",ylab = "rrl");stripchart(data1$PH.1.2. ~ data1$rrl, data = data1,
169                                     method = "jitter"
    ↪ " ,
170                                     pch = 19,
171                                     col = 2:4,
172                                     vertical =
    ↪ FALSE,
173                                     add = TRUE)
174 boxplot(data1$PH.1.3. ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "
    ↪ P.1.3",ylab = "rrl");stripchart(data1$PH.1.3. ~ data1$rrl, data = data1,
175                                     method = "jitter"
    ↪ " ,
176                                     pch = 19,
177                                     col = 2:4,
178                                     vertical =
    ↪ FALSE,
179                                     add = TRUE)
180 boxplot(data1$PH.1.4. ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "
    ↪ P.1.4",ylab = "rrl");stripchart(data1$PH.1.4. ~ data1$rrl, data = data1,
181                                     method = "jitter"
    ↪ " ,
182                                     pch = 19,
183                                     col = 2:4,

```



```

184                                     vertical =
      ↪ FALSE,
185                                     add = TRUE)
186 boxplot(data1$f1 ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "f1",
      ↪ ylab = "rrl");stripchart(data1$f1 ~ data1$rrl, data = data1,
187                                     method = "jitter",
188                                     pch = 19,
189                                     col = 2:4,
190                                     vertical = FALSE,
191                                     add = TRUE)
192 boxplot(data1$P1 ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "P1",
      ↪ ylab = "rrl");stripchart(data1$P1 ~ data1$rrl, data = data1,
193                                     method = "jitter",
194                                     pch = 19,
195                                     col = 2:4,
196                                     vertical = FALSE,
197                                     add = TRUE)
198 boxplot(data1$s ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "s",ylab
      ↪ = "rrl");stripchart(data1$s ~ data1$rrl, data = data1,
199                                     method = "jitter",
200                                     pch = 19,
201                                     col = 2:4,
202                                     vertical = FALSE,
203                                     add = TRUE)
204 boxplot(data1$p2p_s2p ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab =
      ↪ "p2p_s2p",ylab = "rrl");stripchart(data1$p2p_s2p ~ data1$rrl, data = data1,
205                                     method = "jitter
      ↪ ",
206                                     pch = 19,
207                                     col = 2:4,
208                                     vertical =
      ↪ FALSE,
209                                     add = TRUE)
210 boxplot(data1$p2p_spfom ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab
      ↪ = "p2p_spfom",ylab = "rrl");stripchart(data1$p2p_spfom ~ data1$rrl, data = data1,
211                                     method = "
      ↪ jitter",
212                                     pch = 19,
213                                     col = 2:4,
214                                     vertical =
      ↪ FALSE,
215                                     add = TRUE)
216 boxplot(data1$R1 ~ data1$rrl, data = data1, col = "white",horizontal= TRUE,xlab = "R1",
      ↪ ylab = "rrl");stripchart(data1$R1 ~ data1$rrl, data = data1,
217                                     method = "jitter",
218                                     pch = 19,
219                                     col = 2:4,
220                                     vertical = FALSE,
221                                     add = TRUE)
222
223
224
225 #####Eliminación de outliers#####
226 data1 <- TrainingVVV_RRL2
227 data1<-as.data.frame(data1)

```

```

228 #data1<-subset(data1, A.1.1.<=40 &A.1.2.<=40 &A.1.3.<=40)#se elimina desde la
    ↪ observacion 60 en las variables A.1.i
229
230 index <- which(data1$A.1.1.<40 &data1$A.1.2.<40 &data1$A.1.3.<40)
231 data1[index, ]
232 data1<-data.frame(data1[index, ])
233 dim(data1)
234 #View(data1)
235 summary(data1)#se eliminaron 3 variables
236 #####
237
238
239 #####
240 #####RJAGS#####
241 #####DATOS SIMULADOS#####
242 # Cargar los datos
243 data<-LogisticData
244 data<-na.omit(data)
245
246 #####Simulacion con varianza fija#####
247 # Paso 1: especificar el modelo
248 modelo__bayesiano = 'model{
249   for(i in 1:length(y)){
250     y[i] ~ dbern(p[i])
251     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i]
252   }
253   beta0 ~ dnorm(0, 0.000001)
254   beta[1] ~ dnorm(0, 0.000001)
255   beta[2] ~ dnorm(0, 0.000001)
256
257 }'
258
259 # Paso 2: Ajustar el modelo a los datos
260 datos__jags = list(y = data$y, x1 = data$x1, x2 = data$x2)
261 param = c('beta0','beta')
262 modelo__ajustado = jags.model(textConnection(modelo__bayesiano), data = datos__jags,
263                               n.chains = 2)#n.chains la cantidad de veces que corre la cadena#
    ↪ modelo parte por defecto desde 1000
264
265 # Paso 3: MCMC
266 cadenas<- coda.samples(model=modelo__ajustado, variable.names=param, n.iter=10000, thin
    ↪ = 1)
267 muestra.posterior=do.call(rbind, cadenas)
268 summary(cadenas)
269 HPDinterval(cadenas)
270
271 # Exportar algunos objetos de R
272 df<-as.data.frame(muestra.posterior)
273 df<-write.csv(df, "CadenasSimulados1")
274
275 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimulados1")
276 #str(muestra.posterior)
277 muestra.posterior1<-muestra.posterior %>% select (-...1)
278 str(muestra.posterior1)
279 dim(muestra.posterior1)

```

```

280
281 muestra<-muestra.posterior1[1:10000,1:3]
282 muestra1<-muestra.posterior1[10001:20000,1:3]
283 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
284
285 summary(muestras)
286 gelman.diag(muestras)
287 effectiveSize(muestra.posterior1)
288 HPDinterval(muestras)
289
290 # Paso 4: Análisis de convergencia.
291 muestra.posterior<-muestra.posterior1
292 #para beta0
293 plot(muestra.posterior[,3])#cumple estacionaridad #se ve media y varianza constante
294 ts.plot(muestra.posterior[,3],ylab="Beta 0")#los primeros 1000
295 acf(ts(muestra.posterior[,3])#autocorrelacion desaparece en lag 6
296 #para beta1
297 plot(cadenas[,1])#cumple estacionaridad
298 ts.plot(muestra.posterior[,1],ylab="Beta 1")
299 acf(ts(muestra.posterior[,1])#autocorrelacion desaparece en lag 6
300 #para beta2
301 plot(cadenas[,2])#cumple estacionaridad
302 ts.plot(muestra.posterior[,2],ylab="Beta 2")
303 acf(ts(muestra.posterior[,2])#autocorrelacion desaparece en lag 7
304
305 ##se guardan las iteraciones cada 7 y se queman 3000
306
307 # Paso 5: MCMC Final
308 update(modelo__ajustado,2000)#se queman
309 cadenas<- coda.samples(model=modelo__ajustado, variable.names=param, n.iter=70000, thin
    ↪ = 7)#se salta y guarda cada 7 iteraciones
310 muestra.posterior=do.call(rbind, cadenas)
311
312 # Exportar algunos objetos de R
313 dff<-as.data.frame(muestra.posterior)
314 dfcf<-write.csv(dff, "CadenasSimulados1Final")
315
316 CadenasSimulados1Final<-read_csv("C:/Users/56992/Desktop/CadenasSimulados1Final")
317 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimulados1Final")
318 #str(muestra.posterior)
319 muestra.posterior1<-muestra.posterior %>% select (...,1)
320 str(muestra.posterior1)
321 dim(muestra.posterior1)
322
323 muestra<-muestra.posterior1[1:10000,1:3]
324 muestra1<-muestra.posterior1[10001:20000,1:3]
325 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
326
327 summary(muestras)
328 gelman.diag(muestras)
329 effectiveSize(muestra.posterior1)
330 HPDinterval(muestras)
331
332 muestra.posterior<-muestra.posterior1
333 #para beta0

```

```

334 plot(cadenas[,3])#cumple estacionaridad #se ve media y varianza constante
335 ts.plot(muestra.posterior[,3],ylab="Beta 0")#los primeros 1000
336 acf(ts(muestra.posterior[,3])#autocorrelacion desaparece en lag 6
337 #para beta1
338 plot(cadenas[,1])#cumple estacionaridad
339 ts.plot(muestra.posterior[,1],ylab="Beta 1")
340 acf(ts(muestra.posterior[,1])#autocorrelacion desaparece en lag 6
341 #para beta2
342 plot(cadenas[,2])#cumple estacionaridad
343 ts.plot(muestra.posterior[,2],ylab="Beta 2")
344 acf(ts(muestra.posterior[,2])#autocorrelacion desaparece en lag 7
345
346
347
348 # Paso 6: Inferencia.
349 summary(cadenas)
350 HPDinterval(as.mcmc(muestra.posterior))##investigar ambos metodos de intervalos (colas
    ↪ iguales y maxima prob a posteriori)
351 mean(as.mcmc(muestra.posterior)[,1] < 0)
352 mean(as.mcmc(muestra.posterior)[,7]<0)
353
354 #####Curva Roc #####
355 datos<-as.data.frame(LogisticData)
356 betas<-as.data.frame(muestra.posterior1)
357 View(betas)
358 summary(betas)
359 a<-mean(betas[,3]);a
360 b<-mean(betas[,1]);b
361 c<-mean(betas[,2]);c
362 y<-datos$y          #observados
363 x1<-datos$x1
364 x2<-datos$x2
365 n=10000
366 z = a + b*x1 + c*x2      # linear combination with a bias
367 pr = 1/(1+exp(-z))      # pass through an inv-logit function
368 k = rbinom(n,1,pr)      #predichos
369
370 roc_model=roc(y, k,ci=T,auc=T)
371 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
372          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
373          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
374 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
375 points(x=coordenada$specificity,
376        y=coordenada$sensitivity,
377        pch=0,col="red")
378
379 ##### Analisis de sensibilidad y especificidad #####
380 estimados=ifelse(test=k>0.5, yes=1, no=0)
381 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
382 tabla
383 mosaic(tabla, shade = T, colorize = T,
384        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
385
386 sensi=3084/4019 ; sensi
387 espec=5014/5981 ; espec

```

```

388 capa=(3084+5014)/10000 ; capa
389
390
391 cambio=matrix(data=tabla,ncol=2 , byrow=FALSE) ; cambio
392 BDtest(cambio, pr=0.56 ,conf.level = 0.95)
393
394 #####Simulacion con gamma#####
395 # Paso 1: especificar el modelo
396 modelo_bayesiano = 'model{
397   for(i in 1:length(y)){
398     y[i] ~ dbern(p[i])
399     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i]
400   }
401   beta0 ~ dnorm(0, 1/sig20)
402   sig20 ~ dgamma(0.01,0.01)
403   for(j in 1:2){
404     sig2[j] ~ dgamma(0.01, 0.01)
405     beta[j] ~ dnorm(0, 1/sig2[j])
406   }
407 }'
408
409 # Paso 2: Ajustar el modelo a los datos
410 datos_jags = list(y = data$y, x1 = data$x1, x2 = data$x2)
411 param = c('beta0','beta','sig20','sig2')
412 modelo_ajustado = jags.model(textConnection(modelo_bayesiano), data = datos_jags,
413                               n.chains = 2)
414 # Paso 3: MCMC
415 cadenas<- coda.samples(model=modelo_ajustado, variable.names=param, n.iter=10000, thin
416                        ↪ = 1)
417 muestra.posterior=do.call(rbind, cadenas)
418 str(muestra.posterior)
419 summary(cadenas)
420 HPDinterval(as.mcmc(muestra.posterior))
421
422 # Exportar algunos objetos de R
423 df<-as.data.frame(muestra.posterior)
424 dfc<-write.csv(df, "CadenasSimuladosGamma.txt")
425
426 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosGamma.txt")
427 #str(muestra.posterior)
428 muestra.posterior1<-muestra.posterior %>% select (1:6)
429 str(muestra.posterior1)
430 dim(muestra.posterior1)
431
432 muestra<-muestra.posterior1[1:10000,1:6]
433 muestra1<-muestra.posterior1[10001:20000,1:6]
434 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
435
436 summary(muestras)
437 gelman.diag(muestras)
438 effectiveSize(muestra.posterior1)
439 HPDinterval(muestras)
440
441 # Paso 4: Análisis de convergencia.
442 muestra.posterior<-muestra.posterior1

```

```

442 #para beta0
443 plot(muestra.posterior[,3])#cumple estacionaridad #se ve media y varianza constante
444 ts.plot(muestra.posterior[,3],ylab="Beta 0")#los primeros 1000
445 acf(ts(muestra.posterior[,3])#autocorrelacion desaparece en lag 6
446 #para beta1
447 plot(cadenas[,1])#cumple estacionaridad
448 ts.plot(muestra.posterior[,1],ylab="Beta 1")
449 acf(ts(muestra.posterior[,1])#autocorrelacion desaparece en lag 9
450 #para beta2
451 plot(cadenas[,2])#cumple estacionaridad
452 ts.plot(muestra.posterior[,2],ylab="Beta 2")
453 acf(ts(muestra.posterior[,2])#autocorrelacion desaparece en lag 9
454
455 #para sig20
456 plot(muestra.posterior[,6])#cumple estacionaridad #se ve media y varianza constante
457 ts.plot(muestra.posterior[,6],ylab="Sigma2 Beta 0")#los primeros 1000
458 acf(ts(muestra.posterior[,6])#autocorrelacion desaparece en lag 6
459 #para sig2[1]
460 plot(cadenas[,4])#cumple estacionaridad
461 ts.plot(muestra.posterior[,4],ylab="Sigma2 Beta 1")
462 acf(ts(muestra.posterior[,4])#autocorrelacion desaparece en lag 6
463 #para sig2[2]
464 plot(cadenas[,5])#cumple estacionaridad
465 ts.plot(muestra.posterior[,5],ylab="Sigma2 Beta 2")
466 acf(ts(muestra.posterior[,5])#autocorrelacion desaparece en lag 7
467
468
469 ##se guardan las iteraciones cada 9 y se queman 3000
470
471 # Paso 5: MCMC Final
472 update(modelo_ajustado,2000)#se queman
473 cadenas<- coda.samples(model=modelo_ajustado, variable.names=param, n.iter=90000, thin
    ↪ = 9)#se salta y guarda cada 9 iteraciones
474 muestra.posterior=do.call(rbind, cadenas)
475
476 # Exportar algunos objetos de R
477 dff<-as.data.frame(muestra.posterior)
478 dfcf<-write.csv(dff, "CadenasSimuladosGammaFinal")
479
480 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosGammaFinal")
481 #str(muestra.posterior)
482 muestra.posterior1<-muestra.posterior %>% select (-...1)
483 str(muestra.posterior1)
484 dim(muestra.posterior1)
485
486 muestra<-muestra.posterior1[1:10000,1:6]
487 muestra1<-muestra.posterior1[10001:20000,1:6]
488 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
489
490 summary(muestras)
491 gelman.diag(muestras)
492 effectiveSize(muestra.posterior1)
493 HPDIinterval(muestras)
494
495 muestra.posterior<-muestra.posterior1

```

```

496 #para beta0
497 plot(cadenas[,3])#cumple estacionaridad #se ve media y varianza constante
498 ts.plot(muestra.posterior[,3],ylab="Beta 0")#los primeros 1000
499 acf(ts(muestra.posterior[,3])#autocorrelacion desaparece en lag 6
500 effectiveSize(muestra.posterior)#betas estimados
501 dim(muestra.posterior)
502 #para beta1
503 plot(cadenas[,1])#cumple estacionaridad
504 ts.plot(muestra.posterior[,1],ylab="Beta 1")
505 acf(ts(muestra.posterior[,1])#autocorrelacion desaparece en lag 6
506 #para beta2
507 plot(cadenas[,2])#cumple estacionaridad
508 ts.plot(muestra.posterior[,2],ylab="Beta 2")
509 acf(ts(muestra.posterior[,2])#autocorrelacion desaparece en lag 7
510
511 #para sig20
512 plot(muestra.posterior[,6])#cumple estacionaridad #se ve media y varianza constante
513 ts.plot(muestra.posterior[,6],ylab="Sigma2 Beta 0")#los primeros 1000
514 acf(ts(muestra.posterior[,6])#autocorrelacion desaparece en lag 6
515 #para sig2[1]
516 plot(cadenas[,4])#cumple estacionaridad
517 ts.plot(muestra.posterior[,4],ylab="Sigma2 Beta 1")
518 acf(ts(muestra.posterior[,4])#autocorrelacion desaparece en lag 6
519 #para sig2[2]
520 plot(cadenas[,5])#cumple estacionaridad
521 ts.plot(muestra.posterior[,5],ylab="Sigma2 Beta 2")
522 acf(ts(muestra.posterior[,5])#autocorrelacion desaparece en lag 7
523
524 # Paso 6: Inferencia.
525 summary(cadenas)
526 HPDinterval(as.mcmc(muestra.posterior))##investigar ambos metodos de intervalos (colas
    ↪ iguales y maxima prob a posteriori)
527 mean(as.mcmc(muestra.posterior)[,1] < 0)
528 mean(as.mcmc(muestra.posterior)[,7]<0)
529
530 #####Curva Roc #####
531 datos<-as.data.frame(LogisticData)
532 betas<-as.data.frame(muestra.posterior1)
533 View(betas)
534 summary(betas)
535 a<-mean(betas[,3]);a
536 b<-mean(betas[,1]);b
537 c<-mean(betas[,2]);c
538 y<-datos$y          #observados
539 x1<-datos$x1
540 x2<-datos$x2
541 n=10000
542 z = a + b*x1 + c*x2      # linear combination with a bias
543 pr = 1/(1+exp(-z))      # pass through an inv-logit function
544 k = rbinom(n,1,pr)      #predichos
545
546 roc_model=roc(y, k,ci=T,auc=T)
547 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
548         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
549         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )

```

```

550 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
551 points(x=coordenada$specificity,
552        y=coordenada$sensitivity,
553        pch=0,col="red")
554
555 ##### Analisis de sensibilidad y especificidad #####
556 estimados=ifelse(test=k>0.5, yes=1, no=0)
557 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
558 tabla
559 mosaic(tabla, shade = T, colorize = T,
560        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
561
562 sensi=3048/4019 ; sensi
563 espec=5093/5981 ; espec
564 capa=(3048+5093)/10000 ; capa
565
566
567 ##### Simulacion con gamma inversa #####
568 # Paso 1: especificar el modelo
569 modelo_bayesiano = 'model{
570   for(i in 1:length(y)){
571     y[i] ~ dbern(p[i])
572     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i]
573   }
574   beta0 ~ dnorm(0, sig20)
575   sig20 ~ dgamma(0.01,0.01)
576   for(j in 1:2){
577     sig2[j] ~ dgamma(0.01, 0.01)
578     beta[j] ~ dnorm(0, sig2[j])
579   }
580 }'
581
582 # Paso 2: Ajustar el modelo a los datos
583 datos_jags = list(y = data$y, x1 = data$x1, x2 = data$x2)
584 param = c('beta0','beta','sig20','sig2')
585 modelo_ajustado = jags.model(textConnection(modelo_bayesiano), data = datos_jags,
586                             n.chains = 2)
587 # Paso 3: MCMC
588 cadenas<- coda.samples(model=modelo_ajustado, variable.names=param, n.iter=10000, thin
589                       ↪ = 1)
589 muestra.posterior=do.call(rbind, cadenas)
590 str(muestra.posterior)
591 summary(cadenas)
592 HPDinterval(as.mcmc(muestra.posterior))
593
594 # Exportar algunos objetos de R
595 df<-as.data.frame(muestra.posterior)
596 dfc<-write.csv(df, "CadenasSimuladosGammaInv.txt")
597
598 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosGammaInv.txt")
599 #str(muestra.posterior)
600 muestra.posterior1<-muestra.posterior %>% select (-...1)
601 str(muestra.posterior1)
602 dim(muestra.posterior1)
603

```



```

604 muestra<-muestra.posterior1[1:10000,1:6]
605 muestra1<-muestra.posterior1[10001:20000,1:6]
606 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
607
608 summary(muestras)
609 gelman.diag(muestras)
610 effectiveSize(muestra.posterior1)
611 HPDinterval(muestras)
612
613 muestra.posterior<-muestra.posterior1
614 str(muestra.posterior)
615 # Paso 4: Análisis de convergencia.
616 muestra.posterior<-muestra.posterior1
617 #para beta0
618 plot(muestra.posterior[,3])
619 ts.plot(muestra.posterior[,3],ylab="Beta 0")
620 acf(ts(muestra.posterior[,3])#lag6
621 #para beta1
622 plot(cadenas[,1])
623 ts.plot(muestra.posterior[,1],ylab="Beta 1")
624 acf(ts(muestra.posterior[,1])#lag9
625 #para beta2
626 plot(cadenas[,2])
627 ts.plot(muestra.posterior[,2],ylab="Beta 2")
628 acf(ts(muestra.posterior[,2])#lag9
629
630 #para sig20
631 plot(muestra.posterior[,6])
632 ts.plot(muestra.posterior[,6],ylab="Sigma2 Beta 0")
633 acf(ts(muestra.posterior[,6]))#lag0
634 #para sig2[1]
635 plot(cadenas[,4])
636 ts.plot(muestra.posterior[,4],ylab="Sigma2 Beta 1")
637 acf(ts(muestra.posterior[,4]))#lag0
638 #para sig2[2]
639 plot(cadenas[,5])
640 ts.plot(muestra.posterior[,5],ylab="Sigma2 Beta 2")
641 acf(ts(muestra.posterior[,5]))#lag0
642
643
644 # Paso 5: MCMC Final
645 update(modelo_ajustado,2000)#se queman
646 cadenas<- coda.samples(model=modelo_ajustado, variable.names=param, n.iter=90000, thin
  ↪ = 9)
647 muestra.posterior=do.call(rbind, cadenas)
648 effectiveSize(muestra.posterior)#betas estimados
649 dim(muestra.posterior)
650
651 # Exportar algunos objetos de R
652 dff<-as.data.frame(muestra.posterior)
653 dfcf<-write.csv(dff, "CadenasSimuladosGammaInvFinal")
654
655 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosGammaInvFinal.
  ↪ txt")
656 #str(muestra.posterior)

```

```

657 muestra.posterior1<-muestra.posterior %>% select (-...1)
658 str(muestra.posterior1)
659 dim(muestra.posterior1)
660
661 muestra<-muestra.posterior1[1:10000,1:6]
662 muestra1<-muestra.posterior1[10001:20000,1:6]
663 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
664
665 summary(muestras)
666 gelman.diag(muestras)
667 effectiveSize(muestra.posterior1)
668 HPDinterval(muestras)
669
670
671 muestra.posterior<-muestra.posterior1
672 str(muestra.posterior)
673 #para beta0
674 plot(cadenas[,3])#cumple estacionaridad #se ve media y varianza constante
675 ts.plot(muestra.posterior[,3],ylab="Beta 0")#los primeros 1000
676 acf(ts(muestra.posterior[,3]))#autocorrelacion desaparece en lag 6
677 #para beta1
678 plot(cadenas[,1])#cumple estacionaridad
679 ts.plot(muestra.posterior[,1],ylab="Beta 1")
680 acf(ts(muestra.posterior[,1]))#autocorrelacion desaparece en lag 6
681 #para beta2
682 plot(cadenas[,2])#cumple estacionaridad
683 ts.plot(muestra.posterior[,2],ylab="Beta 2")
684 acf(ts(muestra.posterior[,2]))#autocorrelacion desaparece en lag 7
685
686 #para sig20
687 plot(muestra.posterior[,6])
688 ts.plot(muestra.posterior[,6],ylab="Sigma2 Beta 0")
689 acf(ts(muestra.posterior[,6]))#lag0
690 #para sig2[1]
691 plot(cadenas[,4])
692 ts.plot(muestra.posterior[,4],ylab="Sigma2 Beta 1")
693 acf(ts(muestra.posterior[,4]))#lag0
694 #para sig2[2]
695 plot(cadenas[,5])
696 ts.plot(muestra.posterior[,5],ylab="Sigma2 Beta 2")
697 acf(ts(muestra.posterior[,5]))#lag0
698
699
700 # Paso 6: Inferencia.
701 summary(cadenas)
702 HPDinterval(as.mcmc(muestra.posterior))##investigar ambos metodos de intervalos (colas
    ↪ iguales y maxima prob a posteriori)
703 mean(as.mcmc(muestra.posterior)[,1] < 0)
704 mean(as.mcmc(muestra.posterior)[,7]<0)
705
706
707 #####Curva Roc #####
708 datos<-as.data.frame(LogisticData)
709 betas<-as.data.frame(muestra.posterior1)
710 View(betas)

```

```

711 summary(betas)
712 a<-mean(betas[,3]);a
713 b<-mean(betas[,1]);b
714 c<-mean(betas[,2]);c
715 y<-datos$y          #observados
716 x1<-datos$x1
717 x2<-datos$x2
718 n=10000
719 z = a + b*x1 + c*x2      # linear combination with a bias
720 pr = 1/(1+exp(-z))      # pass through an inv-logit function
721 k = rbinom(n,1,pr)      #predichos
722
723 roc_model=roc(y, k,ci=T,auc=T)
724 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
725         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
726         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
727 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
728 points(x=coordenada$specificity,
729        y=coordenada$sensitivity,
730        pch=0,col="red")
731
732 #####Análisis de sensibilidad y especificidad #####
733 estimados=ifelse(test=k>0.5, yes=1, no=0)
734 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
735 tabla
736 mosaic(tabla, shade = T, colorize = T,
737        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
738
739 sensi=2904/4019 ; sensi
740 espec=4719/5981 ; espec
741 capa=(2904+4719)/10000 ; capa
742
743
744
745
746 #####
747 #####
748 #####
749 #####DATOS REALES#####
750 #Cargar datos
751 data1 <- TrainingVWV_RRL2
752 data<-na.omit(data1)
753
754 #####Modelo GLM#####
755 modelo1 <- glm(data1$rrl~ ., data = data1, family =binomial(link='logit')) #https://www.
756      ↪ statology.org/glm-fit-algorithm-did-not-converge/
757 summary(modelo1)
758 confint(object = modelo1, level = 0.95 )#no corre
759
760 predicciones <- ifelse(test = modelo1$fitted.values > 0.5, yes = 1, no = 0)
761 matriz_confusion <- table(data1$rrl, predicciones,
762                          dnn = c("observaciones", "predicciones"));matriz_confusion
763 sensi=16470/16530 ; sensi
764 espec=551/2279 ; espec
765

```

```

765 mosaic(matriz_confusion, shade = T, colorize = T,
766         gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
767
768 GLMroc_model=roc(data1$rrl, predicciones,ci=T,auc=T)
769 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
770         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
771         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
772 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
773 points(x=coordenada$specificity,
774        y=coordenada$sensitivity,
775        pch=0,col="red")
776
777 #####Simulación#####
778 # Paso 1: especificar el modelo
779 modelo_bayesiano1 = 'model{
780   for(i in 1:length(y)){
781     y[i] ~ dbern(p[i])
782     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i] + beta[3]*x3[i] + beta[4]*x4[i] + beta
783     ↪ [5]*x5[i] +
784     beta[6]*x6[i] + beta[7]*x7[i] + beta[8]*x8[i] + beta[9]*x9[i] + beta[10]*x10[i] + beta[11]
785     ↪ *x11[i] + beta[12]*x12[i]
786   }
787   beta0 ~ dnorm(0, 0.000001)
788   for(j in 1:12){
789     beta[j] ~ dnorm(0, 0.000001)
790   }
791 }'
792
793 # Paso 2: Ajustar el modelo a los datos
794 datos_jags1 = list(y = data$rrl, x1 = data$A.1.1., x2 = data$A.1.2., x3 = data$A.1.3.,
795                  x4 = data$PH.1.2., x5 = data$PH.1.3., x6 = data$PH.1.4., x7 = data$f1 , x8
796                  ↪ =data$P1 , x9 = data$s,
797                  x10 = data$p2p_s2p , x11 = data$p2p_spfom , x12 = data$R1)
798 param1 = c('beta0','beta')
799 modelo_ajustado1 = jags.model(textConnection(modelo_bayesiano1), data = datos_jags1,
800                             n.chains = 1)#n.chains la cantidad de veces que corre la cadena#
801 ↪ modelo parte por defecto desde 1000
802
803 # Paso 3: MCMC
804 cadenas1<- coda.samples(model=modelo_ajustado1, variable.names=param1, n.iter=18809,
805                        ↪ thin = 1)
806 muestra.posterior1=do.call(rbind, cadenas1)
807
808 #library(dplyr)
809 #CadenasReal <- CadenasReal %>% select (-X)
810 #View(CadenasReal)
811 #cadenas1<-CadenasReal
812 #muestra.posterior1=CadenasReal
813
814 # Paso 4: Analisis de convergencia.
815 mat <- matrix(c(1, 2, # Primero, segundo
816               3, 4,
817               5,6), # y tercer gráfico
818              nrow = 3, ncol = 2,
819              byrow = TRUE)

```

```

815
816 layout(mat = mat)
817
818
819 ts.plot(muestra.posterior1[,13],ylab="Beta0")
820 ts.plot(muestra.posterior1[,1],ylab="Beta1")
821 ts.plot(muestra.posterior1[,2],ylab="Beta2")
822 ts.plot(muestra.posterior1[,3],ylab="Beta3")#en los primeros 4 beta se decide quedar las
    ↪ 5000 primeras
823 ts.plot(muestra.posterior1[,4],ylab="Beta4")
824 ts.plot(muestra.posterior1[,5],ylab="Beta5")
825 ts.plot(muestra.posterior1[,6],ylab="Beta6")
826 ts.plot(muestra.posterior1[,7],ylab="Beta7")
827 ts.plot(muestra.posterior1[,8],ylab="Beta8")
828 ts.plot(muestra.posterior1[,9],ylab="Beta9")
829 ts.plot(muestra.posterior1[,10],ylab="Beta10")
830 ts.plot(muestra.posterior1[,11],ylab="Beta11")
831 ts.plot(muestra.posterior1[,12],ylab="Beta12")
832
833
834 #para beta
835 acf(ts(muestra.posterior1[,13],)#autocorrelacion desaparece en lag pasado 35
836 acf(ts(muestra.posterior1[,1])#pasado 35
837 acf(ts(muestra.posterior1[,2])#pasado35
838 acf(ts(muestra.posterior1[,3])#pasado 35
839 acf(ts(muestra.posterior1[,4])#pasado 35
840 acf(ts(muestra.posterior1[,5])# en la 7 y las demas no tienen
841 acf(ts(muestra.posterior1[,6])
842 acf(ts(muestra.posterior1[,7])
843 acf(ts(muestra.posterior1[,8])
844 acf(ts(muestra.posterior1[,9])
845 acf(ts(muestra.posterior1[,10])
846 acf(ts(muestra.posterior1[,11])
847 acf(ts(muestra.posterior1[,12])
848
849 cadenas11<- cadenas1 # coda.samples(model=modelo_ajustado1, variable.names=param1, n
    ↪ .iter=10000, thin = 1)
850 muestra.posterior11=muestra.posterior1
851 #Exportar algunos objetos de R
852 #df<-as.data.frame(muestra.posterior11)
853 #dfr<-write.csv(df, "CadenasReal")
854
855 effectiveSize(muestra.posterior11)#betas estimados
856 dim(muestra.posterior11)
857
858 # Paso 5: MCMC final
859 update(modelo_ajustado1,9000)#se quemaron las primeras 10000
860 cadenas1<- coda.samples(model=modelo_ajustado1, variable.names=param1, n.iter=376180,
    ↪ thin = 40)
861 muestra.posterior1=do.call(rbind, cadenas1)
862
863 #Exportar algunos objetos de R
864 df<-as.data.frame(muestra.posterior1)
865 dfr<-write.csv(df, "CadenasRealFinal")
866

```

```

867 ts.plot(muestra.posterior1[,13])
868 ts.plot(muestra.posterior1[,1])
869 ts.plot(muestra.posterior1[,2])
870 ts.plot(muestra.posterior1[,3])
871 ts.plot(muestra.posterior1[,4])
872 ts.plot(muestra.posterior1[,5])
873 ts.plot(muestra.posterior1[,6])
874 ts.plot(muestra.posterior1[,7])
875 ts.plot(muestra.posterior1[,8])
876 ts.plot(muestra.posterior1[,9])
877 ts.plot(muestra.posterior1[,10])
878 ts.plot(muestra.posterior1[,11])
879 ts.plot(muestra.posterior1[,12])
880
881
882 #para beta
883 acf(ts(muestra.posterior1[,13]))#autocorrelacion desaparece en lag
884 acf(ts(muestra.posterior1[,1])
885 acf(ts(muestra.posterior1[,2])
886 acf(ts(muestra.posterior1[,3])
887 acf(ts(muestra.posterior1[,4])
888 acf(ts(muestra.posterior1[,5])
889 acf(ts(muestra.posterior1[,6])
890 acf(ts(muestra.posterior1[,7])
891 acf(ts(muestra.posterior1[,8])
892 acf(ts(muestra.posterior1[,9])
893 acf(ts(muestra.posterior1[,10])
894 acf(ts(muestra.posterior1[,11])
895 acf(ts(muestra.posterior1[,12])
896
897 effectiveSize(muestra.posterior1)#betas estimados
898 dim(muestra.posterior1)
899
900 # Paso 6: Inferencia.
901 summary(cadenas1)
902 HPDinterval(as.mcmc(muestra.posterior1))##investigar ambos metodos de intervalos (colas
    ↪ iguales y maxima prob a posteriori)
903 mean(as.mcmc(muestra.posterior1[,1] < 0)
904 mean(as.mcmc(muestra.posterior1[,7]<0)
905
906
907 #####Simulación sin outliers#####
908 #####Eliminación de outliers#####
909 data1 <- TrainingVVV_RRL2
910 data1<-as.data.frame(data1)
911 #data1<-subset(data1, A.1.1.<=40 &A.1.2.<=40 &A.1.3.<=40)#se elimina desde la
    ↪ observacion 60 en las variables A.1.i
912
913 index <- which(data1$A.1.1.<40 &data1$A.1.2.<40 &data1$A.1.3.<40)
914 data1[index, ]
915 data1<-data.frame(data1[index, ])
916 dim(data1)
917 #View(data1)
918 summary(data1)#se eliminaron 3 observaciones
919

```

```

920 #####Curva ROC#####
921 datos<-data1
922 betas<- CadenasRealSinOutliers
923 dim(betas)
924 head(betas)
925 betas <- betas %>% select (-X)
926 View(betas)
927 summary(betas)
928 a<-mean(betas[,13]);a
929 b<-mean(betas[,1]);b
930 c<-mean(betas[,2]);c
931 d<-mean(betas[,3]);d
932 e<-mean(betas[,4]);e
933 f<-mean(betas[,5]);f
934 g<-mean(betas[,6]);g
935 h<-mean(betas[,7]);h
936 i<-mean(betas[,8]);i
937 j<-mean(betas[,9]);j
938 k<-mean(betas[,10]);k
939 l<-mean(betas[,11]);l
940 m<-mean(betas[,12]);m
941
942 head(datos)
943 y<-datos$rrl          #observados
944 x1<-datos$A.1.1.
945 x2<-datos$A.1.2.
946 x3<-datos$A.1.3.
947 x4<-datos$PH.1.2.
948 x5<-datos$PH.1.3.
949 x6<-datos$PH.1.4.
950 x7<-datos$f1
951 x8<-datos$P1
952 x9<-datos$s
953 x10<-datos$p2p_s2p
954 x11<-datos$p2p_spfom
955 x12<-datos$R1
956
957 n=18806
958 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10+l*x11+m*x12
959 pr = 1/(1+exp(-z))
960 k = rbinom(n,1,pr)      #predichos
961
962 roc_model=roc(y, k,ci=T,auc=T)
963 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
964          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
965          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
966 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
967 points(x=coordenada$specificity,
968        y=coordenada$sensitivity,
969        pch=0,col="red")
970
971 #####Análisis de sensibilidad y especificidad #####
972 estimados=ifelse(test=k>0.5, yes=1, no=0)
973 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
974 tabla

```

```

975 mosaic(tabla, shade = T, colorize = T,
976         gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
977
978 sensi=15750/(15750+777) ; sensi
979 espec=1507/(772+1507) ; espec
980 capa=(15750+1507)/18802 ; capa
981
982 #####
983
984 # Paso 2: Ajustar el modelo a los datos
985 datos_jags1 = list(y = data1$rrl, x1 = data1$A.1.1., x2 = data1$A.1.2., x3 = data1$A.1.3.,
986                  x4 = data1$PH.1.2., x5 = data1$PH.1.3., x6 = data1$PH.1.4., x7 = data1$f1
987                  ↪ , x8 = data1$P1, x9 = data1$s,
988                  x10 = data1$p2p_s2p, x11 = data1$p2p_spfom, x12 = data1$R1)
989 param1 = c('beta0','beta')
990 modelo_ajustado1 = jags.model(textConnection(modelo_bayesiano1), data = datos_jags1,
991                               n.chains = 1)#n.chains la cantidad de veces que corre la cadena#
992                               ↪ modelo parte por defecto desde 1000
993
994 # Paso 3: MCMC
995 cadenas1<- coda.samples(model=modelo_ajustado1, variable.names=param1, n.iter=18806,
996                        ↪ thin = 1)
997 muestra.posterior.sinoutliers=do.call(rbind, cadenas1)
998 #Exportar algunos objetos de R
999 #df<-as.data.frame(muestra.posterior.sinoutliers)
1000 #dfr<-write.csv(df, "CadenasRealSinOutliers")
1001
1002 # Paso 4: Analisis de convergencia.
1003 mat <- matrix(c(1, 2, # Primero, segundo
1004                3, 4,
1005                5,6), # y tercer gráfico
1006              nrow = 3, ncol = 2,
1007              byrow = TRUE)
1008
1009 layout(mat = mat)
1010
1011 ts.plot(muestra.posterior.sinoutliers[,13],ylab="Beta0")
1012 ts.plot(muestra.posterior.sinoutliers[,1],ylab="Beta1")
1013 ts.plot(muestra.posterior.sinoutliers[,2],ylab="Beta2")
1014 ts.plot(muestra.posterior.sinoutliers[,3],ylab="Beta3")#en los primeros 4 beta se decide
1015 ↪ quedar las 5000 primeras
1016 ts.plot(muestra.posterior.sinoutliers[,4],ylab="Beta4")
1017 ts.plot(muestra.posterior.sinoutliers[,5],ylab="Beta5")
1018 ts.plot(muestra.posterior.sinoutliers[,6],ylab="Beta6")
1019 ts.plot(muestra.posterior.sinoutliers[,7],ylab="Beta7")
1020 ts.plot(muestra.posterior.sinoutliers[,8],ylab="Beta8")
1021 ts.plot(muestra.posterior.sinoutliers[,9],ylab="Beta9")
1022 ts.plot(muestra.posterior.sinoutliers[,10],ylab="Beta10")
1023 ts.plot(muestra.posterior.sinoutliers[,11],ylab="Beta11")
1024 ts.plot(muestra.posterior.sinoutliers[,12],ylab="Beta12")
1025
1026 #para beta
1027 acf(ts(muestra.posterior.sinoutliers[,13])#autocorrelacion desaparece en lag pasado 35

```



```

1026 acf(ts(muestra.posterior.sinoutliers)[,1])#pasado 35
1027 acf(ts(muestra.posterior.sinoutliers)[,2])#pasado35
1028 acf(ts(muestra.posterior.sinoutliers)[,3])#pasado 35
1029 acf(ts(muestra.posterior.sinoutliers)[,4])#pasado 35
1030 acf(ts(muestra.posterior.sinoutliers)[,5])# en la 7 y las demas no tienen
1031 acf(ts(muestra.posterior.sinoutliers)[,6])
1032 acf(ts(muestra.posterior.sinoutliers)[,7])
1033 acf(ts(muestra.posterior.sinoutliers)[,8])
1034 acf(ts(muestra.posterior.sinoutliers)[,9])
1035 acf(ts(muestra.posterior.sinoutliers)[,10])
1036 acf(ts(muestra.posterior.sinoutliers)[,11])
1037 acf(ts(muestra.posterior.sinoutliers)[,12])
1038
1039 summary(cadenas1)#se eliminan A.1.1 A.1.2
1040 HPDinterval(as.mcmc(muestra.posterior1))
1041
1042 #####Eliminación de outliers 2#####
1043 data1 <- TrainingVWV_RRL2
1044 data1<-as.data.frame(data1)
1045
1046 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
      ↪ observacion 20 en las variables A.1.i
1047 data1[index, ]
1048 data1<-data.frame(data1[index, ])
1049 dim(data1)
1050 #View(data1)
1051 summary(data1)#se eliminaron 7 observaciones
1052
1053 #####Curva ROC#####
1054 datos<-data1
1055 betas<- CadenasRealFinalSinOutliers2
1056 dim(betas)
1057 head(betas)
1058 betas <- betas %>% select (-X)
1059 dim(betas)
1060 #View(betas)
1061 summary(betas)
1062 a<-mean(betas[,13]);a
1063 b<-mean(betas[,1]);b
1064 c<-mean(betas[,2]);c
1065 d<-mean(betas[,3]);d
1066 e<-mean(betas[,4]);e
1067 f<-mean(betas[,5]);f
1068 g<-mean(betas[,6]);g
1069 h<-mean(betas[,7]);h
1070 i<-mean(betas[,8]);i
1071 j<-mean(betas[,9]);j
1072 l<-mean(betas[,10]);l
1073 m<-mean(betas[,11]);m
1074 o<-mean(betas[,12]);o
1075
1076 head(datos)
1077 y<-datos$rll #observados
1078 x1<-datos$A.1.1.
1079 x2<-datos$A.1.2.

```

```

1080 x3<-datos$A.1.3.
1081 x4<-datos$PH.1.2.
1082 x5<-datos$PH.1.3.
1083 x6<-datos$PH.1.4.
1084 x7<-datos$f1
1085 x8<-datos$P1
1086 x9<-datos$s
1087 x10<-datos$p2p_s2p
1088 x11<-datos$p2p_spfom
1089 x12<-datos$R1
1090
1091 n=18802
1092 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+l*x10+m*x11+o*x12
1093 pr = 1/(1+exp(-z))
1094 k = rbinom(n,1,pr)      #predichos
1095
1096 roc_model=roc(y, k,ci=T,auc=T)
1097 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
1098         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
1099         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
1100 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
1101 points(x=coordenada$specificity,
1102        y=coordenada$sensitivity,
1103        pch=0,col="red")
1104
1105 ##### Analisis de sensibilidad y especificidad #####
1106 estimados=ifelse(test=k>0.5, yes=1, no=0)
1107 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
1108 tabla
1109 mosaic(tabla, shade = T, colorize = T,
1110        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
1111
1112 sensi=15750/(15725+767) ; sensi
1113 espec=1511/(768+1511) ; espec
1114 capa=(15765+1511)/18802 ; capa
1115
1116 #####
1117
1118 # Paso 2: Ajustar el modelo a los datos
1119 datos_jags1 = list(y = data1$rrl, x1 = data1$A.1.1. , x2 = data1$A.1.2., x3 = data1$A.1.3.,
1120                  x4 = data1$PH.1.2., x5 = data1$PH.1.3., x6 = data1$PH.1.4. , x7 = data1$f1
1121                  ↪ , x8 =data1$P1 , x9 = data1$s,
1122                  x10 = data1$p2p_s2p , x11 = data1$p2p_spfom , x12 = data1$R1)
1123 param1 = c('beta0','beta')
1124 modelo_ajustado1 = jags.model(textConnection(modelo_bayesiano1), data = datos_jags1,
1125                               n.chains = 1)
1126
1127 # Paso 3: MCMC
1128 cadenas1<- coda.samples(model=modelo_ajustado1, variable.names=param1, n.iter=18802,
1129                          ↪ thin = 1)
1130 muestra.posterior.sinoutliers=do.call(rbind, cadenas1)
1131 #Exportar algunos objetos de R
1132 df<-as.data.frame(muestra.posterior.sinoutliers1)
1133 dfr<-write.csv(df, "CadenasRealSinOutliers1")
1134

```

```

1133 # Paso 4: Analisis de convergencia.
1134 mat <- matrix(c(1, 2, # Primero, segundo
1135               3, 4,
1136               5,6), # y tercer gráfico
1137              nrow = 3, ncol = 2,
1138              byrow = TRUE)
1139
1140 layout(mat = mat)
1141
1142
1143 ts.plot(muestra.posterior.sinoutliers[,13],ylab="Beta0")
1144 ts.plot(muestra.posterior.sinoutliers[,1],ylab="Beta1")
1145 ts.plot(muestra.posterior.sinoutliers[,2],ylab="Beta2")
1146 ts.plot(muestra.posterior.sinoutliers[,3],ylab="Beta3")#en los primeros 4 beta se decide
    ↪ quedar las 5000 primeras
1147 ts.plot(muestra.posterior.sinoutliers[,4],ylab="Beta4")
1148 ts.plot(muestra.posterior.sinoutliers[,5],ylab="Beta5")
1149 ts.plot(muestra.posterior.sinoutliers[,6],ylab="Beta6")
1150 ts.plot(muestra.posterior.sinoutliers[,7],ylab="Beta7")
1151 ts.plot(muestra.posterior.sinoutliers[,8],ylab="Beta8")
1152 ts.plot(muestra.posterior.sinoutliers[,9],ylab="Beta9")
1153 ts.plot(muestra.posterior.sinoutliers[,10],ylab="Beta10")
1154 ts.plot(muestra.posterior.sinoutliers[,11],ylab="Beta11")
1155 ts.plot(muestra.posterior.sinoutliers[,12],ylab="Beta12")
1156 #Exportar algunos objetos de R
1157 df<-as.data.frame(muestra.posterior.sinoutliers)
1158 dfr<-write.csv(df, "CadenasRealFinalSinOutliers2")
1159
1160 #para beta
1161 acf(ts(muestra.posterior.sinoutliers[,13])#autocorrelacion desaparece en lag pasado 35
1162 acf(ts(muestra.posterior.sinoutliers[,1])#pasado 35
1163 acf(ts(muestra.posterior.sinoutliers[,2])#pasado35
1164 acf(ts(muestra.posterior.sinoutliers[,3])#pasado 35
1165 acf(ts(muestra.posterior.sinoutliers[,4])#pasado 35
1166 acf(ts(muestra.posterior.sinoutliers[,5])# en la 7 y las demas no tienen
1167 acf(ts(muestra.posterior.sinoutliers[,6])
1168 acf(ts(muestra.posterior.sinoutliers[,7])
1169 acf(ts(muestra.posterior.sinoutliers[,8])
1170 acf(ts(muestra.posterior.sinoutliers[,9])
1171 acf(ts(muestra.posterior.sinoutliers[,10])
1172 acf(ts(muestra.posterior.sinoutliers[,11])
1173 acf(ts(muestra.posterior.sinoutliers[,12])
1174
1175 summary(cadenas1)#se eliminan A.1.1 A.1.2 ya que cont el 0
1176 HPDinterval(as.mcmc(muestra.posterior1))
1177
1178 #####Eliminacion de outliers y variables A.1.1 y A.1.2#####
1179 data1<-TrainingVVV_RRL2
1180 data1<-as.data.frame(data1)
1181 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i
1182 data1[index, ]
1183 data1<-data.frame(data1[index, ])
1184 dim(data1)
1185 a<-data1

```

```

1186 head(data1)
1187
1188 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
  ↪ s2p, a$p2p_spfom, a$R1)
1189 head(data2)
1190 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
  ↪ spfom","R1")
1191 head(data2)
1192
1193 modelo_bayesiano2 = 'model{
1194   for(i in 1:length(y)){
1195     y[i] ~ dbern(p[i])
1196     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i] + beta[3]*x3[i] +
1197       beta[4]*x4[i] + beta[5]*x5[i] + beta[6]*x6[i] + beta[7]*x7[i] + beta[8]*x8[i] + beta[9]*x9
  ↪ [i] + beta[10]*x10[i]
1198   }
1199   beta0 ~ dnorm(0, 0.000001)
1200   for(j in 1:10){
1201     beta[j] ~ dnorm(0, 0.000001)
1202   }
1203 }'
1204
1205 # Paso 2: Ajustar el modelo a los datos
1206 datos_jags2 = list(y = data2$rrl, x1 = data2$A.1.3.,
1207   x2 = data2$PH.1.2. , x3 = data2$PH.1.3. , x4 = data2$PH.1.4. , x5 = data2$
  ↪ f1 , x6 =data2$P1 , x7 = data2$s,
1208   x8 = data2$p2p_s2p , x9 = data2$p2p_spfom , x10 = data2$R1)
1209 param1 = c('beta0','beta')
1210 modelo_ajustado2 = jags.model(textConnection(modelo_bayesiano2), data = datos_jags2,
1211   n.chains = 1)#n.chains la cantidad de veces que corre la cadena#
  ↪ modelo parte por defecto desde 1000
1212
1213 # Paso 3: MCMC
1214 cadenas1<- coda.samples(model=modelo_ajustado2, variable.names=param1, n.iter=18802,
  ↪ thin = 1)
1215 muestra.posterior.sinoutliers=do.call(rbind, cadenas1)
1216
1217 #Exportar algunos objetos de R
1218 df<-as.data.frame(muestra.posterior.sinoutliers)
1219 dfr<-write.csv(df, "CadenasRealFinalSinOutliersSinVariables")
1220
1221 # Paso 4: Analisis de convergencia.
1222 mat <- matrix(c(1, 2, # Primero, segundo
1223   3, 4,
1224   5,6), # y tercer gráfico
1225   nrow = 3, ncol = 2,
1226   byrow = TRUE)
1227
1228 layout(mat = mat)
1229 head(muestra.posterior.sinoutliers)
1230
1231 ts.plot(muestra.posterior.sinoutliers[,11],ylab="Beta0")
1232 ts.plot(muestra.posterior.sinoutliers[,1],ylab="Beta1")
1233 ts.plot(muestra.posterior.sinoutliers[,2],ylab="Beta2")
1234 ts.plot(muestra.posterior.sinoutliers[,3],ylab="Beta3")#en los primeros 4 beta se decide

```

```

    ↪ quedar las 5000 primeras
1235 ts.plot(muestra.posterior.sinoutliers[,4],ylab="Beta4")
1236 ts.plot(muestra.posterior.sinoutliers[,5],ylab="Beta5")
1237 ts.plot(muestra.posterior.sinoutliers[,6],ylab="Beta6")
1238 ts.plot(muestra.posterior.sinoutliers[,7],ylab="Beta7")
1239 ts.plot(muestra.posterior.sinoutliers[,8],ylab="Beta8")
1240 ts.plot(muestra.posterior.sinoutliers[,9],ylab="Beta9")
1241 ts.plot(muestra.posterior.sinoutliers[,10],ylab="Beta10")
1242 #Exportar algunos objetos de R
1243 df<-as.data.frame(muestra.posterior.sinoutliers)
1244 dfr<-write.csv(df, "CadenasRealFinalSinOutliers2")
1245
1246 #para beta
1247 acf(ts(muestra.posterior.sinoutliers[,11])#autocorrelacion desaparece en lag pasado 35
1248 acf(ts(muestra.posterior.sinoutliers[,1])#pasado 35
1249 acf(ts(muestra.posterior.sinoutliers[,2])#pasado35
1250 acf(ts(muestra.posterior.sinoutliers[,3])#pasado 35
1251 acf(ts(muestra.posterior.sinoutliers[,4])#pasado 35
1252 acf(ts(muestra.posterior.sinoutliers[,5])# en la 7 y las demas no tienen
1253 acf(ts(muestra.posterior.sinoutliers[,6])
1254 acf(ts(muestra.posterior.sinoutliers[,7])
1255 acf(ts(muestra.posterior.sinoutliers[,8])
1256 acf(ts(muestra.posterior.sinoutliers[,9])
1257 acf(ts(muestra.posterior.sinoutliers[,10])
1258
1259 summary(cadenas1)#todas las variables significativas
1260 HPDinterval(as.mcmc(muestra.posterior1))
1261
1262 #####Curva ROC#####
1263 data1<-TrainingVVV__RRL2
1264 data1<-as.data.frame(data1)
1265 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i
1266 data1[index, ]
1267 data1<-data.frame(data1[index, ])
1268 dim(data1)
1269 a<-data1
1270 head(data1)
1271
1272 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
    ↪ s2p, a$p2p_spfom, a$R1)
1273 head(data2)
1274 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
    ↪ spfom","R1")
1275 head(data2)
1276
1277 datos<-data2
1278 betas<- CadenasRealFinalSinOutliersSinVariables
1279 dim(betas)
1280 dim(datos)
1281 head(betas)
1282 betas <- betas %>% select (-X)
1283 dim(betas)
1284 #View(betas)
1285 summary(betas)

```

```

1286 a<-mean(betas[,11]);a
1287 b<-mean(betas[,1]);b
1288 c<-mean(betas[,2]);c
1289 d<-mean(betas[,3]);d
1290 e<-mean(betas[,4]);e
1291 f<-mean(betas[,5]);f
1292 g<-mean(betas[,6]);g
1293 h<-mean(betas[,7]);h
1294 i<-mean(betas[,8]);i
1295 j<-mean(betas[,9]);j
1296 l<-mean(betas[,10]);l
1297
1298 head(datos)
1299 y<-datos$rrl          #observados
1300 x1<-datos$A.1.3.
1301 x2<-datos$PH.1.2.
1302 x3<-datos$PH.1.3.
1303 x4<-datos$PH.1.4.
1304 x5<-datos$ff1
1305 x6<-datos$P1
1306 x7<-datos$s
1307 x8<-datos$p2p_s2p
1308 x9<-datos$p2p_spfom
1309 x10<-datos$R1
1310
1311 n=18802
1312 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+l*x10
1313 pr = 1/(1+exp(-z))
1314 k = rbinom(n,1,pr)      #predichos
1315
1316 roc_model=roc(y, k,ci=T, auc=T)
1317 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
1318          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
1319          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
1320 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
1321 points(x=coordenada$specificity,
1322        y=coordenada$sensitivity,
1323        pch=0,col="red")
1324
1325 ##### Analisis de sensibilidad y especificidad #####
1326 estimados=ifelse(test=k>0.5, yes=1, no=0)
1327 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
1328 tabla
1329 mosaic(tabla, shade = T, colorize = T,
1330        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
1331
1332 sensi=15736/(15736+787) ; sensi
1333 espec=1505/(774+1505) ; espec
1334 capa=(15736+1505)/18802 ; capa
1335
1336 #####Eliminacion de outliers 2 y eliminacion de variables A.1.1 y A.1.2 y gamma#####
1337 data1<-TrainingVVV_RRL2
1338 data1<-as.data.frame(data1)
1339 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i

```

```

1340 data1[index, ]
1341 data1<-data.frame(data1[index, ])
1342 dim(data1)
1343 a<-data1
1344 head(data1)
1345
1346 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
  ↪ s2p, a$p2p_spfom, a$R1)
1347 head(data2)
1348 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
  ↪ spfom","R1")
1349 head(data2)
1350
1351 modelo_bayesiano2 = 'model{
1352   for(i in 1:length(y)){
1353     y[i] ~ dbern(p[i])
1354     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i] + beta[3]*x3[i] +
1355       beta[4]*x4[i] + beta[5]*x5[i] + beta[6]*x6[i] + beta[7]*x7[i] + beta[8]*x8[i] + beta[9]*x9
  ↪ [i] + beta[10]*x10[i]
1356   }
1357   beta0 ~ dnorm(0, 1/sig20)
1358   sig20 ~ dgamma(0.1,0.1)
1359   for(j in 1:10){
1360     sig2[j] ~ dgamma(0.01, 0.01)
1361     beta[j] ~ dnorm(0, 1/sig2[j])
1362   }
1363
1364 }'
1365
1366 # Paso 2: Ajustar el modelo a los datos
1367 datos_jags2 = list(y = data2$rrl, x1 = data2$A.1.3.,
1368   x2 = data2$PH.1.2. , x3 = data2$PH.1.3. , x4 = data2$PH.1.4. , x5 = data2$
  ↪ f1 , x6 =data2$P1 , x7 = data2$s,
1369   x8 = data2$p2p_s2p , x9 = data2$p2p_spfom , x10 = data2$R1)
1370 param1 = c('beta0','beta',"sig20","sig2")
1371 modelo_ajustado2 = jags.model(textConnection(modelo_bayesiano2), data = datos_jags2,
1372   n.chains = 1)#n.chains la cantidad de veces que corre la cadena#
  ↪ modelo parte por defecto desde 1000
1373
1374 # Paso 3: MCMC
1375 cadenas1<- coda.samples(model=modelo_ajustado2, variable.names=param1, n.iter=18802,
  ↪ thin = 1)
1376 muestra.posteriororg=do.call(rbind, cadenas1)
1377
1378 #Exportar algunos objetos de R
1379 df<-as.data.frame(muestra.posteriororg)
1380 dfr<-write.csv(df, "CadenasRealFinalSinOutliersSinVariablesGamma.csv")
1381
1382 # Paso 4: Analisis de convergencia.
1383 mat <- matrix(c(1, 2, # Primero, segundo
1384   3, 4,
1385   5,6), # y tercer gráfico
1386   nrow = 3, ncol = 2,
1387   byrow = TRUE)
1388

```

```

1389 layout(mat = mat)
1390 head(muestra.posterior.sinoutliers)
1391
1392
1393 ts.plot(muestra.posterior.sinoutliers[,11],ylab="Beta0")
1394 ts.plot(muestra.posterior.sinoutliers[,1],ylab="Beta1")
1395 ts.plot(muestra.posterior.sinoutliers[,2],ylab="Beta2")
1396 ts.plot(muestra.posterior.sinoutliers[,3],ylab="Beta3")#en los primeros 4 beta se decide
    ↪ quedar las 5000 primeras
1397 ts.plot(muestra.posterior.sinoutliers[,4],ylab="Beta4")
1398 ts.plot(muestra.posterior.sinoutliers[,5],ylab="Beta5")
1399 ts.plot(muestra.posterior.sinoutliers[,6],ylab="Beta6")
1400 ts.plot(muestra.posterior.sinoutliers[,7],ylab="Beta7")
1401 ts.plot(muestra.posterior.sinoutliers[,8],ylab="Beta8")
1402 ts.plot(muestra.posterior.sinoutliers[,9],ylab="Beta9")
1403 ts.plot(muestra.posterior.sinoutliers[,10],ylab="Beta10")
1404
1405 #para beta
1406 acf(ts(muestra.posterior.sinoutliers[,11])#autocorrelacion desaparece en lag pasado 35
1407 acf(ts(muestra.posterior.sinoutliers[,1])#pasado 35
1408 acf(ts(muestra.posterior.sinoutliers[,2])#pasado35
1409 acf(ts(muestra.posterior.sinoutliers[,3])#pasado 35
1410 acf(ts(muestra.posterior.sinoutliers[,4])#pasado 35
1411 acf(ts(muestra.posterior.sinoutliers[,5])# en la 7 y las demas no tienen
1412 acf(ts(muestra.posterior.sinoutliers[,6])
1413 acf(ts(muestra.posterior.sinoutliers[,7])
1414 acf(ts(muestra.posterior.sinoutliers[,8])
1415 acf(ts(muestra.posterior.sinoutliers[,9])
1416 acf(ts(muestra.posterior.sinoutliers[,10])
1417
1418 summary(cadenas1)#todas las variables significativas
1419 HPDinterval(as.mcmc(muestra.posterior1))
1420
1421 ##### Analisis de convergencia#####
1422 data1<-TrainingVVV_RRL2
1423 data1<-as.data.frame(data1)
1424 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i
1425 data1[index, ]
1426 data1<-data.frame(data1[index, ])
1427 dim(data1)
1428 a<-data1
1429 head(data1)
1430
1431 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
    ↪ s2p, a$p2p_spfom, a$R1)
1432 head(data2)
1433 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
    ↪ spfom","R1")
1434 head(data2)
1435
1436 datos<-data2
1437 dim(datos)
1438 CadenasReal5<-CadenasRealFinalSinOutliersSinVariablesGamma
1439 betas<- CadenasReal5

```



```

1440
1441 #betas<-select(betas, -X)
1442 dim(betas)
1443 head(betas)
1444 betas <- betas %>% select (-X.1)
1445 View(betas)
1446 summary(betas)
1447
1448 mat <- matrix(c(1, 2, # Primero, segundo
1449                3, 4,
1450                5,6), # y tercer gráfico
1451                nrow = 3, ncol = 2,
1452                byrow = TRUE)
1453
1454 layout(mat = mat)
1455
1456
1457 ts.plot(betas[,1],ylab="Beta0")
1458 ts.plot(betas[,2],ylab="Beta1")
1459 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
1460 ts.plot(betas[,4],ylab="Beta3")
1461 ts.plot(betas[,5],ylab="Beta4")
1462 ts.plot(betas[,6],ylab="Beta5")
1463 ts.plot(betas[,7],ylab="Beta6")
1464 ts.plot(betas[,8],ylab="Beta7")
1465 ts.plot(betas[,9],ylab="Beta8")
1466 ts.plot(betas[,10],ylab="Beta9")
1467 ts.plot(betas[,11],ylab="Beta10")
1468 ts.plot(betas[,12],ylab="Sigma0")
1469 ts.plot(betas[,13],ylab="Sigma1")
1470 ts.plot(betas[,14],ylab="Sigma2")
1471 ts.plot(betas[,15],ylab="Sigma3")
1472 ts.plot(betas[,16],ylab="Sigma4")
1473 ts.plot(betas[,17],ylab="Sigma5")
1474 ts.plot(betas[,18],ylab="Sigma6")
1475 ts.plot(betas[,19],ylab="Sigma7")
1476 ts.plot(betas[,20],ylab="Sigma8")
1477 ts.plot(betas[,20],ylab="Sigma9")
1478 ts.plot(betas[,20],ylab="Sigma10")
1479
1480 #para beta
1481 acf(ts(betas)[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
1482 acf(ts(betas)[,2],main="beta1")
1483 acf(ts(betas)[,3],main="beta2")
1484 acf(ts(betas)[,4],main="beta3")
1485 acf(ts(betas)[,5],main="beta4")
1486 acf(ts(betas)[,6],main="beta5")
1487 acf(ts(betas)[,7],main="beta6")
1488 acf(ts(betas)[,8],main="beta7")
1489 acf(ts(betas)[,9],main="beta8")
1490 acf(ts(betas)[,10],main="beta9")
1491 acf(ts(betas)[,11],main="beta10")
1492 acf(ts(betas)[,12],main="Sigma0")
1493 acf(ts(betas)[,12],main="Sigma1")
1494 acf(ts(betas)[,12],main="Sigma2")

```

```

1495 acf(ts(betas)[,12],main="Sigma3")
1496 acf(ts(betas)[,12],main="Sigma4")
1497 acf(ts(betas)[,12],main="Sigma5")
1498 acf(ts(betas)[,12],main="Sigma6")
1499 acf(ts(betas)[,12],main="Sigma7")
1500 acf(ts(betas)[,12],main="Sigma8")
1501 acf(ts(betas)[,12],main="Sigma9")
1502 acf(ts(betas)[,12],main="Sigma10")
1503
1504 head(betas)
1505 #####Curva ROC#####
1506 a<-mean(betas[,1]);a
1507 b<-mean(betas[,2]);b
1508 c<-mean(betas[,3]);c
1509 d<-mean(betas[,4]);d
1510 e<-mean(betas[,5]);e
1511 f<-mean(betas[,6]);f
1512 g<-mean(betas[,7]);g
1513 h<-mean(betas[,8]);h
1514 i<-mean(betas[,9]);i
1515 j<-mean(betas[,10]);j
1516 k<-mean(betas[,11]);k
1517
1518 head(datos)
1519 dim(betas)
1520 dim(datos)
1521 y<-datos$rrl          #observados
1522 x1<-datos$A.1.3.
1523 x2<-datos$PH.1.2.
1524 x3<-datos$PH.1.3.
1525 x4<-datos$PH.1.4.
1526 x5<-datos$f1
1527 x6<-datos$P1
1528 x7<-datos$s
1529 x8<-datos$p2p_s2p
1530 x9<-datos$p2p_spfom
1531 x10<-datos$R1
1532
1533 ndatos=18802
1534 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10
1535 pr = 1/(1+exp(-z))
1536 kp = rbinom(18802,1,pr)      #predichos
1537
1538 roc_model=roc(y, kp ,ci=T, auc=T)
1539 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
1540          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
1541          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
1542 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
1543 points(x=coordenada$specificity,
1544        y=coordenada$sensitivity,
1545        pch=0,col="red")
1546
1547 #####Análisis de sensibilidad y especificidad #####
1548 estimados=ifelse(test=kp>0.5, yes=1, no=0)
1549 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))

```

```

1550 tabla
1551 mosaic(tabla, shade = T, colorize = T,
1552         gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
1553
1554 sensi=15738/(15738+785) ; sensi
1555 espec=1500/(779+1500) ; espec
1556 capa=(15738+1500)/18802 ; capa
1557
1558
1559 #####Eliminacion de outliers 2 y eliminacion de variables A.1.1 y A.1.2 y gamma inversa
1560     ↪ #####
1561 data1<-TrainingVVV_RRL22 %>% select (-...1)
1562
1563 data1<-as.data.frame(data1)
1564 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
1565     ↪ observacion 20 en las variables A.1.i
1566 data1[index, ]
1567 data1<-data.frame(data1[index, ])
1568 dim(data1)
1569 a<-data1
1570 head(data1)
1571
1572 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
1573     ↪ s2p, a$p2p_spfom, a$R1)
1574 head(data2)
1575 names(data2)=c("rrl", "A.1.3.", "PH.1.2.", "PH.1.3.", "PH.1.4.", "f1", "P1", "s", "p2p_s2p", "p2p_
1576     ↪ spfom", "R1")
1577 head(data2)
1578 dim(data2)
1579
1580 #Exportar algunos objetos de R
1581 dfr<-write.csv(data2, "TrainingVVV_RRL22.csv")
1582
1583 modelo_bayesiano2 = 'model{
1584   for(i in 1:length(y)){
1585     y[i] ~ dbern(p[i])
1586     logit(p[i]) = beta0 + beta[1]*x1[i] + beta[2]*x2[i] + beta[3]*x3[i] +
1587       beta[4]*x4[i] + beta[5]*x5[i] + beta[6]*x6[i] + beta[7]*x7[i] + beta[8]*x8[i] + beta[9]*x9
1588     ↪ [i] + beta[10]*x10[i]
1589   }
1590   beta0 ~ dnorm(0, 1/sig20)
1591   sig20 ~ dgamma(0.1,0.1)
1592   for(j in 1:10){
1593     sig2[j] ~ dgamma(0.01, 0.01)
1594     gi <- 1/sig2[j]
1595     beta[j] ~ dnorm(0, gi)
1596   }
1597 }'
1598
1599 # Paso 2: Ajustar el modelo a los datos
1600 datos_jags2 = list(y = data2$rrl, x1 = data2$A.1.3.,
1601                   x2 = data2$PH.1.2., x3 = data2$PH.1.3., x4 = data2$PH.1.4., x5 = data2$
1602                   ↪ f1, x6 =data2$P1, x7 = data2$s,
1603                   x8 = data2$p2p_s2p, x9 = data2$p2p_spfom, x10 = data2$R1)

```

```

1599 param1 = c('beta0','beta',"sig20","sig2")
1600 modelo_ajustado2 = jags.model(textConnection(modelo_bayesiano2), data = datos_jags2,
1601                               n.chains = 1)#n.chains la cantidad de veces que corre la cadena#
    ↪ modelo parte por defecto desde 1000
1602
1603 # Paso 3: MCMC
1604 cadenas1<- coda.samples(model=modelo_ajustado2, variable.names=param1, n.iter=18802,
    ↪ thin = 1)
1605 muestra.posteriororg=do.call(rbind, cadenas1)
1606
1607 #Exportar algunos objetos de R
1608 df<-as.data.frame(muestra.posteriororg)
1609 dfr<-write.csv(df, "CadenasRealFinal6.txt")
1610
1611
1612 ##### Analisis de convergencia#####
1613 data1<-TrainingVVV_RRL2
1614 data1<-as.data.frame(data1)
1615 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i
1616 data1[index, ]
1617 data1<-data.frame(data1[index, ])
1618 dim(data1)
1619 a<-data1
1620 head(data1)
1621
1622 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
    ↪ s2p, a$p2p_spfom, a$R1)
1623 head(data2)
1624 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
    ↪ spfom","R1")
1625 head(data2)
1626
1627 datos<-data1
1628 dim(datos)
1629 CadenasRealFinal6 <- read_csv("C:/Users/56992/Desktop/CadenasRealFinal6.txt")
1630 CadenasRealFinal6<-CadenasRealFinal6 %>% select (-...1)
1631 str(CadenasReal6)
1632 betas<- CadenasRealFinal6
1633
1634 #betas<-select(betas, -X)
1635 dim(betas)
1636 head(betas)
1637 betas <- betas %>% select (-X.1)
1638 View(betas)
1639 summary(betas)
1640
1641 mat <- matrix(c(1, 2, # Primero, segundo
1642                3, 4,
1643                5,6), # y tercer gráfico
1644              nrow = 3, ncol = 2,
1645              byrow = TRUE)
1646
1647 layout(mat = mat)
1648

```

```

1649
1650 ts.plot(betas[,1],ylab="Beta0")
1651 ts.plot(betas[,2],ylab="Beta1")
1652 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
1653 ts.plot(betas[,4],ylab="Beta3")
1654 ts.plot(betas[,5],ylab="Beta4")
1655 ts.plot(betas[,6],ylab="Beta5")
1656 ts.plot(betas[,7],ylab="Beta6")
1657 ts.plot(betas[,8],ylab="Beta7")
1658 ts.plot(betas[,9],ylab="Beta8")
1659 ts.plot(betas[,10],ylab="Beta9")
1660 ts.plot(betas[,11],ylab="Beta10")
1661 ts.plot(betas[,12],ylab="Sigma0")
1662 ts.plot(betas[,13],ylab="Sigma1")
1663 ts.plot(betas[,14],ylab="Sigma2")
1664 ts.plot(betas[,15],ylab="Sigma3")
1665 ts.plot(betas[,16],ylab="Sigma4")
1666 ts.plot(betas[,17],ylab="Sigma5")
1667 ts.plot(betas[,18],ylab="Sigma6")
1668 ts.plot(betas[,19],ylab="Sigma7")
1669 ts.plot(betas[,20],ylab="Sigma8")
1670 ts.plot(betas[,20],ylab="Sigma9")
1671 ts.plot(betas[,20],ylab="Sigma10")
1672
1673 #para beta
1674 acf(ts(betas)[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
1675 acf(ts(betas)[,2],main="beta1")
1676 acf(ts(betas)[,3],main="beta2")
1677 acf(ts(betas)[,4],main="beta3")
1678 acf(ts(betas)[,5],main="beta4")
1679 acf(ts(betas)[,6],main="beta5")
1680 acf(ts(betas)[,7],main="beta6")
1681 acf(ts(betas)[,8],main="beta7")
1682 acf(ts(betas)[,9],main="beta8")
1683 acf(ts(betas)[,10],main="beta9")
1684 acf(ts(betas)[,11],main="beta10")
1685 acf(ts(betas)[,12],main="Sigma0")
1686 acf(ts(betas)[,13],main="Sigma1")
1687 acf(ts(betas)[,14],main="Sigma2")
1688 acf(ts(betas)[,15],main="Sigma3")
1689 acf(ts(betas)[,16],main="Sigma4")
1690 acf(ts(betas)[,17],main="Sigma5")
1691 acf(ts(betas)[,18],main="Sigma6")
1692 acf(ts(betas)[,19],main="Sigma7")
1693 acf(ts(betas)[,20],main="Sigma8")
1694 acf(ts(betas)[,21],main="Sigma9")
1695 acf(ts(betas)[,22],main="Sigma10")
1696
1697 head(betas)
1698 #####Curva ROC#####
1699 betas<-as.data.frame(betas)
1700 a<-mean(betas[,11]);a
1701 b<-mean(betas[,1]);b
1702 c<-mean(betas[,2]);c
1703 d<-mean(betas[,3]);d

```

```

1704 e<-mean(betas[,4]);e
1705 f<-mean(betas[,5]);f
1706 g<-mean(betas[,6]);g
1707 h<-mean(betas[,7]);h
1708 i<-mean(betas[,8]);i
1709 j<-mean(betas[,9]);j
1710 k<-mean(betas[,10]);k
1711
1712 head(datos)
1713 dim(betas)
1714 dim(datos)
1715 y<-datos$rrl          #observados
1716 x1<-datos$A.1.3.
1717 x2<-datos$PH.1.2.
1718 x3<-datos$PH.1.3.
1719 x4<-datos$PH.1.4.
1720 x5<-datos$ff1
1721 x6<-datos$P1
1722 x7<-datos$s
1723 x8<-datos$p2p_s2p
1724 x9<-datos$p2p_spfom
1725 x10<-datos$R1
1726
1727 ndatos=18802
1728 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10
1729 pr = 1/(1+exp(-z))
1730 kp = rbinom(18802,1,pr)      #predichos
1731
1732 roc_model=roc(y, kp ,ci=T, auc=T)
1733 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
1734          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
1735          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
1736 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
1737 points(x=coordenada$specificity,
1738        y=coordenada$sensitivity,
1739        pch=0,col="red")
1740
1741 ##### Analisis de sensibilidad y especificidad #####
1742 estimados=ifelse(test=kp>0.5, yes=1, no=0)
1743 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
1744 tabla
1745 mosaic(tabla, shade = T, colorize = T,
1746        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
1747
1748 sensi=15738/(15738+785) ; sensi
1749 espec=1500/(779+1500) ; espec
1750 capa=(15738+1500)/18802 ; capa
1751
1752 #####
1753 #####
1754 #####
1755 #####RSTAN#####
1756
1757
1758 #####Datos Simulados#####

```

```

1759 data<-LogisticData
1760 data<-na.omit(data)
1761 View(data)
1762
1763 # Paso 1: especificar el modelo
1764 m1 <- '
1765 data {
1766   int<lower=0> N;           // number of observations
1767   int<lower=0,upper=1> y[N]; // setting the dependent variable (vote) as binary
1768   vector[N] x1;           // independent variable 1
1769   vector[N] x2;           // independent variable 2
1770 }
1771 parameters {
1772   real b0;                // intercept
1773   real b1;
1774   real b2;
1775 }
1776 model {
1777   y ~ bernoulli_logit(b0 + b1 * x1 + b2 * x2); // model
1778   b0 ~ normal(0,1000000); // you can set priors for all betas
1779   b1 ~ normal(0,1000000); // if you prefer not to, uniform priors will be used
1780   b2 ~ normal(0,1000000);
1781 }
1782 '
1783
1784 # Paso 2: Ajustar el modelo a los datos
1785 data.list = list(N = nrow(data), y = data$`"y"` , x1 = data$`"x1"` , x2 = data$`"x2"`)
1786 str(data.list)
1787
1788 # Paso 3: Estimar el modelo
1789 fit = stan(model_code = m1, data = data.list, iter = 11500, chains = 2, warmup = 1500)
1790 print(fit, digits = 3)
1791 summary(fit)
1792
1793 stan2coda <- function(fit) {
1794   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
1795 }
1796 fit.mcmc <- stan2coda(fit)
1797 muestra.posterior=do.call(rbind, fit.mcmc)
1798
1799 # Exportar algunos objetos de R
1800 dff<-as.data.frame(muestra.posterior)
1801 dfcf<-write.csv(dff, "CadenasSimuladosSTAN.txt")
1802
1803 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosSTAN.txt")
1804 str(muestra.posterior)
1805 muestra.posterior1<-muestra.posterior %>% select (-...1)
1806 str(muestra.posterior1)
1807 dim(muestra.posterior1)
1808
1809 muestra<-muestra.posterior1[1:10000,1:4]
1810 muestra1<-muestra.posterior1[10001:20000,1:4]
1811 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
1812
1813 summary(muestras)

```

```

1814 gelman.diag(muestras)
1815 effectiveSize(muestra.posterior1)
1816 HPDIinterval(muestras)
1817
1818 # Paso 4: Análisis de convergencia.
1819 #para beta0
1820 plot(muestra.posterior1[,1])
1821 ts.plot(muestra.posterior1[,1],ylab="Beta 0")#estacionario
1822 acf(ts(muestra.posterior1[,1]))#lag 4
1823 #para beta1
1824 plot(muestra.posterior1[,2])
1825 ts.plot(muestra.posterior1[,2],ylab="Beta 1")#estacionario
1826 acf(ts(muestra.posterior1[,2]))#lag 4
1827 #para beta2
1828 plot(muestra.posterior1[,3])
1829 ts.plot(muestra.posterior1[,3],ylab="Beta 2")#estacionario
1830 acf(ts(muestra.posterior1[,3]))#lag 3
1831
1832 # Paso 5: HMC Final
1833 fit = stan(model_code = m1, data = data.list, iter = 43500, chains = 2, warmup = 3500,
1834           ↪ thin = 4)
1834 print(fit, digits = 3)
1835 summary(fit)
1836
1837 stan2coda <- function(fit) {
1838   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
1839 }
1840 fit.mcmc <- stan2coda(fit)
1841 muestra.posterior=do.call(rbind, fit.mcmc)
1842
1843 # Exportar algunos objetos de R
1844 dff<-as.data.frame(muestra.posterior)
1845 dfcf<-write.csv(dff, "CadenasSimuladosFinalSTAN.txt")
1846
1847 muestra.posterior<-read_csv("C:/Users/56992/Desktop/JAGS Simu 1/
1848   ↪ CadenasSimulados1Final")
1848 str(muestra.posterior)
1849 muestra.posterior1<-muestra.posterior %>% select (1:4)
1850 str(muestra.posterior1)
1851 dim(muestra.posterior1)
1852
1853 muestra<-muestra.posterior1[1:10000,1:4]
1854 muestra1<-muestra.posterior1[10001:20000,1:4]
1855 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
1856
1857 summary(muestras)
1858 gelman.diag(muestras)
1859 effectiveSize(muestra.posterior1)
1860 HPDIinterval(muestras)
1861
1862
1863 #para beta0
1864 plot(muestra.posterior1[,3])
1865 ts.plot(muestra.posterior1[,3],ylab="Beta 0")
1866 acf(ts(muestra.posterior1[,3]))

```



```

1867 #para beta1
1868 plot(muestra.posterior1[,1])
1869 ts.plot(muestra.posterior1[,1],ylab="Beta 1")
1870 acf(ts(muestra.posterior1[,1]))
1871 #para beta1
1872 plot(muestra.posterior1[,2])
1873 ts.plot(muestra.posterior1[,2],ylab="Beta 2")
1874 acf(ts(muestra.posterior1[,2]))
1875
1876
1877 #####Curva Roc #####
1878 muestra.posterior<-as.data.frame(muestra.posterior1)
1879 data<-as.data.frame(LogisticData)
1880 a<-mean(muestra.posterior[,1]);a
1881 b<-mean(muestra.posterior[,2]);b
1882 c<-mean(muestra.posterior[,3]);c
1883 y<-data$y #observados
1884 x1<-data$x1
1885 x2<-data$x2
1886 n=10000
1887 z = a + b*x1 + c*x2 # linear combination with a bias
1888 pr = 1/(1+exp(-z)) # pass through an inv-logit function
1889 k = rbinom(n,1,pr) #predichos
1890
1891 roc_model=roc(y, k,ci=T,auc=T)
1892 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
1893 auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
1894 col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
1895 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
1896 points(x=coordenada$specificity,
1897 y=coordenada$sensitivity,
1898 pch=0,col="red")
1899 #####Análisis de sensibilidad y especificidad #####
1900 estimados=ifelse(test=k>0.5, yes=1, no=0)
1901 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
1902 tabla
1903 mosaic(tabla, shade = T, colorize = T,
1904 gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
1905
1906 sensi=2057/4019 ; sensi
1907 espec=5141/5981 ; espec
1908 acu=(2057+5141)/10000 ; acu
1909
1910 cambio=matrix(data=tabla,ncol=2 , byrow=FALSE) ; cambio
1911 BDtest(cambio, pr=0.56 ,conf.level = 0.95)
1912
1913
1914 #####Simulación con gamma#####
1915 LogisticData <- read_table("LogisticData.txt")
1916 # Paso 1: especificar el modelo
1917 m1 <- '
1918 data {
1919 int<lower=0> N; // number of observations
1920 int<lower=0,upper=1> y[N]; // setting the dependent variable (vote) as binary
1921 vector[N] x1; // independent variable 1

```

```

1922 vector[N] x2;          // independent variable 2
1923 }
1924 parameters {
1925   real b0;              // intercept
1926   real b1;
1927   real b2;
1928   real<lower=0> sig20;
1929   real<lower=0> sig21;
1930   real<lower=0> sig22;
1931 }
1932 model {
1933   y ~ bernoulli_logit(b0 + b1 * x1 + b2 * x2); // model
1934   b0 ~ normal(0,sqrt(sig20)); // you can set priors for all betas
1935   b1 ~ normal(0,sqrt(sig21)); // if you prefer not to, uniform priors will be used
1936   b2 ~ normal(0,sqrt(sig22));
1937   sig20 ~ gamma(0.01, 0.01);
1938   sig21 ~ gamma(0.01, 0.01);
1939   sig22 ~ gamma(0.01, 0.01);
1940 }
1941 '
1942 data<- LogisticData
1943 # Paso 2: Ajustar el modelo a los datos
1944 data.list = list(N = nrow(data), y = data$`"y"` , x1 = data$`"x1"` , x2 = data$`"x2"`)
1945 str(data.list)
1946
1947 # Paso 3: Estimar el modelo
1948 fit = stan(model_code = m1, data = data.list, iter = 11500, chains = 2, warmup = 11500)
1949 print(fit, digits = 3)
1950 summary(fit)
1951
1952 stan2coda <- function(fit) {
1953   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
1954 }
1955 fit.mcmc <- stan2coda(fit)
1956 muestra.posterior1=do.call(rbind, fit.mcmc)
1957 HPDinterval(as.mcmc(muestra.posterior1))
1958
1959 # Exportar algunos objetos de R
1960 df<-as.data.frame(muestra.posterior1)
1961 dfc<-write.csv(df, "CadenasSimuladosGammaStan.txt")
1962
1963 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosGammaStan.txt")
1964 #str(muestra.posterior)
1965 muestra.posterior1<-muestra.posterior %>% select (1:7)
1966 str(muestra.posterior1)
1967 dim(muestra.posterior1)
1968
1969 muestra<-muestra.posterior1[1:10000,1:7]
1970 muestra1<-muestra.posterior1[10001:20000,1:7]
1971 #dim(muestra1)
1972 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
1973
1974 gelman.diag(muestras)
1975 effectiveSize(muestra.posterior1)
1976 summary(muestras)

```

```

1977 HPDinterval(as.mcmc(muestra.posterior1))
1978 HPDinterval(muestras)
1979
1980 muestra.posterior<-muestra.posterior1
1981 #para beta0
1982 plot(muestra.posterior1[,1])
1983 ts.plot(muestra.posterior1[,1], ylab="Beta 0")
1984 acf(ts(muestra.posterior1[,1]))#lag1
1985 #para beta1
1986 plot(muestra.posterior1[,2])
1987 ts.plot(muestra.posterior1[,2], ylab="Beta 1")
1988 acf(ts(muestra.posterior1[,2]))#lag2
1989 #para beta3
1990 plot(muestra.posterior1[,3])
1991 ts.plot(muestra.posterior1[,3], ylab="Beta 2")
1992 acf(ts(muestra.posterior1[,3]))#lag2
1993
1994 #para sig20
1995 plot(muestra.posterior1[,4])
1996 ts.plot(muestra.posterior1[,4],ylab="Sigma2 Beta 0")
1997 acf(ts(muestra.posterior1[,4]))#lag2
1998 #para sig21
1999 plot(muestra.posterior1[,5])
2000 ts.plot(muestra.posterior1[,5],ylab="Sigma2 Beta 1")
2001 acf(ts(muestra.posterior1[,5]))#lag2-3
2002 #para sig23
2003 plot(muestra.posterior1[,6])
2004 ts.plot(muestra.posterior1[,6],ylab="Sigma2 Beta 2")
2005 acf(ts(muestra.posterior1[,6]))#lag2
2006
2007 # Paso 5: HMC Final
2008 fit = stan(model_code = m1, data = data.list, iter = 23000, chains = 2, warmup = 3000,
  ↪ thin = 2)
2009 print(fit, digits = 3)
2010 summary(fit)
2011
2012 stan2coda <- function(fit) {
2013   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2014 }
2015 fit.mcmc <- stan2coda(fit)
2016 muestra.posterior=do.call(rbind, fit.mcmc)
2017
2018 # Exportar algunos objetos de R
2019 dff<-as.data.frame(muestra.posterior)
2020 dfcf<-write.csv(dff, "CadenasSimuladosGammaFinalSTAN.txt")
2021
2022 muestra.posterior<-read_csv("C:/Users/56992/Desktop/
  ↪ CadenasSimuladosGammaFinalSTAN.txt")
2023 #str(muestra.posterior)
2024 muestra.posterior1<-muestra.posterior %>% select (-...1)
2025 str(muestra.posterior1)
2026
2027 muestra<-muestra.posterior1[1:10000,1:7]
2028 muestra1<-muestra.posterior1[10001:20000,1:7]
2029 dim(muestra1)

```

```

2030 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
2031
2032 gelman.diag(muestras)
2033 effectiveSize(muestra.posterior1)
2034 summary(muestras)
2035 HPDIinterval(as.mcmc(muestra.posterior1))
2036 HPDIinterval(muestras)
2037
2038 muestra.posterior<-muestra.posterior1
2039 str(muestra.posterior)
2040 #para beta1
2041 plot(muestra.posterior[,1])
2042 ts.plot(muestra.posterior[,1],ylab="Beta 0")
2043 acf(ts(muestra.posterior[,1]))
2044 #para beta1
2045 plot(muestra.posterior[,2])
2046 ts.plot(muestra.posterior[,2],ylab="Beta 1")
2047 acf(ts(muestra.posterior[,2]))
2048 #para beta3
2049 plot(muestra.posterior[,3])
2050 ts.plot(muestra.posterior[,3],ylab="Beta 2")
2051 acf(ts(muestra.posterior[,3]))
2052
2053 #para sig20
2054 plot(muestra.posterior1[,4])
2055 ts.plot(muestra.posterior1[,4],ylab="Sigma2 Beta 0")
2056 acf(ts(muestra.posterior1[,4]))#
2057 #para sig21
2058 plot(muestra.posterior1[,5])
2059 ts.plot(muestra.posterior1[,5],ylab="Sigma2 Beta 1")
2060 acf(ts(muestra.posterior1[,5]))#
2061 #para sig23
2062 plot(muestra.posterior1[,6])
2063 ts.plot(muestra.posterior1[,6],ylab="Sigma2 Beta 2")
2064 acf(ts(muestra.posterior1[,6]))#
2065
2066 #####Curva Roc #####
2067 muestra.posterior<-as.data.frame(muestra.posterior1)
2068 data<-as.data.frame(LogisticData)
2069 a<-mean(muestra.posterior[,1]);a
2070 b<-mean(muestra.posterior[,2]);b
2071 c<-mean(muestra.posterior[,3]);c
2072 y<-data$y           #observados
2073 x1<-data$x1
2074 x2<-data$x2
2075 n=10000
2076 z = a + b*x1 + c*x2      # linear combination with a bias
2077 pr = 1/(1+exp(-z))       # pass through an inv-logit function
2078 k = rbinom(n,1,pr)       #predichos
2079
2080 roc_model=roc(y, k,ci=T,auc=T)
2081 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
2082         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
2083         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
2084 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))

```

```

2085 points(x=coordenada$specificity,
2086         y=coordenada$sensitivity,
2087         pch=0,col="red")
2088 ##### Analisis de sensibilidad y especificidad #####
2089 estimados=ifelse(test=k>0.5, yes=1, no=0)
2090 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
2091 tabla
2092 mosaic(tabla, shade = T, colorize = T,
2093         gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
2094
2095 sensi=3057/4019 ; sensi
2096 espec=5012/5981 ; espec
2097 acu=(3057+5012)/10000 ; acu
2098
2099 cambio=matrix(data=tabla,ncol=2 , byrow=FALSE) ; cambio
2100 BDtest(cambio, pr=0.56 ,conf.level = 0.95)
2101
2102
2103
2104 ##### Simulación con gamma inversa #####
2105 LogisticData <- read_table("LogisticData.txt")
2106 # Paso 1: especificar el modelo
2107 m1 <- '
2108 data {
2109   int<lower=0> N;           // number of observations
2110   int<lower=0,upper=1> y[N]; // setting the dependent variable (vote) as binary
2111   vector[N] x1;           // independent variable 1
2112   vector[N] x2;           // independent variable 2
2113 }
2114 parameters {
2115   real b0;                // intercept
2116   real b1;
2117   real b2;
2118   real<lower=0> sig20;
2119   real<lower=0> sig21;
2120   real<lower=0> sig22;
2121 }
2122 model {
2123   y ~ bernoulli_logit(b0 + b1 * x1 + b2 * x2); // model
2124   b0 ~ normal(0,sqrt(sig20)); // you can set priors for all betas
2125   b1 ~ normal(0,sqrt(sig21)); // if you prefer not to, uniform priors will be used
2126   b2 ~ normal(0,sqrt(sig22));
2127   sig20 ~ inv_gamma(0.01, 0.01);
2128   sig21 ~ inv_gamma(0.01, 0.01);
2129   sig22 ~ inv_gamma(0.01, 0.01);
2130 }
2131 '
2132 data<- LogisticData
2133 # Paso 2: Ajustar el modelo a los datos
2134 data.list = list(N = nrow(data), y = data$`"y"` , x1 = data$`"x1"` , x2 = data$`"x2"`)
2135 str(data.list)
2136
2137 # Paso 3: Estimar el modelo
2138 fit = stan(model_code = m1, data = data.list, iter = 10000, chains = 2, warmup = 1500)
2139 print(fit, digits = 3)

```

```

2140 summary(fit)
2141
2142 stan2coda <- function(fit) {
2143   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2144 }
2145 fit.mcmc <- stan2coda(fit)
2146 muestra.posterior1=do.call(rbind, fit.mcmc)
2147 HPDIinterval(as.mcmc(muestra.posterior1))
2148
2149 # Exportar algunos objetos de R
2150 df<-as.data.frame(muestra.posterior1)
2151 dfc<-write.csv(df, "CadenasSimuladosGammaInvStan.txt")
2152
2153 muestra.posterior<-read_csv("C:/Users/56992/Desktop/CadenasSimuladosGammaInvStan.
    ↪ txt")
2154 str(muestra.posterior)
2155 muestra.posterior1<-muestra.posterior %>% select (-...1)
2156 str(muestra.posterior1)
2157 dim(muestra.posterior1)
2158
2159 muestra<-muestra.posterior1[1:10000,1:7]
2160 muestra1<-muestra.posterior1[10001:20000,1:7]
2161 #dim(muestra1)
2162 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
2163
2164 gelman.diag(muestras)
2165 effectiveSize(muestra.posterior1)
2166 summary(muestras)
2167 HPDIinterval(as.mcmc(muestra.posterior1))
2168 HPDIinterval(muestras)
2169
2170 muestra.posterior<-muestra.posterior1
2171 #para beta0
2172 plot(muestra.posterior1[,1])
2173 ts.plot(muestra.posterior1[,1], ylab="Beta 0")
2174 acf(ts(muestra.posterior1[,1]))#lag4-5
2175 #para beta1
2176 plot(muestra.posterior1[,2])
2177 ts.plot(muestra.posterior1[,2], ylab="Beta 1")
2178 acf(ts(muestra.posterior1[,2]))#lag4-5
2179 #para beta3
2180 plot(muestra.posterior1[,3])
2181 ts.plot(muestra.posterior1[,3], ylab="Beta 2")
2182 acf(ts(muestra.posterior1[,3]))#lag4-5
2183
2184 #para sig20
2185 plot(muestra.posterior1[,4])
2186 ts.plot(muestra.posterior1[,4],ylab="Sigma2 Beta 0")
2187 acf(ts(muestra.posterior1[,4]))#lag2
2188 #para sig21
2189 plot(muestra.posterior1[,5])
2190 ts.plot(muestra.posterior1[,5],ylab="Sigma2 Beta 1")
2191 acf(ts(muestra.posterior1[,5]))#lag0
2192 #para sig23
2193 plot(muestra.posterior1[,6])

```

```

2194 ts.plot(muestra.posterior1[,6],ylab="Sigma2 Beta 2")
2195 acf(ts(muestra.posterior1[,6]))#lag1
2196
2197 # Paso 5: HMC Final
2198 fit = stan(model_code = m1, data = data.list, iter = 57500, chains = 2, warmup = 7500,
    ↪ thin = 2)
2199 print(fit, digits = 3)
2200 summary(fit)
2201
2202 stan2coda <- function(fit) {
2203   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2204 }
2205 fit.mcmc <- stan2coda(fit)
2206 muestra.posterior=do.call(rbind, fit.mcmc)
2207
2208 # Exportar algunos objetos de R
2209 dff<-as.data.frame(muestra.posterior)
2210 dfcf<-write.csv(dff, "CadenasSimuladosGammaInvFinalSTAN.txt")
2211
2212 muestra.posterior<-read_csv("C:/Users/56992/Desktop/
    ↪ CadenasSimuladosGammaInvFinalSTAN.txt")
2213 str(muestra.posterior)
2214 muestra.posterior1<-muestra.posterior %>% select (-...1)
2215 str(muestra.posterior1)
2216
2217 muestra<-muestra.posterior1[1:10000,1:7]
2218 muestra1<-muestra.posterior1[10001:20000,1:7]
2219 dim(muestra1)
2220 muestras<-mcmc.list(as.mcmc(muestra),as.mcmc(muestra1))
2221
2222 gelman.diag(muestras)
2223 effectiveSize(muestra.posterior1)
2224 summary(muestras)
2225 HPDinterval(as.mcmc(muestra.posterior1))
2226 HPDinterval(muestras)
2227
2228 muestra.posterior<-muestra.posterior1
2229 #para beta1
2230 plot(muestra.posterior[,1])
2231 ts.plot(muestra.posterior[,1],ylab="Beta 0")
2232 acf(ts(muestra.posterior[,1]))
2233 #para beta1
2234 plot(muestra.posterior[,2])
2235 ts.plot(muestra.posterior[,2],ylab="Beta 1")
2236 acf(ts(muestra.posterior[,2]))
2237 #para beta3
2238 plot(muestra.posterior[,3])
2239 ts.plot(muestra.posterior[,3],ylab="Beta 2")
2240 acf(ts(muestra.posterior[,3]))
2241
2242 #para sig20
2243 plot(muestra.posterior1[,4])
2244 ts.plot(muestra.posterior1[,4],ylab="Sigma2 Beta 0")
2245 acf(ts(muestra.posterior1[,4]))#
2246 #para sig21

```

```

2247 plot(muestra.posterior1[,5])
2248 ts.plot(muestra.posterior1[,5],ylab="Sigma2 Beta 1")
2249 acf(ts(muestra.posterior1[,5]))#
2250 #para sig23
2251 plot(muestra.posterior1[,6])
2252 ts.plot(muestra.posterior1[,6],ylab="Sigma2 Beta 2")
2253 acf(ts(muestra.posterior1[,6]))#
2254
2255 #####Curva Roc #####
2256 muestra.posterior<-as.data.frame(muestra.posterior1)
2257 data<-as.data.frame(LogisticData)
2258 a<-mean(muestra.posterior[,1]);a
2259 b<-mean(muestra.posterior[,2]);b
2260 c<-mean(muestra.posterior[,3]);c
2261 y<-data$y          #observados
2262 x1<-data$x1
2263 x2<-data$x2
2264 n=10000
2265 z = a + b*x1 + c*x2      # linear combination with a bias
2266 pr = 1/(1+exp(-z))      # pass through an inv-logit function
2267 k = rbinom(n,1,pr)      #predichos
2268
2269 roc_model=roc(y, k,ci=T,auc=T)
2270 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
2271         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
2272         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
2273 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
2274 points(x=coordenada$specificity,
2275        y=coordenada$sensitivity,
2276        pch=0,col="red")
2277 #####Análisis de sensibilidad y especificidad #####
2278 estimados=ifelse(test=k>0.5, yes=1, no=0)
2279 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
2280 tabla
2281 mosaic(tabla, shade = T, colorize = T,
2282        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
2283
2284 sensi=3057/4019 ; sensi
2285 espec=5012/5981 ; espec
2286 acu=(3057+5141)/10000 ; acu
2287
2288 cambio=matrix(data=tabla,ncol=2 , byrow=FALSE) ; cambio
2289 BDtest(cambio, pr=0.56 ,conf.level = 0.95)
2290
2291
2292
2293
2294 #####DATOS REALES#####
2295 #Cargar datos
2296 data1 <- TrainingVVV_RRL2
2297 data<-na.omit(data1)
2298
2299 # Paso 1: especificar el modelo
2300 m1 <- '
2301 data {

```



```

2302 int<lower=0> N;           // number of observations
2303 int<lower=0,upper=1> y[N]; // setting the dependent variable (vote) as binary
2304 vector[N] x1;           // independent variable 1
2305 vector[N] x2;           // independent variable 2
2306 vector[N] x3;           // independent variable 3
2307 vector[N] x4;           // independent variable 4
2308 vector[N] x5;           // independent variable 5
2309 vector[N] x6;           // independent variable 6
2310 vector[N] x7;           // independent variable 7
2311 vector[N] x8;           // independent variable 8
2312 vector[N] x9;           // independent variable 9
2313 vector[N] x10;          // independent variable 10
2314 vector[N] x11;          // independent variable 11
2315 vector[N] x12;          // independent variable 12
2316 }
2317 parameters {
2318   real b0;               // intercept
2319   real b1;
2320   real b2;
2321   real b3;
2322   real b4;
2323   real b5;
2324   real b6;
2325   real b7;
2326   real b8;
2327   real b9;
2328   real b10;
2329   real b11;
2330   real b12;
2331 }
2332 model {
2333   y ~ bernoulli__logit(b0 + b1 * x1 + b2 * x2 + b3 * x3 + b4 * x4 + b5 * x5 + b6 * x6 + b7
      ↪ * x7
2334     + b8 * x8 + b9 * x9 + b10 * x10 + b11 * x11 + b12 * x12 ); // model
2335   b0 ~ normal(0,1000000); // you can set priors for all betas
2336   b1 ~ normal(0,1000000); // if you prefer not to, uniform priors will be used
2337   b2 ~ normal(0,1000000);
2338   b3 ~ normal(0,1000000);
2339   b4 ~ normal(0,1000000);
2340   b5 ~ normal(0,1000000);
2341   b6 ~ normal(0,1000000);
2342   b7 ~ normal(0,1000000);
2343   b8 ~ normal(0,1000000);
2344   b9 ~ normal(0,1000000);
2345   b10 ~ normal(0,1000000);
2346   b11 ~ normal(0,1000000);
2347   b12 ~ normal(0,1000000);
2348
2349 }
2350
2351 # Paso 2: Ajustar el modelo a los datos
2352 data.list = list(N = nrow(data1), y = data1$rrl, x1 = data1$A.1.1. , x2 = data1$A.1.2. , x3
      ↪ = data1$A.1.3. ,
2353   x4 = data1$PH.1.2. , x5 = data1$PH.1.3. , x6 = data1$PH.1.4. , x7 = data1$f1
      ↪ , x8 = data1$P1 , x9 = data1$s ,

```

```

2354         x10 = data1$p2p_s2p , x11 = data1$p2p_spfom , x12 = data1$R1)
2355 str(data.list)
2356
2357 # Paso 3: Estimar el modelo #18809/7=2687
2358 fit = stan(model_code = m1, data = data.list, iter = 18809, chains = 1, warmup=20 , thin
      ↪ =1)
2359 print(fit, digits = 3)
2360 summary(fit)
2361
2362 stan2coda <- function(fit) {
2363   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2364 }
2365 fit.mcmc <- stan2coda(fit)
2366 muestra.posterior=do.call(rbind, fit.mcmc)
2367 primeramuestra<-muestra.posterior
2368
2369 #Exportar algunos objetos de R
2370 df<-as.data.frame(primeramuestra)
2371 dfr<-write.csv(df, "CadenasRealSTAN")
2372
2373 ##### Analisis de convergencia#####
2374 mat <- matrix(c(1, 2, # Primero, segundo
2375               3, 4,
2376               5,6), # y tercer gráfico
2377               nrow = 3, ncol = 2,
2378               byrow = TRUE)
2379
2380 layout(mat = mat)
2381
2382 betas<-select(CadenasReal, -X)
2383 head(betas)
2384
2385 ts.plot(betas[,1],ylab="Beta0")
2386 ts.plot(betas[,2],ylab="Beta1")
2387 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
2388 ts.plot(betas[,4],ylab="Beta3")
2389 ts.plot(betas[,5],ylab="Beta4")
2390 ts.plot(betas[,6],ylab="Beta5")
2391 ts.plot(betas[,7],ylab="Beta6")
2392 ts.plot(betas[,8],ylab="Beta7")
2393 ts.plot(betas[,9],ylab="Beta8")
2394 ts.plot(betas[,10],ylab="Beta9")
2395 ts.plot(betas[,11],ylab="Beta10")
2396 ts.plot(betas[,12],ylab="Beta11")
2397 ts.plot(betas[,13],ylab="Beta12")
2398
2399 #para beta
2400 acf(ts(betas[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
2401 acf(ts(betas[,2],main="beta1")
2402 acf(ts(betas[,3],main="beta2")
2403 acf(ts(betas[,4],main="beta3")
2404 acf(ts(betas[,5],main="beta4")#pasado 35
2405 acf(ts(betas[,6],main="beta5")# en la 7 y las demas no tienen
2406 acf(ts(betas[,7],main="beta6")
2407 acf(ts(betas[,8],main="beta7")

```

```

2408 acf(ts(betas)[,9],main="beta8")
2409 acf(ts(betas)[,10],main="beta9")
2410 acf(ts(betas)[,11],main="beta10")
2411 acf(ts(betas)[,12],main="beta11")
2412 acf(ts(betas)[,13],main="beta12")
2413
2414 #####Curva ROC#####
2415 data1<-TrainingVVV_RRL2
2416 datos<-data1
2417 betas<- CadenasReal
2418 #betas<-select(betas, -X)
2419 dim(betas)
2420 head(betas)
2421 betas <- betas %>% select (-X)
2422 View(betas)
2423 summary(betas)
2424 a<-mean(betas[,13]);a
2425 b<-mean(betas[,1]);b
2426 c<-mean(betas[,2]);c
2427 d<-mean(betas[,3]);d
2428 e<-mean(betas[,4]);e
2429 f<-mean(betas[,5]);f
2430 g<-mean(betas[,6]);g
2431 h<-mean(betas[,7]);h
2432 i<-mean(betas[,8]);i
2433 j<-mean(betas[,9]);j
2434 k<-mean(betas[,10]);k
2435 l<-mean(betas[,11]);l
2436 m<-mean(betas[,12]);m
2437
2438 head(datos)
2439 y<-datos$rrl          #observados
2440 x1<-datos$A.1.1.
2441 x2<-datos$A.1.2.
2442 x3<-datos$A.1.3.
2443 x4<-datos$PH.1.2.
2444 x5<-datos$PH.1.3.
2445 x6<-datos$PH.1.4.
2446 x7<-datos$ff1
2447 x8<-datos$P1
2448 x9<-datos$s
2449 x10<-datos$p2p_s2p
2450 x11<-datos$p2p_spfom
2451 x12<-datos$R1
2452
2453 ndatos=18809
2454 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10+l*x11+m*x12
2455 pr = 1/(1+exp(-z))
2456 kp = rbinom(ndatos,1,pr)      #predichos
2457
2458 roc_model=roc(y, kp ,ci=T,auc=T)
2459 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
2460          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
2461          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
2462 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))

```

```

2463 points(x=coordenada$specificity,
2464         y=coordenada$sensitivity,
2465         pch=0,col="red")
2466
2467 ##### Analisis de sensibilidad y especificidad #####
2468 estimados=ifelse(test=kp>0.5, yes=1, no=0)
2469 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
2470 tabla
2471 mosaic(tabla, shade = T, colorize = T,
2472        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
2473
2474 sensi=8107/(8107+8423) ; sensi
2475 espec=2257/(22+2257) ; espec
2476 capa=(8107+2257)/18809 ; capa
2477
2478
2479
2480 ##### Eliminación de outliers #####
2481 data1 <- TrainingVWV_RRL2
2482 data1<-as.data.frame(data1)
2483
2484 index <- which(data1$A.1.1.<40 & data1$A.1.2.<40 & data1$A.1.3.<40)
2485 data1[index, ]
2486 data1<-data.frame(data1[index, ])
2487 dim(data1)
2488 #View(data1)
2489 summary(data1)#se eliminaron 3 observaciones
2490
2491 # Paso 2: Ajustar el modelo a los datos
2492 data.list = list(N = nrow(data1), y = data1$rll, x1 = data1$A.1.1. , x2 = data1$A.1.2. , x3
2493               ↪ = data1$A.1.3. ,
2494               x4 = data1$PH.1.2. , x5 = data1$PH.1.3. , x6 = data1$PH.1.4. , x7 = data1$f1
2495               ↪ , x8 = data1$P1 , x9 = data1$s ,
2496               x10 = data1$p2p_s2p , x11 = data1$p2p_spfom , x12 = data1$R1)
2497 str(data.list)
2498 # Paso 3: Estimar el modelo #18809/7=2687
2499 fit = stan(model_code = m1, data = data.list, iter = 18806, chains = 1, warmup=20 , thin
2500         ↪ =1)
2501 print(fit, digits = 3)
2502 summary(fit)
2503
2504 stan2coda <- function(fit) {
2505   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2506 }
2507 fit.mcmc <- stan2coda(fit)
2508 muestra.posterior=do.call(rbind, fit.mcmc)
2509 segundamuestra<-muestra.posterior
2510
2511 #Exportar algunos objetos de R
2512 df<-as.data.frame(segundamuestra)
2513 dfr<-write.csv(df, "CadenasRealSTAN2")
2514
2515 ##### Analisis de convergencia #####
2516 datos<-data1
2517 betas<- CadenasReal2

```

```

2515 #betas<-select(betas, -X)
2516 dim(betas)
2517 head(betas)
2518 betas <- betas %>% select (-X)
2519 View(betas)
2520 summary(betas)
2521 HPDIinterval(as.mcmc(betas))
2522
2523 mat <- matrix(c(1, 2, # Primero, segundo
2524               3, 4,
2525               5,6), # y tercer gráfico
2526               nrow = 3, ncol = 2,
2527               byrow = TRUE)
2528
2529 layout(mat = mat)
2530
2531 betas<-select(CadenasReal2, -X)
2532 head(betas)
2533
2534 ts.plot(betas[,1],ylab="Beta0")
2535 ts.plot(betas[,2],ylab="Beta1")
2536 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
2537 ts.plot(betas[,4],ylab="Beta3")
2538 ts.plot(betas[,5],ylab="Beta4")
2539 ts.plot(betas[,6],ylab="Beta5")
2540 ts.plot(betas[,7],ylab="Beta6")
2541 ts.plot(betas[,8],ylab="Beta7")
2542 ts.plot(betas[,9],ylab="Beta8")
2543 ts.plot(betas[,10],ylab="Beta9")
2544 ts.plot(betas[,11],ylab="Beta10")
2545 ts.plot(betas[,12],ylab="Beta11")
2546 ts.plot(betas[,13],ylab="Beta12")
2547
2548 #para beta
2549 acf(ts(betas)[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
2550 acf(ts(betas)[,2],main="beta1")
2551 acf(ts(betas)[,3],main="beta2")
2552 acf(ts(betas)[,4],main="beta3")
2553 acf(ts(betas)[,5],main="beta4")
2554 acf(ts(betas)[,6],main="beta5")
2555 acf(ts(betas)[,7],main="beta6")
2556 acf(ts(betas)[,8],main="beta7")
2557 acf(ts(betas)[,9],main="beta8")
2558 acf(ts(betas)[,10],main="beta9")
2559 acf(ts(betas)[,11],main="beta10")
2560 acf(ts(betas)[,12],main="beta11")
2561 acf(ts(betas)[,13],main="beta12")
2562
2563 #####Curva ROC#####
2564 a<-mean(betas[,13]);a
2565 b<-mean(betas[,1]);b
2566 c<-mean(betas[,2]);c
2567 d<-mean(betas[,3]);d
2568 e<-mean(betas[,4]);e
2569 f<-mean(betas[,5]);f

```

```

2570 g<-mean(betas[,6]);g
2571 h<-mean(betas[,7]);h
2572 i<-mean(betas[,8]);i
2573 j<-mean(betas[,9]);j
2574 k<-mean(betas[,10]);k
2575 l<-mean(betas[,11]);l
2576 m<-mean(betas[,12]);m
2577
2578 head(datos)
2579 y<-datos$rrl          #observados
2580 x1<-datos$A.1.1.
2581 x2<-datos$A.1.2.
2582 x3<-datos$A.1.3.
2583 x4<-datos$PH.1.2.
2584 x5<-datos$PH.1.3.
2585 x6<-datos$PH.1.4.
2586 x7<-datos$ffl
2587 x8<-datos$P1
2588 x9<-datos$s
2589 x10<-datos$p2p_s2p
2590 x11<-datos$p2p_spfom
2591 x12<-datos$R1
2592
2593 ndatos=18806
2594 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10+l*x11+m*x12
2595 pr = 1/(1+exp(-z))
2596 kp = rbinom(ndatos,1,pr)      #predichos
2597
2598 roc_model=roc(y, kp ,ci=T, auc=T)
2599 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
2600          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
2601          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
2602 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
2603 points(x=coordenada$specificity,
2604        y=coordenada$sensitivity,
2605        pch=0,col="red")
2606
2607 #####Análisis de sensibilidad y especificidad #####
2608 estimados=ifelse(test=kp>0.5, yes=1, no=0)
2609 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
2610 tabla
2611 mosaic(tabla, shade = T, colorize = T,
2612        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
2613
2614 sensi=15750/(15750+777) ; sensi
2615 espec=1507/(772+1507) ; espec
2616 capa=(15750+1507)/18802 ; capa
2617
2618
2619
2620 #####Eliminación de outliers 2#####
2621 data1 <- TrainingVWV_RRL2
2622 data1<-as.data.frame(data1)
2623
2624 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20)

```

```

2625 data1[index, ]
2626 data1<-data.frame(data1[index, ])
2627 dim(data1)
2628 #View(data1)
2629 summary(data1)#se eliminaron 7 observaciones
2630
2631 # Paso 2: Ajustar el modelo a los datos
2632 data.list = list(N = nrow(data1), y = data1$rrl, x1 = data1$A.1.1. , x2 = data1$A.1.2. , x3
  ↪ = data1$A.1.3. ,
2633       x4 = data1$PH.1.2. , x5 = data1$PH.1.3. , x6 = data1$PH.1.4. , x7 = data1$f1
  ↪ , x8 =data1$P1 , x9 = data1$s ,
2634       x10 = data1$p2p_s2p , x11 = data1$p2p_spfom , x12 = data1$R1)
2635 str(data.list)
2636 # Paso 3: Estimar el modelo #18809/7=2687
2637 fit = stan(model_code = m1, data = data.list, iter = 18806, chains = 1, warmup=20 , thin
  ↪ =1)
2638 print(fit, digits = 3)
2639 summary(fit)
2640
2641 stan2coda <- function(fit) {
2642   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2643 }
2644 fit.mcmc <- stan2coda(fit)
2645 muestra.posterior=do.call(rbind, fit.mcmc)
2646 terceramuestra<-muestra.posterior
2647
2648 #Exportar algunos objetos de R
2649 df<-as.data.frame(terceramuestra)
2650 dfr<-write.csv(df, "CadenasReal3")
2651
2652 ##### Analisis de convergencia#####
2653 data1<-TrainingVVV_RRL2
2654 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20)
2655 data1[index, ]
2656 data1<-data.frame(data1[index, ])
2657 dim(data1)
2658
2659 datos<-data1
2660 dim(datos)
2661 betas<- CadenasReal3
2662 #betas<-select(betas, -X)
2663 dim(betas)
2664 head(betas)
2665 betas <- betas %>% select (-X)
2666 View(betas)
2667 summary(betas)
2668
2669 mat <- matrix(c(1, 2, # Primero, segundo
2670               3, 4,
2671               5,6), # y tercer gráfico
2672             nrow = 3, ncol = 2,
2673             byrow = TRUE)
2674
2675 layout(mat = mat)
2676

```

```

2677
2678 ts.plot(betas[,1],ylab="Beta0")
2679 ts.plot(betas[,2],ylab="Beta1")
2680 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
2681 ts.plot(betas[,4],ylab="Beta3")
2682 ts.plot(betas[,5],ylab="Beta4")
2683 ts.plot(betas[,6],ylab="Beta5")
2684 ts.plot(betas[,7],ylab="Beta6")
2685 ts.plot(betas[,8],ylab="Beta7")
2686 ts.plot(betas[,9],ylab="Beta8")
2687 ts.plot(betas[,10],ylab="Beta9")
2688 ts.plot(betas[,11],ylab="Beta10")
2689 ts.plot(betas[,12],ylab="Beta11")
2690 ts.plot(betas[,13],ylab="Beta12")
2691
2692 #para beta
2693 acf(ts(betas[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
2694 acf(ts(betas[,2],main="beta1")
2695 acf(ts(betas[,3],main="beta2")
2696 acf(ts(betas[,4],main="beta3")
2697 acf(ts(betas[,5],main="beta4")
2698 acf(ts(betas[,6],main="beta5")
2699 acf(ts(betas[,7],main="beta6")
2700 acf(ts(betas[,8],main="beta7")
2701 acf(ts(betas[,9],main="beta8")
2702 acf(ts(betas[,10],main="beta9")
2703 acf(ts(betas[,11],main="beta10")
2704 acf(ts(betas[,12],main="beta11")
2705 acf(ts(betas[,13],main="beta12")
2706
2707 head(betas)
2708 #####Curva ROC#####
2709 a<-mean(betas[,1]);a#beta0
2710 b<-mean(betas[,2]);b
2711 c<-mean(betas[,3]);c
2712 d<-mean(betas[,4]);d
2713 e<-mean(betas[,5]);e
2714 f<-mean(betas[,6]);f
2715 g<-mean(betas[,7]);g
2716 h<-mean(betas[,8]);h
2717 i<-mean(betas[,9]);i
2718 j<-mean(betas[,10]);j
2719 k<-mean(betas[,11]);k
2720 l<-mean(betas[,12]);l
2721 m<-mean(betas[,13]);m
2722
2723 head(datos)
2724 y<-datos$rrl #observados
2725 x1<-datos$A.1.1.
2726 x2<-datos$A.1.2.
2727 x3<-datos$A.1.3.
2728 x4<-datos$PH.1.2.
2729 x5<-datos$PH.1.3.
2730 x6<-datos$PH.1.4.
2731 x7<-datos$f1

```



```

2732 x8<-datos$P1
2733 x9<-datos$s
2734 x10<-datos$p2p_s2p
2735 x11<-datos$p2p_spfom
2736 x12<-datos$R1
2737
2738 ndatos=18802
2739 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10+l*x11+m*x12
2740 pr = 1/(1+exp(-z))
2741 kp = rbinom(ndatos,1,pr)      #predichos
2742
2743 roc_model=roc(y, kp ,ci=T, auc=T)
2744 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
2745         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
2746         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
2747 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
2748 points(x=coordenada$specificity,
2749        y=coordenada$sensitivity,
2750        pch=0,col="red")
2751
2752 ##### Analisis de sensibilidad y especificidad #####
2753 estimados=ifelse(test=kp>0.5, yes=1, no=0)
2754 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
2755 tabla
2756 mosaic(tabla, shade = T, colorize = T,
2757        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
2758
2759 sensi=15763/(15763+760) ; sensi
2760 espec=1484/(795+1484) ; espec
2761 capa=(15763+ 1484)/18802 ; capa
2762
2763
2764
2765 #####Eliminacion de outliers 2 y eliminacion de variables A.1.1 y A.1.2#####
2766 data1<-TrainingVVV_RRL2
2767 data1<-as.data.frame(data1)
2768 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
        ↪ observacion 20 en las variables A.1.i
2769 data1[index, ]
2770 data1<-data.frame(data1[index, ])
2771 dim(data1)
2772 a<-data1
2773 head(data1)
2774
2775 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
        ↪ s2p, a$p2p_spfom, a$R1)
2776 head(data2)
2777 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
        ↪ spfom","R1")
2778 head(data2)
2779
2780
2781 # Paso 1: especificar el modelo
2782 m1 <- '
2783 data {

```

```

2784 int<lower=0> N;           // number of observations
2785 int<lower=0,upper=1> y[N]; // setting the dependent variable (vote) as binary
2786 vector[N] x1;           // independent variable 1
2787 vector[N] x2;           // independent variable 2
2788 vector[N] x3;           // independent variable 3
2789 vector[N] x4;           // independent variable 4
2790 vector[N] x5;           // independent variable 5
2791 vector[N] x6;           // independent variable 6
2792 vector[N] x7;           // independent variable 7
2793 vector[N] x8;           // independent variable 8
2794 vector[N] x9;           // independent variable 9
2795 vector[N] x10;          // independent variable 10
2796 }
2797 parameters {
2798     real b0;              // intercept
2799     real b1;
2800     real b2;
2801     real b3;
2802     real b4;
2803     real b5;
2804     real b6;
2805     real b7;
2806     real b8;
2807     real b9;
2808     real b10;
2809 }
2810 model {
2811     y ~ bernoulli_logit(b0 + b1 * x1 + b2 * x2 + b3 * x3 + b4 * x4 + b5 * x5 + b6 * x6 + b7
        ↪ * x7
2812                + b8 * x8 + b9 * x9 + b10 * x10 ); // model
2813     b0 ~ normal(0,1000000); // you can set priors for all betas
2814     b1 ~ normal(0,1000000); // if you prefer not to, uniform priors will be used
2815     b2 ~ normal(0,1000000);
2816     b3 ~ normal(0,1000000);
2817     b4 ~ normal(0,1000000);
2818     b5 ~ normal(0,1000000);
2819     b6 ~ normal(0,1000000);
2820     b7 ~ normal(0,1000000);
2821     b8 ~ normal(0,1000000);
2822     b9 ~ normal(0,1000000);
2823     b10 ~ normal(0,1000000);
2824
2825 }
2826 '
2827
2828 # Paso 2: Ajustar el modelo a los datos
2829 data.list = list(N = nrow(data1), y = data1$rrl, x1 = data1$A.1.3. ,
2830                x2 = data1$PH.1.2. , x3 = data1$PH.1.3. , x4 = data1$PH.1.4. , x5 = data1$f1
        ↪ , x6 = data1$P1 , x7 = data1$s ,
2831                x8 = data1$p2p_s2p , x9 = data1$p2p_spfom , x10 = data1$R1)
2832 str(data.list)
2833 # Paso 3: Estimar el modelo
2834 fit = stan(model_code = m1, data = data.list, iter = 40, chains = 1, warmup=20 , thin=1)
2835 print(fit, digits = 3)
2836 summary(fit)

```

```

2837
2838 stan2coda <- function(fit) {
2839   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
2840 }
2841 fit.mcmc <- stan2coda(fit)
2842 muestra.posterior=do.call(rbind, fit.mcmc)
2843 cuartamuestra<-muestra.posterior
2844
2845 #Exportar algunos objetos de R
2846 df<-as.data.frame(betas)
2847 dfr<-write.csv(df, "CadenasReal4")
2848
2849
2850
2851 ##### Analisis de convergencia#####
2852 datos<-data2
2853 dim(datos)
2854 betas<- CadenasReal4
2855 #betas<-select(betas, -X)
2856 dim(betas)
2857 head(betas)
2858 betas <- betas %>% select (-X)
2859 View(betas)
2860 summary(betas)
2861
2862 mat <- matrix(c(1, 2, # Primero, segundo
2863                3, 4,
2864                5,6), # y tercer gráfico
2865               nrow = 3, ncol = 2,
2866               byrow = TRUE)
2867
2868 layout(mat = mat)
2869
2870
2871 ts.plot(betas[,1],ylab="Beta0")
2872 ts.plot(betas[,2],ylab="Beta1")
2873 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
2874 ts.plot(betas[,4],ylab="Beta3")
2875 ts.plot(betas[,5],ylab="Beta4")
2876 ts.plot(betas[,6],ylab="Beta5")
2877 ts.plot(betas[,7],ylab="Beta6")
2878 ts.plot(betas[,8],ylab="Beta7")
2879 ts.plot(betas[,9],ylab="Beta8")
2880 ts.plot(betas[,10],ylab="Beta9")
2881 ts.plot(betas[,11],ylab="Beta10")
2882
2883 #para beta
2884 acf(ts(betas[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
2885    acf(ts(betas[,2],main="beta1")
2886    acf(ts(betas[,3],main="beta2")
2887    acf(ts(betas[,4],main="beta3")
2888    acf(ts(betas[,5],main="beta4")
2889    acf(ts(betas[,6],main="beta5")
2890    acf(ts(betas[,7],main="beta6")
2891    acf(ts(betas[,8],main="beta7")

```

```

2892 acf(ts(betas)[,9],main="beta8")
2893 acf(ts(betas)[,10],main="beta9")
2894 acf(ts(betas)[,11],main="beta10")
2895
2896 head(betas)
2897 #####Curva ROC#####
2898 a<-mean(betas[,1]);a
2899 b<-mean(betas[,2]);b
2900 c<-mean(betas[,3]);c
2901 d<-mean(betas[,4]);d
2902 e<-mean(betas[,5]);e
2903 f<-mean(betas[,6]);f
2904 g<-mean(betas[,7]);g
2905 h<-mean(betas[,8]);h
2906 i<-mean(betas[,9]);i
2907 j<-mean(betas[,10]);j
2908 k<-mean(betas[,11]);k
2909
2910 head(datos)
2911 dim(betas)
2912 dim(datos)
2913 y<-datos$rrl          #observados
2914 x1<-datos$A.1.3.
2915 x2<-datos$PH.1.2.
2916 x3<-datos$PH.1.3.
2917 x4<-datos$PH.1.4.
2918 x5<-datos$f1
2919 x6<-datos$P1
2920 x7<-datos$s
2921 x8<-datos$p2p_s2p
2922 x9<-datos$p2p_spfom
2923 x10<-datos$R1
2924
2925 ndatos=18802
2926 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10
2927 pr = 1/(1+exp(-z))
2928 kp = rbinom(18802,1,pr)      #predichos
2929
2930 roc_model=roc(y, kp ,ci=T, auc=T)
2931 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
2932          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
2933          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
2934 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
2935 points(x=coordenada$specificity,
2936        y=coordenada$sensitivity,
2937        pch=0,col="red")
2938
2939 #####Análisis de sensibilidad y especificidad #####
2940 estimados=ifelse(test=kp>0.5, yes=1, no=0)
2941 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
2942 tabla
2943 mosaic(tabla, shade = T, colorize = T,
2944        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
2945
2946 sensi=15750/(15750+777) ; sensi

```

```

2947 especí=1507/(772+1507) ; especí
2948 capa=(15750+1507)/18802 ; capa
2949
2950
2951
2952
2953 #####Eliminacion de outliers 2 y eliminacion de variables A.1.1 y A.1.2 y gamma#####
2954 data1<-TrainingVVV_RRL2
2955 data1<-as.data.frame(data1)
2956 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i
2957 data1[index, ]
2958 data1<-data.frame(data1[index, ])
2959 dim(data1)
2960 a<-data1
2961 head(data1)
2962
2963 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
    ↪ s2p, a$p2p_spfom, a$R1)
2964 head(data2)
2965 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
    ↪ spfom","R1")
2966 head(data2)
2967
2968
2969 # Paso 1: especificar el modelo
2970 m1 <- '
2971 data {
2972   int<lower=0> N;           // number of observations
2973   int<lower=0,upper=1> y[N]; // setting the dependent variable as binary
2974   vector[N] x1;           // independent variable 1
2975   vector[N] x2;           // independent variable 2
2976   vector[N] x3;           // independent variable 3
2977   vector[N] x4;           // independent variable 4
2978   vector[N] x5;           // independent variable 5
2979   vector[N] x6;           // independent variable 6
2980   vector[N] x7;           // independent variable 7
2981   vector[N] x8;           // independent variable 8
2982   vector[N] x9;           // independent variable 9
2983   vector[N] x10;          // independent variable 10
2984 }
2985 parameters {
2986   real b0;                // intercept
2987   real b1;
2988   real b2;
2989   real b3;
2990   real b4;
2991   real b5;
2992   real b6;
2993   real b7;
2994   real b8;
2995   real b9;
2996   real b10;
2997   real<lower=0> sig0;      // sig intercept
2998   real<lower=0> sig1;

```

```

2999 real<lower=0> sig2;
3000 real<lower=0> sig3;
3001 real<lower=0> sig4;
3002 real<lower=0> sig5;
3003 real<lower=0> sig6;
3004 real<lower=0> sig7;
3005 real<lower=0> sig8;
3006 real<lower=0> sig9;
3007 real<lower=0> sig10;
3008 }
3009 model {
3010 y ~ bernoulli_logit(b0 + b1 * x1 + b2 * x2 + b3 * x3 + b4 * x4 + b5 * x5 + b6 * x6 + b7
    ↪ * x7
3011                + b8 * x8 + b9 * x9 + b10 * x10 ); // model
3012 b0 ~ normal(0,sqrt(sig0)); // you can set priors for all betas
3013 b1 ~ normal(0,sqrt(sig1)); // if you prefer not to, uniform priors will be used
3014 b2 ~ normal(0,sqrt(sig2));
3015 b3 ~ normal(0,sqrt(sig3));
3016 b4 ~ normal(0,sqrt(sig4));
3017 b5 ~ normal(0,sqrt(sig5));
3018 b6 ~ normal(0,sqrt(sig6));
3019 b7 ~ normal(0,sqrt(sig7));
3020 b8 ~ normal(0,sqrt(sig8));
3021 b9 ~ normal(0,sqrt(sig9));
3022 b10 ~ normal(0,sqrt(sig10));
3023
3024 sig0 ~ gamma(0.01,0.01); // sig intercept
3025 sig1 ~ gamma(0.01,0.01);
3026 sig2 ~ gamma(0.01,0.01);
3027 sig3 ~ gamma(0.01,0.01);
3028 sig4 ~ gamma(0.01,0.01);
3029 sig5 ~ gamma(0.01,0.01);
3030 sig6 ~ gamma(0.01,0.01);
3031 sig7 ~ gamma(0.01,0.01);
3032 sig8 ~ gamma(0.01,0.01);
3033 sig9 ~ gamma(0.01,0.01);
3034 sig10 ~ gamma(0.01,0.01);
3035
3036 }
3037 '
3038
3039 # Paso 2: Ajustar el modelo a los datos
3040 data.list = list(N = nrow(data1), y = data1$rrl, x1 = data1$A.1.3. ,
3041                x2 = data1$PH.1.2. , x3 = data1$PH.1.3. , x4 = data1$PH.1.4. , x5 = data1$fl
    ↪ , x6 = data1$P1 , x7 = data1$s ,
3042                x8 = data1$p2p_s2p , x9 = data1$p2p_spfom , x10 = data1$R1)
3043 str(data.list)
3044 # Paso 3: Estimar el modelo
3045 fit = stan(model_code = m1, data = data.list, iter = 40, chains = 1, warmup=20 , thin=1)
3046 print(fit, digits = 3)
3047 summary(fit)
3048
3049 stan2coda <- function(fit) {
3050   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
3051 }

```

```

3052 fit.mcmc <- stan2coda(fit)
3053 muestra.posterior=do.call(rbind, fit.mcmc)
3054 quintamuestra<-muestra.posterior
3055 HDPIinterval(as.mcmc(quintamuestra))
3056
3057 #Exportar algunos objetos de R
3058 df<-as.data.frame(quintamuestra)
3059 dfr<-write.csv(df, "CadenasReal5")
3060
3061 ##### Analisis de convergencia#####
3062 data1<-TrainingVVV_RRL2
3063 data1<-as.data.frame(data1)
3064 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
    ↪ observacion 20 en las variables A.1.i
3065 data1[index, ]
3066 data1<-data.frame(data1[index, ])
3067 dim(data1)
3068 a<-data1
3069 head(data1)
3070
3071 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p__
    ↪ s2p, a$p2p__spfom, a$R1)
3072 head(data2)
3073 names(data2)=c("rrl", "A.1.3.", "PH.1.2.", "PH.1.3.", "PH.1.4.", "f1", "P1", "s", "p2p__s2p", "p2p__
    ↪ spfom", "R1")
3074 head(data2)
3075
3076 datos<-data2
3077 dim(datos)
3078 betas<- CadenasReal5
3079
3080 #betas<-select(betas, -X)
3081 dim(betas)
3082 head(betas)
3083 betas <- betas %>% select (-X)
3084 View(betas)
3085 summary(betas)
3086
3087 mat <- matrix(c(1, 2, # Primero, segundo
3088                3, 4,
3089                5,6), # y tercer gráfico
3090              nrow = 3, ncol = 2,
3091              byrow = TRUE)
3092
3093 layout(mat = mat)
3094
3095
3096 ts.plot(betas[,1],ylab="Beta0")
3097 ts.plot(betas[,2],ylab="Beta1")
3098 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
3099 ts.plot(betas[,4],ylab="Beta3")
3100 ts.plot(betas[,5],ylab="Beta4")
3101 ts.plot(betas[,6],ylab="Beta5")
3102 ts.plot(betas[,7],ylab="Beta6")
3103 ts.plot(betas[,8],ylab="Beta7")

```

```

3104 ts.plot(betas[,9],ylab="Beta8")
3105 ts.plot(betas[,10],ylab="Beta9")
3106 ts.plot(betas[,11],ylab="Beta10")
3107 ts.plot(betas[,12],ylab="Sigma0")
3108 ts.plot(betas[,13],ylab="Sigma1")
3109 ts.plot(betas[,14],ylab="Sigma2")
3110 ts.plot(betas[,15],ylab="Sigma3")
3111 ts.plot(betas[,16],ylab="Sigma4")
3112 ts.plot(betas[,17],ylab="Sigma5")
3113 ts.plot(betas[,18],ylab="Sigma6")
3114 ts.plot(betas[,19],ylab="Sigma7")
3115 ts.plot(betas[,20],ylab="Sigma8")
3116 ts.plot(betas[,21],ylab="Sigma9")
3117 ts.plot(betas[,22],ylab="Sigma10")
3118
3119 #para beta
3120 acf(ts(betas[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
3121 acf(ts(betas[,2],main="beta1")
3122 acf(ts(betas[,3],main="beta2")
3123 acf(ts(betas[,4],main="beta3")
3124 acf(ts(betas[,5],main="beta4")
3125 acf(ts(betas[,6],main="beta5")
3126 acf(ts(betas[,7],main="beta6")
3127 acf(ts(betas[,8],main="beta7")
3128 acf(ts(betas[,9],main="beta8")
3129 acf(ts(betas[,10],main="beta9")
3130 acf(ts(betas[,11],main="beta10")
3131 acf(ts(betas[,12],main="Sigma0")
3132 acf(ts(betas[,13],main="Sigma1")
3133 acf(ts(betas[,14],main="Sigma2")
3134 acf(ts(betas[,15],main="Sigma3")
3135 acf(ts(betas[,16],main="Sigma4")
3136 acf(ts(betas[,17],main="Sigma5")
3137 acf(ts(betas[,18],main="Sigma6")
3138 acf(ts(betas[,19],main="Sigma7")
3139 acf(ts(betas[,20],main="Sigma8")
3140 acf(ts(betas[,21],main="Sigma9")
3141 acf(ts(betas[,22],main="Sigma10")
3142
3143 head(betas)
3144 #####Curva ROC#####
3145 a<-mean(betas[,1]);a
3146 b<-mean(betas[,2]);b
3147 c<-mean(betas[,3]);c
3148 d<-mean(betas[,4]);d
3149 e<-mean(betas[,5]);e
3150 f<-mean(betas[,6]);f
3151 g<-mean(betas[,7]);g
3152 h<-mean(betas[,8]);h
3153 i<-mean(betas[,9]);i
3154 j<-mean(betas[,10]);j
3155 k<-mean(betas[,11]);k
3156
3157 head(datos)
3158 dim(betas)

```



```

3159 dim(datos)
3160 y<-datos$rrl          #observados
3161 x1<-datos$A.1.3.
3162 x2<-datos$PH.1.2.
3163 x3<-datos$PH.1.3.
3164 x4<-datos$PH.1.4.
3165 x5<-datos$f1
3166 x6<-datos$P1
3167 x7<-datos$s
3168 x8<-datos$p2p_s2p
3169 x9<-datos$p2p_spfom
3170 x10<-datos$R1
3171
3172 ndatos=18802
3173 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10
3174 pr = 1/(1+exp(-z))
3175 kp = rbinom(18802,1,pr)      #predichos
3176
3177 roc_model=roc(y, kp ,ci=T, auc=T)
3178 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
3179          auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
3180          col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
3181 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
3182 points(x=coordenada$specificity,
3183        y=coordenada$sensitivity,
3184        pch=0,col="red")
3185
3186 ##### Analisis de sensibilidad y especificidad #####
3187 estimados=ifelse(test=kp>0.5, yes=1, no=0)
3188 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
3189 tabla
3190 mosaic(tabla, shade = T, colorize = T,
3191        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
3192
3193 sensi=7872/(7872+8651) ; sensi
3194 espec=498/(498+1781) ; espec
3195 capa=(7872+1781)/18802 ; capa
3196
3197
3198 #####Eliminacion de outliers 2 y eliminacion de variables A.1.1 y A.1.2 y gamma inversa
3199   ↪ #####
3200 data1<-TrainingVVV_RRL2
3201 data1<-as.data.frame(data1)
3202 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
3203   ↪ observacion 20 en las variables A.1.i
3204 data1[index, ]
3205 data1<-data.frame(data1[index, ])
3206 dim(data1)
3207 a<-data1
3208 head(data1)
3209
3210 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
3211   ↪ s2p, a$p2p_spfom, a$R1)
3212 head(data2)
3213 names(data2)=c("rrl","A.1.3.", "PH.1.2.", "PH.1.3.", "PH.1.4.", "f1", "P1", "s", "p2p_s2p", "p2p_

```

```

    ↪ spfom", "R1")
3211 head(data2)
3212 dim(data2)
3213
3214 # Paso 1: especificar el modelo
3215 m1 <- '
3216 data {
3217   int<lower=0> N;           // number of observations
3218   int<lower=0,upper=1> y[N]; // setting the dependent variable as binary
3219   vector[N] x1;           // independent variable 1
3220   vector[N] x2;           // independent variable 2
3221   vector[N] x3;           // independent variable 3
3222   vector[N] x4;           // independent variable 4
3223   vector[N] x5;           // independent variable 5
3224   vector[N] x6;           // independent variable 6
3225   vector[N] x7;           // independent variable 7
3226   vector[N] x8;           // independent variable 8
3227   vector[N] x9;           // independent variable 9
3228   vector[N] x10;          // independent variable 10
3229 }
3230 parameters {
3231   real b0;                // intercept
3232   real b1;
3233   real b2;
3234   real b3;
3235   real b4;
3236   real b5;
3237   real b6;
3238   real b7;
3239   real b8;
3240   real b9;
3241   real b10;
3242   real<lower=0> sig0;      // sig intercept
3243   real<lower=0> sig1;
3244   real<lower=0> sig2;
3245   real<lower=0> sig3;
3246   real<lower=0> sig4;
3247   real<lower=0> sig5;
3248   real<lower=0> sig6;
3249   real<lower=0> sig7;
3250   real<lower=0> sig8;
3251   real<lower=0> sig9;
3252   real<lower=0> sig10;
3253 }
3254 model {
3255   y ~ bernoulli_logit(b0 + b1 * x1 + b2 * x2 + b3 * x3 + b4 * x4 + b5 * x5 + b6 * x6 + b7
    ↪ * x7
3256   + b8 * x8 + b9 * x9 + b10 * x10 ); // model
3257   b0 ~ normal(0,sqrt(sig0)); // you can set priors for all betas
3258   b1 ~ normal(0,sqrt(sig1)); // if you prefer not to, uniform priors will be used
3259   b2 ~ normal(0,sqrt(sig2));
3260   b3 ~ normal(0,sqrt(sig3));
3261   b4 ~ normal(0,sqrt(sig4));
3262   b5 ~ normal(0,sqrt(sig5));
3263   b6 ~ normal(0,sqrt(sig6));

```

```

3264 b7 ~ normal(0,sqrt(sig7));
3265 b8 ~ normal(0,sqrt(sig8));
3266 b9 ~ normal(0,sqrt(sig9));
3267 b10 ~ normal(0,sqrt(sig10));
3268
3269 sig0 ~ inv_gamma(0.01,0.01);           // sig intercept
3270 sig1 ~ inv_gamma(0.01,0.01);
3271 sig2 ~ inv_gamma(0.01,0.01);
3272 sig3 ~ inv_gamma(0.01,0.01);
3273 sig4 ~ inv_gamma(0.01,0.01);
3274 sig5 ~ inv_gamma(0.01,0.01);
3275 sig6 ~ inv_gamma(0.01,0.01);
3276 sig7 ~ inv_gamma(0.01,0.01);
3277 sig8 ~ inv_gamma(0.01,0.01);
3278 sig9 ~ inv_gamma(0.01,0.01);
3279 sig10 ~ inv_gamma(0.01,0.01);
3280
3281 }
3282 '
3283
3284 # Paso 2: Ajustar el modelo a los datos
3285 data.list = list(N = nrow(data1), y = data1$rrl, x1 = data1$A.1.3. ,
3286                x2 = data1$PH.1.2. , x3 = data1$PH.1.3. , x4 = data1$PH.1.4. , x5 = data1$f1
3287                ↪ , x6 = data1$P1 , x7 = data1$s ,
3288                x8 = data1$p2p_s2p , x9 = data1$p2p_spfom , x10 = data1$R1)
3289 str(data.list)
3290 # Paso 3: Estimar el modelo
3291 fit = stan(model_code = m1, data = data.list, iter = 18822, chains = 1, warmup=20 , thin
3292          ↪ =1)
3293 print(fit, digits = 3)
3294 summary(fit)
3295
3296 stan2coda <- function(fit) {
3297   mcmc.list(lapply(1:ncol(fit), function(x) mcmc(as.array(fit)[,x]))))
3298 }
3299 fit.mcmc <- stan2coda(fit)
3300 muestra.posterior=do.call(rbind, fit.mcmc)
3301 sextamuestra<-muestra.posterior
3302 HDPIinterval(as.mcmc(sextamuestra))
3303
3304 #Exportar algunos objetos de R
3305 df<-as.data.frame(sextamuestra)
3306 dfr<-write.csv(df, "CadenasReal6.txt")
3307
3308 ##### Analisis de convergencia#####
3309 data1<-TrainingVVV_RRL22
3310 data1<-as.data.frame(data1)
3311 index <- which(data1$A.1.1.<20 &data1$A.1.2.<20 &data1$A.1.3.<20) #se elimina desde la
3312          ↪ observacion 20 en las variables A.1.i
3313 data1[index, ]
3314 data1<-data.frame(data1[index, ])
3315 dim(data1)
3316 a<-data1
3317 head(data1)
3318

```

```

3316 data2<-data.frame(a$rrl, a$A.1.3., a$PH.1.2., a$PH.1.3., a$PH.1.4., a$f1, a$P1, a$s, a$p2p_
      ↪ s2p, a$p2p_spfom, a$R1)
3317 head(data2)
3318 names(data2)=c("rrl","A.1.3.","PH.1.2.","PH.1.3.","PH.1.4.","f1","P1","s","p2p_s2p","p2p_
      ↪ spfom","R1")
3319 head(data2)
3320
3321 datos<-data1
3322 dim(datos)
3323 CadenasReal6 <- read_csv("C:/Users/56992/Desktop/Stam 6/CadenasReal6.txt")
3324 betas<- CadenasReal6 %>% select (-...1)
3325
3326 #betas<-select(betas, -X)
3327 dim(betas)
3328 head(betas)
3329 betas <- betas %>% select (-X)
3330 View(betas)
3331 summary(betas)
3332
3333 mat <- matrix(c(1, 2, # Primero, segundo
3334                 3, 4,
3335                 5,6), # y tercer gráfico
3336               nrow = 3, ncol = 2,
3337               byrow = TRUE)
3338
3339 layout(mat = mat)
3340
3341
3342 ts.plot(betas[,1],ylab="Beta0")
3343 ts.plot(betas[,2],ylab="Beta1")
3344 ts.plot(betas[,3],ylab="Beta2")#en los primeros 4 beta se decide quedar las 5000 primeras
3345 ts.plot(betas[,4],ylab="Beta3")
3346 ts.plot(betas[,5],ylab="Beta4")
3347 ts.plot(betas[,6],ylab="Beta5")
3348 ts.plot(betas[,7],ylab="Beta6")
3349 ts.plot(betas[,8],ylab="Beta7")
3350 ts.plot(betas[,9],ylab="Beta8")
3351 ts.plot(betas[,10],ylab="Beta9")
3352 ts.plot(betas[,11],ylab="Beta10")
3353 ts.plot(betas[,12],ylab="Sigma0")
3354 ts.plot(betas[,13],ylab="Sigma1")
3355 ts.plot(betas[,14],ylab="Sigma2")
3356 ts.plot(betas[,15],ylab="Sigma3")
3357 ts.plot(betas[,16],ylab="Sigma4")
3358 ts.plot(betas[,17],ylab="Sigma5")
3359 ts.plot(betas[,18],ylab="Sigma6")
3360 ts.plot(betas[,19],ylab="Sigma7")
3361 ts.plot(betas[,20],ylab="Sigma8")
3362 ts.plot(betas[,21],ylab="Sigma9")
3363 ts.plot(betas[,22],ylab="Sigma10")
3364
3365 #para beta
3366 acf(ts(betas)[,1],main="beta0")#autocorrelacion desaparece en lag pasado 35
3367 acf(ts(betas)[,2],main="beta1")
3368 acf(ts(betas)[,3],main="beta2")

```

```

3369 acf(ts(betas)[,4],main="beta3")
3370 acf(ts(betas)[,5],main="beta4")
3371 acf(ts(betas)[,6],main="beta5")
3372 acf(ts(betas)[,7],main="beta6")
3373 acf(ts(betas)[,8],main="beta7")
3374 acf(ts(betas)[,9],main="beta8")
3375 acf(ts(betas)[,10],main="beta9")
3376 acf(ts(betas)[,11],main="beta10")
3377 acf(ts(betas)[,12],main="Sigma0")
3378 acf(ts(betas)[,13],main="Sigma1")
3379 acf(ts(betas)[,14],main="Sigma2")
3380 acf(ts(betas)[,15],main="Sigma3")
3381 acf(ts(betas)[,16],main="Sigma4")
3382 acf(ts(betas)[,17],main="Sigma5")
3383 acf(ts(betas)[,18],main="Sigma6")
3384 acf(ts(betas)[,19],main="Sigma7")
3385 acf(ts(betas)[,20],main="Sigma8")
3386 acf(ts(betas)[,21],main="Sigma9")
3387 acf(ts(betas)[,22],main="Sigma10")
3388
3389 head(betas)
3390 #####Curva ROC#####
3391 betas<-as.data.frame(betas)
3392 a<-mean(betas[,11]);a
3393 b<-mean(betas[,1]);b
3394 c<-mean(betas[,2]);c
3395 d<-mean(betas[,3]);d
3396 e<-mean(betas[,4]);e
3397 f<-mean(betas[,5]);f
3398 g<-mean(betas[,6]);g
3399 h<-mean(betas[,7]);h
3400 i<-mean(betas[,8]);i
3401 j<-mean(betas[,9]);j
3402 k<-mean(betas[,10]);k
3403
3404 head(datos)
3405 dim(betas)
3406 dim(datos)
3407 y<-datos$rrl          #observados
3408 x1<-datos$A.1.3.
3409 x2<-datos$PH.1.2.
3410 x3<-datos$PH.1.3.
3411 x4<-datos$PH.1.4.
3412 x5<-datos$f1
3413 x6<-datos$P1
3414 x7<-datos$s
3415 x8<-datos$p2p_s2p
3416 x9<-datos$p2p_spfom
3417 x10<-datos$R1
3418
3419 ndatos=18802
3420 z = a+b*x1+c*x2+d*x3+e*x4+f*x5+g*x6+h*x7+i*x8+j*x9+k*x10
3421 pr = 1/(1+exp(-z))
3422 kp = rbinom(18802,1,pr)    #predichos
3423

```

```
3424 roc_model=roc(y, kp ,ci=T, auc=T)
3425 plot.roc(roc_model, print.thres = "best", print.auc = TRUE,
3426         auc.polygon = FALSE, max.auc.polygon = FALSE, auc.polygon.col = "gainsboro",
3427         col = 2, grid = TRUE,xlab="1-Especificidad",ylab="Sensibilidad" )
3428 coordenada <- pROC::coords(roc_model,"best",ret=c("threshold","specificity","sensitivity"))
3429 points(x=coordenada$specificity,
3430        y=coordenada$sensitivity,
3431        pch=0,col="red")
3432
3433 ##### Analisis de sensibilidad y especificidad #####
3434 estimados=ifelse(test=kp>0.5, yes=1, no=0)
3435 tabla=table(y, estimados, dnn=c("Observados", "Estimados"))
3436 tabla
3437 mosaic(tabla, shade = T, colorize = T,
3438        gp = gpar(fill = matrix(c("green3", "red2", "red2", "green3"), 2, 2)))
3439
3440 sensi=8165/(8165+8358) ; sensi
3441 espec=2257/(22+2257) ; espec
3442 capa=(8165+2257)/18802 ; capa
```