



Universidad de Santiago de Chile
Facultad de Ciencia
Departamento de Matemática y Ciencia de la Computación
Ingeniería Estadística

Un modelo para anticipar periodos de congestión en el Hospital de Urgencia Asistencia Pública (HUAP)

Alumno:
Nicolás Rondán F.

Profesor Guía:
Felipe Elorrieta L.

Comisión:
Claudio Vargas R.
Pamela Toro N.

Santiago, Chile
16 Septiembre, 2017

Resumen.

La congestión en los servicios de urgencia es un problema que se presenta en nuestro país desde hace años, este es un problema no sólo a nivel nacional sino también en países desarrollados. En Chile, aún no existen mayores estudios en torno a este fenómeno, lo que lleva a generar preguntas respecto a definir las causas de la congestión. Debido a esto es que nace la necesidad de poder identificar y anticipar periodos de congestión en el Hospital de Urgencias Asistencia Pública(HUAP) .

En términos del análisis descriptivos de los datos, este tiene dos aristas. La primera es en torno a la base inicial, esta contiene los registros de atención de cada una de las personas que asistió al HUAP durante el periodo de Enero del año 2014 hasta Junio del año 2017. La segunda mirada es a través de una base de censos, que se obtuvo a partir de un programa que permite recrear el proceso de atención de los pacientes, haciendo mediciones cada una hora. En primera instancia con la base inicial se pudo tener una mirada bastante general en torno a los registros de los pacientes, lo que permitió saber a de una manera tentativa las variables que estaban mas relacionadas con la congestión y por otra parte el hecho de poder recrear el proceso de atención permitió resumir la información de los pacientes en un determinado tiempo, en donde el mayor aporte es que se puede saber el rendimiento del HUAP en momentos especificos

Se pudo evidenciar que existen variables del proceso de atención que están altamente relacionadas con la congestión, básicamente los tiempos de atención al proceso de atención, flujos de los pacientes y el Triage. Por otra parte también fue posible dar una definición de congestión y que si bien por el tipo de recopilación de información de HUAP no se pudo tener un ajuste real, esta tuvo bastante coherencia.

Para cumplir con este objetivo se aplicaron dos técnicas de clasificación, la Regresión Logística y Clasificador de Naive Bayes, los cuales se caracterizan por modelar directamente la probabilidad de que ocurra un evento. La información recopilada corresponde a los registros de atención de los pacientes desde el año 2014 hasta junio del año 2017. Con esta información se definirá congestión en base a la cantidad de pacientes hospitalizados en box.

Finalmente, los resultados de las técnicas de clasificación aplicadas, muestran un modelo que permite anticipar periodos de congestión, sin embargo su poder predictivo en torno a la congestión es bajo y por otra parte un modelo que tiene un mejor poder predictivo de casos de congestión, pero que no logra prever con anterioridad los periodos de congestión. Por otra parte se pudo obtener mejores niveles de predicción, pero junto con ello mayor error en la cantidad de periodos clasificados como congestión cuando en realidad no lo están. Por lo tanto la elección de un modelo dependerá de la prioridad que se tenga al momentos de actuar.

Índice general

Lista de figuras	4
Lista de tablas	6
1. Introducción.	8
1.1. Planteamiento del problema.	10
1.2. Objetivos.	11
1.2.1. Objetivo General.	11
1.2.2. Objetivos Específicos.	11
1.3. Metodología	12
2. Marco Teórico.	14
2.1. Conceptos previos.	14
2.2. Modelo de Regresión Logística	15
2.2.1. Introducción al modelo	15
2.2.2. Planteamiento del modelo	16
2.2.3. Odds y Odds-Ratio.	17
2.2.4. Estimación de los parámetros.	18
2.2.5. Significancia de los parámetros	20
2.2.6. Bondad de ajuste del modelo.	21
2.2.7. Selección de Variables.	22
2.3. Modelo Naive Bayes.	23
2.3.1. Introducción al modelo.	23
2.3.2. Clasificador basado en el Teorema de Bayes.	23
2.3.3. Origen del algoritmo Naive Bayes.	23
2.3.4. Naive Bayes Bernoulli.	25
2.3.5. Naive Bayes Multinomial.	25
2.3.6. Naive Bayes Normal.	27
2.4. Indicadores de discriminación.	28
3. Tratamiento de la base de datos.	31
3.1. Proceso de calidad de datos.	31
3.1.1. Unificar Base de datos.	31
3.1.2. Cálculo de los Tiempos de atención.	31
3.1.3. Tratamiento a las variables categóricas.	32
3.2. Recrear proceso de atención.	32
4. Análisis Descriptivo.	37
4.1. Descripción de la base de datos inicial.	37
4.1.1. Descripción de variables.	37
4.2. Variables Discretas.	39
4.2.1. Previsión.	40
4.2.2. Sin diagnóstico.	41
4.2.3. Género.	42

4.2.4. Remitido Por	43
4.3. Variables Continuas.	44
4.3.1. Hospitalizados en Box.	44
4.3.2. Tiempo total en el HUAP.	45
4.3.3. Tiempo hasta la atención.	46
4.3.4. Tiempo Atención Alta.	47
4.3.5. Criterio para eliminar registros.	48
4.4. Descripción de la base de modelamiento.	50
4.4.1. Descripción de las variables.	50
4.5. Análisis de las variables.	52
4.5.1. Congestión.	52
4.5.2. Día de la semana.	53
4.5.3. Triage.	54
4.5.4. Promedio de tiempos asociado al proceso de atención.	55
4.5.5. Mediana de tiempos asociado al proceso de atención.	56
4.5.6. Flujos durante la última hora.	57
4.5.7. Flujos durante las últimas dos horas.	58
4.5.8. Flujos durante las últimas tres horas.	59
5. Implementación de Modelos.	60
5.1. Regresión Logística.	60
5.1.1. Selección de Variables.	60
5.2. Selección del Modelo.	68
5.3. Clasificador de Naïve Bayes.	74
5.4. Selección del modelo final.	82
6. Conclusiones.	84
Anexos	87
A. Tablas de la base inicial.	88
A.1. Variables discretas.	88
A.1.1. Triage.	88
A.1.2. Previsión.	89
A.1.3. Sin diagnóstico.	90
A.1.4. Género.	91
A.1.5. Remitido Por.	92
A.2. Variables Continuas.	93
A.2.1. Set de variables.	93
A.2.2. Hospitalizados en Box	94
B. Tablas Base de modelamiento.	96
B.1. Congestión.	96
B.2. Triage.	96
B.3. Flujos	97
C. Clasificador de Naïve Bayes.	99
C.1. Tablas distribuciones condicionales Modelo 5.	99

Índice de figuras

1.1. Etapas de la metodología KDD	13
2.1. Gráfico Curva ROC	30
4.1. Gráfico demandas según categoría Triage	39
4.2. Gráfico demandas según Previsión de salud	40
4.3. Gráfico cantidad de personas Sin Diagnóstico.	41
4.4. Género de las personas que asistieron al HUAP.	42
4.5. Origen de la asistencia del paciente al HUAP.	43
4.6. Promedio y máximo mensual de pacientes hospitalizados en box.	44
4.7. Tiempo total de los pacientes.	45
4.8. Tiempos transcurridos hasta la atención de los pacientes.	46
4.9. Tiempo transcurrido desde la atención hasta el egreso del paciente.	47
4.10. Tiempo total de los pacientes.	48
4.11. Tiempos transcurridos hasta la atención de los pacientes.	49
4.12. Tiempos transcurridos desde la atención hasta el egreso del paciente.	50
4.13. Frecuencias y porcentajes de estados de congestión.	52
4.14. Distribución del estado de congestión según día de la semana.	53
4.15. Demanda promedio anual según Triage y estado de congestión.	54
4.16. Promedio de los tiempos de atención, tiempo urgencias y tiempo atención alta, identificando periodos de congestión.	55
4.17. Mediana de los tiempos de atención, tiempo urgencias y tiempo atención alta, identificando periodos de congestión.	56
4.18. Promedio mensual de entradas y salidas durante la última hora, identificando periodos de congestión.	57
4.19. Promedio mensual de entradas y salidas durante las últimas dos horas, identificando periodos de congestión.	58
4.20. Promedio mensual de entradas y salidas durante las últimas tres horas, identificando periodos de congestión.	59
5.1. Cutoff vs Accuracy del modelo 5	68
5.2. Cutoff vs Accuracy del modelo 6	68
5.3. Cutoff vs Precision - Recall, del modelo 5	69
5.4. Cutoff vs Precision - Recall, del modelo 5	69
5.5. Curva Roc modelo 5	70
5.6. Curva Roc modelo 6	70
5.7. Curva Roc modelo 5 - Curva Roc modelo 6.	73
5.8. Distribuciones de las variables continuas dado el estado de congestión.	75
5.9. Punto de corte - modelo 5	76
5.10. Punto de corte - modelo 6	76
5.11. Punto de corte - modelo 5	78
5.12. Punto de corte - modelo 6	78
5.13. Curva de Roc - modelo 5	79
5.14. Curva de Roc - modelo 6	79

5.15. Curva de Roc base de validación.	81
5.16. Capacidad de anticipación al estado de congestión.	82

Índice de cuadros

2.1. Matriz de confusión	28
2.2. Matriz de confusión	29
3.1. Recopilación censo de las 03:00 día 01 de enero, año 2014.	34
3.2. Resumen del censo realizado a las 03:00 hrs día 01 de enero, año 2014	35
3.3. Tabla final con resultados de los censos realizados desde las 01:00 hrs hasta las 04:00 día 01 de enero, año 2014	36
5.1. Test de razón de verosimilitudes para la iteración 1	60
5.2. Resumen de los parámetros del modelo 1	61
5.3. Test de razón de verosimilitudes para la iteración 2	61
5.4. Resumen de los parámetros del modelo 2	61
5.5. Test de razón de verosimilitudes para la iteración 3	62
5.6. Test razón de verosimilitudes para sacar variable ingresada en iteración 1	62
5.7. Resumen de los parámetros del modelo 3	62
5.8. Test razón de verosimilitudes para la iteración 4	63
5.9. Test razón de verosimilitudes para determinar si es posible sacar las variables agregadas en las primeras dos iteraciones	63
5.10. Resumen de los coeficientes del modelo 4	63
5.11. Test de razón de verosimilitud para la iteración 5	64
5.12. Factores de inflación de varianza.	64
5.13. Test de razón de verosimilitudes para determinar si es posible sacar las variables agre- gadas en las iteraciones 1 y 3.	65
5.14. Resumen de los coeficientes del modelo 5	65
5.15. Test de razón de verosimilitudes para variable entrante en iteración 6.	66
5.16. Test de razón de verosimilitud para determinar si es posible sacar las variables de las tres primeras iteraciones.	66
5.17. Resumen de los coeficientes del modelo 6	67
5.18. Modelos Propuestos	68
5.19. Puntos de corte y exactitud	68
5.20. Matriz de confusión modelo 5	69
5.21. Matriz de confusión modelo 6	69
5.22. Puntos de corte, según Recall y Precision.	69
5.23. Matriz de confusión modelo 5	70
5.24. Matriz de confusión modelo 6	70
5.25. Matriz de confusión para la base de validación - modelo 5	71
5.26. Matriz de confusión para la base de validación - modelo 6	71
5.27. Matriz de confusión para la base de validación - modelo 5	72
5.28. Matriz de confusión para la base de validación - modelo 6	72
5.29. Modelos Propuestos	74
5.30. Probabilidad a Priori de la variable congestión	75
5.31. Probabilidad de los días de la semana según estado de congestión.	76
5.32. Puntos de corte y exactitud	77

5.33. Matriz de confusión e indicadores - Modelo 5	77
5.34. Matriz de confusión e indicadores - Modelo 6	77
5.35. Puntos de corte, según Recall y Precision.	78
5.36. Matriz de confusión e indicadores - Modelo 5	78
5.37. Matriz de confusión e indicadores - Modelo 6	78
5.38. Matriz de confusión e indicadores - Modelo 5	80
5.39. Matriz de confusión e indicadores - Modelo 6	80
5.40. Matriz de confusión e indicadores - Modelo 5	80
5.41. Matriz de confusión e indicadores - Modelo 6	80
A.1. Demanda Triage en el año 2014	88
A.2. Demanda Triage en el año 2015	88
A.3. Demanda Triage en el año 2016	89
A.4. Demandas según previsión de salud año 2014	89
A.5. Demandas según previsión de salud año 2014	89
A.6. Demandas según previsión de salud año 2014	90
A.7. Cantidad de Pacientes sin diagnóstico en el año 2014.	90
A.8. Cantidad de Pacientes sin diagnóstico en el año 2015.	90
A.9. Cantidad de Pacientes sin diagnóstico en el año 2016.	91
A.10. Género de los pacientes en el año 2014.	91
A.11. Género de los pacientes en el año 2015.	91
A.12. Género de los pacientes en el año 2016.	92
A.13. Cantidad de personas que llegaron a través de distintas entidades el año 2014	92
A.14. Cantidad de personas que llegaron a través de distintas entidades el año 2014	92
A.15. Cantidad de personas que llegaron a través de distintas entidades el año 2016	93
A.16. Estadísticas descriptivas variables continuas durante el año 2014	93
A.17. Estadísticas descriptivas variables continuas durante el año 2015	93
A.18. Estadísticas descriptivas variables continuas durante el año 2016	94
A.19. Promedio de pacientes hospitalizados en Box año 2014	94
A.20. Promedio de pacientes hospitalizados en Box año 2015	95
A.21. Promedio de pacientes hospitalizados en Box año 2016	95
B.1. Frecuencias estados de congestión según censos cada una hora.	96
B.2. Porcentajes estados de congestión según censos cada una hora.	96
B.3. Promedio anual de personas según clasificación Triage entre los censos, identificando periodos de congestión.	96
B.4. Promedio de flujos mensuales durante el año 2014.	97
B.5. Promedio de flujos mensuales durante el año 2015.	97
B.6. Promedio de flujos mensuales durante el año 2016.	97
B.7. Promedio de flujos mensuales durante el año 2017.	98
C.1. Distribución condicional según estado de congestión	99
C.2. Distribución condicional según estado de congestión	99
C.3. Distribución condicional según estado de congestión	99

Capítulo 1

Introducción.

El Hospital de Urgencia Asistencia Pública (HUAP) es el principal centro de urgencias médicas de la Región Metropolitana, además de ser el punto de derivación nacional del sistema público de salud para pacientes politraumatizados y quemados.

Se entiende por urgencia o emergencia vital toda condición clínica que implique riesgo de muerte o de secuela funcional grave, la atención de urgencia o emergencia vital ante un hecho de tal envergadura, debe ser inmediata e impostergable.

En Estados Unidos la alta demanda de los servicios de urgencia ha sido la mayor barrera para recibir a tiempo los cuidados de emergencia necesitados por los pacientes [10], de manera frecuente pacientes que se dirigen a centros públicos de urgencias se ven enfrentados a largas esperas para ser atendidos y para aquellos que necesitan ser internados las esperas son aún más largas debido al hecho de que no hay camas disponibles para ellos. Si el personal que compone estos centros de atención pública pudieran ser prevenidos de este colapso, podrían tomarse medidas para reaccionar de mejor manera antes de tal situación, lo cual impactaría en los tiempos de atención y la calidad de la misma.[1, 3]

Entender cuáles son las características del diario vivir de un servicio de urgencia, que potencialmente podrían ayudar a encontrar una solución en la congestión del HUAP, es vital si se quiere mejorar en el proceso de atención, no sólo de los pacientes sino también de las personas que componen esta entidad, es decir, tener una mirada analítica desde la perspectiva del paciente, como por ejemplo cuáles son los casos más usuales que se presentan en los servicios públicos de urgencia y en su contra parte si el establecimiento se encuentra preparado para atender estos casos, tanto en infraestructura y trabajadores, ya que el establecimiento puede contar con las mejores tecnologías para atender a las personas, sin embargo esto pierde sentido si es que de una manera estratégica, en el lugar no se encuentran preparados para solventar la necesidad de cuidados más usuales, obviamente tomando en cuenta el abanico de tipos de urgencias que llegan al HUAP.

Para los expertos ha sido todo un desafío poder llegar a un consenso en la definición de una congestión alta en los servicios de urgencia, es decir, bajo qué características se puede decir que el servicios de urgencia está en colapso. En el año 2002, la Escuela Americana de Médicos de Emergencias, definió el colapso del servicio de urgencias como un estado donde, la necesidad de servicios de urgencias son superados por los recursos del establecimiento. Sin embargo, cabe mencionar que todo lugar consta con recursos distintos y que además existen factores externos que dificultan una definición universal de esta.[9, 11]

El modelo conceptual de los servicios de urgencias para el sistema de cuidados está dividido en tres etapas: entrada, rendimiento y salida.

La entrada (input) está definida como cualquier evento, condición o características del sistema que contribuya en la demanda de un servicio de urgencia. Atención ambulatoria no programada, servicios urgentes de cuidados, pacientes internados en el servicio de atención de urgencia, son algunas de las características dentro de esta etapa.

Rendimiento (throughput), corresponde a factores que producen demora en la atención de los pacientes, también llamado “cuello de botella”, ya que si bien puede haber una entrada normal de personas al servicio de urgencia, al llegar a esta etapa empiezan a crecer los tiempos de atención para los pacientes. Por último la salida (output), esta etapa contempla los factores que impiden la salida de las personas del servicio de urgencia.

Usando esta estructura conceptual, se recopilará información del HUAP, con el fin de poder crear un modelo que permita poder identificar y anticipar periodos de congestión del establecimiento.

1.1. Planteamiento del problema.

En la actualidad, tanto en Chile como en el extranjero, las consultas a los servicios de urgencia han aumentado considerablemente y se estima que seguirán subiendo en los próximos años [8]. Tomando en consideración una serie de fenómenos relacionados a la gestión y administración de salud, tanto en la atención hospitalaria como ambulatoria, han determinado que se genere un fenómeno de sobrepoblamiento (overcrowding) o desbalance entre el número de pacientes que consulta a un servicio de urgencia y la capacidad de éste de resolverlos de manera eficiente.

Por ello es de gran importancia poder disponer de un modelo estadístico que permita anticipar estos momentos de congestión, lo que permitirá tomar medidas necesarias antes del suceso.

En un estudio realizado en Nashville, Estados Unidos [3], fueron utilizados modelos de clasificación para poder dar solución al problema, en específico el modelo de regresión logística y redes neuronales. En ambos se obtuvieron grandes resultados en términos de discriminación, utilizando la curva Roc como medida (regresión logística = 0.954; redes neuronales = 0.957), no obstante cabe destacar que dentro de los logros, el modelo de regresión logística pudo anticipar los periodos de congestión 62 minutos antes, mientras que el modelo de redes neuronales lo hizo en 13 minutos, esto presenta una clara diferencia entre qué modelo utilizar para poder anticipar los periodos de congestión. Este estudio será utilizado como una guía a seguir para poder dar solución al problema planteado.

1.2. Objetivos.

1.2.1. Objetivo General.

Crear un modelo predictivo de la probabilidad de ocurrencia de un episodio de congestión en el Hospital de Urgencia Asistencia Pública (HUAP) a corto plazo.

1.2.2. Objetivos Específicos.

- Estudiar la literatura y realizar una revisión bibliográfica, tanto en el ámbito contextual de los Servicio de Atención de urgencias, así como también de las existentes herramientas estadísticas que dan solución al objetivo general planteado.
- Realizar un análisis descriptivo, de los datos facilitados por el HUAP.
- Construcción y selección de variables explicativas.
- Implementar los modelos de clasificación binarios de Regresión Logística y Naive Bayes.
- Realizar predicciones utilizando ambos modelos.
- Elegir el mejor modelo usando medidas de bondad de ajuste.

1.3. Metodología

Una vez identificado el objetivo de este proyecto es posible poder determinar una técnica estadística para dar solución a la problemática, es preciso mencionar que la variable respuesta es del tipo binaria, es decir, el HUAP se encuentra o no en periodo de congestión. Debido a ello se proponen las siguientes técnicas estadísticas:

- **Regresión Logística Binomial:** es una técnica estadística multivariante, que permite estimar la relación entre una variable binaria y un conjunto de variables independientes, esto con el fin de poder predecir la probabilidad de que se esté en presencia o no, de una característica, es decir, la variable binaria.[5, 15]
- **Naive Bayes:** es un algoritmo de clasificación basado en el teorema de Bayes, usa frecuencias para calcular probabilidades condicionales (asumiendo independencia) de nuevos casos, por ello también es conocido como Bayes Independiente.[12]

Los pasos a seguir para la obtención de conocimiento en base al fenómeno de congestión, estará dado por la metodología conocida como “Knowledge Discovery in Databases (KDD)”, que se refiere al proceso no-trivial de descubrir conocimiento e información potencialmente útil dentro de los datos [2]. Las etapas de esta metodología son:

- **Selección de datos:** En esta etapa se determinan las fuentes de datos y el tipo de información a utilizar. Es la etapa donde los datos relevantes para el análisis son extraídos desde la o las fuentes de datos.
- **Preprocesamiento:** Esta etapa consiste en la preparación y limpieza de los datos extraídos desde las distintas fuentes de datos en una forma manejable, necesaria para las fases posteriores. En esta etapa se utilizan diversas estrategias para manejar datos faltantes o en blanco, datos inconsistentes o que están fuera de rango, obteniéndose al final una estructura de datos adecuada para su posterior transformación.
- **Transformación:** Consiste en el tratamiento preliminar de los datos, transformación y generación de nuevas variables a partir de las ya existentes con una estructura de datos apropiada. Aquí se realizan operaciones de agregación o normalización, consolidando los datos de una forma necesaria para la fase siguiente.

- Data Mining: Es la fase de modelamiento propiamente tal, en donde métodos inteligentes son aplicados con el objetivo de extraer patrones previamente desconocidos, válidos, nuevos, potencialmente útiles y comprensibles y que están contenidos u ocultos en los datos.
- Interpretación y Evaluación: Se identifican los patrones obtenidos y que son realmente interesantes, basándose en algunas medidas y se realiza una evaluación de los resultados obtenidos.

En la imagen (1.1) se observan las etapas de este proceso



Imagen 1.1: Etapas de la metodología KDD

Capítulo 2

Marco Teórico.

2.1. Conceptos previos.

- **Urgencia Médica:** Se entiende por urgencia o emergencia vital toda condición clínica que implique riesgo de muerte o de secuela funcional grave, la atención de urgencia o emergencia vital ante un hecho de tal envergadura, debe ser inmediata e impostergable. Ninguna Institución de salud puede negar a un paciente la atención rápida a una urgencia vital ni exigir un cheque o documento en garantía para otorgarla. La condición de riesgo de muerte o de secuela funcional grave deberá ser certificada por un médico cirujano de la unidad de urgencia pública o privada en que la persona sea atendida.
- **Centro de Urgencias:** Centro asistencial perteneciente a todo hospital o clínica dónde se atienden requerimientos inmediatos de pacientes con distintos niveles de gravedad.
- **Congestión:** se define como congestión, cuando en un determinado momentos existen igual o mas de 30 pacientes hospitalizados en Box.
- **Triage:** Sistema de evaluación de riesgos que permite determinar la gravedad de un paciente o en su defecto la necesidad de atención médica inmediata de manera estructurada. Establece prioridades y asigna a los pacientes a sectores y tiempos de atención apropiados. En los servicios de urgencias públicos chilenos se emplea un sistema de categorización de riesgo de 5 niveles, estos van desde el C1 hasta el C5. Esta categorización se basa principalmente en la experiencia clínica del enfermero del triage. Las categorías son las siguientes:
 - **C1:** Emergencia vital, por lo que el paciente debe ser atendido de manera inmediata.
 - **C2:** Emergencia evidente, paciente inestable.
 - **C3:** Urgencia, mediano riesgo.
 - **C4:** Urgencia leve, por lo que el paciente también puede acudir a un Servicio de Atención Primaria de Urgencia (SAPU).
 - **C5:** Consulta general, este paciente también puede acudir al consultorio.

2.2. Modelo de Regresión Logística

2.2.1. Introducción al modelo

Es una herramienta estadística que permite modelar la relación de una variable de respuesta categórica binaria y un conjunto de variables explicativas, donde estas pueden ser continuas y/o categóricas [13]. Luego se define:

- y : tener o carecer de una característica determinada.

$$Y = \begin{cases} 0 & \text{no posee la característica} \\ 1 & \text{posee la característica} \end{cases} \quad (2.1)$$

A través de esta iniciativa se propone un modelo inicial errado, el cual explica la variable y como una combinación lineal de las variables explicativas:

$$y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon \quad (2.2)$$

Donde ϵ es el componente de error aleatorio, debe cumplir el supuesto $\epsilon \sim N(0, \sigma^2)$. Luego al obtener la esperanza de la variable se llega a contradicción, ya que Y es una variable aleatoria Bernoulli(π), por lo tanto, se tiene que $\mathbb{E}(Y) = \pi$, es decir, $\pi = \mathbb{E}(Y|X)$, lo cual es no puede ser ya que $Y \in \{0, 1\}$ y las variables explicativas varían dentro del intervalo $(-\infty, \infty)$. Es por ello que se vuelve a replantear el modelo, ya que esto es incompatible, lo que se propone es estudiar $\frac{\pi}{1-\pi} \in (0, \infty)$. En consecuencia se define $\text{logit}(\pi) = \log\left(\frac{\pi}{1-\pi}\right)$, como resultado se obtiene el modelo corregido como:

$$\begin{aligned} \log\left(\frac{\pi}{1-\pi}\right) &= \log\left(\frac{\mathbb{P}(Y=1|X)}{1-\mathbb{P}(Y=1|X)}\right) \\ &= \log\left(\frac{\mathbb{P}(Y=1|X)}{\mathbb{P}(Y=0|X)}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k \end{aligned} \quad (2.3)$$

A partir de esta ecuación es posible obtener el siguiente resultado:

$$\mathbb{P}(Y=1|X) = \frac{\exp(\beta_0 + \sum_{j=1}^k \beta_j X_j)}{1 + \exp(\beta_0 + \sum_{j=1}^k \beta_j X_j)} = \pi(X) \quad (2.4)$$

Luego, es fácil ver que:

$$\mathbb{P}(Y=0|X) = 1 - \pi(x)$$

2.2.2. Planteamiento del modelo

Supongamos que $Y_1, \dots, Y_n$ son v.a independientes tales que:

$$Y_i \sim B_i(n_i, \pi_i) \quad (2.5)$$

Supongamos además que la probabilidad π_i es una función de los predictores:

$$\text{logit}(\pi_i) = x_i' \beta \quad (2.6)$$

Donde las x_i son covariables. El modelo definido por (2.5) y por (2.6) es un modelo lineal generalizado con respuesta binomial y función de enlace logit.

Los coeficientes β tienen una interpretación similar a la de un modelo de regresión lineal múltiple, sin embargo, se debe tener en cuenta que lo que se tiene en la ecuación (2.6) es un logaritmo y no una media como en el caso de la regresión lineal múltiple. Los β_j representan el cambio en el logit de la probabilidad de tener o no cierta característica cuando se produce un cambio de una unidad en el j -ésimo predictor y se mantienen constantes todas las demás variables.

$$\pi_i = \frac{e^{x_i' \beta}}{1 + e^{x_i' \beta}} \quad (2.7)$$

La fórmula (2.7), no es lineal y por lo tanto no es trivial expresar el cambio de π_i , al cambiar un predictor, sin embargo si el predictor es continuo, se puede llegar a una aproximación tomando las derivadas con respecto a la j -ésima coordenada de x_i , obteniendo:

$$\frac{\partial \pi_i}{\partial x_{ij}} = \beta_j \pi_i (1 - \pi_i) \quad (2.8)$$

Luego, el efecto del j -ésimo predictor depende del coeficiente β_j y de la probabilidad π_i .

2.2.3. Odds y Odds-Ratio.

Odds

Los Odds se definen como el cociente entre las probabilidades de las dos alternativas [4], en otras palabras:

$$Odd = \Omega = \frac{P(Y_i = 1|X)}{P(Y_i = 0|X)} = \frac{P(Y_i = 1|X)}{1 - P(Y_i = 1|X)} \quad (2.9)$$

Luego, aplicando esta expresión en el modelo logístico se tiene que:

$$\Omega = \frac{P(Y_i = 1|X)}{P(Y_i = 0|X)} = \frac{P(y = 1|x)}{1 - P(y = 1|x)} = \frac{\frac{e^{x'\beta}}{1+e^{x'\beta}}}{\frac{1}{1+e^{x'\beta}}} = e^{x'\beta} = \frac{\pi(x)}{1 - \pi(x)} \quad (2.10)$$

Analizando la fórmula se puede concluir que los odds son la razón entre la ocurrencia de un evento y el complemento de ésta, es decir, la razón entre la ocurrencia del evento y la no ocurrencia del mismo.

Odds-Ratio.

Con los odds se puede obtener la mirada mas general de en cuanto a la probabilidad de poseer una cierta característica, sin embargo ello no nos indica algún tipo de interpretación de las variables que componen el modelo.[4]

Los resultados que se obtienen al ejecutar un modelo logístico se suelen interpretar en términos de OR, esto es la razón de los odds ajustando por la presencia y ausencia de alguna variable de control o variable explicativa.

Por lo tanto, el OR busca medir la asociación entre un factor de riesgo y la presencia de un evento. Estaría indicando el número de expuestos en los casos por cada expuesto en los controles.

El OR puede fluctuar dentro del intervalo $[0, \infty)$ y se interpreta al comparar un grupo en donde ha sido expuesto y otro que no ha sido expuesto.

- **OR<1**, se considera como una asociación negativa, es decir, la presencia del factor no se asocia con la mayor ocurrencia o tenencia de la característica de estudio. Es considerado factor de protección.
- **OR=1**, no existe asociación entre las variables, por lo tanto la cantidad de veces que ocurra el evento es igual con o sin la presencia del factor.
- **OR>1**, se considera como una asociación positiva, es decir, la presencia del factor se asocia a la mayor ocurrencia del evento. Es considerado factor de riesgo.

2.2.4. Estimación de los parámetros.

Los parámetros del modelo se estiman usualmente empleando el método de máxima verosimilitud.

Para cada observación de la muestra, la variable y_i sigue una distribución Bernoulli, es decir, $y_i \sim Bi(n_i, \pi_i)$ y además se utiliza la ecuación (2.6), con lo cual:

$$\pi_i = \frac{e^{x'_i \beta}}{1 + e^{x'_i \beta}} = \frac{1}{1 + e^{-x'_i \beta}}$$

Luego se tiene la siguiente igualdad:

$$\begin{aligned} Likelihood &= \prod_{i=1}^n \frac{n_i!}{y_i!(n_i - y_i)} \pi_i^{y_i} (1 - \pi_i)^{n_i - y_i} \\ Likelihood &\propto \prod_{i=1}^n \left(\frac{\pi_i}{1 - \pi_i} \right)^{y_i} (1 - \pi_i)^{n_i} \\ Likelihood &\propto \prod_{i=1}^n e^{x'_i \beta y_i} (1 + e^{x'_i \beta})^{n_i} \end{aligned} \tag{2.11}$$

Luego aplicando logaritmo,

$$\begin{aligned} \ell(\beta) &= \sum_{i=1}^n x'_i \beta y_i - \sum_{i=1}^n n_i \log(1 + e^{x'_i \beta}) \\ \frac{\partial \ell(\beta)}{\partial \beta_j} &= \sum_{i=1}^n y_i x_{ij} - \sum_{i=1}^n n_i \frac{1}{1 + e^{x'_i \beta}} e^{x'_i \beta} x_{ij} \\ \frac{\partial \ell(\beta)}{\partial \beta_j} &= \sum_{i=1}^n (y_i - \mu_i) x_{ij} \end{aligned} \tag{2.12}$$

Donde $\mu_i = \mathbb{E}(y_i) = n_i \pi_i$. Luego se tienen las segundas derivadas:

$$\begin{aligned} \frac{\partial^2 \ell(\beta)}{\partial \beta_j \partial \beta_k} &= - \sum_{i=1}^n n_i x_{ij} \frac{\partial}{\partial \beta_k} \left(\frac{e^{x_i' \beta}}{1 + e^{x_i' \beta}} \right) \\ \frac{\partial^2 \ell(\beta)}{\partial \beta_j \partial \beta_k} &= - \sum_{i=1}^n n_i \pi_i (1 - \pi_i) x_{ij} x_{ik} \end{aligned} \quad (2.13)$$

Luego por la no linealidad de los modelos, los estimadores máximo verosímiles se obtienen ocupando métodos numéricos, generalmente el método de Newton-Rhapson.

Si se usa la notación matricial se tiene:

$$Likelihood = \prod_{i=1}^n \frac{n_i!}{y_i!(n_i - y_i)!} \pi_i^{y_i} (1 - \pi_i)^{n_i - y_i}$$

$$\ell'(\beta) = X'(y - \mu)$$

$$\ell''(\beta) = -XWX$$

donde,

$$W = \text{diag}(n_i \pi_i (1 - \pi_i))$$

Luego aplicando el método de Newton-Rhapson se obtiene:

$$\beta^{(t+1)} = \beta^{(t)} + (X'W^{(t)}X)^{-1}X'(y - \mu^{(t)})$$

Luego, si se toma Y como la proporción de éxitos en los n_i ensayos, tendríamos que $n_i Y_i \sim Bi(n_i, \pi_i)$. Se sabe que Y_i tiene distribución Bernoulli, por lo que se conoce su esperanza y varianza.

2.2.5. Significancia de los parámetros .

Estadístico de Wald.

Los estimadores máximo verosímiles de β se distribuyen asintóticamente normal, esto implica que, para tamaños muestrales suficientemente grandes, el estadístico de Wald es:

$$W = \frac{\hat{\beta}_j}{\sqrt{\hat{V}(\hat{\beta}_j)}} \sim N(0, 1) \quad (2.14)$$

Teniendo la distribución del estimador, se plantea el test de hipótesis de la siguiente manera:

$$H_0 : \beta_j = 0 \quad vs \quad H_1 : \beta_j \neq 0 \quad j = 1, \dots, k$$

Luego, existe evidencia suficiente para rechazar H_0 si: $W < Z_{\alpha/2}$ ó $W > Z_{1-\alpha/2}$, siendo α el nivel de significancia.

Intervalos de Confianza.

Intervalos para los parámetros: el intervalo de confianza para β_j está dado por:

$$\left[\hat{\beta}_j - z_{\alpha/2} \sqrt{\hat{V}(\hat{\beta}_j)} \quad ; \quad \hat{\beta}_j + z_{\alpha/2} \sqrt{\hat{V}(\hat{\beta}_j)} \right]$$

Intervalos para los Odds: el intervalo de confianza para e^{β_j} está dado por:

$$\left[e^{\hat{\beta}_j - z_{\alpha/2} \sqrt{\hat{V}(\hat{\beta}_j)}} \quad ; \quad e^{\hat{\beta}_j + z_{\alpha/2} \sqrt{\hat{V}(\hat{\beta}_j)}} \right]$$

2.2.6. Bondad de ajuste del modelo.**Razón de verosimilitud.**

Se compara la verosimilitud del modelo propuesto con la verosimilitud de un modelo saturado, este último quiere decir que contiene tantos parámetros como observaciones tiene la muestra. Por lo tanto lo que se analiza es qué tan próximo es el modelo propuesto con un modelo saturado, donde RV es llamada razón de verosimilitud:

$$RV : \frac{\text{Verosimilitud modelo propuesto}}{\text{Verosimilitud modelo saturado}}$$

Esto hace que se la verosimilitud del modelo saturado se cancele, por lo tanto como resultado se compara directamente las verosimilitudes del modelo propuesto con el modelo nulo, luego la dócima es:

$$H_0 : L_p - L_0 = 0 \quad vs \quad H_1 : L_p - L_0 \neq 0$$

Donde, L_p y L_0 corresponden a la verosimilitud del modelo propuesto y la verosimilitud del modelo saturado respectivamente. La estadística de prueba es:

$$X^2 = 2(\ln L_p - \ln L_0) \sim \chi_k^2$$

Luego si $X^2 > \chi^2$ existe evidencia suficiente para rechazar H_0 , por lo que el modelo propuesto es adecuado.

2.2.7. Selección de Variables.

Procedimiento Stepwise Forward-Backward

De todos los posibles modelos que se pueden ajustar, debemos escoger un único modelo final que explique el comportamiento de la variable dependiente en función de las variables independientes. Para tal efecto, la regla que se debe tener siempre presente es el conocido como “principio de parsimonia”, consistente en la elección del modelo que ajuste bien los datos con el menor número de variables posible y lleve a una interpretación sencilla en términos de cocientes de ventajas. Ajustar todos y cada uno de los posibles modelos a partir de n variables explicativas para compararlos entre sí es una labor tediosa e innecesaria. En su lugar, existen procedimientos que ahorran tiempo y cálculos y que nos guían a través de un camino más directo en la búsqueda del mejor modelo posible, como son los procedimientos paso a paso (stepwise). En cada paso del procedimiento stepwise se incluye una nueva variable (stepwise forward) o se elimina una variable (stepwise backward) y se determina si el modelo resultante mejora al anterior. El procedimiento stepwise forward-backward ajusta en primer lugar un modelo para cada una de las variables y, selecciona para entrar en el modelo final aquella variable que origine el mejor modelo. En el siguiente paso, parte del modelo con la variable introducida en el paso anterior y vuelve a calcular todos los modelos posibles que combinan dicha variable con cada una de las restantes, seleccionando para entrar en el modelo la mejor entre todas las que mejoran el modelo del paso anterior. Asimismo, en cada paso se analiza el modelo resultante si se eliminaran variables de los pasos anteriores (salvo el inmediatamente anterior). El procedimiento se repite hasta que en un determinado paso ningún modelo mejore al del paso anterior, quedándonos entonces con este último modelo como el modelo definitivo. La forma de determinar si un modelo mejora a otro o no es a través de contrastes de hipótesis. En los pasos en los que se prueba introducir una nueva variable, se realizan contrastes condicionales de razón de verosimilitudes con el modelo del paso anterior como hipótesis nula y cada uno de los nuevos como hipótesis alternativa en cada contraste. Aquellos contrastes cuyo p-valor sea inferior al nivel de significación requerido determinarán las variables susceptibles de ser introducidas en el modelo en ese paso. Entre todas, se elegirá la que mejore el modelo, en el sentido de reducir más la devianza, con un p-valor adecuado. En los pasos en los que se prueba eliminar una variable, los contrastes tienen como hipótesis nula los modelos resultantes de eliminar cada una de las variables y como hipótesis alternativa el modelo que se tenía del paso anterior. En esta ocasión, las variables susceptibles de ser eliminadas serán aquellas cuyos modelos proporcionen un p-valor que supere el nivel de significación establecido, que por otra parte debe ser mayor que el nivel de significación fijado para la entrada de variables, de modo que se evite que salga la variable introducida en el paso anterior.

2.3. Modelo Naive Bayes.

2.3.1. Introducción al modelo.

Es un algoritmo de clasificación basado en el teorema de Bayes, usa frecuencias para calcular probabilidades condicionales (asumiendo independencia) de nuevos casos, por ello también es conocido como Bayes Independiente.

2.3.2. Clasificador basado en el Teorema de Bayes.

Para este algoritmo de clasificación se considera la relación entre el aprendizaje supervisado o problemas de aproximación de funciones y el razonamiento Bayesiano.[14]

Considerando un problema de aprendizaje supervisado en donde se desea aproximar un función objetivo desconocida $f : X \rightarrow Y$, o de manera equivalente $P(X|Y)$. Se va asumir que Y es una variable aleatoria de valores booleanos y por lo tanto, X es la matriz que contiene las variables independientes. Luego, aplicando el teorema de Bayes, se puede ver que $P(Y = y_i|X)$ puede ser representados como:

$$P(Y = y_i|X = x_k) = \frac{P(X = x_k|Y = y_i)P(Y = y_i)}{\sum_j P(X = x_k|Y = y_j)P(Y = y_j)} \quad (2.15)$$

Donde, y_i es el valor en específico que puede tomar la variable respuesta, dentro de los m valores posibles, en otras palabras $i = 1, \dots, m$. Una forma para hacer que el algoritmo aprenda $P(Y|X)$, es ocupar una base de entrenamiento para estimar $P(X|Y)$ y $P(Y)$. Luego ocupando estos estimadores y el teorema de Bayes se puede determinar $P(Y|X = x_k)$ para cualquier conjunto de x_k .

2.3.3. Origen del algoritmo Naive Bayes.

El algoritmo de Naive Bayes es un algoritmo de clasificación basado en el Teorema de Bayes y un conjunto de supuestos de independencia condicional. El objetivo del algoritmo es que aprenda $P(Y|X)$, donde para $X = \langle X_1, \dots, X_n \rangle$, asumiendo que cada uno de los X_i es condicionalmente independiente de cada uno de los otros X_k y también independiente de cada uno de los subconjuntos de los otros X_k dado Y . Este supuesto simplifica de manera drástica el cálculo de $P(X|Y)$ y por lo tanto, también soluciona el cálculo a través de una base de entrenamiento.

Cuando X contiene un cantidad n de atributos en donde éstos satisfacen el supuesto de independencia antes mencionado, se tiene que:

$$P(X_1 \dots X_n|Y) = \prod_{i=1}^n P(X_i|Y) \quad (2.16)$$

Luego, una manera de ver la simplificación de este cálculo es suponer que X_i e Y son variables dicotómicas, por lo tanto sólo se necesitan $2n$ parámetros para definir $P(X_i = x_{ik}|Y = y_j)$, esto es mucho más simple que calcular $2(2^n - 1)$ parámetros si no se hiciera el supuesto de independencia condicional.

Ahora bien, en general Y puede tomar cualquier valor de una variable discreta y el conjunto de variables X pueden ser tanto continuas o discretas. Por lo que el objetivo es obtener un clasificador que entregará la probabilidad de una cierta distribución Y , para cada nuevo conjunto de valores de X . La expresión para obtener la probabilidad de que la variable Y tome el valor k , de acorde al teorema de Bayes es:

$$P(Y = y_k | X_1 \dots X_n) = \frac{P(Y = y_k) P(X_1 \dots X_n | Y = y_k)}{\sum_j P(Y = y_j) P(X_1 \dots X_n | Y = y_j)} \quad (2.17)$$

Donde, la sumatoria corresponde a todos los posibles valores y_j de Y . Ahora, asumiendo que X_i es condicionalmente independiente de Y , es posible utilizar la ecuación (2.15) para reescribir lo anterior:

$$P(Y = y_k | X_1 \dots X_n) = \frac{P(Y = y_k) \prod_i P(X_i | Y = y_k)}{\sum_j P(Y = y_j) \prod_i P(X_i | Y = y_j)} \quad (2.18)$$

Esta ecuación es fundamental para el algoritmo de clasificación de Naive Bayes, ya que para un nuevo conjunto $X = \langle X_1 \dots X_n \rangle$, muestra cómo calcular la probabilidad de que Y tome cualquiera de sus valores, esto dado que se tienen los valores de X además de la distribución de $P(Y)$ y $P(X_i | Y)$ que son estimados de la base de entrenamiento. Luego, el clasificador de Naive Bayes está dado por:

$$Y \leftarrow \arg \max_{y_k} P(Y = y_k) \frac{P(Y = y_k) \prod_i P(X_i | Y = y_k)}{\sum_j P(Y = y_k) \prod_i P(X_i | y_j)} \quad (2.19)$$

Sin embargo, esta expresión se reduce a calcular solo el numerador dado que en el denominador no existen términos que dependan de y_k , por lo tanto se obtiene que el clasificador Naive Bayes es:

$$Y \leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i P(X_i | Y = y_k) \quad (2.20)$$

2.3.4. Naive Bayes Bernoulli.

EL clasificador de Naive Bayes Bernoulli, se utiliza cuando las variables predictoras siguen una distribución Bernoulli [6], con probabilidad p_i de tener la característica, donde la distribución de la variable es:

$$P(X = x) = p^x(1 - p)^{1-x} \quad (2.21)$$

Luego ocupando la ecuación (2.20), se tiene que el clasificador está dado por:

$$\begin{aligned} Y &\leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i P(X_i | Y = y_k) \\ &= \arg \max_{y_k} P(Y = y_k) \prod_{i=1}^n p_{i|Y=y_k}^{x_i} (1 - p_{i|Y=y_k})^{1-x_i} \end{aligned} \quad (2.22)$$

2.3.5. Naive Bayes Multinomial.

Cuando los n atributos de entrada X_i son variables discretas y cada variable X_i posee j categorías, donde además la variable respuesta Y puede tomar k valores, entonces se puede construir la siguiente probabilidad[6]:

$$\theta_{ijk} = P(X_i = x_{ij} | Y = y_k) \quad (2.23)$$

La cantidad de parámetros totales serán njk y además sólo $n(j-1)k$ de estos son independientes, deben satisfacer la condición $\sum_j \theta_{ijk} = 1$ para cada par i, j . Además, se debe estimar la probabilidad a priori de cada una de las posibles variables respuesta Y .

$$\pi_k = P(Y = y_k) \quad (2.24)$$

Existen k parámetros y de estos $k - 1$ son independientes.

Métodos de Estimación de Parámetros.

- **Estimadores Máximos Verosímiles (EMV):** este método se sustenta principalmente en el cálculo de las frecuencias relativas de los eventos en la base de datos.

$$\hat{\theta}_{ijk} = P(X_i = x_{ij} | Y = y_k) = \frac{\#D\{X_i = x_{ij} \wedge Y = y_k\}}{\#D\{Y = y_k\}} \quad (2.25)$$

- $\#D\{\}$: es un operador que devuelve el número de elementos en la base de datos que satisfacen las propiedad de x, es decir, la frecuencia relativa de la categoría j de la variable x_i respecto al valor k de la variable respuesta.

Además el EMV para la variable respuesta Y , está dado por:

$$\hat{\pi}_k = P(Y = y_k) = \frac{\#D\{Y = y_k\}}{|D|} \quad (2.26)$$

- **Probabilidad Máxima a Posteriori (MAP):** Un problema de la estimación máxima verosímil es que puedan haber casos donde los parámetros sean iguales a cero, si la base de datos de entrenamiento no contiene elementos en el numerador, es decir, la probabilidad de que exista alguna categoría en la base de entrenamiento pudiese dar cero, entonces por la formula (2.20) se anularía la ecuación de Naive Bayes. Para evitar esto es común hacer un arreglo a la estimación en donde se agrega una constante (l), se asume que estos casos se distribuyen uniformemente sobre los posibles valores de X_i

$$\hat{\theta}_{ijk} = P(X_i = x_{ij} | Y = y_k) = \frac{\#D\{X_i = x_{ij} \wedge Y = y_k\} + l}{\#D\{Y = y_k\} + lJ} \quad (2.27)$$

Por otra parte, el estimador para la variable respuesta Y , está dado por:

$$\hat{\pi}_k = P(Y = y_k) = \frac{\#D\{Y = y_k\} + l}{|D| + lK} \quad (2.28)$$

- J : Número de valores distintos de la variable X_i , es decir, cantidad de categorías de la variable X_i .
- l : Es el valor de la constante para que no se anule la ecuación del clasificador de Naive Bayes.

2.3.6. Naive Bayes Normal.

El clasificador Naive Bayes Normal es utilizado bajo el supuesto de que las variables predictoras condicionadas a la variable respuesta siguen una distribución Normal ($P(X_i = x_i|Y = y_k) \sim N(\mu_{iy_k}, \sigma_{iy_k}^2)$) por lo tanto la distribución de $X = x$ viene dada por [7]:

$$P(X = x|Y = y_k) = \frac{1}{\sqrt{2\pi\sigma_{x|y_k}^2}} \exp\left(-\frac{(x - \mu_{x|y_k})^2}{2\sigma_{x|y_k}^2}\right) \quad (2.29)$$

Luego, ocupando la ecuación (2.20) se tiene que el clasificador de Naive Bayes, cuando las variables predictoras siguen una distribución Normal, viene dado por:

$$\begin{aligned} Y &\leftarrow \arg \max_{y_k} P(Y = y_k) \prod_i^n P(X_i|Y = y_k) \\ &= \arg \max_{y_k} P(Y = y_k) \prod_i^n \frac{1}{\sqrt{2\pi\sigma_{x_i|y_k}^2}} \exp\left(-\frac{(x_i - \mu_{x_i|y_k})^2}{2\sigma_{x_i|y_k}^2}\right) \end{aligned} \quad (2.30)$$

Por último, al igual que en los casos anteriores se debe encontrar la clase que maximiza la probabilidad a priori de la variable respuesta y multiplicarla con las n variables predictoras.

2.4. Indicadores de discriminación.

Matriz de confusión.

Indica según el punto de corte definido por el ajuste del modelo o una categoría única, el nivel de buena clasificación que posee en relación a los valores reales, entendiéndose el punto de corte como el punto de probabilidad en donde se determinan los casos clasificados como negativos y positivos.

		Valor Real		Total
		Positivo	Negativo	
Predicción	Positivo	VP	FP	P'
	Negativo	FN	VN	N'
Total		P	N	T

Tabla 2.1: Matriz de confusión

- VP: Verdaderos positivos (éxitos).
- FP: Falsos positivos (error tipo I).
- FN: Falsos Negativos (Error Tipo II).
- VN: Verdaderos Negativos (Éxitos).

Sensibilidad.

Corresponde al porcentaje de observaciones que poseen la característica de estudio y que han sido clasificadas correctamente como que el sujeto efectivamente posee la característica.

El valor que puede asumir la sensibilidad varía del 0 al 1 (100%), es decir, cuanto más alto es el valor, hay una mejor capacidad en la detección de la característica por medio de la prueba.

$$Sensibilidad = \frac{VP}{VP + FN} \quad (2.31)$$

Especificidad.

Corresponde al porcentaje de observaciones de la otra clase que han sido correctamente clasificadas.

El valor de la especificidad varía del 0 al 1 (100%), lo que significa que cuanto mayor sea el valor, mayor capacidad de detección de sujetos que efectivamente no tiene la característica.

$$Especificidad = \frac{VN}{FP + VN} \quad (2.32)$$

Luego, la matriz de confusión se expresa de la siguiente manera:

		Valor Real	
		Positivo	Negativo
Predicción	Positivo	Sensibilidad	1-Especificidad
	Negativo	1-Sensibilidad	Especificidad
	Total	100 %	100 %

Tabla 2.2: Matriz de confusión

Accuracy:

Esto es la exactitud de un modelo, es decir, la habilidad que tiene para predecir los falsos positivos y verdaderos negativos dentro del total de la matriz de confusión.

$$acc = \frac{VP + VN}{VP + FP + FN + VN} \quad (2.33)$$

Valor Predictivo Positivo(PV+):

Corresponde a la probabilidad de que efectivamente sea positivo dado que la predicción obtuvo el valor positivo.

$$(PV+) = \frac{VP}{FP + VP} \quad (2.34)$$

Valor Predictivo Negativo(PV-):

Corresponde a la probabilidad de que efectivamente sea negativo dado que la predicción obtuvo el valor negativo.

$$(PV-) = \frac{VN}{VN + FN} \quad (2.35)$$

Curva de Roc.

Las curvas ROC (Receiver Operating Characteristic) presentan la sensibilidad de una prueba diagnóstica que produce resultados continuos, en función de los falsos positivos (complementario de la especificidad), para distintos puntos de corte. Este indicador asume el cuadrado de 1x1 como área total, por lo que el valor se mueve entre 0,5 y 1. El comportamiento de esta curva, se puede apreciar en la imagen (2.1).




Imagen 2.1: Gráfico Curva ROC

- Si la prueba fuera perfecta, es decir, sin solapamiento, hay una región en la que cualquier punto de corte tiene sensibilidad y especificidad iguales a 1: la curva sólo tiene el punto (0,1).
- Si la prueba fuera inútil: ambas funciones de probabilidad coinciden y la sensibilidad (verdaderos positivos) es igual a la proporción de falsos positivos, la curva sería la diagonal de (0,0) a (1,1). Por lo tanto no es capaz de discriminar.

Donde claramente buscamos tener una función que se encuentre lo más lejana posible de la identidad.

La Curva ROC permite poder:

- Conocer el rendimiento global del modelo. Área bajo la curva.
- Comparar dos pruebas o dos puntos de corte. Comparación de dos curvas o de dos puntos sobre una curva.
- Elegir el punto de corte apropiado.

Capítulo 3

Tratamiento de la base de datos.

Este capítulo tiene como finalidad dar a conocer el proceso de limpieza de la base de datos y explicar el algoritmo para poder recrear el proceso de atención de los pacientes, a través de censos que fueron medidos cada una hora.

3.1. Proceso de calidad de datos.

Consiste un proceso de unificación y recodificación de las variables que componen la base de datos inicial, esto debido a que la información estaba distribuida en distintas partes, es decir:

- Enero 2014 hasta diciembre del año 2015.
- Diciembre del año 2015.
- Enero hasta diciembre del año 2016.
- Base de datos correspondiente a la cantidad de pacientes hospitalizados en box, según los 4 censos realizados al día.

A continuación se detalla cada uno de los pasos de la preparación de la base de datos inicial.

3.1.1. Unificar Base de datos.

Esto corresponde a la unificación de las cuatros partes de las bases de datos, es decir seleccionar y estandarizar los nombres las variables que potencialmente podrían servir para uso de modelamiento.

3.1.2. Cálculo de los Tiempos de atención.

Las bases de datos contienen las fechas y horas de cada de las etapas del proceso de atención a un paciente del HAUP, es decir:

- Fecha de ingreso.
- Hora de ingreso.
- Fecha de atención.
- Hora de atención.
- Fecha de egreso.
- Hora de egreso.

Es fundamental poder unir la información de estas variables de la siguiente manera:

- Fecha y hora de ingreso.
- Fecha y hora de atención.
- Fecha y hora de egreso.

Esto permite poder calcular los tiempos que estuvo el paciente en cada una de las etapas del proceso de atención:

- Tiempo Urgencias: tiempo transcurrido desde el ingreso hasta el egreso de un paciente.
- Tiempo Atención: tiempo transcurrido desde que el ingresó hasta que fue atendido.
- Tiempo Atención Alta: tiempo transcurrido desde que el paciente fue atendido hasta que se retiró.

3.1.3. Tratamiento a las variables categóricas.

Esto corresponde a la unificación de variables que en distintas base de datos significaban lo mismo, pero que estaban escritas de distinta manera, por ejemplo:

- Género del paciente era posible encontrarlo como “masculino” y “MASCULINO” en términos de información significan lo mismo pero escrito de distinta manera, provocando la duplicación de categorías.

El otro tipo de categorización es la generalización de distintos segmentos llevados a uno sólo, por ejemplo la previsión de salud:

- FONASA A = FONASA
- FONASA B = FONASA

Obteniendo así, la generalización de una variable.

3.2. Recrear proceso de atención.

Dado que la base de datos obtenida del proceso anterior corresponde a los registros de cada uno de los pacientes que asistió al HUAP, carece de sentido modelar con esta base de datos, ya que se le estaría atribuyendo la característica de congestión o no congestión a un paciente, lo que es erróneo.

Para ello se creó un programa, que básicamente entrega una base de datos con la recopilación de información de todos los pacientes en un determinado momento, es decir, censos tomados cada una hora.

Especificaciones macro para recrear proceso de atención.

Esta sección hace referencia a las principales especificaciones del programa creado en el Software SAS para imitar el proceso de atención de los pacientes que asistieron al HUAP.

- **Paso 1:** Ingresar fecha inicio y fecha fin, la fecha del censo es calculada como la hora posterior a la fecha inicio.

```
%let fecha_inicio = %Sysfunc(InputN( 01JAN2015:00:00:00 , DateTime18)) ;
%let fec_censo     = %sysfunc(intnx(hour , &fecha_inicio , 1));
%let fecha_fin     = %Sysfunc(InputN( 01FEB2015:04:00:00 , DateTime18)) ;
%let hours         = %sysfunc(intck(hour,&fecha_inicio,&fecha_fin));
```

- **Paso 2:** Condición de término, el programa sigue en ejecución hasta que la fecha censo sea menor a la fecha fin

```
%do %while (&fec_censo. <= &fecha_fin.);
```

- **Paso 3:** filtros para determinar que pacientes entran en el censo.

```
data censo_&i.;
set &base_atencion.;
if fec_censo < fec_ingreso2 then delete; /*Paciente aún no entra*/
if fec_egreso2 < fecha_inicio then delete;
/*Paciente se retiró en el censo anterior*/
```

- **Paso 4:** Cálculo de los tiempo de atención según fecha censo.

```
/*TIEMPO TOTAL EN URGENCIAS*/
if      fec_censo < fec_egreso2 then
    t_urgencias =intck('minute',fec_ingreso2,fec_censo)/60;
else if fec_censo > fec_egreso2 then t_urgencias = tiempo_urgencias2;
else if fec_egreso2 = . then t_urgencias = .;

/*TIEMPO HASTA ATENCION*/
if      fec_censo > fec_ingreso2 and fec_censo < fec_atencion2
    then t_atencion = intck('minute',fec_ingreso2, fec_censo)/60;
else if fec_censo > fec_atencion2 then t_atencion = tiempo_atencion2;
else if fec_atencion2 =. then t_atencion = .;
```

- **Paso 5:** Marcar las personas que entraron y se fueron dentro del censo.

```
if fec_egreso2 < fec_censo then salida = 1 ; else salida =0;
if fec_inicio < fec_ingreso2 then entrada = 1; else entrada =0;
```

Hasta este punto se genera una tabla como la del cuadro (3.1),

Fec_inicio	Fec_censo	Fec_ingreso	Fec_egreso	Entrada	Salida	C1	C2	C3	C4
02:00:00	03:00:00	01ene14:00:11:00	01ene14:07:28:00	0	0	0	0	0	1
02:00:00	03:00:00	01ene14:00:45:00	01ene14:03:43:00	0	0	0	0	1	0
02:00:00	03:00:00	01ene14:01:12:00	01ene14:04:59:00	0	0	0	1	0	0
02:00:00	03:00:00	01ene14:01:21:00	01ene14:03:58:00	0	0	0	0	1	0
02:00:00	03:00:00	01ene14:01:54:00	01ene14:06:49:00	0	0	0	0	1	0
02:00:00	03:00:00	01ene14:01:59:00	01ene14:08:16:00	0	0	0	0	1	0
02:00:00	03:00:00	01ene14:02:05:00	01ene14:05:22:00	1	0	0	1	0	0
02:00:00	03:00:00	01ene14:02:10:00	02ene14:03:15:00	1	0	0	0	0	0
02:00:00	03:00:00	01ene14:02:19:00	01ene14:05:50:00	1	0	0	0	1	0
02:00:00	03:00:00	01ene14:02:22:00	01ene14:08:42:00	1	0	0	0	1	0
02:00:00	03:00:00	01ene14:02:33:00	01ene14:06:36:00	1	0	0	0	1	0
02:00:00	03:00:00	01ene14:02:36:00	01ene14:07:31:00	1	0	0	0	0	1
02:00:00	03:00:00	01ene14:02:38:00	01ene14:02:57:00	1	1	0	0	1	0
02:00:00	03:00:00	01ene14:02:40:00	01ene14:11:56:00	1	0	0	0	1	0
02:00:00	03:00:00	01ene14:02:46:00	01ene14:06:39:00	1	0	0	0	1	0
02:00:00	03:00:00	01ene14:02:56:00	01ene14:12:24:00	1	0	0	0	1	0
02:00:00	03:00:00	01ene14:03:00:00	01ene14:10:56:00	1	0	0	0	1	0

Tabla 3.1: Recopilación censo de las 03:00 día 01 de enero, año 2014.

- **Paso 6:** Construcción de variables que resumen las característica dentro del censo.

```
proc sql ;
create table censo_summary_&i.
as select
a.*,
b.camás1,
b.camás7,
b.camás13,
b.camás19,
sum(C1) as cant_c1 ,
sum(C2) as cant_c2 ,
sum(C3) as cant_c3 ,
sum(C4) as cant_c4 ,
sum(C5) as cant_c5 ,
median(t_urgencias) as mediana_t_urgencias,
median(t_atencion) as mediana_t_atencion,
mean(t_urgencias) as mean_t_urgencias,
mean(t_atencion) as mean_t_atencion,
sum(salida) as sum_salidas,
sum(entrada) as sum_entradas
from censo_&i. a
left join &base_camás b
on (a.fec_censo2 = b.fec_ingreso)
group by iteracion;quit;
```

Este punto muestra el cálculo de algunas de las variables finales, incluye el valor de las variables para determinar el estado de congestión, existen otras mas sin embargo no es el fin de las especificaciones. De este resultado se desprende una resultado similar al del cuadro (3.2).

Fec_inicio	Fec_censo	Entrada	Salida	C1	C2	C3	C4
01ene14:02:00:00	01ene14:03:00:00	11	1	0	2	12	2

Tabla 3.2: Resumen del censo realizado a las 03:00 hrs día 01 de enero, año 2014 .

- **Paso 7:** determinar si en el momento de la fecha del censo el HUAP está en congestión.

```
if      hora = 0 and          camás1 >= 30 then congestion = 1;
else if hora >= 1 and hora < 7 and camás1 >= 30 then congestion = 1;
else if hora >= 7 and hora < 13 and camás7 >= 30 then congestion = 1;
else if hora >= 13 and hora < 19 and camás13 >= 30 then congestion = 1;
else if hora >= 19 and          camás19 >= 30 then congestion = 1;
else congestion = 0;
```

Dado que en la realidad el HUAP mide censos , de las personas que están hospitalizadas en Box cada seis horas, la asignación del estado de congestión no es idéntica a la real, ya que hay un desfase de hasta 5 horas, es decir:

Si el censo fue realizado a las 18 hrs, se determinará si el HUAP estuvo congestionado con la información del censo real de las 13 hrs, ya que los censos reales son realizados a las; 1:00 hrs, 7:00 hrs, 13:00 hrs y 19:00 hrs.

- **Paso 8:** sumar en el contador de horas, para poder asignar la nueva hora de censo.

```
%let i = %eval(&i + 1);
%let fec_censo = %sysfunc(intnx(hour, &fec_censo. , 1));
```

- **Paso 9:** volver al Paso 2.

Luego al finalizar el proceso del programa, este entrega una base de datos resumen de cada uno de los censos que se hizo.

Fec_inicio	Fec_censo	Entrada	Salida	C1	C2	C3	C4
01ene14:00:00:00	01ene14:01:00:00	2	0	0	0	1	1
01ene14:01:00:00	01ene14:02:00:00	4	0	0	1	4	1
01ene14:02:00:00	01ene14:03:00:00	11	1	0	2	12	2
01ene14:03:00:00	01ene14:04:00:00	10	2	0	4	18	3

Tabla 3.3: Tabla final con resultados de los censos realizados desde las 01:00 hrs hasta las 04:00 día 01 de enero, año 2014

Capítulo 4

Análisis Descriptivo.

Este capítulo tiene como finalidad hacer un análisis exploratorio de la base de datos, con el fin de poder interiorizarse con el fenómeno de estudio pudiendo así tener una mirada un poco mas técnica respecto a la información que se dispone y ver la relación que tiene cada variable con el fenómeno de congestión.

Por otra parte cabe mencionar que el análisis descriptivo de los datos se hará bajo una base de datos inicial que corresponde a los registros de atención de cada persona que asistió al HUAP.

4.1. Descripción de la base de datos inicial.

La base de datos corresponde a los registros de atención de cada paciente que asistió al HUAP, es decir, los datos recopilados desde que el paciente ingresa hasta que se retira. El set de información contiene 195.218 registros de personas que asistieron al HUAP desde el año Enero del 2014 hasta Diciembre del año 2016, donde éstas fueron categorizadas como adultos.

4.1.1. Descripción de variables.

- **Sexo:** Género del paciente.
- **Previsión:** Previsión de salud del paciente.
- **Triage:** Categoría del paciente según riesgo.
- **Tiempo urgencias:** Tiempo transcurrido en horas desde ingreso del paciente al sistema hasta que se retira.
- **Tiempo atención:** Tiempo transcurrido en horas desde ingreso del paciente al sistema hasta que es atendido.
- **Camas1:** Cantidad de personas hospitalizadas en Box según censo de las 1:00 horas
- **Camas7:** Cantidad de personas hospitalizadas en Box según censo de las 7:00 horas
- **Camas13:** Cantidad de personas hospitalizadas en Box según censo de las 13:00 horas
- **Camas19:** Cantidad de personas hospitalizadas en Box según censo de las 19:00 horas

- **Sin diagnóstico:** Indica si el paciente fue atendido o si dejó el sistema antes de ser atendido.
- **Demanda:** Variable calculada que indica la cantidad de consultas en un determinado tiempo.
- **Remitido:** Lugar desde donde se envía o llega el paciente al HUAP.

4.2. Variables Discretas.

Triage.

Como se mencionó anteriormente el Triage es la categoría que se asigna a un paciente según su gravedad, existen cinco categorías para el Triage, las cuales van desde la categoría C1 hasta la categoría C5, siendo la categoría C1 la mas grave y la C5 la menos grave.




Imagen 4.1: Gráfico demandas según categoría Triage

En la figura (4.1) es posible observar las demandas de que hubo en el HUAP según la categoría Triage. Durante el transcurso de los años la demanda de los pacientes va en aumento. En términos generales existe una baja en la demanda de los pacientes en los meses de invierno, entre los meses de Junio a Septiembre pero manteniendo una estabilidad de manera porcentual, es decir, si bien la cantidad de pacientes dentro de estos meses disminuye, siguen manteniéndose los porcentajes de pacientes en sus respectivas categorías, a excepción del año 2016, se observa una baja entre los meses Abril y Junio de los pacientes clasificados con categoría C4, esto tanto en términos de frecuencias y de manera porcentual.

Para los meses Octubre y Noviembre del año 2015 no se dispone de información del Triage.

4.2.1. Previsión.

Parte de la información que se recopila en el registro de los pacientes es la previsión de salud que poseen los pacientes, existen seis categorías de previsión de salud; Capredena-Dipreca, FONASA, ISAPRE, Particular,Otros, y Sin Información.




Imagen 4.2: Gráfico demandas según Previsión de salud

A través de la figura (4.2), es posible destacar a simple vista que la mayor cantidad de personas que asisten al HUAP constan con previsión de salud FONASA.

Para los meses Julio hasta Noviembre del año 2015 no se dispone de información de la previsión de salud de los pacientes.

4.2.2. Sin diagnóstico.

Para determinar si una persona fue atendida o se retiró del HUAP, si el paciente no registra diagnóstico esto implica que la persona se retiró del HUAP antes de ser atendido.

Sin Diagnóstico




Imagen 4.3: Gráfico cantidad de personas Sin Diagnóstico.

Los meses en los que existe mayor cantidad de personas que se retiraron antes de ser atendidas se encuentran entre los meses de Abril y Septiembre, esto a lo largo de los tres años. En el mes de Julio del año 2014 se encuentra el máximo de personas que abandonaron el HUAP, siendo este el 38 % del total de las personas que asistieron aquel mes al centro de urgencias, después le siguen Septiembre del año 2016 y luego Abril del año 2015.

4.2.3. Género.

Corresponde al género de los pacientes que asistieron al HUAP.



Imagen 4.4: Género de las personas que asistieron al HUAP.

Es posible decir que prácticamente no existen diferencias entre los pacientes que asisten al HUAP, en lo que a su género se refiere.

4.2.4. Remitido Por

Esta variable refleja el origen desde el cual asiste el paciente al HUAP. Cabe notar que para el caso de Voluntario hace referencia a pacientes que llegan por su propia cuenta sin ser derivados desde alguna otra entidad.




Imagen 4.5: Origen de la asistencia del paciente al HUAP.

No es posible apreciar mayor diferencia en torno al origen desde el que llegan los pacientes en el transcurso del tiempo, si bien existe mayor o menor demanda en algunos meses, la distribución es estable en el tiempo.

4.3. Variables Continuas.

4.3.1. Hospitalizados en Box.

Esta variable es de suma importancia, debido a que será utilizada para construir el los estados de congestión en el HUAP.

Hospitalizados en Box




Imagen 4.6: Promedio y máximo mensual de pacientes hospitalizados en box.

En la figura (4.6) es posible observar dos gráficos, el primero corresponde a la cantidad promedio de personas hospitalizadas en box, de manera mensual, según su respectivo censo. Por otra parte el segundo gráfico muestra el número máximo de personas hospitalizadas en box en un mes.

En el año 2014 se observa un comportamiento más abrupto en la cantidad de pacientes hospitalizados en box, llegando a un promedio de 40 pacientes en el mes de Julio, siendo este año también el más irregular.

En el transcurso de los años 2014 y 2015 empieza haber un comportamiento más estacionario en base a sus promedios mensuales, conservando los promedios más altos entre los meses de Junio y Septiembre. Además se observa un traslado en el máximo de pacientes hospitalizados en box entre el año 2015 y 2016, siendo en Septiembre y Junio respectivamente.

4.3.2. Tiempo total en el HUAP.




Imagen 4.7: Tiempo total de los pacientes.

En la figura (4.7), se puede ver el tiempo total que estuvieron los pacientes en el HUAP contabilizados en horas y medidos en días, en torno al promedio, mediana y percentil 90.

Al igual que en las variables medidas anteriormente, las diferencias se encuentran entre los meses de Abril a Septiembre, se observan puntos de grandes magnitudes, que no se asemejan a la realidad, reflejo de ello son ejemplos como:

- Promedio registrado el día 9 de abril del año 2014, el cual llegó hasta 58 horas
- Percentil 90 registrado el día 23 de octubre del año 2014, el cual llegó hasta 118 horas.
- Promedios en octubre y diciembre los cuales superaron las 60 horas.

Por lo que en estos casos existieron problemas al registrar las fechas y horas de egreso de un conjunto de pacientes, provocando este sesgo.

4.3.3. Tiempo hasta la atención.




Imagen 4.8: Tiempos transcurridos hasta la atención de los pacientes.

En la figura (4.8), están las mediciones del tiempo hasta la atención de cada paciente, se puede apreciar que estos tiempos suben entre los meses de Abril a Septiembre, encontrando que sobrepasan las 30 horas, siendo esto un indicio más de datos que podrían haber sido mal ingresados.

4.3.4. Tiempo Atención Alta.




Imagen 4.9: Tiempo transcurrido desde la atención hasta el egreso del paciente.

El Tiempo de Atención Alta, es el tiempo medido en horas desde que el paciente es atendido hasta que este se retira del HUAP, en referencia al promedio se observan tiempos que sobrepasan las 60 horas hasta el egreso del paciente desde que estos fueron atendidos, sin embargo en ninguno de estos casos el percentil 90 sobrepasa las 20 horas, esto indica que existen algunas observaciones con fechas y horas de egreso mal ingresadas. Además se observa que la mediana y el percentil 90 permanecen estables a través del tiempo.

4.3.5. Criterio para eliminar registros.

Debido al análisis descriptivo antes mencionado, se procede a eliminar registros de pacientes, esto debido a que en la realidad los pacientes no demoran más allá de 13 horas entre la hora de ingreso y egreso, sin embargo cabe mencionar que algunas de las razones del mal ingreso de fechas que provocan estos valores irreales:

- Pacientes que se registraron, pero que se retiraron antes de ser atendidos(sin diagnóstico), por lo que muchos de estos casos son cerrados de manera administrativa, mucho tiempo después del que los pacientes se retiraron.
- Pacientes de la categoría Triage C3,C4 Y C5: estos pacientes contemplan el tiempo hasta la atención, más el tiempo de atención. En ellos el tiempo de egreso es el momento en que se cerró el caso administrativamente. Por lo tanto la verdadera hora de egreso (aquella en que se retiraron) en C3, C4 y C5 tiene censura intervalar. Se sabe que el enfermo se fue entre la hora de triage y la hora de egreso. Lo más probable es que esos pacientes se hayan ido antes del percentil 75 del tiempo de espera de los que si se atendieron y en su mayoría antes del percentil 90.

Debido a estas razones, se eliminaron a los pacientes que tuvieron un tiempo en urgencias mayor a 17 horas. Esto corresponde a un total de 6296 observaciones, por lo tanto los sujetos de modelamiento corresponden a un total 189.684 registros de pacientes. Al eliminar estos pacientes de la base de datos, los registros de las variables discretas no se ven afectadas en gran manera, es decir, no cambian sus distribuciones a través del tiempo, sin embargo las variables relacionadas a los tiempos del proceso de atención si se ven afectadas:




Imagen 4.10: Tiempo total de los pacientes.




Imagen 4.11: Tiempos transcurridos hasta la atención de los pacientes.

Dada la limitación en los tiempos que se aplicó a la base de datos, se puede apreciar un comportamiento más estable en los tiempos totales, de atención y de alta, donde además se conservan los puntos altos en los periodos de abril a septiembre indicados en primera instancia, por otra parte el promedio deja de ser tan distante de la mediana, habiendo así mas homogeneidad en los tiempos. También es preciso indicar que los valores en el percentil 90 tanto en la variable Tiempo Urgencias, Tiempo Atención y Tiempo atención Alta, siguen un comportamiento similar de sus respectivas medianas y medias.




Imagen 4.12: Tiempos transcurridos desde la atención hasta el egreso del paciente.

4.4. Descripción de la base de modelamiento.

A través de las especificaciones explicadas en el punto (3.2), el cual consiste en un algoritmo para recrear el proceso de atención de los pacientes que acuden al HUAP, a través de censos que son medidos cada una hora. Dado que la base de entrenamiento contiene registros desde el 1 de enero del año 2014 hasta el día 31 enero del año 2016, se midieron censos cada una hora, donde:

- El primer censo fue con fecha “01ENE14:01:00:00”, es decir, el día 01 de Enero del año 2014 a las 1:00 horas.
- El último censo fue con fecha “30JUN17:00:00:00”, es decir, el día 31 de Enero del año 2017 a las 00:00 horas.

Dado que ahora se tiene una base de datos que mide el estado o rendimiento del HUAP en un determinado tiempo, es posible hablar de congestión.

4.4.1. Descripción de las variables.

- **Congestión:**
 - 1: Congestión.
 - 0: No congestión.

Las variables que siguen a continuación corresponden pacientes que cumplen las siguientes características:

- Pacientes que se encuentran en tránsito, es decir, según sea la fecha y hora del censo el paciente llegó, pero aún no se ha retirado.
- Pacientes que llegaron dentro de la última hora, según la fecha y hora del censo.
- Pacientes que se retiraron dentro de la última hora, según la fecha y hora del censo.

- **Dia de la semana:** Corresponde al día de la semana del censo.
- **Cant_C1:** Cantidad de pacientes, clasificados como Triage C1.
- **Cant_C2:** Cantidad de pacientes, clasificados como Triage C2.
- **Cant_C3:** Cantidad de pacientes, clasificados como Triage C3.
- **Cant_C4:** Cantidad de pacientes, clasificados como Triage C4.
- **Cant_C5:** Cantidad de pacientes, clasificados como Triage C5.
- **Mediana_t_urgencias:** Mediana del tiempo transcurrido desde la fecha de ingreso hasta la fecha de egreso de los pacientes o hasta la fecha del censo.
- **Mediana_t_atencion:** Mediana del tiempo transcurrido desde la fecha de ingreso hasta la fecha de atención de los pacientes o hasta la fecha del censo.
- **Mediana_t_atencion_alta:** Mediana del tiempo transcurrido desde la fecha de atención hasta la fecha de egreso de los pacientes o hasta la fecha del censo.
- **Media_t_urgencias:** Media del tiempo transcurrido desde la fecha de atención hasta la fecha de egreso de los pacientes o hasta la fecha del censo.
- **Media_t_atencion:** Media del tiempo transcurrido desde la fecha de ingreso hasta la fecha de atención de los pacientes o hasta la fecha del censo.
- **Media_t_atencion_alta:** Media del tiempo transcurrido desde la fecha de atención hasta la fecha de egreso de los pacientes o hasta la fecha del censo.
- **Sum_entradas:** Cantidad de pacientes que llegaron dentro de la última hora.
- **Sum_entradas_2h:** Cantidad de pacientes que llegaron dentro de las últimas dos horas.
- **Sum_entradas_3h:** Cantidad de pacientes que llegaron dentro de las últimas tres horas.
- **Sum_salidas:** Cantidad de pacientes que retiraron dentro de la última hora.
- **Sum_salidas_2h:** Cantidad de pacientes que retiraron dentro de las últimas horas.
- **Sum_salidas_3h:** Cantidad de pacientes que retiraron dentro de la últimas tres horas.
- **Cant_sin_triage:** Cantidad de pacientes, clasificados como “Sin Info”.
- **Cant_masculino:** Cantidad de pacientes, clasificados con género Masculino.
- **Cant_femenino:** Cantidad de pacientes, clasificados con género Femenino.
- **Cant_fonasa:** Cantidad de pacientes, clasificados con previsión de salud FONASA.
- **Cant_isapre:** Cantidad de pacientes, clasificados con previsión de salud ISAPRE.
- **Cant_particular:** Cantidad de pacientes, clasificados con previsión de salud particular.
- **Cant_particular:** Cantidad de pacientes, clasificados con previsión de salud particular.
- **Cant_rem_atencion_pr** Cantidad de pacientes, remitidos por un Centro de Atención Primaria.
- **Cant_rem_carabineros** Cantidad de pacientes, remitidos por Carabineros.
- **Cant_rem_hospital** Cantidad de pacientes, remitidos por hospitales.
- **Cant_rem_samu** Cantidad de pacientes, remitidos por algún SAMU.
- **Cant_rem_voluntario** Cantidad de pacientes, que llegaron por su cuenta.

4.5. Análisis de las variables.

4.5.1. Congestión.




Imagen 4.13: Frecuencias y porcentajes de estados de congestión.

En la Imagen (4.13), se observan las frecuencias y porcentajes de los censos en los que se presentó estados de congestión, existiendo una tendencia a la baja en los estados de congestión desde el año 2014 hasta el año 2016, para el año 2017 se tiene información desde Enero hasta Junio por lo que es un poco anticipado decir que es el año con menos estados de congestión, pero si se mantuviera la tendencia la baja sería de alrededor del 2 % cada año.

4.5.2. Dia de la semana.

Esta variable corresponde al día de la semana en cual se registró el censo, por ejemplo, la fecha y hora “01ENE14:03:00:00” corresponde a un día miércoles.

Distribución estado de congestión según día de la semana




Imagen 4.14: Distribución del estado de congestión según día de la semana.

En la Imagen (4.14) se observa que los días lunes y martes son los que presentan mayor estados de congestión. En el transcurso de la semana empieza a disminuir la cantidad de estados de congestión hasta el día sábado, donde es posible observar un aumento de la congestión en el HUAP.

4.5.3. Triage.

Demanda Promedio por Censo




Imagen 4.15: Demanda promedio anual según Triage y estado de congestión.

La Imagen (4.15), se observa la cantidad promedio de personas en los censos, separando por estado de congestión, a través de este gráfico se observa que principalmente la categoría Triage C4 es la que presenta mayor cambio cuando el HUAP está congestionado, en promedio existen alrededor de 5 a 7 personas más en la categoría C4 cuando hay congestión. Para el resto de las categorías no existen mayor diferencia cuando el HUAP está congestionado.

4.5.4. Promedio de tiempos asociado al proceso de atención.

Promedio de los tiempos según estado de congestión




Imagen 4.16: Promedio de los tiempos de atención, tiempo urgencias y tiempo atención alta, identificando periodos de congestión.

La Imagen (4.16) muestra los promedios por censo relacionado a los tiempos del proceso de atención, es decir:

- Promedio del tiempo hasta la atención.
- Promedio del tiempo desde la atención hasta el egreso.
- Promedio del tiempo total en urgencias.

Se puede ver una clara estacionalidad en los estados de congestión, donde estos aparecen principalmente durante los periodos de Abril y Septiembre, esto para cualquiera de los años. En el año 2014 existieron más periodos de congestión, además cabe mencionar que el promedio del tiempo hasta la atención, es donde se observan que los puntos más altos separando por estados de congestión, por lo que la asignación del estado de congestión tiene sentido, debido a que los pacientes permanecen más tiempo hasta que puedan ser atendidos, así también el promedio del tiempo total en urgencias, el cual tiene incluido el tiempo hasta la atención, sin embargo es posible observar que para el tiempo desde la atención hasta el egreso aquello no cumple dicho comportamiento.

4.5.5. Mediana de tiempos asociado al proceso de atención.

Mediana de los tiempos según estado de congestión




Imagen 4.17: Mediana de los tiempos de atención, tiempo urgencias y tiempo atención alta, identificando periodos de congestión.

La imagen 4.17 muestra las medianas por censo relacionado a los tiempos del proceso de atención, es decir:

- Mediana del tiempo hasta la atención.
- Mediana del tiempo desde la atención hasta el egreso.
- Mediana del tiempo total en urgencias.

Es posible apreciar un comportamiento similar que en los promedios de los tiempos relacionados al proceso de atención, donde los puntos con magnitud en las variables medianas del tiempo hasta la atención y mediana del tiempo en urgencias, se encuentran en periodos de congestión, no así para la variable mediana del tiempo atención alta.

4.5.6. Flujos durante la última hora.

Promedio de los flujos durante la última hora




Imagen 4.18: Promedio mensual de entradas y salidas durante la última hora, identificando periodos de congestión.

Por flujos se entiende, la cantidad de personas que entraron y salieron del HUAP en un determinado intervalo de tiempo. La Imagen (4.18) representa el promedio mensual del flujo de personas durante la última hora, es decir, el promedio mensual de personas que entraron y salieron dentro de la última hora. Se puede ver claramente la diferencia entre las entradas y salidas, cuando el HUAP se encuentra en estado de congestión y cuando no lo está. A continuación se indican las principales observaciones:

- El comportamiento de la cantidad de personas que entran y se retiran del HUAP es bastante regular y además mantienen el mismo nivel entre la cantidad de personas que llegan y se retiran, cuando no hay congestión.
- El comportamiento de la cantidad de personas que entran y se retiran del HUAP es mas bien irregular, cuando existe congestión.
- La cantidad de personas que llegan al HUAP sube de siete a diez personas en promedio durante una hora, tomando en cuenta el estado de no congestión a congestión.
- La cantidad de personas que se retiran es sobrepasada por la cantidad de personas que llegan, cuando existe congestión.

4.5.7. Flujos durante las últimas dos horas.

Promedio de los flujos durante las últimas dos horas




Imagen 4.19: Promedio mensual de entradas y salidas durante las últimas dos horas, identificando periodos de congestión.

La Imagen (4.19) representa lo mismo que la Imagen (4.18) mencionada en el punto anterior, destacando que esta variable representa los flujos durante las últimas dos horas y es posible apreciar que la interpretación es análoga a la anterior, sólo con la distinción que las magnitudes suben.

4.5.8. Flujos durante las últimas tres horas.

Promedio de los flujos durante las últimas tres horas




Imagen 4.20: Promedio mensual de entradas y salidas durante las últimas tres horas, identificando periodos de congestión.

El comportamiento apreciado en la Imagen (4.20) es idéntico al observado en los flujos durante la última hora.

Sin embargo, cabe destacar que si bien los comportamientos son iguales en los tres tipos de flujos, este último tiene mayor sentido o importancia en el sentido lógico de la variable, es decir, en términos de anticipar periodos de congestión claramente esta podría ser una variable de gran ayuda.

Capítulo 5

Implementación de Modelos.

5.1. Regresión Logística.

El modelo logístico completo contiene un total de 29 variables, por lo tanto se debe seguir una estrategia para poder reducir la cantidad de variables, en otras palabras tener en consideración la regla de parsimonia sin perder el nivel de clasificación.

5.1.1. Selección de Variables.

En este apartado se explican los pasos seguidos dentro del procedimiento de selección stepwise forward-backward. En primer lugar se ajustará el modelo sin variables y a continuación se irán añadiendo y/o eliminando variables en cada paso tal y como se explicó cuando se habló de este método de selección. En cada paso se realizará un test condicional de razón de verosimilitudes para contrastar el modelo del paso anterior con cada uno de los posibles modelos planteados en el nuevo paso. En base a él, se decidirá qué variable debe entrar (o salir) en ese paso, si procede.

Iteración 1.

En primer lugar se ajusta el modelo sin variables, que será el modelo básico frente al que contrastaremos los nuevos modelos en este paso. Posteriormente se ajustará un modelo para cada una de las variables consideradas, incluidas las variables de diseño, y mediante el test condicional de razón de verosimilitudes decidiremos cuál debería entrar. Los resultados del test en este primer paso se observan en la tabla.

Modelo 0: Congestión $\sim$ Nulo			
Modelo 1: Congestión $\sim$ Media.t.atención			
Modelo	Devianza	Delta Devianza	P-valor
Modelo 0	21606	-	-
Modelo 1	20363	1243	0.00

Tabla 5.1: Test de razón de verosimilitudes para la iteración 1

En la Tabla (5.1), se observa el valor de la devianza del modelo nulo y el modelo ajustado con la variable `media_t_atención`, al comparar estos valores se concluye que la diferencia es significativa a través del p-valor del test de razón de verosimilitud.

Coeficiente	Estimado	Error Estándar	z	P-valor
Intercepto	-2.73237	0.03436	-79.52	0.00
Media_t_atención	0.4037	0.01141	35.38	0.00

Tabla 5.2: Resumen de los parámetros del modelo 1

La Tabla (5.2), muestra un resumen del modelo en el que se puede concluir que la variable ingresada al modelo es significativa.

Iteración 2.

Para la segunda iteración se comienza a partir del modelo con la variable `media_t_atención` y se ajustan nuevos modelos para cada una de las variables restantes.

Modelo1: Congestión $\sim$ Media_t_atención			
Modelo2: Congestión $\sim$ Media_t_atención + Mean_t_urgencias			

Modelo	Devianza	Delta Devianza	P-valor
Modelo 1	20363	-	-
Modelo 2	19448	915	0.00

Tabla 5.3: Test de razón de verosimilitudes para la iteración 2

A través de la Tabla (5.3) se observa que la variable que minimiza la devianza es `Media_t_urgencias` y el p-valor es muy cercano a cero, por lo tanto esta variable debe entrar al modelo.

Coeficiente	Estimado	Error Estándar	z	P-valor
Intercepto	-1.29216	0.05913	-21.85	0.00
Media_t_atención	1.26754	0.03432	36.93	0.00
Media_t_urgencias	-0.93405	0.03431	-27.23	0.00

Tabla 5.4: Resumen de los parámetros del modelo 2

De la Tabla (5.4), se observa que ambas variables son significativas de acuerdo al p-valor, pero cabe destacar que según el coeficiente de la variable `Media_t_urgencias`, ésta variable es un factor de protección, por lo que carece de sentido lógico, ya que mediante más alto sean los tiempos medios en urgencias se podría esperar con mayor probabilidad que el HUAP esté en congestión.

Iteración 3.

Para la tercera iteración se comienza a partir del modelo con la variable Media.t.atención más la variable Media.t.urgencias y se ajustan nuevos modelos para cada una de las variables restantes.

Modelo 2: Congestión $\sim$ Media.t.atención + Mean.t.urgencias			
Modelo 3: Congestión $\sim$ Media.t.atención + Mean.t.urgencias + Dia.Semana			
Modelo	Devianza	Delta Devianza	P-valor
Modelo 2	19448	-	-
Modelo 3	19091	357	0.00

Tabla 5.5: Test de razón de verosimilitudes para la iteración 3

A través de la Tabla (5.3) se observa que la variable que minimiza la devianza es día de la semana, además el p-valor es muy cercano a cero, por lo tanto esta variable debe entrar al modelo.

Luego se realiza el test de razón de verosimilitudes para determinar si es posible sacar la variable Media.t.atención del modelo, variable que fue ingresada en la iteración 1.

Modelo 3: Congestión $\sim$ Media.t.atencion + Media.t.urgencias + Día			
Modelo 3.1: Congestión $\sim$ Media.t.urgencias + Día			
Modelo	Devianza	Delta Devianza	P-valor
Modelo 3	19091	-	-
Modelo 3.1	20840	1749	0.00

Tabla 5.6: Test razón de verosimilitudes para sacar variable ingresada en iteración 1

De la Tabla (5.6), se observa que al sacar la variable Media.t.atención el modelo no mejora, por lo tanto la variable ingresada en la iteración 1 debe permanecer en el modelo.

Coefficiente	Estimado	Error Estándar	z	P-valor
Intercepto	-1.19004	0.07573	-15.713	0.00
Media.t.atención	1.2536	0.03462	36.215	0.00
Media.t.urgencias	-0.90782	0.0345	-26.316	0.00
Día.lunes	0.27779	0.0659	4.216	0.00
Día.martes	0.12793	0.06613	1.935	0.053
Día.miércoles	-0.1177	0.06844	-1.72	0.0854
Día.jueves	-0.5269	0.07434	-7.088	0.00
Día.viernes	-0.72835	0.07817	-9.317	0.00
Día.sábado	-0.50773	0.07548	-6.726	0.00

Tabla 5.7: Resumen de los parámetros del modelo 3

Se observa de la Tabla (5.7) que todos los coeficientes del modelo son significativos a excepción de la variable dummy Día miércoles, tomando un nivel de significancia del 5 %.

Iteración 4.

Para la cuarta iteración se comienza a partir del modelo con la variable Media.t.atención, Media.t.urgencias y Día, luego se ajustan nuevos modelos para cada una de las variables restantes.

Modelo 3:	Congestión $\sim$	Media.t.atencion + Media.t.urgencias + Día
Modelo 4:	Congestión $\sim$	Media.t.atencion + Media.t.urgencias + Día + Sum_salidas_3h

Modelo	Devianza	Delta Devianza	P-valor
Modelo 3	19091	-	-
Modelo 4	18792	299	0.00

Tabla 5.8: Test razón de verosimilitudes para la iteración 4

Seguendo la estrategia de las iteraciones anteriores, se puede observar en la Tabla (5.8) que la variable seleccionada es suma de salidas durante las últimas tres horas (sum_salidas_3h), ya que es la variable que minimiza la devianza.

Luego se realiza el test de verosimilitudes para determinar si es posible sacar las variables ingresadas en la iteración 1 e iteración 2.

Modelo 4:	Congestión $\sim$	Media.t.atencion + Media.t.urgencias + Día + Sum_salidas_3h
Modelo 4.1:	Congestión $\sim$	Media.t.urgencias + Día + Sum_salidas_3h
Modelo 4.2:	Congestión $\sim$	Media.t.atencion + Día + Sum_salidas_3h

Modelo	Devianza	Delta Devianza	P-valor
Modelo 4	18792	-	-
Modelo 4.1	20709	1917	0.00
Modelo 4.2	19783	991	0.00

Tabla 5.9: Test razón de verosimilitudes para determinar si es posible sacar las variables agregadas en las primeras dos iteraciones

En la Tabla (5.9), se observa que al sacar las variables ingresadas en las primeras dos iteraciones los modelos no mejoran, por lo tanto estas deben permanecer en el modelo.

Coefficiente	Estimado	Error Estándar	z	P-valor
(Intercept)	-0.458579	0.086689	-5.29	0.00
mean.t.atencion	1.309181	0.034454	37.998	0.00
mean.t.urgencias	-0.964876	0.034068	-28.322	0.00
Día_lunes	0.356667	0.066522	5.362	0.00
Día_martes	0.255479	0.067116	3.807	0.00
Día_miércoles	-0.014145	0.069361	-0.204	0.083
Día_jueves	-0.453168	0.075033	-6.04	0.00
Día_viernes	-0.660113	0.078856	-8.371	0.00
Día_sábado	-0.43918	0.076288	-5.757	0.00
sum_salidas_3h	-0.034508	0.002062	-16.738	0.00

Tabla 5.10: Resumen de los coeficientes del modelo 4

En la Tabla (5.10) se tiene el resumen del modelo obtenido en la iteración 4 y es posible observar que todas las variables son significativas a excepción de el día miércoles.

Iteración 5.

Para la quinta iteración se comienza a partir del modelo con la variable Media.t.atención, Media.t.urgencias, Día y sum.salidas.3h luego se ajustan nuevos modelos para cada una de las variables restantes.

Modelo 4:	Congestión $\sim$	Media.t.atencion + Media.t.urgencias + Día + Sum.salidas.3h
Modelo 5:	Congestión $\sim$	Media.t.atencion + Media.t.urgencias + Día + Sum.salidas.3h + Media.t.atención.alta

Modelo	Devianza	Delta Devianza	P-valor
Modelo 4	18792	-	-
Modelo 5	18654	138	0.00

Tabla 5.11: Test de razón de verosimilitud para la iteración 5

En la iteración 5, la variable que minimiza es Media.t.atención.alta y si bien esta diferencia en la devianza es significativa, se decide ingresar esta variable pero sacando del modelo la variable Media.t.urgencias, ya que esta última se compone por las otras dos variables de tiempo ingresadas en el modelo, pudiendo provocar multicolinealidad.

Variable	VIF
Media.t.atencion	13.694
Media.t.urgencias	16.249
Día	1.069
Sum.salidas.3h	1.139
Media.t.atencion.alta	2.221

Variable	VIF
Media.t.atencion	1.087
Día	1.060
Sum.salidas.3h	1.145
Media.t.atencion.alta	1.175

Tabla 5.12: Factores de inflación de varianza.

Al ver la Tabla (5.12), se rectifica lo mencionado anteriormente, por lo tanto la variable Media.t.atencion.alta entra al modelo y la variable Media.t.urgencias debe salir.

Modelo 5:	Congestión $\sim$	Media.t.atencion + Media.t.atencion.alta+ Día + Sum.salidas.3h
Modelo 5_1:	Congestión $\sim$	Media.t.atencion.alta+ Día + Sum.salidas.3h
Modelo 5_2:	Congestión $\sim$	Media.t.atencion + Media.t.atencion.alta + Sum.salidas.3h

Modelo	Devianza	Delta Devianza	P-valor
Modelo 5	19566	-	-
Modelo 5_1	20963	1397	0.00
Modelo 5_2	19981	415	0.00

Tabla 5.13: Test de razón de versosimilitudes para determinar si es posible sacar las variables agregadas en las iteraciones 1 y 3.

En la Tabla (5.13), se observa que al sacar cualquiera de las dos variables, el modelo no mejora, por lo tanto ambas variables deben permanecer en el modelo.

Coefficiente	Estimado	Error Estándar	z	P-valor
(Intercept)	-1.276475	0.09005	-14.175	0.00
Media.t.atención	0.446618	0.012066	37.014	0.00
Media.t.atención.alta	-0.316453	0.022052	-14.351	0.00
Día_lunes	0.483744	0.064986	7.444	0.00
Día_martes	0.346157	0.065862	5.256	0.00
Día_miércoles	0.046933	0.068186	0.688	0.491
Día_jueves	-0.369532	0.07363	-5.019	0.00
Día_viernes	-0.607845	0.077727	-7.82	0.00
Día_sábado	-0.434534	0.075084	-5.787	0.00
sum.salidas.3h	-0.035188	0.002102	-16.737	0.00

Tabla 5.14: Resumen de los coeficientes del modelo 5

Por último en la Tabla (5.14), se tiene que todos los coeficientes del modelo son significativos a excepción de la variable Día miércoles.

Iteración 6.

Para la sexta iteración se comienza a partir del modelo con la variable `Media.t.atención`, `Media.t.atención.alta`, `Día` y `sum.salidas.3h` luego se ajustan nuevos modelos para cada una de las variables restantes.

Modelo 5:	Congestión $\sim$	<code>Media.t.atencion</code> + <code>Media.t.atención.alta</code> + <code>Día</code> + <code>Sum.salidas.3h</code>
Modelo 6:	Congestión $\sim$	<code>Media.t.atencion</code> + <code>Media.t.atención.alta</code> + <code>Día</code> + <code>Sum.salidas.3h</code> + <code>Cant.C4</code>

Modelo	Devianza	Delta Devianza	P-valor
Modelo 5	19566	-	-
Modelo 6	19288	278	0.00

Tabla 5.15: Test de razón de verosimilitudes para variable entrante en iteración 6.

Para esta última iteración la variable que minimiza la devianza es cantidad de personas categorizadas como Triage C4.

Modelo 6:	Congestión $\sim$	<code>Media.t.atención.alta</code> + <code>Día</code> + <code>Sum.salidas.3h</code> + <code>Cant.C4</code>
Modelo 6_1:	Congestión $\sim$	<code>Media.t.atencion</code> + <code>Media.t.atención.alta</code> + <code>Día</code> + <code>Sum.salidas.3h</code> + <code>Cant.C4</code>
Modelo 6_3:	Congestión $\sim$	<code>Media.t.atencion</code> + <code>Media.t.atención.alta</code> + <code>Sum.salidas.3h</code> + <code>Cant.C4</code>
Modelo 6_4:	Congestión $\sim$	<code>Media.t.atencion</code> + <code>Media.t.atención.alta</code> + <code>Día</code> + <code>Cant.C4</code>

Modelo	Devianza	Delta Devianza	P-valor
Modelo 6:	19288	-	-
Modelo 6_1:	19715	427	0.00
Modelo 6_3:	19605	315	0.00
Modelo 6_4:	19715	427	0.00

Tabla 5.16: Test de razón de verosimilitud para determinar si es posible sacar las variables de las tres primeras iteraciones.

Al igual que en las iteraciones anteriores, de la Tabla (5.16) se concluye que las variables de las iteraciones anteriores deben permanecer dentro del modelo, debido a que éste no mejora al sacarlas.

Coefficiente	Estimado	Error Estándar	z	P-valor
(Intercept)	-1.510846	0.09268	-16.302	0.00
Media_t_atención	0.376586	0.012846	29.315	0.00
Media_t_atención_alta	-0.265087	0.022568	-11.746	0.00
Día_lunes	0.317653	0.066434	4.782	0.00
Día_martes	0.208211	0.066914	3.112	0.00
Día_miércoles	-0.025275	0.068625	-0.368	0.7126
Día_jueves	-0.428286	0.074004	-5.787	0.00
Día_viernes	-0.647317	0.077991	-8.3	0.00
Día_sábado	-0.467874	0.075338	-6.21	0.00
sum_salidas_3h	-0.044595	0.002253	-19.796	0.00
Cant_C4	0.026536	0.001604	16.548	0.00

Tabla 5.17: Resumen de los coeficientes del modelo 6

En la Tabla (5.17), se observa que todos los coeficientes son significativas a excepción de la variable día miércoles, sin embargo se decide dejar esta variable en el modelo debido a que esta variable es una categoría de la variable dummy día de la semana.

5.2. Selección del Modelo.

En esta sección, explica cual es el modelo seleccionado, si bien se han seleccionado las variables no se puede perder el criterio de parsimonia, por lo tanto se busca un modelo que pueda predecir de manera eficaz con la menor cantidad de variables.

Modelos Propuestos	
Modelo 5: Congestión ~	Media.t.atencion + Media.t.atención.alta + Día + Sum_salidas_3h
Modelo 6: Congestión ~	Media.t.atencion + Media.t.atención.alta + Día + Sum_salidas_3h + Cant_C4

Tabla 5.18: Modelos Propuestos

En la Tabla (5.29), están indicados los modelos que se trabajarán para determinar cuál es el mejor. A continuación se entregarán los resultados de cada modelo.

Resultado base de entrenamiento.




Imagen 5.1: Cutoff vs Accuracy del modelo 5




Imagen 5.2: Cutoff vs Accuracy del modelo 6

Punto de corte, según exactitud. Las imágenes (5.1) y (5.2) se observa la exactitud en función del punto de corte, con el fin de determinar el punto de corte que maximiza la precisión.

En la Tabla (5.19), se observa que el punto de corte para el modelo 5 es 0.51 y para el modelo 6 el punto de corte es 0.45,

	Modelo 5	Modelo 6
Punto corte	0.51	0.45
Exactitud	0.857	0.86

Tabla 5.19: Puntos de corte y exactitud

Matriz de Confusión: En las tablas (5.20) y (5.21), se observa el cruce entre los valores predichos y valores reales de estados de congestión. Ambos modelos tienen un rendimiento muy similar basándose en la medidas de discriminación. Cabe destacar que el modelo 6 presenta un índice de sensibilidad del 10 %, esto es un 4 % más que el modelo 5, por lo tanto se tiene que el modelo 6 identifica de mejor manera los estados de congestión, lo que se puede corroborar en la matriz de confusión, donde el modelo 6 predice de mejor manera 158 estados de congestión positivos más que el modelo 5. Si bien el modelo 6 tiene mayor cantidad de falsos positivos, en términos de porcentaje no es tan significativa como el alza en los verdaderos positivos.

		Real Congestión	
		1	0
Predicción Congestión	1	224	221
	0	3535	22387

Accuracy	85.8 %	VP+	50.34 %
Sensibilidad	6.0 %	VP-	86.36 %
Especificidad	99.0 %		

Tabla 5.20: Matriz de confusión modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	382	357
	0	3377	22251

Accuracy	85.84 %	VP+	51.69 %
Sensibilidad	10.2 %	VP-	86.82 %
Especificidad	98.4 %		

Tabla 5.21: Matriz de confusión modelo 6




Imagen 5.3: Cutoff vs Precision - Recall, del modelo 5




Imagen 5.4: Cutoff vs Precision - Recall, del modelo 5

Punto de corte, según Recall y Precision. En la Imagen (5.3) y (5.4) se observa los gráficos de las tasas de precisión (sensibilidad) y valor predictivo positivo (PV+) con sus respectivos puntos de corte esto con el fin de conseguir el menor error al momento de predecir congestión (congestión = 1). Sin embargo, se puede observar que los puntos de corte son bajos. En la tabla (5.22), se encuentran los puntos de corte de ambos modelos.

	Modelo 5	Modelo 6
Punto corte	0.225	0.235
Exhaustividad - Precisión	0.355	0.374

Tabla 5.22: Puntos de corte, según Recall y Precision.

		Real Congestión	
		1	0
Predicción Congestión	1	224	221
	0	3535	22387

Accuracy	85.8 %	VP+	50.34 %
Sensibilidad	6.0 %	VP-	86.36 %
Especificidad	99.0 %		

Tabla 5.23: Matriz de confusión modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	382	357
	0	3377	22251

Accuracy	85.84 %	VP+	51.69 %
Sensibilidad	10.2 %	VP-	86.82 %
Especificidad	98.4 %		

Tabla 5.24: Matriz de confusión modelo 6

Curva Roc: El mejor rendimiento del modelo 6 indicado anteriormente se puede observar a través de sus respectivas gráficas de la curva de Roc en las imágenes (5.5) y (5.6), donde el modelo 6 presenta mayor nivel de la sensibilidad en función de la razón de los falsos positivos.




Imagen 5.5: Curva Roc modelo 5




Imagen 5.6: Curva Roc modelo 6

Resultados base de validación

Matriz de confusión (Accuracy): Al igual que para la base de entrenamiento en la Imagen (5.25) y (5.26), se observa el cruce de los valores predichos y los valores reales de ambos modelos, se observa que el modelo 6 clasifica mejor que el modelo 5 los estados de congestión positivos. Cabe destacar que en ambos modelos la exactitud subió alrededor de un 5 %, sin embargo la sensibilidad disminuyó en un 4 % y con ello también el valor predictivo positivo, no obstante el modelo 6 sigue siendo mejor.

		Real Congestión	
		1	0
Predicción Congestión	1	13	14
	0	376	3905

Accuracy	90.95 %	VP+	48.15 %
Sensibilidad	3.3 %	VP-	91.22 %
Especificidad	99.6 %		

Tabla 5.25: Matriz de confusión para la base de validación - modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	25	35
	0	364	3884

Accuracy	90.74 %	VP-	41.67 %
Sensibilidad	6.4 %	VP+	91.43 %
Especificidad	99.1 %		

Tabla 5.26: Matriz de confusión para la base de validación - modelo 6

		Real Congestión	
		1	0
Predicción Congestión	1	83	308
	0	233	3686

Accuracy	87.4 %	VP+	21.23 %
Sensibilidad	26.3 %	VP-	94.05 %
Especificidad	92.3 %		

Tabla 5.27: Matriz de confusión para la base de validación - modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	93	298
	0	270	3646

Accuracy	86.81 %	VP+	23.79 %
Sensibilidad	25.6 %	VP-	93.11 %
Especificidad	92.4 %		

Tabla 5.28: Matriz de confusión para la base de validación - modelo 6

Matriz de confusión (Precision - Recall): En las tablas (5.27) y (5.28), se observa la matriz de confusión para la base de validación, donde es posible ver que el accuracy, especificidad y valor predictivo positivo disminuyen, esto tiene sentido debido a que el punto de corte asignado es muy bajo en comparación en el método de punto de corte a través del accuracy. Sin embargo la sensibilidad y el valor predictivo negativo aumentan.

Por lo tanto, el puntaje de corte escogido es a través del accuracy, si bien no logra predecir una gran cantidad de periodos de congestión, la cantidad de valores falsos positivos son significativamente menores a la clasificación según el punto de corte de sensibilidad vs valor predictivo positivo.

Curva Roc: Los resultados explicados anteriormente pueden verse reflejados en la curva Roc en la Imagen (5.7). en la imagen se observa que el modelo 6 es levemente mejor al modelo 5.




Imagen 5.7: Curva Roc modelo 5 - Curva Roc modelo 6.

5.3. Clasificador de Naïve Bayes.

En la selección del modelo logístico se propuso el modelo 5 y el modelo 6, por lo tanto para poder comparar el rendimiento del Modelo Logístico y el Clasificador de Naïve Bayes se mostrarán los resultados del clasificador de Naïve Bayes con las mismas variables que en los modelos logísticos.

Modelos Propuestos			
Modelo 5:	Congestión $\sim$	Media.t.atencion + Media.t.atención.alta + Día + Sum_salidas_3h	
Modelo 6:	Congestión $\sim$	Media.t.atencion + Media.t.atención.alta + Día + Sum_salidas_3h + Cant_C4	

Tabla 5.29: Modelos Propuestos

Modelos propuestos Para recordar, en la Tabla (5.29), se indican las variables con las que se construye cada modelo.

Recordar que para las variables predictoras continuas, se trabajará bajo el supuesto de distribución condicional Normal.

$$P(X_i = x_i | Y = y_k) \sim N(\mu_{iy_k}, \sigma_{iy_k}^2)$$

Las siguientes variables fueron estandarizadas para cumplir con el supuesto de distribución Normal de las variables predictoras:

- Media.t.atención.
- Media.t.atención.alta.
- Sum_salidas_3h.
- Cant_C4.

Probabilidad de congestión.

$P(\text{congestión}=0)$	$P(\text{congestión}=1)$
0.8574	0.1426

Tabla 5.30: Probabilidad a Priori de la variable congestión

En la tabla(5.30), se tiene la probabilidad a priori del estado de congestión, por lo que se puede observar que la base es desbalanceada en cuando a esta probabilidad, ya que sólo un 15 % de la base de entrenamiento presenta estado de congestión positivo.


Distribuciones condicionales de las variables continuas.

Imagen 5.8: Distribuciones de las variables continuas dado el estado de congestión.

En Imagen (5.8), se encuentran graficadas las distribuciones condicionales de cada una de las variables continuas según sea el estado de congestión, se puede observar la semejanza con la distribución Normal o más bien con la distribución T-Student.

Distribución condicional variable día de la semana.

Congestión	Día de la semana						
	Lunes	Martes	Miércoles	Jueves	Viernes	Sábado	Domingo
0	0.134	0.132	0.140	0.148	0.152	0.151	0.144
1	0.197	0.206	0.162	0.110	0.090	0.099	0.136

Tabla 5.31: Probabilidad de los días de la semana según estado de congestión.

En la Imagen (5.31) se tienen las probabilidades condicionales $P(Diadelasemana|Congestión)$ para cada una de sus combinaciones, las observaciones son las siguientes:

- Cuando no hay congestión, los días con menor probabilidad son lunes y martes.
- Cuando no hay congestión, los días con mayor probabilidad son jueves, viernes y sábado.
- Cuando hay congestión, los días con mayor probabilidad son lunes y martes.
- Cuando hay congestión, los días con menor probabilidad son jueves, viernes y sábado.

Esto tiene sentido, para ello recordar la sección(4.5.2) donde se hizo el análisis descriptivo de esta variable.


Resultados base de entrenamiento.**Punto de Corte (Accuracy).**

Imagen 5.9: Punto de corte - modelo 5




Imagen 5.10: Punto de corte - modelo 6

De las Imágenes (5.9) y (5.10) se puede desprender que ambos modelos maximizan su exactitud alrededor del mismo punto de corte, estos valores se pueden observar en la Tabla (5.32).

	Modelo 5	Modelo 6
Punto de corte	0.62	0.61
Exactitud	0.85	0.85

Tabla 5.32: Puntos de corte y exactitud

Matriz de confusión.

		Real Congestión	
		1	0
Predicción Congestión	1	344	570
	0	3415	22038

Accuracy	84.9 %	VP+	37.64 %
Sensibilidad	9.2 %	VP-	86.58 %
Especificidad	97.5 %		

Tabla 5.33: Matriz de confusión e indicadores - Modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	555	834
	0	3204	21774

Accuracy	84.69 %	VP+	39.96 %
Sensibilidad	14.8 %	VP-	87.17 %
Especificidad	96.3 %		

Tabla 5.34: Matriz de confusión e indicadores - Modelo 6

A través de las tablas (5.33) y (5.39), se observa el cruce entre los valores reales y las predicciones de ambos modelos. En términos generales ambos modelos presentan el mismo nivel de exactitud, sin embargo el modelo 6 presenta un poder de predicciones en los verdaderos positivos considerablemente mayor al del modelo 5, llegando a un nivel de sensibilidad del 5 %. En torno a los demás indicadores no existen mayores diferencias.


Punto de Corte (Recall-Precision).

Imagen 5.11: Punto de corte - modelo 5




Imagen 5.12: Punto de corte - modelo 6

En las Imágenes (5.11) y (5.12) se observa que los puntos de corte a través de esta metodología son bajos, aún mas que en la regresión logística.

	Modelo 5	Modelo 6
Punto corte	0.205	0.258
Exhaustividad - Precisión	0.328	0.335

Tabla 5.35: Puntos de corte, según Recall y Precision.

Matriz de confusión.

		Real Congestión	
		1	0
Predicción Congestión	1	1219	2541
	0	2529	20088
Accuracy	80.8 %	VP+	32.42 %
Sensibilidad	32.5 %	VP-	88.82 %
Especificidad	88.8 %		

Tabla 5.36: Matriz de confusión e indicadores - Modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	1255	2505
	0	2500	20117
Accuracy	81.03 %	VP+	33.38 %
Sensibilidad	33.4 %	VP-	88.95 %
Especificidad	88.9 %		

Tabla 5.37: Matriz de confusión e indicadores - Modelo 6

Al ver las clasificaciones a través de las tablas (5.36) y (5.41), se puede observar que el modelo logra clasificar mayor cantidad de estados de congestión positivos, sin embargo la cantidad de falsos positivos también aumenta y además la exactitud del modelo baja en alrededor de un 5 %.


Curva Roc.

Imagen 5.13: Curva de Roc - modelo 5




Imagen 5.14: Curva de Roc - modelo 6

Anteriormente se mencionó que no había grandes diferencias entre los dos modelos, a través de las Curvas de Roc de las Imágenes (5.13) y (5.14), es posible concluir que no existe mayores diferencias entre ellos.

Resultados base de validación.**Matriz de confusión(Accuracy).**

		Real Congestión	
		1	0
Predicción Congestión	1	29	44
	0	360	3875

Accuracy	90.6 %	VP+	39.73 %
Sensibilidad	7.5 %	VP-	91.50 %
Especificidad	98.9 %		

Tabla 5.38: Matriz de confusión e indicadores - Modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	42	124
	0	347	3795

Accuracy	89.07 %	VP+	25.30 %
Sensibilidad	10.8 %	VP-	91.62 %
Especificidad	96.8 %		

Tabla 5.39: Matriz de confusión e indicadores - Modelo 6

En las tablas (5.33) y (5.39) se observa que ambos modelos alcanzan una exactitud similar y al observar los demás indicadores se puede concluir que no existe gran diferencia entre ambos modelos, excepción de los valores predictivos positivos que en el modelo 5 alcanza el 39.73 %, mientras que en el modelo 6 un 25.3 %.

Matriz de confusión(Recall - Precision).

		Real Congestión	
		1	0
Predicción Congestión	1	87	249
	0	306	3666

Accuracy	87.1 %	VP+	25.89 %
Sensibilidad	22.1 %	VP-	92.30 %
Especificidad	93.6 %		

Tabla 5.40: Matriz de confusión e indicadores - Modelo 5

		Real Congestión	
		1	0
Predicción Congestión	1	104	355
	0	289	3560

Accuracy	85.05 %	VP+	22.66 %
Sensibilidad	26.5 %	VP-	92.49 %
Especificidad	90.9 %		

Tabla 5.41: Matriz de confusión e indicadores - Modelo 6

En las tablas (5.36) y (5.41), es posible observar que al bajar el punto de corte con este método, el accuracy baja en alrededor de 4 %, sin embargo la sensibilidad aumenta en hasta en un 26 % en el modelo 6.


Curva Roc.

Imagen 5.15: Curva de Roc base de validación.

Por último, es posible observar que en términos de Curva de Roc no existen diferencias significativas, obteniéndose el mismo valor para el área bajo la curva en ambos modelos.

5.4. Selección del modelo final.

A lo largo del capítulo de implementación de los modelos, se ha podido observar que en términos de clasificación no existe mayor diferencia entre el modelo 5 o el modelo 6, esto en cualquiera de las dos técnicas aplicadas, Naive Bayes o Regresión Logística, sin embargo falta un criterio para determinar que modelo podría ser mejor y esto es saber con cuánto tiempo de anticipación prever el estado de colapso.

Para esta etapa de selección se descarta el modelo 5 de Regresión Logística. Esto implica que los modelos a comparar serán los siguientes:

- Regresión Logística - Modelo 6.
- Clasificador de Naive Bayes - Modelo 5.
- Clasificador de Naive Bayes - Modelo 6.




Imagen 5.16: Capacidad de anticipación al estado de congestión.

En la Imagen (5.16) se encuentran graficadas las probabilidades a través del tiempo. Los gráficos de la contemplan solo los censos desde el día 27 de mayo al 30 de mayo, esto con el fin de poder ilustrar el crecimiento de las probabilidades hasta el momento de identificar un periodo de congestión.

Se escogen como mejor modelos:

- **Regresión Logística - Modelo 6:** modelo que mejor anticipa los periodos de congestión, habiendo casos donde la tendencia de la probabilidad antes de la congestión aumenta hasta ocho horas antes, sin embargo no es el modelo que predice mas estados de congestión.
- **Clasificador de Naive Bayes - Modelo 6:** es el modelo que mejor clasifica los estados de congestión, sin embargo no es el que mejor los anticipa, llegando a prever los periodos de congestión hasta un máximo de cuatro horas.

Respecto al punto de corte de los modelos según metodología, esto dependerá de mirada que se tenga, ya que un alto punto de corte es bastante conservador, es decir, la cantidad de predicciones de congestión es baja, pero así también la cantidad de falsos positivos. Por otra parte un punto de corte bajo permitió poder predecir considerablemente mas estados de congestión, pero junto con ello también aumentaron la cantidad de falsos positivos.

Capítulo 6

Conclusiones.

En este seminario tesis fue posible analizar un problema de la Salud Pública, como lo es la congestión. Este se desarrolló específicamente con la información de atención de los pacientes que asistieron al HUAP.

Para poder estudiar el estado de congestión en el HUAP se requirieron de dos herramientas fundamentales:

- Crear un programa que permitiera recrear el proceso de atención de los pacientes, a través de mediciones cada una hora.
- Técnicas de clasificación basadas en probabilidad, estas fueron la Regresión Logística y el Clasificador de Naive

Al aplicar las técnicas de clasificación se entregó como resultado final dos modelos con distinta clasificación según metodología del punto de corte, donde los modelos con un punto de corte mas alto no lograban predecir una gran cantidad de estados de congestión, pero si lograban tener un alto nivel de exactitud y por otra parte al disminuir el puntaje de corte, ambos modelos con las distintas técnicas lograban predecir una gran cantidad de estados de congestión, sin embargo la cantidad de falsos positivos aumentaba junto con la capacidad de los verdaderos positivos. Por lo tanto la elección de un sólo modelo estaría dado por el punto de vista que se tenga, es decir, si se está dispuesto a tomar medidas para prevenir congestión aún cuando es más probable de que en la realidad el HUAP no esté congestionado, la mejor clasificación estaría dada por un punto de corte bajo. Por otra parte si se tiene una mirada más conservadora, donde se podrá predecir pocos periodos de congestión pero con ello menos valores de falsos positivos, sería mejor un punto de corte más alto.

La baja predicción de estados de congestión podría estar dado por diversos factores: restricción a los individuos de estudios, ya que estos fueron solamente pacientes categorizados como adultos, por otra parte se encuentra la calidad de los datos, si bien se contaba con información de tres años, el hecho de que no exista una metodología de recopilación de información implicó tener que eliminar registros de personas, afectando así a la base de modelamiento y a la cantidad de sujetos de estudio. Sin embargo esto no fue impedimentos para poder encontrar dos miradas en torno a los resultados de modelamiento, es decir, se obtuvo un modelo que si bien no logra clasificar de una manera ideal, éste si logra poder anticipar los periodos de congestión, tal como lo indica la literatura acerca de este tema. La otra mirada se tuvo con el clasificador de Naive el que pudo clasificar de mejor manera el estado de congestión, sin embargo no permite prever con mucho tiempo la ocurrencia del mismo.

En el futuro, se recomienda implementar una metodología de recopilación de información automatizada y en tiempo real, esto permitiría obtener mediciones en el momento y en intervalos de tiempos modificables, esto mejoraría la calidad de la información evitando una mayor limpieza de información. Incorporar variables no sólo del proceso de atención sino también internas del HUAP, esto permitiría tener una visión mas completa del fenómeno.

Es posible considerar otras técnicas según la definición de congestión, se pudo evidenciar que los tiempos están altamente relacionados con los periodos de congestión, por lo que definir un estado de congestión en base a los tiempos del proceso de atención, permitiría implementar modelos de series de tiempo para predecir congestión.

Bibliografía

- [1] Asplin, B. R., Magid, D. J., Rhodes, K. V., Solberg, L. I., Lurie, N., and Camargo, C. A. (2003). A conceptual model of emergency department crowding. *Annals of emergency medicine*, 42(2).
- [2] Han, J., Pei, J., and Kamber, M. (2011). *Data mining: concepts and techniques*. Elsevier.
- [3] Hoot, N. and Aronsky, D. (2005). An early warning system for overcrowding in the emergency department. In *AMIA... Annual Symposium proceedings. AMIA Symposium*, volume 2006, pages 339–343. American Medical Informatics Association.
- [4] Hosmer Jr, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied logistic regression*, volume 398. John Wiley & Sons.
- [5] John Lu, Z. (2010). The elements of statistical learning: data mining, inference, and prediction. *Journal of the Royal Statistical Society: Series A (Statistics in Society)*, 173(3).
- [6] Manning, C., Raghavan, P., and Schütze, H. (2009). Introduction to information retrieval/christopher d.
- [7] Metsis, V., Androutsopoulos, I., and Paliouras, G. (2006). Spam filtering with naive bayes-which naive bayes? In *CEAS*, volume 17, pages 28–69.
- [8] Pines, J. M., Hilton, J. A., Weber, E. J., Alkemade, A. J., Al Shabanah, H., Anderson, P. D., Bernhard, M., Bertini, A., Gries, A., Ferrandiz, S., et al. (2011). International perspectives on emergency department crowding. *Academic Emergency Medicine*, 18(12):1358–1370.
- [9] Richardson, L. D., Asplin, B. R., and Lowe, R. A. (2002). Emergency department crowding as a health policy issue: past development, future directions. *Annals of emergency medicine*, 40(4).
- [10] Schull, M. J., Morrison, L. J., Vermeulen, M., and Redelmeier, D. A. (2003). Emergency department overcrowding and ambulance transport delays for patients with chest pain. *Canadian Medical Association Journal*, 168(3).
- [11] Schull, M. J., Slaughter, P. M., and Redelmeier, D. A. (2002). Urban emergency department overcrowding: defining the problem and eliminating misconceptions. *Cjem*, 4(02).
- [12] Todd, B. a. and Stamper, R. (1994). The relative accuracy of a variety of medical diagnostic programs. *Methods of information in medicine*, 33(4).
- [13] Weisberg, S. (2005). *Applied linear regression*, volume 528. John Wiley & Sons.
- [14] Zhang, H. (2004). The optimality of naive bayes. *AA*, 1.
- [15] Zhao, Y. (2012). *R and data mining: Examples and case studies*. Academic Press.

Anexos

Apéndice A

Tablas de la base inicial.

A.1. Variables discretas.

A.1.1. Triage.

Triage	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
C1	51	46	41	46	57	53	57	62	52	48	48	52
C2	483	334	435	393	390	395	400	360	377	365	378	326
C3	1797	1525	1752	1466	1515	1237	1288	1238	1203	1507	1448	1475
C4	3015	2648	3112	2979	3099	2896	2799	2748	2789	2985	2852	2799
C5	325	305	251	200	97	297	215	309	242	304	158	307
Sin info	123	79	146	119	112	113	111	75	88	96	100	80
Total general	5794	4937	5737	5203	5270	4991	4870	4792	4751	5305	4984	5039

Tabla A.1: Demanda Triage en el año 2014

Triage	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
C1	42	49	52	71	57	61	67	45	67			70
C2	329	283	365	313	324	318	306	351	356			343
C3	1465	1361	1441	1486	1581	1724	1625	1743	1735			2033
C4	2867	2547	3344	3064	2873	2675	3116	3367	3072			3227
C5	347	310	289	187	175	154	85	126	195			160
Sin info	99	74	83	111	80	65	77	112	94	5943	5680	94
Total general	5149	4624	5574	5232	5090	4997	5276	5744	5519	5943	5680	5927

Tabla A.2: Demanda Triage en el año 2015

Triage	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
C1	84	71	75	79	85	73	100	84	95	57	76	76
C2	326	336	381	431	346	398	385	330	337	366	312	358
C3	2098	1980	2073	2145	2146	2002	2024	1926	1916	2073	2022	2082
C4	3332	3012	3392	2388	2602	2646	3149	3301	3101	3112	2616	2874
C5	146	137	176	192	188	213	382	254	247	174	134	149
Sin info	70	66	63	105	106	59	101	95	109	107	141	103
Total general	6056	5602	6160	5340	5473	5391	6141	5990	5805	5889	5301	5642

Tabla A.3: Demanda Triage en el año 2016

A.1.2. Previsión.

Previsión	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
FONASA	5283	4457	5182	4611	4654	4386	4378	4256	4198	4623	4374	4409
ISAPRE	99	96	133	120	126	109	82	84	117	132	117	134
Particular	381	334	368	425	445	463	376	418	407	511	446	411
Sin Información	31	50	54	47	45	33	34	34	29	39	47	85
Total general	5794	4937	5737	5203	5270	4991	4870	4792	4751	5305	4984	5039

Tabla A.4: Demandas según previsión de salud año 2014

Previsión	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
CAPR												7
FONAS	4468	4056	4839	4555	4214	4164						5118
ISAPR	109	97	126	134	145	112						192
OTROS												8
PARTI	436	318	459	418	587	595						572
SIN I	136	153	150	125	144	126	5276	5744	5519	5943	5680	30
Total general	5149	4624	5574	5232	5090	4997	5276	5744	5519	5943	5680	5927

Tabla A.5: Demandas según previsión de salud año 2014

Previsión	2016											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
CAPR	5	3	6	4	7	5	6	1	2	2	5	7
FONAS	5166	4816	5295	4581	4716	4632	5246	5180	4955	5046	4451	4770
ISAPR	160	134	159	152	133	139	148	134	177	154	141	128
OTROS	6	8	1	9	7	21	24	16	5	27	14	14
PARTI	590	535	586	508	519	499	586	515	568	556	555	603
SIN I	127	105	111	84	91	93	128	143	97	85	117	117
Total general	6058	5603	6162	5342	5473	5393	6144	5991	5806	5908	5319	5645

Tabla A.6: Demandas según previsión de salud año 2014

A.1.3. Sin diagnóstico.

Sin Diagnóstico	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
0	4753	4232	4593	3842	3978	3476	3020	3793	3971	4253	3958	4290
1	1041	705	1144	1361	1292	1515	1850	999	780	1052	1026	749
Total general	5794	4937	5737	5203	5270	4991	4870	4792	4751	5305	4984	5039

Tabla A.7: Cantidad de Pacientes sin diagnóstico en el año 2014.

Sin Diagnóstico	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
0	4302	3973	4618	4060	4398	4298	4558	4588	4596	5943	5680	5038
1	847	651	956	1172	692	699	718	1156	923			889
Total general	5149	4624	5574	5232	5090	4997	5276	5744	5519	5943	5680	5927

Tabla A.8: Cantidad de Pacientes sin diagnóstico en el año 2015.

Sin Diagnóstico	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
0	5332	5051	5567	4377	4302	4344	4862	4859	4342	4727	4183	4943
1	724	551	593	963	1171	1047	1279	1131	1463	1162	1118	699
Total general	6056	5602	6160	5340	5473	5391	6141	5990	5805	5889	5301	5642

Tabla A.9: Cantidad de Pacientes sin diagnóstico en el año 2016.

A.1.4. Género.

Sexo	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Desconocido	3	3	2	1	5	7	1	2	3	3	2	4
Femenino	2690	2248	2749	2484	2438	2444	2301	2384	2305	2531	2352	2425
Indefinido	7	7	5	4	9	3	9	3	6	7	6	11
Masculino	3094	2679	2981	2714	2818	2537	2559	2403	2437	2764	2624	2599
Total general	5794	4937	5737	5203	5270	4991	4870	4792	4751	5305	4984	5039

Tabla A.10: Género de los pacientes en el año 2014.

Sexo	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Desconocido	4	4	7	3	1	1	4		3	4	1	2
Femenino	2454	2209	2738	2530	2396	2403	2531	2737	2679	2930	2668	2911
Indefinido	6	6	16	5	11	7	3	7	9	4	7	6
Masculino	2685	2405	2813	2694	2682	2586	2738	3000	2828	3005	3004	3008
Total general	5149	4624	5574	5232	5090	4997	5276	5744	5519	5943	5680	5927

Tabla A.11: Género de los pacientes en el año 2015.

Sexo	2016											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Desconocido	2	2	4	2	1	4	5	6	4	2	5	2
Femenino	2937	2724	2997	2680	2678	2553	2993	2944	2739	2938	2550	2702
Indefinido	7	7	9	5	2	11	6	7	4	10	10	1
Masculino	3110	2869	3150	2653	2792	2823	3137	3033	3058	2939	2736	2937
Total general	6056	5602	6160	5340	5473	5391	6141	5990	5805	5889	5301	5642

Tabla A.12: Género de los pacientes en el año 2016.

A.1.5. Remitido Por.

Remitido por	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Atencio Pr	377	329	327	323	306	310	365	347	310	262	314	303
Carabineros	229	146	253	161	138	115	106	119	106	150	117	80
Centro Espe											1	1
Hospital	394	113	113	82	157	154	108	53	63	40	45	40
Otro Centro	122	184	220	177	159	163	181	138	133	140	141	118
SAMU	194	149	196	196	210	190	179	213	183	217	208	205
Voluntario	4478	4016	4628	4264	4300	4059	3931	3922	3956	4496	4158	4292

Tabla A.13: Cantidad de personas que llegaron a través de distintas entidades el año 2014

Remitido por	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Atencio Pr	303	308	280	225	184	253	268	302	243	255	232	264
Carabineros	105	67	111	82	144	99	110	131	163	146	177	193
Centro Espe	2		4			1	1				1	1
Hospital	45	44	41	30	23	32	39	42	39	29	40	38
Otro Centro	104	81	75	57	52	86	75	75	74	72	57	79
SAMU	152	146	201	171	182	155	184	197	200	213	243	247
Voluntario	4438	3978	4862	4667	4505	4371	4599	4997	4800	5228	4930	5105

Tabla A.14: Cantidad de personas que llegaron a través de distintas entidades el año 2014

Remitido por	2016											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
Atencio Pr	235	223	207	229	239	229	268	212	219	175	170	198
Carabineros	207	159	171	97	168	146	124	47	69	38	43	35
Centro Espe	1								2		1	
Hospital	27	32	33	29	31	32	33	27	35	35	21	39
Otro Centro	78	74	72	60	75	44	51	9	15	14	10	12
SAMU	190	213	224	223	198	252	265	226	257	222	154	199
Voluntario	5318	4901	5453	4702	4762	4688	5400	5469	5208	5405	4902	5159

Tabla A.15: Cantidad de personas que llegaron a través de distintas entidades el año 2016

A.2. Variables Continuas.

A.2.1. Set de variables.

Año 2014												
Variable	N	Miss	Min	Max	Media	Dev std	P10	P25	P50	P75	P90	P95
Tiempo Urg	61673	0	0	2246.5	11.3	59.6	1	2.1	4.3	7.9	13	17.4
Tiempo Aten	61673	0	-0.5	890.5	3.3	10.5	0.3	0.7	1.8	4	7.7	10.8
camas1	61673	0	1	44	18.7	8.5	8	13	18	24	31	34
camas7	61673	0	2	48	20.8	9.4	9	14	20	27	34	38
camas13	61673	0	2	51	22.8	9.9	9	16	22	29	37	41
camas19	61673	0	1	47	20	8.7	9	14	19	26	32	36

Tabla A.16: Estadísticas descriptivas variables continuas durante el año 2014

Año 2015												
Variable	N	Miss	Min	Max	Media	Dev std	P10	P25	P50	P75	P90	P95
Tiempo Urg	64416	339	0	2807.1	12.2	96	0.9	1.9	3.6	6.1	9.4	12.7
Tiempo Aten	64741	14	-0.2	1671.3	2.3	8.7	0.3	0.5	1.4	2.9	5	7.4
camas1	64755	0	5	49	20.9	6.6	13	16	21	25	29	31
camas7	64755	0	5	44	22.5	6.8	14	18	22	27	31	34
camas13	64755	0	6	44	24	6.7	15	20	24	28	33	35
camas19	64755	0	4	53	21.5	6.7	13	17	22	26	29	32

Tabla A.17: Estadísticas descriptivas variables continuas durante el año 2015

Año 2016												
Variable	N	Miss	Min	Max	Media	Dev std	P10	P25	P50	P75	P90	P95
Tiempo Urg	67836	954	0	1963.2	4.6	9.1	0.9	1.8	3.5	5.8	8.8	11.7
Tiempo Aten	68790	0	-0.6	2468.1	2.5	16.9	0.2	0.5	1.3	2.6	5.1	8.5
camas1	68790	0	0	41	20.5	6.4	12	16	20	25	29	30
camas7	68790	0	0	43	21.5	7.1	13	16	21	27	30	32
camas13	68790	0	7	42	23.1	6.7	14	18	23	27	32	34
camas19	68790	0	7	58	21.6	6.2	14	17	21	26	29	31

Tabla A.18: Estadísticas descriptivas variables continuas durante el año 2016

A.2.2. Hospitalizados en Box

Hopitalizados en Box	2014											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
camas1	11.7	9.3	12.8	18.3	20.9	27.1	33.2	26.3	19.9	14.2	19.0	14.2
camas7	14.1	8.8	13.9	20.3	23.4	28.7	36.9	29.0	22.9	16.9	20.6	16.8
camas13	15.4	10.2	15.5	21.5	26.3	30.8	39.5	31.0	24.9	18.9	22.6	18.2
camas19	12.5	9.8	14.4	17.6	22.8	26.5	34.9	27.8	22.3	16.8	20.1	15.9

Tabla A.19: Promedio de pacientes hospitalizados en Box año 2014

Hopitalizados en Box	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
camas1	16.5	17.3	18.5	22.0	14.4	18.8	23.4	24.0	28.9	20.4	23.6	20.6
camas7	18.8	19.1	21.0	25.3	15.8	20.9	25.0	27.4	29.7	20.4	23.6	20.6
camas13	20.7	21.0	23.5	25.6	15.7	21.5	25.9	28.6	29.4	23.6	26.2	24.0
camas19	17.2	17.9	20.0	22.3	13.7	19.0	23.4	26.1	28.8	22.0	23.2	21.4

Tabla A.20: Promedio de pacientes hospitalizados en Box año 2015

Hopitalizados en Box	2015											
	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
camas1	11.7	9.3	12.8	18.3	20.9	27.1	33.2	26.3	19.9	14.2	19.0	14.2
camas7	14.1	8.8	13.9	20.3	23.4	28.7	36.9	29.0	22.9	16.9	20.6	16.8
camas13	15.4	10.2	15.5	21.5	26.3	30.8	39.5	31.0	24.9	18.9	22.6	18.2
camas19	12.5	9.8	14.4	17.6	22.8	26.5	34.9	27.8	22.3	16.8	20.1	15.9

Tabla A.21: Promedio de pacientes hospitalizados en Box año 2016

Apéndice B

Tablas Base de modelamiento.

B.1. Congestión.

	Año			
Congestión	2014	2015	2016	2017
0	7145	7607	7785	3935
1	1614	1139	999	393
Total general	8759	8746	8784	4328

Tabla B.1: Frecuencias estados de congestión según censos cada una hora.

	Año			
Congestión	2014	2015	2016	2017
0	82 %	87 %	89 %	91 %
1	18 %	13 %	11 %	9 %
Total general	100 %	100 %	100 %	100 %

Tabla B.2: Porcentajes estados de congestión según censos cada una hora.

B.2. Triage.

	Año							
	2014		2015		2016		2017	
Variable \ Congestion	0	1	0	1	0	1	0	1
Cant_C1	0.2	0.2	0.2	0.2	0.3	0.3	0.3	0.3
Cant_C2	2.6	2.6	1.6	1.6	1.8	2.0	2.1	2.1
Cant_C3	14.6	14.1	10.8	12.1	15.2	16.5	16.6	18.6
Cant_C4	19.1	24.9	15.1	21.5	18.4	23.6	19.9	23.7
Cant_C5	2.1	2.4	1.4	1.5	1.6	2.4	1.6	3.1

Tabla B.3: Promedio anual de personas según clasificación Triage entre los censos, identificando periodos de congestión.

B.3. Flujos

	2014											
Variable	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
sum_salidas	7.4	7.0	7.3	6.7	6.7	6.4	5.8	6.2	6.3	6.9	6.7	6.6
sum_entradas	7.4	7.0	7.3	6.7	6.7	6.4	5.7	6.2	6.4	6.8	6.7	6.6
sum_salidas_2h	14.7	14.1	14.7	13.4	13.5	12.7	11.5	12.4	12.7	13.7	13.4	13.2
sum_entradas_2h	14.9	14.1	14.6	13.5	13.4	12.8	11.5	12.4	12.8	13.7	13.4	13.1
sum_salidas_3h	22.1	21.1	22.0	20.1	20.2	19.1	17.3	18.6	19.0	20.6	20.2	19.8
sum_entradas_3h	22.3	21.1	22.0	20.2	20.2	19.1	17.2	18.6	19.1	20.5	20.1	19.7

Tabla B.4: Promedio de flujos mensuales durante el año 2014.

	2015											
Variable	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
sum_salidas	6.7	6.8	7.3	7.0	6.7	6.8	6.9	7.4	7.4	7.7	7.5	7.7
sum_entradas	6.7	6.8	7.3	7.0	6.7	6.8	6.9	7.4	7.4	7.6	7.5	7.7
sum_salidas_2h	13.4	13.6	14.6	13.9	13.5	13.5	13.9	14.7	14.8	15.3	15.0	15.5
sum_entradas_2h	13.5	13.5	14.6	14.0	13.3	13.6	13.8	14.8	14.8	15.2	15.1	15.4
sum_salidas_3h	20.0	20.4	21.9	20.9	20.2	20.3	20.8	22.0	22.3	23.0	22.5	23.2
sum_entradas_3h	20.2	20.3	21.9	21.0	20.0	20.5	20.7	22.2	22.2	22.8	22.6	23.0

Tabla B.5: Promedio de flujos mensuales durante el año 2015.

	2016											
Variable	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic
sum_salidas	7.9	7.9	8.1	7.2	7.0	7.2	8.0	7.8	7.5	7.8	7.0	7.4
sum_entradas	8.0	7.9	8.1	7.2	7.1	7.2	8.0	7.8	7.6	7.7	7.0	7.4
sum_salidas_2h	15.9	15.7	16.2	14.4	14.1	14.4	16.0	15.6	15.1	15.5	14.1	14.9
sum_entradas_2h	15.9	15.7	16.2	14.4	14.1	14.4	16.0	15.6	15.2	15.5	14.1	14.8
sum_salidas_3h	23.8	23.6	24.4	21.6	21.2	21.6	24.0	23.4	22.6	23.3	21.1	22.3
sum_entradas_3h	23.9	23.6	24.4	21.6	21.2	21.6	24.0	23.4	22.8	23.2	21.1	22.2

Tabla B.6: Promedio de flujos mensuales durante el año 2016.

	2017					
Variable	Ene	Feb	Mar	Abr	May	Jun
sum_salidas	7.9	7.8	8.5	8.1	7.9	9.0
sum_entradas	8.0	7.9	8.4	8.0	7.9	9.1
sum_salidas_2h	15.9	15.7	16.9	16.1	15.9	18.0
sum_entradas_2h	16.0	15.7	16.9	16.0	15.8	18.1
sum_salidas_3h	23.9	23.5	25.4	24.1	23.8	27.0
sum_entradas_3h	24.0	23.6	25.3	24.1	23.7	27.2

Tabla B.7: Promedio de flujos mensuales durante el año 2017.

Apéndice C

Clasificador de Naive Bayes.

C.1. Tablas distribuciones condicionales Modelo 5.

	Media_t_atención	
Congestión	Media	Desv.Est
0	-0.097	0.926
1	0.577	1.206

Tabla C.1: Distribución condicional según estado de congestión

	Media_t_atención_alta	
Congestión	Media	Desv.Est
0	0.010	0.999
1	-0.061	1.056

Tabla C.2: Distribución condicional según estado de congestión

	Media_t_atención	
Congestion	Media	Desv.Est
0	0.030	0.990
1	-0.174	1.037

Tabla C.3: Distribución condicional según estado de congestión