

Procesos no Estacionarios

Clase 11

Felipe Elorrieta López

Universidad de Santiago de Chile

Jun 28, 2023



Contenidos

Raiz Unitaria

Modelo ARIMA

Modelo SARIMA

Librerias de Series Temporales en R

Análisis Exploratorio Series Temporales

Aplicación en Datos Climáticos

Raiz Unitaria

- ▶ En un proceso $y_t \sim AR(1)$ definido por $y_t = \phi y_{t-1} + \epsilon_t$, si $|\phi| < 1$ entonces $\{y_t\}$ es estacionario.
- ▶ Que sucede si $\phi = 1$?

Raiz Unitaria

- ▶ En un proceso $y_t \sim AR(1)$ definido por $y_t = \phi y_{t-1} + \epsilon_t$, si $|\phi| < 1$ entonces $\{y_t\}$ es estacionario.
- ▶ Que sucede si $\phi = 1$?
- ▶ Tenemos que $y_t = y_{t-1} + \epsilon_t$. En este caso decimos que y_t es un proceso de caminata aleatoria.
- ▶ Un proceso de caminata aleatoria es un proceso no estacionario.

Raiz Unitaria

- ▶ En un proceso $y_t \sim AR(1)$ definido por $y_t = \phi y_{t-1} + \epsilon_t$, si $|\phi| < 1$ entonces $\{y_t\}$ es estacionario.
- ▶ Que sucede si $\phi = 1$?
- ▶ Tenemos que $y_t = y_{t-1} + \epsilon_t$. En este caso decimos que y_t es un proceso de caminata aleatoria.
- ▶ Un proceso de caminata aleatoria es un proceso no estacionario.
- ▶ Los test de Raíz unitaria permiten verificar la siguiente hipótesis:

$$H_0 : \phi = 1 \quad \text{vs} \quad H_1 : \phi < 1$$

- ▶ o equivalentemente,

$$H_0 : \text{Caminata Aleatoria} \quad \text{vs} \quad \text{Proceso Estacionario}$$

el más conocido de estos test, es el test de Dickey Fuller.

Modelo ARIMA

- ▶ Sea $x_t = (1 - B)^d y_t$ y suponga que $x_t \sim ARMA(p, q)$, es decir

$$\Phi_p(B)x_t = \Theta_q(B)\epsilon_t$$

donde $\epsilon_t \sim RB(0, \sigma^2)$, entonces podemos reescribir el proceso como,

$$\Phi_p(B)(1 - B)^d y_t = \Theta_q(B)\epsilon_t$$

- ▶ Este proceso $\{y_t\}$ se conoce como “Autoregresivo integrado de medias móviles” y se denota como $\{y_t\} \sim ARIMA(p,d,q)$

Modelos ARIMA estacionales.

- ▶ Previamente se discutió la descomposición clásica de una serie de tiempo $Y_t = N_t + T_t + S_t + \epsilon_t$, donde T_t es la componente de tendencia, S_t es la componente estacional y ϵ_t la componente aleatoria. Sin embargo, a veces no se puede esperar que la componente estacional se repita exactamente en el mismo modo ciclo a ciclo. Por esta razón se proponen los modelos SARIMA para permitir la aleatoriedad en la forma de la estacionalidad ciclo a ciclo.

Modelos ARIMA estacionales.

- ▶ Supongamos que se tienen r años de datos mensuales tabulados como muestra la tabla siguiente:

Año	Meses			
	1	2	...	12
1	Y_1	Y_2	...	Y_{12}
2	Y_{13}	Y_{14}	...	Y_{24}
3	Y_{25}	Y_{26}	...	Y_{36}
:	:	:		:
r	$Y_{1+12(r-1)}$	$Y_{2+12(r-1)}$...	$Y_{12+12(r-1)}$

Cada columna en esta tabla puede ser considerada en si misma como una realización de una serie de tiempo.

Modelos ARIMA estacionales.

- ▶ Suponga que cada una de estas 12 series es generada por el mismo proceso ARMA(P,Q), o más específicamente que la serie correspondiente al mes j , dada por Y_{j+12t} , con $t = 0, 1, \dots, r - 1$ y $j = 1, 2, \dots, 12$ satisface la siguiente ecuación en diferencias:

$$\begin{aligned} Y_{j+12t} &= \Phi_1 Y_{j+12(t-1)} + \dots + \Phi_P Y_{j+12(t-P)} + U_{j+12t} \\ &+ \Theta_1 U_{j+12(t-1)} + \dots + \Theta_Q U_{j+12(t-Q)} \end{aligned}$$

donde ϵ_{j+12t} , $t = 0, \pm 1, \pm 2, \dots$, $j = 1, 2, \dots, 12$ es $RB(0, \sigma_U^2)$. Como se supone el mismo modelo para cada mes, escribimos para cada t escribimos el modelo en la forma siguiente,

$$Y_t = \Phi_1 Y_{t-12} + \dots + \Phi_P Y_{t-12P} + U_t + \Theta_1 U_{t-12} + \dots + \Theta_Q U_{t-12Q}$$

Modelos ARIMA estacionales

- ▶ Sean $\Phi(z) = 1 - \Phi_1 z - \dots - \Phi_P z^P$ y $\Theta(z) = 1 + \Theta_1 z + \dots + \Theta_Q z^Q$, entonces el modelo para cada mes puede ser escrito como,

$$\Phi(B^{12})Y_t = \Theta(B^{12})U_t$$

Modelos ARIMA estacionales

- ▶ Sean $\Phi(z) = 1 - \Phi_1 z - \dots - \Phi_P z^P$ y $\Theta(z) = 1 + \Theta_1 z + \dots + \Theta_Q z^Q$, entonces el modelo para cada mes puede ser escrito como,

$$\Phi(B^{12})Y_t = \Theta(B^{12})U_t$$

- ▶ Note que $\mathbb{E}(U_t U_{t+k})$ no es cero excepto cuando k es un múltiplo de 12. Esto quiere decir que uno espera que las doce series estén correlacionadas entre si. Para incorporar esta dependencia entre series se asume que $U_t \sim \text{ARMA}(p, q)$.

$$\phi(B)U_t = \theta(B)\epsilon_t, \quad \epsilon_t \sim RB(0, \sigma^2)$$

Combinando estas dos últimas ecuaciones se tiene

$$\Phi(B^{12})\phi(B)Y_t = \Theta(B^{12})\theta(B)\epsilon_t$$

,

Este es el modelo estacional SARMA($p, q) \times (P, Q)_{12}$

Modelo SARIMA

- ▶ Decimos que $\{y_t\}$ sigue un proceso SARIMA(p, d, q) \times (P, D, Q)_S si puede escribirse como,

$$\phi_p(B)\Phi_P(B^S)(1 - B)^d(1 - B^S)^D Y_t = \theta_q(B)\Theta_Q(B^S)\epsilon_t \quad (1)$$

- ▶ donde

$$\begin{aligned}
 \phi_p(B) &= 1 - \phi_1 B - \dots - \phi_p B^p \\
 \Phi_P(B^S) &= 1 - \Phi_1 B^S - \dots - \Phi_P B^{PS} \\
 \theta_q(B) &= 1 + \theta_1 B + \dots + \theta_q B^q \\
 \Theta_Q(B^S) &= 1 + \Theta_1 B + \dots + \Theta_Q B^{QS}
 \end{aligned}$$

Modelo SARIMA

- Decimos que $\{y_t\}$ sigue un proceso SARIMA(p, d, q) \times (P, D, Q_S)_S si puede escribirse como,
 Polinomio Autoregresivo Orden de Integracion Polinomio de Medias Moviles

$$\phi_p(B)\Phi_P(B^S)(1 - B)^d(1 - B^S)^D Y_t = \theta_q(B)\Theta_Q(B^S)\varepsilon_t \quad (2)$$

- donde
 - Polinomio Autoregresivo Estacional
 - Orden de Integracion Estacional
 - Polinomio de Medias Moviles Estacional

$$\begin{aligned}
 \phi_p(B) &= 1 - \phi_1 B - \dots - \phi_p B^p \\
 \Phi_P(B^S) &= 1 - \Phi_1 B^S - \dots - \Phi_P B^{PS} \\
 \theta_q(B) &= 1 + \theta_1 B + \dots + \theta_q B^q \\
 \Theta_Q(B^S) &= 1 + \Theta_1 B + \dots + \Theta_Q B^{QS}
 \end{aligned}$$

Metodología de Box y Jenkins

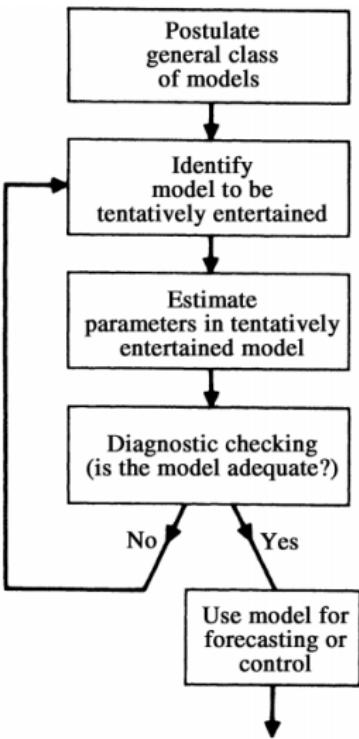
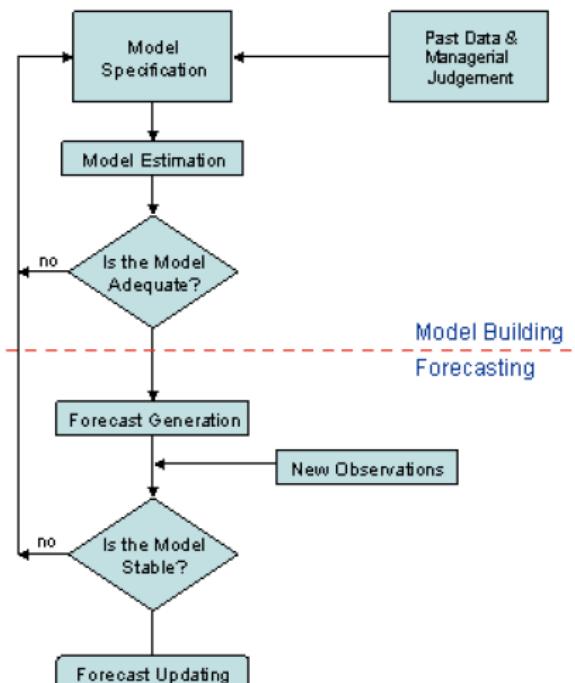


FIGURE 1.7 Stages in the iterative approach to model building.

Metodología de Box y Jenkins



**Forecasting System:
The Model-Building and The Forecasting Phases**

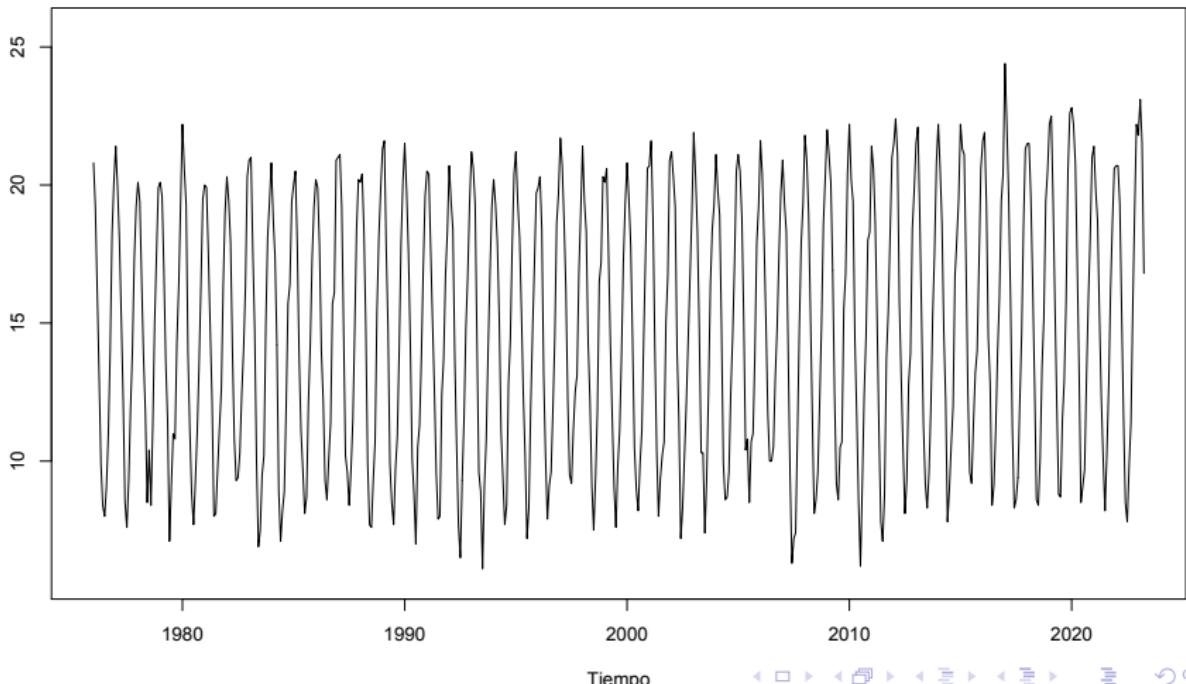
Librerías de Series Temporales en R

- ▶ **TSA:** Cryer and Chan (2010, 2nd ed) Time series analysis with applications in R
- ▶ **astsa:** Shumway and Stoffer (2017, 4th ed) Time Series Analysis and Its Applications: With R Examples
- ▶ **forecast:** by Rob Hyndman et al.
- ▶ **fUnitRoots:** by Diethelm Wuertz et al.
- ▶ **rugarch:** by Alexios Galanos
- ▶ **Imtest:** by Torsten Hothorn et al.

Aplicación

- ▶ Serie de Temperatura Promedio Mensual medida en la estación Arturo Merino Benítez entre Enero de 1976 y Abril de 2023.

Temperatura Promedio Estacion Arturo Merino Benitez



Función Auto-ARIMA

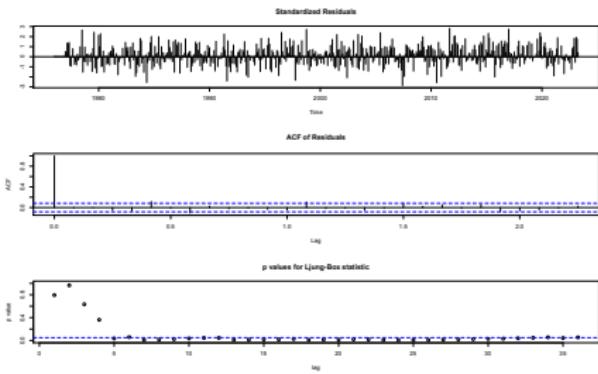
```
model=auto.arima(Temp)
```

Series: Temp

ARIMA(2,0,2)(0,1,1)[12]

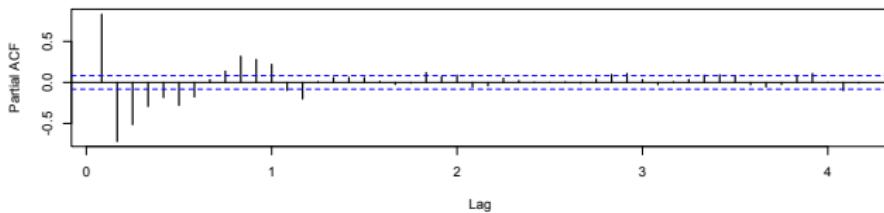
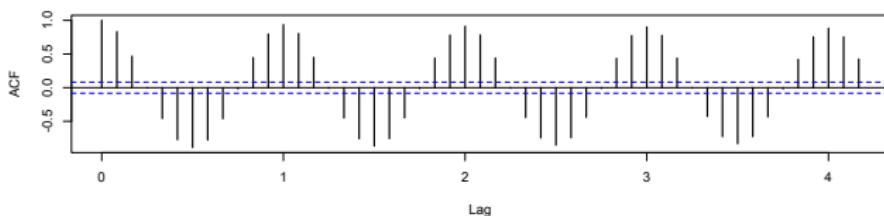
Coefficients:

	ar1	ar2	ma1	ma2	sma1
	1.4955	-0.5991	-1.2706	0.4657	-0.8675
s.e.	0.2599	0.2224	0.2723	0.1886	0.0272
σ^2	0.6877				
log likelihood					-690.89
AIC	1393.78				
AICc	1393.93				
BIC					1419.7



Aplicación

```
y=log(Temp)
par(mfrow=c(2,1))
acf(y,lag.max=50,lwd=2,main="")
pacf(y,lag.max=50,lwd=2,main="")
```



Test de Raíz Unitaria

```
require(fUnitRoots)
adfTest(y, lags = 1, type = c("nc"))
```

Title:
Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 1

STATISTIC:

Dickey-Fuller: -1.7525

P VALUE:

0.07992

```
adfTest(y, lags = 12, type = c("nc"))
```

Title:
Augmented Dickey-Fuller Test

Test Results:

PARAMETER:

Lag Order: 12

STATISTIC:

Dickey-Fuller: 0.4029

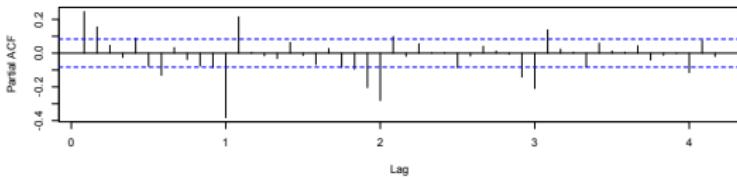
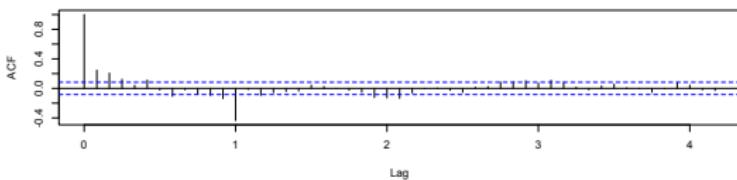
P VALUE:

0.7447

Test de Raíz Unitaria

Serie	X_t	∇X_t	$\nabla_{12} X_t$	$\nabla_{12} \nabla X_t$	$\nabla^2 X_t$	$\nabla_{12}^2 \nabla X_t$
adfTest(., lags = 1)	0.08	0.01	0.01	0.01	0.01	0.01
adfTest(., lags = 12)	0.75	0.01	0.01	0.01	0.01	0.01
Stdev	0.116	0.039	0.009	0.014	0.033	0.027

- ▶ La solución de mínima varianza es $d = 0$ y $D = 1$.



Modelo Propuesto

- ▶ SARIMA(1, 0, 1) \times (0, 1, 1)₁₂

```
model4=arima(y,order=c(1,0,1),seasonal=list(order=c(0,1,1),period=12))
summary(model4)
Call:
arima(x = y, order = c(1, 0, 1), seasonal = list(order = c(0, 1, 1),
, period = 12))
Coefficients:
          ar1      ma1      sma1
          0.7471 -0.5213 -0.8958
  s.e.  0.0836  0.1033  0.0264
```

- ▶ Significancia de Parametros

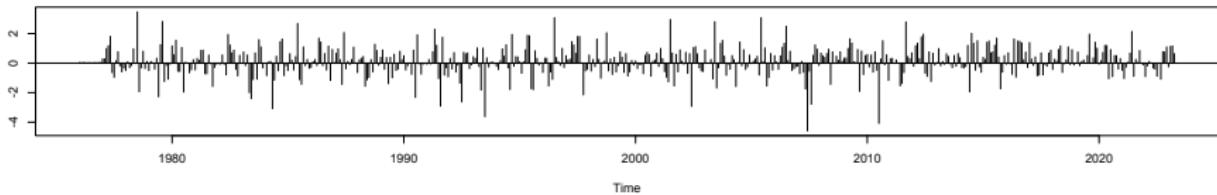
```
require(lmtest)
coefest(model4)
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)
ar1	0.747089	0.083583	8.9383	< 2.2e-16 ***
ma1	-0.521283	0.103272	-5.0477	4.472e-07 ***
sma1	-0.895826	0.026441	-33.8801	< 2.2e-16 ***

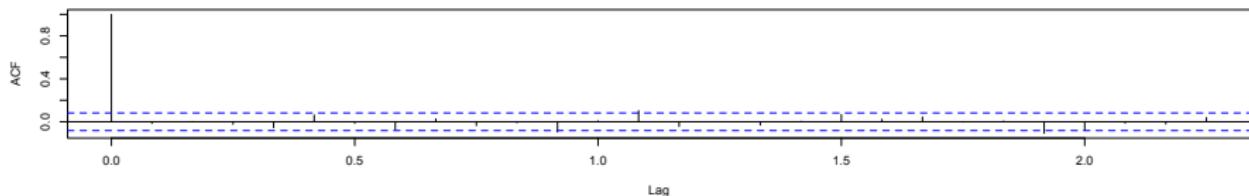
Diagnóstico del Modelo

`tsdiag(model4,gof.lag=36)`

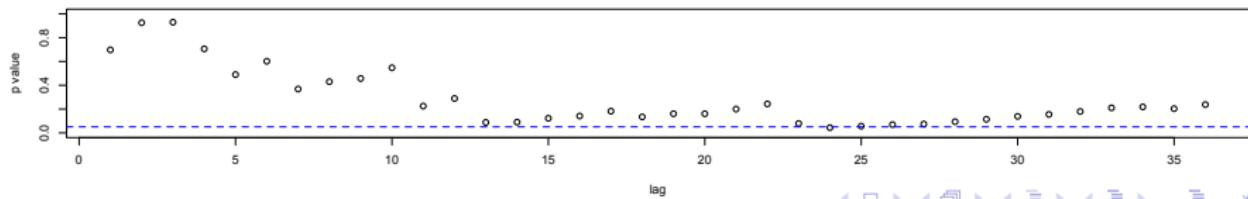
Standardized Residuals



ACF of Residuals

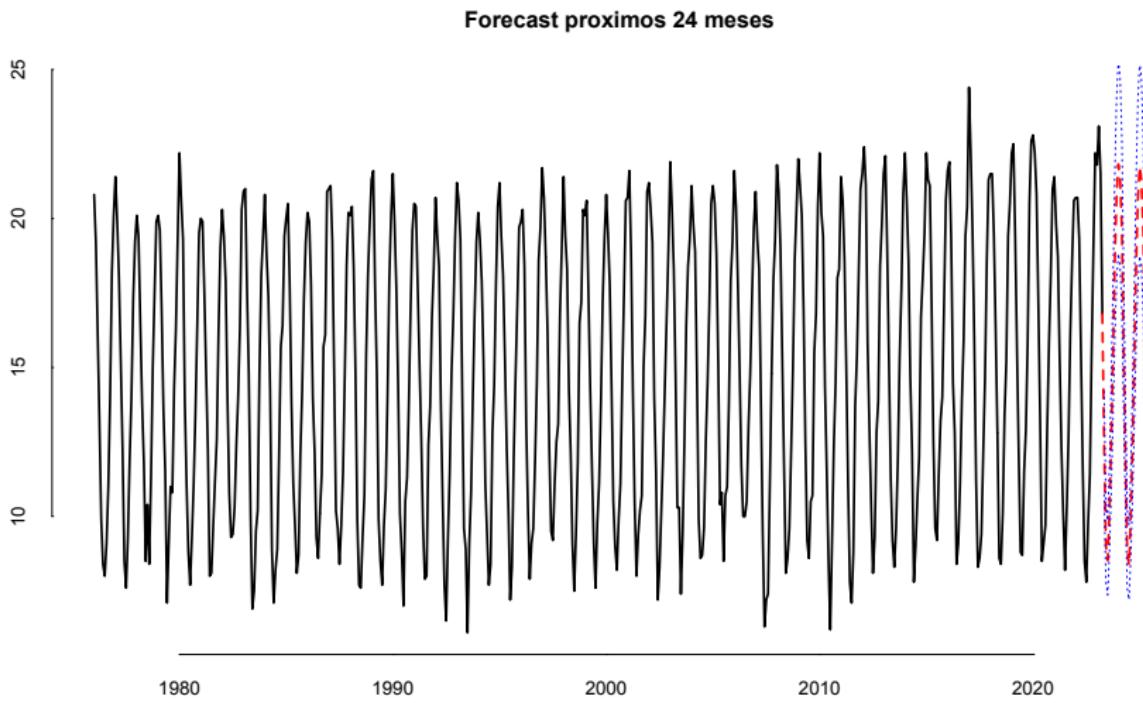


p values for Ljung-Box statistic



Forecast

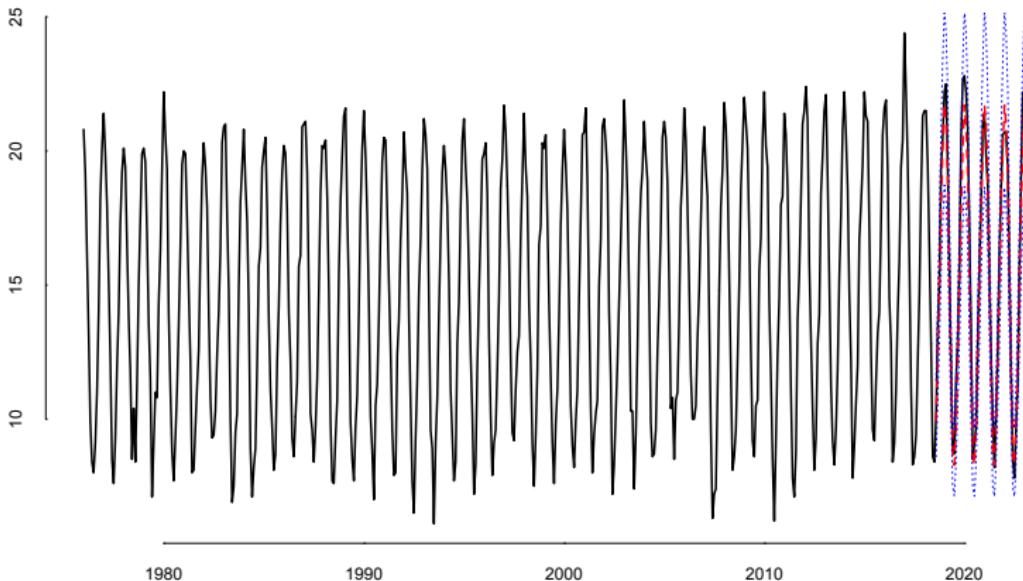
```
Forecast<-predict(model4,n.ahead=24)
```



Validacion

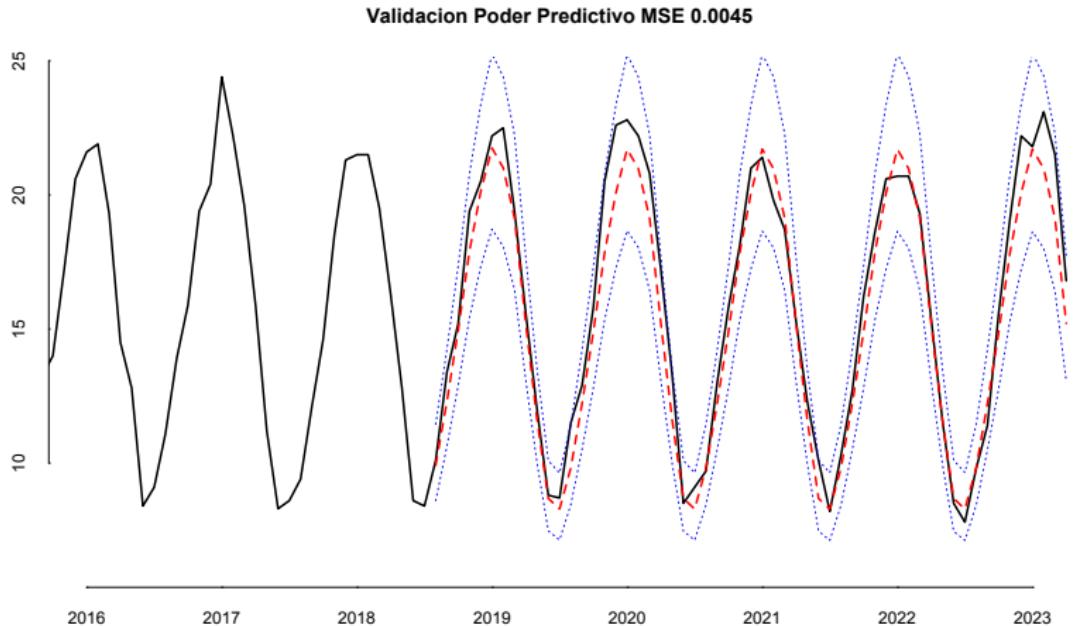
- ▶ Para evaluar la capacidad predictiva del modelo propuesto, usaremos el primer 90 % de la serie para entrenar el modelo propuesto y el 10 % para validararlo.

Validacion Poder Predictivo MSE 0.0045



Validacion

- ▶ Para evaluar la capacidad predictiva del modelo propuesto, usaremos el primer 90 % de la serie para entrenar el modelo propuesto y el 10 % para validararlo.



tusind tak
謝謝 dakujem vám
ありがとう
thank you
suksema
danke
gracias
obrigada
obrigado
teşekkür ederim
tack så mycket
ngiyabonga
dziekuję
merci
baie dankie
ধন্যবাদ molte grazie
mahalo
dank u
dank u
dank u
dank u
teşekkür edire
mahalo

✉ felipe.elorrieta@usach.cl
⌚ @felipeelorrieta