

# Clase 3 Series de Tiempo

Felipe Elorrieta Lopez

Universidad de Santiago de Chile

April 17, 2025



# Conceptos Previos

- ▶ Alisado Exponencial Simple-Medias Móviles Simples.

# Conceptos Previos


- ▶ Alisado Exponencial Simple-Medias Móviles Simples.
- ▶ Alisado Exponencial Lineal Biparametrico de Holt.

# Conceptos Previos


- ▶ Alisado Exponencial Simple-Medias Móviles Simples.
- ▶ Alisado Exponencial Lineal Biparametrico de Holt.
- ▶ Alisado Exponencial de Holt Winters

# Tipos de Tendencia


**Linear Trend**




**Quadratic Trend**



**Logarithmic Trend**



**Exponential Trend**



# Enfoque Regresión

- Usualmente, la información disponible para predecir el comportamiento de un fenómeno es como sigue:

$y_1, \dots, y_n$	$\Rightarrow$	Serie de Tiempo
$x_{01}, \dots, x_{0n}$	$\Rightarrow$	Covariable 1
$x_{11}, \dots, x_{1n}$	$\Rightarrow$	Covariable 2
$\vdots$	$\vdots$	$\vdots$
$x_{p1}, \dots, x_{pn}$	$\Rightarrow$	Covariable p

# Enfoque Regresión

- Un caso particular de covariables es  $x_{0t} = 1$  y  $x_{1t} = t$ , que corresponde a un modelo lineal, donde

$$y_t = \beta_0 x_{0t} + \beta_1 x_{1t} + \epsilon_t$$

# Enfoque Regresión

- ▶ Un caso particular de covariables es  $x_{0t} = 1$  y  $x_{1t} = t$ , que corresponde a un modelo lineal, donde

$$y_t = \beta_0 x_{0t} + \beta_1 x_{1t} + \epsilon_t$$

- ▶ Agregando una tercera componente  $x_{2t} = t^2$ . Podemos ajustar un modelo cuadrático a una serie del tipo:

$$y_t = \beta_0 x_{0t} + \beta_1 x_{1t} + \beta_2 x_{2t} + \epsilon_t$$



# Enfoque Regresión

- ▶ En general, para un polinomio de grado  $m$  se puede ajustar un modelo polinomial definido por:

$$y_t = \beta_0 x_{0t} + \beta_1 x_{1t} + \dots + \beta_m x_{mt} + \epsilon_t$$

donde  $x_{jt} = t^j \forall j = 0, \dots, m$ .

# Enfoque Regresión

- ▶ En general, para un polinomio de grado  $m$  se puede ajustar un modelo polinomial definido por:

$$y_t = \beta_0 x_{0t} + \beta_1 x_{1t} + \dots + \beta_m x_{mt} + \epsilon_t$$

donde  $x_{jt} = t^j \forall j = 0, \dots, m$ .

- ▶ Para estimar los parámetros del modelo podemos utilizar métodos convencionales como MCO. El problema es que se puede presentar correlación entre las variables independientes, pero se puede utilizar algún procedimiento para ortogonalizar las variables.

# Estimación de Mínimos Cuadrados

- Sea el vector de parámetros dado por  $\beta = (\beta_0, \dots, \beta_m)$ , el estimador de mínimos cuadrados se define por





$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

donde las matrices  $X$  e  $Y$  se definen como,

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \quad X = \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ 1 & 2 & 4 & \dots & 2^m \\ 1 & 3 & 9 & \dots & 3^m \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & N & N^2 & \dots & N^m \end{bmatrix}$$

# Estacionalidad

- ▶ La estacionalidad es una característica que presentan algunas series en lo largo del tiempo, y dicha característica es observada con periodicidad. En esta sección podemos considerar los siguientes casos,



# Regresión Armónica

- Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

# Regresión Armónica

- ▶ Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

- ▶ A=amplitud de la serie.

# Regresión Armónica

- ▶ Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

- ▶  $A$ =amplitud de la serie.
- ▶  $\omega$  es el número de ciclos por unidad de tiempo.

# Regresión Armónica

- ▶ Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

- ▶  $A$ =amplitud de la serie.
- ▶  $\omega$  es el número de ciclos por unidad de tiempo.
- ▶  $\omega = 2\pi f = \frac{2\pi}{P}$ .



# Regresión Armónica

- ▶ Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

- ▶  $A$ =amplitud de la serie.
- ▶  $\omega$  es el número de ciclos por unidad de tiempo.
- ▶  $\omega = 2\pi f = \frac{2\pi}{P}$ .
- ▶  $P$  período de la serie.

# Regresión Armónica

- ▶ Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

- ▶  $A$ =amplitud de la serie.
- ▶  $\omega$  es el número de ciclos por unidad de tiempo.
- ▶  $\omega = 2\pi f = \frac{2\pi}{P}$ .
- ▶  $P$  período de la serie.
- ▶  $f$  frecuencia de la serie.

# Regresión Armónica

- ▶ Sea el modelo

$$Y_t = A \sin(\omega t + \psi) \quad (1)$$

donde

- ▶  $A$ =amplitud de la serie.
- ▶  $\omega$  es el número de ciclos por unidad de tiempo.
- ▶  $\omega = 2\pi f = \frac{2\pi}{P}$ .
- ▶  $P$  período de la serie.
- ▶  $f$  frecuencia de la serie.
- ▶  $\psi$  desfase de la serie

# Regresión Armónica

- Consideremos el modelo (1), como  $\omega = 2\pi f$  podemos escribir,

$$\begin{aligned}Y_t &= A\sin(2\pi ft + \psi) \\&= A[\sin(2\pi ft)\cos(\psi) + \cos(2\pi ft)\sin(\psi)] \\&= \underbrace{A\cos(\psi)}_{\beta_1}\sin(2\pi ft) + \underbrace{A\sin(\psi)}_{\beta_2}\cos(2\pi ft)\end{aligned}$$

Luego,

$$Y_t = \beta_1\sin(2\pi ft) + \beta_2\cos(2\pi ft) \quad (2)$$

# Regresión Armónica

- Esto puede ser visto como un modelo de regresión simple,

$$\begin{bmatrix} Y_1 \\ \vdots \\ \vdots \\ Y_N \end{bmatrix} = \begin{bmatrix} \sin(2\pi f) & \cos(2\pi f) \\ \vdots & \vdots \\ \vdots & \vdots \\ \sin(2\pi fN) & \cos(2\pi fN) \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}$$

# Regresión Armónica

- Ahora, en el caso general,

$$Y_t = \beta_{11}\sin(2\pi f_1 t) + \beta_{21}\cos(2\pi f_1 t) + \dots + \beta_{1q}\sin(2\pi f_q t) + \beta_{2q}\cos(2\pi f_q t) + \epsilon_t \quad (3)$$

donde, las frecuencias propias  $\{f_1, \dots, f_q\}$  se calculan en base al espectro de la serie o transformada de Fourier, tópico que veremos más adelante. Supondremos ahora que las frecuencias propias  $f_i$  son conocidas.

# Regresión Armónica

- Sea la regresión armónico simple ajustada con una frecuencia propia del tipo,

$$Y_t = \beta_1 \sin(2\pi ft) + \beta_2 \cos(2\pi ft) + \epsilon_t$$

podemos obtener una estimación de  $A$  y  $\psi$  a partir de las estimaciones de  $\beta_1$  y  $\beta_2$ , usando,

$$\begin{aligned} A &= \sqrt{\beta_1^2 + \beta_2^2} \\ \psi &= \text{atan}(\beta_1/\beta_2) \end{aligned}$$

# Regresión con variables dummy

- Suponga el modelo con tendencia determinística,

$$T_t = \beta_0 + \beta_1 t + \dots + \beta_m t^m$$



# Regresión con variables dummy

- Suponga el modelo con tendencia determinística,

$$T_t = \beta_0 + \beta_1 t + \dots + \beta_m t^m$$

- Para nuestro modelo vamos a suponer que la periodicidad observada ocurre cada 12 periodos de tiempo, entonces

$$S_t = \sum_{j=1}^{12} \alpha_j d_{jt}$$

# Regresión con variables dummy

- Suponga el modelo con tendencia determinística,

$$T_t = \beta_0 + \beta_1 t + \dots + \beta_m t^m$$

- Para nuestro modelo vamos a suponer que la periodicidad observada ocurre cada 12 periodos de tiempo, entonces

$$S_t = \sum_{j=1}^{12} \alpha_j d_{jt}$$

- Como suponemos la estacionalidad constante,  $\alpha_j$  no dependen del tiempo, entonces podemos pensar en variables “dummys”, por ejemplo en el caso que se presente una estacionalidad cada 12 meses (en una serie mensual).

$$d_{jt} = \begin{cases} 1, & \text{si el periodo } t \text{ corresponde al mes } j \quad j = 1, \dots, 12 \\ 0, & \text{si no} \end{cases}$$

# Regresión con variables dummy

- En este caso,

$$\sum_{j=1}^{12} d_{jt} = d_{1t} + d_{2t} + \dots + d_{12t}, \quad t = 1, 2, \dots, n$$

de modo que la matriz no es de rango completo, así, imponemos la restricción adicional

$$\sum_{j=1}^{12} \alpha_j = 0$$

y obtenemos el modelo de rango completo

$$Y_t = \sum_{j=0}^m \beta_j t^j + \sum_{j=1}^{11} \alpha_j D_{jt} + \epsilon_t$$

# Regresión con variables dummy

- El modelo de rango completo

$$Y_t = \sum_{j=0}^m \beta_j t^j + \sum_{j=1}^{11} \alpha_j D_{jt} + \epsilon_t$$

donde ahora,

$$D_{jt} = \begin{cases} 1, & \text{si el periodo } t \text{ corresponde al mes } j \quad j = 1, \dots, 11 \\ -1, & \text{si el periodo } t \text{ corresponde al mes } 12, \\ 0, & \text{eoc} \end{cases}$$

# Regresión con variables dummy

- De este modelo podemos utilizar la teoría usual de mínimos cuadrados y obtener los estimadores de  $\alpha_j$  y  $\beta_j$ , o sea, para una muestra  $Y_1, \dots, Y_N$  obtenemos el modelo

$$Y = C\beta + D\alpha + \epsilon$$

donde,

$$Y_{n \times 1} = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad C_{n \times (m+1)} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 2 & \dots & 2^m \\ \vdots & \vdots & & \vdots \\ 1 & n & \dots & n^m \end{bmatrix}, \quad \alpha_{11 \times 1} = \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_{11} \end{bmatrix}$$
$$\beta_{(m+1) \times 1} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix}, \quad D_{n \times 11} = \begin{bmatrix} D_{11} & D_{21} & \dots & D_{11,1} \\ D_{12} & D_{22} & \dots & D_{11,2} \\ \vdots & \vdots & & \vdots \\ D_{1n} & D_{2n} & \dots & D_{11,n} \end{bmatrix}, \quad \epsilon_{n \times 1} = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

# Regresión con variables dummy

- El modelo se puede escribir de la siguiente manera,

$$Y = X\gamma + \epsilon$$

donde,

$$X = [C : D] \quad y \quad \gamma = \begin{bmatrix} \beta \\ \dots \\ \alpha \end{bmatrix}$$

de modo que el estimador de mínimos cuadrados está dado por

$$\hat{\gamma} = [X'X]^{-1}X'Y$$