



UNIVERSIDAD
DE SANTIAGO
DE CHILE

Facultad de Ciencia
Departamento de Matemática y Ciencia de la Computación
Ingeniería Estadística
Seminario de Tesis II

Entendiendo las causas y consecuencias del COVID-19: un análisis espacio-temporal

Andrés Ayala Muñoz

Profesor guía
Felipe Elorrieta López

Comisión
Claudio Vargas Rona
Pablo Villalobos Dintrans

Mayo 2022

Resumen

Los efectos del COVID-19 han sido variados en la Región Metropolitana, lo que se ha reflejado en las medidas tomadas para restringir el avance de la pandemia. Sin embargo, es observado que los indicadores de COVID-19 como ciertas características socioeconómicas y demográficas no están distribuidas aleatoriamente en las comunas. De esta manera, el presente estudio busca analizar cuáles son los determinantes de los efectos del COVID-19 a nivel comunal, es decir, qué características de cada comuna son relevantes en el desarrollo de la pandemia. Además de esto, se consideran variables íntimamente relacionadas con el COVID-19, como son la vacunación, movilidad y trazabilidad. El estudio se llevó a cabo a través de la estimación de modelos espacio-temporales que corrigen dependencia de este tipo. Sus resultados indican que la pobreza multidimensional, el porcentaje de áreas verdes y de mujeres en la comuna estarían estrechamente relacionadas con el impacto del virus en ella, y que la movilidad afectarían positivamente tanto los casos como defunciones. La vacunación disminuiría la tasa de incidencia de casos, mientras que la oportunidad en la notificación de casos lo haría con las defunciones.

Índice

Resumen	1
1. Introducción	6
2. Objetivos	8
2.1. Generales	8
2.2. Específicos	8
3. Marco Teórico	9
3.1. Estadística Espacial	9
3.1.1. Clasificación Datos Espaciales	9
3.1.2. Efectos Espaciales	11
3.1.2.1. Heterogeneidad Espacial	11
3.1.2.2. Autocorrelación Espacial	11
3.1.3. Criterio de Vecindad	12
3.1.4. Matriz de Contigüidad	13
3.1.5. Pruebas de Asociación Espacial	15
3.1.5.1. Autocorrelación Global	15
3.1.5.2. Autocorrelación Local	17
3.1.6. Modelos Espaciales	18
3.2. Estadística Espacio-Temporal	20
3.2.1. Datos de Panel Espaciales	20
3.2.2. Pruebas de Asociación Temporal	21
3.2.3. Modelos con Datos de Panel Espaciales	22
3.2.4. Pruebas útiles para especificación de modelos con datos de Panel espaciales .	26
3.2.4.1. Prueba de Hausman Espacial	26
3.2.4.2. Pruebas del Multiplicador de Lagrange	26
3.3. Conceptos adicionales	29
3.3.1. Selección de variables	29
3.3.2. Indicadores de bondad de ajuste	30
4. Metodología	31
5. Aplicación	33
5.1. Periodos de estudio por comuna	33
5.2. Bases de datos	35
5.2.1. Variables independientes	36
5.2.2. Variables dependientes	38
5.3. Estudio Espacial	40
5.3.1. Determinación Matriz de Contigüidad	40

5.3.2.	Análisis Descriptivo base de datos transversal	41
5.3.2.1.	Estadísticas descriptivas y correlación espacial	41
5.3.2.2.	Relaciones entre variables	47
5.3.3.	Modelos	49
5.4.	Estudio Espacio-Temporal	59
5.4.1.	Análisis Descriptivo datos de panel espaciales	59
5.4.2.	Modelos	66
5.4.2.1.	Modelos de efecto fijo	66
5.4.2.2.	Modelos de efecto aleatorio	71
5.5.	Resumen de resultados	80
6.	Conclusiones	81
7.	Bibliografía	83
8.	Anexo	88
8.1.	Periodos de estudio por comuna	88
8.2.	Gráficos de distribución espacial	90
8.3.	Gráficos Clusters I de Moran Local	95
8.4.	Correlación variables (base transversal)	100
8.5.	Análisis de autocorrelación espacial en los residuos (efectos fijos iniciales)	105
8.6.	Análisis de autocorrelación espacial en los residuos (efectos fijos corregidos)	107
8.7.	Análisis de autocorrelación espacial en los residuos (efectos aleatorios iniciales)	109

Índice de figuras

1.	Concentración de ozono	9
2.	Región Metropolitana según zonas regular o irregularmente espaciadas.	10
3.	Ubicación de árboles Secuoya California.	10
4.	Tipos de autocorrelación.	12
5.	Tipos de Contigüidad de primer orden.	14
6.	Tipos de Contigüidad de segundo orden.	14
7.	Olas Pudahuel (hasta el 01-08-2021).	34
8.	Largo 2da ola (en días).	35
9.	Extracto base de datos 1 (datos transversales).	39
10.	Extracto base de datos 2 (datos de panel espaciales).	40
11.	Región Metropolitana con relaciones de vecindad.	40
12.	Distribución espacial de variables dependientes.	43
13.	Distribución espacial de variables independientes.	44
14.	I de Moran Local para variables dependiente de casos.	45
15.	I de Moran Local para variables dependiente de defunciones.	46
16.	Relación tasa de Contagios/Defunciones y Movilidad (más Paso a Paso).	59
17.	Relación tasa de Contagios/Defunciones y porcentaje vacunación.	60
18.	Relación tasa de Contagios/Defunciones y Oportunidad en la notificación.	60
19.	Relación entre tasa de Contagios y tasa de Defunciones	62
20.	Histograma de frecuencia correlación cruzada (casos v.s defunciones)	62
21.	Histogramas de frecuencia para correlaciones cruzadas	63
22.	Extracto matriz de correlaciones (variables originales)	64
23.	Extracto matriz de correlaciones (variables rezagadas)	65
24.	Análisis de correlación espacial en residuos.	67
25.	Análisis de correlación espacial para residuos de modelo corregido (casos)	70
26.	Análisis de correlación espacial para residuos de modelo de efecto aleatorio (casos n°1)	73
27.	Análisis de correlación espacial para residuos de modelo de efecto aleatorio simplificado (casos n°1)	75
28.	Distribución espacial de variables independientes faltantes.	94
29.	Clusters I de Moran local.	99

Lista de tablas

1.	Datos de panel espacial.	21
2.	Modelos para datos de panel espacial.	24
3.	Estadísticas descriptivas datos de corte transversal.	41
4.	OLS completos para modelos de casos.	50
5.	OLS completos para modelos de defunciones.	52
6.	OLS simplificados para modelos de casos.	55
7.	OLS simplificados para modelos de defunciones.	56
8.	Modelos de casos corregidos espacialmente (SAR).	58
9.	Modelos de efecto fijo para Casos y Defunciones	66
10.	P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los tres modelos de efecto fijo (Comuna: La Florida).	68
11.	Pruebas LM para modelo de efecto fijo de casos.	68
12.	Pruebas LM para modelo de efecto fijo de defunciones n° 1.	68
13.	Pruebas LM para modelo de efecto fijo de defunciones n° 2.	69
14.	Modelos de efecto fijo para Casos y Defunciones corregidos	69
15.	P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los tres modelos de efecto fijo corregido (Comuna: La Florida).	70
16.	Modelos de efecto aleatorio para Casos y Defunciones	71
17.	P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los seis modelos de efecto aleatorio (Comuna: La Reina).	73
18.	Modelos de efecto aleatorio para Casos y Defunciones simplificados	74
19.	P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los seis modelos simplificados de efecto aleatorio (Comuna: La Reina).	76
20.	Pruebas LM para modelo de efecto aleatorio de casos n°1.	76
21.	Pruebas LM para modelo de efecto aleatorio de casos n°2.	76
22.	Pruebas LM para modelo de efecto aleatorio de defunciones n°1.	76
23.	Pruebas LM para modelo de efecto aleatorio de defunciones n°2.	77
24.	Pruebas LM para modelo de efecto aleatorio de defunciones n°3.	77
25.	Pruebas LM para modelo de efecto aleatorio de defunciones n°4.	77
26.	Modelos de efecto aleatorio para Casos y Defunciones corregidos	78
27.	Resumen determinantes del impacto de COVID-19	80
28.	Periodos de estudio por comuna.	88
29.	Correlaciones variables (base transversal)	100

1. Introducción

El 30 de enero del 2020 la Organización Mundial de la Salud declaró como pandemia a la enfermedad COVID-19 causada por el virus SARS-CoV-2 (OMS, 2020), correspondiente al último virus descubierto de la familia coronavirus. A más de dos años, mayo del 2022, se suman a nivel mundial más de 500 millones de casos confirmados y más de 6 millones de muertes (OMS, 2022).

Pese a que se lleva un largo periodo combatiendo la propagación de esta enfermedad, el surgimiento de nuevas variantes, la disponibilidad de vacunas, entre otras situaciones, mantienen a los países en estado de alerta, lo que ha requerido de un continuo estudio de los factores que explican el impacto del COVID-19.

En Chile, el primer caso fue reportado el 3 de marzo del 2020 y, durante el periodo de pandemia, hasta mayo del 2022, acumula más de 3.5 millones de casos y 57.000 fallecidos (Gobierno de Chile, 2022), lo que ha puesto a prueba el sistema de salud y su red hospitalaria, presentando en más de una vez momentos críticos.

Actualmente, mayo del 2022, Chile ha sido uno de los países más afectados por la pandemia, ocupando la octava posición entre los países con más casos en América (OMS, 2022). Además, se ha caracterizado por proponer una serie de estrategias para prevenir y/o minimizar el avance del virus, como el plan de vacunación o el Plan Paso a Paso, que establece restricciones para las comunas del país según indicadores epidemiológicos (Gobierno de Chile, 2021). Lo anterior, junto con sus altos índices de desigualdad (CEPAL, 2018), hacen de Chile un caso interesante de estudiar entre los países latinoamericanos, y que puede aportar información relevante tanto de los factores determinantes del COVID-19 como de la eficiencia de las medidas tomadas, tal como busca hacer el siguiente trabajo.

Estudios destacan el carácter multicausal al momento de examinar los determinantes del COVID-19, estudiando el efecto de condiciones de salud preexistentes, distintas estructuras demográficas y factores socioeconómicos (Villalobos, et al. 2021; Su, et al. 2020; Raifman & Raifman, 2020). Este análisis multicausal se extiende a indicadores relacionados con la enfermedad, número de casos confirmados, muertes y hospitalizaciones.

El siguiente análisis busca continuar con el desarrollo del estudio “COVID-19 incidence and mortality in the Metropolitan Region, Chile: time, space, and structural factors” (Villalobos, et al. 2021) en el cual se analiza, mediante múltiples modelos que consideran el análisis espacial, el efecto de factores sociales, demográficos, y de salud sobre indicadores del COVID-19. Sus resultados muestran que los impactos del COVID-19 se distribuyen de manera desigual entre las comunas de la Región Metropolitana, destacando factores que impactan en resultados del COVID-19 como el porcentaje de uso de transporte público o pobreza multidimensional en cada comuna y destaca la necesidad de investigar los determinantes sociales de la salud y la dinámica espacio-temporal al analizar el COVID-19. Sin embargo, puesto que se desarrolló con mucha menor información a la que hoy se

dispone, el presente estudio propone incorporar nuevas aristas a la investigación, algunas de estas son:

- Presentar una metodología para la determinación de periodos de estudio en cada comuna de la Región Metropolitana (el estudio previo consideraba una ventana de 100 días para cada comuna). La evidencia muestra que existen diferencias en la evolución de la pandemia en cada sector geográfico (Chowell, et al. 2020) demostrando la necesidad de tener de un método objetivo al momento de la fijación de periodos.
- Incluir nuevas variables independientes que el estudio previo no pudo, ya sea por la menor cantidad de información que se disponía en dicho momento (Ej. movilidad, días de cuarentena, entre otras) o simplemente variables que aún no existían (Ej. vacunación). Además, agregar nuevas variables dependientes sobre indicadores relacionados con el COVID-19, permitiendo realizar un análisis más completo al momento de estudiar el efecto de factores sociales, demográficos, y de salud sobre indicadores de esta enfermedad.
- El estudio previo estima principalmente modelos que corrigen dependencia espacial. De esta manera, se incorporarán al análisis modelos con datos de panel espaciales, los cuales logran capturar la dependencia espacial y temporal de los datos en caso de presentarse.

Las pruebas y modelos empleados en este estudio, provenientes en su mayoría de la econometría espacial, tienen sustento en la forma en que se contagia el COVID-19, y las diferencias en el acceso y la calidad de la atención médica en cada comuna de la Región Metropolitana. En esta línea, se observa que tanto variables dependientes (indicadores de COVID-19) como independientes (variables demográficas, de salud y socioeconómicas) no están distribuidas aleatoriamente en las distintas zonas geográficas (Sabatini, et al. 2001). Por ejemplo, la Región Metropolitana muestra una marcada concentración de los ingresos en ciertos sectores geográficos, además de que sus habitantes tienden a agruparse según ciertas características socioeconómicas y demográficas. De modo que, como nuestro fin es identificar qué variables impactan significativamente en indicadores del COVID-19, es imprescindible utilizar las herramientas que nos ofrece esta área del conocimiento.

2. Objetivos

2.1. Generales

- Entender los determinantes del impacto del COVID-19, para las comunas de la Región Metropolitana, mediante un análisis espacio-temporal.

2.2. Específicos

- Revisar literatura para la apropiada definición de variables, temporalidad y espacialidad.
- Definir una metodología que permita determinar el periodo de estudio en cada comuna de la región.
- Calcular variables dependientes e independientes por comuna para modelos posteriores.
- Verificar si existe dependencia espacial y/o temporal en los datos.
- Estimar modelos espacio-temporales para testear las variables seleccionadas.
- Determinar qué variables demográficas, de salud y socioeconómicas impactan significativamente en indicadores del COVID-19.

3. Marco Teórico

3.1. Estadística Espacial

La estadística espacial es una rama de la estadística que permite estudiar cualquier fenómeno en el que se considera relevante la distribución espacial y la influencia que esta posee sobre los datos. De esta manera, posee aplicaciones en múltiples áreas como la salud, análisis económicos, climatología, entre otros, ofreciendo un conjunto de herramientas que consideran e incorporan los efectos espaciales en los análisis.

3.1.1. Clasificación Datos Espaciales

Según la información que se disponga existen distintas clasificaciones para los datos espaciales, a continuación se presenta la más utilizada.

Supongamos que se posee la medición de variables aleatorias en distintas ubicaciones, o de manera más formal “un proceso estocástico espacial (también llamado a menudo campo aleatorio espacial), o una colección de variables aleatorias y , indexadas por la ubicación i ” (Anselin, 2001).

$$\{y_i, i \in D\}$$

Donde el conjunto de índices D es una superficie continua o un conjunto finito de lugares discretos. Así, los datos espaciales pueden clasificarse en tres grandes áreas según las características de D (Ortiz, 2017; Giraldo, 2016):

- **Geoestadística:** En este caso y_i corresponde a un vector aleatorio en una ubicación i , donde i varía de manera continua sobre D . Eso quiere decir, que para cualquier punto de la superficie se pueden medir un conjunto de variables aleatorias. Así, el propósito esencial de la geoestadística será interpolar valores según un conjunto fijo de unidades espaciales conocidas (Ver ejemplo en Figura 1).




Figura 1: Concentración de ozono

Fuente: Ortiz, 2017

- **Datos de área:** En este caso D es un conjunto discreto asociados a ubicaciones delimitadas por polígonos (áreas con fronteras bien definidas), donde cada una de ellas se comporta como una unidad de análisis y se espera que las variables estudiadas presenten un comportamiento específico en cada una. Dichas zonas pueden estar regular o irregularmente espaciadas, donde las primeras son subdivisiones idénticas en la superficie total (generalmente rectangulares) y las segundas son divisiones de distintos tamaños y formas (generalmente límites ya estipulados como comunas, regiones, países). Ver ejemplo en la Figura 2.




Figura 2: Región Metropolitana según zonas regular o irregularmente espaciadas.

Fuente: Elaboración Propia

- **Datos de procesos puntuales:** En este caso D puede ser discreto o continuo, además de ser aleatorio ya que la selección no depende del investigador. Uno de los objetivos principales de estudio de procesos puntuales es la detección de patrones en el análisis de cierto evento de interés (ver ejemplo en Figura 3).




Figura 3: Ubicación de árboles Secuoya California.

Fuente: Ortiz, 2017

Ya especificados los tipos de datos espaciales, cabe destacar que como el presente análisis busca identificar los determinantes del impacto del COVID-19 en las distintas comunas de la Región Metropolitana, gran parte los datos necesarios corresponden a datos de área con zonas irregularmente espaciadas.

3.1.2. Efectos Espaciales

Según Acevedo & Velásquez (2008) en el estudio de cualquier fenómeno de carácter social, económico, entre otros, donde un suceso en determinada zona posee repercusiones sobre otras, la ubicación geográfica será un aspecto importante a considerar dentro de las técnicas que se utilizarán, ya que puede existir algún “efecto espacial” que afecte la validez de los resultados de no ser incorporado en las especificaciones.

Al trabajar con datos espaciales son dos los “efectos espaciales” que se pueden presentar, impidiendo que los métodos clásicos de la estadística y la econometría sean una buena herramienta para su modelación. A continuación se hace una descripción de ambos, donde la atención se centrará en el segundo de estos efectos.

3.1.2.1 Heterogeneidad Espacial

La heterogeneidad espacial “es un caso especial de inestabilidad estructural, un problema familiar en la econometría estándar. La heterogeneidad está estructurada espacialmente, es decir, con respecto a ubicaciones en el espacio, o subconjuntos regionales de observaciones” (Anselin, 1988, citado en Anselin, 2021). Aunque es un problema por considerar, investigadores coinciden en que las dificultades ocasionados por este tipo de efecto espacial pueden ser resueltos, en su mayoría, por técnicas de econometría clásica tales como métodos de parámetros cambiantes, coeficientes aleatorios e inestabilidad estructural, los cuales pueden ser fácilmente adaptados para que consideren variaciones en el espacio (Acevedo & Velásquez, 2008).

3.1.2.2 Autocorrelación Espacial

La autocorrelación espacial es un concepto que ha sido definido y estudiado por múltiples autores desde mediados del siglo pasado (Getis, 2010). Algunas de las definiciones que se encuentran al estudiar este concepto son “todas las cosas están relacionadas entre sí, pero las cosas más próximas en el espacio tienen una relación mayor que las distantes”, correspondiente a la primera ley de la geografía de Tobler (1970), o similarmente, “la autocorrelación espacial refleja el grado en que objetos o actividades en una unidad geográfica son similares a otros objetos o actividades en unidades geográficas próximas” (Goodchild, 1987 citado en Acevedo & Velásquez, 2008), o desde una perspectiva un poco más formal tenemos, “el valor de la variable dependiente en una unidad espacial es parcialmente función del valor de la misma variable en unidades vecinas” (Flint et al. 2000), entre muchas otras. De esta manera, podemos entender a la autocorrelación espacial como la dependencia que posee el espacio geográfico sobre cierta variable de interés en las distintas ubicaciones.

Al analizar la autocorrelación espacial son tres las situaciones en las que nos podemos encontrar:

- **Autocorrelación positiva (similitud):** El valor de la variable de interés en cierta ubicación es similar a los valores de la variable en las ubicaciones más cercanas (vecinas).
- **Autocorrelación negativa (disimilitud):** El valor de la variable de interés en cierta ubicación difiere mucho de los valores de la variable en las ubicaciones más cercanas (vecinas).
- **Aleatoriedad:** Los valores de la variable de interés se distribuyen de forma aleatoria en el espacio.

Para un mejor entendimiento de cada caso ver Figura 3.1.2.2.




Figura 4: Tipos de autocorrelación.

Fuente: Elaboración Propia

Claramente el criterio que tengamos para definir vecindades afectará a la autocorrelación calculada, por lo que en la siguiente sección se hablará de cómo definir vecindades y la forma de representar dichas relaciones.

3.1.3. Criterio de Vecindad

Se denomina criterio de vecindad a aquella regla que permite discernir qué unidades espaciales son cercanas entre sí (vecinas) y cuáles no. Existe una infinidad de formas de definir un criterio de vecindad y según Acevedo & Velásquez (2008) la principal forma de seleccionar uno de ellos, será la naturaleza del problema que se esté estudiando más la información adicional que se tenga de las unidades espaciales. A continuación se da una pequeña descripción de los criterios de vecindad generalmente utilizados para datos de área, correspondiente a criterios geográficos:

- **Por contigüidad:** Considerará vecinas a aquellas unidades espaciales que compartan algún borde (definición utilizada en el presente análisis).
- **Basado en distancias:** Considerará vecinas a aquellas unidades espaciales que cumplan cierta condición bajo una función de distancia definida (usualmente distancia euclidiana).

Posteriormente, definido un criterio de vecindad, se procede a la construcción de la matriz de Contigüidad, la cual resumirá las relaciones multidireccionales calculadas.

3.1.4. Matriz de Contigüidad

La matriz de Contigüidad o de Pesos Espaciales W es una matriz cuadrada de $n \times n$, donde cada una de las filas/columnas simboliza una ubicación y los elementos de la matriz w_{ij} representan la intensidad de la interdependencia entre cada par de ubicaciones (Moreno y Vayá, 2000 citado en Baronio, 2018). De esta manera, estamos ante una matriz de la siguiente forma:

$$W = \begin{bmatrix} 0 & w_{12} & \dots & w_{1n} \\ w_{21} & 0 & \dots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n1} & w_{n2} & \dots & 0 \end{bmatrix}_{n \times n}$$

Donde los w_{ij} tomarán valores de acuerdo con la relación e intensidad de dependencia entre cada par de ubicaciones y la diagonal tendrá siempre ceros, ya que una ubicación no puede estar relacionada consigo misma. Los valores que toman w_{ij} dependerán del criterio de vecindad considerado:

a) Vecindad por Contigüidad.

En este caso, correspondiente al utilizado en este análisis, los elementos de la matriz tomarán un valor uno si las dos unidades espaciales son contiguas o cero en caso contrario, donde existen tres formas principales para definir la presencia o ausencia de contigüidad (Acevedo & Velásquez, 2008).

- **Contigüidad Torre:** Son vecinos aquellas unidades que comparten un lado común con la región de interés (arriba, abajo, a la izquierda o a la derecha).
- **Contigüidad Alfil:** Son vecinos aquellas unidades que comparten un vértice común con la región de interés.
- **Contigüidad Reina:** Son vecinos aquellas unidades que comparten un lado o vértice con la región de interés.

Para mejor entendimiento se presenta la Figura 5 que ejemplifica cada uno de estos casos, donde la región denotada por “a” representa la región de interés y “b” sus respectivos vecinos (que son representados posteriormente como $w_{ij} = 1$ en la matriz W).

	b	
b	a	b
	b	

Contigüidad de torre

b		b
	a	
b		b

Contigüidad de alfil

b	b	b
b	a	b
b	b	b

Contigüidad de reina

Figura 5: Tipos de Contigüidad de primer orden.

Fuente: Fuente: Acevedo & Velásquez, 2008.

Es importante mencionar que los criterios recién presentados corresponden a casos de contigüidad de primer orden. No obstante, según Baronio (2018) en algunos problemas puede resultar particularmente útil el abordaje de contigüidades de segundo orden, el cual es simplemente es una extensión de lo anterior, como se puede ver en la Figura 6.

		b		
		b		
b	b	a	b	b
		b		
		b		

Contigüidad de torre

b				b
	b		b	
		a		
	b		b	
b				b

Contigüidad de alfil

b	b	b	b	b
b	b	b	b	b
b	b	a	b	b
b	b	b	b	b
b	b	b	b	b

Contigüidad de reina

Figura 6: Tipos de Contigüidad de segundo orden.

Fuente: Elaboración Propia

b) Vecindad basado en la distancia euclidiana.

En este caso, se calculará las distancias euclidianas entre los distintos puntos representativos de cada unidad espacial (generalmente centroides) y se considerará vecinas a aquellas que cumplan cierta condición (Martínez, 2018), a continuación se describen dos posibles criterios:

- **K vecinos más cercanos:** Serán vecinos a la región de interés las k regiones con menor distancia a esta.
- **Criterio distancia:** Serán vecinos a la región de interés aquellas regiones que se encuentren a menos de cierta distancia impuesta. Este criterio funcionará bien cuando las

regiones tienen una distancia similar entre ellas, ya que al existir una distancia más grande que las demás esta región se quedará sin vecinos o las demás regiones con demasiados.

Generalmente la matriz W , posterior a su definición, es estandarizada por filas, donde cada elemento w_{ij} es dividido por la suma de la fila a la que pertenece. Esta transformación da lugar a una serie de propiedades deseables (Anselin, 2021) y permitirá interpretar más fácilmente algunos resultados (que se definirán más adelante).

3.1.5. Pruebas de Asociación Espacial

Previamente se definió la autocorrelación espacial como la dependencia que posee el espacio geográfico sobre cierta variable de interés en las distintas unidades espaciales. El estudio y testeo de esta dependencia se debe hacer desde una perspectiva global y local, donde la primera permite analizar la existencia de esta y, en caso de existir, la segunda permite distinguir entre que unidades se presenta. A continuación se definen ambas y se presentan las pruebas diseñadas para su detección.

3.1.5.1 Autocorrelación Global

El estudio de la autocorrelación espacial global se realiza sobre el conjunto de todas las unidades espaciales, donde se busca analizar si una variable de interés presenta algún tipo de asociación con el espacio geográfico completo o esta se encuentra distribuida aleatoriamente. De esta manera, para las distintas pruebas que permiten detectar dicha asociación, las hipótesis son:

H_0 : Ausencia de autocorrelación espacial global para la variable de interés.
v.s

H_1 : Existencia de autocorrelación espacial global para la variable de interés.

Algunas pruebas para la detección de autocorrelación global son:

1. **I de Moran**: Prueba más utilizada para la detección de autocorrelación global, cuyo estadístico es:

$$I = \frac{n}{\sum_{i=1}^n \sum_{j=1}^n w_{ij}} * \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (y_i - \bar{y})(y_j - \bar{y})}{\sum_{i=1}^n (y_i - \bar{y})^2} \stackrel{a}{\sim} N(E(I), Var(I))$$

Donde:

- I : Estadístico I de Moran (cuando se estandariza W por filas entonces $I \in [-1; 1]$, pudiendo ser interpretado como cualquier correlación).
- n : Número de unidades espaciales.
- w_{ij} : Elemento (i, j) de la matriz de Contigüidad.
- y_i : Valor de la variable de estudio en la ubicación i.
- $\bar{y}$: Media de la variable de interés.

Puesto que el estadístico distribuye asintóticamente a una normal¹, es posible hacer un contraste de hipótesis para analizar la significancia del índice I. Donde si el p-valor es menor al nivel de significancia asignado, existirá evidencia suficiente para afirmar la existencia de la autocorrelación espacial global.

2. **C de Geary**: Prueba que se basa en el concepto de disimilaridad, cuyo estadístico es:

$$C = \frac{(n-1)}{2 \sum_{i=1}^n \sum_{j=1}^n w_{ij}} * \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij} (y_i - y_j)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Donde:

- C : Estadístico de Geary (con $C \in [0; 2]$).
- n : Número de unidades espaciales.
- w_{ij} : Elemento (i, j) de la matriz de Contigüidad.
- y_i : Valor de la variable de estudio en la ubicación i.
- $\bar{y}$: Media de la variable de interés.

Este estadístico también distribuye asintóticamente a una normal, pudiendo realizar un contraste de hipótesis para analizar la existencia de autocorrelación espacial global. Donde, debido a que el estadístico está comprendido entre 0 y 2, debe ser interpretado de la siguiente forma:

- $0 \leq C < 1$: Autocorrelación espacial positiva.
- $C = 1$: Aleatoriedad espacial.
- $1 < C \leq 2$: Autocorrelación espacial negativa.

3. **G(d) de Getis y Ord**: Prueba que incluye la distancia entre las unidades espaciales, cuyo estadístico es:

$$G(d) = \frac{\sum_{i=1}^n \sum_{j=1}^n w_{ij}(d) y_i y_j}{\sum_{i=1}^n \sum_{j=1}^n y_i y_j}$$

Donde:

- $G(d)$: Estadístico G(d) de Getis y Ord.
- n : Número de unidades espaciales.
- $w_{ij}(d)$: Distancia entre las unidades espaciales i y j.
- y_i : Valor de la variable de estudio en la ubicación i.

Al igual que previos estadísticos, la G(d) de Getis y Ord también distribuye asintóticamente normal, pudiendo realizar un contraste de hipótesis para analizar la existencia de autocorrelación espacial global.

¹Los valores teóricos de la esperanza y varianza de este índice pueden ser encontrados en Buzay & Montes (2021)

3.1.5.2 Autocorrelación Local

En el estudio de la autocorrelación espacial local se calcula un valor para cada unidad espacial, permitiendo analizar el grado de dependencia individual respecto a sus unidades vecinas (Martínez, 2018). De esta manera, en presencia de autocorrelación espacial (prueba global rechazada), mediante las pruebas de autocorrelación local será posible examinar dónde se encuentra dicha dependencia.

Para el testeo de esta autocorrelación existen los indicadores LISA (Local Indicators of Spatial Association). Donde las hipótesis para las distintas pruebas locales, son:

H_0 : Ausencia de autocorrelación espacial local.

v.s

H_1 : Existencia de autocorrelación espacial local.

Se presentan las versiones locales de las pruebas de autocorrelación expuestas en la sección previa (3.1.5.1).

1. **I de Moran Local**: Versión local de la prueba I de Moran, cuyo índice para cada unidad espacial i es:

$$I_i = (y_i - \bar{y}) * \sum_{j=1}^{N_i} w_{ij}(y_j - \bar{y})$$

Donde:

- I_i : Índice de Moran para la ubicación i .
- w_{ij} : Elemento (i, j) de la matriz de Contigüidad.
- y_i : Valor de la variable de estudio en la ubicación i .
- $\bar{y}$: Media de la variable de interés.
- N_i : Conjunto de vecinos de la ubicación i .

2. **C de Geary Local**: Versión local de la prueba C de Geary, cuyo índice es construido como:

$$C_i = \frac{1}{\sum_i^n (y_i - \bar{y})^2 / n^3} \sum_{j=1}^{N_i} w_{ij}(y_i - y_j)^2$$

Donde:

- c_i : Índice de Geary para la ubicación i .
- w_{ij} : Elemento (i, j) de la matriz de Contigüidad.
- y_i : Valor de la variable de estudio en la ubicación i .
- $\bar{y}$: Media de la variable de interés.
- n : Total de unidades espaciales.

- N_i : Conjunto de vecinos de la ubicación i .

3. G(d) de Getis y Ord Local:

$$G_i(d) = \frac{\sum_{j=1}^n w_{ij}(d)y_j - (\sum_{j \neq i} w_{ij}(d))\bar{y}}{\sqrt{s^2 * \frac{n \sum_{j=1}^{N_i} w_{ij}(d)^2 - (\sum_{j \neq i} w_{ij}(d))^2}{n-1}}}$$

Donde:

- $G_i(d)$: Índice de Getis y Ord Local para la ubicación i .
- n : Número de unidades espaciales.
- N_i : Conjunto de vecinos de la ubicación i .
- $w_{ij}(d)$: Distancia entre las unidades espaciales i y j .
- y_i : Valor de la variable de estudio en la ubicación i .
- $\bar{y}$: Media de la variable de interés.
- s^2 : cuasivarianza de la variable en estudio.

Al igual que en sus versiones globales, para los tres índices locales, es posible realizar un contraste de hipótesis que analiza su significancia. Donde si el p-valor es menor al nivel de significancia asignado, existirá evidencia suficiente para afirmar la existencia de la autocorrelación espacial local en dicha unidad espacial (con sus vecinas).

3.1.6. Modelos Espaciales

Cuando los datos de corte transversal² poseen autocorrelación espacial, no es correcta la implementación de técnicas clásicas de la estadística (como modelos de regresión lineal) para su análisis, ya que al no incorporar el “efecto espacial” en las especificaciones del modelo, conducirá a resultados sesgados (Anselin, 2003). De esta manera, de la econometría espacial nacen los modelos Espaciales o modelos de Corte Transversal que permiten solucionar dicho problema.

Según Pérez (2006) “la dependencia espacial en modelos de regresión aparece como consecuencia de autocorrelación en variables dependientes o independientes y por la aparición de un esquema de dependencia espacial”. Así, el efecto espacial puede ser incluido a las especificaciones del modelo mediante la incorporación de “variables espacialmente rezagadas” para la variable dependiente, explicativas o términos de error, donde estas pueden ser definidas como:

$$W_z = W_{n \times n} * z_{n \times 1}$$

Donde:

²Datos recopilados de individuos, regiones, comunas, etc. en un mismo instante de tiempo.

- W : Matriz de Contigüidad.
- z : Vector de observaciones en cada ubicación (variable dependiente, independiente o término de error).

Recordar que la matriz W generalmente es estandarizada por filas, donde cada elemento w_{ij} es dividido por la suma de la fila a la que pertenece, por lo que los elementos del vector W_z corresponderán a los promedios de los valores observados (ya sea la variable dependiente, independiente o término de error) en los vecinos de cada ubicación.

Según Anselin (2021) cada una de estas variables espacialmente rezagadas pueden agregarse a las especificaciones, dando lugar a una amplia gama de modelos. De esta forma, se presenta el modelo más general, que incorpora los tres tipos de dependencia, denominado modelo de Cliff-Ord (Paelinck, 2015).

$$\begin{aligned} y &= \lambda W_y + x\beta + \theta W_x + u \\ u &= \rho W_u + \varepsilon \end{aligned}$$

Donde, y es el vector de la variable dependiente ($nx1$), x es la matriz de las k variables independientes (nxk), β es el vector de parámetros ($kx1$), W_y es la variable dependiente rezagada espacialmente ($nx1$), W_x es la variable independiente rezagada espacialmente ($nx1$), W_u es el término de error rezagado espacialmente ($nx1$), λ es el coeficiente autorregresivo espacial, θ es el coeficiente espacial de dependencia local, ρ es el coeficiente de error espacial y ε es el componente de error ($nx1$).

Según las restricciones que se impongan a cada coeficiente espacial es posible obtener ocho distintos modelos:

1. **OLS: Modelo de Regresión Lineal** ($\lambda = 0$, $\theta = 0$ y $\rho = 0$).

$$y = x\beta + \varepsilon$$

2. **SAR: Modelo Espacial Autorregresivo** ($\theta = 0$ y $\rho = 0$).

$$y = \lambda W_y + x\beta + \varepsilon$$

3. **SEM: Modelo de Error Espacial** ($\lambda = 0$ y $\theta = 0$).

$$y = x\beta + u$$

$$u = \rho W_u + \varepsilon$$

4. **SLX: Modelo de Rezago Espacial en X** ($\lambda = 0$ y $\rho = 0$).

$$y = x\beta + \theta W_x + \varepsilon$$

5. **Modelo Espacial de Durbin** ($\rho = 0$).

$$y = \lambda W_y + x\beta + \theta W_x + \varepsilon$$

6. **SAREM: Modelo Espacial Autorregresivo con Autorregresión en los Errores** ($\theta = 0$).

$$y = \lambda W_y + x\beta + u$$

$$u = \rho W_u + \varepsilon$$

7. **Modelo de Error Espacial de Durbin** ($\lambda = 0$).

$$y = x\beta + \theta W_x + u$$

$$u = \rho W_u + \varepsilon$$

8. **GSM: Modelo de Cliff-Ord** ($\lambda \neq 0$ y $\theta \neq 0$ y $\rho \neq 0$).

$$y = \lambda W_y + x\beta + \theta W_x + u$$

$$u = \rho W_u + \varepsilon$$

Para encontrar el modelo adecuado, se puede empezar por ajustar el modelo más simple (OLS), para luego analizar si es necesario ir incorporado alguno de los efectos de interacción espacial. Esto se logrará estudiando si los residuos del modelo están espacialmente correlacionados o no, donde será necesario incluir alguno de los efectos si dicha autocorrelación es encontrada.

3.2. Estadística Espacio-Temporal

Denominaremos estadística espacio-temporal al conjunto de metodologías y herramientas que permiten estudiar cualquier fenómeno en el que se considera relevante la distribución espacial y temporal que pudieran tener los datos.

3.2.1. Datos de Panel Espaciales

Los “datos de panel” corresponden a datos de corte transversal que integran una dimensión temporal a su estructura, si además dicho panel considera que hay dependencia espacial entre cada unidad, entonces corresponderá a “datos de panel espaciales” (ver tabla 1).

Comuna	Día	Número casos	Número defunciones
San Joaquín	Lunes	10	2
San Joaquín	Martes	15	2
San Joaquín	Miércoles	18	3
La Reina	Lunes	7	1
La Reina	Martes	10	0
La Reina	Miércoles	9	2
Pudahuel	Lunes	14	3
Pudahuel	Martes	13	2
Pudahuel	Miércoles	22	2
⋮	⋮	⋮	⋮

Tabla 1: Datos de panel espacial.

Un panel se puede clasificar de distintas formas según la característica que se analice. De esta forma, si consideramos el número de observaciones que se poseen, tendremos:

- Balanceado: Para las distintas unidades se posee la misma cantidad de observaciones.
- Desbalanceado: Las unidades presentan distintas cantidades de observaciones.

Además, dependiendo del número de observaciones de corte transversal y temporal que se tengan se pueden clasificar en:

- Macropanel: Se tiene una mayor cantidad de observaciones temporales que número de unidades.
- Micropanel: Se tiene una menor cantidad de observaciones temporales que número de unidades.

3.2.2. Pruebas de Asociación Temporal

Como la estructura temporal es añadida a los datos, además de verificar la dependencia espacial utilizando las pruebas vistas en la sección 3.1.5.1, es necesario examinar si existe dependencia en esta nueva dimensión. De esta manera, se presentan la prueba de Box-Pierce y Ljung-Box que permiten contrastar las siguientes hipótesis.

H_0 : Los datos no están autocorrelacionados temporalmente (independencia).

v.s

H_1 : Los datos están autocorrelacionados temporalmente.

Y cuyos estadísticos son:

1. Estadístico de Box-Pierce

$$Q_{BP} = T \sum_{j=1}^L \hat{\rho}_j^2 \sim \chi_L^2$$

2. Estadístico de Ljung-Box

$$Q_{LB} = T(T+2) \sum_{j=1}^L \frac{\hat{\rho}_j^2}{T-j} \sim \chi_L^2$$

Donde,

- T : Total de observaciones temporales que tiene cada unidad espacial.
- $\hat{\rho}_j$: Autocorrelación estimada para el rezago j .
- L : Hasta que rezago se probará.

Puesto que los estadísticos siguen una distribución chi-cuadrado es posible hacer un contraste de hipótesis para analizar la autocorrelación temporal, donde, si el p-valor obtenido es menor al nivel de significancia asignado, existirá evidencia suficiente para afirmar que los datos están autocorrelacionados temporalmente.

Algunos puntos a considerar, son:

1. Pese a que ambas pruebas tienen la misma finalidad, se recomienda utilizar la prueba de Box-Ljung ya que corrige para muestras pequeñas y en el caso de muestras grandes, es asintóticamente igual a Box-Pierce.
2. Elegida una prueba, esta deberá ser realizada para cada unidad espacial.
3. Se recomienda realizar cada prueba considerando distintos valores de L .

3.2.3. Modelos con Datos de Panel Espaciales

Cuando se poseen datos como los presentados en la sección 3.2.1, es decir, datos de corte transversal que integran una dimensión temporal en su estructura y tienen dependencia espacial entre sus unidades, los Modelos con Datos de Panel Espaciales permiten capturar las interacciones espaciales y temporales entre unidades, considerando en su estructura interna dichas dependencias (espacial y/o temporal).

Múltiples autores han contribuido al actual estudio de estos modelos mediante la incorporación de estructuras y supuestos al momento de ajustarlos. De esta manera, suponiendo que se poseen datos de panel espaciales con N unidades espaciales y un total de T observaciones temporales para cada una (caso balanceado para simplificar la notación) se presenta el modelo general, del cual se desprenden una serie de modelos según las necesidades del investigador.

$$y = \lambda \underbrace{(I_T \otimes W)}_{W_y^*} y + X\beta + u$$

Donde y es el vector de dimensiones $TN \times 1$ que contiene a la variable dependiente, λ es el parámetro espacial, I_T es una matriz identidad de dimensión $T \times T$, W es la matriz de contigüidad de dimensión $N \times N$ (donde $\otimes$ es el producto Kronecker que permite combinar matricialmente las dimensiones temporales y espaciales, formando la matriz $(I_T \otimes W)$ de dimensiones $TN \times TN$, que al multiplicarla por y se obtiene la matriz W_y^* de dimensiones $TN \times 1$, que bajo este contexto corresponde a la variable dependiente rezagada espacialmente en los distintos tiempos), X es la matriz de dimensiones $TN \times k$ de las k variables independientes y el vector de perturbaciones u es conformado de la siguiente forma:

$$u = (\iota_T \otimes I_N)\mu + \varepsilon$$

$$\varepsilon = \rho(I_T \otimes W)\varepsilon + v$$

Donde ι_T es un vector de dimensión $T \times 1$ conformado por unos, I_N es una matriz identidad de dimensión $N \times N$, μ es un vector de efectos específicos por unidad espacial y ρ es el parámetro autorregresivo espacial (con $|\rho| < 1$). De esta manera, el primer término, μ , representa los efectos específicos de cada unidad espacial (no espacialmente correlacionados) y el segundo, ε , a los residuos espacialmente autocorrelacionados. Donde se supone que $\varepsilon_{it} \stackrel{iid}{\sim} N(0, \sigma_\varepsilon^2)$ y $v_{it} \stackrel{iid}{\sim} N(0, \sigma_v^2)$.

Los “efectos específicos de cada unidad espacial”, μ , pueden ser planteados como efectos fijos o aleatorios, donde la selección de uno de estos enfoques según Paelinck (2015) “suele desembocar en una polémica árida que la literatura tradicional resuelve con el test de Hausman” (prueba que será vista en la sección 3.2.4.1). Sin embargo, considerar efectos aleatorios en este tipo de modelos posee un beneficio adicional, ya que Baltagi et al. (2007) amplió dichos modelos considerando correlación serial en los errores restantes, como se muestra a continuación³.

$$v_t = \psi v_{t-1} + e_t \quad \text{con } v'_t = (v_{1t}, \dots, v_{Nt})$$

Donde ψ es el coeficiente de correlación serial, el cual posee la restricción $|\psi| < 1$ para una correcta implementación (ya que es un proceso autorregresivo de orden 1). Además, puesto que se está considerando un enfoque de efectos aleatorios, asumiendo implícitamente que los efectos individuales no están correlacionados con las otras variables explicativas, se tiene que $\mu_i \stackrel{iid}{\sim} N(0, \sigma_\mu^2)$. Finalmente, son necesarios los supuestos adicionales⁴: $v_{i0} \sim N(0, \frac{\sigma_e^2}{1-\psi^2})$ y $e_{it} \stackrel{iid}{\sim} N(0, \sigma_e^2)$.

Según las necesidades del investigador es posible imponer distintas restricciones a los parámetros λ , ρ , ψ y σ_μ^2 para obtener el modelo deseado. Así, Millo (2013) presenta la siguiente tabla resumen (ver tabla 2) que muestra las dieciséis posibles combinaciones.

³Baltagi estudia la correlación serial en los errores cuando se consideran efectos aleatorios o en ausencia de efectos individuales. De esta manera, sólo ante los efectos fijos no se podrá aplicar.

⁴Cuando se desea que el modelo considere la correlación serial en los errores, los supuestos para v_{i0} y e_{it} reemplazan el supuesto presentado previamente de $v_{it} \stackrel{iid}{\sim} N(0, \sigma_v^2)$.

Restricción	$\rho \neq 0,$ $\psi \neq 0$	$\rho \neq 0,$ $\psi = 0$	$\rho = 0,$ $\psi \neq 0$	$\rho = 0,$ $\psi = 0$
$\lambda \neq 0, \sigma_\mu^2 \neq 0$	SAREMSRRE	SAREMRE	SARSRRE	SARRE
$\lambda = 0, \sigma_\mu^2 \neq 0$	SEMSRRE	SEMRE	SRRE	RE
$\lambda \neq 0, \sigma_\mu^2 = 0$	SAREMSR	SAREM	SARSR	SAR
$\lambda = 0, \sigma_\mu^2 = 0$	SEMSR	SEM	SR	OLS

Tabla 2: Modelos para datos de panel espacial.

De todas estas combinaciones sólo aquellos modelos de la tabla 2 que son presentados en negrita serán considerados en esta sección, los demás no aportan nuevas aristas a la investigación ya que fueron vistos previamente⁵ en la sección 3.1.6.

Los doce modelos considerados poseen la siguiente forma.

- **SR:** Modelo espacial de panel con correlación serial.

$$y = X\beta + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **SEMSR:** Modelo espacial de panel con correlación espacial y serial.

$$y = X\beta + \rho(I_T \otimes W)\varepsilon + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **SARSR:** Modelo espacial de panel con retraso espacial y correlación serial.

$$y = \lambda(I_T \otimes W)y + X\beta + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **SAREMSR:** Modelo espacial de panel con retraso espacial, correlación espacial y serial.

$$y = \lambda(I_T \otimes W)y + X\beta + \rho(I_T \otimes W)\varepsilon + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **RE:** Modelo de datos de panel con efectos aleatorios.

$$y = X\beta + (\iota_T \otimes I_N)\mu + e$$

⁵Los modelos OLS, SAR, SEM y SAREM poseen las restricciones $\sigma_\mu^2 = 0$ y $\psi = 0$, por lo que no consideran efecto específico individual ni la correlación serial en los errores, que son las nuevas estructuras que se presentan en esta sección.

- **SRRE:** Modelo de datos de panel con efectos aleatorios y correlación serial.

$$y = X\beta + (\iota_T \otimes I_N)\mu + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **SEMRE:** Modelo de datos de panel con efectos aleatorios y correlación espacial.

$$y = X\beta + (\iota_T \otimes I_N)\mu + \rho(I_T \otimes W)\varepsilon + e$$

- **SEMSRRE:** Modelo de datos de panel con efectos aleatorios con correlación espacial y serial.

$$y = X\beta + (\iota_T \otimes I_N)\mu + \rho(I_T \otimes W)\varepsilon + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **SARRE:** Modelo de datos de panel espaciales con retraso espacial y efectos aleatorios.

$$y = \lambda(I_T \otimes W)y + X\beta + (\iota_T \otimes I_N)\mu + e$$

- **SARSRRE:** Modelo de datos de panel espaciales con retraso espacial, efectos aleatorios y correlación serial.

$$y = \lambda(I_T \otimes W)y + X\beta + (\iota_T \otimes I_N)\mu + v$$

$$v_t = \psi v_{t-1} + e_t$$

- **SAREMRE:** Modelo de datos de panel espaciales con retraso espacial, efectos aleatorios y correlación espacial.

$$y = \lambda(I_T \otimes W)y + X\beta + (\iota_T \otimes I_N)\mu + \rho(I_T \otimes W)\varepsilon + e$$

- **SAREMSRRE:** Modelo de datos de panel espaciales con retraso espacial, efectos aleatorios, correlación espacial y serial.

$$y = \lambda(I_T \otimes W)y + X\beta + (\iota_T \otimes I_N)\mu + \rho(I_T \otimes W)\varepsilon + v$$

$$v_t = \psi v_{t-1} + e_t$$

Algunas observaciones respecto a estos modelos son:

1. Es posible ajustar modelos similares a los modelos SAREMRE, SEMRE, SARRE y RE (aquellos que consideran efectos específicos y no poseen correlación serial en los errores) con la única diferencia de poseer en su especificación efectos fijos en vez de aleatorios. La abreviatura de estos modelos será similares a los ya mencionados, donde la única diferencia será cambiar las siglas RE de efectos aleatorios (Random Effects en ingles) por FE de efectos fijos (Fixed Effects).

2. Siguiendo con la idea del punto anterior, dentro de los modelos con datos de panel espaciales es posible considerar muchas otras variaciones, tales como, rezagos espaciales en las variables independientes, utilizar un proceso de medias móviles en los errores, entre muchas otras. Sin embargo, pese a la extensa literatura, muchas de estas aún no pueden ser implementadas en R.
3. El paquete **splm** de R permite implementar todos los modelos descritos de la tabla 2, donde los parámetros de cada uno de ellos son estimados mediante el método de máxima verosimilitud⁶.

3.2.4. Pruebas útiles para especificación de modelos con datos de Panel espaciales

Ante la inmensidad de modelos con datos de panel espaciales que se pueden ajustar (modelos presentados en sección 3.2.3) las siguientes pruebas permitirán conocer, en base a los datos que se posean, qué especificaciones del modelo son las más adecuadas, permitiendo acotar el espectro de modelos.

3.2.4.1 Prueba de Hausman Espacial

La prueba de Hausman Espacial es una modificación realizada por Mult y Pfaffermayr (2011) a la prueba de Hausman, la cual permite implementarla en un contexto espacial. Dicha prueba posibilita vislumbrar si efectos fijos (en caso de rechazar la hipótesis nula) o efectos aleatorios (en caso de no rechazar la hipótesis nula) deben ser considerados.

El estadístico de la prueba es:

$$H = NT(\hat{\theta}_{EA} - \hat{\theta}_{EF})^T(\hat{\Sigma}_{EA} - \hat{\Sigma}_{EF})^{-1}(\hat{\theta}_{EA} - \hat{\theta}_{EF}) \sim \chi_k^2$$

Donde N es el total de unidades espaciales, T es el total de observaciones temporales por unidad espacial, $\hat{\theta}_{EA}$ y $\hat{\theta}_{EF}$ son los estimadores espaciales bajo efectos aleatorios y fijos, $\hat{\Sigma}_{EA}$ y $\hat{\Sigma}_{EF}$ son sus respectivas estimaciones de matriz de varianza-covarianza.

Puesto que el estadístico sigue una distribución chi-cuadrado con k grados de libertad (número de covariables) es posible realizar un contraste de hipótesis para analizar que enfoque utilizar.

3.2.4.2 Pruebas del Multiplicador de Lagrange

Las pruebas del Multiplicador de Lagrange (LM) contribuirán a encontrar el modelo que mejor se adecue a los datos que se tienen. De esta manera, Baltagi et al. (2007) presentaron un conjunto de pruebas conjuntas, marginales y condicionales para las distintas combinaciones de parámetros, que permitirán tener una idea de que modelo ajustar, o con cual iniciar.

Es importante tener en cuenta que las pruebas LM consideran un gran espectro de modelos, pero poseen las siguientes limitaciones:

⁶Para más detalles del algoritmo empleado para estos procedimientos ver Millo (2012).

- No consideran el rezago espacial de la variable dependiente.
- En caso de existir efectos específicos, solo son considerados bajo un enfoque de efecto aleatorio. Esto, aunque limita las especificaciones del modelo, permite a su vez poder examinar la posibilidad de considerar correlación serial en los errores.

De esta manera, es posible encontrar dos versiones de las pruebas LM, donde la primera tan solo restringe los parámetros ρ y σ_μ^2 y la segunda a ρ , ψ y σ_μ^2 . A continuación son presentadas las pruebas correspondientes a ambas versiones.

Primera versión

1. Prueba conjunta para los dos parámetros. (J)

$$H_0^a : \rho = \sigma_\mu^2 = 0 \quad \text{v.s.} \quad H_1^a : \text{Alguno de estos dos parámetros es distinto de 0.}$$

2. Prueba marginal unidimensional para el parámetro autorregresivo espacial ρ , ignorando la presencia de efectos aleatorios. (M.1)

$$H_0^b : \rho = 0 \text{ (asumiendo } \sigma_\mu^2 = 0) \quad \text{v.s.} \quad H_1^b : \rho \neq 0 \text{ (asumiendo } \sigma_\mu^2 = 0)$$

3. Prueba marginal unidimensional para los efectos individuales aleatorios σ_μ^2 , ignorando la presencia de correlación espacial en los errores. (M.2)

$$H_0^c : \sigma_\mu^2 = 0 \text{ (asumiendo } \rho = 0) \quad \text{v.s.} \quad H_1^c : \sigma_\mu^2 > 0 \text{ (asumiendo } \rho = 0)$$

4. Prueba condicional unidimensional para el parámetro autorregresivo espacial ρ , que permite la presencia de efectos aleatorios. (C.1)

$$H_0^d : \rho = 0 \text{ (permitiendo } \sigma_\mu^2 > 0) \quad \text{v.s.} \quad H_1^d : \rho \neq 0 \text{ (permitiendo } \sigma_\mu^2 > 0)$$

5. Prueba condicional unidimensional para los efectos individuales aleatorios σ_μ^2 , que permite la presencia de correlación espacial en los errores. (C.2)

$$H_0^e : \sigma_\mu^2 = 0 \text{ (permitiendo } \rho \neq 0) \quad \text{v.s.} \quad H_1^e : \sigma_\mu^2 > 0 \text{ (permitiendo } \rho \neq 0)$$

Segunda versión

1. Prueba conjunta para los tres parámetros. (J)

$$H_0^f : \rho = \psi = \sigma_\mu^2 = 0 \quad \text{v.s.} \quad H_1^f : \text{Alguno de los parámetros es distinto de 0.}$$

2. Prueba marginal unidimensional para el parámetro autorregresivo espacial ρ , ignorando la presencia de correlación serial en los errores y efectos aleatorios. (M.1)

$$H_0^g : \rho = 0 \text{ (asumiendo } \psi = \sigma_\mu^2 = 0) \quad \text{v.s.} \quad H_1^g : \rho \neq 0 \text{ (asumiendo } \psi = \sigma_\mu^2 = 0)$$

3. Prueba marginal unidimensional para el coeficiente de correlación serial ψ , ignorando la presencia de correlación espacial en los errores y efectos aleatorios. (M.2)

$$H_0^h : \psi = 0 \text{ (asumiendo } \rho = \sigma_\mu^2 = 0) \quad \text{v.s.} \quad H_1^h : \psi \neq 0 \text{ (asumiendo } \rho = \sigma_\mu^2 = 0)$$

4. Prueba marginal unidimensional para los efectos individuales aleatorios σ_μ^2 , ignorando la presencia de correlación espacial y serial en los errores. (M.3)

$$H_0^i : \sigma_\mu^2 = 0 \text{ (asumiendo } \rho = \psi = 0) \quad \text{v.s.} \quad H_1^i : \sigma_\mu^2 > 0 \text{ (asumiendo } \rho = \psi = 0)$$

5. Prueba marginal bidimensional para el parámetro autorregresivo espacial ρ y el coeficiente de correlación serial ψ , ignorando los efectos aleatorios. (M.4)

$$H_0^j : \rho = \psi = 0 \text{ (asumiendo } \sigma_\mu^2 = 0) \quad \text{v.s.} \quad H_1^j : \rho \neq 0 \vee \psi \neq 0 \text{ (asumiendo } \sigma_\mu^2 = 0)$$

6. Prueba marginal bidimensional para el parámetro autorregresivo espacial ρ y efectos individuales aleatorios σ_μ^2 , ignorando correlación serial en los errores. (M.5)

$$H_0^k : \rho = \sigma_\mu^2 = 0 \text{ (asumiendo } \psi = 0) \quad \text{v.s.} \quad H_1^k : \rho \neq 0 \vee \sigma_\mu^2 > 0 \text{ (asumiendo } \psi = 0)$$

7. Prueba marginal bidimensional el coeficiente de correlación serial ψ y efectos individuales aleatorios σ_μ^2 , ignorando correlación espacial de los errores. (M.6)

$$H_0^l : \psi = \sigma_\mu^2 = 0 \text{ (asumiendo } \rho = 0) \quad \text{v.s.} \quad H_1^l : \psi \neq 0 \vee \sigma_\mu^2 > 0 \text{ (asumiendo } \rho = 0)$$

8. Prueba condicional unidimensional para el parámetro autorregresivo espacial ρ , que permite tanto la presencia de correlación serial en los errores como efectos aleatorios. (C.1)

$$H_0^m : \rho = 0 \text{ (permitiendo } \psi \neq 0 \text{ y } \sigma_\mu^2 > 0) \quad \text{v.s.} \quad H_1^m : \rho \neq 0 \text{ (permitiendo } \psi \neq 0 \text{ y } \sigma_\mu^2 > 0)$$

9. Prueba condicional unidimensional para el coeficiente de correlación serial ψ , que permite tanto la presencia de correlación espacial en los errores como efectos aleatorios. (C.2)

$$H_0^n : \psi = 0 \text{ (permitiendo } \rho \neq 0 \text{ y } \sigma_\mu^2 > 0) \quad \text{v.s.} \quad H_1^n : \psi \neq 0 \text{ (permitiendo } \rho \neq 0 \text{ y } \sigma_\mu^2 > 0)$$

10. Prueba condicional unidimensional para los efectos individuales aleatorios σ_μ^2 , que permite la presencia de correlación espacial y serial en los errores. (C.3)

$$H_0^o : \sigma_\mu^2 = 0 \text{ (permitiendo } \rho \neq 0 \text{ y } \psi \neq 0) \quad \text{v.s.} \quad H_1^o : \sigma_\mu^2 > 0 \text{ (permitiendo } \rho \neq 0 \text{ y } \psi \neq 0)$$

11. Prueba condicional bidimensional para el parámetro autorregresivo espacial ρ y el coeficiente de correlación serial ψ , permitiendo los efectos aleatorios. (C.4)

$$H_0^p : \rho = \psi = 0 \text{ (permitiendo } \sigma_\mu^2 > 0) \quad \text{v.s.} \quad H_1^p : \rho \neq 0 \vee \psi \neq 0 \text{ (permitiendo } \sigma_\mu^2 > 0)$$

12. Prueba condicional bidimensional para el parámetro autorregresivo espacial ρ y efectos individuales aleatorios σ_μ^2 , permitiendo correlación serial en los errores. (C.5)

$$H_0^q : \rho = \sigma_\mu^2 = 0 \text{ (permitiendo } \psi \neq 0) \quad \text{v.s.} \quad H_1^q : \rho \neq 0 \vee \sigma_\mu^2 > 0 \text{ (permitiendo } \psi \neq 0)$$

13. Prueba condicional bidimensional el coeficiente de correlación serial ψ y efectos individuales aleatorios σ_μ^2 , permitiendo correlación espacial de los errores. (C.6)

$$H_0^r : \psi = \sigma_\mu^2 = 0 \text{ (permitiendo } \rho \neq 0) \quad \text{v.s.} \quad H_1^r : \psi \neq 0 \vee \sigma_\mu^2 > 0 \text{ (permitiendo } \rho \neq 0)$$

Una vez que el investigador selecciona la versión a utilizar, dependiendo de si incorpora correlación serial en los errores o no, el procedimiento a seguir es similar, iniciándose con su respectiva prueba conjunta. En caso de rechazarse, probando que al menos uno de los parámetros es distinto de 0, se debe ir comprobando sistemáticamente (partiendo por las pruebas condicionales unidimensionales y luego marginales) qué parámetros son distintos de 0 y así se tendrá una idea más acotada de qué modelo ajustar (o con cual iniciar).

3.3. Conceptos adicionales

Puesto que en este proyecto serán estimados una gran cantidad modelos espaciales y espacio-temporales, cada uno con múltiples variables independientes, en esta sección se expondrán brevemente el criterio de selección de variables e indicadores de bondad de ajuste para encontrar los “mejores” modelos.

3.3.1. Selección de variables

Se busca encontrar el subconjunto de variables independientes que entreguen el mejor ajuste para describir la variable respuesta, bajo algún criterio especificado. Uno de estos criterios corresponde al criterio de información de Akaike (AIC), el cual se basa en la teoría de la información.

$$AIC = 2p - 2\ln(\hat{L})$$

Este cálculo realiza una compensación entre la complejidad del modelo y la bondad de ajuste, en el cual p corresponde número de parámetros en el modelo y $\hat{L}$ es el valor de la función de verosimilitud para el modelo estimado, donde se preferirá aquel modelo con las variables seleccionadas que posean un menor valor AIC (pérdida de información).

Establecido el criterio de selección, se procede con alguna de las siguientes estrategias de selección:

1. **Backward:** Se inicia con un modelo completo (con todas las variables explicativas) y se va eliminando en cada paso aquella variable explicativa que al ser removida minimiza/maximiza el criterio de selección (minimizar en el caso del AIC). De esta manera, cuando eliminar alguna de las variables ya no aporta en la optimización del criterio de selección, la estrategia se detiene y se obtiene el subconjunto de variables.
2. **Forward:** Se inicia con un modelo nulo (sin variables explicativas) y se va agregando en cada paso aquella variable explicativa que al ser añadida minimiza/maximiza el criterio de selección (minimizar en el caso del AIC). De esta manera, cuando agregar variables ya no aporta en la optimización del criterio de selección, la estrategia se detiene y se obtiene el subconjunto de variables.
3. **Stepwise:** Combinación de las estrategias Backward y Forward, en el que se inicia con un modelo completo y en cada paso se analiza la entrada y salida de las variables explicativas, con el fin de optimizar el criterio de selección.

3.3.2. Indicadores de bondad de ajuste

Estos índices permiten corroborar el ajuste del modelo (que tan bien se adecua a los datos), permitiéndonos comparar modelos al momento de explicar alguna variable.

1. R^2 : Índice que mide el porcentaje en que el modelo explica la variación de la variable respuesta.

$$R^2 = 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

2. R_{adj}^2 : Corresponde al mismo R^2 pero corregido por número de variables utilizadas k y el tamaño de la muestra n .

$$R_{ajustado}^2 = 1 - \frac{n-1}{n-k-1}(1 - R^2)$$

4. Metodología

Habiendo realizado la revisión de los conceptos, pruebas y modelos clásicos al momento de efectuar un análisis espacio-temporal (ver sección 3), a continuación se detalla brevemente tanto el procedimiento seguido, como las decisiones metodológicas tomadas en este estudio.

Con el objetivo entender los determinantes del impacto del COVID-19, en el presente análisis se estudian las interacciones, entre una serie de variables demográficas, de salud y socioeconómicas (a nivel comunal) y dos grupos de variables dependientes relativas a la enfermedad: casos y defunciones por COVID-19⁷ ⁸. Esta última idea, de diferenciar las variables dependientes en grupos, se basa en que “los casos se relacionan con la capacidad de prevenir la infección en cada comuna y las muertes reflejan la respuesta individual al virus” (Villalobos, et al. 2021) siendo relevante estudiar variables relacionadas con ambos indicadores.

Para un correcto análisis de dichas “interacciones”, esta problemática será abordada bajo las dos grandes áreas exhibidas en el marco teórico: “estadística espacial” y “estadística espacio-temporal”. Donde la primera permite incorporar efectos espaciales al estudio y la segunda tanto efectos espaciales como temporales. De esta manera, como primer paso, se construyó una base de datos con las características necesarias para cada área de estudio, donde la base de corte transversal (para la estadística espacial) y los datos de panel espaciales (para la estadística espacio-temporal) poseen las mismas variables estudiadas pero estructurada de distinta forma.

Cabe destacar que tanto el cálculo de las variables dependientes (incidencias acumuladas de casos y defunciones, más sus versiones ajustadas) como algunas de las independientes (porcentaje de vacunación, movilidad promedio, entre otras) dependen estrictamente del periodo de estudio escogido para cada comuna. De esta forma, ya que en todas las comunas la evolución de la pandemia es distinta, por ejemplo, cierto día una comuna puede estar en su “peak” de contagios de COVID-19 mientras que otra puede estar recién iniciando, se utilizará la metodología desarrollada en “Identification of COVID-19 Waves: Considerations for Research and Policy” (Ayala, et al. 2021) para la determinación de periodos de estudio objetivos en cada comuna (donde un periodo estará dado por el inicio y término de una ola⁹).

Posterior a la formación de base de datos, es necesario la creación de la matriz de contigüidad W , la cual permite cuantificar y resumir las relaciones de vecindad entre comunas. En este caso, se considera la matriz de contigüidad de tipo reina de primer orden, donde los vecinos serán todas las comunas que comparten una frontera. Otras especificaciones tales como, usar una “contigüidad

⁷Lista de variables dependientes e independientes se presentan en profundidad en la sección 5.2.

⁸Las variables dependientes son calculadas con información proveniente de las bases abiertas del Departamento de Estadísticas e Información de Salud (DEIS, 2022) y el Ministerio de Ciencia, Tecnología, Conocimiento e Innovación (MinCiencia, 2022), mientras que las variables independientes principalmente con datos de la encuesta CASEN (Ministerio de Desarrollo Social y Familia, 2017).

⁹Metodología descrita con más profundidad en la sección 5.1.

de tipo torre/alfil” o usar un “criterio basado en distancias” fueron descartadas debido a que las comunas de la RM “están irregularmente espaciadas” y “poseen una gran heterogeneidad en sus tamaños”.

Para entender el impacto de las variables en los casos y defunciones por el COVID-19, tanto en el análisis espacial como espacio-temporal, se iniciará por ajustar los modelos más simples (OLS y modelos de panel con efectos fijos/aleatorios) considerando distintas combinaciones de variables independientes¹⁰. Luego, mediante la aplicación del test I de Moran y Ljung-Box sobre los residuos de los modelos será posible saber si el espacio geográfico y/o la dimensión temporal son relevantes en la determinación de las variables analizadas¹¹. Donde, en caso de serlo, los resultados estarán sesgados y será necesario ajustar modelos que consideren en sus especificaciones estos nuevos efectos.

En el caso de que autocorrelación espacial sea detectada en los residuos de los OLS, se procederá a ajustar un modelo SAR o SEM dependiendo si la variable dependiente es de casos o defunciones respectivamente. Esta decisión fue tomada en base a la naturaleza de cada variable, por ejemplo, para la variable “casos” se espera que el número de contagios en cierta comuna afecte los de sus vecinos, por lo que un modelo que incluye la variable dependiente rezagada espacialmente en su especificación parece más apropiado (SAR). Ahora, para el caso de los modelos espacio-temporales, ante la inmensidad de modelos que se pueden ajustar, la selección de uno de ellos se hará mediante las pruebas del Multiplicador de Lagrange (LM).

Los criterios, además de todos los cálculos y estimaciones de este proyecto, serán desarrollados en el software R (R Core Team, 2013).

¹⁰Para más información de dichas combinaciones revisar punto 5.3.3

¹¹En el caso de la “estadística espacial” solo hace falta hacer el test I de Moran, mientras que en el área “espacio-temporal” se deben hacer los dos.

5. Aplicación

5.1. Periodos de estudio por comuna

Como la evolución de la pandemia varía para cada comuna de la Región Metropolitana, fue necesario establecer una metodología objetiva que permita definir periodos de estudio en cada una de ellas. Se determinó, que dichos periodos se calcularían en base a las “olas” del COVID-19, sin embargo, pese a la popularidad que ha ganado este concepto al momento de estudiar y comunicar el avance de la pandemia, no existe una definición ni método establecido para la identificación de estas.

Ante tal problemática, como Data Salud USACH se desarrollo y publicó “Identification of COVID-19 Waves: Considerations for Research and Policy” (Ayala, et al. 2021) en el cual se propone una estrategia para la detección de olas del COVID-19.

A continuación, se resume dicha estrategia de detección basada en las tasas de incidencia acumuladas semanalmente, calculadas como:

$$\text{Incidencia Semanal} = \frac{\text{Casos confirmados semanales acumulados en la comuna}}{\text{Población Comuna}} * 100000$$

De esta manera, los inicios y términos de las olas en cada comuna fueron determinadas bajo los siguientes criterios:

- **Inicio ola:** Semana epidemiológica¹² que cumple con las siguientes condiciones.
 1. Posee una tasa de incidencia mayor de 70 casos confirmados por 100.000 habitantes.
 2. Crecimiento positivo de al menos una semana desde que superó el umbral de 70 casos confirmados por 100.000 habitantes.
- **Término ola:** Semana epidemiológica que cumple con las siguientes condiciones (después del inicio de una ola).
 1. Posee una tasa de incidencia menor de 70 casos confirmados por 100.000 habitantes.
 2. Disminución en la tasa de incidencia semanal de al menos dos semanas consecutivas.

El umbral de 70 casos por 100.000 habitantes se estableció siguiendo la estrategia de gobierno Plan Paso a Paso, en la cual una tasa de incidencia diaria sobre 10 casos por cada 100.000 personas (cuyo valor semanalmente se traduce en 70 casos por 100.000 habitantes) se consideraba crítica y, en consecuencia, provocaba avances en cuanto al rigor de las medidas tomadas.

¹²Semanas que comienzan el domingo y terminan en sábado.

A continuación, se presentan las olas determinadas bajo esta metodología para la comuna de Pudahuel (ver Figura 7).




Figura 7: Olas Pudahuel (hasta el 01-08-2021).

Fuente: Elaboración Propia

Así, podemos ver como esta metodología logra identificar dos olas para la comuna de Pudahuel, donde la primera inicia el 9 de mayo del 2020 (semana epidemiológica 19 del 2020) y finaliza el 1° de agosto del mismo año (semana epidemiológica 31 del 2020), mientras que la segunda inicia el 27 de diciembre del 2020 (semana epidemiológica 53 del 2020) y finaliza el 24 de julio del 2021 (semana epidemiológica 29 del 2021).

Este procedimiento se realizó para las 52 comunas de la Región Metropolitana, guardando el inicio y término de todas las olas identificadas, donde el periodo de estudio corresponderá a la segunda ola de cada una de ellas (periodos que pueden ser revisados en la sección 8.1 del anexo). La decisión de estudiar este segundo ciclo se basa en que es posible calcular más variables independientes, debido a la información disponible en estas fechas, además que el estudio previo ya abordó el periodo comprendido por la primera ola¹³.

¹³Esta metodología también se aplicó para el caso de la primera ola y al ajustar los modelos con esos nuevos periodos, los resultados principales de “COVID-19 incidence and mortality in the Metropolitan Region, Chile: time, space, and structural factors” (Villalobos, et al. 2021) se mantuvieron.

Como análisis adicional se presenta la Figura 8 que permite visualizar espacialmente la duración, en días, de la segunda ola. Donde se puede apreciar cierta asociación espacial positiva debido a que aquellas comunas más cercanas entre si tienden a tener largos de ola similares (por ejemplo, podemos ver que justo tres comunas del sector oriente tuvieron las olas de menor duración). Esto último se puede comprobar mediante el test I de Moran donde, bajo las especificaciones de la matriz de contigüidad que se verán en la sección 5.3.1, la variable “largo ola” resulta tener una autocorrelación espacial positiva y significativa, es decir, la duración de la ola no está distribuida aleatoriamente en la región (donde comunas cercanas tienden a tener largos de ola similares).




Figura 8: Largo 2da ola (en días).

Fuente: Elaboración Propia

5.2. Bases de datos

En esta sección se dará una breve descripción de todas las variables utilizadas en ese estudio. Es preciso señalar que como se estiman modelos espaciales y espacio-temporales se necesitará crear dos bases de datos para el correcto ajuste de cada modelo, así tendrán las mismas variables pero estructuradas de forma distinta.

5.2.1. Variables independientes

Se presentan las variables utilizadas para describir las características demográficas, de salud, socioeconómicas y relacionadas con las estrategias para prevenir el avance del COVID-19 que caracterizan a cada comuna¹⁴.

1. **Mujer***: Porcentaje de mujeres que viven en la comuna (CASEN 2017).
2. **Niños***: Porcentaje de niños menores de 6 años que viven en la comuna (CASEN 2017).
3. **Personas +65***: Porcentaje de personas sobre 65 años que viven en la comuna (CASEN 2017).
4. **Pesonas +80***: Porcentaje de personas sobre 80 años que viven en la comuna (CASEN 2017).
5. **Migrantes***: Porcentaje de personas que viven en la comuna que declara tener una nacionalidad extranjera y haber estado viviendo en otro país hace cinco años (CASEN 2017).
6. **Densidad poblacional***: Cociente entre la población de la comuna y su superficie en km^2 (SINIM 2019).
7. **Ruralidad***: Porcentaje de personas que viven en un territorio definido como rural en la comuna (SINIM 2019).
8. **Pobreza Multidimensional***: Porcentaje de personas clasificadas como pobres utilizando el índice de pobreza multidimensional, en cada comuna. Este índice mide las carencias por hogar en educación (escolarización (7,5 %), asistencia (7,5 %) y rezago (7,5 %)), salud (afiliación al seguro (7,5 %), desnutrición (7,5 %) y acceso a la atención (7,5 %)), trabajo y seguridad social (ocupación (7,5 %), seguridad social (7,5 %) y pensiones (7,5 %)), vivienda y medio ambiente (servicios básicos (7,5 %), situación de la vivienda y hacinamiento (7,5 %) y medio ambiente (7,5 %)) y redes y cohesión social (apoyo social percibido y participación (3,33 %), igualdad de trato (3,33 %) y seguridad (3,33 %)) en la comuna (CASEN 2017).
9. **Pobreza de ingresos***: Porcentaje de personas que no pueden satisfacer sus necesidades básicas, estimado a partir de una canasta de alimentos en la comuna (CASEN 2017).
10. **Sin hacinamiento***: Porcentaje de personas que declaran vivir en un hogar con menos de 2,5 personas por dormitorio de uso exclusivo en la comuna (CASEN 2017).
11. **Hacinamiento crítico***: Porcentaje de personas que declaran vivir en un hogar con 5 o más personas por dormitorio de uso exclusivo, más hogares sin dormitorios de uso exclusivo en la comuna (CASEN 2017).
12. **Años de educación***: Promedio de años de escolarización de la población de 15 años o más en la comuna (CASEN 2017).

¹⁴Las variables marcadas con un asterisco y sus descripciones corresponden a las presentadas en el artículo del estudio previo (Villalobos, et al. 2021).

13. **Trabajo por cuenta propia***: Porcentaje de personas que declaran su situación laboral como trabajador autónomo en la comuna (CASEN 2017).
14. **Espacios verdes***: Cociente de superficie verde (m^2) por persona que vive en la comuna (SIEDU).
15. **Uso de transporte público***: Porcentaje de personas en la comuna que declara utilizar el transporte público regularmente (CASEN 2017).
16. **Disponibilidad de agua***: Porcentaje de personas que declaran tener agua potable en casa en cada comuna (CASEN 2017).
17. **Seguro de salud público***: Porcentaje de la población que está cubierta por un seguro médico (público, privado o de las fuerzas armadas) en la comuna (CASEN 2017).
18. **Dificultad para obtener atención médica***: Porcentaje de personas que afirma haber tenido problemas para obtener atención médica (por alguna de las siguientes razones: no tenía tiempo, no tenía dinero, es demasiado caro, pidió pero no consiguió una cita con el médico, o consiguió una cita pero más a tiempo), en los últimos tres meses en la comuna (CASEN 2017).
19. **Distancia al centro de salud***: Porcentaje de personas en la comuna que declara vivir a una distancia inferior a 2,5 kilómetros de un centro de salud (CASEN 2017).
20. **Factores de riesgo de COVID-19***: Porcentaje de la población que declara haber estado en tratamiento médico durante los últimos doce meses por hipertensión arterial, diabetes, infarto agudo de miocardio, enfermedad pulmonar obstructiva crónica, asma bronquial moderada o grave o insuficiencia renal crónica terminal en la comuna (CASEN 2017) .
21. **Días en cuarentena**: Total de días que la comuna estuvo en cuarentena durante el periodo de estudio (MinCiencia 2021).
22. **Movilidad promedio (semana)**: Promedio comunal de las variaciones de movilidad en los días de semana (lunes-viernes) tomando como referencia las dos primeras semanas de marzo 2020 (MinCiencia 2021).
23. **Movilidad promedio (fin de semana)**: Promedio comunal de las variaciones de movilidad pero sólo considerando los fines de semana (sábado y domingo) (MinCiencia 2021).
24. **Vacunación 1° dosis**: Porcentaje de vacunación con primera dosis durante el periodo de estudio en la comuna (MinCiencia, 2021).
25. **Vacunación 2° dosis**: Porcentaje de vacunación con segunda dosis durante el periodo de estudio en la comuna (MinCiencia, 2021).

26. **Oportunidad en la notificación:** Promedio comunal de las proporciones de casos nuevos confirmados por laboratorio, que fueron notificados en la primera consulta o contacto con salud (es decir, antes del proceso de la toma de muestra) durante el periodo de estudio (MinCiencia 2021).

Es preciso señalar que las últimas seis variables se calcularon de formas distintas según la base que se estuviera construyendo. Se calculó un sólo valor por comuna (que resumiera la información de la segunda ola) para el caso de los datos de corte transversal, mientras que para los datos de panel espaciales, las variables fueron calculadas por semana epidemiológica.

5.2.2. Variables dependientes

En esta sección se presentan las variables dependientes que serán utilizadas en los modelos, donde se buscará estudiar variables tanto para casos como defunciones por COVID-19.

Variables dependientes para modelos espaciales

1. **Tasa de incidencia acumulada de casos:** Número de casos confirmados de COVID-19 (acumulados durante la segunda ola) por cada 100.000 habitantes en cada comuna.

$$T_C = \frac{\text{Casos confirmados de COVID-19 (acumulados)}}{\text{Población Comuna}} * 100000$$

2. **Tasa de incidencia acumulada de defunciones:** Número de defunciones por COVID-19 (acumuladas durante la segunda ola) por cada 100.000 habitantes en cada comuna.

$$T_D = \frac{\text{Defunciones por COVID-19 (acumuladas)}}{\text{Población Comuna}} * 100000$$

3. **Tasa de incidencia acumulada de casos (ajustada):** Modificación de la “tasa de incidencia acumulada de casos” en la cual se divide por el largo de la segunda ola en cada comuna.

$$T_C(\text{Ajustada}) = \frac{T_C}{\text{Largo segunda ola (en días)}}$$

4. **Tasa de incidencia acumulada de defunciones (ajustada):** Modificación de la “tasa de incidencia acumulada de defunciones” en la cual se divide por el largo de la segunda ola en cada comuna.

$$T_D(\text{Ajustada}) = \frac{T_D}{\text{Largo segunda ola (en días)}}$$

Las dos últimas variables, además de medir la severidad, permiten agregar la dimensión del tiempo en su cálculo (ajustando por la duración de cada ola). De esta manera, si se posee dos comunas con la misma tasa de incidencia acumulada de casos/defunciones, pero una alcanzó dicho valor en 100 días y la otra en tan sólo 50 días, las podremos diferenciar (donde claramente el comportamiento de la segunda comuna fue más extremo).

Variables dependientes para modelos espacio-temporales

Las variables dependientes de estos modelos corresponden a las tasas de incidencia acumulada semanalmente de casos y defunciones, donde la primera de estas es la misma utilizada para la determinación de olas.

1. **Tasa de incidencia semanal de casos:** Número de casos confirmados de COVID-19 (acumulados por semana epidemiológica) por cada 100.000 habitantes en cada comuna.

$$\text{Incidencia semanal (casos)} = \frac{\text{Casos confirmados acumulados semanalmente}}{\text{Población Comuna}} * 100000$$

2. **Tasa de incidencia semanal de defunciones:** Número de defunciones por COVID-19 (acumuladas por semana epidemiológica) por cada 100.000 habitantes en cada comuna.

$$\text{Incidencia semanal (defunciones)} = \frac{\text{Defunciones acumuladas semanalmente}}{\text{Población Comuna}} * 100000$$

Calculadas todas las variables descritas en esta sección, se obtendrán las dos bases necesarias para el análisis. Donde la primera corresponde a la base de datos transversal (Figura 9) la cual resume dichas variables por comuna en un sólo instante de tiempo, correspondiente a su segunda ola, y permitirá realizar la estimación de los modelos espaciales. Mientras que la segunda base corresponde a el panel espacial (Figura 10) que incorpora una dimensión temporal a su estructura (debido a que las variables son calculadas por semana epidemiológica) y será utilizada para estimar los modelos espacio temporales. Para esta última base, las semanas estudiadas por comuna se restringen a la segunda ola nacional (entre semana epidemiológica 52 del 2020 y semana epidemiológica 30 del 2021) obteniendo un panel balanceado (ya que los modelos espacio temporales en R solo aceptan este tipo de panel hasta el momento).

	Comuna	Largo 2da ola	Tasa casos ajustada	Tasa casos	Tasa defunciones ajustada	Tasa defunciones	prom_mov_semana	prom_mov_fin_semana
1	Santiago	195	24.68667	4813.901	0.3292100	64.19595	0.8048330	0.8404697
2	Cerrillos	188	26.13652	4913.665	0.6218709	116.91173	0.8251309	0.8301304
3	Cerro Navia	209	32.82599	6860.632	0.9672484	202.15492	0.8174657	0.8260691
4	Conchalí	174	26.86218	4674.018	0.9124717	158.77007	0.7998794	0.8388370
5	El Bosque	209	36.13553	7552.326	0.7510849	156.97674	0.8857487	0.9194118
6	Estación Central	181	26.54334	4804.344	0.4755626	86.07683	0.8762789	0.8991299
7	Huechuraba	153	25.96304	3972.345	0.8073517	123.52481	0.6615623	0.6701414
8	Independencia	160	26.80991	4289.586	0.6335128	101.36205	0.8850351	0.8938716
9	La Cisterna	167	32.95279	5503.116	0.9658680	161.29996	0.8768730	0.8999085
10	La Florida	202	30.47552	6156.056	0.6519750	131.69894	0.7984754	0.8173547
11	La Granja	195	34.86813	6799.285	0.8494216	165.63721	0.8862120	0.8908797
12	La Pintana	209	34.03754	7113.846	0.6974802	145.77336	0.9177749	0.9374779

Figura 9: Extracto base de datos 1 (datos transversales).

Fuente: Elaboración propia

	txt_comuna	semana_epi	Tasa_casos_semana	tasa_def_semana	var_salidas_sem	var_salidas_fds	prom_opor_noti_sem	mujer
39	Santiago	202139	53.06600	0.1987491	0.8868388	0.9839521	116.4285714	0.5010623
40	Santiago	202140	54.65600	0.3974981	0.8994774	0.9916979	120.7142857	0.5010623
41	Santiago	202141	83.67336	0.1987491	0.8845541	0.9766297	299.7142857	0.5010623
42	Santiago	202142	128.98815	0.1987491	0.8709335	0.9814426	481.1428571	0.5010623
43	Santiago	202143	138.72685	0.1987491	0.8941425	0.9356341	497.0000000	0.5010623
44	Cerrillos	202052	39.34529	2.2483025	0.8481559	0.8462863	0.0000000	0.5400332
45	Cerrillos	202053	43.84190	1.1241513	0.8377433	0.8665409	0.0000000	0.5400332
46	Cerrillos	202101	59.58002	4.4966051	0.8579373	0.8192583	0.0000000	0.5400332
47	Cerrillos	202102	79.81474	2.2483025	0.8521502	0.7946191	0.0000000	0.5400332

Figura 10: Extracto base de datos 2 (datos de panel espaciales).

Fuente: Elaboración propia

5.3. Estudio Espacial

En esta sección se llevará a cabo todo lo relacionado con la estadística espacial.

5.3.1. Determinación Matriz de Contigüidad

Para la creación de la matriz W se considerará el criterio de vecindad por contigüidad de tipo Reina de primer orden, es decir, serán vecinas aquellas comunas que compartan alguna frontera. Puesto que las comunas están irregularmente espaciadas, utilizar una contigüidad de tipo torre o alfil carece de sentido y fueron descartadas. De igual manera, un criterio basado en distancias fue descartado debido a la gran heterogeneidad en los tamaños de las comunas. A continuación, se presentan las relaciones de vecindad para las comunas de la Región Metropolitana, donde cada línea representa una vecindad (ver Figura 11).




Figura 11: Región Metropolitana con relaciones de vecindad.

Fuente: Elaboración propia

Calculada la matriz W , que esta estandarizada por filas, se puede observar que en promedio las comunas de la Región Metropolitana poseen cinco vecinos, donde la comuna con más vecinos corresponde a San Bernardo (doce vecinos) y las comunas con menos vecinos son San Pedro, Tiltill y María Pinto (con 2 vecinos cada una).

5.3.2. Análisis Descriptivo base de datos transversal

5.3.2.1 Estadísticas descriptivas y correlación espacial

La Tabla 3 muestra las estadísticas descriptivas de las variables pertenecientes a la base de corte transversal.

Variable	Media	Desv. Estándar	Máximo	Mínimo	I de Moran
Inci. acum. (casos)	5355.779	1385.366	8360.74	2349.805	0.425
Inci. acum. (defunciones)	117.486	42.374	225.274	37.2	0.326
Inci. acum. ajus. (casos)	30.013	5.257	40.62	17.802	0.253
Inci. acum. ajus. (defunciones)	0.665	0.235	1.472	0.282	0.119
Mujer	0.521	0.022	0.561	0.464	0.000
Niños	0.065	0.012	0.089	0.043	-0.036
Mayores 65	0.133	0.036	0.225	0.058	0.245
Mayores 80	0.028	0.014	0.068	0.002	0.064
Migrantes	0.032	0.063	0.376	0	0.263
Densidad poblacional	6165.658	6152.605	22870.32	3.73	0.644
Ruralidad	0.123	0.212	1	0	0.485
Pobreza multidimensional	0.219	0.079	0.375	0.034	0.318
Pobreza ingresos	0.058	0.028	0.141	0.001	0.255
Sin hacinamiento	0.885	0.048	0.977	0.781	0.255
Hacinamiento crítico	0.012	0.013	0.052	0	0.141
Años de educación	9.626	1.495	14.05	7.995	0.485
Trabajo por cuenta propia	0.102	0.021	0.15	0.047	0.044
Áreas verdes	5.883	4.139	18.67	1.55	0.317
Uso transporte público	0.207	0.072	0.414	0.047	0.487
Disponibilidad agua	0.98	0.018	1	0.922	0.025
Seguro de salud público	0.749	0.178	0.988	0.133	0.479
Dificultad atención médica	0.001	0.002	0.01	0	0.016
Distancia centro salud	0.88	0.129	0.993	0.448	0.293
Factor riesgo COVID-19	0.161	0.034	0.243	0.073	0.242
Días cuarentena	84.654	16.712	98	50	0.367
Mov. promedio (semana)	0.799	0.103	0.942	0.42	0.352
Mov. promedio (fin de semana)	0.805	0.12	0.986	0.335	0.405
Porcentaje 1° dosis	0.615	0.113	0.908	0.433	0.028
Porcentaje 2° dosis	0.607	0.137	1	0.412	0.338
Opor. notificación	524.917	442.088	1957.489	31.792	0.173

Tabla 3: Estadísticas descriptivas datos de corte transversal.


En la tabla se presentan en negrita aquellos estadísticos I Moran globales que poseen un p-valor menor a una significancia de un 5 %, pudiendo verificar la ausencia o existencia de autocorrelación espacial global en las distintas variables testeadas. Así, se observa que para las cuatro variables dependientes (indicadores del COVID-19) y para diecinueve de las veintiséis variables independientes (factores sociales, demográficos, y de salud) dicha autocorrelación es significativa y positiva, mostrando que estas variables tienden a agruparse espacialmente y que se posee valores similares en unidades geográficas más cercanas.

Por otra parte, si se analizan las otras estadísticas descriptivas (media, desviación estándar, mínimo y máximo) se observa que las variables no se distribuyen de forma uniforme en la región (heterogeneidad). De todas maneras, esto se esperaba pues, como fue mencionado previamente, es sabido que los habitantes de la región tienden a agruparse según ciertas características socioeconómicas y demográficas.


Como se verificó la existencia de autocorrelación espacial global en la mayoría de las variables, en la Figura 12 y 13 se presentan las distribuciones espaciales para las cuatro variables dependientes y dos independientes respectivamente (las cuales son graficadas según los quintiles de cada variable). Donde se puede observar que todas las variables dependientes (indicadores del COVID-19) siguen cierto comportamiento, pudiendo distinguir grupos de comunas vecinas que poseen valores similares. Por ejemplo (ver figura 12) en las cuatro variables de interés, las comunas del sector oriente fueron siempre las menos afectadas (ya que se muestran en colores más claros). También es preciso señalar, que el comportamiento que tenían las tasas de incidencia acumuladas es similar al que se posee después de ajustarlas por el tamaño de la ola.

De igual forma, si analizamos las variables “áreas verdes” y “densidad poblacional” (ver figura 13) veremos que se forman ciertos grupos de comunas vecinas que poseen valores similares. En la primera de figura, nuevamente se observa que las comunas del sector oriente se diferencian de las demás, ya que poseen más áreas verdes. En la segunda vemos como las comunas al centro de la región son las que tienen una mayor densidad (lo cual se asemeja mucho a la Figura 3.1.2.2 que ejemplificaba la autocorrelación positiva)¹⁵.


¹⁵En este caso se mostraron tan sólo dos variables independientes. Los gráficos de las demás variables se pueden encontrar en el anexo (ver sección 8.2)




(a) Incidenia acumulada (casos)



(b) Incidenia acumulada (defunciones)



(c) Incidenia acumulada ajus. (casos)



(d) Incidenia acumulada ajus. (defunciones)

Figura 12: Distribución espacial de variables dependientes.

Fuente: Elaboración propia




Figura 13: Distribución espacial de variables independientes.

Fuente: Elaboración propia

Más allá de visualizar el comportamiento espacial de las variables, es posible querer saber dónde se encuentra la correlación espacial detectada. De esta manera, se procede a calcular el índice I de Morán local en cada comuna de la Región Metropolitana, donde índices significativos permitirán encontrar la ubicación de dicha correlación.

A continuación, se presenta como ejemplo los índices locales que resultaron ser significativos para las cuatro variables dependientes (gráficos a la izquierda de la Figura 14 y 15), donde un índice con signo positivo indicará que dicha unidad espacial está rodeada por otras con valores similares en la variable (y un signo negativo lo contrario).

Además, es posible agrupar a las comunas que resultaron tener un I de Morán local significativo según el comportamiento de la variable en dicha comuna con respecto a sus vecinas (gráficos a la derecha de la Figura 14 y 15), pudiendo encontrar cuatro grupos: “high-high”/“low-low” los que hacen referencia a que en esa comuna junto con sus vecinas posee valores altos/bajos en la variable, mientras que “low-high”/“high-low” aluden a una comuna con un valor bajo/alto en la variable y que es rodeada por comunas con valores altos/bajos.¹⁶

¹⁶En este caso se mostró únicamente los gráficos para las variables dependientes, para ver el gráfico de las demás variables visitar el punto 8.3 del anexo.




Figura 14: I de Moran Local para variables dependiente de casos.

Fuente: Elaboración propia




Figura 15: I de Moran Local para variables dependiente de defunciones.

Fuente: Elaboración propia

La autocorrelación espacial local es complementaria en el análisis de este proyecto, ya que principalmente nos importara saber si hay o no autocorrelación espacial en las variables. Sin embargo, es bueno tenerla en consideración ya que permitirá entender a mayor profundidad el comportamiento espacial de cada una de ellas.

5.3.2.2 Relaciones entre variables

En esta sección se estudiarán y describirán brevemente relaciones entre variables que deberán ser consideradas al momento de ajustar los futuros modelos.

1. **Movilidades y Vacunaciones:** Encontramos que los pares de variables relacionados a Movilidad (semana y fin de semana) y vacunación (primera y segunda dosis) poseen una alta correlación de Pearson.

- $\rho(\text{Mov. semana; Mov. fin de semana})=0.949$
- $\rho(\text{Porcentaje 1° dosis; Porcentaje 2° dosis})=0.803$

De esta manera, incluir ambas variables en los futuros modelos conduciría a problemas de multicolinealidad, por lo que se decidió (para la sección de estudio espacial) tan solo trabajar con “Mov. promedio semana” y “Porcentaje 2° dosis” ya que estas poseen una mayor correlación con las variables dependientes¹⁷. Además, es importante considerar que, para el caso de movilidad, aquella variable que considera los días de semana entrega mayor información que la que tan solo considera el fin de semana, y para el caso de vacunación, dos dosis representan un esquema “completo” lo que puede ser más relevante al momento de analizar estas nuevas variables.


2. **Días cuarentena y Tasa de casos acumulada:** Es importante tener en cuenta la relación de ambas variables, donde se sabe que las cuarentenas son definidas principalmente en base a los casos de COVID-19. Así, incluir la variable “Días cuarentena” conducirá a problemas de endogeneidad en el modelo. Algunas opciones para lidiar con este problema son, rezagar las variables independientes involucradas o, en un caso más extremo, no considerarlas al momento de ajustar el modelo.

En el presente análisis, debido a que no existe la dimensión temporal, se rezago la variable “días de cuarentena” calculándola en el periodo de transición (previo a la segunda ola), sin embargo, esto no logro solucionar dicho problema y se tuvo que excluir del análisis.


3. **Análisis de correlaciones:** En las Figuras 16a y 16b son presentadas las correlaciones de algunas variables con las variables dependientes de casos y defunciones respectivamente. A continuación, son mencionadas algunas que se deben de tener presente.

- La variable de movilidad y oportunidad en la notificación poseen una correlación positiva con ambos grupos de variables dependientes (donde esta última correlación es contraintuitiva). Lo mismo pasa con la variable de vacunación, pero de forma negativa.
- Se posee una gran correlación entre grupos de variables dependientes. De esta manera, desde un punto de vista estadístico, será imprescindible utilizar en los modelos de defunciones una variable explicativa los casos.

¹⁷Para ver las distintas correlaciones entre variables dirigirse al punto 8.4 de Anexo.



(a) Extracto matriz de correlaciones (con variables de casos).



(b) Extracto matriz de correlaciones (con variables de defunciones).

5.3.3. Modelos

En esta sección se llevarán a cabo múltiples modelos que permitan determinar qué variables demográficas, de salud y socioeconómicas son significativas al momento de explicar los indicadores del COVID-19 (desde una perspectiva espacial). Donde los modelos ajustados serán divididos en un grupo denominado “defunciones” y otro llamado “casos”, según las variables dependientes a estudiar.

Como fue visto en el punto 3.1.6 del marco teórico, en ambos grupos de modelos se iniciará por ajustar los más simples (OLS) para luego examinar, mediante el análisis de residuos, si es necesario incorporar algún efecto de interacción espacial. De esta manera, en la Tabla 4 y 5 se resumen los modelos de regresión lineal “completos” (modelos iniciales) para las variables de casos y defunciones respectivamente.

Tener en consideración que para cada variable dependiente de estos modelos “completos” se proponen distintas combinaciones de variables independientes, donde en algunos se ocupará la pobreza multidimensional (índice que considera múltiples factores) y en otros un conjunto de variables socioeconómicas en su lugar. Además, para los modelos de defunciones se considerará otra variación, donde en algunos de los modelos se incorpora como variable independiente la variable “incidencias de casos acumulada ajustada” (también se probó la variable “incidencias de casos acumulada”, pero en general presentaba peor performance).

Asimismo, debido a las relaciones entre variables presentadas en la sección 5.3.2.2, es importante recalcar que tres variables independientes fueron descartadas al momento de ajustar estos modelos. Donde las variables “movilidad promedio (fin de semana)” y “porcentaje 1° dosis” fueron eliminadas por multicolinealidad y la variable “días en cuarentena” por endogeneidad. Para este último caso, se intentó rezagar la variable para un periodo previo a la segunda ola (periodo de transición), sin embargo, esto no tuvo efecto y fue necesario excluirla.

Tabla 4: OLS completos para modelos de casos.

	<i>Modelos de Casos</i>			
	Incid. acumulada		Incid. acumulada ajustada	
	(1)	(2)	(3)	(4)
Mujer	4.649 (7.936)	8.194 (8.091)	−0.005 (0.030)	0.021 (0.029)
Niños	−14.926 (14.918)	−23.780 (16.703)	−0.062 (0.056)	−0.089 (0.060)
Mayores 65	6.321 (7.287)	2.570 (7.516)	0.073** (0.027)	0.065** (0.027)
Mayores 80	−11.715 (14.589)	−2.885 (15.040)	−0.003 (0.054)	−0.017 (0.054)
Migrantes	−6.956* (3.877)	−6.407 (4.586)	−0.015 (0.014)	0.004 (0.017)
Densidad	0.00001 (0.00005)	0.00004 (0.00005)	−0.00000 (0.00000)	−0.00000 (0.00000)
Ruralidad	2.337 (1.745)	0.403 (2.246)	0.007 (0.006)	−0.007 (0.008)
Pobreza multidimensional	5.026 (2.985)		0.007 (0.011)	
Pobreza ingresos		0.005 (0.008)		−0.00001 (0.00003)
Sin hacinamiento		1.533 (5.555)		−0.0004 (0.020)

Continúa la tabla...

Hacinamiento crítico		11.169 (16.681)		−0.090 (0.060)
Años de educación		−0.371 (0.371)		−0.002 (0.001)
Trabajo por cuenta propia		−10.638 (8.800)		−0.049 (0.032)
Áreas verdes	−0.108** (0.047)	−0.103** (0.047)	−0.0002 (0.0002)	−0.0003 (0.0002)
Transporte público	3.670 (4.875)	0.974 (5.250)	0.017 (0.018)	0.010 (0.019)
Disponibilidad agua	15.545 (10.177)	19.375* (10.544)	0.031 (0.038)	0.030 (0.038)
Seguro salud público		1.303 (3.100)		0.004 (0.011)
Dificultad atención médica	81.160 (96.796)	165.546 (104.506)	−0.477 (0.360)	0.074 (0.378)
Distancia centro salud	2.399 (1.929)	1.077 (2.198)	0.003 (0.007)	−0.007 (0.008)
Factor riesgo COVID	−9.430 (8.643)	−10.339 (8.803)	−0.060* (0.032)	−0.048 (0.032)
Mov. prom. semana	2,312.399 (1,762.579)	2,524.625 (2,018.065)	12.919* (6.560)	8.156 (7.301)
Opor. notificación	82.583* (40.645)	69.686* (38.734)	0.499*** (0.151)	0.401*** (0.140)
Porcentaje 2° dosis	−0.602 (1.904)	1.607 (2.185)	−0.013* (0.007)	−0.001 (0.008)
Constante	−22,863.660* (12,416.880)	−23,139.880 (15,270.030)	−45.857 (46.215)	−17.057 (55.242)
R ²	0.664	0.742	0.676	0.766
R ² ajustado	0.495	0.547	0.515	0.588
I de Moran (residuos)	0.0472	0.123**	−0.142	−0.166

Nota:

*p<0.1; **p<0.05; ***p<0.01

Tabla 5: OLS completos para modelos de defunciones.

	<i>Modelos de Defunciones:</i>							
	Incid. acumulada				Incid. acumulada ajustada			
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Mujer	-0.489** (0.214)	-0.479** (0.209)	-0.413* (0.234)	-0.466* (0.228)	-0.004** (0.002)	-0.004** (0.001)	-0.003** (0.002)	-0.004** (0.002)
Niños	-0.642 (0.402)	-0.519 (0.400)	-0.901* (0.483)	-0.676 (0.483)	-0.003 (0.003)	-0.002 (0.003)	-0.003 (0.003)	-0.002 (0.003)
Mayores 65	0.107 (0.197)	-0.037 (0.212)	0.144 (0.217)	-0.022 (0.230)	0.001 (0.001)	0.0002 (0.001)	0.002 (0.001)	0.001 (0.002)
Mayores 80	-0.129 (0.393)	-0.122 (0.384)	-0.094 (0.435)	-0.050 (0.421)	0.001 (0.003)	0.001 (0.003)	-0.0004 (0.003)	-0.0001 (0.003)
Migrantes	-0.221** (0.105)	-0.192* (0.104)	-0.278** (0.133)	-0.288** (0.128)	-0.001 (0.001)	-0.001 (0.001)	-0.001 (0.001)	-0.001 (0.001)
Densidad	0.00000 (0.00000)	2.250e-06* (0.00000)	2.920e-06** (0.00000)	3.213e-06** (0.00000)	0.000 (0.000)	0.000 (0.000)	0.000 (0.000)	0.000 (0.000)
Ruralidad	-0.030 (0.047)	-0.044 (0.047)	0.007 (0.065)	0.026 (0.064)	-0.0002 (0.0003)	-0.0003 (0.0003)	-0.0001 (0.0004)	0.00005 (0.0004)
Pobreza multidimensional	0.219** (0.081)	0.204** (0.079)			0.001 (0.001)	0.001 (0.001)		
Pobreza ingresos			-0.0003 (0.0002)	-0.0003 (0.0002)			-0.00000 (0.00000)	-0.00000 (0.00000)
Sin hacinamiento			-0.115 (0.161)	-0.114 (0.155)			-0.001 (0.001)	-0.001 (0.001)
Hacinamiento crítico			0.211 (0.483)	0.440 (0.483)			-0.003 (0.003)	-0.001 (0.003)
Años de educación			-0.005 (0.011)	0.0001 (0.011)			0.00001 (0.0001)	0.00004 (0.0001)
Trabajo por cuenta propia			0.443* (0.255)	0.568** (0.256)			0.003 (0.002)	0.004** (0.002)
Áreas verdes	-0.002 (0.001)	-0.001 (0.001)	-0.002* (0.001)	-0.002 (0.001)	-0.00000 (0.00001)	0.00000 (0.00001)	-0.00000 (0.00001)	0.00000 (0.00001)
Transporte público	0.292** (0.131)	0.259* (0.130)	0.226 (0.152)	0.200 (0.147)	0.002* (0.001)	0.002* (0.001)	0.002 (0.001)	0.001 (0.001)
Disponibilidad agua	-0.464 (0.274)	-0.524* (0.271)	-0.279 (0.305)	-0.354 (0.297)	-0.004* (0.002)	-0.004** (0.002)	-0.003 (0.002)	-0.004* (0.002)
Seguro salud público			0.089 (0.090)	0.078 (0.087)			0.001 (0.001)	0.001 (0.001)
Dificultad atención médica	0.266 (2.610)	1.207 (2.614)	-0.746 (3.024)	-0.934 (2.920)	-0.022 (0.018)	-0.015 (0.018)	-0.028 (0.021)	-0.029 (0.020)
Distancia centro salud	-0.022 (0.052)	-0.028 (0.051)	-0.012 (0.064)	0.006 (0.062)	-0.0003 (0.0004)	-0.0003 (0.0004)	-0.0003 (0.0004)	-0.0002 (0.0004)

Continúa la tabla...

Factor riesgo COVID	0.215 (0.233)	0.332 (0.239)	0.030 (0.255)	0.151 (0.255)	0.002 (0.002)	0.002 (0.002)	0.001 (0.002)	0.002 (0.002)
Incid. acumulada ajus. casos		1.974 (1.214)		2.544* (1.433)		0.015* (0.008)		0.020** (0.010)
Mov. prom. semana	45.937 (47.532)	20.430 (48.997)	64.680 (58.401)	43.932 (57.549)	0.244 (0.334)	0.056 (0.343)	0.168 (0.401)	0.006 (0.389)
Opor notificación	1.166 (1.096)	0.182 (1.230)	1.130 (1.121)	0.110 (1.225)	0.009 (0.008)	0.002 (0.009)	0.008 (0.008)	0.0002 (0.008)
Porcentaje 2° dosis	0.105** (0.051)	0.131** (0.053)	0.108* (0.063)	0.110* (0.061)	0.0005 (0.0004)	0.001* (0.0004)	0.0004 (0.0004)	0.0004 (0.0004)
Constante	536.905 (334.848)	627.441* (331.723)	444.127 (441.899)	487.517 (427.075)	4.557* (2.354)	5.223** (2.323)	4.496 (3.038)	4.835 (2.888)
R ²	0.738	0.758	0.769	0.793	0.581	0.615	0.646	0.692
R ² ajustado	0.608	0.626	0.594	0.622	0.371	0.405	0.378	0.439
I de Moran (residuos)	-0.002	0.012	0.036	0.040	-0.030	-0.012	-0.035	-0.01
<i>Nota:</i>					*p<0.1; **p<0.05; ***p<0.01			

Al examinar los modelos completos de casos (ver Tabla 4), se aprecia que todos logran explicar cerca de un 50 % de la variación de las variables dependientes (donde aquellos modelos que no utilizan pobreza multidimensional poseen un mejor ajuste) presentando cada uno un distinto subconjunto de variables significativas. Respecto a los coeficientes de dichas variables significativas, tanto la asociación positiva encontrada entre disponibilidad de agua e incidencia acumulada de casos (en el modelo 2) como la asociación positiva entre oportunidad de notificación y las variables dependientes de casos (en los cuatro modelos) son resultados contraintuitivos. Una explicación para el coeficiente de “disponibilidad de agua” podría ser que precisamente aquellas comunas que poseen una mayor urbanización y población (por ende mayor número de casos) son las que poseen a su vez un mayor porcentaje de agua potable (aunque es una hipótesis poco probable ya que el modelo está controlando tanto por ruralidad como densidad) o, otra opción, es que se trate de un resultado sesgado, ya que justo esta asociación es encontrada en aquel modelo que presenta correlación espacial en sus errores. En cuanto a los coeficientes positivos en “oportunidad de notificación” puede tratarse de un problema de endogeneidad, ya que para un periodo con mayor cantidad de casos es natural tener un mayor número de oportunidades en la notificación¹⁸

Los demás coeficientes significativos presentaron un comportamiento igual al esperado, donde el porcentaje de migrantes y áreas verdes muestran una asociación significativa y negativa con la incidencia acumulada (resultado que también se visualizó en modelos del estudio de antiguo (Villalobos, 2021)). Mientras que para la variable dependiente incidencia acumulada de casos ajustada se encontró una asociación positiva con los mayores de 65 y la movilidad semanal; y una asociación negativa con las variables factor riesgo COVID-19 y Porcentaje 2° dosis (personas con esquema completo de vacunación).

¹⁸Bajo esta hipótesis, esta variable se rezago y se ajusto nuevamente los modelos, sin embargo, se presento el mismo comportamiento.

Ahora, al analizar la bondad de ajuste de los modelos completos de defunciones (Tabla 5) se estará frente a dos escenarios. Por un lado, los modelos que estudian las tasas de incidencia acumulada poseen valores del orden de un 60 %, y por el otro, el mayor R^2_{ajus} que se tiene es aproximadamente de un 44 % (aunque coinciden en que ninguno posee errores autocorrelacionados espacialmente).

Si se examinan las variables que presentaron coeficientes significativos de estos modelos (defunciones) se puede observar que son distintas a las analizadas previamente (modelos de casos) pudiendo deducir que los determinantes para los casos y defunciones difieren entre si (habiendo excepciones como la variable migrantes, la cual presentó una asociación significativa y negativa tanto para casos como de defunciones).

Enfocándonos nuevamente en los modelos de la Tabla 5, podemos ver que muchas de las variables resultaron ser significativas para ambas variables dependientes, además de exhibir la misma asociación (signo). Donde “disponibilidad agua” y “mujer” presentaron una asociación negativa (destacando la variable mujer que fue significativa en los ocho modelos) y las variables “trabajo por cuenta propia”, “uso de transporte público”, “Incid. acumulada ajus. casos” y “porcentaje 2° dosis” una asociación positiva. De todos estos resultados, el último (porcentaje 2° dosis) es el único contraintuitivo, sin embargo, esto se puede deber a como fue llevado el proceso de vacunación en Chile, donde las dosis fueron suministradas iniciando por los adultos mayores (grupo de la población que más fallece)¹⁹.

Además, se puede observar que los modelos asociados a la variable “Incid. acumulada (defunciones)” poseen más variables independientes significativas que los modelos con la variable dependiente ajustada. Donde, las variables “densidad” y “pobreza multidimensional” resultan tener una asociación positiva; mientras que las variables “migrantes”, “áreas verdes” y “niños” una asociación negativa.

Ya analizados los modelos completos se procede a encontrar el subconjunto de variables independientes que entreguen el mejor ajuste para describir las variable respuesta. Esto se hará ya que “algunos problemas potenciales con la inferencia están relacionados con los grados de libertad debido al gran número de variables explicativas y la muestra relativamente pequeña ($n=52$), así como la existencia de multicolinealidad entre las variables” (Villalobos, 2021). De esta manera, será efectuada una simplificación que consta de dos partes, primero se hará selección de variables mediante el criterio AIC a cada modelo (utilizando la estrategia de selección stepwise) para luego analizar si es necesario quitar alguna otra variable que este presentando coeficientes contraintuitivos (solo si es estrictamente necesario²⁰). El resultado de dichos modelos simplificados se presenta en las tablas 6 y 7.

¹⁹Al igual que para otras variables, se ajusto los modelos con la variable de vacunación rezagada, sin embargo, se obtuvo el mismo comportamiento.

²⁰Luego de varios intentos, se decidió que para los modelos simplificados de casos se excluiría la variable “oportunidad en la notificación” y para los de defunciones “porcentaje de la 2° dosis” (esto obviamente previo al ajuste).

Tabla 6: OLS simplificados para modelos de casos.

	<i>Modelos de Casos simplificados</i>			
	Incid. acumulada		Incid. acumulada ajustada	
	(1)	(2)	(3)	(4)
Mujer		13.194** (6.488)		
Niños		-25.653* (13.637)	-0.028 (0.058)	-0.081 (0.054)
Mayores 65			0.067** (0.028)	0.056** (0.022)
Migrantes	-6.537** (2.661)	-5.390* (3.012)		
Densidad		0.0001** (0.00003)	-0.00000 (0.00000)	
Ruralidad				-0.013** (0.005)
Pobreza multidimensional	8.068*** (2.268)			
Hacinamiento crítico				-0.065 (0.046)
Años de educación		-0.610*** (0.119)		-0.003*** (0.001)
Trabajo por cuenta propia		-10.289 (7.392)		-0.032 (0.030)
Áreas verdes	-0.127*** (0.037)	-0.109*** (0.038)	-0.0004** (0.0002)	-0.0004** (0.0002)
Transporte público	6.938*** (2.548)			
Disponibilidad agua		18.763* (10.105)		
Dificultad atención médica		177.827** (78.638)	-0.394 (0.348)	
Distancia centro salud				-0.014** (0.006)
Factor riesgo COVID		-6.675 (6.421)	-0.016 (0.031)	-0.045 (0.028)
Mov. pro. semana		2,156.478 (1,495.355)	14.913** (7.268)	9.325 (6.561)
Porcentaje 2° dosis	0.832 (1.458)		-0.018*** (0.006)	0.002 (0.007)
Constante	2,604.734* (1,487.971)	-11,736.560 (9,292.476)	28.304*** (8.656)	75.206*** (12.195)
R ²	0.535	0.660	0.426	0.630
Adjusted R ² ajustado	0.484	0.566	0.319	0.529
I de Moran (residuos)	0.0898*	0.1187**	-0.097	-0.041

Nota:

*p<0.1; **p<0.05; ***p<0.01

Tabla 7: OLS simplificados para modelos de defunciones.

	<i>Modelos de def simplificados</i>							
	Incid. acumulada				Incid. acumulada ajustada			
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
Mujer	-0.396* (0.202)	-0.441** (0.191)	-0.472** (0.208)	-0.416** (0.204)	-0.003** (0.001)	-0.003** (0.001)	-0.003** (0.001)	-0.004*** (0.001)
Niños	-0.648 (0.390)	-0.619 (0.372)	-0.800** (0.377)	-0.830** (0.370)			-0.004* (0.002)	
Mayores 65							0.003*** (0.001)	
Migrantes	-0.263*** (0.093)	-0.229** (0.088)	-0.302*** (0.084)	-0.258*** (0.085)				
Densidad	2.757e-06*** (0.00000)	2.776e-06*** (0.00000)	3.110e-06*** (0.00000)	3.108e-06 *** (0.00000)				9.639e-09* (0.000)
Ruralidad					-0.0004* (0.0002)	-0.0004* (0.0002)		
Pobreza multidimensional	0.162** (0.061)	0.104 (0.065)			0.0001 (0.0005)	-0.00003 (0.0005)		
Pobreza ingresos				-0.0003 (0.0002)			-0.00000 (0.00000)	-0.00000 (0.00000)
Hacinamiento crítico				0.564 (0.378)				
Trabajo por cuenta propia			0.349* (0.196)	0.508** (0.191)			0.003** (0.001)	0.004*** (0.001)
Áreas verdes	-0.001 (0.001)		-0.001 (0.001)	-0.001 (0.001)				
Uso transporte público	0.245*** (0.090)	0.229** (0.087)	0.159* (0.092)	0.081 (0.099)	0.001 (0.001)	0.001 (0.001)	0.002*** (0.0004)	0.001 (0.001)
Disponibilidad agua	-0.445* (0.240)	-0.569** (0.234)	-0.538** (0.239)	-0.592** (0.254)	-0.003** (0.002)	-0.004** (0.002)	-0.003** (0.002)	-0.004*** (0.001)
Seguro salud público			0.062* (0.032)	0.062 (0.044)			0.001*** (0.0002)	
Dificultad atención médica							-0.029 (0.020)	-0.028 (0.024)
Factor riesgo COVID	0.266 (0.176)	0.264 (0.161)			0.003*** (0.001)	0.003*** (0.001)		0.003*** (0.001)
Incid. acumulada ajus. casos		1.971** (0.915)		2.744** (1.074)		0.015** (0.006)		0.023*** (0.006)
Mov. prom sem	30.886 (47.565)	15.192 (45.946)	29.016 (46.874)	42.789 (49.052)	0.040 (0.302)	-0.093 (0.300)	0.485 (0.292)	-0.032 (0.263)
Opor noti.			1.731 (1.207)		0.012 (0.007)			
Constante	644.434** (280.991)	751.898*** (272.062)	643.944** (279.034)	741.614** (299.610)	4.151** (1.978)	5.492*** (1.980)	3.905** (1.854)	5.273*** (1.675)
R ²	0.658	0.690	0.681	0.724	0.442	0.476	0.558	0.611
R ² ajustado	0.575	0.614	0.593	0.629	0.338	0.379	0.451	0.516
I de Moran (residuos)	0.003	-0.007	-0.043	0.019	0.035	0.031	0.030	0.037

Nota:

*p<0.1; **p<0.05; ***p<0.01

Al analizar los modelos simplificados para casos (ver Tabla 6) observamos que la bondad de ajuste es similar a la de modelos completos, probando que estos nuevos subconjuntos de variables logran explicar casi el mismo porcentaje de variabilidad de las variables dependientes, que los modelos previos (este comportamiento también se aprecia para los modelos de defunciones simplificados).

Si observamos los coeficientes de los modelos de casos simplificados, notaremos que aquellas variables que antes resultaron ser significativas (en los modelos completos) nuevamente lo son en estos, sin embargo, algunas variables que antes no eran significativas ahora sí lo son. De esta manera, es posible encontrar que las variables “niños”, “años de educación” y “ruralidad” poseen una asociación negativa con las variables de interés; mientras que las variables “mujer”, “densidad”, “dificultad en la atención médica” y “pobreza multidimensional” presentan una asociación positiva. Es importante indicar que estos resultados deben ser interpretados de forma conservadora, puesto que dos de los cuatro modelos presentan correlación espacial en los errores, pudiendo estar sesgados.

Respecto a los modelos simplificados de defunciones (ver Tabla 6) ocurre lo mismo descrito en el párrafo anterior, donde las asociaciones encontradas en los modelos completos se mantienen y se encuentran algunas nuevas, que antes no eran significativas. Así, se tiene que la variable “ruralidad” posee una asociación negativa con la variable de interés (defunciones ajustada); mientras que las variables “mayores 65”, “seguro de salud público” y “factor riesgo COVID” presentan una asociación positiva. Además, cabe destacar que la variable “movilidad promedio (semana)”, pese a que no es significativa, siempre quedo dentro del subconjunto de variables seleccionado por el criterio AIC, donde una explicación a este fenómeno podría ser que dicha variable sea importante al momento de modelar las variables de defunciones, pero debido a que posee una alta correlación con la variable “uso de transporte público” (correlación de un 41 %) esta no finalice siendo significativa (y uso de transporte sí).

Finalmente, para los dos modelos de “casos” en los que se encontró autocorrelación espacial en los residuos, se ajustarán modelos espaciales permitirán controlar dichos efectos espaciales. Debido a la naturaleza de esta variable dependiente, donde se espera que el número de casos de COVID-19 en una comuna afecte los casos en sus vecinas, el modelo espacial autorregresivo (SAR) es el más apropiado²¹.

En la tabla 8 se presentan los modelos espaciales autorregresivos ajustados. Se puede apreciar que gran parte de los resultados se mantienen, con tan solo dos principales cambios respecto a los coeficientes del modelo (2), donde ahora la variable “trabajo por cuenta propia” resulta si ser significativa (con una asociación negativa); mientras que la variables “niños” y “disponibilidad agua”, que previamente eran significativas, ahora no lo son. Cabe destacar dicho cambio en la variable “disponibilidad agua”, ya que era una de las variables que presentaba coeficientes contraintuitivos en los modelos previos, donde este resultado puede haberse obtenido ya que anteriormente no se corregía la correlación espacial presente (y por ende los resultados estaban sesgados).

²¹Recordar que se incluye la variable dependiente rezagada espacialmente en las especificaciones del modelo (ver sección 3.1.6).

Tabla 8: Modelos de casos corregidos espacialmente (SAR).

	<i>Modelos corregidos</i>	
	Incid. acumulada casos	
	(1)	(2)
Mujer		12.893** (5.509)
Niños		-22.105 (11.874)
Migrantes	-5.315** (2.462)	-4.790* (2.567)
Densidad		0.00005* (0.00003)
Pobreza multidimensional	7.364*** (2.064)	
Años de educación		-0.549*** (0.107)
Trabajo por cuenta propia		-11.205* (6.278)
Áreas verdes	-0.088** (0.035)	-0.078** (0.034)
Transporte público	5.184** (2.320)	
Disponibilidad agua		16.935 (9.056)
Dificultad atención médica		178.784*** (66.959)
Factor riesgo COVID		-6.702 (5.467)
Mov. prom. semana		1,664.952 (1,301.472)
Porcentaje 2° dosis	1.022 (1.326)	
Constante	920.836 (1,626.082)	-11,712.670 (7,899.592)
R ²	0.57	0.68
R ² ajustado	0.523	0.592
I de Moran (residuos)	-0.078	0.014
<i>Nota:</i>	*p<0.1; **p<0.05; ***p<0.01	

5.4. Estudio Espacio-Temporal

En esta sección se llevará a cabo todo lo relacionado con la estadística espacio-temporal.

5.4.1. Análisis Descriptivo datos de panel espaciales

En esta sección es incorporada la dimensión temporal por lo que se proceden a examinar las relaciones entre las variables dependientes (tasa de incidencia semanal de casos y defunciones) y aquellas variables independientes que varían a través del tiempo²². Utilizando la información para toda la Región Metropolitana, las Figuras 16, 17 y 18 grafican como serie de tiempo cada una de las variables dependientes junto a la variable independiente a analizar (movilidad promedio en la semana, vacunación con 2 dosis y oportunidad en la notificación, respectivamente).




Figura 16: Relación tasa de Contagios/Defunciones y Movilidad (más Paso a Paso).

Fuente: Elaboración propia

²²Recordar que existen variables que varían por comuna pero no a través del tiempo (características demográficas de cada comuna).




Figura 17: Relación tasa de Contagios/Defunciones y porcentaje vacunación.

Fuente: Elaboración propia




Figura 18: Relación tasa de Contagios/Defunciones y Oportunidad en la notificación.

Fuente: Elaboración propia

Analizando la Figura 16, se puede observar que periodos con mayor cantidad de casos/defunciones poseen menores valores en la variable de movilidad, lo cual es contraintuitivo. Esto se debe a que existe una tercera variable, correspondiente a las restricciones de movilidad (Plan Paso a Paso), la cual está claramente ligada a esta relación, donde periodos con mayores tasas de casos/defunciones traerán consigo etapas más restrictivas en el Plan Paso a Paso, disminuyendo así la movilidad (y viceversa). De esta manera, son dos los puntos a tener en consideración:

- Si se desea analizar el efecto de la movilidad sobre los casos/defunciones, es de suma importancia controlar mediante las restricciones de movilidad.
- Bajo la idea de que la movilidad presente afecte los casos/defunciones futuras será preciso rezagar la variable de movilidad para capturar la correcta relación entre ambas variables (eliminando posibles problemas de endogeneidad)²³.

Al examinar la Figura 17 es posible observar que el proceso de vacunación con dos dosis (esquema completo) para la Región Metropolitana comienza al mismo tiempo que el inicio de su segunda ola de contagios/defunciones, donde esta ola empieza a decrecer cuando se alcanza alrededor de un 50 % de la población con esquema completo. Cabe destacar que, considerando solo la información graficada, pese a que hay un alto porcentaje de vacunación con dos dosis no se logró reprimir el aumento de casos presentados en la tercera ola de contagios, no así las defunciones las cuales presentaron un peak mucho menor que en la ola pasada²⁴ (de todas formas, hay que recordar que este análisis se restringe a la segunda ola de COVID-19). Por último, al igual que en el caso de las movilidades, se espera que el porcentaje de población con 2 dosis tenga un efecto en los casos/defunciones futuras, esto más la necesidad de esperar cierto periodo para una correcta eficacia de la vacuna, hacen necesario rezagar esta variable para una buena especificación en los modelos.

Ahora, si nos enfocamos en la Figura 18 notaremos que en general existe una relación inversa entre variables, donde se posee periodos con alta oportunidad en la notificación y bajas tasas de incidencia de casos/defunciones (y viceversa). Al igual que en casos previos, será necesario rezagar esta variable independiente ya que se espera que un alto promedio de notificaciones en el presente afecte negativamente a ambas variables dependientes.

Además de las asociaciones ya expuestas, en la Figura 19 se presenta la relación entre las dos variables dependientes. Es posible observar que ambas series siguen el mismo comportamiento, relación directa entre las variables, y que aquella serie relativa a los casos esta ligeramente desplazada a la izquierda, resaltando la necesidad de rezagar la tasa de casos al momento de explicar la tasa de defunciones.

²³El análisis de cuál es el rezago adecuado de esta variable será discutido más adelante.

²⁴Destacar que estas son meramente descripciones de los gráficos presentados, puesto que hay que entender que ambas olas poseen contextos completamente distintos (por ejemplo, ambas se producen debido a distintas variantes del COVID-19, cada una con distintas características) por lo que estos gráficos deben ser interpretados de forma conservadora.




Figura 19: Relación entre tasa de Contagios y tasa de Defunciones

Para saber cuál es el rezago adecuado, se calcularon las correlaciones cruzadas entre pares de variables por comuna. Así, para determinar el rezago de la variable “tasa de casos”, se obtuvieron las correlaciones de Pearson entre la variable “casos” -considerando distintos rezagos- y la “tasa de defunciones”, donde posteriormente será seleccionado aquel rezago que maximice/minimice dicha correlación. Como este procedimiento se repite para cada unidad del panel, es generado un histograma de frecuencias que resume los resultados. De esta manera, se puede ver que para la variable “tasa de casos” un rezago de dos semanas presenta, en la mayoría de las comunas, una mayor correlación significativa con la variable tasa de defunciones (ver Figura 20).




Figura 20: Histograma de frecuencia correlación cruzada (casos v.s defunciones)




Figura 21: Histogramas de frecuencia para correlaciones cruzadas

Fuente: Elaboración propia

El procedimiento previamente descrito es utilizado para todas las variables explicativas que varían en el tiempo, donde los histogramas de frecuencia a la izquierda de la Figura 21 son relativos a las correlaciones con la variable dependiente de casos, mientras que los de la derecha con la variable de defunciones. Para el caso de movilidad promedio semanal se decide rezagar en una semana, ya que se presenta como uno de los rezagos con mayor frecuencia en ambos gráficos. En cuanto al porcentaje con segunda dosis, los rezagos con mayor frecuencia son de una semana y cuatro semanas, sin embargo, se decide utilizar este último puesto que “las vacunas solo confieren la máxima protección pasadas de 2 a 3 semanas de la última dosis necesaria” (OMS, 2021). Finalmente, para la variable de oportunidad en la notificación se utiliza un rezago de una semana.

De manera adicional, se realiza un análisis de correlaciones de las variables antes y después de rezagarlas. Vemos que para todas las variables el signo de la correlación se mantiene y la magnitud de las correlaciones disminuyen, a excepción de la correspondiente a la de tasa de defunciones con tasa de casos (rezagada en dos semanas) que aumenta. Pese a la disminución en las correlaciones, se utilizarán las variables rezagadas para evitar posibles problemas de endogeneidad.




Figura 22: Extracto matriz de correlaciones (variables originales)

Fuente: Elaboración propia




Figura 23: Extracto matriz de correlaciones (variables rezagadas)

Fuente: Elaboración propia

5.4.2. Modelos

En la presente sección se exhiben los resultados de los modelos espacio-temporales para casos y defunciones. En una primera parte se considerarán solo aquellas variables independientes que varían en el tiempo y se controlará con un efecto fijo de comuna. Posteriormente, con el fin de conocer los coeficientes de las variables de caracterización de cada comuna, se ajustan modelos de efecto aleatorio.

5.4.2.1 Modelos de efecto fijo

Con el fin de abordar posibles problemas en las especificaciones pasadas, principalmente de posibles variables omitidas relevantes referidas a características de las comunas que no son observables y puedan influir en las variables dependientes, se aplican modelos de efecto fijo. La ventaja de este tipo de modelos es que permiten conocer, de forma simplificada, los coeficientes de las variables dinámicas.

Es relevante mencionar, debido a todo lo analizado en la sección 5.4.1, que para el ajuste de estos modelos se utilizó las variables rezagadas, además de añadir como control una variable que considera las etapas del Plan Paso a Paso (donde se utiliza como base la etapa de Apertura inicial). De esta manera, en una primera instancia, se estimaron los modelos de efecto fijo presentados en la Tabla 9, donde el primer modelo tiene por variable dependiente la incidencia semanal de casos y los dos últimos la incidencia semanal de defunciones.

Tabla 9: Modelos de efecto fijo para Casos y Defunciones

	<i>Variable dependiente:</i>		
	<i>Incidencia semanal casos</i>	<i>Incidencia semanal defunciones</i>	
	(1)	(1)	(2)
Mov. semana (rez 1)	126.226*** (36.418)	1.299 (1.105)	1.409 (1.038)
Etapas: cuarentena (rez 1)	163.015*** (31.850)	3.114*** (0.966)	0.285 (0.927)
Etapas: transición (rez 1)	7.088 (31.499)	0.715 (0.955)	0.292 (0.899)
Etapas: preparación (rez 1)	-44.125 (31.584)	-0.114 (0.958)	0.331 (0.901)
Porcentaje 2 dosis (rez 4)	-23.654** (10.976)	3.100*** (0.333)	1.774*** (0.325)
Oportunidad noti. (rez 1)	1.085*** (0.250)	-0.011 (0.008)	-0.017** (0.007)
Tasa semanal casos (rez 2)			0.014*** (0.001)
R ²	0.433	0.249	0.337
R ² ajustado	0.414	0.224	0.314
<i>Nota:</i>		*p<0.1; **p<0.05; ***p<0.01	

Al examinar la Tabla 9, se puede observar que varias de las variables de interés presentan efectos significativos, donde se destaca el coeficiente de oportunidad en la notificación, debido a que es primera vez que muestra un resultado no contraintuitivo y significativo en un modelo de defunción, comparando con los modelos espaciales. Sin embargo, estos resultados deben ser analizados de forma conservadora, puesto que los tres modelos poseen una bondad de ajuste baja y presentan autocorrelación espacial en algunas semanas²⁵. Cabe destacar que para el modelo de casos es posible encontrar, además de la autocorrelación espacial, dependencia temporal.

En la Figura 24 y Tabla 10 son expuestas ambas dependencias, donde en la primera se presentan los p-valores obtenidos en el test I de Moran para el primer modelo²⁶, y la segunda presenta los p-valores obtenidos en el test de Ljung-Box (en la comuna de La Florida²⁷) en los tres modelos.




Figura 24: Análisis de correlación espacial en residuos.

Fuente: Elaboración propia

²⁵Recordar que, en el caso de paneles espaciales, la dependencia espacial se analiza por unidad temporal (semana epidemiológica) y la dependencia temporal por unidad espacial (comuna).

²⁶Si se desea ver los gráficos para los modelos de defunciones visitar punto 8.5 del Anexo.

²⁷El comportamiento para las otras 51 comunas es similar y no son presentados para simplificar la presentación.

Rezago	p-valor (casos)	p-valor (def. 1)	p-valor (def. 2)
1	0.00	0.29	0.16
2	0.00	0.43	0.31
3	0.00	0.41	0.11
4	0.00	0.50	0.10
5	0.00	0.60	0.12
6	0.00	0.10	0.05
7	0.00	0.14	0.09
8	0.00	0.15	0.07
9	0.00	0.17	0.05
10	0.00	0.17	0.06

Tabla 10: P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los tres modelos de efecto fijo (Comuna: La Florida).

Posteriormente, se realiza el test del Multiplicador de Lagrange en su primera versión para los tres modelos, pudiendo identificar el modelo adecuado para su corrección²⁸ ²⁹. En la Tabla 11 se presenta el test LM para el modelo de casos, donde se observa que la hipótesis conjunta (J) es rechazada, por lo que al menos efectos específicos o autocorrelación espacial en los errores existe. Luego, como ambas hipótesis condicionales (C.1 y C.2) también son rechazadas, el modelo a estimar según el test es un SEMFE, es decir, un modelo que considera efectos fijos y autocorrelación espacial en los errores. Sin embargo, debido a la naturaleza de la variable dependiente, donde se espera que el número de casos de COVID-19 en una comuna afecte los casos en sus vecinas, se incorpora la dependencia espacial de la variable dependiente, ajustando así un modelo SAREMFE. En la Tabla 12 y 13 se presenta el test LM para los modelos de defunciones, donde ambos serán corregidos con un mediante un SEMFE.

	J	M.1	M.2	C.1	C.2	Modelo
Estadístico	42.97	-3.59	6.55	41.50	38.86	SEMFE+SAR
p-valor	0.00	1.00	0.00	0.00	0.00	

Tabla 11: Pruebas LM para modelo de efecto fijo de casos.

	J	M.1	M.2	C.1	C.2	Modelo
Estadístico	24.58	-0.28	4.96	4.64	25.12	SEMFE
p-valor	0.00	1.00	0.00	0.00	0.002	

Tabla 12: Pruebas LM para modelo de efecto fijo de defunciones n° 1.

²⁸Si bien no es preciso utilizar el test LM en modelos de efecto fijo, esto se realiza como guía.

²⁹Se utiliza la primera versión ya que esta no analiza la inclusión de correlación serial en los errores, estructura que solo puede ser considerada en modelos de efecto aleatorio.

	J	M.1	M.2	C.1	C.2	Modelo
Estadístico	24.29	-0.25	4.93	0.74	26.73	SEMFE
p-valor	0.00	0.84	0.00	0.046	0.00	

Tabla 13: Pruebas LM para modelo de efecto fijo de defunciones n° 2.

A continuación se presentan los resultados de los modelos corregidos de manera espacio-temporal (ver Tabla 14). Se puede apreciar que gran parte de las asociaciones significativas se mantienen, donde el mayor cambio lo presentó el coeficiente de movilidad, el cual resulta ser positivo y significativo en uno de los nuevos modelos de defunciones. De esta manera, para el modelo de casos, resultaron ser significativos y con asociación positiva la movilidad y la oportunidad de notificación, ambas rezagadas una semana. Donde este último efecto es contraintuitivo, se esperaría que a una mayor oportunidad de notificación los casos disminuyan, considerando que genera una menor exposición de los contagiados. Por otro lado, es relevante que para ambos modelos de defunciones el porcentaje de vacunación con 2 dosis tiene un efecto positivo y significativo, resultado contraintuitivo encontrado y comentado en los modelos espaciales.

Finalmente en las Figura 25 y Tabla 15 es posible observar que estos nuevos modelos logran corregir la dependencia tanto temporal como espacial³⁰.

Tabla 14: Modelos de efecto fijo para Casos y Defunciones corregidos

	<i>Variable dependiente:</i>		
	Incidencia semanal casos	Incidencia semanal defunciones	
	(1)	(1)	(2)
Mov. semana (rez 1)	33.67*** (10.54)	0.8503 (1.16)	1.381** (0.664)
Etapas: cuarentena (rez 1)	-7.453 (12.22)	3.409*** (0.955)	0.3649 (0.9141)
Etapas: transición (rez 1)	-22.73* (12.1)	1.135 (0.9418)	0.3593 (0.8852)
Etapas: preparación (rez 1)	24.64** (12.23)	0.372 (0.942)	0.396 (0.887)
Porcentaje 2 dosis (rez 4)	-2.738 (2.918)	3.035** (0.3706)	1.772*** (0.3261)
Oportunidad noti. (rez 1)	0.3455*** (0.102)	-0.0098 (0.007)	-0.017*** (0.007)
Tasa semanal casos (rez 2)			0.014*** (0.0009)
R ²	0.452	0.315	0.4449
R ² ajustado	0.447	0.314	0.429
<i>Nota:</i>		*p<0.1; **p<0.05; ***p<0.01	

³⁰Revisar punto 8.6 del Anexo para análisis completo de autocorrelacion espacial.




Figura 25: Análisis de correlación espacial para residuos de modelo corregido (casos) .

Fuente: Elaboración propia

Rezago	(casos) p-valor	(def. 1) p-valor	(def. 2) p-valor
1	0.11	0.23	0.13
2	0.09	0.48	0.30
3	0.10	0.63	0.42
4	0.14	0.79	0.44
5	0.23	0.87	0.58
6	0.28	0.93	0.70
7	0.33	0.90	0.60
8	0.40	0.94	0.69
9	0.49	0.96	0.76
10	0.42	0.98	0.82

Tabla 15: P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los tres modelos de efecto fijo corregido (Comuna: La Florida).

5.4.2.2 Modelos de efecto aleatorio

Con el fin de conocer los efectos de las variables que caracterizan demográficamente las comunas, además de analizar si el comportamiento visto en los modelos de efecto fijo se mantienen con ellas incluidas, a continuación se desarrollan modelos de efecto aleatorio para ambas variables dependientes.

En la Tabla 16 se presentan los resultados para los modelos estimados. Las primeras dos columnas corresponden a estimaciones para la variable dependiente de casos, donde la primera especificación utiliza como variable independiente la pobreza multidimensional y la segunda presenta su desagregación. Las siguientes cuatro columnas corresponden a modelos para defunciones, donde las primeras dos utilizan pobreza multidimensional y las otras su desagregación. La diferencia entre los modelos de cada par es la inclusión de la incidencia semanal de casos como variable independiente.

Tabla 16: Modelos de efecto aleatorio para Casos y Defunciones

	<i>Variable dependiente:</i>					
	Incidencia semanal casos		Incidencia semanal defunciones			
	(1)	(2)	(1)	(2)	(3)	(4)
Mujer	123.276 (140.000)	168.910 (143.195)	-14.537* (7.674)	-15.990** (7.773)	-12.373 (8.174)	-14.702* (8.334)
Niños	-430.507* (259.323)	-735.006** (289.911)	-22.444 (14.035)	-20.004 (14.195)	-24.652 (16.091)	-18.590 (16.362)
Mayores 65	264.686** (112.386)	238.440** (115.540)	10.778* (6.136)	8.928 (6.213)	12.859* (6.591)	11.140* (6.720)
Mayores 80	-331.531 (262.359)	-130.578 (273.632)	-0.546 (14.476)	4.076 (14.672)	-3.227 (15.705)	-0.560 (16.017)
Migrantes	-111.182 (69.552)	-95.404 (82.705)	-5.404 (3.812)	-3.692 (3.862)	-7.901* (4.733)	-6.605 (4.827)
Densidad	-0.0003 (0.001)	0.0003 (0.001)	0.00004 (0.00005)	0.00004 (0.00005)	0.0001 (0.00005)	0.0001 (0.00005)
Ruralidad	62.429 (35.012)	55.416 (36.020)	-1.092 (1.653)	-1.655 (1.675)	0.423 (2.033)	0.253 (2.070)
Pobreza multidimensional	121.608*** (42.559)		5.440** (2.322)	2.980 (2.357)		
Pobreza ingresos		79.938 (151.371)			-16.189* (8.664)	-18.105** (8.835)
Sin hacinamiento		111.499 (101.891)			-6.920 (5.827)	-8.274 (5.941)
Hacinamiento crítico		463.127 (285.465)			-0.634 (15.779)	-2.758 (16.034)
Años de educación		-12.766** (6.285)			0.130 (0.357)	0.287 (0.363)

Continúa la tabla...

Trabajo por cuenta propia		-98.411 (161.500)			16.998* (9.260)	18.198* (9.443)
Áreas verdes	-2.053*** (0.780)	-1.692** (0.802)	-0.010 (0.043)	0.026 (0.044)	-0.042 (0.046)	-0.014 (0.047)
Transporte público	76.292 (87.137)	35.757 (95.641)	11.398** (4.796)	10.117** (4.860)	9.571* (5.486)	9.220* (5.594)
Disponibilidad agua	444.268** (180.825)	479.646** (192.084)	-19.950** (9.973)	-26.216*** (10.114)	-12.648 (10.968)	-18.537* (11.188)
Seguro salud público		-20.568 (56.000)			4.147 (3.178)	3.817 (3.238)
Dificultad atención médica	508.713 (1,679.595)	1,474.574 (1,760.030)	-82.527 (92.688)	-99.240 (93.934)	-134.624 (101.028)	-165.346 (103.056)
Distancia centro salud	48.174 (33.668)	47.885 (37.866)	-2.214 (1.849)	-2.758 (1.874)	-1.768 (2.148)	-2.093 (2.189)
Factor riesgo COVID	-294.707** (147.602)	-395.962** (154.370)	3.293 (8.128)	6.113 (8.237)	-1.099 (8.813)	3.234 (8.988)
Mov. semana (rez 1)	63.218*** (24.097)	78.480*** (26.116)	1.408 (0.937)	1.453 (0.900)	1.446 (0.982)	1.473 (0.938)
Etapas: cuarentena (rez 1)	150.234*** (31.281)	153.782*** (31.246)	3.092*** (0.959)	0.334 (0.922)	3.113*** (0.960)	0.314 (0.922)
Etapas: transición (rez 1)	-1.113 (31.073)	2.009 (31.029)	0.693 (0.951)	0.309 (0.896)	0.705 (0.951)	0.299 (0.895)
Etapas: preparación (rez 1)	-53.273 (33.206)	-50.972 (31.154)	-0.142 (0.954)	0.331 (0.899)	-0.122 (0.954)	0.339 (0.898)
Porcentaje 2 dosis (rez 4)	-20.123* (10.692)	-18.745* (10.750)	3.154*** (0.329)	1.855*** (0.322)	3.137*** (0.330)	1.818*** (0.323)
Oportunidad noti. (rez 1)	1.081*** (0.238)	1.105*** (0.237)	-0.009 (0.007)	-0.015** (0.007)	-0.009 (0.007)	-0.016** (0.007)
Incidencia semanal casos (rez 2)				0.014*** (0.001)		0.014*** (0.001)
Constante	-536.148** (219.760)	-509.835* (280.413)	26.992** (11.998)	33.934*** (12.158)	21.484 (15.899)	27.210* (16.205)
R ²	0.454	0.459	0.265	0.345	0.267	0.349
R ² ajustado	0.448	0.452	0.256	0.338	0.257	0.339
Nota: *p<0.1; **p<0.05; ***p<0.01						

Al analizar los resultados de estos modelos (ver Tabla 16) se puede observar que la bondad de ajuste es similar a los modelos de efecto fijo, donde ninguno logró superar un 50 % de variabilidad explicada).

Si se examinan los coeficientes, es posible notar una clara similitud con los modelos espaciales (tanto de casos como defunciones), donde variables como niños, áreas verdes, años de educación y porcentaje con 2 dosis poseen una asociación negativa y significativa con las variables dependientes de casos; mientras que, variables como mayores de 65, pobreza multidimensional y movilidad tienen una asociación positiva. Sin embargo, también es posible encontrar diferencias, por ejemplo, la oportunidad en la notificación para los modelos de defunciones resulta tener un coeficiente negativo

y significativo, resultado que solo ha sido visto en los modelos de efecto fijo.

Al igual que para el caso de efecto fijo se realizó un análisis de residuos (Figura 26 y Tabla 17) que entregó como resultado la necesidad de corregir tanto espacial³¹ como temporalmente. Donde esta última dependencia solo fue encontrada en los modelos de casos.




Figura 26: Análisis de correlación espacial para residuos de modelo de efecto aleatorio (casos n°1) .

Rezago	casos 1 p-valor	casos 2 p-valor	def. 1 p-valor	def. 2 p-valor	def. 3 p-valor	def. 4 p-valor
1	0.00	0.00	0.74	0.50	0.73	0.49
2	0.00	0.00	0.94	0.77	0.94	0.76
3	0.00	0.00	0.86	0.87	0.86	0.87
4	0.00	0.00	0.83	0.74	0.83	0.74
5	0.00	0.00	0.91	0.80	0.91	0.79
6	0.00	0.00	0.81	0.83	0.81	0.83
7	0.00	0.00	0.88	0.90	0.88	0.90
8	0.00	0.00	0.78	0.90	0.78	0.90
9	0.00	0.00	0.7	0.82	0.71	0.82
10	0.01	0.01	0.56	0.76	0.56	0.76

Tabla 17: P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los seis modelos de efecto aleatorio (Comuna: La Reina).

³¹Para ver el análisis de correlación espacial en los residuos de los otros cinco modelos, dirigirse al punto 8.7 del Anexo.

Sin embargo, como paso previo a corregir estas dependencias, se buscará simplificar los modelos debido a que se posee una gran cantidad de variables independientes y no tantas unidades temporales por unidad espacial. Estos modelos son presentados en la Tabla 18 y fueron simplificados bajo los mismos criterios utilizados en los modelos espaciales.

Tabla 18: Modelos de efecto aleatorio para Casos y Defunciones simplificados

	<i>Variable dependiente:</i>					
	Incidencia semanal casos		Incidencia semanal defunciones			
	(1)	(2)	(1)	(2)	(3)	(4)
Mujer			-12.744* (7.007)	-11.767** (5.604)		-17.600** (7.217)
Niños	-408.650 (253.766)	-620.560*** (228.902)				
Mayores 65	219.419** (95.042)	295.619*** (85.657)	14.021*** (4.302)		8.297* (4.971)	10.885** (4.641)
Migrantes					-5.959** (3.011)	
Ruralidad	20.145 (15.318)					
Pobreza multidimensional	135.813*** (42.188)		6.390*** (1.884)			
Pobreza ingresos					5.763 (5.650)	-4.140 (5.351)
Años de educación		-11.806*** (2.152)				
Trabajo por cuenta propia					5.670 (7.742)	16.463** (7.377)
Áreas verdes	-1.846*** (0.708)	-1.924*** (0.612)				
Transporte público			9.961*** (2.294)	6.778*** (2.384)	9.678*** (2.750)	8.707*** (2.387)
Disponibilidad agua	366.388** (163.008)	276.855** (135.344)	-10.980 (7.997)	-19.050** (8.847)		-22.103*** (8.195)
Factor riesgo COVID	-195.465 (124.611)	-337.041*** (114.265)				
Mov. semana (rez1)	66.259*** (24.189)	55.032*** (20.895)	1.498* (0.905)	1.513* (0.887)	1.775* (0.934)	1.798** (0.874)

Continúa la tabla...

Etapa: cuarentena (rez1)	150.878*** (31.074)	151.113*** (30.706)	3.148*** (0.958)	0.389 (0.922)	3.138*** (0.959)	0.407 (0.920)
Etapa: transición (rez1)	-0.768 (30.859)	1.448 (30.575)	0.735 (0.949)	0.381 (0.895)	0.680 (0.950)	0.375 (0.894)
Etapa: preparación (rez1)	-52.842* (31.020)	-52.029* (30.761)	-0.102 (0.953)	0.400 (0.898)	-0.139 (0.953)	0.421 (0.897)
Porcentaje 2 dosis (rez 4)	-19.763* (10.695)	-15.509 (10.624)	3.144*** (0.328)	1.826*** (0.319)	3.062*** (0.329)	1.761*** (0.321)
Oportunidad noti. (rez 1)	1.110*** (0.235)	1.124*** (0.228)	-0.008 (0.007)	-0.014** (0.007)	-0.008 (0.007)	-0.014** (0.007)
Incidencia semanal casos (rez 2)				0.014*** (0.001)		0.014*** (0.001)
Constante	-367.365** (173.221)	-101.071 (148.623)	13.606 (9.183)	23.284** (9.996)	-2.455 (1.700)	26.793*** (9.273)
R ²	0.449	0.458	0.260	0.337	0.254	0.342
R ² ajustado	0.445	0.455	0.256	0.333	0.249	0.337

Nota:

*p<0.1; **p<0.05; ***p<0.01

Realizando el mismo análisis que en los casos anteriores, como se observa en la Figura 27 y Tabla 19 se presenta dependencia espacio-temporal que debe ser corregida. Donde, nuevamente, la dependencia temporal solo se presenta en los modelos de casos.




Figura 27: Análisis de correlación espacial para residuos de modelo de efecto aleatorio simplificado (casos n°1) .

Rezago	casos simpli. 1 p-valor	casos simpli. 2 p-valor	def. simpli. 1 p-valor	def. simpli. 2 p-valor	def. simpli. 3 p-valor	def. simpli. 4 p-valor
1	0.00	0.00	0.73	0.48	0.71	0.47
2	0.00	0.00	0.94	0.76	0.93	0.75
3	0.00	0.00	0.86	0.87	0.85	0.86
4	0.00	0.00	0.83	0.74	0.83	0.74
5	0.00	0.00	0.91	0.79	0.91	0.79
6	0.00	0.00	0.81	0.83	0.81	0.82
7	0.00	0.00	0.88	0.90	0.88	0.90
8	0.00	0.00	0.78	0.90	0.78	0.90
9	0.01	0.00	0.71	0.82	0.71	0.82
10	0.01	0.01	0.56	0.76	0.56	0.76

Tabla 19: P-valores prueba de Ljung-Box, hasta 10 rezagos, para residuos de los seis modelos simplificados de efecto aleatorio (Comuna: La Reina).

Al estar utilizando modelos de efecto aleatorio, es importante recordar que es posible utilizar la segunda versión de las pruebas LM, la cual permite ver si se debe incorporar correlación serial en las especificaciones de los errores. De esta manera, para los modelos de casos se corregirá mediante un modelo SAREMSRRE debido a que la prueba LM sugiere un modelo SEMSRRE y se le agregará la dependencia espacial en la variable dependiente debido a la naturaleza de la variable dependiente (casos) (ver Tablas 20 y 21). Los modelos de defunciones se corregirán mediante un modelo SEMRE dado que su prueba condicional para la correlación serial en los errores es la única que no se rechaza (ver Tablas 22 a 25).

	J	C.1	C.2	C.3	Modelo
Estadístico	165.70	26.75	13.17	24.75	SEMSRRE+SAR
p-valor	0.00	0.00	0.03	0.00	

Tabla 20: Pruebas LM para modelo de efecto aleatorio de casos n°1.

	J	C.1	C.2	C.3	Modelo
Estadístico	174.50	26.82	14.01	49.06	SEMSRRE+SAR
p-valor	0.00	0.00	0.02	0.00	

Tabla 21: Pruebas LM para modelo de efecto aleatorio de casos n°2.

	J	C.1	C.2	C.3	Modelo
Estadístico	9.30	10.64	-1663.29	39.52	SEMSRRE
p-valor	0.03	0.00	1.00	0.00	

Tabla 22: Pruebas LM para modelo de efecto aleatorio de defunciones n°1.

	J	C.1	C.2	C.3	Modelo
Estadístico	13.64	8.37	-3913.32	17.90	SEMSRRE
p-valor	0.00	0.01	1.00	0.00	

Tabla 23: Pruebas LM para modelo de efecto aleatorio de defunciones n°2.

	J	C.1	C.2	C.3	Modelo
Estadístico	14.68	10.94	-2072.71	39.41	SEMSRRE
p-valor	0.00	0.00	1.00	0.00	

Tabla 24: Pruebas LM para modelo de efecto aleatorio de defunciones n°3.

	J	C.1	C.2	C.3	Modelo
Estadístico	10.69	11.32	-3119.75	13.72	SEMSRRE
p-valor	0.01	0.00	1.00	0.00	

Tabla 25: Pruebas LM para modelo de efecto aleatorio de defunciones n°4.

En la Tabla 26 son presentados los resultados de los modelos de efecto aleatorio corregidos, donde es interesante ver que para las variables dinámicas se mantienen comportamientos encontrados bajo los modelos de efecto fijo, por ejemplo, para los modelos de casos el coeficiente de movilidad continua teniendo un signo positivo y el de vacunación con 2 dosis negativo (ambos significativos). De igual manera, si son analizados los modelos de defunciones las variables oportunidad en la notificación y vacunación con 2 dosis presentaron las mismas asociaciones previas, donde este última nuevamente resulta ser contraintuitivo.

Al examinar las variables demográficas y socioeconómicas que caracterizan a las comunas, es posible observar que las variables mayores de 65, ruralidad y pobreza multidimensional poseen una asociación positiva con la tasa de casos semanal; mientras que la variables niños, áreas verdes y factor riesgo presentan una asociación negativa. Dichas relaciones entre variables, en general, también fueron obtenidas en los modelos espaciales. Finalmente cabe destacar que estos nuevos modelos despacio-temporales logran corregir la dependencia espacial y temporal.

Tabla 26: Modelos de efecto aleatorio para Casos y Defunciones corregidos

	<i>Variable dependiente:</i>					
	Incidencia semanal casos		Incidencia semanal defunciones			
	(1)	(2)	(1)	(2)	(3)	(4)
Mujer			-11.51* (6.781)	-9.217 (7.506)		-17.27*** (6.811)
Niños	160.3 (282.2)	134.2 (281.6)				
Mayores 65	77.53 (93.67)	126.5 (96.5)	13.85*** (4.187)		8.173* (4.861)	10.94*** (4.382)
Migrantes					-5.843**	
Ruralidad	-13.9 (14.92)					
Pobreza multidimensional	136.3*** (43.32)		6.309*** (1.824)			
Pobreza ingresos					6.445 (5.391)	-4.094 (5.036)
Años de educación		-8.306*** (2.504)				
Trabajo por cuenta propia					4.492 (7.594)	16.32*** (6.953)
Áreas verdes	-2.145*** (0.7263)	-2.135*** (0.7199)				
Transporte público			9.966*** (2.186)	6.74*** (2.349)	10.01*** (2.67)	8.679*** (2.252)
Disponibilidad agua	320.6* (188.1)	344.6* (179.9)	-10.59 (7.596)	-18.99*** (8.722)		-21.99*** (7.716)
Factor riesgo COVID	64.78 (134.4)	-42.97 (138.6)				

Nota:

Continúa la tabla...

Mov. semana (rez1)	2.375 (8.309)	5.344 (8.146)	1.122 (0.9283)	1.47* (0.8911)	1.344 (0.9723)	1.798*** (0.8631)
Etap. cuarentena (rez1)	-10.27 (12.59)	-8.837 (12.58)	3.418*** (0.9595)	0.4681 (0.9213)	3.414*** (0.9603)	0.4807 (0.9191)
Etap. transición (rez1)	-18.37 (12.46)	-17.41 (12.46)	1.119 (0.9491)	0.4489 (0.894)	1.076 (0.9493)	0.4363 (0.8924)
Etap. preparación (rez1)	-22.54* (12.46)	-21.7* (12.46)	0.3407 (0.95)	0.4656 (0.8963)	0.3201 (0.9501)	0.4814 (0.895)
Porcentaje 2 dosis (rez 4)	-0.6895 (5.053)	-0.8253 (5.033)	3.096*** (0.367)	1.827*** (0.3248)	2.999*** (0.3697)	1.76*** (0.3246)
Oportunidad noti. (rez 1)	0.01289 (0.08818)	0.02804 (0.08789)	-0.0072 (0.007)	-0.01394** (0.007)	-0.0074 (0.007)	-0.0134* (0.0069)
Incidencia semanal casos (rez 2)				0.01388*** (0.0009)		0.01399*** (0.0009)
Constante	-334.1* (199.3)	-241.7 203.9	12.54 (8.673)	22.89*** (9.846)	-2.475 (1.698)	26.42*** (8.732)
R ²	0.462	0.438	0.293	0.3364	0.2705	0.3633
R ²	0.451	0.435	0.289	0.334	0.269	0.354
<i>Nota:</i>				*p<0.1; **p<0.05; ***p<0.01		

5.5. Resumen de resultados

En base a los modelos finales de la sección espacial y espacio-temporal, en la Tabla 27 son resumidas las variables que demostraron tener efectos significativos, de manera general, en las variables de impacto del COVID-19, separadas en los grupos de casos y defunciones.

<i>Resumen determinantes del impacto de COVID-19</i>			
Casos		Defunciones	
(+)	(-)	(+)	(-)
Mayores 65	Migrantes	Mayores 65	Migrantes
Densidad	Niños	Densidad	Niños
Pobreza multidimensional	Distancia centro salud	Pobreza multidimensional	Mujer
Uso transporte público	Trabajo por cuenta propia	Uso transporte público	Ruralidad
Movilidad prom. semana	Porcentaje vacunación 2 dosis	Movilidad prom. semana	Oportunidad en la notificación
Mujer	Áreas verdes	Factor riesgo COVID-19	Disp. agua
Dificultad atención médica	Factor riesgo COVID-19	Incid. acum. ajus casos	Pobreza ingresos
		Trabajo por cuenta propia	
		Niños	
		Seguro salud público	

Tabla 27: Resumen determinantes del impacto de COVID-19

Destacar que cinco variables coinciden en afectar positivamente tanto casos como defunciones, estas son mayores de 65 años, densidad, pobreza multidimensional, uso de transporte público y movilidad promedio en la semana. Por otra parte, el porcentaje de migrantes y niños en la comuna afectan negativamente ambos grupos de variables dependientes.

6. Conclusiones

El presente trabajo de investigación tuvo por objetivo identificar los determinantes que impactan variables relativas al COVID-19 tomando como punto de partida el trabajo realizado en “COVID-19 incidence and mortality in the Metropolitan Region, Chile: time, space, and structural factors” (Villalobos, et al. 2021), donde se analizan los determinantes para el primer periodo de pandemia (primera ola).

Esta tesis rescata las variables previamente examinadas, pero se añaden nuevos factores considerando que se trata de un contexto distinto, nos enfocamos en la segunda ola de COVID-19. Las nuevas variables explicativas que se añadieron a los modelos son movilidad promedio en la semana, porcentaje de vacunación con 2 dosis y la oportunidad en la notificación.

Fue posible observar que los resultados de los modelos espaciales desarrollados, tanto para casos como para defunciones, arrojan que para las variables de características de las comunas que para Villalobos, et al. (2021) fueron significativas, aquí mantuvieron su significancia y signo. Ejemplos de esto son, para la variable dependiente de casos, la densidad poblacional, pobreza multidimensional, uso de transporte público y dificultad para obtener atención médica. Además, con la agregación de las nuevas variables al modelo, y teniendo en cuenta que es un periodo de estudio distinto, los coeficientes de más variables demográficas resultaron ser significativos, como el caso de áreas verdes.

En cuanto a las nuevas variables, para los modelos de casos, la movilidad promedio en la semana y el porcentaje de vacunación con 2 dosis fueron significativas para la variable dependiente de incidencia acumulada ajustada, donde la primera afecta positivamente y la segunda negativamente. La variable relativa a oportunidad en la notificación fue quitada en el proceso de simplificación de modelos. Para los modelos de defunciones, la movilidad y la oportunidad en la notificación no son significativas y, en el caso de la vacunación, consistentemente presentó una asociación positiva con la variable dependiente, resultado contrario a lo esperado.

De esta forma, la inclusión de las nuevas variables no provocó un gran cambio en los modelos espaciales lo que puede ser explicado por el tipo de base de datos que se posee. La base de datos utilizada es de tipo transversal, resumiendo la información de toda la segunda ola en un solo instante de tiempo para cada unidad espacial. Para solucionarlo, se realiza la estimación de nuevos modelos que sí consideren temporalidad, es decir, a través de un análisis espacio-temporal utilizando un panel.

En este último punto se tomaron dos posibles procedimientos. En el primero solo se analizaron variables dinámicas, quedando excluidas las relativas a caracterización de las comunas, mediante modelos de efecto fijo. Estos modelos fueron corregidos porque presentaban dependencias espacio-temporales. Respecto a los coeficientes encontrados, en comparación con los modelos espaciales, las variables dinámicas son significativas de manera reiterada. De todas maneras, el comportamiento contraintuitivo de la variable porcentaje de vacunación con 2 dosis en los modelos de defunciones se mantuvo. Esto, como fue discutido, podría deberse a que primeramente se vacunó a población

adulta mayor que, intrínsecamente, tienen una mayor probabilidad de fallecer al padecer el virus.

Finalmente, se estimaron modelos de efecto aleatorio que permitieron conocer los coeficientes de las variables de caracterización comunal. Al igual que para los de efecto fijo, fue necesario corregir por dependencia espacio-temporal, además de realizar una simplificación de ellos. Los resultados son consistentes con los modelos anteriores dado que el comportamiento de las variables dinámicas es similar al observado en los de efecto fijo, y las variables relativas a las comunas mantienen las relaciones encontradas en los modelos espaciales.

En síntesis, simplificando los efectos del COVID-19 en dos grupos de variables dependientes, de casos y defunciones, se observa, de manera general, que las variables que tienen efectos positivos sobre los casos son densidad, mayores de 65 años, pobreza multidimensional, uso de transporte público, movilidad promedio en la semana, mujer y dificultad en la atención médica; aquellas que tienen efectos negativos son migrantes, niños, distancia al centro de salud, trabajo por cuenta propia, porcentaje de vacunación con 2 dosis, áreas verdes y factor riesgo COVID-19. En cuanto a defunciones, las variables que afectan de manera positiva son densidad, mayores de 65 años, pobreza multidimensional, uso de transporte público, movilidad promedio en la semana, factor riesgo COVID-19, incidencia acumulada ajustada de casos, trabajo por cuenta propia, niños y seguro de salud pública; y las que tienen una relación negativa son migrantes, niños, mujer, ruralidad, oportunidad en la notificación, disponibilidad de agua y pobreza de ingresos.

Es necesario considerar que el presente análisis tiene una serie de limitantes que pueden afectar los resultados encontrados, entre ellos que la elección de las variables independientes no es sencilla. Pueden presentarse problemas de endogeneidad o de variables omitidas relevantes, ya sea porque son difíciles de observar o de incluir en el estudio. Por otro lado, la variable para reflejar la trazabilidad durante la pandemia, oportunidad en la notificación, puede no ser la más adecuada y sería interesante abordar otras posibles medidas para ella, como razón por contactos. Respecto a la vacunación y la reiterada presentación de resultados contraintuitivos para los modelos de defunciones, se podrían generar modelos alternativos de tipo Poisson donde la variable dependiente de defunción este estandarizada por edad para corroborar el efecto de la vacunación. De todas formas, la presente investigación representa un avance en el análisis de factores que inciden en los impactos del COVID-19 en Chile considerando los componentes de espacialidad y temporalidad como relevantes, y entrega sólidos resultados.

7. Bibliografía

- Acevedo, I., & Ermilson, V. (2008). Algunos conceptos de la econometría espacial y el análisis exploratorio de datos espaciales. *Ecos de Economía*, 12(27), 9–34. <https://www.redalyc.org/pdf/3290/329027263007.pdf>
- Adin, A. (2019). Análisis espacio-temporal de datos de área: aplicaciones en epidemiología. https://seminariomirianandres.unirioja.es/wp-content/uploads/2019/05/si_ma20190527_04.pdf
- Agha, B., Gallo, L., & Lionel, V. (s. f.). Spatial econometrics on panel data (pp. 180–194).
- Anselin, L. (2001). Spatial Econometrics. En B.H Baltagi (Ed.), *A Companion to Theoretical Econometrics* (Wiley-Blac, pp. 310–331).
- Anselin, L. (2005). *Exploring Spatial Data with GeoDaTM: A Workbook*.
- Anselin, L. (2019). A Local Indicator of Multivariate Spatial Association: Extending Geary's c. *Geographical Analysis*, 51(2), 133–150. <https://doi.org/10.1111/gean.12164>
- Anselin, L. (2021). Spatial Models in Econometric Research. <https://doi.org/10.13140/RG.2.2.26447.20641>
- Ayala, A., Villalobos Dintrans, P., Elorrieta, F., Castillo, C., Vargas, C., & Maddaleno, M. (2021). Identification of COVID-19 Waves: Considerations for Research and Policy. *International Journal of Environmental Research and Public Health*, 18(21), 11058. <https://doi.org/10.3390/ijerph182111058>
- Baltagi, Badi H., Heun Song, S., Cheol Jung, B., & Koh, W. (2007). Testing for serial correlation, spatial autocorrelation and random effects using panel data. *Journal of Econometrics*, 140(1), 5–51. <https://doi.org/10.1016/j.jeconom.2006.09.001>
- Baltagi, Badi H., Song, S. H., & Koh, W. (2003). Testing panel data regression models with spatial error correlation. *Journal of Econometrics*, 117(1), 123–150. [https://doi.org/10.1016/S0304-4076\(03\)00120-9](https://doi.org/10.1016/S0304-4076(03)00120-9)
- Baronio, A., Vianco, A. M., & Rabanal, C. (2018). Una introducción a la econometría espacial. https://www.researchgate.net/publication/328812646_UNA_INTRODUCCION_A_LA_ECONOMETRIA_ESPACIAL
- Buzai, G., & Montes, E. (2021). *Estadística Espacial: Fundamentos y aplicación con Sistemas de Información Geográfica* (1a ed.).

- Carracedo, P. (2017). Metodología espacio-temporal con datos de panel. Estudio de la mortalidad europea. Polit cnica de Val ncia.
- Carracedo, P., & Debon, A. (2017). Selecci n de Modelos Espacio-Temporales con Datos de Panel en MATLAB y R. *Revista Electr nica de Comunicaciones y Trabajos de ASEPUMA*, 18(1), 93–118. https://www.researchgate.net/publication/324508254_Seleccion_de_modelos_espacio-temporales_con_datos_de_panel_en_Matlab_y_R
- Castillo, C., Villalobos Dintrans, P., & Maddaleno, M. (2021). The successful COVID-19 vaccine rollout in Chile: factors and challenges. *Vaccine: X*, 100114. <https://doi.org/10.1016/j.jvacx.2021.100114>
- Castro, M., Foster, W., & Ortega, J. (2015). An lisis de Correlaci n Espacial en el Precio de la Tierra de uso Agr cola en Chile periodo 2000-2008. <http://ru.iiec.unam.mx/2943/1/Eje5-242-Castro-Foster-Ortega.pdf>
- Chowell, G., Rothenberg, R., Roosa, K., Tariq, A., Hyman, J. M., & Luo, R. (2020). Sub-epidemic model forecasts for COVID-19 pandemic spread in the USA and European hotspots, February-May 2020. *medRxiv*, 2020.07.03.20146159. <https://doi.org/10.1101/2020.07.03.20146159>
- Comisi n Econ mica para America Latina y el Caribe (CEPAL). (2018). Panorama Social de Am rica Latina. <https://www.docdroid.net/5ztkWv0/informe-de-la-cepal-pdf>
- Departamento de Estad sticas e Informaci n de la Salud (DEIS). (2022). Sistemas de Informaci n Abiertos: Defunciones por Causa (actualizaci n semanal). <https://deis.minsal.cl/#datosabiertos>
- Getis, A. (2010). Spatial Autocorrelation. En *Handbook of Applied Spatial Analysis* (pp. 255–278). Springer Berlin Heidelberg. https://doi.org/10.1007/978-3-642-03647-7_14
- Giraldo, R. (2002). Introducci n a la Geoestad stica: Teor a y Aplicaci n.
- Gobierno de Chile. (2022). Actualizaci n de la Estrategia Gradual “Paso a Paso nos cuidamos”. <http://www.seguridadciudadana.gob.cl/media/2021/01/210111-Actualizacion-Paso-a-Paso.pdf>
- Gobierno de Chile. (2022). Cifras Oficiales COVID-19. <https://www.gob.cl/coronavirus/cifrasoficiales/>
- Greene, W. (2010). MODELS FOR PANEL DATA. <http://pages.stern.nyu.edu/~wgreene/DiscreteChoice/Readings/Greene-Chapter-9.pdf>

- Hausman, J. A. (1978). Specification Tests in Econometrics. *Econometrica*, 46(6), 1251. <https://doi.org/10.2307/1913827>
- Hidalgo Bucheli, G. E. (2020). Uso del Índice de Moran y LISA para explicar el ausentismo electoral rural en Ecuador. *Revista Geográfica*, 160, 91–108. <https://doi.org/10.35424/regeo.160.2019.746>
- Jong, P., Sprenger, C., & Veen, F. (2010). On Extreme Values of Moran's I and Geary's c. *Geographical Analysis*, 16(1), 17–24. <https://doi.org/10.1111/j.1538-4632.1984.tb00797.x>
- Kleiber, C., & Zeileis, A. (2008). *Applied Econometrics with R*. Springer New York. <https://doi.org/10.1007/978-0-387-77318-6>
- Koh, W., Cheol Jung, B., Baltagi, B. H., & Heun Song, S. (2004). Testing for Serial Correlation, Spatial Autocorrelation and Random Effects. https://www.researchgate.net/publication/4812897_Testing_for_Serial_Correlation_Spatial_Autocorrelation_and_Random_Effects
- Mas, J.-F. (2018). *Análisis espacial con R: Usa R como un Sistema de Información Geográfica*. European Scientific Institute. <https://eujournal.org/files/journals/1/books/JeanFrancoisMas.pdf>
- Millo, G. (2014). Maximum likelihood estimation of spatially and serially correlated panels with random effects. *Computational Statistics & Data Analysis*, 71, 914–933. <https://doi.org/10.1016/j.csda.2013.07.024>
- Millo, G. (2016). Testing for Serial Correlation in Spatial Panels. <https://www.siecon.org/sites/siecon.org/files/oldfiles/uploads/2016/09/MILLO.pdf>
- Millo, G. (2018). Cross-sectional and Spatial Dependence in Panels. <https://www.r-project.org/conferences/useR-2008/slides/Millo.pdf>
- Millo, G., & Piras, G. (2012). splm: Spatial Panel Data Models in R. *Journal of statistical software*, 47(1), 1–38. https://www.researchgate.net/publication/260298189_splm_Spatial_Panel_Data_Models_in_R
- MinCiencia. (2022). Base de Datos COVID-19. <https://www.minciencia.gob.cl/covid19/>
- Ministerio de Desarrollo Social y Familia. (2017). Encuesta de caracterización socio-económica nacional (CASEN). <http://observatorio.ministeriodesarrollosocial.gob.cl/encuesta-casen-2017>
- Morales-Oñate, V. (2018). Un recorrido por la estadística espacial. <https://doi.org/10.>

13140/RG.2.2.32041.65122

Moreno, R., & Vayá, E. (2002). Econometría espacial: nuevas técnicas para el análisis regional. Una aplicación a las regiones europeas. *Journal of Regional Research*, 1, 83–106. <https://www.redalyc.org/articulo.oa?id=28900104>

Mutl, J., & Pfaffermayr, M. (2011). The Hausman test in a Cliff and Ord panel model. *The Econometrics Journal*, 14(1), 48–76. <https://doi.org/10.1111/j.1368-423X.2010.00325.x>

Organización Mundial de la Salud (OMS). (2020). COVID-19: cronología de la actuación de la OMS. <https://www.who.int/es/news/item/27-04-2020-who-timeline---covid-19>

Organización Mundial de la Salud (OMS). (2021). Eficacia teórica, eficacia real y protección de las vacunas. <https://www.who.int/es/news-room/feature-stories/detail/vaccine-efficacy-effectiveness-and-protection>

Organización Mundial de la Salud (OMS). (2022a). Coronavirus Disease (COVID-19): Weekly Epidemiological Update (02 May 2022). <https://www.who.int/publications/m/item/weekly-epidemiological-update-on-covid-19---27-april-2022>

Organización Mundial de la Salud (OMS). (2022b). WHO Coronavirus (COVID-19) Dashboard. <https://covid19.who.int/table>

Paelinck, J., Mur, J., & Trávez, F. J. (2015). Modelos para datos espaciales con estructura transversal o de panel. Una revisión. 33(1), 7–30. <https://www.redalyc.org/articulo.oa?id=30133775001>

Peréz, J. (2016). Econometría espacial y ciencia regional. *Investigación Económica*, 129–160. <https://www.redalyc.org/articulo.oa?id=60125804>

Polo, M. (2017). Trabajo Monográfico Descripción Metodológica del Modelo Espacial Autorregresivo en el Error. <https://1library.co/document/q51m49ry-descripcion-metodologica-modelo-espacial-autorregresivo-error.html>

R Core Team. (2020). R: A language and environment for statistical computing. <https://www.r-project.org/>

Raifman, M. A., & Raifman, J. R. (2020). Disparities in the Population at Risk of Severe Illness From COVID-19 by Race/Ethnicity and Income. *American Journal of Preventive Medicine*, 59(1), 137–139. <https://doi.org/10.1016/j.amepre.2020.04.003>

Sabatini, F., Cáceres, G., & Cerda, J. (2021). Segregación residencial en las principales ciudades chilenas: Tendencias de las tres últimas décadas y posibles cursos de acción. 27(1), 21–42.

Srinivasan, S. (2008). Spatial Regression Models. En Encyclopedia of GIS (pp. 1102–1105). Springer US. https://doi.org/10.1007/978-0-387-35973-1_1294

Su, D., Chen, Y., He, K., Zhang, T., Tan, M., Zhang, Y., & Zhang, X. (2020). Influence of socio-ecological factors on COVID-19 risk: a cross-sectional study based on 178 countries/regions worldwide. medRxiv, 2020.04.23.20077545. <https://doi.org/10.1101/2020.04.23.20077545>

Villalobos Dintrans, P., Castillo, C., de la Fuente, F., & Maddaleno, M. (2021). COVID-19 incidence and mortality in the Metropolitan Region, Chile: Time, space, and structural factors. PLOS ONE, 16(5), e0250707. <https://doi.org/10.1371/journal.pone.0250707>

Ward, M., & Gleditsch, K. (2018). Spatial Regression Models. (2a ed.). housand Oaks: Sage.

Wooldridge, J. M. (2002). Econometric Analysis of Cross Section and Panel Data. MIT Press.

Wooldridge, J. M. (2009). Introductory Econometrics A Modern Approach. https://economics.ut.ac.ir/documents/3030266/14100645/Jeffrey_M._Wooldridge_Introductory_Econometrics_A_Modern_Approach__2012.pdf

8. Anexo

8.1. Periodos de estudio por comuna

Se presentan las fechas de inicio y fin de la segunda ola por comuna.

Tabla 28: Periodos de estudio por comuna.


Comuna	Inicio segunda ola	Fin segunda ola
Santiago	03-01-2021 (Sem. 1 del 2021)	17-07-2021 (Sem. 28 del 2021)
Cerrillos	17-01-2021 (Sem. 3 del 2021)	24-07-2021 (Sem. 29 del 2021)
Cerro Navia	03-01-2021 (Sem. 1 del 2021)	31-07-2021 (Sem. 30 del 2021)
Conchalí	07-02-2021 (Sem. 6 del 2021)	31-07-2021 (Sem. 30 del 2021)
El Bosque	03-01-2021 (Sem. 1 del 2021)	31-07-2021 (Sem. 30 del 2021)
Estación Central	17-01-2021 (Sem. 3 del 2021)	17-07-2021 (Sem. 28 del 2021)
Huechuraba	14-02-2021 (Sem. 7 del 2021)	17-07-2021 (Sem. 28 del 2021)
Independencia	14-02-2021 (Sem. 7 del 2021)	24-07-2021 (Sem. 29 del 2021)
La Cisterna	31-01-2021 (Sem. 5 del 2021)	17-07-2021 (Sem. 28 del 2021)
La Florida	03-01-2021 (Sem. 1 del 2021)	24-07-2021 (Sem. 29 del 2021)
La Granja	10-01-2021 (Sem. 2 del 2021)	24-07-2021 (Sem. 29 del 2021)
La Pintana	03-01-2021 (Sem. 1 del 2021)	31-07-2021 (Sem. 30 del 2021)
La Reina	28-02-2021 (Sem. 9 del 2021)	24-07-2021 (Sem. 29 del 2021)
Las Condes	28-02-2021 (Sem. 9 del 2021)	10-07-2021 (Sem. 27 del 2021)
Lo Barnechea	28-02-2021 (Sem. 9 del 2021)	24-07-2021 (Sem. 29 del 2021)
Lo Espejo	17-01-2021 (Sem. 3 del 2021)	17-07-2021 (Sem. 28 del 2021)
Lo Prado	27-12-2020 (Sem. 53 del 2020)	07-08-2021 (Sem. 31 del 2021)
Macul	14-02-2021 (Sem. 7 del 2021)	17-07-2021 (Sem. 28 del 2021)
Maipú	21-02-2021 (Sem. 8 del 2021)	17-07-2021 (Sem. 28 del 2021)
Ñuñoa	21-02-2021 (Sem. 8 del 2021)	10-07-2021 (Sem. 27 del 2021)
Pedro Aguirre Cerda	17-01-2021 (Sem. 3 del 2021)	24-07-2021 (Sem. 29 del 2021)
Peñalolén	21-02-2021 (Sem. 8 del 2021)	24-07-2021 (Sem. 29 del 2021)
Providencia	28-02-2021 (Sem. 9 del 2021)	10-07-2021 (Sem. 27 del 2021)
Pudahuel	27-12-2020 (Sem. 53 del 2020)	24-07-2021 (Sem. 29 del 2021)
Quilicura	28-02-2021 (Sem. 9 del 2021)	24-07-2021 (Sem. 29 del 2021)
Quinta Normal	27-12-2020 (Sem. 53 del 2020)	21-08-2021 (Sem. 33 del 2021)
Recoleta	21-02-2021 (Sem. 8 del 2021)	17-07-2021 (Sem. 28 del 2021)
Renca	27-12-2020 (Sem. 53 del 2020)	31-07-2021 (Sem. 30 del 2021)
San Joaquín	27-12-2020 (Sem. 53 del 2020)	24-07-2021 (Sem. 29 del 2021)
San Miguel	13-12-2020 (Sem. 51 del 2020)	17-07-2021 (Sem. 28 del 2021)
San Ramón	28-02-2021 (Sem. 9 del 2021)	24-07-2021 (Sem. 29 del 2021)
Vitacura	28-02-2021 (Sem. 9 del 2021)	10-07-2021 (Sem. 27 del 2021)
Puente Alto	27-12-2020 (Sem. 53 del 2020)	24-07-2021 (Sem. 29 del 2021)
Pirque	13-12-2020 (Sem. 51 del 2020)	17-07-2021 (Sem. 28 del 2021)
San José de Maipo	21-02-2021 (Sem. 8 del 2021)	24-07-2021 (Sem. 29 del 2021)

Continúa la tabla...


Comuna	Inicio segunda ola	Fin segunda ola
Colina	14-02-2021 (Sem. 7 del 2021)	24-07-2021 (Sem. 29 del 2021)
Lampa	21-02-2021 (Sem. 8 del 2021)	24-07-2021 (Sem. 29 del 2021)
Tiltil	10-01-2021 (Sem. 2 del 2021)	31-07-2021 (Sem. 30 del 2021)
San Bernardo	10-01-2021 (Sem. 2 del 2021)	24-07-2021 (Sem. 29 del 2021)
Buín	03-01-2021 (Sem. 1 del 2021)	07-08-2021 (Sem. 31 del 2021)
Calera de Tango	21-02-2021 (Sem. 8 del 2021)	31-07-2021 (Sem. 30 del 2021)
Paine	10-01-2021 (Sem. 2 del 2021)	24-07-2021 (Sem. 29 del 2021)
Melipilla	07-02-2021 (Sem. 6 del 2021)	24-07-2021 (Sem. 29 del 2021)
Alhué	21-03-2021 (Sem. 12 del 2021)	04-09-2021 (Sem. 35 del 2021)
Curacaví	28-02-2021 (Sem. 9 del 2021)	24-07-2021 (Sem. 29 del 2021)
María Pinto	17-01-2021 (Sem. 3 del 2021)	31-07-2021 (Sem. 30 del 2021)
San Pedro	14-02-2021 (Sem. 7 del 2021)	28-08-2021 (Sem. 34 del 2021)
Talagante	21-02-2021 (Sem. 8 del 2021)	24-07-2021 (Sem. 29 del 2021)
El Monte	28-02-2021 (Sem. 9 del 2021)	24-07-2021 (Sem. 29 del 2021)
Isla de Maipo	10-01-2021 (Sem. 2 del 2021)	24-07-2021 (Sem. 29 del 2021)
Padre Hurtado	07-02-2021 (Sem. 6 del 2021)	14-08-2021 (Sem. 32 del 2021)
Peñaflor	21-02-2021 (Sem. 8 del 2021)	24-07-2021 (Sem. 29 del 2021)

8.2. Gráficos de distribución espacial


Se presentan las distribuciones espaciales para todas variables independientes faltantes (para los datos de corte transversal).




(a) Porcentaje mujeres




(b) Porcentaje niños




(c) Porcentaje +65




(d) Porcentaje +80




(e) Porcentaje migrantes




(f) Años de educación




(g) Porcentaje ruralidad




(h) Pobreza multidimensional




(i) Pobreza ingresos




(j) Porcentaje sin hacinamiento




(k) Porcentaje hacinamiento crítico




(l) Trabajo por cuenta propia




(m) Días en cuarentena




(n) Uso transporte público




(ñ) Disponibilidad agua




(o) Seguro de salud público




(p) Dificultad atención médica




(q) Distancia centro de salud




(r) Factor riesgo COVID-19




(s) Mov. promedio (semana)




(t) Mov. promedio (fin de semana)



(u) Porcentaje 1° dosis



(v) Porcentaje 2° dosis




(w) Oportunidad notificación


Figura 28: Distribución espacial de variables independientes faltantes.

Fuente: Elaboración propia


8.3. Gráficos Clusters I de Moran Local

Se presentan los clusters encontrados mediante el indicador I de Moran local (a una significancia del 5%).







(e) Porcentaje migrantes




(f) Años de educación




(g) Porcentaje ruralidad




(h) Pobreza multidimensional




(i) Pobreza ingresos




(j) Porcentaje sin hacinamiento




(k) Porcentaje hacinamiento crítico




(l) Trabajo por cuenta propia




(m) Días en cuarentena




(n) Uso transporte público




(ñ) Disponibilidad agua




(o) Seguro de salud público




(p) Dificultad atención médica




(q) Distancia centro de salud




(r) Factor riesgo COVID-19



(s) Mov. promedio (fin de semana)



(t) Mov. promedio (semana)



(u) Porcentaje 1° dosis




Figura 29: Clusters I de Moran local.

8.4. Correlación variables (base transversal)

Tabla 29: Correlaciones variables (base transversal)

CORRELACIÓN	Inci. acum. ajus.(casos)	Inci. acum.(casos)	Inci. acum. ajus.(defun)	Inci. acum. (defun)	Mov. prom semana
Inci. acum. ajus.(casos)	1	-	-	-	-
Inci. acum.(casos)	0.79	1	-	-	-
Inci. acum. ajus.(defun)	0.43	0.23	1	-	-
Inci. acum. (defun)	0.51	0.56	0.89	1	-
Mov. prom semana	0.31	0.34	0.27	0.36	1
Mov. prom fin semana	0.26	0.29	0.22	0.3	0.95
Días cuarentena	0.73	0.8	0.33	0.54	0.49
Porcentaje 1° dosis	-0.27	-0.02	-0.06	0.03	-0.26
Porcentaje 2° dosis	-0.43	-0.44	-0.11	-0.24	-0.37
Opor. notificación	0.65	0.62	0.38	0.48	0.24
Mujer	0.01	0.04	-0.12	-0.08	0.01
Niños	0.05	0.07	-0.07	-0.02	0.41
Mayores 65	0.08	0.01	0.22	0.17	-0.27
Mayores 80	-0.12	-0.16	0.05	-0.00	-0.18
Densidad	-0.02	0.09	0.23	0.31	0.32
Ruralidad	0.04	0.03	-0.14	-0.15	-0.26
Pobreza Ingresos	0.5	0.56	0.11	0.27	0.22
Pobreza mult.	0.54	0.57	0.36	0.5	0.23
Sin haci.	-0.22	-0.3	-0.23	-0.34	-0.34
Haci. crít	-0.03	0.14	0.1	0.23	-0.02
Áreas verdes	-0.43	-0.49	-0.2	-0.33	-0.22
Años de educa.	-0.61	-0.58	-0.24	-0.37	-0.19
Migrantes	-0.21	-0.17	-0.13	-0.15	0.08
Trabajo cuenta propia	-0.12	-0.13	0.2	0.17	-0.01
Transporte público	0.12	0.2	0.25	0.32	0.41
Disponibilidad agua	0.07	-0.00	-0.21	-0.24	-0.1
Seguro de salud público	0.62	0.64	0.34	0.48	0.28
Dificultad atención	-0.02	0.12	0.06	0.16	0.06
Dist. centro salud	-0.08	0.02	0.16	0.2	0.19
Factor riesgo COVID	0.32	0.30	0.34	0.37	-0.04

Continúa la tabla (1/5)

CORRELACIÓN	Mov. prom fin semana	Días cuarentena	Porcentaje 1° dosis	Porcentaje 2° dosis	Opor. notificación
Inci. acum. ajus.(casos)	-	-	-	-	-
Inci. acum.(casos)	-	-	-	-	-
Inci. acum. ajus.(defun)	-	-	-	-	-
Inci. acum. (defun)	-	-	-	-	-
Mov. prom semana	-	-	-	-	-
Mov. prom fin semana	1	-	-	-	-
Días cuarentena	0.45	1	-	-	-
Porcentaje 1° dosis	-0.23	-0.22	1	-	-
Porcentaje 2° dosis	-0.32	-0.57	0.8	1	-
Opor. notificación	0.26	0.68	-0.12	-0.36	1
Mujer	0.15	0.08	0.02	0.07	0.17
Niños	0.41	0.22	-0.2	-0.21	0.2
Mayores 65	-0.21	-0.1	0.36	0.43	-0.01
Mayores 80	-0.12	-0.11	0.17	0.26	-0.09
Densidad	0.43	0.08	-0.02	-0.15	0.1
Ruralidad	-0.4	0.03	0.13	0.19	0.07
Pobreza Ingresos	0.12	0.49	-0.25	-0.49	0.42
Pobreza mult.	0.14	0.59	-0.28	-0.55	0.56
Sin haci.	-0.33	-0.35	0.32	0.49	-0.3
Haci crít	0.01	0.1	-0.01	-0.23	0.2
Áreas verdes	-0.16	-0.48	0.19	0.41	-0.35
Años de educa.	-0.05	-0.6	0.35	0.58	-0.48
Migrantes	0.11	-0.22	-0.13	-0.09	-0.07
Trabajo cuenta propia	0.1	-0.12	-0.16	-0.05	0.1
Transporte público	0.49	0.2	-0.23	-0.39	0.22
Disponibilidad agua	-0.05	-0.21	-0.09	-0.05	-0.08
Seguro de salud público	0.12	0.65	-0.32	-0.61	0.54
Dificultad atención	0.12	0.13	-0.03	-0.1	0.16
Dist. centro salud	0.29	-0.07	-0.01	-0.04	-0.18
Factor riesgo COVID	-0.11	0.36	-0.03	-0.14	0.30

Continúa la tabla (2/5)

CORRELACIÓN	Mujer	Niños	Mayores 65	Mayores 80	Densidad	Ruralidad	Pobreza Ingresos
Inci. acum. ajus.(casos)	-	-	-	-	-	-	-
Inci. acum.(casos)	-	-	-	-	-	-	-
Inci. acum. ajus.(defun)	-	-	-	-	-	-	-
Inci. acum. (defun)	-	-	-	-	-	-	-
Mov. prom semana	-	-	-	-	-	-	-
Mov. prom fin semana	-	-	-	-	-	-	-
Días cuarentena	-	-	-	-	-	-	-
Porcentaje 1° dosis	-	-	-	-	-	-	-
Porcentaje 2° dosis	-	-	-	-	-	-	-
Opor. notificación	-	-	-	-	-	-	-
Mujer	1	-	-	-	-	-	-
Niños	0.14	1	-	-	-	-	-
Mayores 65	0.13	-0.19	1	-	-	-	-
Mayores 80	0.23	-0.19	0.57	1	-	-	-
Densidad	0.16	0.23	-0.09	0.02	1	-	-
Ruralidad	-0.23	-0.01	0.17	0.17	-0.57	1	-
Pobreza Ingresos	-0.05	0.06	0.03	-0.14	-0.07	0.2	1
Pobreza mult.	-0.13	0.12	-0.01	-0.12	-0.13	0.25	0.72
Sin haci.	-0.00	-0.31	0.31	0.35	-0.35	0.28	-0.47
Haci. crít	0.08	0.25	-0.16	-0.31	0.32	-0.3	0.16
Áreas verdes	0.13	-0.11	0.12	0.06	-0.14	-0.2	-0.36
Años de educa.	0.18	-0.2	0.04	0.21	0.31	-0.34	-0.68
Migrantes	-0.06	0.21	-0.4	-0.18	0.59	-0.22	-0.01
Trabajo cuenta propia	0.21	-0.09	0.26	0.28	0.02	-0.25	0.06
Transporte público	0.25	0.23	-0.36	-0.27	0.72	-0.72	0.04
Disponibilidad agua	-0.09	-0.26	-0.08	-0.15	-0.04	-0.37	-0.05
Seguro de salud público	-0.18	0.16	-0.09	-0.21	-0.18	0.32	0.73
Dificultad atención	0.06	0.16	0.26	0.36	0.11	0.18	0.12
Dist. centro salud	0.16	-0.05	-0.03	-0.16	0.55	-0.73	-0.07
Factor riesgo COVID	-0.03	-0.19	0.52	0.36	-0.41	0.43	0.36

Continúa la tabla (3/5)

CORRELACIÓN	Pobreza mult.	Sin haci	Haci crít.	Áreas verdes	Años educa.	Migrantes	Trabajo cuenta propia
Inci. acum. ajus.(casos)	-	-	-	-	-	-	-
Inci. acum.(casos)	-	-	-	-	-	-	-
Inci. acum. ajus.(defun)	-	-	-	-	-	-	-
Inci. acum. (defun)	-	-	-	-	-	-	-
Mov. prom semana	-	-	-	-	-	-	-
Mov. prom fin semana	-	-	-	-	-	-	-
Días cuarentena	-	-	-	-	-	-	-
Porcentaje 1° dosis	-	-	-	-	-	-	-
Porcentaje 2° dosis	-	-	-	-	-	-	-
Opor. notificación	-	-	-	-	-	-	-
Mujer	-	-	-	-	-	-	-
Niños	-	-	-	-	-	-	-
Mayores 65	-	-	-	-	-	-	-
Mayores 80	-	-	-	-	-	-	-
Densidad	-	-	-	-	-	-	-
Ruralidad	-	-	-	-	-	-	-
Pobreza Ingresos	-	-	-	-	-	-	-
Pobreza mult.	1	-	-	-	-	-	-
Sin haci.	-0.49	1	-	-	-	-	-
Haci. crít.	0.23	-0.54	1	-	-	-	-
Áreas verdes	-0.29	0.1	-0.03	1	-	-	-
Años educa.	-0.88	0.43	-0.14	0.32	1	-	-
Migrantes	-0.2	-0.38	0.38	-0.09	0.31	1	-
Trabajo cuenta propia	0.14	-0.07	0.07	0.28	0.1	-0.1	1
Transporte público	-0.03	-0.46	0.47	-0.11	0.14	0.53	0.13
Disponibilidad agua	-0.2	0.14	-0.12	0.17	0.21	0.05	0.15
Seguro de salud público	0.84	-0.5	0.21	-0.41	-0.93	-0.16	-0.09
Dificultad atención	0.14	-0.05	0.1	0.02	-0.03	0	0.35
Dist. centro salud	-0.18	-0.37	0.19	0.09	0.21	0.22	-0.01
Factor riesgo COVID	0.48	0.09	-0.13	-0.26	-0.53	-0.59	0.18

Continúa la tabla (4/5)


CORRELACIÓN	Transporte público	Dispo. agua	Seguro de salud públi.	Dificultad atención	Dist. centro salud	Factor riesgo COVID
Inci. acum. ajus.(casos)	-	-	-	-	-	-
Inci. acum.(casos)	-	-	-	-	-	-
Inci. acum. ajus.(defun)	-	-	-	-	-	-
Inci. acum. (defun)	-	-	-	-	-	-
Mov. prom semana	-	-	-	-	-	-
Mov. prom fin semana	-	-	-	-	-	-
Días cuarentena	-	-	-	-	-	-
Porcentaje 1° dosis	-	-	-	-	-	-
Porcentaje 2° dosis	-	-	-	-	-	-
Opor. notificación	-	-	-	-	-	-
Mujer	-	-	-	-	-	-
Niños	-	-	-	-	-	-
Mayores 65	-	-	-	-	-	-
Mayores 80	-	-	-	-	-	-
Densidad	-	-	-	-	-	-
Ruralidad	-	-	-	-	-	-
Pobreza Ingresos	-	-	-	-	-	-
Pobreza mult.	-	-	-	-	-	-
Sin haci.	-	-	-	-	-	-
Haci. crítico	-	-	-	-	-	-
Áreas verdes	-	-	-	-	-	-
Años educa.	-	-	-	-	-	-
Migrantes	-	-	-	-	-	-
Trabajo cuenta propia	-	-	-	-	-	-
Transporte público	1	-	-	-	-	-
Dispo. agua	0.12	1	-	-	-	-
Seguro de salud público	0.02	-0.25	1	-	-	-
Dificultad atención	0.05	-0.28	0.12	1	-	-
Dist. centro salud	0.56	0.07	-0.19	-0.22	1	-
Factor riesgo COVID	-0.39	-0.23	0.50	0.22	-0.29	1

Continúa la tabla (5/5)


8.5. Análisis de autocorrelación espacial en los residuos (efectos fijos iniciales)

En esta sección son presentados los gráficos para el análisis de autocorrelación espacial en los residuos, para los modelos de efecto fijo (modelos de defunciones).

1. Análisis de correlación espacial en residuos (modelo de defunciones con efecto Fijo n°1).




2. Análisis de correlación espacial en residuos (modelo de defunciones con efecto Fijo $n^{\circ}2$).




8.6. Análisis de autocorrelación espacial en los residuos (efectos fijos corregidos)

En esta sección son presentados los gráficos para el análisis de autocorrelación espacial en los residuos, para los modelos de efecto fijo corregidos (modelos de defunciones).

1. Análisis de correlación espacial en residuos (modelo de defunciones con efecto Fijo corregido n°1).




2. Análisis de correlación espacial en residuos (modelo de defunciones con efecto Fijo corregido n°2).




8.7. Análisis de autocorrelación espacial en los residuos (efectos aleatorios iniciales)

En esta sección son presentados los gráficos para el análisis de autocorrelación espacial en los residuos, para los modelos de efecto aleatorio (modelo de casos y defunciones).


1. Análisis de correlación espacial en residuos (modelo de casos con efecto aleatorio n°2).




2. Análisis de correlación espacial en residuos (modelo de defunciones con efecto aleatorio n°1).



3. Análisis de correlación espacial en residuos (modelo de defunciones con efecto aleatorio n°2).



4. Análisis de correlación espacial en residuos (modelo de defunciones con efecto aleatorio n°3).



5. Análisis de correlación espacial en residuos (modelo de defunciones con efecto aleatorio n°4).

