

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE CIENCIA
Departamento de Matemática y Ciencia de la Computación



Modelo de Predicción de la Demanda de Cemento para corto y largo plazo en Chile

Gerardo Darío Sepúlveda Barrera

Profesor guía: Felipe Elorrieta Lopez

Trabajo de titulación presentado a la Facultad de
Ciencia en cumplimiento parcial de los requisitos exi-
gidos para optar al título de Ingeniero Estadístico

Santiago, Chile

2016

Agradecimientos

En primer lugar, y como más importante, quisiera agradecer a mis padres Pedro Sepúlveda y Claudia Barrera, por estar siempre a mi lado desde el primer día de vida como un apoyo trascendental e incondicional durante toda mi existencia.

A Carla Lastra, quien es un gran pilar durante 4 de mis 5 años en ésta carrera, mostrando preocupación, apoyo y amor incondicional.

También mis hermanas, tías y amigos, que, indirectamente han sido un apoyo manifestando siempre su fe en mis capacidades.

A mi profesor guía Felipe Elorrieta, que no solo me asesoró durante estos meses aconsejándome y dándose el tiempo de compartir sus conocimientos durante las dificultades que surgieron, si no que además me ha dado mayor confianza en mis habilidades.

A Benjamín Araneda de Melón S.A., jefe directo en mi primer experiencia laboral, quien confió siempre en mis capacidades, mostró apoyo y me presentó éste gran desafío como proyecto de tesis.

A Pablo Torres de Melón S.A., quien estuvo siempre para ayudarme con el contexto del negocio del Cemento y, en más de alguna oportunidad, se dio el tiempo de aconsejarme sobre diversos ámbitos de la vida.

Por último, a mis compañeros de carrera. Patricio Canelo, Diego Salmerón, Seomara Palominos, Eduardo Salinas, Felipe Varas, Cindy Zuñiga, Barbara Oyaban y todos y cada uno de los que han compartido gratos momentos conmigo. Hicieron de ésta experiencia algo muy agradable.

Resumen

El objetivo principal consiste en utilizar técnicas de Series Temporales con el fin de pronosticar distintos elementos propios de la Empresa Melón S.A. para obtener, de ésta manera, una visión anticipada del Mercado y proponer planes de acción frente a éste.

Para ello, y en necesidad de la Empresa, éste trabajo se dividió en dos enfoques, uno Anual para la Demanda de Cemento Total de Chile y un grupo de Series Diarias Regionales, compuestas de los Despachos Diarios de Melón S.A.

En cuanto a la Serie Anual Total País, en primer lugar, se creó una Base de Datos con variables Macroeconómicas, cuyo detalle no es posible revelar en el presente trabajo debido a políticas de confidencialidad de Melón S.A., para así complementar el poder predictivo que tendría un Modelo de Serie de Tiempo. Se buscó una consolidación del Ajuste de Serie Temporal y la influencia de Variables Exógenas para anticipar quiebres en el Mercado como los ocurridos en 1999 y 2009.

Las Series Diarias, a su vez, se dividen en HPM (Hormigón Pre-Mezclado) y NHPM (No Hormigón Pre-Mezclado). La principal dificultad que éstas conllevan es la alta presencia de variabilidad, por lo que se propuso probar desde Modelos Lineales, Redes Neuronales Perceptrón Multi Capa hasta un híbrido de ARIMAX $\sim$ GARCH.

Finalmente, para la Serie Anual se logra implementar una variable que reduzca el margen de error del Modelo en años críticos como lo son 1999 y 2009 y, por otra parte, las Series Diarias obtuvieron un mejor resultado con los Modelos de la familia ARIMAX $\sim$ GARCH.

Declaración de Confidencialidad

El presente informe está orientado tanto a la Universidad como a Melón S.A., es por ello que existirán informaciones tal como el nombre de algunas variables, lugares, etc. que no podrán ser revelados debido a los intereses comprometidos que podría existir para con Melón S.A.

Por lo tanto, existirán algunas variables cuyo origen y características no es posible detallarlas públicamente.

Índice de figuras

1.1. Demanda de Cemento histórica.	7
1.2. Despachos Diarios de Cemento HPM RM.	9
1.3. Retornos Despachos Diarios de Cemento HPM RM.	10
1.4. Algoritmo Box-Jenkins.	16
2.1. Fuente: Brockwell (2002). Introduction Time Series and Forecasting [4]	31
2.2. Fuente: Administración de operaciones: estrategia y análisis. Facultad de Ciencias, Universidad Nacional de Colombia [7]	33
2.3. Fuente: Brockwell (2002). Introduction Time Series and Forecasting [4]	45
2.4. Fuente: Gras, A.J. (2001) <i>Diseños de series temporales: técnicas de análisis</i> . [13]	46
2.5. Red Neuronal	54
2.6. Esquema de aprendizaje supervisado	58
2.7. Imagen referencial Mapas de Kohonen	59
2.8. Imagen referencial de la retropropagación del error δ_1	60
2.9. Heterocedástico	65
2.10. Homocedástico	65
3.1. Fuente: Memorias Melon, Polpaico y Bío-Bío.	72
3.2. Fuente: Información Histórica de Melón S.A.	73
3.3. Correlaciones significativas con la Demanda Anual de Cemento.	74
3.4. Correlaciones Cruzadas Demanda de Cemento Anual.	75
3.5. Simbología.	76
3.6. Participación Regional Melón S.A.	77
3.7. 91 % de la Participación Regional Melón S.A.	78
3.8. Precipitaciones v/s Despachos de Melón S.A.	80

3.9. Variables independientes Serie diaria.	81
4.1. Ajuste ARIMAX Serie Anual.	85
4.2. Ajuste ARIMAX Seleccionado	86
4.3. Predicción 2016-2017 ARIMAX.	88
4.4. Escenarios Forecast.	89
4.5. Ajuste Serie del Logaritmo RM HPM	93
4.6. Ajuste de Validación Serie del Logaritmo RM HPM	94
4.7. Ajuste Serie Original HPM RM.	95
4.8. Residuos estandarizados GARCH RM HPM.	96
4.9. Desviación Estándar del Modelo GARCH.	97
4.10. Residuos Estandarizados Modelo GARCH.	97
4.11. Serie con Intervalo de 95 % de confianza Modelo GARCH.	98
4.12. Ajuste final ARIMAX GARCH RM HPM.	99
5.1. Cemento Mundial 1, McKinsey and Company, Inc.	103
5.2. Fuente: Elaboración propia en base a información de McKinsey and Company, Inc.	103
5.3. Fuente: Elaboración propia en base a información de McKinsey and Company, Inc.	104
5.4. Fuente: Elaboración propia en base a información de McKinsey and Company, Inc.	105
7.1. Comportamiento residual Modelo ARIMAX con variable Crisis incluída	112
7.2. Residuos I Región HPM.	115
7.3. Ajuste I Región HPM.	116
7.4. Varianza Condicional I Región HPM.	116
7.5. Residuos Estandarizados I Región HPM.	117
7.6. Ajuste ARMAX I Región HPM.	117
7.7. Serie con Intervalo de 95 % de confianza Modelo GARCH I HPM.	118
7.8. Ajuste ARMAX $\sim$ GARCH I HPM.	118
7.9. Residuos II Región HPM.	120
7.10. Ajuste II Región HPM.	120
7.11. Varianza Condicional II Región HPM.	121
7.12. Residuos Estandarizados II Región HPM.	121
7.13. Ajuste ARIMAX II Región HPM.	122
7.14. Serie con Intervalo de 95 % de confianza Modelo GARCH II HPM.	122

7.15. Ajuste ARIMAX $\sim$ GARCH II HPM.	123
7.16. Residuos IV Región HPM.	125
7.17. Ajuste IV Región HPM.	125
7.18. Varianza Condicional IV Región HPM.	126
7.19. Residuos Estandarizados IV Región HPM.	126
7.20. Ajuste ARMAX IV Región HPM.	127
7.21. Serie con Intervalo de 95 % de confianza Modelo GARCH IV HPM.	127
7.22. Ajuste ARMAX $\sim$ GARCH IV HPM.	128
7.23. Residuos V Región HPM.	130
7.24. Ajuste de Validación V Región HPM.	130
7.25. Ajuste ARMAX V Región HPM.	131
7.26. Varianza Condicional V HPM.	131
7.27. Residuos Estandarizados V Región HPM.	132
7.28. Serie con Intervalo de 95 % de confianza Modelo GARCH V HPM.	132
7.29. Ajuste ARMAX $\sim$ GARCH V HPM.	133
7.30. Residuos RM HPM.	135
7.31. Ajuste Validación Región Metropolitana HPM.	135
7.32. Ajuste Región Metropolitana HPM.	136
7.33. Desviación Estándar del Modelo GARCH.	136
7.34. Residuos Estandarizados Modelo GARCH.	137
7.35. Serie con Intervalo de 95 % de confianza Modelo GARCH RM HPM.	137
7.36. Ajuste final ARIMAX GARCH RM HPM.	138
7.37. Residuos VI Región HPM.	140
7.38. Ajuste de Validación VI Región HPM.	140
7.39. Ajuste ARIMAX VI Región HPM.	141
7.40. Varianza Condicional VI HPM.	141
7.41. Residuos Estandarizados VI Región HPM.	142
7.42. Serie con Intervalo de 95 % de confianza Modelo GARCH VI HPM.	142
7.43. Ajuste ARIMAX $\sim$ GARCH VI HPM.	143
7.44. Residuos X HPM.	145
7.45. Ajuste de Validación Log X Región HPM.	146
7.46. Ajuste ARIMAX X Región HPM.	146
7.47. Varianza Condicional X Región HPM.	147

7.48. Varianza Condicional X Región HPM.	147
7.49. Serie con Intervalo de 95 % de confianza Modelo GARCH X HPM.	148
7.50. Ajuste final ARIMAX GARCH X HPM.	148
7.51. Residuos IV Región NHPM.	150
7.52. Ajuste IV Región NHPM.	151
7.53. Varianza Condicional IV Región NHPM.	151
7.54. Residuos Estandarizados IV Región NHPM.	152
7.55. Ajuste ARIMAX IV Región NHPM.	152
7.56. Serie con Intervalo de 95 % de confianza Modelo GARCH IV HPM.	153
7.57. Ajuste ARIMAX $\sim$ GARCH IV HPM.	153
7.58. Residuos V Región NHPM.	155
7.59. Ajuste de Validación V Región NHPM.	156
7.60. Ajuste ARMAX V Región NHPM.	156
7.61. Varianza Condicional V NHPM.	157
7.62. Residuos Estandarizados V Región NHPM.	157
7.63. Serie con Intervalo de 95 % de confianza Modelo GARCH V NHPM.	158
7.64. Ajuste ARMAX $\sim$ GARCH V NHPM.	158
7.65. Residuos RM Región NHPM.	160
7.66. Ajuste RM NHPM.	161
7.67. Varianza Condicional RM NHPM.	161
7.68. Residuos Estandarizados RM NHPM.	162
7.69. Ajuste ARIMAX RM NHPM.	162
7.70. Serie con Intervalo de 95 % de confianza Modelo GARCH RM NHPM.	163
7.71. Ajuste Modelo ARIMAX $\sim$ GARCH RM NHPM.	163
7.72. Ajuste V Región NHPM.	164
7.73. Residuos VI Región NHPM.	166
7.74. Ajuste de Validación VI Región NHPM.	167
7.75. Ajuste ARIMAX VI Región NHPM.	167
7.76. Varianza Condicional VI NHPM.	168
7.77. Residuos Estandarizados VI Región NHPM.	168
7.78. Serie con Intervalo de 95 % de confianza Modelo GARCH VI NHPM.	169
7.79. Ajuste ARIMAX $\sim$ GARCH VI NHPM.	169
7.80. Residuos VIII Región NHPM.	171

7.81. Ajuste de Validación VIII Región NHPM.	171
7.82. Ajuste ARIMAX VIII Región NHPM.	172
7.83. Varianza Condicional VIII NHPM.	172
7.84. Residuos Estandarizados VIII Región NHPM.	173
7.85. Serie con Intervalo de 95 % de confianza Modelo GARCH VIII NHPM.	173
7.86. Ajuste ARIMAX $\sim$ GARCH VIII NHPM.	174
7.87. Residuos Modelo IX Región NHPM.	176
7.88. Ajuste Validación IX Región NHPM.	177
7.89. Varianza Condicional IX Región NHPM.	177
7.90. Residuos Estandarizados IX Región NHPM.	178
7.91. Ajuste ARIMAX IX Región NHPM.	178
7.92. Serie con Intervalo de 95 % de confianza Modelo GARCH IX Región NHPM.	179
7.93. Ajuste ARIMAX $\sim$ GARCH IX Región NHPM.	179
7.94. Residuos Modelo X Región NHPM.	181
7.95. Ajuste Validación X Región NHPM.	182
7.96. Varianza Condicional X Región NHPM.	182
7.97. Residuos Estandarizados X Región NHPM.	183
7.98. Ajuste ARIMAX X Región NHPM.	183
7.99. Serie con Intervalo de 95 % de confianza Modelo GARCH X Región NHPM.	184
7.100Ajuste ARX $\sim$ GARCH X Región NHPM.	184

Índice general

Referencias	1
1. Introducción	2
1.1. Definición del Problema	4
1.1.1. Enfoque de la Empresa	4
1.1.2. Enfoque Estadístico	6
1.1.3. Serie Anual total País	7
1.1.4. Serie Diaria Región Metropolitana	9
1.1.5. Modelos a probar	11
1.2. Objetivos	14
1.3. Metodología	15
1.3.1. Procedimiento Box Jenkins	16
1.3.2. Resumen de Modelos a ajustar	19
2. Marco Teórico	20
2.1. Modelos lineales	20
2.1.1. Regresión Lineal	20
2.1.2. Estimación de Parámetros	21
2.1.3. Propiedades e interpretación de los estimadores	22
2.1.4. Bondad de ajuste del modelo	22
2.1.5. Coeficiente de determinación	24
2.1.6. Observaciones influyentes	24
2.1.7. Selección de modelos	26
2.2. Series de Tiempo	27
2.2.1. Componentes básicos de una serie de tiempo	27

2.2.2.	Clasificación de series de tiempo	28
2.2.3.	Proceso estocástico y estacionaridad	28
2.2.4.	Ruido Blanco	29
2.2.5.	Función de Autocovarianza	30
2.2.6.	Función de Autocorrelación	31
2.2.7.	Función de Correlación Cruzada	32
2.2.8.	Modelo AR	35
2.2.9.	Modelo MA	35
2.2.10.	Modelo ARMA	36
2.2.11.	Representaciones $MA(\infty)$ y $AR(\infty)$	36
2.2.12.	Teorema de proyección	37
2.2.13.	Estimación para modelos ARMA	39
2.2.14.	Identificación de Modelos	41
2.2.15.	Diferenciación	41
2.2.16.	Modelo ARIMA	41
2.2.17.	Modelo SARIMA	42
2.2.18.	Estrategia de Predicción	43
2.2.19.	Análisis Espectral	43
2.3.	Modelo ARIMAX	46
2.4.	Modelo ARCH	47
2.4.1.	Modelo de Regresión	47
2.4.2.	Supuestos	48
2.4.3.	Función de Verosimilitud	49
2.5.	Modelo GARCH	51
2.5.1.	Estimación de Parámetros.	52
2.6.	Redes Neuronales	53
2.6.1.	Introducción	53
2.6.2.	Estructura	54
2.6.3.	Aprendizaje	58
2.6.4.	Algoritmo de Retropropagación o Backpropagation	60
2.7.	Análisis y diagnóstico de Modelos	64
2.7.1.	Diagnostico en Regresión Lineal	64
2.7.2.	Test de Dickey-Fuller	67
2.7.3.	Test de Ljung-Box	69
2.7.4.	Error Medio Absoluto Porcentual	70

2.7.5. Error Cuadrático Medio de Predicción	71
3. Análisis preliminares	72
3.1. Resumen Descriptivo	72
3.1.1. Serie Anual	72
3.1.2. Serie Diaria	77
4. Modelos	83
4.1. Modelo Anual	83
4.1.1. Pronósticos	88
4.1.2. Conclusiones y Predicción Modelo Anual	90
4.2. Modelos de Despachos diarios	91
4.2.1. Modelamiento GARCH	96
4.2.2. Conclusiones Modelo Diario	101
5. Cemento Mundial	102
5.1. McKinsey and Company	102
5.1.1. Segmentación del Cemento Mundial	103
5.2. Chile	105
5.3. Conclusiones Cemento Mundial	106
6. Conclusiones	107
6.1. Modelo Anual	107
6.2. Modelos Diarios	108
6.3. Cemento Mundial	108
Bibliografía	109
7. Anexos	111
7.1. Resumen Modelos Por Canal de Venta	113
7.2. Hormigón Pre-Mezclado	114
7.2.1. I Región	114
7.2.2. II Región	119
7.2.3. IV Región	123
7.2.4. V Región	128
7.2.5. Región Metropolitana.	133
7.2.6. VI Región	139
7.2.7. X Región	144

7.3. No Hormigón Pre-Mezclado	149
7.3.1. IV Región.	149
7.3.2. V Región	154
7.3.3. Región Metropolitana.	159
7.3.4. VI Región	165
7.3.5. VIII Región	170
7.3.6. IX Región	175
7.3.7. X Región	180

Índice de cuadros

2.1. Fuente: Brockwell (2002). Introduction Time Series and Forecasting [4]	41
3.1. Promedio Despachos de Cemento con y sin lluvia.	80
3.2. Puntajes por día Series diarias HPM.	82
3.3. Puntajes por día Series diarias NHPM.	82
4.1. Resumen diagnóstico de Modelos Serie Anual.	84
4.2. Resumen Supuestos Residuales Serie Anual.	84
4.3. Coeficientes Modelo ARIMAX Anual.	87
4.4. My caption	91
4.5. Resumen Modelos de Despachos Diarios RM HPM.	91
4.6. Supuestos Residuales Modelos Diarios RM HPM.	92
4.7. Tabla Modelo ARIMAX RM HPM.	93
4.8. Test Ljung-Box sobre Residuos RM HPM.	96
4.9. Coeficientes GARCH RM HPM	99
4.10. Modelo ARIMAX $\sim$ GARCH RM HPM.	100
7.1. Resumen de Ajustes según MAPE.	111
7.2. Resumen Modelos Diarios NHPM	113
7.3. Resumen Modelos Diarios HPM	113
7.4. Resumen Supuestos Residuales Modelos I Región HPM.	114
7.5. Resumen Modelos I Región HPM.	114
7.6. Test Ljung-Box sobre Residuos I Región HPM.	114
7.7. Coeficientes Modelos I Región HPM.	115
7.8. Resumen Supuestos Residuales Modelos II Región HPM.	119
7.9. Resumen Modelos II Región HPM.	119
7.10. Test Ljung-Box sobre Residuos II Región HPM.	119

7.11. Coeficientes Modelo ARIMAX $\sim$ GARCH II Región HPM.	119
7.12. Resumen Supuestos Residuales Modelos IV Región HPM.	123
7.13. Resumen Modelos IV Región HPM.	124
7.14. Test Ljung-Box sobre Residuos IV Región HPM.	124
7.15. Coeficientes Modelo HPM IV Región.	124
7.16. Resumen Supuestos Residuales V Región HPM.	128
7.17. Resumen Modelos V Región HPM.	129
7.18. Test Ljung-Box sobre Residuos V Región HPM.	129
7.19. Coeficientes Modelo ARMAX $\sim$ GARCH V Región HPM.	129
7.20. Supuestos Residuales Modelos Diarios RM HPM.	133
7.21. My caption	134
7.22. Resumen Modelos de Despachos Diarios RM HPM.	134
7.23. Test Ljung-Box sobre Residuos RM HPM.	134
7.24. Modelo ARIMAX $\sim$ GARCH RM HPM.	134
7.25. Resumen Supuestos Residuales VI Región HPM.	139
7.26. Resumen Modelos VI Región HPM.	139
7.27. Test Ljung-Box sobre Residuos VI Región HPM.	139
7.28. Coeficientes Modelo ARMAX $\sim$ GARCH VI Región HPM.	139
7.29. Resumen Supuestos Residuales Modelos X Región HPM.	144
7.30. Resumen Modelos X Región HPM.	144
7.31. Test Ljung-Box sobre Residuos X Región HPM.	144
7.32. Modelo SARMAX $\sim$ GARCH X Región HPM.	145
7.33. Resumen Supuestos Residuales Modelos IV Región NHPM.	149
7.34. Resumen Modelos IV Región NHPM.	149
7.35. Test Ljung-Box sobre Residuos IV Región NHPM.	149
7.36. Coeficientes Modelo ARIMAX $\sim$ GARCH IV Región NHPM.	150
7.37. Resumen Supuestos Residuales V Región NHPM.	154
7.38. Resumen Modelos V Región NHPM.	154
7.39. Test Ljung-Box sobre Residuos V Región NHPM.	154
7.40. Coeficientes Modelo ARMAX $\sim$ GARCH V Región NHPM.	155
7.41. Resumen Supuestos Residuales Modelos RM NHPM.	159
7.42. Resumen Modelos RM NHPM.	159
7.43. Test Ljung-Box sobre Residuos RM NHPM.	159
7.44. Modelo ARIMAX $\sim$ GARCH RM NHPM.	160
7.45. Resumen Supuestos Residuales VI Región NHPM.	165

7.46. Resumen Modelos VI Región NHPM.	165
7.47. Test Ljung-Box sobre Residuos VI Región NHPM.	165
7.48. Coeficientes Modelo ARIMAX $\sim$ GARCH VI Región NHPM.	166
7.49. Resumen Supuestos Residuales Modelos VIII Región NHPM.	170
7.50. Resumen Modelos VIII Región NHPM.	170
7.51. Test Ljung-Box sobre Residuos VIII Región NHPM.	170
7.52. Coeficientes Modelo ARIMAX $\sim$ GARCH NHPM VIII Región.	170
7.53. Resumen Supuestos Residuales Modelos X Región NHPM.	175
7.54. Resumen Modelos X Región NHPM.	175
7.55. Test Ljung-Box sobre Residuos IX Región NHPM.	175
7.56. Coeficientes ARIMAX $\sim$ GARCH IX Región NHPM.	176
7.57. Resumen Supuestos Residuales Modelos X Región NHPM.	180
7.58. Resumen Modelos X Región NHPM.	180
7.59. Test Ljung-Box sobre Residuos X Región NHPM.	180
7.60. Coeficientes Modelo ARX GARCH X Región NHPM.	181

Capítulo 1

Introducción

Melón S.A. es una empresa cuyo origen remonta a principios del siglo XX. Consta con más de 50 plantas hormigoneras a lo largo del país y presencia en todo Chile. Su principal actividad es la venta y despacho de Cemento y Hormigones.

Participó en el levantamiento de las obras más emblemáticas de la historia de nuestro país tales como el puerto de San Antonio, la Torre Entel, el Estadio Nacional, Costanera Norte, el edificio Titanium, entre otros.

Los despachos de Cemento se sub dividen en categorías, las cuales corresponden a la cantidad en kilotoneladas de HPM (Hormigón pre-mezclado) que consta básicamente de los envíos mediante camiones hormigoneros, NHPM (No Hormigón pre-mezclado) cuya mayoría son los sacos de cemento distribuidos mediante grandes casas comerciales tales como EASY o Home-center y el total general compuesto por la suma de éstos.

Actualmente el competitivo mercado del Cemento en Chile presenta comportamientos difíciles de anticipar con exactitud, por lo cual se realizan una serie de predicciones mediante métodos estadísticos a fin de reducir el margen de error en los pronósticos de Mercado. Para esto es necesario estudiar posibles causalidades reflejadas en datos conocidos de variables macroeconómicas ligadas a la Industria del Cemento.

Una vez determinadas las variables como posibles predictoras se realizará un estudio de asociaciones para posteriormente efectuar un modelamiento tanto de Series Económicas como Redes Neuronales supervisadas con la finalidad de determinar el comportamiento futuro de la variable de estudio, es decir, la Demanda de Cemento.

1.1. Definición del Problema

1.1.1. Enfoque de la Empresa

El mercado del Cemento se caracteriza por ser muy competitivo y una de las razones es que el producto (cemento) se considera un “Commoditie”, que en pocas palabras implica que es un producto genérico, sin mayores variaciones y por ende, no cambia mucho dependiendo de dónde o a quien se le compre.

Dentro de la competencia destacan 3 grandes empresas, las cuales son Melón, Bío-Bío y Polpaico cuyas participaciones abarcan cerca de un 80 por ciento del mercado total del país (Brescia, F.A. (2014) [3]).

Para Melón un aspecto crucial para la toma de decisiones es tener información futura sobre el mercado, para ello se busca realizar métodos predictivos a fin de anticipar y a su vez actuar en consecuencia a los cambios que pueda tener la Industria del Cemento. Existen múltiples riesgos dentro del comportamiento del Mercado que pueden abordarse teniendo una buena planificación. Para tenerla se necesita de un buen Forecast.

Frente a una baja del mercado se pueden contraer las inversiones, posponer o cancelar proyectos y reducir gastos para así tener siempre utilidades; en caso de anticipar un crecimiento es posible incrementar la inversión, aumentar personal e incluso instalar más plantas productoras en lugares donde se tiene menos presencia.

Desde el punto de vista económico se busca encontrar Q (Demanda), el cual apoyado por una planificación eficiente y sumado a la elección de un precio de equilibrio, permitan maximizar el EBITDA¹ compañía. Para encontrar este Q, resulta fundamental anticipar el comportamiento del Q del Mercado y realizar predicciones del volumen certeras.

¹Proviene del acrónimo en inglés **Earnings Before Interest, Taxes, Depreciation, and Amortization** (beneficio antes de intereses, impuestos, depreciaciones y amortizaciones), es decir, el beneficio bruto de explotación calculado antes de la deducibilidad de los gastos financieros

En este contexto, el problema principal de la Empresa es anticipar los escenarios futuros de Mercado con la mayor precisión posible, todo esto considerando los múltiples factores de causalidad que puedan encontrarse dentro del marco macroeconómico del negocio del Cemento.

Por lo tanto nuestra principal tarea es crear métodos de predicción lo más certeros posibles para la Industria total del cemento en Chile y los despachos diarios por planta productora. Éstas a su vez serán realizadas a nivel nacional, regional y por planta productora de Melón, las cuales se ubican en La Calera, Ventanas y Puerto Montt.

1.1.2. Enfoque Estadístico

Como estadístico la labor es encontrar e identificar posibles factores estacionales dentro del comportamiento de la Demanda de Cemento, así como también anticipar tendencias y posibles quiebres en el Mercado. De esta manera, podremos asesorar y recomendar métodos predictivos adecuados que sean lo más certeros posibles, estables y de un aceptable manejo futuro para un uso y actualización sostenida en el tiempo.

Para esto nos basaremos en diversos artículos de estudio tales como los de Adamowski, F.J (2008) [1], Andrews, B.H. et al,(2013). [2] y Escobar, L. et al (2010) [9]. En estos estudios las técnicas utilizadas para el ajuste se basan en la incorporación de covariables para explicar las fluctuaciones de las series estudiadas.

Preliminarmente, para justificar los tipos de modelos utilizados en el presente informe, se mostrarán de manera gráfica los comportamientos de la Serie Anual de los Despachos en kilotoneladas de Cemento y una de las series diarias correspondiente a la Región Metropolitana.

1.1.3. Serie Anual total País

Evolución histórica

Demanda Anual Nacional : Se compone de datos históricos desde 1989 hasta el 2015, son los despachos en Kilotoneladas de Cemento total del país.




Figura 1.1: Demanda de Cemento histórica.

A priori se observa una tendencia creciente y sostenida en en el tiempo.

Sin embargo existen dos quiebres significativos dentro de la creciente evolución histórica de la Demanda, corresponden a los años 1999 y 2009 en los cuales se presume el efecto de la Crisis Asiática o Crisis del Fondo Monetario Internacional y la Crisis Subprime respectivamente.

Por otro lado también se considerará el efecto de variables exógenas que puedan incidir en el efecto del Mercado, para este caso se creó una Base de Datos con información histórica de ciertas variables macroeconómicas escogidas en base a estudios como Pinto, Z.D. en 1999 ([19]), Cárdenas, S.M. en 2007 ([5]) y también con información recopilada de entrevistas a ejecutivos de Melón S.A.

En el análisis se estudiará el grado de asociación lineal entre la Demanda y las variables macro incluidas en la Base de Datos utilizando el Coeficiente de correlación de Pearson por sobre el de Spearman debido a su sensibilidad respecto a los datos outliers, en donde se espera represente de mejor manera la respuesta a los quiebres del Mercado (1999 y 2009).

Tomando en cuenta que todas las variables son analizadas a través del tiempo también se hará uso de la Función de Correlación Cruzada para detectar posibles desfases dentro de los grados de asociación con la Demanda. También es importante utilizar ésta función ya que uno de los principales problemas de incluir variables independientes es que éstas generalmente no presentan "Dato futuro", es decir, no es posible tener el dato 2016 para incluirlo en el modelo predictivo y se trabaja bajo expectativas de Mercado.

Por lo tanto en vista de que existe tendencia creciente con el pasar del tiempo y variables independientes que podrían ser utilizadas surge la propuesta de usar modelos Autorregresivos Integrados de Medias Móviles con variables Exógenas (ARIMAX) ya que consideraría el efecto de las variables macro a estudiar y la propia influencia autorregresiva de la serie.

Sin embargo es posible que existan relaciones no lineales que un modelo lineal de serie de tiempo no pueda percibir y es por ello que también se propone implementar una Red Neuronal del tipo Perceptrón Multicapa con Aprendizaje Supervisado que pueda cubrir las falencias que podrían tener los modelos convencionales.

1.1.4. Serie Diaria Región Metropolitana

Demanda Diaria : Es el volumen diario de Cemento en toneladas despachado por Melon, está seccionado por regiones de destino. Para éste avance se presentará un análisis previo correspondiente a la Región Metropolitana.

La base de datos se compone de despachos diarios de la empresa Melón S.A. desde el 2 de Enero de 2013 hasta el 22 de Noviembre de 2015, todo esto sujeto a actualización para el análisis final.

Evolución histórica




Figura 1.2: Despachos Diarios de Cemento HPM RM.

Existe cierta estacionalidad a priori en los Despachos diarios y un incremento en la variabilidad con el pasar del tiempo por lo que podría no existir estacionariedad en la serie y presentarse una Heterocedasticidad en sus retornos.




Figura 1.3: Retornos Despachos Diarios de Cemento HPM RM.

Efectivamente en el gráfico de los Retornos Diarios se puede apreciar una visible volatilidad. Todo esto indica que la serie podría ser Heterocedástica, frente a esto una buena alternativa son los modelos Autorregresivos con Heterocedasticidad Condicional (ARCH).

1.1.5. Modelos a probar

Modelo de Regresión Lineal

En primer lugar se aplicará un modelo de Regresión Lineal para estudiar el comportamiento e influencia de las variables explicativas que resulten significativas sobre el Modelo (Rojo, J.M. (2007) [20]).

Se desea implementar un modelo de Regresión Lineal ya que existen variables exógenas que históricamente tienen un alto grado de asociación lineal con la demanda del cemento (Pinto, Z.D. (1999) [19]).

También servirá como punto de comparación con los modelos propuestos ya que el modelo de Regresión Lineal es el método convencional más común y usado para éste tipo de problema.

Modelo ARIMAX

El modelo ARIMAX es básicamente un modelo ARIMA, es decir, un modelo que posee elementos Auto Regresivos Integrados de Medias Móviles con la variación de que en ARIMAX podemos asociar el modelo a las posibles causalidades de otras variables independientes a través del tiempo (Gras, A.J. (2001) [13] y Andrews, B.H. et al,(2013) [2]).

Se utilizará este modelo porque de estudios previos (Pinto, Z.D., (1999) [19]) se sabe que la Demanda histórica de Cemento posee una tendencia y a su vez se pretende agregar el efecto de otras variables macroeconómicas.

Redes Neuronales

Han sido utilizadas en diversos problemas de predicción y han logrando grandes resultados en el pronóstico de series temporales tanto lineales como no lineales. Su gran capacidad para encontrar relaciones entre variables (Fausett, L. (1994) [10]) la hace una gran alternativa para resolver el problema en cuestión.

Para ello se tendrán en cuenta los siguientes factores: Arquitectura, la cual hace referencia a la cantidad de entradas y salidas, nodos ocultos y funciones de activación. Aprendizaje, cuyo fin consiste en la forma en que la red comienza a captar la información de la muestra de estudio, determinando pesos sinápticos y reduciendo iterativamente el error de ajuste. Por último su capacidad de generalización, que trata básicamente de la capacidad predictiva del modelo, determinando patrones de comportamiento de datos futuros. (Adamowski, J.F. (2008) [1], Guoqiang, Z., et al, (1998) [14] y Correa, R. (2006) [8])

Es por esto que se las Redes Neuronales artificiales supervisadas serán implementadas a fin de encontrar mejoras a los modelos planteados anteriormente. Se busca encontrar relaciones no lineales, las cuales no serían percibidas por la Regresión Lineal, obtener iterativamente un valor que optimice las posibles causalidades de las variables exógenas y una combinación óptima de todos sus pesos (Correa, R. (2006) [8]) logrando así, una mejor predicción que sus predecesores en este estudio.

Modelos Auto Regresivos Condicionalmente Heterocedásticos

El comportamiento de los retornos de Despachos diarios de Cemento posee características que sugieren el uso de éste tipo de modelos. (Casas, M.(2008) [6])

Gráficamente las variaciones (o retornos) de la variable de interés presentan incrementos o descensos bastante pronunciados (Heterocedasticidad) y difíciles de anticipar para los modelos convencionales.

En muchas ocasiones en economía se habla de sucesos condicionados o de generación de expectativas a partir de los movimientos relativos que se produjeron en el pasado, es decir, comportamientos ligados a una Heterocedasticidad Condicional.

Dado lo anterior es que se ajustarán modelos de la familia ARCH para buscar pronosticar el comportamiento diario de los Despachos de Cemento.

1.2. Objetivos

Objetivo General

- Predecir la cantidad de Cemento despachada en 2016 a nivel nacional.

Objetivos Específicos

- Hacer un estudio de la literatura respecto a los potenciales Modelos Predictores a utilizar.
- Estudiar Variables macroeconómicas potencialmente predictoras.
- Crear una Base de Datos con las Variables pre-seleccionadas.
- Analizar grados de asociación de las variables obtenidas versus la Demanda de Cemento.
- Recomendar variables relevantes a considerar como palancas de la Demanda de Cemento en Chile.
- Sugerir Modelos Estadísticos para el Pronóstico de la Demanda de Cemento.
- Realizar una predicción Anual de la Demanda de Cemento como Total País.
- Ajustar Despachos Regionales de Cemento.

1.3. Metodología

Existen estudios previos tanto nacionales como internacionales Cárdenas, S.M., et al, (2007) [5] y Pinto, Z.D. (1999) [19] en donde se destacan ciertas variables que inciden en el comportamiento del Mercado del Cemento.

Estos estudios serán considerados y tomados como referencia para realizar la selección de variables que posiblemente puedan explicar las variaciones en la Demanda de Cemento y a su vez se agregarán más variables independientes según criterio y estudios previos de personal de la Empresa.

Se realizará un análisis detallado de cada una de las variables a considerar dentro de los modelos predictivos. Bajo este contexto se tomarán en cuenta diversos factores, entre los más importantes destacan la accesibilidad de la información, las fuentes de donde se originan los datos y su grado de asociación con la variable de interés.

Una vez determinadas las variables independientes a estudiar se analizará su grado de asociación con la Demanda de Cemento y se estudiarán desfases dentro de las posibles causalidades que éstas puedan aplicar sobre nuestra variable de estudio.

Para ello se hará uso de correlaciones cruzadas a fin de obtener referencias de en cuántos años, días o meses están desfasadas algunas variables para explicar a la Demanda de Cemento con el más alto grado de asociación posible.

Posteriormente se probarán diversos modelos predictivos tales como Modelos Lineales Generalizados (Rojo, J.M. (2007) [20]) , Series Econométricas (Gras, A.J. (2001) [13] y Andrews, B.H. (2013) [2]) y Redes Neuronales supervisadas (Adamowski, J.F. (2008) [1],Guoqiang, Z., (1998) [14] y Correa, R. (2006) [8]) para luego compararlos entre sí utilizando como criterio el Ajuste, Error Medio Absoluto y Error Cuadrático de Predicción.

Luego se escogerá el Modelo predictivo con los mejores atributos, tanto ajuste como precisión en sus pronósticos, para ser implementado en el software estadístico R-Proyect.

Finalmente se señalarán los posibles escenarios del Mercado, sugiriendo acciones en respuesta para abordar de manera óptima los cambios en la Industria del Cemento.

1.3.1. Procedimiento Box Jenkins

Procedimiento de predicción basado en procesos Auto Regresivo de Media Móvil Integrado ARIMA(p,d,q).

El primer paso es, mediante el operador diferenciador, hacer que la serie de tiempo se vuelva estacionaria, ésto determinará el parámetro d del modelo ARIMA. Luego los parámetros p y q son determinados mediante los gráficos de ACF y PACF de la serie diferenciada.

El algoritmo a seguir es ilustrado en la siguiente imagen:




Figura 1.4: Algoritmo Box-Jenkins.

Formulación de una clase de modelos

En primer lugar existen tres tipos de modelos básicos en la metodología Box Jenkins para describir series de tiempo estacionarias. El ajuste de estos modelos a una serie de datos reales parte del supuesto de que las series analizadas no poseen tendencia ni estacionalidad:

- Procesos de media móvil MA
- Procesos autoregresivos AR
- Procesos ARMA

Considerando el proceso ARIMA(p,d,q), se puede predecir a través de:

- Ecuaciones de diferencias finitas
- Un proceso MA(∞)
- Representación de X_t como un proceso AR(∞)

Identificación del modelo

En éste paso se debe establecer si el modelo tendrá componentes de Estacionalidad (SAR-MA o SARIMA) y/o de Tendencia (ARIMA).

Para ello se harán test de estacionariedad como el ADF así como análisis gráficos en donde se verificará si existe tendencia o comportamientos cíclicos que indiquen patrones estacionales a través del tiempo.

Estimación de Parámetros

Una vez determinada la clase de modelo mediante los gráficos de ACF y PACF se determinará el orden Auto Regresivo (p) y de Medias Móviles (q) del modelo.

Para determinar los parámetros d y D de un modelo ARIMA y SARIMA respectivamente se contará el número de diferenciaciones por tendencia (d) y por estacionalidad (D) para hacer efectiva la determinación del argumento en la función.

Por último los parámetros P y Q se determinarán en los lags correspondientes a cada período en el ACF para Q y PACF para P.

Crítica y diagnóstico del modelo

Una vez determinados los tipos de modelos que se ajustan mejor a los datos se debe decidir cual de ellos quedarnos, para estos hay varios criterios, entre los cuales destacan:

- Considerar el número de parámetros, con el fin de escoger el más parsimonioso y a la vez perder la menor capacidad predictiva posible.
- Comparar utilizando el criterio de Información de Akaike (AIC)
- Observar el criterio de Error Cuadrático Medio (ECM)
- Estudiar el Error Medio Absoluto Porcentual (MAPE)

¿Es el modelo adecuado?

Para saber si el modelo es adecuado, se deben comprobar los supuestos residuales, en el cual se ve si los residuos distribuyen ruido blanco, es decir, si sus residuos son no correlacionados, de media constante y homocedásticos. Para esto se pueden realizar los siguientes test a cada modelo:

- **Test de Box-Ljung:** el cual ve la independencia de los residuos, autocorrelación igual a cero. H_0 : Los residuos son independientemente distribuidos v/s
 H_1 : Los residuos no son independientemente distribuidos
- **Test ADF:** Comprueba que los residuos no dependan del tiempo, es decir, que tengan media constante.
- **Homocedasticidad** Se aplica un gráfico con el comportamiento residual a través del tiempo, el cual no debe tener saltos anómalos y representar cierta estabilidad.

Predicciones

- Para comprobar si un modelo funciona en la practica con datos desconocidos es utilizar una parte de la muestra para la estimación, denominada muestra de entrenamiento, y la otra parte para el pronóstico, llamado muestra de validación.
- La previsión de la muestra de validación se puede también utilizar como un método de selección de modelo(s)
- Sin embargo, el fallo de previsión puede ocurrir por razones de cambios en un medio externo que afecte a nuestra variable de interés, y no necesariamente porque el modelo esté mal ajustado.

Este algoritmo bien puede y será aplicado para los modelos Lineales, Redes Neuronales o de series de tiempo con variables exógenas ARIMAX para comprobar sus supuestos residuales.

1.3.2. Resumen de Modelos a ajustar

Finalmente los modelos a ajustar tanto para los despachos diarios como los anuales son los siguientes:

- Modelo de Regresión Lineal.
- ARIMAX.
- GARCH.
- Redes Neuronales Perceptrón Multicapa.

Serán implementados en el software estadístico R-Proyect y evaluados según criterios de:

Ajuste:

- AIC
- MAPE
- Muestra de entrenamiento
- R^2

Supuestos Residuales:

- Normalidad
- Homocedasticidad
- No-Autocorrelación

Poder predictivo:

- Muestra de Validación
- Error Cuadrático de Predicción (ECM en muestra de validación)
- MAPE en Muestra de Validación

Capítulo 2

Marco Teórico

2.1. Modelos lineales

Proporciona modelar variable de interés respecto a variables explicativas simultáneamente, bajo cierto supuestos matemáticos con la finalidad de poder respaldar la efectividad y consistencia de los estimadores, obteniendo una ecuación lineal empírica de predicción razonablemente precisa, en base a un modelo teórico. (Norman R. (1998) [18] y Rojo, J.M.(2007). [20])

2.1.1. Regresión Lineal

La idea de un modelo de regresión es modelar la esperanza de una *respuesta* de interés (Variable dependiente), en términos de una o más variables explicativas (Variable independiente). Este modelo se expresa de la forma:

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + \epsilon_i$$

Donde Y_i es la i -ésima observación de la respuesta, x_{ip} es la i -ésima observación de la p -ésima variable independiente, ϵ_i es el error aleatorio no observable asociado a Y_i y β_p son parámetros lineales desconocidos. Este modelo se puede expresar de forma matricial de la siguiente forma:
 $Y_{n \times 1} = X_{n \times p'} \beta_{p' \times 1} + \epsilon_{n \times 1}$ Existen supuestos para el modelo, siendo estos:

- Normalidad, se tiene $\epsilon \sim N(0, \sigma^2 I)$
- No colinealidad, no puede haber combinación lineal entre las $\mathbf{X}$, ya que no se cumpliría la inversa de la matriz $(\mathbf{X}'\mathbf{X})^{-1}$
- Normalidad para cada perfil de $\mathbf{X}$ la v.a Y tiene distribución normal
- No correlación entre los errores

2.1.2. Estimación de Parámetros

Frente al modelo planteado se debe estimar los parámetros β_0, β_p y $\sigma_{y|x}^2$. Para esto se utiliza el método de mínimos cuadrados, el uso de este método es para minimizar las distancias entre los valores observados y_i y los valores estimados de la recta $\hat{y}_i$, esto consiste en minimizar la suma de cuadrado de los residuos.

$$S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

$$\frac{\partial S}{\partial \beta_1} = 0 \qquad \frac{\partial S}{\partial \beta_0} = 0$$

De esta forma se tienen las ecuaciones normales para así formar un sistema de ecuaciones del cual se obtiene

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

Donde $(\mathbf{X}'\mathbf{X})$ es no singular, es decir, determinante distinto de cero.

La forma de estimar σ^2 se obtiene a partir de la desviación de Y_i con respecto a su propia media, la constante apropiada por la que se divide la suma de cuadrado de estas diferencias es $n - 2$, ya que se pierden dos grados de libertad al tener que estimar dos parámetros.

$$s_{y|x}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2} = \frac{\sum_{i=1}^n \hat{e}_i^2}{n - 2}$$

Por otra parte estos parámetros se pueden obtener a través de la función de verosimilitud, aunque para que esto es necesario el supuesto de que los residuos distribuyan normal. En donde

$$\ln[\mathcal{L}(\beta_0, \beta_1, \sigma^2)] = -\frac{n}{2}\ln(2\pi) - \frac{n}{2}\ln(\sigma^2) - \frac{1}{2\sigma^2} \sum (y_i - \beta_0 - \beta_1 x_i)^2$$

Al igualar las derivadas parciales respecto a β_0, β_i se puede demostrar que los estimadores de máxima verosimilitud son idénticos a los obtenidos por el método de mínimos cuadrados. Aunque para el caso de σ^2 se tiene.

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}$$

Donde este estimador es sesgado aunque para valores grandes de n , la diferencia entre el estimador obtenido por mínimo cuadrados y este último no es importante.

2.1.3. Propiedades e interpretación de los estimadores

Considerando el supuesto de Normalidad, en donde se tiene

$$\varepsilon \sim N(0, \sigma^2 I) \quad \mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 I)$$

Luego

$$\mathbb{E}(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta} \quad \mathbb{V}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$$

Por lo que $\boldsymbol{\beta} \sim N(\boldsymbol{\beta}; \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$

La distribución de la varianza residual muestral esta dada por una $\chi^2_{(n-(p+1))}$

Interpretación de los Coeficientes

- $\hat{\beta}_0$ es el intercepto y corresponde al punto en que intersecta al eje oclusal.
- Si es que se habla de regresión lineal simple, se tiene que $\hat{\beta}_1$ corresponde a la pendiente de la recta. Y su interpretación corresponde a la estimación del cambio en el valor esperado de $\hat{y}_i$ por cada unidad en que se incrementa la variable x_i .
- Los β_j se interpretan como el cambio en el valor esperado del modelo Y cuando x_j aumenta en una unidad dado que el resto de las variables se mantienen constantes.

2.1.4. Bondad de ajuste del modelo

Una vez ajustado el modelo se debe evaluar la contribución de las variables independientes, donde se debe estudiar:

- i) Evaluar simultáneamente todas las variables independiente.
- ii) Evaluar individualmente cada variable independiente.

i Significancia simultanea de todas las variables independientes

Para estudiar el caso *i* es necesario hacer una descomposición de la suma de cuadrados total del modelo, de la siguiente forma:

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{Suma de cuadrado total(SCT)}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{Suma de cuadrado del modelo(SCM)}} + \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{\text{Suma de cuadro residual(SCR)}}$$

Esta suma de cuadros se resume en una Tabla de Análisis de Varianza denominada ANOVA. Primero se presenta el caso para un modelo lineal simple, ya que posee solo

una variable independiente, por lo que se obtiene

De esto se desprende la siguiente d cima:

$$H_0 : \beta_1 = 0 \text{ versus } H_1 : \beta_1 \neq 0$$

Cuya estad stica de prueba esta dada por

$$F_{\text{obs}} = \frac{SCM/1}{SCR/(N-2)} \sim F_{(1;(n-2))}$$

Si es que el $F_{\text{obs}} > F_{\text{teo}}$ existe evidencia para rechazar H_0 , es decir que la variable x_i podr a estar explicando el comportamiento de la variable dependiente. De lo contrario si es que el coeficiente es cero 0, la variable explicativa no estar a respondi endo a la variable dependiente por lo que el modelo no tendr a sentido.

Para el caso de que se tengo x_i variables independientes, se tiene la siguiente Tabla ANOVA, bajo la misma l gica de descomposici n de varianza.

como se debe evaluar las contribuciones globales de las variables independientes, se plantea la siguiente d cima.

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \text{ versus } H_1 : \forall \beta_j \neq 0; j = 1, \dots, p$$

Siendo el estad stico de prueba

$$F_{\text{obs}} = \frac{CM_{\text{modelo}}}{CM_{\text{residual}}} \sim F_{(p, n-(p+1))}$$

Si es que $F_{\text{obs}} > F_{\text{teo}}$ existe suficiente evidencia para rechazar H_0 por lo que al menos una variable independiente podr a responder a la variable respuesta.

ii Significancia individual para cada variable independiente

Debido a que es conocida la distribuci n de los estimadores se pueden realizar d cimas de contraste para estos, donde se plantea

$$H_0 : \beta_i = 0 \text{ versus } H_1 : \beta_i \neq 0 ; i = 0, \dots, p$$

Donde el estad stico de prueba corresponde a

$$t_{\text{obs}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\mathbb{V}(\hat{\beta}_1)}} \sim t_{(n-2)}$$

Si es que $t_{\text{obs}} > t_{\text{teo}}$ existe suficiente evidencia para rechazar H_0 , es decir, la variable x_i se ajusta bien al modelo, de lo contrario si β_i toma un valor cero significaría que la variable x_i no está respondiendo al comportamiento de la variable dependiente por lo que se recomienda sacar la variable del modelo.

Bajo la condición de normalidad de los coeficientes, se puede llegar al siguiente intervalo de confianza:

$$IC(\beta_1; 1 - \alpha) = \hat{\beta}_1 \pm t_{1-\frac{\alpha}{2}; (n-2)} \sqrt{\mathbb{V}(\hat{\beta}_1)}$$

2.1.5. Coeficiente de determinación

Para estudiar la asociación lineal entre las variable X e Y se calcula el coeficiente de determinación (r^2), este pertenece al coeficiente de Pearson (r). Dado que SCT representa la variación total respecto a la media y SCM mide la proporción de esta, se tiene que

$$r^2 = \frac{SCM}{SCT} = \frac{SCT - SCR}{SCT} = 1 - \frac{SCR}{SCT}$$

El valor del coeficiente de determinación esta entre $0 \leq r^2 \leq 1$ ya que $0 \leq SCR \leq SCT$, mientras que este sea mas cercano a 1 indicará que el ajuste del modelo es mejor, de lo contrario siendo cercano a cero se podría decir que el modelo no es el adecuado. Cabe mencionar que este coeficiente por si sólo no es un buen indicador, ya que se ve afectado por la cantidad de variables independientes (mayor cantidad de variable el r^2 será más cercano a 1).

Es por esto que en esos casos se estudia el R^2 ajustado, definido como $= 1 - (1 - R^2) \frac{n - 1}{n - (p + 1)}$. Ya que jamás decrece cuando una nueva variable es introducida al modelo.

Aunque no posee una distribución conocida, sin embargo se tiene $F = \frac{R^2}{1 - R^2} \cdot \frac{n - (p + 1)}{p}$

2.1.6. Observaciones influyentes

Si en algún conjunto de datos la estimación de uno o más parámetros depende fuertemente de un pequeño número de observación podemos tener problemas (de interpretación). Es por esto que se consideran diagnósticos para detectar si una observación es un ?outlier? o un punto de leverage alto.

Se define

$$\hat{y} = \underbrace{\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'}_{\text{matriz Hat}} \mathbf{Y} \Rightarrow \hat{y} = \mathbf{H}\mathbf{Y}$$

Donde $\mathbf{H}$ se conoce como la matriz sombrero, actua como una transformación entre y e $\hat{y}$. En particular

$$\hat{y}_i = \sum_{j=1}^n h_{ij} y_j$$

donde h_{ij} es el elemento de la matriz H que está en la i -ésima fila y j -ésima columna.

Con esta matriz se tiene si $h_{ii} > \frac{2p}{n}$ entonces la i -ésima observación es considerada un punto "leverage".

Residuos Estudentizados

: se denominan así debido a que tienen aproximadamente distribución t- Student con $(n - p - 1)$ grados de libertad, cuando los supuestos del modelo se satisfacen.

$$r_{si} = \frac{\hat{e}_i}{\hat{\sigma}\sqrt{1 - h_{ii}}}$$

Si es que $r_{si} > 2$ entonces la i -ésima observación se puede considerar un "outlier".

Distancia de Cook

: Esta medida combina los residuos con los leverages. Permite medir la influencia de la i -ésima observación, donde

$$cook_i = \left(\frac{e_i}{\hat{\sigma}\sqrt{1 - h_{ii}}} \right)^2 \left(\frac{h_{ii}}{1 - h_{ii}} \right) \left(\frac{1}{p} \right)$$

grandes valores de esta medida indican observaciones cuya eliminación tiene gran influencia sobre los valores predichos. Como punto de corte para determinar si un dato es influyente se pueden usar los percentil 50 de una F $cook_i > F - (0, 5; p; n - p)$ es considerado una valor influyente. En general $cook_i \geq 1$ indica que la i -ésima observación es potencialmente influyente. Una observación con $cook_i < 0,1$ no merece ninguna discusión y si su $cook_i < 0,5$ merece un poco de atención.

DFITS

: Es similar a la Distancia Cook, excepto por un factor de escala y el remplazo de la varianza estimada $\hat{\sigma}^2$ por $\hat{\sigma}_{(-i)}^2$, la varianza estimada del error excluyendo la i -ésima observación en los cálculos. Más precisamente

$$DFITS_i = \frac{\hat{y}_i - \hat{y}_{(-i)}}{\sqrt{\hat{\sigma}_{(-i)}^2 h_{ii}}} \quad \text{Un } |DFITS_i| > 2\sqrt{\frac{p}{n}} \text{ indica un posible valor influyente.}$$

DFBetas

: Mide la influencia de la i -ésima observación en cada uno de los coeficientes de regresión.

$$DFBetas_{ij} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\hat{\sigma}_i \sqrt{c_{jj}}} \quad \text{Un } |DFBetas_{ij}| > \frac{2}{\sqrt{n}} \text{ indica un posible valor influyente.}$$

Donde $\hat{\beta}_{j(i)}$ es el j -ésimo coeficiente sin la i -ésima observación y $\hat{\sigma}_i$ es la desviación del modelo sin la i -ésima observación y c_{jj} es el j -ésimo elemento de la diagonal de $(X'X)^{-1}$.

CovRatio

: Mide el efecto en la variabilidad de los coeficientes de regresión al remover la i -ésima observación. Se define por

$$CovRatio_i = \left(\frac{\hat{\sigma}_{(-i)}^2}{\hat{\sigma}^2} \right)^p \frac{1}{(1 - h_{ii})}$$

Si $CovRatio_i > 1 + \frac{3p}{n}$ o $CovRatio_i < 1 - \frac{3p}{n}$ la i -ésima observación es un valor influyente.

2.1.7. Selección de modelos

Criterios para la comparación de modelos.

Criterio R^2

Se optará por el modelo que posea mayor $R_{ajustado}^2$

Criterio de cp de Mallows

considera el sesgo en la selección del modelo ya que si se omite una variable independiente importante los estimadores de los coeficientes de regresión son sesgados, donde se selecciona el modelo que minimice cp, siendo este

$$cp = \frac{SCE}{\hat{\sigma}^2} + 2p$$

Donde SCE corresponde al modelo ajustado y $\hat{\sigma}^2$ al modelo completo.

Criterio AIC

consiste en seleccionar el modelo que satisfaga el criterio de parsimonia (optar por un modelo sencillo en vez de uno complicado) por lo que penaliza a los modelos dependiendo del número de parámetros.

$$AIC = 2p - 2\ln[L]$$

Donde L es el máximo valor de la función de verosimilitud para el modelo estimado. Es por esto que se optará por el modelo con menor AIC.

2.2. Series de Tiempo

Una serie temporal se define como una secuencia de datos medidos en determinados momentos y ordenados cronológicamente. Para su análisis, se utilizan métodos que ayudan a estudiar su comportamiento, y a su vez, extrapolar a fin pronosticar valores de lo investigado. (Brockwell, P. (2002). [4])

Es una familia de variables aleatorias Y_t donde t denota el tiempo, tales que para cualquier valor de $t_1, t_2, \dots, t_n$ existe la distribución de probabilidad conjunta correspondiente a las variables aleatorias $Y_{t_1}, Y_{t_2}, \dots, Y_{t_n}$.

Las series temporales se pueden clasificar en discretas, si es observada en instantes aislados en el tiempo, y en continuas, si ésta es observada continuamente en el tiempo.

2.2.1. Componentes básicos de una serie de tiempo

Una serie de tiempo se puede denotar como:

$$Y_t = T_t + S_t + E_t$$

Donde T_t es la tendencia, S_t es la componente estacional e E_t es la componente aleatoria

- **Componente de Tendencia:** Se define como un cambio a largo plazo que se produce en la relación al nivel medio, o el cambio a largo plazo de la media. Se identifica con un movimiento suave de la serie a largo plazo.
- **Componente de Estacionalidad:** Corresponde a un comportamiento periódico de la serie. Son oscilaciones que se produce alrededor de la tendencia, en forma repetitivas.
- **Componente Aleatorio:** Esta componente no responde a ningún patrón de comportamiento si no que es el resultado de factores fortuitos o aleatorios de inciden de forma aislada en una serie de tiempo.

2.2.2. Clasificación de series de tiempo

En primera instancia las series de tiempo se pueden clasificar en series **estacionarias** y **no estacionarias**.

Una serie es estacionaria se caracteriza por presentar un comportamiento relativamente estable a lo largo del tiempo con una media y varianza constante. Gráficamente los valores de la serie oscilan alrededor de una media que es invariable, es decir, los datos observados no se incrementan o decrecen con el pasar del tiempo y la variabilidad con respecto a esa media también permanece constante, dicho de otra forma el *ruido*¹ de la serie no se incrementa.

Por otro lado una serie no estacionaria presenta tendencia o varianza inestable en el tiempo. Los cambios en la media determinan una tendencia a crecer o decrecer a largo plazo, por lo que la serie no oscila alrededor de un valor constante y la inestabilidad en varianza se refleja en una oscilación creciente a lo largo del tiempo.

2.2.3. Proceso estocástico y estacionaridad

Para poder analizar la estacionaridad de una serie de tiempo primero se definirá un concepto base, los procesos estocásticos. (Brockwell, P. (2002). [4])

Sea T un conjunto arbitrario, un proceso estocástico es una familia $Z = \{Z(t), t \in T\}$ tal que para cada $t \in T$, $Z(t)$ es una variable aleatoria.

Desde un punto de vista intuitivo, un proceso estocástico se describe como una secuencia de datos que evolucionan en el tiempo. Las series temporales se definen como un caso particular de los procesos estocásticos.

Un proceso estocástico se dice que es estacionario si su media y su varianza son constantes en el tiempo y si el valor de la covarianza entre dos periodos depende solamente de la distancia o rezago entre estos dos periodos de tiempo y no del tiempo en el cual se ha calculado la covarianza.

Proceso débilmente estacionario

Una serie de tiempo Y_t se dice débilmente estacionaria o estacionaria de segundo orden, si satisface las siguientes condiciones:

¹Hace referencia al grado de oscilación en una representación gráfica del comportamiento de una variable

- $E(Y_t) = \mu_t \quad \forall t \in T$ Es decir, la media del proceso Y_t es constante.
- $V(Y_t) = \sigma_t^2 < \infty \quad \forall t \in T$ Es decir, la variabilidad del proceso es constante y finita.
- $Cov(Y_t, Y_{t-k}) = \gamma_k$ Es decir, la covarianza no depende de t .

Proceso estrictamente estacionario

Un proceso es estrictamente estacionario si la distribución conjunta de $(Z_t, \dots, Z_k)$ y $(Z_{t+h}, \dots, Z_{k+h})$ es la misma para todo $k \geq 0$ y $h \in \mathbb{Z}$.

2.2.4. Ruido Blanco

Un ruido blanco es un caso simple de los procesos estocásticos, donde los valores son independientes e idénticamente distribuidos a lo largo del tiempo, con media cero e igual varianza.

Un ruido blanco debe cumplir las siguientes condiciones:

- $E(Y_t) = 0$
- $V(Y_t) = \sigma_t^2$
- $Cov(Y_t, Y_{t-k}) = 0$

2.2.5. Función de Autocovarianza

La función de Autocovarianza de una serie de tiempo Y_t de orden k , denotada por γ_k , es la Covarianza de la serie separada en k periodos, es decir:

$$\gamma_k = Cov(Y_t, Y_{t-k}) = E[(Y_t - \mu)(Y_{t-k} - \mu)] \quad (2.1)$$

Donde $\mu = E(Y_t) = E(Y_{t-k})$.

El conjunto de valores de γ_k para $k \geq 0$ configuran la Función de Autocovarianza.

La cual satisface las siguientes propiedades:

- $\gamma_0 = V(Y_t)$
- $\gamma_k = \gamma_{-k}$ La función es par
- $|\gamma_k| \leq \gamma_0$ para $k = 1, 2, \dots$

2.2.6. Función de Autocorrelación

La autocorrelación de orden k para un periodo Y_t , denotada por ρ_k , es la correlación de la serie separada en k periodos (Brockwell, P. (2002). [4]), es decir:

$$\rho_k = Corr(Y_t, Y_{t-k}) = \frac{Cov(Y_t, Y_{t-k})}{\sqrt{V(Y_t)V(Y_{t-k})}} \quad (2.2)$$

Y si el proceso es estacionario, entonces la autocorrelación de orden k es:

$$\rho_k = \frac{\gamma_k}{\gamma_0} \quad \forall k \geq 0 \quad (2.3)$$

El gráfico de los valores de autocorrelación se llama correlograma.

Correlograma




Figura 2.1: Fuente: Brockwell (2002). Introduction Time Series and Forecasting [4]

El correlograma de una serie puede ayudar a determinar si la serie es estacionaria de segundo orden: Si los valores del gráfico decaen rápidamente a cero se dice que el proceso es estacionario. Si los valores decaen lentamente a cero, el proceso no es estacionario.

2.2.7. Función de Correlación Cruzada

Considere dos procesos conjuntamente estacionarios x_t e y_t para $t = 0, \pm 1, \pm 2, \dots$. La covarianza cruzada de orden k entre x_t e y_t está definida como (Castaño, E. (1998) [7]):

$$\gamma_{xy}(k) = E[(X_t - \mu_x)(y_{t+k} - \mu_y)] \quad (2.4)$$

Para $k = 0, \pm 1, \pm 2, \dots$

Como función de k , $\gamma_{xy}(k)$ es llamada la **Función de Covarianza Cruzada** entre x_t e y_t .

La estandarización de $\gamma_{xy}(k)$ produce la **Función de Correlación Cruzada** (CCF) representada matemáticamente por la siguiente expresión:

$$\rho_{xy}(k) = \frac{\gamma_{xy}(k)}{\sigma_x \sigma_y} \quad (2.5)$$

Para $k = 0, \pm 1, \pm 2, \dots$, donde σ_x y σ_y son las desviaciones estándar de los procesos x_t e y_t .

La CCF no solo mide la fortaleza en la relación lineal de dos procesos sino que también su dirección. Ésta propiedad puede ser de gran utilidad para identificar causalidad entre variables, por lo que es una función que se debe estudiar tanto para valores positivos como negativos de k . Para valores negativos de k , la FCC describe la influencia lineal de los valores pasados de y_t sobre x_t . Para valores positivos de k , la CCF indica la influencia lineal de los valores pasados de x_t sobre y_t .

El gráfico de la FCC contra k , llamado **Correlograma Cruzado** (Figura), es útil para visualizar estas relaciones.

Correolograma Cruzado




Figura 2.2: Fuente: Administración de operaciones: estrategia y análisis. Facultad de Ciencias, Universidad Nacional de Colombia [7]

Dada una realización de n periodos del proceso estacionario bivalente x_t, y_t , la FCC se estimada con la función de correlación cruzada muestral (FCCM):

$$\hat{\rho}_{xy}(k) = \frac{\hat{\gamma}_{xy}(k)}{\hat{\sigma}_x \hat{\sigma}_y} \quad (2.6)$$

Para $k = 0, \pm 1, \pm 2, \dots$, donde:

$$\hat{\gamma}_{xy}(k) = \begin{cases} \frac{1}{n} \sum_{t=1}^{n-k} (x_t - \bar{x})(y_{t+k} - \bar{y}) & , si \ k \geq 0 \\ \frac{1}{n} \sum_{t=1-k}^n (x_t - \bar{x})(y_{t+k} - \bar{y}) & , si \ k < 0 \end{cases} \quad (2.7)$$

con $\hat{\sigma}_x = [\hat{\gamma}_{xx}(0)]^{\frac{1}{2}}$, $\hat{\sigma}_y = [\hat{\gamma}_{yy}(0)]^{\frac{1}{2}}$, $\bar{x}$ e $\bar{y}$ son las desviaciones estándar y medias muestrales de las series x_t e y_t respectivamente.

Con los supuestos de normalidad, es decir, que la serie x_t es ruido blanco y que las series x_t e y_t son incorrelacionadas, Bartlett (1985) probó que:

$$\text{Var} [\hat{\rho}_{xy}(k)] \approx (n - k)^{-1} \quad (2.8)$$

Por lo tanto, cuando la serie x_t es ruido blanco y hay normalidad, podemos contrastar la hipótesis de que las dos series tienen correlación cruzada nula comparando $\hat{\rho}_{xy}(k)$ con su error estándar aproximado $\sqrt{(n - k)^{-1}}$.

2.2.8. Modelo AR

Sea un proceso estocastico X_t con $t \in T$, y $T \in \mathbb{Z}$ Se dice autoregresivo de orden p , (AR(p)) (Brockwell, P. (2002) [4]) si:

- $X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \epsilon_t \quad t \in T, p \geq 1$ Donde $\epsilon_t \sim RB(0, \sigma^2)$
- $Cov(\epsilon_t, X_{t-j}) = E(\epsilon_t X_{t-j}) = 0$
- $\phi_1, \dots, \phi_p$ son coeficientes fijos.

Equivalentemente se define el polinomio:

$$\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p \quad (2.9)$$

$$\Phi(B)X_t = \epsilon_t \quad (2.10)$$

De esta manera el proceso es invertible, ya que $\Phi(B)$ es finito. Para que un modelo AR sea estacionario se debe cumplir $|\phi| < 1$ que quiere decir que todas las raíces están fuera del círculo unitario.

2.2.9. Modelo MA

Sea ϵ_t una sucesión de ruido blanco, $E(\epsilon_t) = 0$ y $V(\epsilon_t) = \sigma^2$ consideremos el proceso X_t (Brockwell, P. (2002) [4]) definido por: $X_t = \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$ Este modelo se conoce como modelo de medias móviles, desde ahora MA(q).

Otra forma de escribir el proceso:

$$X_t = \epsilon - \theta_1 B \epsilon_t - \dots - \theta_q B^q \epsilon_t = (1 - \theta_1 B - \dots - \theta_q B^q) \epsilon_t \quad (2.11)$$

$$X_t = \Theta(B) \epsilon_t \quad (2.12)$$

Como $\Theta(B)$ es finita, se puede decir que el proceso es estacionario. Para que el proceso sea invertible, se debe cumplir que todas las raíces del polinomio deben estar fuera del círculo unitario. $|\theta| < 1$.

2.2.10. Modelo ARMA

Sea X_t un proceso definido por la ecuación (Brockwell, P. (2002) [4]):

$$X_t - \phi_1 X_{t-1} - \dots - \phi_p X_{t-p} = \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q} \quad (2.13)$$

El cual es una combinación de los procesos AR(p) y MA(q).

Este modelo mixto se denota como $X_t \sim \text{ARMA}(p, q)$ proceso autoregresivo de medias móviles, donde:

- $\epsilon_t \sim RB(0, \sigma^2)$
- $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q$ son coeficientes fijos.

Otra forma equivalente de escribir el modelo ARMA(p,q) es:

$$\Phi(B)X_t = \Theta(B)\epsilon_t \quad (2.14)$$

X_t sera causal e invertible, si las raíces de $\Phi(Z) = 0$ y $\Theta(Z) = 0$ están fuera del circulo unitario.

Suponiendo que se cumplen estas condiciones, se podrán escribir los procesos MA(∞) y AR(∞)

2.2.11. Representaciones MA(∞) y AR(∞)

Representación MA(∞) de Wold

La descomposición en MA(∞) o representación de Wold esta definida por:

$$X_t = \sum_{j=0}^{+\infty} \Psi_j \epsilon_{t-j} \quad (2.15)$$

$$X_t = \Psi(B)\epsilon_t \quad (2.16)$$

Sea el proceso ARMA(p,q) $\Phi(B)X_t = \Theta(B)\epsilon_t$

$$X_t = \frac{\Theta(B)}{\Phi(B)}\epsilon_t \quad \Rightarrow \quad \Psi(B) = \frac{\Theta(B)}{\Phi(B)} \quad (2.17)$$

Expansión AR(∞)

Por otro lado se puede encontrar la representación de AR(∞) que esta definida por:

$$\sum_{j=0}^{+\infty} \Pi_j X_{t-j} = \epsilon_t \quad (2.18)$$

$\Pi(B)X_t = \epsilon_t$ Sea el proceso ARMA(p,q)

$$\Phi(B)X_t = \Theta(B)\epsilon_t \quad (2.19)$$

$$\frac{\Phi(B)X_t}{\Theta(B)} = \epsilon_t \quad \Rightarrow \quad \Pi(B) = \frac{\Phi(B)}{\Theta(B)} \quad (2.20)$$

2.2.12. Teorema de proyección

Espacio de Hilbert

Un espacio de Hilbert es un espacio con producto interno completo, donde un producto interno completo, cumple con:

$$\langle X, X \rangle = \|X\|^2 \Rightarrow \|X\| = \sqrt{\langle X, X \rangle} \quad (2.21)$$

Este espacio se dice completo si toda la sucesión de Cauchy tiene límite en el mismo espacio.

Sucesión de Cauchy

X_n es una sucesión de Cauchy si

$$\|X_n - X_m\|_{n,m \rightarrow \infty} \rightarrow 0 \quad (2.22)$$

La definición de los espacios de Hilbert se hace necesaria para tratar los casos de pasado infinito.

Por otra parte, para un teorema de proyección, es necesario tener un espacio con producto interno, el cual define la geometría del espacio.

Sea $X_1, \dots, X_n$ un proceso estacionario en sentido débil. Interesa predecir X_{n+1}

Para resolver esta pregunta se debe definir un teorema de proyección.

Teorema de Proyección

Sea $\mathbb{H}$ un espacio de Hilbert y sea M un subespacio cerrado de Hilbert.

Sea $X \in \mathbb{H}$ existe un único elemento $\hat{X} \in M$ tal que:

$$\|X - \hat{X}\| \leq \|X - Y\| \quad \forall Y \in M \quad (2.23)$$

Además, $\langle X - \hat{X}, Y \rangle = 0 \quad \forall Y \in M$

Mejor Predictor Lineal

De acuerdo con el teorema de proyección, existe un único elemento $\hat{X}_{n+1} \in M$ tal que:

$$\langle X_{n+1} - \hat{X}_{n+1}, X_t \rangle = 0 \quad \forall t = 1, \dots, T \quad (2.24)$$

Sea $M = S_p\{X_1, \dots, X_T\}$ y el espacio del Hilbert es L^2

$\Rightarrow$ Como M es un subespacio generado y $\hat{X}_{n+1} \in M$

$$\hat{X}_{n+1} = \alpha_1 X_1 + \dots + \alpha_n X_n \quad (2.25)$$

El espacio $M \in L^2$, entonces $\langle X, Y \rangle = E(XY) \Leftrightarrow E(X) = E(Y) = 0$

En el caso general se busca predecir $\hat{X}_{n+1}$ en base a $M = \{X_n, X_{n+1}, X_{n+2}, \dots\}$

El valor de $\hat{X}_{n+1}$ corresponde a:

$$\hat{X}_{n+1} = E(X_{n+1} | X_1, \dots, X_n) \quad (2.26)$$

También se puede denotar como:

$$E_M(X) = E(X|M) = P_M X \quad (2.27)$$

2.2.13. Estimación para modelos ARMA

Ecuación de Yule-Walker

Las ecuaciones de Yule-Walker, también conocidas como ecuaciones de los momentos, consisten en aplicar un esquema para estimar los parámetros de un proceso.

Sea $X_t \sim ARMA(p, q)$

$$(B)X_t = \Theta(B)\epsilon_t \quad / * X_{t-j} \quad / * E(\cdot) \quad (2.28)$$

El resultado permite escribir los parámetros del modelo, en función de las autocorrelaciones, que por lo general son conocidas.

Función de Autocorrelación Parcial

La autocorrelación parcial mide el exceso de correlación debida a X_{t-k} y se obtiene como la correlación que existe entre X_t y X_{t-k} después de eliminar el efecto de todas las variables aleatorias que están entre ellas, se denota por φ_{kk} y esta dada por:

$$\varphi_{kk} = Corr(X_t, X_{t-k} | X_{t-1}, X_{t-2}, \dots, X_{t-k+1}) \quad (2.29)$$

$$\varphi_{kk} = \frac{Cov(X_t - \hat{X}_t, X_{t-k} - \hat{X}_{j-k})}{\sqrt{V(X_t - \hat{X}_t)}\sqrt{V(X_{t-k} - \hat{X}_{j-k})}} \quad (2.30)$$

A continuación veremos dos métodos para obtener la Función de Autocorrelación Parcial (FACP):

■ **Algoritmo Durbin-Levinson**

Los coeficientes $\phi_{n1}, \dots, \phi_{nn}$ se pueden calcular de forma recursiva con el algoritmo de Durbin-Levinson:

$$\phi_{nn} = \{\gamma(n) - \sum_{j=1}^{n-1} \phi_{n-1,j} \gamma_{1-j}\} V_{n-1}^{-1} \quad (2.31)$$

$$\begin{bmatrix} \phi_{n1} \\ \vdots \\ \phi_{nn} \end{bmatrix} = \begin{bmatrix} \phi_{n-1,1} \\ \vdots \\ \phi_{n-1,n-1} \end{bmatrix} - \phi_{nn} \begin{bmatrix} \phi_{n-1,1} \\ \vdots \\ \phi_{n-1,n-1} \end{bmatrix} \quad (2.32)$$

$$V_n = V_{n-1}(1 - \phi_{nn}^2) \quad (2.33)$$

Donde $\phi_{11} = \frac{\gamma(1)}{\gamma(0)} = \rho(1)$

$$V_0 = \gamma(0) \quad (2.34)$$

$$\hat{X}_{n+1} = \sum_{j=1}^n \phi_{nj} X_{n+1-j} = \phi_{n1} X_n + \phi_{n2} X_{n-1} + \dots + \phi_{nn} X_1 \quad (2.35)$$

■ **Algoritmo de Innovaciones**

Los coeficientes $\theta_{n1}, \dots, \theta_{nn}$ se pueden calcular de forma recursiva con el algoritmo de innovaciones:

$$V_0 = \Gamma(1, 1) \quad (2.36)$$

$$\theta_{n,n-k} = V_n^{-1}(\Gamma(n+1, k+1) - \sum_{j=0}^{k-1} \theta_{k,k-j} \theta_{n,n-j} V_j) \quad (2.37)$$

$$\text{Con } V_n = \Gamma(n+1, n+1) - \sum_{j=0}^{n-1} \theta_{n,n-j}^2 V_j \quad (2.38)$$

$$\hat{X}_{n+1} = \sum_{k=1}^n \theta_{nk} (X_{n+1-k} - \hat{X}_{n+1-k}) \quad (2.39)$$

2.2.14. Identificación de Modelos

Para poder identificar los modelos de la series de tiempo, se debe observar la Función de Autocorrelación (FAC) Y la Función de Autocorrelación Parcial (FACP), la cual veremos para cada modelo.

Modelo	FAC	FACP
AR(p)	Infinito. Decrecimiento como mezcla de exponenciales y senoidales	Finito. p primeros coeficientes no nulos, el resto cero
MA(q)	Finito. q primeros coeficientes no nulos, el resto cero	Infinito. Decrecimiento como mezcla de exponenciales y senoidales
ARMA(p,q)	Infinito. Decrecimiento hacia cero desde q	Infinito. Decrecimiento hacia cero desde p

Cuadro 2.1: Fuente: Brockwell (2002). Introduction Time Series and Forecasting [4]

2.2.15. Diferenciación

Cuando una serie tiene tendencia es un proceso no estacionario, para poder solucionar ese problema se ocupa el operador de diferencia:

$$\nabla^d = (1 - B)^d \quad (2.40)$$

$$Tal\ que\ Y_t = (1 - B)^d X_t \quad (2.41)$$

Se dice que el proceso Y_t es de orden d, si se tuvo que diferenciar la serie d veces para que fuese un proceso estacionario.

Para saber si se debe diferenciar o no, se debe estudiar la variabilidad de la serie original y la serie diferenciada. En general, no debería observarse un aumento sustantivo en la varianza de la serie diferenciada.

2.2.16. Modelo ARIMA

Sea $Y_t = (1 - B)^d X_t$ y suponga que $Y_t \sim ARMA(p, q)$ es decir (Brockwell, P. (2002) [4]):

$$\Phi(B)X_t = \Theta(B)\epsilon_t \quad (2.42)$$

Entonces podemos reescribir el proceso como:

$$\Phi(B)(1 - B)^d X_t = \Theta(B)\epsilon_t \quad (2.43)$$

Este proceso se conoce como integrado de Autoregresivo integrado de medias móviles y se denota como $X_t \sim ARIMA(p, d, q)$ donde p corresponde al orden de la parte autorregresiva estacionaria, d es el número de veces que se diferencia la serie y q es el orden de la parte de medias móviles.

Donde:

- $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$
- $\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$

2.2.17. Modelo SARIMA

El modelo SARIMA, también llamado ARIMA estacional, permite la aleatoriedad en la forma estacional de ciclo a ciclo. Este modelo se escribe de la siguiente forma (Brockwell, P. (2002) [4]):

$$\Phi(B)\Phi_P(B^s)(1 - B)^d(1 - B^s)X_t = \Theta(B)\Theta_Q(B^s)\epsilon_t \quad (2.44)$$

Donde:

- $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$
- $\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$
- $\Phi_P(B^s) = 1 - \phi_1 B^s - \phi_2 B^{2s} - \dots - \phi_p B^{ps}$
- $\Theta_Q(B^s) = 1 - \theta_1 B^s - \theta_2 B^{2s} - \dots - \theta_q B^{qs}$

2.2.18. Estrategia de Predicción

1. Obtener la mayor cantidad de información posible acerca del fenómeno a analizar
2. Graficar datos originales, fijándose en:
 - Tendencias
 - Variaciones estacionales
 - Cambios estructurados
 - Varianza (estable)
3. “Limpiar datos”, eliminar datos extremos. Transformación de datos originales.
4. Determinar si la serie posee variación estacional, ya sea aditiva, multiplicativa u otra. Además revisar su tendencia.
5. Ajustar modelo
6. Estudiar si el modelo es el adecuado, si no es así volver a 4,5.
7. Calcular predicciones.

2.2.19. Análisis Espectral

El análisis espectral es una herramienta que permite analizar las características cíclicas de los datos. Su objetivo es determinar las frecuencias que influyen mayoritariamente en la variabilidad de la Serie de Tiempo.

Densidad Espectral

Sea X_t un proceso estocástico estacionario, donde:

- $E(X_t)$: Esperanza del proceso.
- $\gamma(k)$: Función de autocovarianza del proceso.

Se define la función generadora de autocovarianzas como:

$$\Gamma(Z) = \sum_{k=-\infty}^{+\infty} \gamma(k) Z^k \quad \frac{1}{r} < |Z| < r \quad (2.45)$$

$$Y \text{ donde } \sum_{k=-\infty}^{+\infty} |\gamma(k)| < \infty \quad (2.46)$$

Luego, la densidad espectral se define como:

$$f(\lambda) = \frac{1}{2\pi} \Gamma(e^{-ik\lambda}) = \frac{1}{2\pi} \sum_{k=-\infty}^{+\infty} \gamma(k) e^{-ik\lambda} \quad (2.47)$$

Donde $e^{-ik\lambda} = \cos(k\lambda) - i \sin(k\lambda)$ con $i = \sqrt{-1}$

Ya que Coseno y Seno tienen periodo 2π , entonces $f(\lambda)$ también está en el intervalo $[-\pi, \pi]$.

Propiedades

- $f(\lambda)$ es una función real de λ
- $f(\lambda)$ es simétrica entorno al cero
- $f(\lambda) \geq 0$
- $f(\lambda) = f(\lambda + 2k\pi)$

A partir de $f(\lambda)$ se puede escribir:

$$\gamma(k) = \int_{-\pi}^{\pi} f(\lambda) e^{-ik\lambda} d\lambda \quad (2.48)$$

Otra forma de escribir la densidad espectral, es a través de un proceso estacionario

$$X_t = \sum_{j=0}^{+\infty} \Psi_j \epsilon_{t-j} \quad (2.49)$$

$$\text{Donde } \Psi(Z) = \sum_{j=-\infty}^{+\infty} \Psi_j B^j \quad \Rightarrow \quad f(\lambda) = \frac{\sigma^2}{2\pi} \left| \sum_{j=-\infty}^{+\infty} \Psi_j e^{-ij\lambda} \right|^2 \quad (2.50)$$

Periodograma

Si se quiere estimar el espectro a partir de la información que se tiene disponible se utiliza el periodograma, su característica es que corresponde a un estimador asintóticamente insesgado con varianza no consistente.

$$I(\lambda) = \frac{1}{2\pi n} \left| \sum_{t=1}^n X_t e^{-i\lambda t} \right|^2 \quad (2.51)$$

Al graficar el periodograma versus la frecuencia se obtiene un gráfico que muestra los diversos peaks los cuales aportan a la variabilidad de la serie.

Periodograma




Figura 2.3: Fuente: Brockwell (2002). Introduction Time Series and Forecasting [4]

Análisis espectral en una serie de tiempo

- Graficar la serie y observar la existencia de tendencia.
- Estudiar la variabilidad de los datos.
- Si la serie presenta una tendencia la clara (vector de medias no constante), aplicar una transformación a los datos, como Logarítmica, Exponencial, entre otros.
- Si la serie presenta un comportamiento no estacionario, se procede a diferenciarla.
- Estimar el periodograma y graficar estimadores con el fin de observar un comportamiento mas suave de la serie y de esta manera poder identificar aquellos peaks más pronunciados que realmente aportan a la variabilidad

2.3. Modelo ARIMAX

Proviene del acrónimo en inglés Autoregressive Integrated Moving-average with eXogenous variables.

Éste modelo se puede seccionar en tres partes: La primera es la parte Auto Regresiva (AR) que plantea una combinación lineal con la serie misma en periodos de tiempo anterior, la segunda de Medias Móviles (MA) que estima los valores a través de una relación en una sucesión de errores ponderados y de períodos anteriores y por último la tercera parte (X) son las observaciones anteriores de una serie exógena o dicho de otra forma, de datos conocidos de una variable independiente a través del tiempo. Adicionalmente, al considerar la serie diferenciada, que se espera que sea estacionaria se obtiene el modelo ARIMAX.

La estimación de parámetros ARIMA es análogo al modelo tradicional mientras que las variables independientes incluidas se estiman mediante regresión, quedando finalmente el modelo de la forma:

$$\left(1 - \sum_{i=1}^p \phi_i B^i\right) y_t = \left(1 + \sum_{j=1}^q \theta_j B^j\right) \epsilon_j + \left(1 + \sum_{i=1}^k \beta_i B^i\right) x_i \quad (2.52)$$

O bien también podemos reescribirlo de ésta manera:

$$y_t = \beta_0 + \beta_1 X_{1,t} + \beta_2 X_{2,t} + \dots + \beta_k X_{k,t} + \frac{(1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)}{(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)} \epsilon_t \quad (2.53)$$

Gráficamente podemos describir su funcionamiento mediante la siguiente imagen:




Figura 2.4: Fuente: Gras, A.J. (2001) *Diseños de series temporales: técnicas de análisis*. [13]

2.4. Modelo ARCH

La volatilidad es una característica inherente a las series de tiempo financieras. En general, no es constante y en consecuencia los modelos de series de tiempo tradicionales, que suponen homocedasticidad en varianza, no son efectivos para modelar éste tipo de comportamiento. (Casas, M. (2008)[6])

Engle (1982) propuso el modelo ARCH, que significa modelo Auto Regresivo Condicionalmente Heterocedástico en los cuales la varianza condicionada a la información pasada no es constante, y depende del cuadrado de las innovaciones pasadas.

Años más tarde Bollerslev (1986) generaliza los modelos ARCH al proponer los modelos GARCH² en los cuales la varianza condicional depende no solo de los cuadrados de las perturbaciones, como en Engle, sino además, de las varianzas condicionales de períodos anteriores.

2.4.1. Modelo de Regresión

Si la variable aleatoria y_t con $t \in I$, donde I es un conjunto discreto de índices), es muestreada de la función de densidad condicional

$$f(y_t | \psi_{t-1}) \quad (2.54)$$

el pronóstico del valor actual de la variable condicionado a la información pasada ψ_{t-1} es:

$$\mu_t = E[y_t | \psi_{t-1}] \quad (2.55)$$

La media puede modelarse, por ejemplo, a través del modelo de regresión $\mu_t = x_t \beta$, donde $x_t = (1, x_{t1}, \dots, x_{tk})$ es el vector de observaciones de las variables independientes y $\beta_0 = (\beta_0, \beta_1, \dots, \beta_k)$ es un vector de parámetros desconocidos. La varianza condicional, $\text{Var}(y_t | \psi_{t-1})$, depende de la información pasada y esta dependencia puede modelarse mediante una función $h_t = h(\epsilon_{t-1}, \epsilon_{t-2}, \dots, \epsilon_{t-p}, a)$, la cual se tiene en cuenta que la varianza es positiva y donde $\alpha_0 = (\alpha_0, \alpha_1, \dots, \alpha_p)$ es un vector de parámetros desconocidos. En este modelo, $\epsilon_t = y_t - x_t \beta$ para $t \in I$ y la información ψ_{t-1} es la sigma álgebra generada por $(\epsilon_{t-1}, \epsilon_{t-2}, \dots)$.

²Proviene del acrónimo en inglés **Generalized Autoregressive Conditional Heterocedasticity**.

2.4.2. Supuestos

Un proceso y_t con $t \in I$ obedece al modelo en regresión auto regresivo condicionalmente heterocedástico de orden p , ARCH(p) (Engle 1982), si:

$$y_t | \psi_{t-1} \sim N(\mu_t, h_t) \quad (2.56)$$

$$\mu_t = x_t \beta \quad (2.57)$$

$$h_t = \alpha_0 + \alpha_1 \epsilon_{t-1}^2 + \dots + \alpha_p \epsilon_{t-p}^2 \quad (2.58)$$

$$\epsilon = y_t - x_t \beta \quad (2.59)$$

con $\alpha_0 > 0, \alpha_i \geq 0, i = 1, \dots, p$

A partir de los supuestos del modelo se deduce que $\epsilon_t | \psi_{t-1} \sim N(0, h_t)$ y si el proceso $y_t | \psi_{t-1}$ tiene media $\mu_t = 0$, $\epsilon_t = y_t$ dentro de la varianza h_t sólo quedarían los errores al cuadrado y como resultado el modelo puede expresarse como:

$$\epsilon_t | \psi_{t-1} \sim N(0, h_t) \quad (2.60)$$

$$h_t = \alpha_0 + \alpha_1 \epsilon_{t-1}^2 + \dots + \alpha_p \epsilon_{t-p}^2 \quad (2.61)$$

La cual corresponde a un modelo ARCH de orden p . La varianza es modelada como un proceso auto regresivo AR(p) en las variables $\mu_t = \epsilon_t^2$. Análogamente las esperanzas y varianzas no condicionales para el modelo definido en (2.60) y (2.61) son:

$$E[\epsilon_t] = E[E[\epsilon_t | \psi_{t-1}]] = 0 \quad (2.62)$$

$$Var[\epsilon_t] = E[\epsilon_t^2] = E[E[\epsilon_t^2 | \psi_{t-1}]] = E[h_t] = \sigma_t^2 \quad (2.63)$$

Si la varianza condicional h_t está dada por la ecuación (2.61), al sustituir $Var[\epsilon_t] = E[h_t]$ se obtiene lo siguiente:

$$Var[\epsilon_t] = \alpha_0 + \alpha_1 Var[\epsilon_{t-1}] + \dots + \alpha_p Var[\epsilon_{t-p}] \quad (2.64)$$

Luego, dado el proceso ϵ_t estacionario, $Var[\epsilon_t] = Var[\epsilon_{t-k}]$ para todo k y, luego de despejar, la varianza no condicional está dada por:

$$Var[\epsilon_t] = \frac{\alpha_0}{1 - \alpha_1 - \dots - \alpha_p} = \sigma_t^2 \quad (2.65)$$

A raíz de ésta expresión es que surge una de las restricciones para la suma de coeficientes α : $\sum_{i=1}^p \alpha_i < 1$.

2.4.3. Función de Verosimilitud

Suponiendo que $y_t \in I$ es generado por un proceso ARCH(p) en regresión como el definido por las ecuaciones (2.56) a (2.59). La función de verosimilitud para la observación t-ésima es:

$$f(y_t|\psi_{t-1}) = \frac{1}{\sqrt{h_t}\sqrt{2\pi}} e^{-\frac{1}{2} \frac{(y_t - \mu_t)^2}{h_t}} = \frac{1}{\sqrt{h_t}\sqrt{2\pi}} e^{-\frac{1}{2} \frac{\epsilon_t^2}{h_t}} \quad (2.66)$$

entonces su logaritmo, sin tomar en cuenta las constantes es el siguiente:

$$l_t = -\frac{1}{2} \log(h_t) - \frac{1}{2} \frac{\epsilon_t^2}{h_t} \quad (2.67)$$

Por lo tanto el logaritmo de la función de verosimilitud L para T observaciones es:

$$L = \frac{1}{T} \sum_{t=1}^T l_t \quad (2.68)$$

Esta función puede ser maximizada respecto a los vectores paramétricos α y β . Los estimadores máximo verosímiles se encuentran al resolver el sistema dado por las condiciones de primer orden:

$$\frac{\partial l_t}{\partial \alpha} = -\frac{1}{2h_t} \frac{\partial h_t}{\partial \alpha} \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \quad (2.69)$$

$$\frac{\partial l_t}{\partial \beta} = \frac{\epsilon_t x_t'}{h_t} + \frac{1}{2h_t} \frac{\partial h_t}{\partial \beta} \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \quad (2.70)$$

Para la ecuación (2.69), la derivada parcial de l_t respecto a la componente j-ésima de α , $1 \leq j \leq p$, es:

$$\frac{\partial l_t}{\partial \alpha_j} = -\frac{1}{2} \frac{1}{h_t} \frac{\partial h_t}{\partial \alpha_j} + \frac{1}{2} \left(\frac{\epsilon_t^2}{h_t^2} \frac{\partial h_t}{\partial \alpha_j} \right) = \frac{1}{2h_t} \frac{\partial h_t}{\partial \alpha_j} \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \quad (2.71)$$

Para (2.70) la derivada parcial de l_t respecto a β_l , para $1 \leq l \leq k$ es:

$$\frac{\partial l_t}{\partial \beta_l} = -\frac{1}{2} \frac{1}{h_t} \frac{\partial h_t}{\partial \beta_l} - \frac{1}{2} \left(2\epsilon_t \frac{\partial \epsilon_t}{\partial \beta_l} h_t^{-1} - \epsilon_t^2 h_t^{-2} \frac{\partial h_t}{\partial \beta_l} \right) = \frac{\epsilon_t x_{tl}}{h_t} + \frac{1}{2h_t} \frac{\partial h_t}{\partial \beta_l} \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \quad (2.72)$$

puesto que $\frac{\partial \epsilon_t}{\partial \beta_l} = -x_{tl}$, para $1 \leq l \leq k$.

Los bloques de la Matriz Hessiana H serán:

$$H_{\alpha\alpha} = \frac{\partial^2 l_t}{\partial \alpha \partial \alpha'} = -\frac{1}{2h_t^2} \frac{\partial h_t}{\partial \alpha} \frac{\partial h_t}{\partial \alpha'} \left(\frac{\epsilon_t^2}{h_t} \right) + \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \frac{\partial}{\partial \alpha'} \left(\frac{1}{2h_t} \frac{\partial h_t}{\partial \alpha} \right) \quad (2.73)$$

$$H_{\beta\beta} = -\frac{x_t' x_t}{h_t} \frac{\partial^2 l_t}{\partial \beta \partial \beta'} = -\frac{1}{2h_t^2} \frac{\partial h_t}{\partial \beta} \frac{\partial h_t}{\partial \beta'} \left(\frac{\epsilon_t^2}{h_t} \right) - \frac{2\epsilon_t x_t'}{h_t^2} \frac{\partial h_t}{\partial \beta'} + \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \frac{\partial}{\partial \beta'} \left(\frac{1}{2h_t} \frac{\partial h_t}{\partial \beta} \right) \quad (2.74)$$

$$H_{\alpha\beta} = \frac{\partial^2 l_t}{\partial \alpha \partial \beta'} = \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \frac{\partial}{\partial \beta'} \left[\frac{1}{2h_t} \frac{\partial h_t}{\partial \alpha} \right] - \frac{1}{2h_t^2} \frac{\partial h_t}{\partial \alpha} \left[2\epsilon_t x_t + \left(\frac{\epsilon_t^2}{h_t} \right) \frac{\partial h_t}{\partial \beta'} \right] \quad (2.75)$$

Los Hessianos se obtienen al derivar parcialmente las ecuaciones (2.69) y (2.70) respecto a α y β . La matriz de información I queda de la siguiente forma:

$$I(\Theta) = -E \left[\frac{\partial^2 \ln L}{\partial \Theta \partial \Theta'} \right] = E \left[\frac{\partial \ln L}{\partial \Theta} \frac{\partial \ln L}{\partial \Theta'} \right] = -E[H] \quad (2.76)$$

En donde H es la matriz Hessiana y Θ el vector de parámetros. Al estimar la matriz de información se hallan las varianzas estimadas de los parámetros, lo que nos permite realizar estimaciones de los parámetros por intervalos de confianza.

En el caso que está tratando, el cálculo de la matriz de información se simplifica si se condiciona a la información pasada ψ_{t-1} y se tienen en cuenta los siguientes hechos:

- $I(\Theta) = -E[H] = E[E(H|\psi_{t-1})]$
- $E \left[\frac{\epsilon_t^2}{h_t} | \psi_{t-1} \right] = 1$
- $E[\epsilon_t | \psi_{t-1}] = 0$

Entonces, es posible obtener los bloques de la matriz de información aplicando esperanza condicional a las ecuaciones (2.73), (2.74) y (2.75):

$$I_{\alpha\alpha} = \frac{1}{T} \sum_t^T -E \left[E \left(\frac{\partial^2 l_t}{\partial \alpha \partial \alpha'} | \psi_{t-1} \right) \right] = \frac{1}{T} \sum_t^T E \left[\frac{1}{2h_t^2} \frac{\partial h_t}{\partial \alpha} \frac{\partial h_t}{\partial \alpha'} \right] \quad (2.77)$$

$$I_{\beta\beta} = \frac{1}{T} \sum_t^T -E \left[E \left(\frac{\partial^2 l_t}{\partial \beta \partial \beta'} | \psi_{t-1} \right) \right] = \frac{1}{T} \sum_t^T E \left[\frac{x_t' x_t}{h_t} + \frac{1}{2h_t^2} \frac{\partial h_t}{\partial \beta} \frac{\partial h_t}{\partial \beta'} \right] \quad (2.78)$$

$$I_{\alpha\beta} = \frac{1}{T} \sum_t^T -E \left[E \left(\frac{\partial^2 l_t}{\partial \alpha \partial \beta'} | \psi_{t-1} \right) \right] = \frac{1}{T} \sum_t^T E \left[\frac{1}{2h_t^2} \frac{\partial h_t}{\partial \alpha} \frac{\partial h_t}{\partial \beta'} \right] \quad (2.79)$$

A modo de ejemplo si quisiéramos obtener el resultado (2.77) al calcular la esperanza condicionada a la información pasada a la ecuación (2.70), la esperanza del primer sumando es el resultado que se muestra (2.77) y la del segundo sumando es cero. De manera similar se obtienen los bloques restantes de la matriz de información.

2.5. Modelo GARCH

Proviene del Acrónimo en inglés **Generalized Autoregressive Conditional Heteroscedasticity**, que extiende la clase de los modelos ARCH, introducidas por Bollerslev en 1991. En éstos la estructura de la varianza condicional depende, además del cuadrado de los errores retrasados q períodos como en el modelo ARCH(q), de las varianzas condicionales retrasadas p períodos.

Sea $y_{t \in T}$ un proceso estocástico donde T es un conjunto discreto de índices. Sean

$$\beta = (\beta_0, \beta_1, \dots, \beta_k,) \quad (2.80)$$

$$\omega = (\alpha_0, \alpha_1, \dots, \alpha_q, \gamma_1, \dots, \gamma_p) \quad (2.81)$$

Vectores para modelar la media y varianza respectivamente, $Z_t = (1, \epsilon_{t-1}^2, \dots, \epsilon_{t-q}^2, h_{t-1}, \dots, h_{t-p})$ el vector de variables para la varianza, $X_t = (1, x_{t1}, \dots, x_{tk})$ el vector de variables explicativas observadas en el tiempo t . En este modelo, $\epsilon_t = y_t - x_t\beta$ y ϕ_t es la información disponible hasta el tiempo $t - 1$. El Modelo GARCH(p, q) en regresión Bollerslev (1991) está dado por:

$$y_t | \phi_{t-1} \sim N(\mu_t, h_t) \quad (2.82)$$

$$\mu_t = x_t\beta \quad (2.83)$$

$$h_t = z_t\omega = \alpha_0 + \sum_{i=1}^q \alpha_i \epsilon_{t-i}^2 + \sum_{i=1}^p \gamma_i h_{t-i} \quad (2.84)$$

$$\epsilon_t = y_t - x_t\beta \quad (2.85)$$

Donde, $p \geq 0$, $q > 0$, $\alpha_0 > 0$, $\alpha_i \geq 0$, $i = 1, \dots, q$ y $\gamma_i \geq 0$, $i = 1, \dots, p$.

Ahora la varianza condicional depende tanto del cuadrado de los errores como de las varianzas condicionales retrasadas en p períodos, como se indica en 2.84. Si $p = 0$, se tiene un proceso ARCH(q) en regresión.

2.5.1. Estimación de Parámetros.

Notaremos que $\Theta = \theta : \theta = (\beta, \omega)$ el espacio paramétrico, un subespacio compacto de un espacio euclidiano, donde $\beta = (\beta_0, \beta_1, \dots, \beta_k)$ y $\omega = (\alpha_0, \alpha_1, \dots, \alpha_q, \gamma_1, \dots, \gamma_p)$. La función de verosimilitud para una muestra de T observaciones, tiene la forma dada en la ecuación del proceso ARCH(p):

$$l(\Theta) = \frac{1}{T} \sum_{t=1}^T l_t(\Theta) \quad (2.86)$$

$$l(\Theta) = -\frac{1}{2} \log h_t - \frac{1}{2} \epsilon_t^2 h_t^{-1} \quad (2.87)$$

Derivando $l(\Theta)$ con respecto a los parámetros para la varianza, se obtienen, de manera semejante al proceso ARCH(q), las condiciones del primer y segundo orden para la varianza serán:

$$\frac{\partial l_t}{\partial \omega} = -\frac{1}{2} h_t^{-1} \frac{\partial h_t}{\partial \omega} \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \quad (2.88)$$

$$\frac{\partial^2 l_t}{\partial \omega \partial \omega'} = \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \frac{\partial}{\partial \omega'} \left[\frac{1}{2} h_t^{-1} \frac{\partial h_t}{\partial \omega} \right] - \frac{1}{2} h_t^{-2} \frac{\partial h_t}{\partial \omega} \frac{\partial^2 l_t}{\partial \omega' \partial \omega} \frac{\epsilon_t^2}{h_t} \quad (2.89)$$

donde

$$\frac{\partial h_t}{\partial \omega} = z_t + \sum_{i=1}^p \gamma_i \frac{\partial h_{t-1}}{\partial \omega} \quad (2.90)$$

El resultado se obtiene dado que $\frac{\partial h_t}{\partial \omega_i} = \frac{\partial h_t}{\partial \alpha_i} = \epsilon_{t-i}^2 + \sum_{i=1}^p \gamma_i \frac{\partial h_{t-1}}{\partial \alpha_i}$.

Luego, la matriz de información para los parámetros de la varianza está dada por:

$$I_{\omega\omega} = \frac{1}{T} \sum_t E \left[\frac{1}{2h_t^2} \frac{\partial h_t}{\partial \omega} \frac{\partial h_t}{\partial \omega'} \right] \quad (2.91)$$

$I_{\omega\omega}$ es la estimada consistentemente por su análogo muestral, que involucra únicamente las primeras derivadas.

$$\hat{I}_{\omega\omega} = \frac{1}{T} \sum_t \frac{1}{2h_t^2} \frac{\partial h_t}{\partial \omega} \frac{\partial h_t}{\partial \omega'} \quad (2.92)$$

Diferenciando la verosimilitud con respecto a los parámetros para la media, obtenemos las condiciones de primer y segundo orden para la media:

$$\frac{\partial l_t}{\partial \beta} = \frac{\epsilon_t x_t'}{h_t} + \frac{1}{2h_t} \frac{\partial h_t}{\partial \beta} \left(\frac{\epsilon_t^2}{h_t} - 1 \right) \quad (2.93)$$

2.6. Redes Neuronales

2.6.1. Introducción

Se define una Red Neuronal como a través de la siguiente cita: "Conjunto de procesadores elementales interconectados, no lineal ni estacionario, que realiza al menos alguna de las siguientes funciones: Aprendizaje, Memorización, Generalización o Abstracción de características esenciales, a partir de un conjunto de ejemplos". Correa, R. (2006) [8]

Es un paradigma de aprendizaje y procesamiento computacional inspirado en el funcionamiento del cerebro humano. Simula un gran número de interconexiones denominadas Dentrinas, las cuales cumplen la función de conectar y realizar intercambio de información entre Neuronas o Nodos.

Los pioneros en proponer formalmente el uso de Redes Neuronales Artificiales fueron el matemático Walter Pitts y el neurofisiólogo Warren McCulloch en su artículo "*A Logical Calculus of the Ideas Immanent in Nervous Activity*", en el cual plantean un modelo computacional formado por unidades dicotómicas que percibían dos tipos de estímulos de otras unidades o nodos, formando una red de intercomunicación.

2.6.2. Estructura

Para entender el funcionamiento dentro de una Red Neuronal Artificial debemos identificar los elementos que la componen. En nuestro caso el enfoque se centrará en las Redes Neuronales tipo Perceptrón Multicapa:




Figura 2.5: Red Neuronal

Conexiones

Existen dos principales tipos de conexiones. *FeedForward*, en la cual las señales viajan de entrada a salida y las capas internas son actualizadas antes de la salida. Por otro lado las *Recurrentes*, en donde existen conexiones entre capas anteriores así como también entre perceptrones.

Capas de entrada, ocultas y de salida

- **Capas de entrada** : Hace referencia a las unidades en donde ingresa el estímulo externo, es decir, el valor de las variables explicativas. El número de capas de entrada para efectos de este estudio será determinado por el número de variables independientes a analizar.
- **Capas de salida** : Representa el valor pronosticado de la red neuronal
- **Capas ocultas** : Conjunto de nodos interconectados entre la capa de entrada y salida mediante Dentrías representadas por Pesos sinápticos o coeficientes w_j .

Uno de los principales problemas al implementar una Red Neuronal Perceptrón Multicapa (MPL) es definir el número de capas y nodos ocultos.

El desempeño del modelo predictivo dependerá directamente del número de nodos ocultos en su arquitectura. Para determinarlo nos basaremos en el documento "Las redes neuronales artificiales: fundamentos teóricos y aplicaciones prácticas" de Florez-Lopez, R(2008) [11].

En el texto de Florez-Lopez (2008) [11] señalan que la propiedad de aproximador universal de funciones de la MPL requiere un máximo de dos capas ocultas, normalmente se requiere de sólo una para conseguir resultados óptimos.

LIPPMAN (1987) considera que las redes con una única capa oculta resultan suficientes para resolver problemas arbitrariamente complejos, siempre y cuando que la capa oculta incluya al menos tres veces el número de nodos de entrada.

Por otra parte HECHT-NIELSEN (1990) y LIPPMAN (1987) aplican una extensión del teorema de Kolmogorov para demostrar que con una red con una única capa oculta integrada por $2N + 1$ neuronales y con funciones de transferencia continuas, no lineales y monótonamente crecientes, resulta suficiente para computar cualquier función continua de N variables de entrada.

Entre las reglas más conocidas para determinar el número de neuronas en una capa oculta destacan las siguientes:

- **Regla de la Pirámide geométrica** : Se basa en la suposición de que el número de neuronas de la capa oculta ha de ser inferior al total de variables de entrada, pero superior al de variables de salida. Se considera que el número de neuronas de cada capa sigue una progresión geométrica, tal que, para una red con una única capa oculta, el número de neuronas intermedias debe ser próximo a $\sqrt{N * M}$, siendo N el número de variables de entrada y M el total de neuronas de salida.
- **Regla de la capa oculta-capla entrada** : El número de neuronas ocultas está relacionado con el número de neuronas de entrada. En particular, suele aplicarse la regla de 2x1, de forma que el número de neuronas ocultas no puede ser superior al doble del número de variables de entrada.
- **Regla de la capa oculta-número de patrones** : Ésta regla relaciona el número de neuronas de la capa oculta con el total de patrones representados al sistema, siendo habitual la relación 1/30, es decir, una neurona por cada 30 patrones

Función de Activación

: Define la salida de un nodo dada una entrada o un conjunto de entradas. Debe ser continua y derivable en todos sus puntos. La función puede estar dada por

$$g(x) = \begin{cases} 1 & x + t > 0 \\ 0 & x + t \leq 0 \end{cases} \quad (2.94)$$

$$g(x) = \frac{1}{1 + e^{-2s(x+t)}} \quad (2.95)$$

$$g(x) = \frac{e^{2(s(x+t))-1}}{e^{2(s(x+t))+1}} \quad (2.96)$$

En donde s es la inclinación y t el valor de activación de la función.

Regularización

Una de las formas de controlar el ajuste de la función obtenida por la red es mediante el control del término de suavizado, lo que requiere limitar el número de parámetros del sistema. Éste proceso se conoce como **Regularización**, existiendo distintas propuestas para su aplicación en Redes Neuronales. Entre ellas destaca el conjunto de inclusión de términos adicionales en la función de error que penalizan los pesos con valores elevados.

$$E_g(w) \approx \sum_{p=1}^P E(y_p^l, t_p) + \frac{1}{2} \lambda \sum_{l=0}^L \sum_{k=0}^{N_j} w_{lk}^2 \quad (2.97)$$

Donde l y k son índices del total de pesos en la red.

La aplicación del *Gradiente descendente* a la función de error previa a la obtención de la regla de actualización:

$$\Delta w = -\eta \frac{\partial E(w)}{\partial w} - \eta \lambda w \quad (2.98)$$

que resulta equivalente a llevar a cabo una actualización ordinaria del vector de pesos y luego reducir su valor a través de un pequeño término $\eta \lambda$, obteniéndose:

$$w_{ij}(t+1) = (1 - \eta \lambda) w_{ij}(t) \quad (2.99)$$

donde $w_{ij}(t)$ es el valor de los pesos obtenido después de una actualización ordinaria. Los parámetros η y λ deben ser reducidos y se determinan a priori por el usuario, lo que constituye una de las limitaciones del modelo.

Otras técnicas de regularización altamente aplicadas en la práctica son el modelo de parada temprana o *early stopping* y las variantes del decaimiento de pesos basadas en modelos bayesianos.

2.6.3. Aprendizaje

Es el proceso de adaptación de los pesos sinápticos w_j de la Red Neuronal. Se busca iterativamente el valor óptimo que minimice el error tanto para los datos de entrenamiento como los de validación. Si nos enfocamos en el tipo de aprendizaje que puede tener una Red Neuronal podemos destacar dos tipos:

1. **Supervisado** : Cuenta con un llamado "Maestro", es decir, la Red Neuronal aprende iterativamente comparando con una referencia de datos conocidos para así minimizar el error. Actualiza los pesos sinápticos w_j a fin de que la salida actual y la esperada se acerquen lo más posible. Para la optimización iterativa se utilizan generalmente métodos matemáticos de optimización no lineal y una función de discrepancia, que en nuestro caso será el Error Cuadrático Medio, cuyo valor se busca minimizar.




Figura 2.6: Esquema de aprendizaje supervisado

2. **No Supervisado** : No posee un "Maestro" y en base a entrenamiento busca encontrar patrones a partir de los datos de entrada. Se utilizan principalmente para categorizar comportamientos de variables. Un ejemplo de ellas son las Redes de Kohonen.




Figura 2.7: Imagen referencial Mapas de Kohonen

Para efectos de éste estudio se utilizarán las Redes Neuronales de aprendizaje supervisado ya que se busca pronosticar el comportamiento de la demanda de Cemento en Chile.

2.6.4. Algoritmo de Retropropagación o Backpropagation

En 1986 los científicos Rumelhart, Williams y Hinton desarrollaron un método de aprendizaje que consta de más capas que el Perceptrón original. (Rumelhart (1985) [21])

Consiste en que la red asocie los patrones de entrada a si misma y sus clases correspondientes. Se conoce como Backpropagation o Retropropagación del Error, es un tipo de aprendizaje supervisado con un ciclo de propagación-adaptación de dos fases.

En el momento en que se aplica el patrón de entrenamiento en la capa de entrada, éste se propaga hacia adelante, desde el inicio del Perceptrón hasta la capa de salida, luego el valor de salida es comparado con el observado, calculando el error de aprendizaje.

Posteriormente el error es propagado hacia atrás, desde la capa de salida hacia las capas ocultas anteriores hasta llegar a la capa de entrada, actualizando los pesos sinápticos w_j a fin de que las predicciones sean lo más certeras posibles.




Figura 2.8: Imagen referencial de la retropropagación del error δ_1

El algoritmo puede describirse mediante los siguientes pasos:

1. Se asignan aleatoriamente valores iniciales a los pesos sinápticos W_j de la red. Luego ingresar un patrón de entrada, es decir, valores a la capa de entrada de las variables independientes $X_p : (X_{p1}, X_{p2}, \dots, X_{pn})$ para posteriormente especificar la salida deseada que debe generar la red.
2. Calcular la salida actual de la red a partir de los valores de respuesta de cada capa según la capa de entrada. Dentro de este paso se realiza lo siguiente:
 - Calcular entradas netas (N) para las neuronas ocultas procedentes de las neuronas de entrada. Para una neurona oculta j (O_j).

$$N_{pj}^h = \sum_{i=1}^m w_{ji}^h x_{pi} + b_i^h \quad (2.100)$$

Donde el sub índice p corresponde al p -ésimo vector de entrenamiento, j a la j -ésima neurona oculta, w_{ji} es el peso sináptico de la conexión entre E_i y O_j . b_j Corresponde al umbral mínimo para la activación de la neurona utilizando la función de activación f .

$$y_{pj} = f_j^h \left(N_{pj}^h = \sum_{i=1}^m w_{ji}^h x_{pi} + b_i^h \right) \quad (2.101)$$

- Se realizan los mismos pasos para obtener el resultado de los cálculos de cada neurona k en la capa de salida.

$$N_{pk}^o = \sum_{j=1}^m w_{kj}^o y_{pj} + b_k^o \quad (2.102)$$

$$y_{pk} = f_k^o \left(N_{pk}^o = \sum_{j=1}^m w_{kj}^o y_{pj} + b_k^o \right) \quad (2.103)$$

Para minimizar el error la función f debe ser derivable, lo que implica que la función de escalón queda descartada. En general se utilizan dos tipos de función de activación: La función lineal y la función sigmoidea definida por la ecuación ().

$$f(N_{jk}) = \frac{1}{1 + e^{-N_{jk}}} \quad (2.104)$$

3. Se continúa encontrando el error para todas las neuronas, excepto las de la capa de entrada. Para la neurona k de la capa de salida, si la respuesta es $(y_1, y_2, \dots, y_m)$, el error (d), puede ser descrito por:

$$e = (d_{pk} - y_{pk}) \quad (2.105)$$

4. Obtención de delta, cuya composición es el producto del error con la derivada de la función de activación respecto a los pesos de la red:

$$\delta_{pk}^o = e f_k^{o'} (N_{pk}^o) \quad (2.106)$$

Luego, si reemplazamos la función de activación y el error tenemos lo siguiente:

$$\delta_{pk} = (d_{pk} - y_{pk}) y_{pk} (1 - y_{pk}) \quad (2.107)$$

5. Si la neurona j no es de salida, entonces la derivada parcial del error no puede ser evaluada directamente. Por tanto, se obtiene el desarrollo a partir de los valores que son conocidos y otros que pueden ser evaluados. La expresión obtenida en este caso es:

$$\delta_{pk} = x_{pi} (1 - x_{pi}) \sum_{k=1}^T \delta_{pk} w_{kj} \quad (2.108)$$

Donde T es el total de capas de salida del proceso. Se observa que el error en las capas ocultas depende de todos los términos del error de la capa de salida. De aquí el nombre de Retropropagación.

6. Éste paso consiste en la actualización de los pesos W . Se utiliza el algoritmo recursivo del gradiente descendente, comenzando por las neuronas de salida y trabajando hacia atrás hasta llegar a la capa de entrada.

- Para los pesos de las neuronas de salida se tiene:

$$w_{kj}^o(t+1) = w_{kj}^o(t) + \Delta w_{kj}^o(t+1) \quad (2.109)$$

$$\Delta w_{kj}^o(t+1) = \alpha \delta_{pk}^o y_{pj} \quad (2.110)$$

- Análogamente para los pesos de las neuronas de la capa oculta:

$$w_{ji}^h(t+1) = w_{ji}^h(t) + \Delta w_{ji}^h(t+1) \quad (2.111)$$

$$\Delta w_{ji}^h(t+1) = \alpha \delta_{pi}^h y_{pj} \quad (2.112)$$

7. El proceso termina cuando se encuentra un valor aceptablemente pequeño para el Error Cuadrático Medio para cada uno de los patrones aprendidos. el ECM está determinado por:

$$ECM = \frac{1}{m} \sum_{k=1}^m (\delta_{pk})^2 \quad (2.113)$$

El método estándar y utilizado en ésta tesis para el criterio de minimización del ECM es Levenberg-Mardquardt que consiste en modificar los parámetros según la relación:

$$\Theta_k = \Theta_{k-1} - [H_{k-1} + \Lambda_{k-1} \cdot I]^{-1} \nabla J_{k-1} \quad (2.114)$$

Donde I representa a la matriz identidad. La ventaja de éste método radica en que se adapta a sí mismo a la función de costo.

2.7. Análisis y diagnóstico de Modelos

2.7.1. Diagnostico en Regresión Lineal

Esto se realiza para comprobar si los supuestos propuestos antes mencionados se satisfacen. (Norman R. (1998) [18] y Rojo, J.M. (2007) [20]).

Normalidad de los Residuos

Existen dos formas de comprobar éste supuesto, una es mediante representaciones gráficas un histograma, el cual debe seguir la forma de una campana de Gauss.

Otra forma es mediante Ésta gráfica contrasta cuantiles de una variable contra cuantiles de una distribución normal. Cuanto más cerca estén los cuantiles de la variable a los cuantiles de la distribución normal (línea diagonal continua) más cerca está la variable de estar normalmente distribuida.

Por otra parte esta el contaste inferencial, entre los test más conocidos para poder evaluar dicho supuesto es Shapiro-Wilk³ y Kolmogorov- Smirnov⁴ cuya dócima corresponde a:

$$H_0 : \epsilon_i \sim N(0, \sigma^2) \quad \text{versus} \quad H_1 : \epsilon_i \not\sim N(0, \sigma^2)$$

Donde cada test en particular presenta su estadístico para analizar dicha dócima, la finalidad de estos test es no rechazar H_0 , ya que de esta forma se podría decir que los residuos distribuyen normal.

Si es que esto no se cumple se podrían realizar algunas transformaciones convenientes para solucionar el problema y poder cumplir con el supuesto. Entre la más conocida está la familia de Box-Cox, que soluciona los problemas de falta de normalidad y de heterocedasticidad , cuya definición es la siguiente.

$$Z_{\lambda,i} = \begin{cases} \frac{y_i \lambda^{-1}}{\lambda \dot{y}^{\lambda-1}} & \text{si } \lambda \neq 0 \\ \dot{y} \cdot \ln(y_i) & \text{si } = 0 \end{cases} \quad \text{Donde } \dot{y} = (y_1 y_2 \cdot \dots \cdot y_n)^{1/2}$$

³El Test de Shapiro-Wilk se usa para contrastar la normalidad de un conjunto de datos.

⁴ Prueba no paramétrica que se utiliza para determinar la bondad de ajuste de dos distribuciones de probabilidad entre sí.




Figura 2.9: Heterocedástico




Figura 2.10: Homocedástico

Homocedasticidad

Se habla de homocedasticidad cuando la varianza de las perturbaciones aleatorias condicional a los valores de las variables independientes se mantiene constante $\mathbb{V}(\epsilon_i|x_i) = \sigma^2$. Este supuesto es muy importante, ya que si se cumple homocedasticidad (Figura 2.10) significa que el modelo está bien especificado, no debería existir un patrón definido entre los residuos y la variable dependiente.

Si no se cumple el supuesto se le denomina heterocedasticidad (Figura 2.9), provocando que la varianza de los estimadores esté sesgada, por lo que las pruebas t y F no serían tan confiables. Para la detección de heterocedasticidad existen métodos gráficos e inferenciales para evaluar el supuesto. Gráficamente se tiene la relación de los residuos del modelo en el eje y versus el indicador de la observación correspondiente en el eje x.

Por otra parte dentro de los métodos formales que se utilizan para probar el supuesto de homocedasticidad se encuentra el Contraste de Breusch-Pagan, Contraste de White y El test de Bartlett.

En caso de que se esté en presencia de heterocedasticidad (Figura 2.9) se puede aplicar la transformación de Box-Cox antes mencionada, ya que proporciona una solución tanto para el cumplimiento de la normalidad y homocedasticidad.

No Autocorrelación de los errores

: Este supuesto quiere decir que los errores no dependan de sus valores anteriores, es decir, que la estimación debe ser aleatoria. Si es que no se cumple este supuesto implica que la estimación de β no son eficiente ya que no serán de mínima varianza, por otra parte el $\hat{\sigma}^2$ será sesgado.

Una de las formas de detectar la autocorrelación es a través de test de Durbin Watson, cuya docima corresponde a

H_0 : No hay autocorrelación de los errores *versus* H_1 : Hay autocorrelación de los errores

La estadística para este test se muestra a continuación , cabe mencionar que esta estadística es comparada con la distribución ($D = 2(1 - \hat{\rho})$), la cual fue construida por los autores del test en base a simulación.

$$d = \frac{\sum_{i=2}^n (\epsilon_i - \epsilon_{i-1})^2}{\sum_{i=1}^n \epsilon_i^2} \sim D = 2(1 - \hat{\rho})$$

A continuación se presenta una tabla que indica la decisión que se debe considerar respecto a este test.

H_0	Decisión	Criterio
No autocorrelación positiva	Rechazar	$0 < d < d_l$
No autocorrelación positiva	No tomar decisión	$d_l < d < d_u$
No correlación negativa	Rechazar	$4 - d_l < d < 4$
No correlación negativa	No tomar decisión	$4 - d_u < d < 4 - d_l$
No autocorrelación, positiva o negativa	No rechazar	$d_u < d < 4 - d_l$

d_l y d_u son obtenidos la tabla de valores críticos de Durbin-Watson. [\[18\]](#)

2.7.2. Test de Dickey-Fuller

David Dickey y Wayne Fuller (1979) desarrollaron esta prueba para determinar la estacionariedad de un modelo, planteándolo como un contraste de no estacionariedad, ya que la hipótesis nula es la presencia de una raíz unitaria en el proceso generador de datos de la serie analizada. En otras palabras esta prueba confirma si una raíz unitaria está presente en el modelo Autoregresivo.

Para realizar esta prueba se asume que la serie se puede aproximar por un proceso AR(1) con tres variantes: con media igual a cero, con media distinta de cero y con tendencia lineal. Inicialmente se asume que Y_t sigue un modelo AR(1), es decir:

$$\begin{aligned} Y_t &= \varphi_1 Y_{t-1} + \varepsilon_t \\ Y_t Y_{t-1} &= (\varphi_1 - 1) Y_{t-1} + \varepsilon_t \\ \Delta Y_t &= \rho Y_{t-1} + \varepsilon_t \end{aligned}$$

con $\varepsilon_t \sim RB(0, \sigma^2)$, además $\rho = \varphi_1 - 1$. Por lo tanto la raíz unitaria equivale a $\varphi_1 = 1$ o $\rho = 0$.

Luego, la prueba de Dickey-Fuller puede ser estimada de tres distintas formas, las cuales serán:

- Caso 1: Si Y_t es un camino aleatorio, es decir, con media cero.

El modelo será de la forma:

$$\Delta Y_t = \rho Y_{t-1} + \varepsilon_t$$

Este no contendrá tendencia ni intercepto.

- Caso 2: Si Y_t es un camino aleatorio con intercepto, es decir, con media distinta de cero.

El modelo será de la forma:

$$\Delta Y_t = \mu + \rho Y_{t-1} + \varepsilon_t$$

Este no contendrá tendencia, pero sí intercepto.

- Caso 3: Si Y_t es un camino aleatorio con tendencia e intercepto, es decir, con media distinta de cero y tendencia.

El modelo será de la forma:

$$\Delta Y_t = \mu + \beta_t + \rho Y_{t-1} + \varepsilon_t$$

Este contendrá tendencia e intercepto.

En cada uno de estos casos la hipótesis nula será que existe una raíz unitaria (serie no estacionaria) y la hipótesis alternativa es $\rho < 0$, que representa la estacionalidad de la serie Y_t , con media distinta de cero y una tendencia determinística.

H_0 = la serie de tiempo no es estacionaria ($\rho = 0$) y presenta raíz unitaria.

Por lo que $\rho = 0$, $\mu = 0$ y $\beta = 0$

v/s

H_1 = la serie de tiempo es estacionaria y no presenta raíz unitaria.

Por lo que $\rho < 0$, $\mu \neq 0$ y $\beta \neq 0$

2.7.3. Test de Ljung-Box

Esta prueba tiene su nombre debido a Greta M. Ljung y George E. P. Box y tiene como fin, para un modelo de serie de tiempo, comprobar la existencia de autocorrelación residual.

El test de Ljung-Box puede definirse de la siguiente manera (Ljung, G. M. (1978) [17]):

H_0 : Los datos se distribuyen de forma independiente.

V/S

H_1 : Los datos no se distribuyen de forma independiente.

El Estadístico Chi-Cuadrado del test de compone de la siguiente forma:

$$Q = n(n+2) \sum_{k=1}^h \frac{\rho_k^2}{n-k} \quad (2.115)$$

Donde ρ_k es la autocorrelación de orden k en la muestra, h el número de retardos que se están probando. Por nivel de significación α (Generalmente 0,05), la región crítica para el rechazo de la hipótesis de aleatoriedad es :

$$Q > \chi_{1-\alpha, h}^2 \quad (2.116)$$

Con $\chi_{1-\alpha, h}^2$ es la α -cuantil de la distribución Chi-Cuadrado con h grados de libertad.

Al probar la hipótesis sobre un modelo integrado, como por ejemplo un ARIMA, los grados de libertad quedan sujetos al orden de los parámetros Auto Regresivos (p) y de Medias Móviles (q) mediante la siguiente expresión: Grados de libertad = m-p-q

2.7.4. Error Medio Absoluto Porcentual

El Error Porcentual Absoluto Medio MAPE por sus siglas en inglés Mean Absolute Percentage Error, es un indicador del desempeño del pronóstico de demanda que mide el tamaño del error en términos absolutos porcentuales.

El hecho que se estime una magnitud del error porcentual lo hace un indicador frecuentemente utilizado por los encargados de elaborar pronósticos debido a su fácil interpretación.

Dado que es una medida relativa, su principal ventaja radica en que es útil cuando no se conoce la magnitud de la variable a estudiar y el margen de error aceptable dentro del contexto.

Puede utilizarse para medir tanto el ajuste en la muestra de entrenamiento como el poder predictivo con datos desconocidos en la muestra de validación.

Su fórmula matemática está dada por la siguiente expresión (Krajewski, L. (1998)[16]):

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - F_t|}{|Y_t|} \quad (2.117)$$

2.7.5. Error Cuadrático Medio de Predicción

Corresponde un indicador de rendimiento residual, utilizado en el presente informe para determinar la distancia entre las predicciones que se realizan sobre la variable de interés y los datos observados.

Mide el tamaño del error, elevado al cuadrado, para evitar que la media muestral se vea afectada por los distintos signos que pueda haber en el vector residual.

Su utilización se hará sobre el último 10 por ciento de los datos para verificar la capacidad predictiva del modelo.

Básicamente es un Error Cuadrático Medio, pero aplicado a datos desconocidos para el Modelo Predictivo, su fórmula matemática está dada por la siguiente expresión:

$$ECMP = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - F_t)^2}{Y_t} \quad (2.118)$$

Capítulo 3

Análisis preliminares

3.1. Resumen Descriptivo

3.1.1. Serie Anual

Modelo Anual: Datos desde 1989 con los despachos totales a nivel nacional por año.

Los principales actores del Mercado son Melón S.A., Polpaico y Bío-Bío:




Figura 3.1: Fuente: Memorias Melon, Polpaico y Bío-Bío.

Históricamente los despachos de Cemento presentan un constante crecimiento que va de la mano con la situación económica del País.




Figura 3.2: Fuente: Información Histórica de Melón S.A.

Sin embargo, cada cierto tiempo existen bajas significativas en el Mercado, anticiparlas es crucial para mantener siempre un margen de rentabilidad sobre los costos.

Es por ello que surge noción de que puede ser posible, teniendo información de ciertas variables Macroeconómicas, anticipar cómo se comportará el Mercado del Cemento en Chile.

Variables independientes

En primer lugar creó una base de datos compuesta de 22 variables macroeconómicas con información anual histórica desde el año 1989.

Las fuentes consideradas fueron el Banco Central, Insituto Nacional de Estadísticas (INE), Cámara Chilena de la Construcción, Dirección de presupuestos (DIPRES), Ministerio de Obras Públicas (MOP), entre otras entes gubernamentales y privadas.

Correlaciones absolutas significativas con Demandada de Cemento en Kton	
Variable	Correlación
PIB	0,9552
FBCF	0,9499
IPC	0,9454
Infraestructura Privada	0,9187
PIB Construcción	0,9177
Vivienda Privada	0,9126
MOP	0,8922
Permisos de edificación iniciados	0,8864
MINVU	0,8827
Petróleo (WTI)	0,8474
Presupuesto del Gobierno	0,8439
PIB Minería	0,8316
Permisos ambientales (clp)	0,7917
Vivienda Pública	0,7766
Permisos Ambientales (num)	0,6117
Dólar	0,5479
Permisos de edificación aprobados	0,5245
Variación PIB Construcción	0,4702
Variación Dólar	0,4179

Figura 3.3: Correlaciones significativas con la Demanda Anual de Cemento.

Se observan las variables macroeconómicas con correlaciones de Pearson significativas ordenadas de mayor a menor.

Sus índices de asociación lineal son bastante altos, lo cual hace suponer que modelos que impliquen una combinación de sumas ponderadas con las variables independientes puedan lograr resultados óptimos como lo son el Modelo Lineal o bien los modelos de serie de tiempo con variables exógenas como ARIMAX.

Correlación Cruzada

Por otro lado se aplicó una correlación cruzada (CCF por sus siglas en inglés "Cross Correlation Function") para estudiar si es posible encontrar algún desfase temporal en las relaciones que tienen éstas variables para con la Demanda de Cemento.

Correlaciones absolutas desfasadas con Dda Cemento en Kton				
Variable	Correlación		Lag	Variación
	Normal	Nueva		
PIB	0,9552	0,9398	1	📉 -0,0154
FBCF	0,9499	0,9157	1	📉 -0,0342
IPC	0,9454	0,9221	1	📉 -0,0233
PIB Construcción	0,9177	0,8858	1	📉 -0,0320
MOP	0,8922	0,8815	1	📉 -0,0107
Variación vivienda pública	0,1748	0,8757	4	📈 0,7009
MINVU	0,8827	0,8728	1	📉 -0,0099
PIB Minería	0,8316	0,8649	1	📈 0,0333
Presupuesto del Gobierno	0,8439	0,8335	1	📉 -0,0104
Permisos de edificación iniciados	0,8864	0,8303	1	📉 -0,0561
Infraestructura privada	0,9187	0,8191	1	📉 -0,0996
Petróleo	0,8474	0,8171	1	📉 -0,0303
Permisos Ambientales (num)	0,6117	0,8006	5	📈 0,1889
Permisos Ambientales (num)	0,6117	0,7976	4	📈 0,1860
Permisos Ambientales (num)	0,6117	0,7924	3	📈 0,1807
Permisos ambientales (clp)	0,7917	0,7899	1	📉 -0,0018
Vivienda pública	0,7766	0,7789	1	📈 0,0023
Permisos Ambientales (num)	0,6117	0,7294	2	📈 0,1178
Variación Dólar	0,4179	0,6648	1	📈 0,2469
Permisos Ambientales (num)	0,6117	0,6584	1	📈 0,0467
IPEC	0,2925	0,6210	6	📈 0,3285
Tasa de interés	0,1380	0,6033	2	📈 0,4654
Dólar	0,5479	0,5923	2	📈 0,0444
Dólar	0,5479	0,5366	1	📉 -0,0113
Permisos de edificación aprobados	0,5245	0,5207	1	📉 -0,0037
Variación PIB Construcción	0,4702	0,5136	1	📈 0,0435

Figura 3.4: Correlaciones Cruzadas Demanda de Cemento Anual.

En este caso se presentan dos columnas con índices de correlación, la columna *Normal* hace referencia al nivel de asociación lineal de las variables independientes con la Demanda de Cemento en el mismo año mientras que la columna *Nueva* es la que indica el nivel de correlación con X años de desfase, donde X es igual al número de lags indicado en la columna siguiente.

La columna "Variación" señala la diferencia entre la correlación original y la desfasada. Pa-

ra obtenerla se realiza una resta entre los valores absolutos de los índices obtenidos para luego calificar su incremento o descenso según la siguiente simbología:

Símbolo	Regla
	incremento de más de 0,5
	incremento entre 0,1 y menos de 0,5
	diferencia de menos de 0,1 y más de -0,1
	descenso de entre -0,1 y más de -0,5
	descenso de más de -0,5

Figura 3.5: Simbología.

Se aprecian excelentes índices de correlación, sin embargo ciertas variables (con su lag destacado) poseen un desfase excesivo y lógicamente inviable ya que se perderán muchos datos y contextualmente no son del todo aceptables. Por lo tanto no serán considerados en éste estudio

3.1.2. Serie Diaria

Modelo Diario: Despachos diarios de Melón S.A., se subdividen por Regiones (sistema antiguo de 13 utilizado por Melón S.A.) y éstas a su vez por HPM (Hormigón Pre-Mezclado) y NHPM (No Hormigón Pre-Mezclado). Su distribución Regional está resumida en la siguiente tabla:




Figura 3.6: Participación Regional Melón S.A.

Se observa que la gran mayoría se concentra en la Región Metropolitana tanto para HPM como NHPM, por lo que el principal modelo a estimar será el de dicha región. Luego, por orden de importancia se verán las Regiones V, X y IV debido a la gran participación de la Empresa en ellas, en contraste con la casi nula presencia en las regiones del extremo austral del país.

Se espera que en las Regiones del Sur prevalezcan efectos de distintas variables a las del Norte, así como también en la Zona Centro del país.

Luego, se observa que tomando un segmento de las Regiones se obtiene un 91 % de los Despachos de Melón, a partir de esto se decide centrar el análisis en las Regiones que conforman la mayoría del Mercado de la Empresa.

HPM			NHPM		
Región	Participación %	Acumulado	Región	Participación %	Acumulado
RM	43,71%	43,71%	RM	37,04%	37,04%
V	12,87%	56,58%	V	16,86%	53,90%
X	11,32%	67,89%	X	11,98%	65,88%
VI	7,58%	75,47%	IV	8,91%	74,79%
IV	6,13%	81,60%	VI	7,83%	82,62%
I	4,59%	86,19%	IX	4,48%	87,10%
II	3,79%	89,97%	VIII	4,23%	91,33%
VIII	3,76%	93,73%	III	3,20%	94,53%
III	2,17%	95,90%	I	2,45%	96,98%
IX	2,17%	98,07%	VII	1,68%	98,66%
VII	1,45%	99,52%	II	0,82%	99,48%
XI	0,45%	99,96%	XI	0,49%	99,97%
XII	0,04%	100,00%	XII	0,03%	100,00%

91%

Figura 3.7: 91 % de la Participación Regional Melón S.A.

Por lo tanto, el modelo que se verá en mayor detalle es el de Hormigón Pre-Mezclado de la Región Metropolitana, dejando a las demás Regiones, señaladas en la imagen, en una tabla resumen y con representaciones gráficas dentro del Anexo.

Variables independientes**Tipo de Día**

Para poder predecir la Demanda de Cemento, se observa que el volumen de despachos puede tener directa relación con el tipo de día, es decir, si es un día sandwich se espera que la cantidad despachada se reduzca aproximadamente a la mitad respecto a un día normal.

Por lo tanto se propone utilizar información de los días festivos oficiales de la República de Chile para crear una base de datos que represente qué días serán Feriados, Hábiles, entre otros.

Se considerarán los siguientes tipos de días representados mediante variables dicotomicas:

- Anterior doble feriado
- Anterior triple feriado
- Doble feriado
- Hábil
- Posterior triple feriado
- Posterior doble feriado
- Sábado
- Sandwich
- Triple feriado

Precipitaciones

Por otro lado también se cree que el nivel de precipitación puede afectar directamente el volumen de despachos diarios de la empresa.

Para estudiar este caso se creó una base de datos con el nivel de precipitación en milímetros cúbicos diarios de cada Región. La fuente utilizada fue la Dirección General de Aeronáutica Civil en conjunto con la Dirección Meteorológica de Chile.

Éste tipo de variable es continua y su efecto a priori se puede visualizar en la siguiente tabla:

Condición	Promedio de despachos de Cemento
Sin Lluvia	3352
Con Lluvia	2601

Cuadro 3.1: Promedio Despachos de Cemento con y sin lluvia.




Figura 3.8: Precipitaciones v/s Despachos de Melón S.A.

Finalmente las variables a considerar para el modelo diario de la Región Metropolitana son las siguientes:

Variable	Tipo	Presencias
Anterior doble feriado	Dicotómica	3
Anterior triple feriado	Dicotómica	4
Doble feriado	Dicotómica	10
Hábil	Dicotómica	458
Posterior triple feriado	Dicotómica	4
Posterior doble feriado	Dicotómica	6
Sábado	Dicotómica	90
Sandwich	Dicotómica	2
Triple feriado	Dicotómica	7
Pp RM Pudahuel	Continua	50

Figura 3.9: Variables independientes Serie diaria.

Luego, para emplear un uso adecuado de ellas, se realizó un análisis descriptivo histórico de los tipos de días, por región, para de ésta forma establecer una tabla de puntaje.

Dicha tabla se construyó en base al comportamiento de los despachos diarios de Cemento por cada una de las Regiones de Chile por separado.

Se establece como referencia al día del tipo *Hábil* cuyo valor esperado será el cien por ciento de los despachos estimados para ese tipo de día.

Puntaje HPM	Región												
Tipo día	I	II	III	IV	V	VI	VII	VIII	IX	X	XI	XII	RM
Sábado	47 %	67 %	61 %	50 %	32 %	61 %	55 %	47 %	58 %	56 %	59 %	50 %	39 %
Anterior Doble Feriado	68 %	97 %	91 %	75 %	91 %	94 %	129 %	67 %	87 %	99 %	102 %	0 %	94 %
Anterior Triple Feriado	96 %	70 %	115 %	115 %	88 %	92 %	82 %	107 %	113 %	86 %	105 %	0 %	88 %
Doble Feriado	12 %	71 %	18 %	14 %	2 %	33 %	22 %	1 %	122 %	0 %	0 %	0 %	11 %
Feriado	8 %	62 %	17 %	15 %	12 %	45 %	31 %	1 %	386 %	6 %	0 %	0 %	6 %
Hábil	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %
Posterior Doble Feriado	92 %	125 %	81 %	78 %	80 %	80 %	64 %	46 %	71 %	51 %	73 %	0 %	86 %
Posterior Triple Feriado	70 %	87 %	88 %	56 %	73 %	86 %	39 %	52 %	92 %	62 %	78 %	0 %	74 %
Sandwich	3 %	48 %	22 %	16 %	6 %	43 %	10 %	14 %	5 %	24 %	24 %	0 %	7 %
Triple Feriado	0 %	9 %	42 %	8 %	1 %	45 %	23 %	0 %	0 %	0 %	0 %	0 %	5 %

Cuadro 3.2: Puntajes por día Series diarias HPM.

Puntajes NHPM	Región												
Tipo día	I	II	III	IV	V	VI	VII	VIII	IX	X	XI	XII	RM
Sábado	67 %	145 %	101 %	70 %	40 %	85 %	72 %	56 %	68 %	57 %	97 %	0 %	53 %
Anterior Doble Feriado	180 %	33 %	106 %	120 %	87 %	97 %	97 %	93 %	101 %	93 %	154 %	184 %	89 %
Anterior Triple Feriado	101 %	112 %	81 %	83 %	82 %	82 %	82 %	87 %	89 %	75 %	66 %	164 %	66 %
Cuádruple Feriado	55 %	42 %	0 %	41 %	24 %	0 %	62 %	71 %	0 %	0 %	0 %	0 %	252 %
Doble Feriado	-34 %	71 %	20 %	44 %	17 %	80 %	64 %	14 %	46 %	13 %	0 %	0 %	17 %
Feriado	46 %	180 %	152 %	21 %	17 %	37 %	91 %	18 %	81 %	28 %	0 %	0 %	19 %
Hábil	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %	100 %
Posterior Doble Feriado	73 %	63 %	74 %	104 %	97 %	109 %	93 %	95 %	90 %	85 %	82 %	0 %	96 %
Posterior Triple Feriado	79 %	70 %	114 %	70 %	83 %	119 %	107 %	97 %	90 %	86 %	59 %	0 %	105 %
Sandwich	73 %	42 %	216 %	66 %	52 %	109 %	91 %	80 %	89 %	63 %	44 %	0 %	49 %
Triple Feriado	0 %	1 %	47 %	15 %	3 %	85 %	62 %	9 %	32 %	8 %	0 %	0 %	9 %

Cuadro 3.3: Puntajes por día Series diarias NHPM.

Capítulo 4

Modelos

4.1. Modelo Anual

Hasta la fecha se han probado modelos de Serie de tiempo convencionales como ARIMA y SARMA, Modelos Lineales, ARIMAX, entre otros.

Debido a las bruscas caídas que se presentan en el año 1999 y 2009 es que se plantea crear la variable **Crisis Económica**.

En primera instancia su comportamiento será dicotómico en base a la siguiente regla:

$$C = \begin{cases} 1 & \text{Existe crisis o receso en el mercado} \\ 0 & \text{No existen variaciones en el escenario actual del mercado} \end{cases} \quad (4.1)$$

Para su uso se considerarán las predicciones del mercado chileno y su situación económica en base a expectativas del Banco Central, la Cámara chilena de la Construcción, entre otras entidades con credibilidad consolidada.

Una vez definida la nueva variable se probaron diversos modelos con y sin su presencia.

Los más destacados ARIMAX, los cuales obtuvieron los siguientes resultados:

Nombre	#Variables	MAPE	AIC	ECP	Predicción 2015
Modelo Práctica	3	4,17 %	333	468.455	5.501
Modelo Lineal desfasado	3	6,12 %	339	94.051	5.155
ARIMA(1,1,0)	0	7,18 %	384	132.925	5.216
ARIMAX desfase	13	1,79 %	238	11.441.833	4.402
ARIMAX 1er Avance	6	2,64 %	259	8.976	5.314
ARIMAX 2do Avance	3	1,86 %	242	27.208	5.578
ARIMAX Final	4	1,65 %	238	3.782	5.421

Cuadro 4.1: Resumen diagnóstico de Modelos Serie Anual.

Nombre	Autocorrelación	Homocedasticidad	Media cte	Normalidad	Estado
Modelo Práctica	✓	X	✓	X	X
Modelo Lineal desfasado	X	X	✓	X	X
ARIMA(1,1,0)	✓	X	✓	X	X
ARIMAX desfase	✓	X	X	X	X
ARIMAX 1er Avance	✓	✓	✓	X	✓
ARIMAX 2do Avance	✓	✓	✓	✓	✓
ARIMAX Final	✓	✓	✓	✓	✓

Cuadro 4.2: Resumen Supuestos Residuales Serie Anual.

Los modelos destacados poseen un MAPE que va desde 1,6 % hasta 6 %. Considerado que para la empresa un MAPE de 5 % es aceptable, es posible señalar que los modelos a priori cumplen con las expectativas. No obstante en su mayoría están violando los supuestos residuales.

El modelo destacado es el ARIMAX Final con la variable Crisis ya que, quien junto al ARIMAX del segundo avance y a diferencia de sus homólogos, cumple los supuestos residuales. Su diferencia radica en la Homocedasticidad ya que al implementar la variable Crisis el modelo se adaptó de mejor manera a esos años de baja. (Figura 4.1)

En contraste con el Modelo del segundo avance que si bien, cumple los supuestos, posee un MAPE considerablemente bajo, posee una falla que radica en su poder predictivo, el cual, muestra un comportamiento errático. Ésto se refleja en el Error Cuadrático de Predicción, cuyo valor asciende hasta 27.208, mientras que el ARIMAX Final presenta un ECP de 3.782.

Por lo tanto se logra ajustar un Modelo que cumple con los supuestos residuales, calcula de buena manera las 5400 kilotoneladas de 2015 fallando sólo en 21 (Error del 0,3 %), un ECP de 3.782 muy por debajo de sus predecesores y un Error Medio Absoluto de 1,65 %.




Figura 4.1: Ajuste ARIMAX Serie Anual.

Gráficamente se observa un buen ajuste, con la curva del Modelo que presenta un comportamiento bastante similar a la Serie observada.

Se logra reflejar satisfactoriamente las caídas de 1999 y 2009, justificando el uso de la variable *Crisis* dentro del pronóstico.

Su ajuste es ilustrado a continuación:




Figura 4.2: Ajuste ARIMAX Seleccionado

Efectivamente el modelo se adapta de buena manera a las bajas del Mercado, aumentando el nivel de ajuste original y mejorando el desempeño en los supuestos residuales (Ver Anexo -Resultados supuestos Residuales).

Por lo tanto se conservará el uso de la variable Crisis Económica.

Modelo ARIMAX Definitivo					
Parámetros	MA1	FBCF	IPC	Inf Privada	Crisis
Coef	-1,00	637,66	-300,41	390,46	-435,05
S.E.	0,15	257,32	127,29	175,22	55,59

Cuadro 4.3: Coeficientes Modelo ARIMAX Anual.

Finalmente su expresión matemática está dada por la siguiente fórmula:

$$(1 - B)Y_t = (1 - \theta B) + \beta X \quad (4.2)$$

$$(1 - \theta_t B)\epsilon_t = -1 \cdot \epsilon_{t-1} + \epsilon_t \quad (4.3)$$

$$\beta X = 637,66 \cdot X1_t - 300,41 \cdot X2_t + 390,46 \cdot X3_t - 435,05 \cdot X4_t \quad (4.4)$$

Donde y_t corresponde a la Demanda de Cemento en el tiempo t , ϵ_t a una perturbación estocástica.

Las variables utilizadas fueron las siguientes:

- X1 Formación Bruta de Capital Fijo.
- X2 Índice del Precio al Consumidor.
- X3 Infraestructura Privada (CChC).
- X4 Crisis.

4.1.1. Pronósticos

Antes de realizar un Forecast, se debe estudiar la situación actual y proyectada de las Variables independientes.

Según Jorge Mas, presidente de la Cámara Chilena de la Construcción (CChC), quien proyectó para 2016 una menor inversión en vivienda y un mayor dinamismo en infraestructura productiva privada. Así, estimó un frágil crecimiento del sector en torno a 1 % para 2016. (Fuente: <http://www.revistaenconcreto.cl/proyecciones-en-construccion-2016-menor-inversion-en-vivienda/>).

Por otro lado, el Banco Central redujo el lunes 28 de Marzo de 2016 su proyección de crecimiento para el Producto Interno Bruto (PIB) a un rango de 1,25 % - 2,25 % desde el 2 %-3 % previsto en diciembre. (Fuente: <http://www.latercera.com/noticia/negocios/2016/03/655-674127-9-banco-central-reduce-a-rango-de-125-225-proyeccion-de-crecimiento-para-2016.shtml>).

Bajo éste contexto, y considerando el Mach Macroeconómico de la Cámara Chilena de la Construcción de Diciembre de 2015, se hizo una estimación de los valores 2016 y 2017 de los las Variables exógenas del modelo.

Finalmente la Predicción para el año 2016 es la siguiente:




Figura 4.3: Predicción 2016-2017 ARIMAX.

Se observa un Pronóstico que indica un receso en el crecimiento acelerado que presentaba la Demanda de Cemento, manteniéndose cerca de las 5400 Kilotoneladas para 2016 y 2017.

Se espera que la Demanda no sufra grandes cambios ni este ni el próximo año, sin embargo, a medida que se reactive la Economía Nacional, es de esperar que la Demanda de Cemento reaccione positivamente ante un escenario de crecimiento.




Figura 4.4: Escenarios Forecast.

Los escenarios pre-dispuestos son 3, en primer lugar está el escenario Optimista, el cual plantea un crecimiento en el Mercado de un 2 %, lo cual se traduce en cerca de 100 Kilotoneladas más que el 2015.

Por otro lado, tanto el escenario Medio como el Pesimista pronostican una baja en la Demanda de Cemento que podría llegar al 4 %, cifra que significaría una disminución de 200 Kilotoneladas en los Despachos de Cemento.

4.1.2. Conclusiones y Predicción Modelo Anual

- Los ajustes son altamente satisfactorios, con un Error Medio Absoluto de 1,6 %.
- Se espera una baja en los despachos de cemento de un 1 %.
- La nueva variable “crisis” mejoró el nivel de ajuste de los modelos.
- El mejor modelo con mejor ajuste es el ARIMAX Final con la variable Crisis.
- Su predicción de 2015 fue cerca de 5.421 Kton, con un Intervalo que oscila entre 5.246 y 5.596 utilizando una confianza del 95 %, muy cerca e incluyendo las 5400 observadas.
- Finalmente para 2016 y 2017 se pronostican 5.343 y 5.322 kilotoneladas con Intervalos de confianza que van de 5.173 a 5.513 y de 5.152 a 5.493 Kton respectivamente.

4.2. Modelos de Despachos diarios

Los despachos diarios presentan la particularidad de tener mucho ruido, por lo que se espera que un modelo del tipo lineal no logre ajustarse de manera óptima.

Hasta la fecha los mejores Modelos probados en la Región Metropolitana son los siguientes:.

Cuadro 4.4: My caption

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	678	50,6 %	10941	814558
Mejor Modelo Lineal con desfase	7	671	71,9 %	10957	815804
Mejor Modelo Lineal con interacción	8	678	48,3 %	10935	814102
SARMA	0	678	113 %	11224	835652
SARMAX	1	678	53,4 %	10939	814429
Red Neuronal	15	678	41,6 %	9420	24110
ARIMAX	4	678	33,7 %	820	22786

Cuadro 4.5: Resumen Modelos de Despachos Diarios RM HPM.

Se probaron diversos Modelos, destacando los mostrados en la tabla. En primer lugar, se probaron Modelos Lineales, tanto con variables desfasadas en el tiempo como con el tiempo relativo a la Serie observada, sin resultados alentadores.

Del mismo modo, se incluyeron Modelos de Serie de Tiempo puros e híbridos con variables exógenas, destacando ejemplares tanto Estacionales (SARMA y SARMAX) como del tipo Tendencial ARIMAX, siendo éste último el que posee la mayor precisión entre ellos.

El Error Medio Absoluto va de 33 % a 113 %, encontrando la cota inferior en el último ARIMAX compuesto de 4 variables. Por otro lado también presenta un menor Error Cuadrático de Predicción, seguido de cerca por la Red Neuronal Perceptrón Multi capa de aprendizaje supervisado.

Sin Embargo, el Modelo ARIMAX es superior a la Red Neuronal, ya que con una menor cantidad de variables logra ajustarse a la serie observada con mayor precisión.

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
SARMA	√	X	√	X	X
SARMAX	√	X	√	X	√
Red Neuronal	√	X	√	X	√
ARIMAX	√	X	√	X	√

Cuadro 4.6: Supuestos Residuales Modelos Diarios RM HPM.

Refiriéndonos al último ARIMAX, existe un incumplimiento en el supuesto residual de Homocedasticidad, sin embargo su MAPE es mucho más pequeño que el de sus homólogos, con pequeños saltos residuales, que hacen que no se cumpla el supuesto pero aún así muestra mayor poder de ajuste.

Ésto puede tener origen en la presencia de outliers, los cuales no es posible eliminar debido a que es una Serie de Tiempo.

Por lo tanto, se escogerá el que presente menor Error Medio Absoluto y se ajustarán sus residuos al cuadrado mediante un Modelo GARCH.

Luego, los coeficientes del Modelo Diario ARIMAX seleccionado son los siguientes:

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2	ma3
Coef	16.333	-13.666	0.4559	-0.0877	0.1147	-23.733	23.925	-11.793
S.E.	0.3054	0.474	0.3628	0.0714	0.0567	0.3075	0.6977	0.6497
Variable	ma4	V1	V2	V3	V4	V5	V6	
Coef	0.168	-0.4114	-0.2233	0.5195	0.8432	-0.0219	32.309	
S.E.	0.1566	0.2483	0.1364	0.2055	0.0651	0.0048	0.1527	

Cuadro 4.7: Tabla Modelo ARIMAX RM HPM.

El ajuste obtenido con el Modelo ARIMAX a continuación:




Figura 4.5: Ajuste Serie del Logaritmo RM HPM

En donde, en primer lugar, se aplicó Logaritmo para disminuir la variabilidad de la Serie para luego ajustar el Modelo sobre ella. Para efectos de pronóstico, ajustes y residuos se aplica la función Exponencial sobre los datos ajustados.

Se observa un ajuste aparentemente satisfactorio, sin embargo, existen saltos dentro de la serie que incrementan el balance final de error dentro del Modelo.




Figura 4.6: Ajuste de Validación Serie del Logaritmo RM HPM

Posteriormente, para testear el desempeño sobre datos desconocidos se hace uso de una muestra de Validación con el último 10% de la Serie de modo tal que el pronóstico deba contener a los datos observados de los Despachos de Cemento.

Luego, el ajuste de la Serie original pasa a ser el siguiente:




Figura 4.7: Ajuste Serie Original HPM RM.

Luego, aplicando Exponencial sobre los datos predichos del Modelo sobre el Logaritmo, se obtiene el ajuste sobre los datos originales.

Se observa un buen seguimiento de la serie, no obstante, existen casos en donde la serie se escapa de la predicción del Modelo.

Por lo tanto, a partir de los gráficos expuestos se puede señalar lo siguiente:

- Existe alta volatilidad dentro de la Serie.
- Los intervalos de confianza al 95 % en la muestra de Validación contienen a la serie.
- Sin embargo, los supuestos residuales de Normalidad y Homocedasticidad no se cumplen.
- Por lo tanto, se modelarán los residuos para solucionar dichos problemas de ajuste.

4.2.1. Modelamiento GARCH

Se utilizará un GARCH Debido a la gran volatilidad de la serie y el incumplimiento de la Homocedasticidad y Normalidad residual.




Figura 4.8: Residuos estandarizados GARCH RM HPM.

Luego, mediante el Test de Ljung-Box, verificaremos que los residuos del modelo no estén correlacionados y sus residuos al cuadrado si. Condición inicial para ajustar un modelo con Heterocedasticidad Condicional.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,03	0,87
Residuos al cuadrado	5,24	0,02

Cuadro 4.8: Test Ljung-Box sobre Residuos RM HPM.

El test de Ljung-Box puede definirse de la siguiente manera (Ljung, G. M. (1978) [17]):

H_0 : Los datos se distribuyen de forma independiente.

V/S

H_1 : Los datos no se distribuyen de forma independiente.

Por lo tanto, se rechaza la hipótesis nula para los residuos del ARIMAX, mientras que el cuadrado de éstos si posee correlación al no existir evidencia suficiente, con un 5 % de significancia, de rechazar la Hipótesis Nula.

Luego, una vez que tenemos las condiciones para modelar un modelo del tipo GARCH, el resultado posee las siguientes características:




Figura 4.9: Desviación Estándar del Modelo GARCH.

En donde podemos observar que su efecto sobre los residuos finales del modelo es el siguiente:




Figura 4.10: Residuos Estandarizados Modelo GARCH.

Se observa que los residuos no superan los umbrales de 2 y -2, lo cual es una señal clara de que el supuesto de Homocedasticidad se cumple.

Finalmente, y como recomendación final, se sugiere utilizar un Intervalo de Confianza con un 95 % para utilizar.

La expresión matemática es la siguiente:

$$IC(95\%) = \hat{X}_t \pm 1,96\sigma_t \quad (4.5)$$

En donde $\hat{X}_t$ corresponde a los valores ajustados de la parte ARIMAX del Modelo y σ_t al error estándar condicional obtenido por la parte GARCH estimada.

Gráficamente podemos apreciar su comportamiento en la siguiente tabla:




Figura 4.11: Serie con Intervalo de 95 % de confianza Modelo GARCH.

Por lo tanto, el modelo final para los Despachos diarios de Melon sobre la Región Metropolitana tendrá elementos de Serie de Tiempo, Variables Exógenas y Varianza Condicional (GARCH).




Figura 4.12: Ajuste final ARIMAX GARCH RM HPM.

En donde se puede ver que los Intervalos logran contener el ruido de la serie original.

Sus coeficientes son los siguientes:

GARCH	Coef	Std Error
μ	3223	71
ω	1758	1403
α	0,0129	0,0053
β	0,8873	0,0044

Cuadro 4.9: Coeficientes GARCH RM HPM

Finalmente, el modelo ARIMAX $\sim$ GARCH final es el siguiente:

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2
Coef	16.333	-13.666	0.4559	-0.0877	0.1147	-23.733	23.925
S.E.	0.3054	0.474	0.3628	0.0914	0.0567	0.3075	0.6977
Variable	ma3	ma4	V1	V2	V3	V4	V5
Coef	-11.793	0.168	-0.4114	-0.2233	0.5195	0.8432	-0.0219
S.E.	0.6497	0.2566	0.2483	0.1364	0.2055	0.0651	0.0048
Variable	V6	μ	ω_t	α_t	β_t		
Coef	32.309	3223	1758	0.01288	0.8873		
S.E.	0.1527	71	1403	0.005296	0.004374		

Cuadro 4.10: Modelo ARIMAX $\sim$ GARCH RM HPM.

Luego, la expresión matemática del Modelo ARIMAX $\sim$ GARCH es la siguiente:

$$(1 - B)\Phi(B)Y_t = \Theta(B)\epsilon_t + \beta X_t + \epsilon_t \quad (4.6)$$

con,

$$\Phi(B) = 1 + 1,6333Y_{t-1} - 1,3666Y_{t-2} + 0,4559Y_{t-3} - 0,0877Y_{t-4} + 0,1147Y_{t-5} \quad (4.7)$$

$$\Theta(B)\epsilon_t = 2,3733\epsilon_{t-1} + 2,3925\epsilon_{t-2} - 1,1793\epsilon_{t-3} \quad (4.8)$$

$$\beta X_t = -0,4114V_1 - 0,2233V_2 + 0,5195V_3 + 0,8432V_4 - 0,0219V_5 + 32,309V_6 \quad (4.9)$$

$$\epsilon_t = \eta\sigma_t \quad (4.10)$$

$$\eta_t = 3223 + 0,8873\epsilon_{t-1}^2 + 1758\sigma_{t-1} \quad (4.11)$$

4.2.2. Conclusiones Modelo Diario

- Se utilizó una transformación del tipo Logarítmica para ajustar el Modelo debido a la alta variabilidad.
- Aparentemente existe un buen ajuste dentro de la Validación del modelo.
- Los supuestos residuales no se cumplen de manera satisfactoria.
- Para solucionarlo se utilizó un modelo de la familia GARCH(1,1).
- Se obtiene un MAPE con la serie Logarítmica de 4,7 % de error, lo que representa una alta tasa de acierto.
- En cuanto a la Serie Original el MAPE es de un 31 % para la Muestra de Entrenamiento, es decir, del primer 70 % de la Serie; y de un 33 % para la Validación, superando la precisión de 41 % de la Red Neuronal.
- Se hizo un trabajo análogo con las Regiones restantes (Ver Anexo Final Con ajustes y tablas).
- La variable Precipitación es significativa en Regiones del Centro como la V y la Región Metropolitana y Sur del país como la X Región.

Capítulo 5

Cemento Mundial

5.1. McKinsey and Company

McKinsey and Company, Inc. es una consultora estratégica global que se focaliza en resolver problemas concernientes a la administración estratégica.

Conocida en el mundo de los negocios como "La Firma" ("The Firm"), es globalmente reconocida como la empresa de consultoría más prestigiosa del mundo.

Fue fundada en Chicago en 1926 por James O. McKinsey, profesor de Contabilidad de la escuela de negocios University of Chicago Booth School of Business. James O. McKinsey es considerado el padre de la Contabilidad Gerencial.

Dicha consultora plantea, en base a la histórica relación entre el Producto Interno Bruto, Población y Demanda de Cemento, que los países pasan por ciertas etapas en función al nivel de ingresos per cápita.

5.1.1. Segmentación del Cemento Mundial




Figura 5.1: Cemento Mundial 1, McKinsey and Company, Inc.

En el eje de las abscisas tenemos el ingreso per cápita por país en dólares y en el de las ordenadas el consumo de Cemento per cápita.

Se aprecia un incremento lineal similar en cuanto a Consumo de Cemento e Ingresos, sin embargo, el consumo de Cemento tiende a estancarse en países desarrollados como Italia, Alemania, entre otros.




Figura 5.2: Fuente: Elaboración propia en base a información de McKinsey and Company, Inc.

En base a ésta observación es que se dispone a seccionar países en función de su PIB per cápita. El primer grupo es para países con menos de 2.000 USD per cápita, compuesto por economías emergentes principalmente como lo son los países africanos tales como Nigeria o Kenya.

Luego, países entre 2.000 y 20.000 USD per cápita. La principal característica de éste segmento es presentar países en vías de desarrollo.

El tercer grupo posee países consolidados económicamente como Australia o Francia.




Figura 5.3: Fuente: Elaboración propia en base a información de McKinsey and Company, Inc.

El primer grupo muestra una relación bastante marcada entre el PIB per cápita y el cemento per cápita, ilustrada gráficamente con una pendiente creciente.

Por otro lado países en vías de desarrollo como Chile o Colombia, cuya característica es presentar una relación lineal entre Ingresos y Consumo de Cemento al igual que en el grupo anterior, pero con el alcance de que el Cemento ya presenta señales de des-aceleración.

Luego, los países desarrollados como Finlandia y Bélgica tienen un alto ingreso per cápita pero un bajo consumo de Cemento. Es esa instancia la que se busca anticipar para Chile, punto en el cual la relación Cemento-PIB deje de ser lineal como históricamente lo ha sido.

5.2. Chile




Figura 5.4: Fuente: Elaboración propia en base a información de McKinsey and Company, Inc.

En base al escenario propuesto se pronostica, a una tasa de crecimiento constante del 3 %, que Chile cruzará el umbral en el año 2020.

A raíz de lo expuesto, el escenario de análisis para la Demanda de Cemento tendrá un gran cambio respecto a los factores independientes que se suelen utilizar para su pronóstico.

Ésto significa que ya no se podrán utilizar variables que deriven de la capacidad adquisitiva del País.

Por lo tanto, para ese año, se sugiere cambiar el enfoque de variables exógenas para pronosticar la Demanda de Cemento.

Para ello, las variables a estudiar se verán reducidas netamente a temáticas directamente de construcción y consumo directo de Cemento tales como Permisos de Edificación, Permisos Ambientales, Presupuesto del Ministerio de Obras Públicas, entre otros.

5.3. Conclusiones Cemento Mundial

- Es posible clasificar diversos países según el nivel de ingreso per cápita.
- El nivel de asociación entre el ingreso per cápita de un país y el consumo de Cemento per cápita dependerá del nivel de ingresos alcanzado.
- Chile se encuentra en una etapa de transición, propia de países en vías de desarrollo.
- Se estima que en el año 2020 Chile pasará al grupo de países desarrollados, cambiando drásticamente el escenario macroeconómico de la Demanda de Cemento.
- Por lo tanto, se propone utilizar variables que apunten netamente al consumo directo de Cemento tales como Permisos de Edificación, Permisos Ambientales, Presupuesto del Ministerio de Obras Públicas, entre otros.

Capítulo 6

Conclusiones

6.1. Modelo Anual

- Los ajustes son altamente satisfactorios, con un Error Medio Absoluto de 1,6 %.
- La nueva variable “crisis” mejoró el nivel de ajuste de los modelos.
- El mejor modelo con mejor ajuste es el ARIMAX Final con la variable Crisis.
- Es imperativo considerar el escenario económico del país, con un crecimiento desacelerado, lo que repercutirá negativamente en el Mercado del Cemento.
- Se espera una baja en los Demanda de Cemento de un 1 %.
- Su predicción de 2015 fue cerca de 5.421 Kton, con un Intervalo que oscila entre 5.246 y 5.596 utilizando una confianza del 95 %, muy cerca e incluyendo las 5400 observadas.
- Finalmente para 2016 y 2017 se pronostican 5.343 y 5.322 kilotoneladas con Intervalos de confianza que van de 5.173 a 5.513 y de 5.152 a 5.493 Kton respectivamente.
- Se sugiere realizar un enfoque internacional respecto al comportamiento de la Demanda de Cemento.

6.2. Modelos Diarios

- Los ajustes son aceptables, con Error Medio Absoluto que oscilan entre 3 y 5 por ciento para el Logaritmo de la Serie.
- Se puso en prueba Modelos Lineales con variables tanto en tiempo correlativo como desfasadas con resultados desfavorables en cuanto al supuesto residual de la Autocorrelación Residual, por lo que fueron desestimados.
- La variable Puntaje obtuvo excelentes estimaciones y se adecuó a cada una de las Regiones en donde se probó.
- Las precipitaciones logran significancia estadística en el sector centro y sur del país.
- Los mejores modelos son variantes del Modelo ARIMAX, superando a las Redes Neuronales, Modelos Lineales.
- Sin embargo, existe una permanente problemática con respecto a la Heterocedasticidad, se sugiere contextualizar los valores atípicos y realizar imputaciones pertinentes.
- Para solucionarlo se modelaron los cuadrados residuales del mejor modelo respectivo, obteniendo modelos del tipo ARIMAX $\sim$ GARCH con excelentes resultados.
- Finalmente los ajustes contienen a las Series observadas, utilizando Series de Tiempo, Variables de Regresión y Varianzas Condicionales.

6.3. Cemento Mundial

- Chile se encuentra en una etapa de transición en el contexto de la segmentación en función del PIB per cápita versus el Cemento per cápita.
- Los modelos relacionados con variables Macroeconómicas seguirán siendo efectivos hasta el año 2020.
- Luego de traspasar el umbral se sugiere utilizar variables netamente relacionadas con la construcción y el consumo directo de Cemento.

Bibliografía

- [1] Adamowski, J.F. (2008). *Peak Daily Water Demand Forecast Modeling Using Artificial Neural Networks*. American Society of Civil Engineers (ASCE)
- [2] Andrews, B.H., Dean, D.M., Swain, R y Cole, C. (2013). *Building ARIMA and ARIMAX Models for Predicting Long-Term Disability Benefit Application Rates in the Public/Private Sectors*. University of Southern Maine.
- [3] Brescia, F.A. (2014) *Memoria Melón S.A.*. Santiago de Chile
- [4] Brockwell, P. y Davis, R. (2002). *Introduction Time Series and Forecasting*. Department of Statistics, Colorado State University. USA
- [5] Cárdenas, S.M., Mejía M.C. y García A.F. (2007). *La industria del Cemento en Colombia*. Fedesarrollo, Bogotá, Colombia
- [6] Casas, M., Cepeda, E. (2008). *Modelos ARCH, GARCH Y EGARCH: Aplicaciones a series financieras*. Universidad Nacional de Colombia. Bogotá.
- [7] Castaño, E. y Martínez, J. (1998). *Administración de operaciones: estrategia y análisis*. Facultad de Ciencias, Universidad Nacional de Colombia, Bogotá, Colombia.
- [8] Correa, R. (2006) *Tesis Doctoral: "Redes Neuronales Artificiales en Ingeniería y Física nuclear. Caracterización de espectros PIXE"*. Universidad de Granada.
- [9] Escobar, L. Valdes, J. Zapata, S. (2010). *Redes Neuronales Artificiales en predicción de Series de Tiempo. Una aplicación a la Industria*. Universidad de Palermo.
- [10] Fausett, L. (1994). *Fundamentals of Neural Networks* Prentice-Hall, New Yersey, USA.
- [11] Florez-Lopez, R. y Fernández, J.M.(2008) . *Las redes neuronales artificiales: fundamentos teóricos y aplicaciones prácticas*. Departamento de Dirección y Economía de la Empresa, Universidad de Leon, España.

-
- [12] Frauke, G. y Stefan F. (2010). *neuralnet: Training of Neural Networks*. The R Journal Vol. 2/1
- [13] Gras, A.J. (2001). *Diseños de series temporales: técnicas de análisis*. Universidad de Barcelona.
- [14] Guoqiang, Z., Patuwo, B.E., Hu Y.M. (1998). *Forecasting with artificial neural networks: The state of the art*. Graduate School of Management, Kent State University, Kent, Ohio.
- [15] Haykin, S (1998). *Neural Networks*. McMaster University, Canada
- [16] Krajewski, L. y Larry, P. (1998). *Administración de operaciones: estrategia y análisis*. Reading, Massachusetts, USA.
- [17] Ljung, G. M. ,Box, G. E. P. (1978). *On a Measure of a Lack of Fit in Time Series Models*. College of Bussines Administration, University of Denver, Colorado. Department of Statistics, University of Wisconsin, Madison.
- [18] Norman R., Smith D.H. (1998). *Applied Regression Analysis Third edition..* Universidad de Michigan.
- [19] Pinto, Z.D. (1999). *Estructura de la Demanda de Cemento en Chile*. Universidad de Chile. Departamento de Ingeniería Industrial.
- [20] Rojo, J.M. (2007). *Regresión Lineal Múltiple* Instituto de Economía y Geografía. Madrid
- [21] Rumelhart, Williams y Hinton (1985). *Backpropagation*. University of California, San Diego. USA

Capítulo 7

Anexos

HPM		NHPM	
Región	MAPE	Región	MAPE
I	34,8 %	IV	29,1 %
II	44,9 %	V	26,0 %
IV	51,3 %	RM	21,5 %
V	59,1 %	VI	30,4 %
RM	33,1 %	VIII	39,3 %
VI	79,1 %	IX	35,7 %
X	20,7 %	X	33,3 %

Cuadro 7.1: Resumen de Ajustes según MAPE.




Figura 7.1: Comportamiento residual Modelo ARIMAX con variable Crisis incluída

7.1. Resumen Modelos Por Canal de Venta

Resumen NHPM

Región	Nombre	n	#Variables	AIC	Entrenamiento	Validación
RM	SARMAX(1,0,0)(1,1,0)6	1.217	7	974	3,02 %	2,7 %
X	SARMAX(1,0,1)(0,1,0)6	1.217	4	880	3,01 %	4,2 %
V	ARMAX(5,0,5)	1217	5	489	2,97 %	3,5 %

Cuadro 7.2: Resumen Modelos Diarios NHPM

Resumen HPM

Región	Nombre	n	#Variables	AIC	Entrenamiento	Validación
RM	ARIMAX(5,1,4)	678	3	820	3,0 %	3,1 %
X	ARMAX(0,1)	570	6	733	6,1 %	5,6 %
V	ARIMAX(5,0,5)	587	4	769	5,5 %	7,1 %

Cuadro 7.3: Resumen Modelos Diarios HPM

7.2. Hormigón Pre-Mezclado

7.2.1. I Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
ARMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARMAX	√	X	√	X	√

Cuadro 7.4: Resumen Supuestos Residuales Modelos I Región HPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	574	50,6 %	8538	820
Mejor Modelo Lineal con desfase	7	574	71,9 %	8551	822
Mejor Modelo Lineal con interacción	8	574	48,4 %	8533	820
ARMA	0	574	113 %	8759	842
Red Neuronal	9	574	41,7 %	7351	48
ARMAX	6	574	34,8 %	631	41

Cuadro 7.5: Resumen Modelos I Región HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0092	0,9234
Residuos al cuadrado	78.728	2,2e-16

Cuadro 7.6: Test Ljung-Box sobre Residuos I Región HPM.

Variable	ar1	ar2	ar3	ar4	ma1	ma2	ma3
Coef	0,79	-0,01	-0,95	0,64	-0,34	-0,05	0,91
S.E	0,16	0,26	0,26	0,16	0,17	0,20	0,17
Variable	ma4	ma5	intercept	v1	v2	v3	v4
Coef	-0,22	0,02	3,05	2,67	2,68	3,02	2,63
S.E	0,11	0,07	0,12	0,24	0,23	0,12	0,23
Variable	v5	v6	μ	ω	α	β	
Coef	2,73	2,21	409,00	20830,00	0,14	0,03	
S.E	0,19	0,12	6,30	8332,00	0,06	0,01	

Cuadro 7.7: Coeficientes Modelos I Región HPM.




Figura 7.2: Residuos I Región HPM.




Figura 7.3: Ajuste I Región HPM.




Figura 7.4: Varianza Condicional I Región HPM.




Figura 7.5: Residuos Estandarizados I Región HPM.




Figura 7.6: Ajuste ARMAX I Región HPM.





Figura 7.7: Serie con Intervalo de 95 % de confianza Modelo GARCH I HPM.

Figura 7.8: Ajuste ARMAX $\sim$ GARCH I HPM.

7.2.2. II Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
ARIMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARIMAX	√	X	√	X	√

Cuadro 7.8: Resumen Supuestos Residuales Modelos II Región HPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	5	604	65,2 %	11978	2289
Mejor Modelo Lineal con desfase	6	604	92,7 %	11997	2293
Mejor Modelo Lineal con interacción	7	604	62,3 %	11972	2288
ARIMA	0	604	145 %	12289	2349
Red Neuronal	7	604	53,7 %	10314	134
ARIMAX	4	604	44,9 %	886	114

Cuadro 7.9: Resumen Modelos II Región HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0014	0,9697
Residuos al cuadrado	24,863	6.154e-07

Cuadro 7.10: Test Ljung-Box sobre Residuos II Región HPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2	v1
Coef	0,82	-0,05	0,09	-0,07	0,10	-1,52	0,53	1,04
S.E	0,19	0,07	0,06	0,06	0,05	0,19	0,18	0,07
Variable	v2	v3	v4	μ	ω	α	β	
Coef	0,71	0,49	-0,07	281,34	470,95	0,12	0,85	
S.E	0,20	0,08	0,02	5,13	224,75	0,03	0,03	

Cuadro 7.11: Coeficientes Modelo ARIMAX ~ GARCH II Región HPM.




Figura 7.9: Residuos II Región HPM.




Figura 7.10: Ajuste II Región HPM.




Figura 7.11: Varianza Condicional II Región HPM.




Figura 7.12: Residuos Estandarizados II Región HPM.




Figura 7.13: Ajuste ARIMAX II Región HPM.





Figura 7.14: Serie con Intervalo de 95 % de confianza Modelo GARCH II HPM.

Figura 7.15: Ajuste ARIMAX $\sim$ GARCH II HPM.

7.2.3. IV Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	✓	X	X
Mejor Modelo Lineal con desfase	X	X	✓	X	X
Mejor Modelo Lineal con interacción	X	X	✓	X	X
ARMA	✓	X	✓	X	X
Red Neuronal	✓	X	✓	X	✓
ARMAX	✓	X	✓	X	✓

Cuadro 7.12: Resumen Supuestos Residuales Modelos IV Región HPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	648	70,6 %	13553	5731
Mejor Modelo Lineal con desfase	7	648	71,9 %	13574	5739
Mejor Modelo Lineal con interacción	8	648	68,3 %	13546	5727
ARMA	0	648	113 %	13904	5879
Red Neuronal	10	648	61,6 %	11670	170
ARMAX	6	648	51,3 %	1016	160

Cuadro 7.13: Resumen Modelos IV Región HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,5672	0,6627
Residuos al cuadrado	6,2673	0,0184

Cuadro 7.14: Test Ljung-Box sobre Residuos IV Región HPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2	ma3	ma4
Coef	10.211	-0,0602	-0,504	0,0648	0,4189	-0,737	-0,1898	0,5428	0,0605
S.E.	0,3789	0,7257	0,7245	0,4189	0,2182	0,3801	0,6391	0,5383	0,2748
Variable	ma5	intercept	V1	V2	V3	V4	V5	V6	
Coef	-0,4112	104,65	408,18	517,85	479,02	265,37	446,74	189,97	
S.E.	0,1786	29,94	82,19	80,93	21,46	70,30	65,68	21,47	

Cuadro 7.15: Coeficientes Modelo HPM IV Región.




Figura 7.16: Residuos IV Región HPM.




Figura 7.17: Ajuste IV Región HPM.




Figura 7.18: Varianza Condicional IV Región HPM.



Figura 7.19: Residuos Estandarizados IV Región HPM.




Figura 7.20: Ajuste ARMAX IV Región HPM.





Figura 7.21: Serie con Intervalo de 95 % de confianza Modelo GARCH IV HPM.

Figura 7.22: Ajuste ARMAX $\sim$ GARCH IV HPM.

7.2.4. V Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	✓	X	X
Mejor Modelo Lineal con desfase	X	X	✓	X	X
Mejor Modelo Lineal con interacción	X	X	✓	X	X
ARMA	✓	X	✓	X	X
Red Neuronal	✓	X	✓	X	✓
ARMAX	✓	X	✓	X	✓

Cuadro 7.16: Resumen Supuestos Residuales V Región HPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	1171	85,4 %	13487	6208
Mejor Modelo Lineal con desfase	7	1171	121,3 %	13507	6218
Mejor Modelo Lineal con interacción	8	1171	81,5 %	13479	6205
ARMA	0	1171	190 %	13836	6369
Red Neuronal	10	1171	70,3 %	11612	184
ARMAX	6	1171	59,1 %	1011	174

Cuadro 7.17: Resumen Modelos V Región HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0103	0,9191
Residuos al cuadrado	7,1211	0,0076

Cuadro 7.18: Test Ljung-Box sobre Residuos V Región HPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2
Coef	-0,11	0,92	0,93	-0,57	-0,54	0,12	-0,86
S.E.	0,43	0,27	0,29	0,24	0,41	0,44	0,28
Variable	ma3	ma4	ma5	intercept	v1	v2	v3
Coef	-0,93	0,56	0,49	5,15	0,02	1,52	-2,16
S.E.	0,29	0,27	0,42	0,11	0,01	0,30	0,59
Variable	v4	v5	v6	μ	ω	α	β_1
Coef	1,90	0,64	-0,02	112,1	649,8	0,00	0,71
S.E.	0,10	0,11	0,00	19,5	259,9	0,00	0,28

Cuadro 7.19: Coeficientes Modelo ARMAX $\sim$ GARCH V Región HPM.




Figura 7.23: Residuos V Región HPM.




Figura 7.24: Ajuste de Validación V Región HPM.




Figura 7.25: Ajuste ARMAX V Región HPM.




Figura 7.26: Varianza Condicional V HPM.




Figura 7.27: Residuos Estandarizados V Región HPM.





Figura 7.28: Serie con Intervalo de 95 % de confianza Modelo GARCH V HPM.

Figura 7.29: Ajuste ARMAX $\sim$ GARCH V HPM.

7.2.5. Región Metropolitana.

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	✓	X	X
Mejor Modelo Lineal con desfase	X	X	✓	X	X
Mejor Modelo Lineal con interacción	X	X	✓	X	X
SARMA	✓	X	✓	X	X
SARMAX	✓	X	✓	X	✓
Red Neuronal	✓	X	✓	X	✓
ARIMAX	✓	X	✓	X	✓

Cuadro 7.20: Supuestos Residuales Modelos Diarios RM HPM.

Cuadro 7.21: My caption

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	678	50,6 %	10941	814558
Mejor Modelo Lineal con desfase	7	671	71,9 %	10957	815804
Mejor Modelo Lineal con interacción	8	678	48,3 %	10935	814102
SARMA	0	678	113 %	11224	835652
SARMAX	1	678	53,4 %	10939	814429
Red Neuronal	15	678	41,6 %	9420	24110
ARIMAX	4	678	33,1 %	820	22786

Cuadro 7.22: Resumen Modelos de Despachos Diarios RM HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,03	0,87
Residuos al cuadrado	5,24	0,02

Cuadro 7.23: Test Ljung-Box sobre Residuos RM HPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2
Coef	16.333	-13.666	0.4559	-0.0877	0.1147	-23.733	23.925
S.E.	0.3054	0.474	0.3628	0.0914	0.0567	0.3075	0.6977
Variable	ma3	ma4	V1	V2	V3	V4	V5
Coef	-11.793	0.168	-0.4114	-0.2233	0.5195	0.8432	-0.0219
S.E.	0.6497	0.2566	0.2483	0.1364	0.2055	0.0651	0.0048
Variable	V6	μ	ω	α	β		
Coef	32.309	3223	1758	0.01288	0.8873		
S.E.	0.1527	71	1403	0.005296	0.004374		

Cuadro 7.24: Modelo ARIMAX $\sim$ GARCH RM HPM.




Figura 7.30: Residuos RM HPM.




Figura 7.31: Ajuste Validación Región Metropolitana HPM.




Figura 7.32: Ajuste Región Metropolitana HPM.




Figura 7.33: Desviación Estándar del Modelo GARCH.




Figura 7.34: Residuos Estandarizados Modelo GARCH.




Figura 7.35: Serie con Intervalo de 95 % de confianza Modelo GARCH RM HPM.




Figura 7.36: Ajuste final ARIMAX GARCH RM HPM.

7.2.6. VI Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	✓	X	X
Mejor Modelo Lineal con desfase	X	X	✓	X	X
Mejor Modelo Lineal con interacción	X	X	✓	X	X
ARMA	✓	X	✓	X	X
Red Neuronal	✓	X	✓	X	✓
ARMAX	✓	X	✓	X	✓

Cuadro 7.25: Resumen Supuestos Residuales VI Región HPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	690	99,4 %	13487	8208
Mejor Modelo Lineal con desfase	7	690	121,3 %	13507	7218
Mejor Modelo Lineal con interacción	8	690	98,3 %	13479	9205
ARIMA	0	690	190 %	13836	836
Red Neuronal	7	690	93,4 %	11612	197
ARIMAX	2	690	79,1 %	1011	93,13

Cuadro 7.26: Resumen Modelos VI Región HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0231	0,7823
Residuos al cuadrado	5,2355	0,0327

Cuadro 7.27: Test Ljung-Box sobre Residuos VI Región HPM.

Variable	ar1	ma1	ma2	ma3	ma4	v1
Coef	-0,0576	-0,8173	-0,0151	0,0269	-0,1522	0,1461
S.E.	0,2192	0,2157	0,1986	0,0504	0,0473	0,0819
Variable	v2	μ	ω	α	β	
Coef	2,2811	233,6	599,1	0,0278	0,9342	
S.E.	0,1194	5,0	239,6	0,0111	0,0537	

Cuadro 7.28: Coeficientes Modelo ARMAX ~ GARCH VI Región HPM.




Figura 7.37: Residuos VI Región HPM.




Figura 7.38: Ajuste de Validación VI Región HPM.




Figura 7.39: Ajuste ARIMAX VI Región HPM.




Figura 7.40: Varianza Condicional VI HPM.




Figura 7.41: Residuos Estandarizados VI Región HPM.





Figura 7.42: Serie con Intervalo de 95 % de confianza Modelo GARCH VI HPM.

Figura 7.43: Ajuste ARIMAX $\sim$ GARCH VI HPM.

7.2.7. X Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
SARMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
SARMAX	√	X	√	X	√

Cuadro 7.29: Resumen Supuestos Residuales Modelos X Región HPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	5	570	42,0 %	2084	14741
Mejor Modelo Lineal con desfase	6	570	45,5 %	2087	14764
Mejor Modelo Lineal con interacción	8	570	40,6 %	2083	14733
SARMA	0	570	71 %	2138	15123
Red Neuronal	10	570	26,3 %	62	436
SARMAX	5	570	20,7 %	58	412

Cuadro 7.30: Resumen Modelos X Región HPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,1259	0.7226
Residuos al cuadrado	7,2356	0,0124

Cuadro 7.31: Test Ljung-Box sobre Residuos X Región HPM.

Variable	ar1	ar2	ar3	ma1	ma2	ma3
Coef	1,8553	-1,7706	0,8863	-1,6936	1,4936	-0,7165
S.E.	0,0429	0,0673	0,0405	0,0634	0,0978	0,0598
Variable	sma1	sma2	intercept	V1	V2	V3
Coef	-0,0738	0,0014	6,8615	-0,0031	0,3647	0,1809
S.E.	0,047	0,0489	0,0366	0,0015	0,1412	0,0308
Variable	V4	V5	μ	ω	α	β_1
Coef	-0,3327	-0,0066	1013,00	148900	0,13	0,0023
S.E.	0,1228	0,0022	18,38	84520	0,10	0,0015


Cuadro 7.32: Modelo SARMAX $\sim$ GARCH X Región HPM.

Figura 7.44: Residuos X HPM.




Figura 7.45: Ajuste de Validación Log X Región HPM.




Figura 7.46: Ajuste ARIMAX X Región HPM.




Figura 7.47: Varianza Condicional X Región HPM.




Figura 7.48: Varianza Condicional X Región HPM.




Figura 7.49: Serie con Intervalo de 95 % de confianza Modelo GARCH X HPM.




Figura 7.50: Ajuste final ARIMAX GARCH X HPM.

7.3. No Hormigón Pre-Mezclado

7.3.1. IV Región.

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
ARIMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARIMAX	√	X	√	X	√

Cuadro 7.33: Resumen Supuestos Residuales Modelos IV Región NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	5	1062	59,1 %	34124	1422
Mejor Modelo Lineal con desfase	4	1062	64,0 %	34176	1424
Mejor Modelo Lineal con interacción	6	1062	57,1 %	34105	1421
ARIMA	0	1062	100 %	35008	1459
Red Neuronal	9	1062	37,1 %	1010	42
ARIMAX	2	1062	29,1 %	955	40

Cuadro 7.34: Resumen Modelos IV Región NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0.07685	0.7816
Residuos al cuadrado	25.048	5.593e-07

Cuadro 7.35: Test Ljung-Box sobre Residuos IV Región NHPM.

Variable	ar1	ar2	ar3	ma1	ma2	ma3	ma4
Coef	-0,426	-0,0212	-0,4536	-0,4271	-0,2741	0,2436	-0,4007
S.E.	0,3291	0,1595	0,2366	0,3318	0,2358	0,2586	0,1559
Variable	m1	m2	μ	ω	α	β	
Coef	-0,0094	2,021	447,90	3923,00	0,12	0,70	
S.E.	0,0049	0,0735	4,49	1683,00	0,04	0,10	


Cuadro 7.36: Coeficientes Modelo ARIMAX $\sim$ GARCH IV Región NHPM.

Figura 7.51: Residuos IV Región NHPM.




Figura 7.52: Ajuste IV Región NHPM.




Figura 7.53: Varianza Condicional IV Región NHPM.




Figura 7.54: Residuos Estandarizados IV Región NHPM.




Figura 7.55: Ajuste ARIMAX IV Región NHPM.




Figura 7.56: Serie con Intervalo de 95 % de confianza Modelo GARCH IV HPM.




Figura 7.57: Ajuste ARIMAX ~ GARCH IV HPM.

7.3.2. V Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
ARMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARMAX	√	X	√	X	√

Cuadro 7.37: Resumen Supuestos Residuales V Región NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	1171	37,7 %	11406	2526
Mejor Modelo Lineal con desfase	7	1171	53,6 %	11424	2530
Mejor Modelo Lineal con interacción	8	1171	36,1 %	11400	2525
ARMA	0	1171	84 %	11702	2592
Red Neuronal	10	1171	31,1 %	9821	148
ARMAX	7	1171	26,0 %	843	126

Cuadro 7.38: Resumen Modelos V Región NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0234	0,8934
Residuos al cuadrado	6,5342	0,0235

Cuadro 7.39: Test Ljung-Box sobre Residuos V Región NHPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2	ma3
Coef	-0,225	0,233	-0,272	0,182	0,877	0,294	-0,171	0,339
S.E.	0,009	0,026	0,023	0,016	0,040	0,022	0,032	0,025
Variable	ma4	ma5	intercept	v1	v2	v3	v4	v5
Coef	-0,124	-0,879	6,158	-0,232	0,004	0,248	-2,238	0,659
S.E.	0,026	0,038	0,059	0,136	0,001	0,137	0,122	0,053
Variable	v2	v3	μ	ω	α	β		
Coef	-0,332	-0,012	858,50	256,10	0,023	0,730		
S.E.	0,058	0,002	343,40	102,44	0,009	0,292		


Cuadro 7.40: Coeficientes Modelo ARMAX $\sim$ GARCH V Región NHPM.

Figura 7.58: Residuos V Región NHPM.




Figura 7.59: Ajuste de Validación V Región NHPM.




Figura 7.60: Ajuste ARMAX V Región NHPM.




Figura 7.61: Varianza Condicional V NHPM.



Figura 7.62: Residuos Estandarizados V Región NHPM.




Figura 7.63: Serie con Intervalo de 95 % de confianza Modelo GARCH V NHPM.




Figura 7.64: Ajuste ARMAX $\sim$ GARCH V NHPM.

7.3.3. Región Metropolitana.

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	√	X	√	X	X
ARIMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARIMAX	√	X	√	X	√

Cuadro 7.41: Resumen Supuestos Residuales Modelos RM NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	8	1.217	38,6 %	11.128	7.399
Mejor Modelo Lineal con desfase	7	1.217	59,9 %	11.145	7.410
Mejor Modelo Lineal con interacción	9	1.217	36,3 %	11.122	7.395
ARIMA(5,1,5)	0	1.217	101 %	11.411	7.591
Red Neuronal	12	1.217	29,6 %	9.608	218
ARIMAX(5,1,5)	7	1.217	21,5 %	1.007	91

Cuadro 7.42: Resumen Modelos RM NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0197	0,8885
Residuos al cuadrado	8,2673	0,0047

Cuadro 7.43: Test Ljung-Box sobre Residuos RM NHPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2
Coef	-0,0986	-0,7094	-0,2853	-0,7208	0,0152	-0,7811	0,5622
S.E.	0,0821	0,1030	0,0899	0,0952	0,0383	0,0788	0,1812
Variable	ma3	ma4	ma5	V1	V2	V3	V4
Coef	-0,4014	0,4368	-0,7517	0,596	0,5851	0,6366	1,0271
S.E.	0,1477	0,1323	0,0848	0,0864	0,153	0,1266	0,0544
Variable	V5	V6	V7	μ	ω	α	β
Coef	1,0213	-0,0161	2,2425	1842	320800	0,1084	0,0300
S.E.	0,1425	0,0039	0,1115	18	83450	0,0367	0,0100

Cuadro 7.44: Modelo ARIMAX ~ GARCH RM NHPM.




Figura 7.65: Residuos RM Región NHPM.




Figura 7.66: Ajuste RM NHPM.




Figura 7.67: Varianza Condicional RM NHPM.




Figura 7.68: Residuos Estandarizados RM NHPM.




Figura 7.69: Ajuste ARIMAX RM NHPM.




Figura 7.70: Serie con Intervalo de 95 % de confianza Modelo GARCH RM NHPM.




Figura 7.71: Ajuste Modelo ARIMAX ~ GARCH RM NHPM.




Figura 7.72: Ajuste V Región NHPM.

7.3.4. VI Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
ARIMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARIMAX	√	X	√	X	√

Cuadro 7.45: Resumen Supuestos Residuales VI Región NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	1218	44,2 %	13062	1624
Mejor Modelo Lineal con desfase	7	1218	62,9 %	13082	1627
Mejor Modelo Lineal con interacción	8	1218	42,3 %	13055	1624
ARIMA	0	1218	99 %	13401	1667
Red Neuronal	7	1218	36,4 %	11247	95
ARIMAX	2	1218	30,4 %	966	81

Cuadro 7.46: Resumen Modelos VI Región NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,0231	0,7823
Residuos al cuadrado	5,2355	0,0327

Cuadro 7.47: Test Ljung-Box sobre Residuos VI Región NHPM.

Variable	ar1	ar2	ar3	ar4	ma1	ma2	ma3
Coef	-0,57	0,61	0,63	-0,26	-0,30	-1,14	-0,12
S.E.	-0,23	0,25	0,25	-0,10	-0,12	-0,46	-0,05
Variable	ma4	ma5	v1	v2	v3	v4	v5
Coef	0,83	-0,25	0,41	0,50	0,46	0,25	0,55
S.E.	0,33	-0,10	0,13	0,14	0,06	0,14	0,05
Variable	v6	μ	ω	α	β		
Coef	2,14	380,44	625,40	0,08	0,90		
S.E.	0,14	4,01	243,65	0,02	0,02		


Cuadro 7.48: Coeficientes Modelo ARIMAX $\sim$ GARCH VI Región NHPM.

Figura 7.73: Residuos VI Región NHPM.




Figura 7.74: Ajuste de Validación VI Región NHPM.




Figura 7.75: Ajuste ARIMAX VI Región NHPM.




Figura 7.76: Varianza Condicional VI NHPM.




Figura 7.77: Residuos Estandarizados VI Región NHPM.




Figura 7.78: Serie con Intervalo de 95 % de confianza Modelo GARCH VI NHPM.




Figura 7.79: Ajuste ARIMAX ~ GARCH VI NHPM.

7.3.5. VIII Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	✓	X	X
Mejor Modelo Lineal con desfase	X	X	✓	X	X
Mejor Modelo Lineal con interacción	X	X	✓	X	X
ARIMA	✓	X	✓	X	X
Red Neuronal	✓	X	✓	X	✓
ARIMAX	✓	X	✓	X	✓

Cuadro 7.49: Resumen Supuestos Residuales Modelos VIII Región NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	5	1128	57,1 %	19177	371
Mejor Modelo Lineal con desfase	6	1128	81,1 %	19207	371
Mejor Modelo Lineal con interacción	7	1128	54,5 %	19167	371
ARIMA	0	1128	127 %	19674	380
Red Neuronal	8	1128	47,0 %	16512	22
ARIMAX	5	1128	39,3 %	1418	18

Cuadro 7.50: Resumen Modelos VIII Región NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,1739	0,8983
Residuos al cuadrado	6,8344	0,0342

Cuadro 7.51: Test Ljung-Box sobre Residuos VIII Región NHPM.

Variable	ar1	ar2	ma1	ma2	v1	v2	v3
Coef	0,20	-0,06	-1,17	0,23	0,49	0,45	0,70
S.E	0,35	0,04	0,35	0,33	0,18	0,19	0,09
Variable	v4	v5	v6	mu	omega	alpha1	beta1
Coef	0,72	-0,22	-0,01	131,50	39,36	0,06	0,92
S.E	0,15	0,10	0,00	3,57	24,27	0,01	0,01

Cuadro 7.52: Coeficientes Modelo ARIMAX ~ GARCH NHPM VIII Región.




Figura 7.80: Residuos VIII Región NHPM.




Figura 7.81: Ajuste de Validación VIII Región NHPM.




Figura 7.82: Ajuste ARIMAX VIII Región NHPM.




Figura 7.83: Varianza Condicional VIII NHPM.




Figura 7.84: Residuos Estandarizados VIII Región NHPM.





Figura 7.85: Serie con Intervalo de 95 % de confianza Modelo GARCH VIII NHPM.

Figura 7.86: Ajuste ARIMAX $\sim$ GARCH VIII NHPM.

7.3.6. IX Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
ARIMA	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARIMAX	√	X	√	X	√

Cuadro 7.53: Resumen Supuestos Residuales Modelos X Región NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	5	604	51,9 %	17844	1322
Mejor Modelo Lineal con desfase	6	604	73,7 %	17871	1324
Mejor Modelo Lineal con interacción	7	604	49,6 %	17834	1321
ARIMA	0	604	116 %	18306	1356
Red Neuronal	8	604	42,7 %	15364	77
ARIMAX	5	604	35,7 %	1319	66

Cuadro 7.54: Resumen Modelos X Región NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,2739	0,6007
Residuos al cuadrado	5,2734	0,0407

Cuadro 7.55: Test Ljung-Box sobre Residuos IX Región NHPM.

Variable	ar1	ar2	ar3	ar4	ar5
Coef	-0,81	-0,64	-0,53	-0,37	-0,25
S.E	0,03	0,04	0,04	0,04	0,03
Variable	v1	v2	v3	v4	v5
Coef	-1,04	-0,10	0,28	-0,40	-0,01
S.E	0,47	0,04	0,06	0,06	0,00
Variable	mu	omega	alpha1	beta1	
Coef	208,72	252,19	0,10	0,88	
S.E	3,08	102,07	0,02	0,03	


Cuadro 7.56: Coeficientes ARIMAX $\sim$ GARCH IX Región NHPM.

Figura 7.87: Residuos Modelo IX Región NHPM.




Figura 7.88: Ajuste Validación IX Región NHPM.




Figura 7.89: Varianza Condicional IX Región NHPM.




Figura 7.90: Residuos Estandarizados IX Región NHPM.




Figura 7.91: Ajuste ARIMAX IX Región NHPM.




Figura 7.92: Serie con Intervalo de 95 % de confianza Modelo GARCH IX Región NHPM.




Figura 7.93: Ajuste ARIMAX ~ GARCH IX Región NHPM.

7.3.7. X Región

Modelo	Autocorr	Homoced	Media cte	Normalidad	Estado
Mejor Modelo Lineal	X	X	√	X	X
Mejor Modelo Lineal con desfase	X	X	√	X	X
Mejor Modelo Lineal con interacción	X	X	√	X	X
AR	√	X	√	X	X
Red Neuronal	√	X	√	X	√
ARX	√	X	√	X	√

Cuadro 7.57: Resumen Supuestos Residuales Modelos X Región NHPM.

Modelo	#Var	n	MAPE	AIC	ECP
Mejor Modelo Lineal	6	1171	50,6 %	14419	1857
Mejor Modelo Lineal con desfase	7	1171	71,9 %	14441	1860
Mejor Modelo Lineal con interacción	8	1171	48,3 %	14411	1856
AR	0	1171	113 %	14793	1905
Red Neuronal	10	1171	41,6 %	12415	55
ARX	6	1171	33,3 %	1080	52

Cuadro 7.58: Resumen Modelos X Región NHPM.

Test Ljung-Box		
Serie	Estadístico	P-Valor
Residuos	0,4739	0,4892
Residuos al cuadrado	7,3891	0,0065

Cuadro 7.59: Test Ljung-Box sobre Residuos X Región NHPM.

Variable	ar1	ar2	ar3	ar4	ar5	ma1	ma2
Coef	10.211	-0,0602	-0,504	0,0648	0,4189	-0,737	-0,1898
S.E.	0,3789	0,7257	0,7245	0,4189	0,2182	0,3801	0,6391
Variable	ma3	ma4	ma5	intercept	V1	V2	V3
Coef	0,5428	0,0605	-0,4112	104,6	408,2	517,8	479,0
S.E.	0,5383	0,2748	0,1786	29,9	82,2	80,9	21,5
Variable	V4	V5	V6	μ	ω	α	β
Coef	265,4	446,7	190,0	473	635	0,0314	0,9573
S.E.	70,3	65,7	21,5	10	64	0,0125	0,0171

Cuadro 7.60: Coeficientes Modelo ARX GARCH X Región NHPM.




Figura 7.94: Residuos Modelo X Región NHPM.




Figura 7.95: Ajuste Validación X Región NHPM.




Figura 7.96: Varianza Condicional X Región NHPM.




Figura 7.97: Residuos Estandarizados X Región NHPM.




Figura 7.98: Ajuste ARIMAX X Región NHPM.




Figura 7.99: Serie con Intervalo de 95 % de confianza Modelo GARCH X Región NHPM.




Figura 7.100: Ajuste ARX $\sim$ GARCH X Región NHPM.