

Filtro de Partículas Para la Estimación Online de Procesos Autorregresivos Irregularmente Observados

Miguel Angel Valdés Hernández

Profesor Guía:
Felipe Elorrieta

Propuesta de tesis para optar al título de Ingeniero Matemático de la Universidad de Santiago de Chile

Universidad de Santiago de Chile
Facultad de Ciencias
Departamento de Matemática y Ciencias de la computación

© **2024, Miguel Angel Valdés Hernández**

Se autoriza la reproducción parcial o total de esta obra, con fines académicos, por cualquier forma, medio o procedimiento, siempre y cuando se incluya la cita bibliográfica del documento.

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE CIENCIA
DEPARTAMENTO DE MATEMÁTICA Y CIENCIA DE LA COMPUTACIÓN



Filtro de Partículas Para la Estimación Online de Procesos Autorregresivos Irregularmente Observados

Miguel Angel Valdés Hernández.

Trabajo de Titulación presentado a la Facultad de Ciencia, en cumplimiento parcial de los requisitos exigidos para optar al título de **Ingeniero Matemamático**.
Este trabajo de Graduación fue presentado bajo la supervisión del profesor guía Dr. Felipe Elorrieta, del Departamento de Matemática y Ciencia de la Computación de la Facultad de Ciencia.

Resumen

En muchos métodos de análisis y modelización de datos, se asume que las observaciones son regularmente espaciadas en el tiempo, sin embargo, este supuesto no se cumple en diversas áreas como desastres naturales, finanzas y astronomía. Este estudio propone un método basado en el filtro de partículas para la estimación secuencial del parámetro autorregresivo en modelos autorregresivos con datos regularmente e irregularmente espaciados. Se obtuvieron algoritmos teóricos basados en la metodología de partículas y se implementaron en los lenguajes de programación R y Python utilizando tanto conjuntos de datos simulados como reales para evaluar su efectividad, donde se analizan los tiempos de ejecución y se compara la precisión de las estimaciones junto con las predicciones realizadas por los métodos propuestos con el método de estimación por Máxima Verosimilitud. Los datos simulados incluyeron tres escenarios con distintas dinámicas en el parámetro autorregresivo: constante, con cambios súbitos y con cambios graduales, los que fueron analizados a través de simulaciones de Monte Carlo, mientras que en los datos reales se aplicaron los métodos propuestos a una serie de tiempo que contiene las mediciones anuales del caudal del río Nilo para el caso regularmente espaciado y a curvas de luz astronómicas de Núcleos de Galaxia Activa y Objeto Cuasiestelar en el caso irregular.

Los resultados muestran que el método propuesto es eficaz en la detección de cambios estructurales y en la actualización del parámetro autorregresivo, lo cual permite una mejor adaptabilidad frente a cambios en la dinámica del sistema. En comparación con el método de Máxima Verosimilitud, el filtro de partículas mostró mayor capacidad de predicción y precisión especialmente en escenarios con cambios estructurales abruptos y graduales.

Palabras clave: Series de Tiempo, Modelo AR, Modelo IAR, Aprendizaje Secuencial, Filtro de Partículas.

Agradecimientos

Quisiera expresar mi más sincera gratitud a todas las personas que han contribuido y brindado su apoyo durante este proceso. En primer lugar, deseo agradecer a mi familia, a mi pareja y a mis amigos, quienes con su respaldo, aliento constante y amor incondicional me han ayudado a superar los desafíos que se presentaron a lo largo de este recorrido. A mi perrito Kayser quien me acompañó en noches interminables de estudio y que desde el cielo de los perritos me sigue acompañando.

Asimismo, expreso mi agradecimiento a los profesores que tuve el privilegio de conocer durante el transcurso de mi formación académica, quienes en numerosas ocasiones me ofrecieron valiosos consejos que resultaron fundamentales para mi desarrollo personal, académico y profesional.

Finalmente, muchas gracias a todas las personas que, de una manera u otra, aportaron su granito de arena en este proceso y me han ayudado a crecer como persona.

¡Gracias totales!

Índice general

Resumen iii

Agradecimientos iv

1. Introducción 1

1.1. Objetivo General . . . 3

1.2. Objetivos Específicos . . . 3

2. Marco Teórico 4

2.1. Procesamiento Batch y Online . . . 4

2.2. Enfoque Bayesiano y Enfoque Frecuentista . . . 5

2.3. Teorema de Bayes . . . 7

2.4. Series de Tiempo . . . 8

2.4.1. Proceso Estocástico . . . 8

2.4.2. Procesos Estacionarios . . . 9

2.4.3. Ruido Blanco . . . 9

2.4.4. Modelo Autorregresivo . . . 10

2.4.4.1. Modelo Autorregresivo de orden 1 . . . 10

2.4.4.1.1. Propiedades del modelo AR(1). . . . 11

2.4.5. Modelo Autorregresivo Irregular . . . 11

2.4.6. Modelos Espacio-Estado . . . 12

2.4.6.1. Modelos Espacio-Estado Probabilísticos 12
2.5. Métodos de Monte Carlo: Filtro de Partículas 13
2.5.1. Aproximaciones Monte Carlo en inferencia Bayesiana . . . 14
2.5.2. Muestreo de Importancia 15
2.5.3. Muestreo Secuencial de Importancia 16
2.5.4. Filtro de Estado 18
2.5.5. Filtro de Estados y Parámetros 21
2.5.5.1. Evolución Artificial de Parámetros 22
2.5.5.2. Suavizado de Kernel 22

3. Estimación Online de Procesos Autorregresivos 24
3.1. Estimación Online Modelo AR(1) 24
3.2. Estimación Online Modelo IAR 27
3.3. Implementación en Software R 29
3.3.1. Simulación de Datos 29
3.3.2. Estimación Online Modelo AR (1) 31
3.3.3. Estimación Batch Modelo IAR 32
3.3.4. Estimación Online Modelo IAR 33

4. Simulaciones 34
4.1. Simulación de Tiempos 35
4.2. Criterios de Evaluación 38
4.2.1. Mean Squared Errors 38
4.2.2. Diferencia entre el parámetro real y estimado 39
4.3. Modelo AR(1) con Parámetro Fijo 39
4.4. Modelo Autorregresivo Irregular 42
4.4.1. Modelo IAR con Parámetro Constante en el Tiempo . . . 44
4.4.1.1. Modelo IAR con Parámetro $\phi = 0.9$ 44

4.4.1.2. Modelo IAR con Parámetro $\phi = 0.5$ 47
4.4.1.3. Modelo IAR con Parámetro $\phi = 0.3$ 49
4.4.2. Modelo IAR con Cambio Abrupto en el Parámetro 51
4.4.2.1. Modelo IAR Cambio Abrupto de Parámetro $\phi = 0.3$ a $\phi = 0.95$ 52
4.4.2.2. Modelo IAR Cambio Abrupto de Parámetro $\phi = 0.8$ a $\phi = 0.3$ 55
4.4.3. Modelo IAR con Cambio Constante en el Parámetro . . . 56
4.4.3.1. Modelo IAR Cambio Constante de Parámetro $\phi_1 = 0.3$ a $\phi_2 = 0.95$ 57
4.4.3.2. Modelo IAR Cambio Constante de Parámetro $\phi_1 = 0.8$ a $\phi_2 = 0.4$ 59
4.5. Resultados Generales 62
4.5.1. Modelos con Parámetro Fijo 62
4.5.2. Modelos con Cambio Abrupto en el Parámetro 64
4.5.3. Modelos con Cambio Constante en el Parámetro 65

5. Aplicación en Datos Reales **68**
5.1. Flujo del Río Nilo 68
5.2. Curvas de Luz Atronómicas 73
5.2.1. Núcleo de Galaxia Activa - Curva ZTF18aaabbuy 73
5.2.2. Objeto Cuasiestelar - Curva ZTF18acefhus 75

6. Conclusiones **78**

Referencias **80**

7. Anexo **84**
7.1. Distribuciones de Probabilidad 84
7.1.1. Distribución Normal 84

7.1.2. Distribución Uniforme 84
7.1.3. Distribución Gamma 84
7.1.4. Distribución Exponencial 85
7.1.5. Mezcla de Distribuciones 85
7.2. Código Filtro de Partículas - Modelos AR1 86
7.3. Códigos Filtro de Partículas - Modelos IAR 87
7.3.1. Código en Lenguaje R 87
7.3.2. Código en Lenguaje Python 88
7.4. Resultados Generales - Python 89
7.4.1. Modelos con Parámetro Fijo 89
7.4.2. Modelos con Cambio Abrupto en el Parámetro 90
7.4.3. Modelos con Cambio Constante en el Parámetro 91
7.5. Residuos Nilo - Estimación Máxima Verosímil 92

Capítulo 1

Introducción

A través del tiempo se han recopilado datos de variadas índoles, tales como sociales, empresariales, médicos, entre otros. Esta información almacenada puede ser utilizada en diversos fines, como apoyar en la toma de decisiones, entender comportamientos de clientes, fenómenos naturales e incluso enfermedades. Una manera para recopilar información es a través de las series de tiempo, puesto que por definición son una colección de observaciones de un evento, fenómeno o dato de interés que se mide secuencialmente en intervalos de tiempo.

Una metodología presente desde hace siglos para el análisis de la información recolectada es el procesamiento de datos en lotes (batch), donde se procesa toda la información disponible para generar resultados. Un ejemplo de este enfoque es el Estimador Máximo Verosímil (EMV o MLE por sus siglas en inglés), utilizado para estimar los parámetros de un modelo probabilístico. En la actualidad, dado el gran volumen de información disponible y en constante recolección, el uso de métodos batch resultan cada vez menos apropiados para el análisis de datos, puesto que a medida que la cantidad de información aumenta, el método será más lento. En consecuencia, surgen desafíos en cuanto a cómo procesar de manera óptima una gran cantidad de información y en constante actualización. Una propuesta para sobrellevar este desafío se encuentra en el procesamiento de datos online o algoritmos de aprendizaje online, puesto que su enfoque se basa en analizar la información en tiempo real, es decir, a medida que es generada y almacenada, de manera rápida y simple sin necesidad de analizar los datos anteriores, ideal para situaciones en las que los datos se obtienen continuamente en el tiempo (Bisong,

2019).

En el ámbito de series de tiempo, uno de los modelos base es el modelo autorregresivo (AR), el cual predice la variable de interés a través de una combinación lineal de valores pasados de la misma, más una variable de error. Una limitante de este modelo es que asume que las series de tiempo son observadas en intervalos de tiempo regulares. En la realidad, las series cronológicas irregularmente espaciadas son comúnmente observadas en diversos fenómenos, como por ejemplo los desastres naturales (terremotos, erupciones volcánicas o inundaciones). En astronomía las observaciones de cuerpos celestes se obtienen habitualmente en intervalos de tiempo irregulares, dado que dependen, entre otros factores, de la claridad del cielo para recopilar la información de interés. (Eyheramendy et al., 2018).

En la práctica, la mayoría de las metodologías utilizadas para el análisis y modelización de datos irregularmente espaciados se realizan asumiendo regularidad del tiempo en las mediciones, ignorando su irregularidad inherente. Otra práctica comúnmente realizada, consiste en interpolar la serie de tiempo irregular y convertirla una serie temporal regular, para posteriormente aplicar modelos y metodologías ya existentes para datos uniformemente espaciados. Sin embargo, prácticas como las mencionadas anteriormente, generan un sesgo significativo al estimar los parámetros del modelo (Eyheramendy et al., 2018). Con el propósito de abordar la irregularidad del tiempo, S. Eyheramendy, F. Elorrieta y W. Palma propusieron en 2018 un modelo autorregresivo irregular (IAR) que permite trabajar con este tipo de series temporales.

El objetivo de estudio principal de este trabajo es derivar una estructura espacio-estado para la estimación online del parámetro ϕ en el modelo autorregresivo irregular (IAR) utilizando el método Bayesiano de *Filtro de Partículas* (Liu and West, 2001). Posteriormente, se implementará el algoritmo planteado en los lenguajes de programación R y Python. Se realizarán estimaciones a distintos conjuntos de datos simulados evaluando la adaptabilidad y eficiencia de la estimación online analizando la convergencia de los parámetros. Por último se aplicará el algoritmo propuesto a conjuntos de datos astronómicos y se analizará su desempeño.

1.1. Objetivo General

Implementar un método de estimación secuencial basado en el filtro de partículas para procesos autorregresivos observados de manera regular e irregular.

1.2. Objetivos Específicos

- Realizar una revisión bibliográfica respecto a los algoritmos de aprendizaje online enfocada en el filtro de partículas.
- Derivar una estructura espacio-estado para la estimación de los parámetros tanto para el modelo autorregresivo regular como el autorregresivo irregular.
- Proponer métodos de estimación online para los parámetros de los modelos autorregresivo regular y autorregresivo irregular basados en el filtro de partículas.
- Implementar los algoritmos propuestos de estimación online para el modelo autorregresivo regular y autorregresivo irregular en los lenguajes de programación Python y R.
- Evaluar la adaptabilidad y eficiencia de los métodos propuestos realizando comparaciones entre ellos y evaluando sus métricas de bondad de ajuste.
- Aplicar el algoritmo propuesto a distintos conjuntos de datos simulados y datos reales.

Capítulo 2

Marco Teórico

2.1. Procesamiento Batch y Online

A lo largo de la historia, se han recopilado datos de diversas índoles, ya sean sociales, empresariales, médicos, etc. Esta información almacenada puede ser utilizada para diversos fines, como apoyar en la toma de decisiones, entender el comportamiento de clientes, fenómenos naturales e incluso enfermedades. Con el crecimiento exponencial de la cantidad de datos en los últimos años, el análisis y procesamiento de datos se ha vuelto fundamental para cualquier organización. Para este propósito, se pueden distinguir, entre otros, dos tipos de procesamiento basados en el uso y el tipo de datos: el procesamiento *batch* y el procesamiento *online* (streaming o secuencial).

El procesamiento batch se enfoca en procesar toda la información a disposición o por lotes (de manera individual), para luego entregar resultados, por lo que se requiere una gran cantidad de recursos de memoria y procesamiento. Su principal ventaja es poder realizar grandes trabajos computacionales en partes pequeñas para asegurar la eficiencia, además tiene la habilidad de trabajar "offline", lo cual genera menos estrés en el procesador (Benjelloun et al., 2020). Sin embargo, no es adecuado cuando el tiempo de respuesta es crítico, ya que el procesamiento no se realiza en tiempo real.

Por otro lado, el procesamiento online analiza la información a medida que

esta llega, sin necesidad de crear lotes de datos, lo cual permite tomar decisiones y acciones en tiempo real. En general, los algoritmos de aprendizaje online son rápidos, simples y suelen hacer pocos supuestos estadísticos, lo que las hace útiles a una amplia gama de aplicaciones (Hoi et al., 2014) como en la detección de fraudes, análisis de datos en redes sociales, entre otros.

En base a lo anterior y dada la naturaleza de los datos con que se trabajarán a largo de esta investigación, el procesamiento online sería el tipo de técnica ideal a utilizar, puesto que, analiza la información a medida que esta va llegando y entrega resultados sin recurrir al análisis de los datos previos.

2.2. Enfoque Bayesiano y Enfoque Frecuentista

Realizar inferencia a partir de datos puede tomar muchas formas, pero los principales objetivos inferenciales serán a menudo la *estimación puntual*, para proporcionar una "mejor estimación"de un parámetro desconocido, y la *estimación por intervalos*, para producir rangos de parámetros desconocidos que se apoyen en los datos (Wakefield, 2013).

Uno de los debates que se ha forjado entre los estadísticos, es acerca del enfoque a seguir en el tratamiento e inferencia de datos y naturalmente surgen preguntas como: ¿Cuál enfoque es mejor que el otro? ¿Cuándo se debería ocupar el enfoque Bayesiano? ¿Cuándo se debería ocupar el enfoque frecuentista?. Ambos enfoques entregan soluciones válidas y al momento de enfrentarse a problemas pueden utilizarse en forma separada y a menudo en conjunto (Wakefield, 2013). Como señala Gelman et al. (2004), "la estadística bayesiana es un enfoque para la inferencia estadística en el que se utilizan distribuciones de probabilidad para representar la incertidumbre sobre los parámetros o las hipótesis en cuestión, y para actualizar esta incertidumbre a medida que se recopilan datos observacionales". Según Hogg and Tanis (2012), "el enfoque frecuentista se basa en la idea de que la probabilidad de un evento es una frecuencia límite, es decir, una proporción a largo plazo de veces que el evento ocurre en un gran número de ensayos". Los escenarios más comunes donde se pueden conectar los enfoques es cuando no existe información externa aparte de los datos y el propio modelo, cuando se utilizan "distribuciones objetivas a priori"(Bayarri and Berger, 2004).

Por una parte el **enfoque frecuentista** se centra en el uso de los datos de la muestra para hacer inferencias sobre los parámetros de la población. Este enfoque se basa en los siguientes postulados:

- Se supone que la probabilidad de un evento es el límite de la frecuencia relativa de ese evento a medida que el número de repeticiones tiende a infinito (Wasserman, 2010).
- Los parámetros y las hipótesis se consideran cantidades fijas pero desconocidas (Wakefield, 2013), por lo tanto, no se pueden hacer afirmaciones probabilísticas útiles sobre estos (Wasserman, 2010).
- Los procedimientos estadísticos deben diseñarse para que tengan propiedades de frecuencia a largo plazo bien definidas. Por ejemplo, un intervalo de confianza del 95 % debe contener el valor verdadero del parámetro con una frecuencia límite de al menos el 95 % (Wasserman, 2010).

Una de las principales críticas al enfoque frecuentista es que las probabilidades se consideran frecuencias límite en infinitas réplicas hipotéticas de la situación considerada. Esto implica que la probabilidad se refiere únicamente a eventos aleatorios repetidos muchas veces y en consecuencia, esta definición de probabilidad no es adecuada para situaciones en las que solo se tiene una muestra única.

Por otro lado, el **enfoque Bayesiano** utiliza tanto los datos de la muestra como la información previa sobre los parámetros de la población para hacer inferencias. En este enfoque, se asume que los parámetros de la población son variables aleatorias (Wakefield, 2013) y se utiliza la probabilidad condicional para actualizar la probabilidad a *priori* de los parámetros a medida que se recopilan más datos (Gelman et al., 2004) y así obtener información a *posteriori*. Este enfoque se basa en los siguientes postulados (Wasserman, 2010):

- La probabilidad describe el grado de creencia, no la frecuencia límite. Como resultado, podemos hacer afirmaciones de probabilidades de muchas cosas, no solamente de datos sujetos a variación aleatoria.
- Se pueden realizar afirmaciones probabilísticas sobre parámetros, aunque sean constantes fijas.

- Se realiza inferencia sobre un parámetro obteniendo su distribución de probabilidad.

Una crítica común al enfoque Bayesiano es que puede ser más costoso computacionalmente y sensible a las elecciones subjetivas de la información a priori, lo que puede afectar significativamente las inferencias finales.

En resumen, mientras que el enfoque Bayesiano utiliza distribuciones de probabilidad para representar la incertidumbre subjetiva y actualizar el conocimiento sobre las hipótesis, el enfoque frecuentista se centra en la estimación de parámetros poblacionales a partir de muestras aleatorias y la construcción de intervalos de confianza basados en la variabilidad de los estimadores. Ambos enfoques tienen sus ventajas y desventajas, y la elección entre ellos a menudo depende de las suposiciones y objetivos específicos del problema en cuestión.

2.3. Teorema de Bayes

Consideremos un evento A y un conjunto de n eventos $B_1, B_2, \ldots, B_n$ que son una partición en el universo U, esto es:

- La unión de los eventos es igual al universo, es decir: $B_1 \cup B_2 \cup \cdots \cup B_n = U$.
- Los pares de eventos son mutuamente excluyentes,es decir: $B_i \cap B_j = \emptyset$ para $i, j \in \{1, \ldots, n\}$ e $i \neq j$.

y se conocen las probabilidades de $\mathbb{P}(A|B_i)$, y $\mathbb{P}(B_i)$ para $i = 1, \ldots, n$ entonces el teorema de bayes está dado por:

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\mathbb{P}(A)} \tag{2.3.1}$$

Donde:

- $\mathbb{P}(B_i|A)$ es la probabilidad a posteriori del evento B_i dado el evento A.
- $\mathbb{P}(A|B_i)$ es la probabilidad de A condicionada al i-ésimo evento B.
- $\mathbb{P}(B_i)$ es la probabilidad a priori de la ocurrencia del evento B_i.

- $\mathbb{P}(A)$ es la probabilidad de que suceda el evento A.

Al trabajar en un contexto Bayesiano, se reinterpretan los eventos probabilísticos del clásico teorema de Bayes en términos de datos (D) e hipótesis (H).

$$\mathbb{P}(H|D) = \frac{\mathbb{P}(D|H)\mathbb{P}(H)}{\mathbb{P}(D)} \tag{2.3.2}$$

Donde:

- $\mathbb{P}(H|D)$ es la probabilidad a posteriori y representa a la probabilidad de que la hipótesis H sea verdadera luego de tener en consideración los datos D.
- $\mathbb{P}(D|H)$ se conoce como la verosimilitud de los datos D y es la evidencia que se tiene de la hipótesis H que proviene directamente de los datos.
- $\mathbb{P}(H)$ es la probabilidad a priori y corresponde a la probabilidad de que la hipótesis sea verdadera.
- $\mathbb{P}(D)$ representa la probabilidad total de los datos D.

2.4. Series de Tiempo

Las series de tiempo se definen como una serie de observaciones numéricas de un evento o fenómeno medidas secuencialmente en el tiempo. Formalmente, se define como un conjunto de observaciones $\{y_t, t \in T\}$ con T estrictamente creciente. Las series de tiempo tienen aplicación en diversas áreas como son la economía, ingeniería, sociología, geofísica, demografía, química, marketing, transporte y también en el mundo empresarial. Los objetivos principales del estudio y análisis de las series cronológicas radican en describir, encontrar patrones o comportamientos de estas para luego ajustar modelos matemáticos a la serie, predecir el comportamiento tanto futuro como pasado (retropredicción) de la serie e imputar datos que no se observaron y que puedan ser necesarios.

2.4.1. Proceso Estocástico

Un proceso estocástico es una familia de variables aleatorias $Y = \{Y_t, t \in T\}$, donde para todo $t \in T$, Y_t es una variable aleatoria. En el contexto de la series de

tiempo, el conjunto T está dado por los tiempos de observación $T = \{t_1, t_2, \ldots, t_n\}$, en consecuencia el proceso estocástico se define como $Y = \{y_1, y_2, \ldots, y_n\}$.

2.4.2. Procesos Estacionarios

Una de las características más importantes de los procesos estocásticos es la estacionaridad, esto se debe principalmente a la definición de la función de autocovarianza para su posterior análisis. Existen dos tipos de estacionaridad, la fuerte y la débil:

- **Estacionaridad Fuerte**: Un proceso estocástico $\{y_t\},\ t \in T$ se dice estacionario fuerte o estrictamente estacionario si todas las distribuciones de dimensión finita permanecen iguales en el tiempo, es decir, $F(y_1, y_2, \ldots, y_n) = F(y_{t+1}, y_{t+2}, \ldots, y_{t+n}) \forall n, t \in \mathbb{Z}$.

- **Estacionaridad Débil**: Un proceso estocástico $\{y_t\},\ t \in T$ se dice débilmente estacionario o estacionario de segundo orden, si cumple las siguientes condiciones:

  1. $\mathbb{E}[y_t] = \mu < \infty$, donde μ es constante $\forall t \in T$.
  2. $\mathbb{V}[y_t] = \sigma^2 < \infty$, donde σ^2 es constante $\forall t \in T$.
  3. Se define la función de autocovarianza $\gamma(\cdot)$ tal que $\mathbb{C}(y_t, y_s) = \gamma(t - s)$, $\forall t, s \in T$.
     Esta propiedad implica que la función de autocovarianza entre dos observaciones cualesquiera depende solo de la diferencia de los tiempos t y s.

2.4.3. Ruido Blanco

Un ejemplo de un proceso débilmente estacionario, es el ruido blanco, el cual es un proceso que cumple las siguientes propiedades:

1. $\mathbb{E}[y_t] = 0,\ \forall t \in T$.
2. $\mathbb{V}[y_t] = \sigma^2, \forall t \in T$.
3. $\mathbb{C}(y_t, y_s) = 0,\ \forall t, s \in T$.

Si un proceso y_t es un ruido blanco, se denotará como:

$$y_t \sim RB(0, \sigma^2).$$

2.4.4. Modelo Autorregresivo

Un proceso estocástico $\{y_t\}, t \in T$ se dice autorregresivo de orden p (AR(p)), si:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t \tag{2.4.1}$$

donde $p \geq 1$, $\varepsilon \sim RB(0, \sigma^2)$ y $\phi_1, \phi_2, \ldots, \phi_p$ son constantes.
El modelo anterior corresponde al caso centrado, donde la media de y_t es 0. En el caso general, donde la media del proceso es $\mu \neq 0$, se reemplaza y_t por $y_t - \mu$, es decir,

$$y_t - \mu = \phi_1(y_{t-1} - \mu) + \phi_2(y_{t-2} - \mu) + \cdots + \phi_p(y_{t-p} - \mu) + \varepsilon_t \tag{2.4.2}$$

O también:

$$y_t = \alpha + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \varepsilon_t \tag{2.4.3}$$

donde $\alpha = \mu(1 - \phi_1 - \phi_2 - \cdots - \phi_p)$.
Para que este proceso sea estacionario, las raíces del polinomio:

$$\Phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \cdots - \phi_p z^p = 0 \tag{2.4.4}$$

deben estar fuera del círculo unitario, es decir, $\left|z_j^*\right| > 1, \ \forall j \in \{1, \ldots, p\}$.

2.4.4.1. Modelo Autorregresivo de orden 1

Un caso importante de los modelos autorregresivos, es cuando se tiene el valor de p=1, es decir, un modelo AR(1) el cual es de la forma:

$$y_t = \phi y_{t-1} + \varepsilon_t \tag{2.4.5}$$

donde $\varepsilon_t \sim RB(0, \sigma^2)$.
Previamente se mencionó que las raíces del polinomio $\Phi(z)$ deben estar fuera del círculo unitario para que el proceso sea estacionario. Para el caso AR(1), esto es,

$$\Phi(z) = 1 - \phi z = 0$$
$$\Rightarrow |z| = \left|\frac{1}{\phi}\right| > 1$$

Por lo tanto para que el proceso y_t sea estacionario es equivalente la condición $|\phi| < 1$.

2.4.4.1.1 Propiedades del modelo AR(1).

Sea y_t un proceso AR(1). Bajo el supuesto $|\phi| < 1$, el proceso y_t es estacionario con las siguientes propiedades:

1. $\mathbb{E}(y_t) = 0,\ \forall y_t,\ t \in T.$
2. $\mathbb{V}(y_t) = \dfrac{\sigma^2}{1-\phi^2},\ \forall y_t,\ t \in T$
3. $\gamma(k) = \mathbb{C}(y_t, y_{t-k}) = \dfrac{\sigma^2\phi^{|k|}}{1-\phi^2},\ \forall t \in T$
4. $\rho(k) = \dfrac{\gamma(k)}{\gamma(0)} = \phi^{|k|}$ (Función de autocorrelación)

2.4.5. Modelo Autorregresivo Irregular

El modelo autorregresivo descrito previamente fue propuesto considerando que las series de tiempo están regularmente espaciadas, es decir, la distancia entre tiempos consecutivos $t_j - t_{j-1}$ es constante, sin embargo, las series de tiempo irregularmente espaciadas son comúnmente observadas en diversas disciplinas, por ejemplo, en los desastres naturales como terremotos, erupciones volcánicas o inundaciones. En astronomía, las observaciones usualmente están obtenidas en intervalos de tiempo irregulares dado que dependen, entre otras cosas, de la claridad del cielo para poder obtener los datos de los telescopios (Elorrieta et al., 2019).

Debido a la existencia de series irregularmente espaciadas en la realidad, S. Eyheramendy, F. Elorrieta y W. Palma proponen en 2018 un modelo autorregresivo irregular (IAR) (Eyheramendy et al., 2018), el cual se define como:

$$y_{t_j} = \phi^{t_j - t_{j-1}} y_{t_{j-1}} + \sigma\sqrt{1-\phi^{2(t_j-t_{j-1})}}\varepsilon_{t_j} \tag{2.4.6}$$

donde y_{t_j} corresponde a la observación medida en el tiempo t_j, y se considera t_j como una secuencia de tiempos de observación estrictamente creciente para $j = 1, \ldots, n$, ϕ corresponde al parámetro de la función de autocorrelación (ACF), σ es la desviación estándar para todo y_{t_j} y $\varepsilon_{t_j} \overset{iid}{\sim} RB(0,1)$.

Note que el proceso IAR es una extensión del proceso autorregresivo regular. Si $t_j - t_{j-1} = 1$, el proceso IAR se convierte en el modelo AR(1).

Además, se tiene

- $\mathbb{E}(y_{t_j}) = 0$ para todo y_{t_j},
- $\mathbb{V}(y_{t_j}) = \sigma^2$ para todo y_{t_j},
- La covarianza entre dos tiempos de observación distintos s y t con $s < t$ es $\mathbb{E}(y_t, y_s) = \gamma(t-s) = \sigma^2\phi^{t-s}$,

y también se tiene la ACF, $\rho(t-s) = \frac{\gamma(t-s)}{\gamma(0)} = \phi^{t-s}$. Por lo tanto, si $0 < \phi < 1$ la sucesión $\{y_{t_j}\}$ corresponde a un proceso estacionario de segundo orden.

2.4.6. Modelos Espacio-Estado

Las series de tiempo pueden ser representadas a través de distintas formas, una de ellas es a través de modelos espacio-estado. Estos modelos constan de dos ecuaciones, una es conocida como la ecuación de observación, la cual permite expresar la observación Y_t a través de una variable de estado v-dimensional X_t más una componente de ruido aleatoria y por otro lado la ecuación de estado, que permite representar a la variable de estado X_{t+1} en el tiempo $t+1$ en términos del estado anterior X_t sumando una componente de ruido aleatoria (Brockwell and Davis, 2016).

De esta forma, las ecuaciones generales del modelo espacio-estado son las siguientes:

$$X_{t+1} = F_t X_t + V_t \tag{2.4.7}$$

$$Y_t = G_t X_{t+1} + W_t \tag{2.4.8}$$

donde $W_t \sim RB(0, R_t)$, $V_t \sim RB(0, Q_t)$, con R_t y Q_t las matrices de covarianza de W_t y V_t respectivamente. G_t es una matriz de dimensión $w \times v$, F_t es una matriz de dimensión $v \times v$ y W_t no está correlacionado con V_t.
Por definición, toda serie de tiempo Y_t tendrá una representación espacio-estado si se puede escribir a partir de las ecuaciones mencionadas previamente.

2.4.6.1. Modelos Espacio-Estado Probabilísticos

Un modelo probabilístico de espacio-estado o modelo de filtrado no lineal consiste en una secuencia de distribuciones de probabilidad condicionada de la

siguiente forma:

$$\begin{aligned} x_t &\sim p(x_t|x_{t-1}), \\ y_t &\sim p(y_t|x_t), \end{aligned} \tag{2.4.9}$$

para $t = 1, 2, ...$, donde

- $x_t \in \mathbb{R}^n$ es el estado del sistema en el paso de tiempo t,
- $y_t \in \mathbb{R}^m$ es la observación en el paso de tiempo t,
- $p(x_t|x_{t-1})$ es el modelo dinámico que describe la dinámica estocástica del sistema,
- $p(y_t|x_t)$ es el modelo de observación, que es la distribución de la observación dado el estado x_t.

Se asume que el modelo (2.4.9) es Markoviano, para lo cual se cumplen las siguientes dos propiedades.

Propiedad 1. *(Propiedad de Markov de los estados)*
Los estados $\{x_t : t = 0, 1, 2, ...\}$ *forman una una secuencia o cadena de Markov, es decir,* x_t *dado* x_{t-1} *depende únicamente de lo ocurrido en el paso de tiempo* $t-1$ *y no de la historia previa al tiempo* $t-1$*. Esto es:*

$$p(x_t|x_{1:t-1}, y_{1:t-1}) = p(x_t|x_{t-1}).$$

También el pasado es independiente del futuro dado el presente:

$$p(x_{t-1}|x_{t:T}, y_{t:T}) = p(x_{t-1}|x_t)$$

Propiedad 2. *(Independencia condicional de las observaciones)*
La observación actual y_t *dado el estado actual* x_t *es condicionalmente independiente a las observaciones y estados previos. Esto es:*

$$p(y_t|x_{1:t}, y_{1:k-1}) = p(y_k|x_k).$$

2.5. Métodos de Monte Carlo: Filtro de Partículas

En muchos problemas donde se desea determinar el estado de un sistema (problema de filtrado) las aproximaciones gaussianas funcionan bien, sin embargo, a

veces nos podemos encontrar con distribuciones que pueden ser multimodales o que algunos de los componentes del estado puede ser discreto, en cuyo caso las aproximaciones gaussianas no son apropiadas (Särkkä, 2013). Para estos casos, los filtros de partículas pueden ser una mejor alternativa.

El filtro de partículas, o también conocido como filtro de de Monte Carlo es una secuencia de Monte Carlo que se utiliza para resolver el filtrado Bayesiano recursivo en sistemas no lineales y/o no gaussianos. Fue introducido por primera vez en la literatura científica en la década de los 90. La invención de este filtro se le atribuye a varios autores, entre ellos, *Gordon, N.J., Salmond, D.J.* y *Smith* quienes en 1993 en su publicación "Novel approach to nonlinear/non-Gaussian Bayesian state estimation" (N.J. Gordon, 1993) desarrollaron métodos Monte Carlo recursivos a los que llamaron filtros de partículas y *Pierre Del Moral* que en 1996 publicó el artículo llamado "Nonlinear Filtering: Interacting Particle Solution" (Del Moral, 1997) en el que describió un método de filtrado no lineal basado en una aproximación de Monte Carlo con muestras aleatorias posteriormente llamadas partículas.

2.5.1. Aproximaciones Monte Carlo en inferencia Bayesiana

En la inferencia Bayesiana, incluyendo el filtrado Bayesiano, el principal problema usualmente se reduce al cálculo del siguiente tipo de esperanzas sobre la distribución posterior:

$$\mathbb{E}[g(x)|y_{1:T}] = \int g(x)p(x|y_{1:T})dx \tag{2.5.1}$$

donde $g : \mathbb{R}^n \to \mathbb{R}^m$ es una función arbitraria (usualmente considerada como la función identidad) y $p(x|y_{1:T})$ es la densidad de probabilidad posterior de x dadas las observaciones $y_1, \ldots, y_T$. El problema es que dicha integral puede ser calculada de manera directa solo en casos especiales y generalmente, se deben usar métodos numéricos (Särkkä, 2013).

Los métodos de Monte Carlo entregan métodos numéricos para el calculo de integrales de la forma (2.5.1). En una aproximación (perfecta) de Monte Carlo, se

escogen N muestras aleatorias independientes $x^{(i)} \sim p(x|y_{1:T}),\ i = 1, \ldots, N$ y se estima la esperanza como

$$\mathbb{E}[g(x)|y_{1:T}] \approx \frac{1}{N} \sum_{i=1}^{N} g(x^{(i)}). \tag{2.5.2}$$

Así, los métodos de Monte Carlo aproximan la distribución objetivo por un conjunto de muestras que están distribuidas acorde a la densidad objetivo.

2.5.2. Muestreo de Importancia

A menudo, en los modelos Bayesianos, no es posible obtener muestras directamente de $p(x|y_{1:T})$ debido a su complicada forma funcional. En esta sección se introduce una distribución de aproximación llamada *distribución de importancia* $\pi(x|y_{1:T})$, de la cual podemos fácilmente escoger muestras. La distribución de importancia está basada en la siguiente descomposición de la esperanza sobre la densidad de probabilidad posterior $p(x|y_{1:T})$:

$$\int g(x)p(x|y_{1:T})dx = \int \left[g(x)\frac{p(x|y_{1:T})}{\pi(x|y_{1:T})} \right] \pi(x|y_{1:T})dx, \tag{2.5.3}$$

donde el soporte de la densidad de importancia $\pi(x|y_{1:T})$ debe ser igual o más grande que el soporte de $p(x|y_{1:T})$. Como la expresión anterior no es más que la esperanza del término entre paréntesis sobre la distribución $\pi(x|y_{1:T})$, podemos realizar una aproximación Monte Carlo escogiendo N muestras desde la distribución de importancia:

$$x^{(i)} \sim \pi(x|y_{1:T}), \quad i = 1, \ldots, N,$$

y formando la aproximación como

$$\begin{aligned} \mathbb{E}[g(x)|y_{1:T}] &\approx \frac{1}{N} \sum_{i=1}^{N} \frac{p(x^{(i)}|y_{1:T})}{\pi(x^{(i)}|y_{1:T})} g(x^{(i)}) \\ &= \sum_{i=1}^{N} \tilde{w}^{(i)} g(x^{(i)}), \end{aligned}$$

donde los pesos son definidos como

$$\tilde{w}^{(i)} = \frac{1}{N} \frac{p(x^{(i)}|y_{1:T})}{\pi(x^{(i)}|y_{1:T})}.$$

Tomamos muestras de la distribución de importancia, que es una aproximación a la distribución objetivo. Como la distribución de las muestras no es exacta, se debe corregir la aproximación asociando un peso a cada una de las muestras. El inconveniente de este muestreo de importancia directo es que deberíamos poder evaluar $p(x^{(i)}|y_{1:T})$ para poder utilizarlo directamente. Recordemos que por teorema de Bayes, la evaluación de la densidad de probabilidad posterior se puede escribir como

$$p(x^{(i)}|y_{1:T}) = \frac{p(y_{1:T}|x^{(i)})p(x^{(i)})}{\int p(y_{1:T}|x)p(x)dx}.$$

La probabilidad $p(y_{1:T}|x^{(i)})p(x^{(i)})$ y los términos a priori sueles ser fáciles de calcular, pero a menudo la integral en el denominador, conocida como la constante de normalización, no puede ser calculada. Para solucionar este problema, se puede formar una aproximación por muestreo de importancia a la integral de la esperanza aproximando también la constante de normalización por muestreo de importancia. Para este propósito se puede descomponer la integral de la esperanza y formar la aproximación. La aproximación a la densidad de probabilidad posterior formada por el algoritmo anterior puede escribirse formalmente como

$$p(x|y_{1:T}) \approx \sum_{i=1}^{N} w^{(i)}\delta(x - x^{(i)}), \tag{2.5.4}$$

donde $\delta(\cdot)$ es la función delta de Dirac.

2.5.3. Muestreo Secuencial de Importancia

El algoritmo de muestreo secuencial de importancia (SIS, por sus siglas en inglés) es un método de Monte Carlo que forma las bases de la mayor parte de los filtros de Monte Carlo secuenciales. Puede ser usado para generar aproximaciones de muestreo de importancia a las distribuciones de filtrado de modelos espacio-estado de la forma:

$$x_k \sim p(x_k|x_{k-1}) \tag{2.5.5}$$

$$y_k \sim p(y_k|x_k) \tag{2.5.6}$$

donde $x_k \in \mathbb{R}^n$ corresponde al estado al tiempo k y $y_k \in \mathbb{R}^m$ son las medidas.

El algoritmo SIS usa un conjunto de partículas con peso $\{(w_k^{(i)}, x_k^{(i)}) : \ i = 1, \ldots, N\}$, esto es, muestras de la distribución de importancia y sus pesos para representar a la distribución de filtrado $p(x_k|y_{1:k})$ tal que a cada paso de tiempo k la aproximación de la esperanza de una función arbitraria $g(\cdot)$ pueda ser calculada como el promedio ponderado:

$$\mathbb{E}[g(x_k)|y_{1:k}] \approx \sum_{i=1}^{N} w_k^{(i)} g(x_k^{(i)}). \tag{2.5.7}$$

Equivalentemente, SIS se puede interpretar como una aproximación a la distribución de filtrado como

$$p(x_k|y_{1:k}) \approx \sum_{i=1}^{N} w_k^{(i)} \delta(x_k - x_k^{(i)}). \tag{2.5.8}$$

Para derivar el algoritmo, consideramos la distribución posterior completa de los estados $x_{0:k}$ dada las medidas $y_{1:k}$. Usando propiedades de Markov del modelo, se tiene la siguiente recursión para la distribución posterior.

$$\begin{aligned} p(x_{0:k}|y_{1:k}) &\propto p(y_k|x_{0:k}, y_{1:k-1}) p(x_{0:k}|y_{1:k-1}) \\ &= p(y_k|x_{0:k}) p(x_k|x_{0:k-1}, y_{1:k-1}) p(x_{0:k-1}|y_{1:k-1}) \\ &= p(y_k|x_k) p(x_k|x_{k-1}) p(x_{0:k-1}|y_{1:k-1}). \end{aligned} \tag{2.5.9}$$

Ahora se puede construir un método de muestreo de importancia, que extrae muestras de una distribución de importantia dada $x_{0:k}^{(i)} \sim \pi(x_{0:k}|y_{1:k})$ y calcular los pesos de importancia por:

$$w_k^{(i)} \propto \frac{p(y_k|x_k^{(i)}) p(x_k^{(i)}|x_{k-1}^{(i)}) p(x_{0:k-1}^{(i)}|y_{1:k-1})}{\pi(x_{0:k}^{(i)}|y_{1:k})} \tag{2.5.10}$$

Si se forma la distribución de importancia para los estados x_k recursivamente como sigue:

$$\pi(x_{0:k}|y_{1:k}) = \pi(x_k|x_{0:k-1}, y_{1:k}) \pi(x_{0:k-1}|y_{1:k-1}), \tag{2.5.11}$$

entonces la expresión para los pesos se puede escribir como

$$w_k^{(i)} \propto \frac{p(y_k|x_k^{(i)}) p(x_k^{(i)}|x_{k-1}^{(i)})}{\pi(x_k^{(i)}|x_{0:k-1}^{(i)}, y_{1:k})} \cdot \frac{p(x_{0:k-1}^{(i)}|y_{1:k-1})}{\pi(x_{0:k-1}^{(i)}|y_{1:k-1})} \tag{2.5.12}$$

Ahora, asumamos que se tienen las muestras $x_{0:k-1}^{(i)}$ de la distribución de importancia $\pi(x_{0:k-1}|y_{1:k-1})$ y se calcularon sus pesos correspondientes $w_{k-1}^{(i)}$. Ahora se pueden extraer muestras $x_{0:k}^{(i)}$ de la distribución de importancia $\pi(x_{0:k}|y_{1:k})$ escogiendo las nuevas muestras de estado para el paso k como $x_k^{(i)} \sim \pi(x_k|x_{0:k-1}^{(i)}, y_{1:k})$. Los pesos de importancia del paso previo son proporcionales al último término en la ecuación (2.5.12):

$$w_{k-1}^{(i)} \propto \frac{p(x_{0:k-1}^{(i)}|y_{1:k-1})}{\pi(x_{0:k-1}^{(i)}|y_{1:k-1})}, \tag{2.5.13}$$

así se tiene la siguiente recursión para los pesos

$$w_k^{(i)} \propto \frac{p(y_k|x_k^{(i)})p(x_k^{(i)}|x_{k-1}^{(i)})}{\pi(x_k^{(i)}|x_{0:k-1}^{(i)}, y_{1:k})} \cdot w_{k-1}^{(i)}. \tag{2.5.14}$$

Notar que es conveniente seleccionar que la distribución de importancia sea Markoviana en el sentido que

$$\pi(x_k|x_{0:k-1}, y_{1:k}) = \pi(x_k|x_{k-1}, y_{1:k}) \tag{2.5.15}$$

Con esta forma de la distribución no se necesita almacenar toda la historia $x_{1:k}^{(i)}$ en el algoritmo SIS, solo los estados actuales $x_k^{(i)}$.

2.5.4. Filtro de Estado

Considere el siguiente modelo espacio-estado dinámico de Markov para datos secuencialmente observados $\{y_t : t = 1, 2, ...\}$, donde el vector de estado a tiempo t es x_t y el vector de parámetros fijos es θ.

$$\begin{aligned} y_t &\sim p(y_t|x_t, \theta) \\ x_t &\sim p(x_t|x_{t-1}, \theta), \end{aligned} \tag{2.5.16}$$

donde $p(y_t|x_t, \theta)$ corresponde a densidad de la ecuación de observación y $p(x_t|x_{t-1}, \theta)$ define la ecuación de evolución Markoviana o densidad de la ecuación de transición de estado.

Los métodos secuenciales de Monte Carlo (SMC) apuntan a actualizar las aproximaciones muestrales a las secuencias de las distribuciones posteriores $p(x_t, \theta|D_t)$, donde $D_t = \{D_{t-1}, y_t\}$ se define como el *conjunto de información a tiempo t*. Así, a

tiempo t, la distribución a posteriori estará representada por una muestra discreta de puntos y pesos.
Ahora bien, cuando evoluciona el tiempo y se tiene una nueva observación y_{t+1}, se desea generar una muestra de la posterior actual

$$p(x_{t+1}, \theta|D_{t+1}) = p(x_{t+1}, \theta|D_t, y_{t+1}).$$

Los métodos más eficaces utilizan la ecuación de estado para generar valores muestrales del vector de estado actual x_{t+1} basados en valores muestrales pasados del estado x_t. Esto es fundamental para la utilidad y el rendimiento de los métodos de aproximación discreta, ya que la generación de nuevos conjuntos de estados a partir de lo que suele ser una densidad de transición de estados continua permite que las aproximaciones posteriores se muevan en el espacio de estados a medida que el estado evoluciona y se procesan nuevos datos (Doucet et al., 2013).

En cuanto al filtro para el estado del modelo, considere un modelo dinámico como en la ecuación (2.5.16) con parámetros θ variables o en el que se asumen conocidos, de esta manera se buscará netamente el filtrado del estado del sistema.

Sea el vector de estado a tiempo t $\{x_t^{(1)}, ..., x_t^{(N)}\}$ y sus pesos asociados $\{w_t^{(1)}, ...w_t^{(N)}\}$ que juntos forman una aproximación de Monte Carlo a la distribución posterior $p(x_t|D_t)$. Suponga que el tiempo evoluciona a $t+1$, se observa y_{t+1} y se desea generar una muestra de la posterior $p(x_{t+1}|D_{t+1})$. En términos de distribuciones,

$$\begin{aligned} p(x_{t+1}|D_{t+1}) &= p(x_{t+1}|D_t, y_{t+1}) \\ &= \frac{p(x_{t+1}, D_t, y_{t+1})}{p(D_t, y_{t+1})} \end{aligned}$$

Por un lado $p(x_{t+1}, D_t, y_{t+1}) = p(y_{t+1}|x_{t+1}, D_t)p(x_{t+1}|D_t)p(D_t)$ y dado que D_t es independiente al estado x_{t+1},

$$p(x_{t+1}, D_t, y_{t+1}) = p(y_{t+1}|x_{t+1})p(x_{t+1}|D_t)p(D_t).$$

Así,

$$\begin{aligned} p(x_{t+1}|D_{t+1}) &= \frac{p(y_{t+1}|x_{t+1})p(x_{t+1}|D_t)p(D_t)}{p(D_t, y_{t+1})} \\ &= \frac{p(y_{t+1}|x_{t+1})p(x_{t+1}|D_t)p(D_t)}{p(y_{t+1}|D_t)p(D_t)}. \end{aligned}$$

Por lo tanto,

$$p(x_{t+1}|D_{t+1}) \propto p(y_{t+1}|x_{t+1})p(x_{t+1}|D_t), \tag{2.5.17}$$

donde $p(y_{t+1}|x_{t+1})$ es la verosimilitud del sistema dinámico y $p(x_{t+1}|D_t)$ la densidad a priori del estado a tiempo $t+1$, la cual implícitamente se obtiene por la ecuación de estado:

$$p(x_{t+1}|D_t) = \int p(x_{t+1}|x_t)p(x_t|D_t)dx_t.$$

Bajo una aproximación de Monte Carlo a $p(x_t|D_t)$, la integral se puede abordar como una suma ponderada sobre los puntos de la muestra $x_t^{(k)}$, así, la ecuación (2.5.17) queda:

$$p(x_{t+1}|D_{t+1}) \propto p(y_{t+1}|x_{t+1}) \sum_{k=1}^{N} w_t^{(k)} p(x_{t+1}|x_t^{(k)}), \tag{2.5.18}$$

donde $x_t^{(1)}, ..., x_t^{(N)} \sim p(x_t|D_t)$. Para generar aproximaciones de Monte Carlo a la densidad $p(x_{t+1}|D_{t+1})$, West (1993a,b) desarrolló un método eficaz de muestreo de importancia adaptativo basado en el filtro de partículas auxiliar (Pitt and Shephard, 1999) para resolver este problema el cual propone lo siguiente:

1. Incorpora la función de verosimilitud $p(y_{t+1}|x_{t+1})$ a la suma de la ecuación (2.5.18) para obtener

   $$p(x_{t+1}|D_{t+1}) \propto \sum_{k=1}^{N} w_t^{(k)} p(x_{t+1}|x_t^{(k)}) p(y_{t+1}|x_{t+1})$$

   y genere muestras del estado actual como sigue:

2. Para cada $k = 1, ..., N$, considere una estimación $\mu_{t+1}^{(k)}$ de x_{t+1}, como la media, mediana o moda de $p(x_{t+1}|x_t^{(k)})$. Evalúe los pesos

   $$g_{t+1}^{(k)} \propto w_t^{(k)} p(y_{t+1}|\mu_{t+1}^{(k)}).$$

3. Luego, el índice j es muestreado con probabilidades proporcionales a $g_{t+1}^{(j)}$, y valores $x_{t+1}^{(j)}$ del estado actual son muestras de $p(x_{t+1}|x_t^{(j)})$ basadas en el este índice auxiliar. Estas muestras de estados son en esencia muestras de importancia del tiempo posterior $t+1$ y tiene pesos asociados

   $$w_{t+1}^{(j)} = \frac{p(y_{t+1}|x_{t+1}^{(j)})}{p(y_{t+1}|\mu_{t+1}^{(j)})}.$$

Las inferencias posteriores en tiempo $t+1$ se pueden basar directamente en estos valores y pesos muestreados o se puede realizar un re-muestreo en relación a los pesos de importancia $w_{t+1}^{(j)}$ para obtener un conjunto de datos igualmente ponderados que representarían una aproximación de Monte Carlo directa a la posteriori de interés en la ecuación (2.5.17) (Liu and West, 2001).

2.5.5. Filtro de Estados y Parámetros

El filtro de estado en la sección previa se puede extender a un marco más general donde se incluye la estimación de los parámetros θ. Suponga que a tiempo t se tiene la muestra combinada de estados y parámetros

$$\{x_t^{(j)}, \theta_t^{(j)} : j = 1, ..., N\}$$

y los pesos asociados

$$\{w_t^{(j)} : j = 1, ..., N\}$$

que representan una aproximación muestral de importancia al tiempo t posterior $p(x_t, \theta|D_t)$ tanto para el parámetro como para el estado. Ahora bien, el tiempo cambia a $t+1$, se observa y_{t+1} y se quiere generar una muestra de $p(x_{t+1}, \theta|D_{t+1})$. Por el Teorema de Bayes,

$$\begin{aligned} p(x_{t+1}, \theta|D_{t+1}) &= \frac{p(x_{t+1}, \theta, D_t, y_{t+1})}{p(D_t, y_{t+1})} \\ &= \frac{p(y_{t+1}|x_{t+1}, \theta, D_t)p(x_{t+1}|\theta, D_t)p(\theta|D_t)}{p(y_{t+1}|D_t)} \\ &\propto p(y_{t+1}|x_{t+1}, \theta)p(x_{t+1}|\theta)p(\theta|D_t), \end{aligned} \tag{2.5.19}$$

donde explícitamente queda en evidencia la necesidad de la densidad $p(\theta|D_t)$ para la actualización de la estimación.
Notar que si θ se considera conocido, la ecuación (2.5.19) se simplifica y obtiene la ecuación para el filtro de estado (2.5.18). Por otro lado, en el presente caso de interés donde se desea un filtro combinado sobre el estado y parámetros, se debe tratar con el problema de no conocer teóricamente la forma de la densidad $p(\theta|D_t)$.

En cuanto a la problemática de cómo abordar la densidad $p(\theta|D_t)$, a continuación se presentan dos principales enfoques, uno donde se plantea una evolución artificial de los parámetros y otra que suaviza la densidad a través de una función propuesta.

2.5.5.1. Evolución Artificial de Parámetros

Para abordar la variabilidad temporal en los estados, (N.J. Gordon, 1993) propone un enfoque para mitigar la degeneración o deterioro en la calidad de las muestras (partículas) mediante la adición de pequeñas perturbaciones aleatorias a las partículas de estado entre intervalos de tiempo. Una variante de esta idea sugiere incorporar pequeñas perturbaciones a todas las partículas asociadas a los parámetros θ bajo la densidad posterior en cada punto antes de avanzar al siguiente tiempo. Este método se interpreta como una derivación de un modelo extendido en el que los parámetros del modelo no son fijos en el tiempo, lo que amplía la metodología cuando los parámetros varían y se puede considerar como una evolución artificial cuando permanecen constantes.

En base a la idea anterior, la implementación según (Liu and West, 2001) considera que en el modelo dinámico (2.5.16) , el vector de parámetros fijo es variante en el tiempo por pequeñas perturbaciones de ruido blanco, es decir, θ pasa a ser $\theta(t) = \theta_t$ y ante la evolución en el tiempo se tiene lo siguiente:

$$\begin{aligned} \theta_{t+1} &= \theta_t + \xi_{t+1} \\ \xi_{t+1} &\sim N(0, W_{t+1}), \end{aligned}$$

con W_{t+1} es una matriz de varianza especificada y donde θ_t y ξ_{t+1} son condicionalmente independientes dado D_t.

2.5.5.2. Suavizado de Kernel

El método de suavizado de kernel (o Kernel Smoothing) propuesto por Lui and West (Liu and West, 2001) corresponde a una técnica la cual busca suavizar datos a través de una función llamada "kernel", mediante la asignación de pesos en base a la proximidad con el punto que se desea comparar.

La propuesta consiste en emplear una combinación de aproximaciones para generar nuevas muestras a partir de la distribución posterior actual. El objetivo es mitigar el fenómeno de decaimiento de las partículas, el cual ocurre cuando la variedad de muestras disminuye a medida que se avanza en el proceso de muestreo (Carvalho et al., 2010).

Considerando que nos encontramos en tiempo t, suponga que se tienen muestras actuales de parámetros posteriores $\theta_t^{(j)}$ y pesos $w_t^{(j)}, (j = 1, ..., N)$, con lo cual se puede formar una aproximación de Monte Carlo discreta a $p(\theta, D_t)$. Se define $\overline{\theta}_t$ y V_t como la media y matriz de varianza de la aproximación de Monte Carlo de la posterior $p(\theta|D_t)$, calculadas a partir de las muestras de Monte Carlo $\theta_t^{(j)}$ con pesos $w_t^{(j)}$.
El suavizado de kernel propuesto por (West, 1993b) es dado por:

$$p(\theta|D_t) \approx \sum_{j=1}^{N} w_t^{(j)} N(\theta|m_t^{(j)}, h^2 V_t), \tag{2.5.20}$$

donde $N(\cdot|m, S)$ es una densidad normal multivariante con media m y matriz de varianza S y $h > 0$ se define como el parámetro de suavizado. Por lo tanto, la densidad 2.5.20 es una mezcla de las normales multivariantes $N(\theta|m_t^{(j)}, h^2 V_t)$ ponderadas por los pesos muestreados $w_t^{(j)}$.

La ubicación del kernel $m_t^{(j)}$ se determina utilizando una regla de contracción introducida por (West, 1993a,b). Los métodos estándar sugieren que $m_t^{(j)} = \theta_t^{(j)}$, situando el kernel de la ecuación en valores de muestra existentes. Sin embargo, el resultado corresponde a una densidad kernel que está sobre dispersada en relación a la muestra posterior, debido a que la varianza resultante es $(1 + h^2)V_t > V_t$, lo cual genera un problema de sobre dispersión que se acumula en cada paso, aludiendo a la pérdida de información que se acumula en futuros tiempos. Para corregir esto, se introduce una idea de contracción de las ubicaciones del kernel donde se considera

$$m_t^{(j)} = a\theta_t^{(j)} + (1 - a)\overline{\theta}_t,$$

con $a = \sqrt{1 - h^2}$ (West, 1993a,b).
Utilizando estas ubicaciones del kernel, la media resultante de la mezcla de distribuciones normales se mantiene en $\overline{\theta}_t$ y la varianza se corrige al valor V_t, por lo tanto, la sobre dispersión se corrige (Doucet et al., 2013).

Capítulo 3

Estimación Online de Procesos Autorregresivos

En el presente capítulo, se aplicarán métodos secuenciales de Monte Carlo o Filtro de Partículas como estimación online a los Modelos Autorregresivos Regulares e Irregulares con el propósito de derivar un algoritmo que estime secuencialmente los parámetros de cada modelo.

3.1. Estimación Online para el Modelo Autorregresivo AR(1)

Considere el siguiente modelo autorregresivo de orden 1:

$$y_t = \phi y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim RB(0, \sigma^2). \tag{3.1.1}$$

Note que el modelo AR(1) representa un proceso de Markov, dado que y_t depende únicamente de su valor anterior y_{t-1} y no de la historia previa al tiempo $t-1$. En el presente modelo, es posible establecer la representación espacio-estado como sigue:

$$\begin{aligned} y_t &= x_t \\ x_t &= \phi x_{t-1} + \varepsilon_t \quad \varepsilon_t \sim RB(0, \sigma^2). \end{aligned} \tag{3.1.2}$$

Dada la forma del modelo AR(1), surge de manera natural considerar x_t como una distribución normal con media ϕx_{t-1} y varianza σ^2. En consecuencia, su

representación espacio-estado probabilística queda determinada por:

$$\begin{aligned} y_t &= x_t \\ x_t &\sim N(x_t|\phi x_{t-1}, \sigma^2). \end{aligned} \tag{3.1.3}$$

El vector de parámetros asociados al modelo dinámico del modelo AR(1) se define por $\theta = (\phi, \sigma^2)$.

Supongamos que a tiempo t se tiene una muestra de estados y parámetros $\{x_t^{(j)}, \theta^{(j)} : j = 1, ..., N\}$ y pesos asociados $\{w_t^{(j)} : j = 1, ..., N\}$ que juntos forman una aproximación de Monte Carlo a la distribución posterior a $p(x_t, \theta|D_t)$. Ante una evolución del tiempo a $t+1$, se observa y_{t+1} y se desea generar una muestra de la distribución posterior

$$p(x_{t+1}, \theta|D_{t+1}). \tag{3.1.4}$$

Note que la representación espacio-estado (3.1.3) considera todos los estados observados, por lo tanto, solo nos enfocamos en el filtrado de los parámetros θ para el modelo, en consecuencia, la densidad posterior de interés pasa a ser

$$p(\theta|D_{t+1}). \tag{3.1.5}$$

Considerando la evolución artificial de los parámetros y el suavizado de kernel propuesto por (Liu and West, 2001), se forma el siguiente algoritmo secuencial de Monte Carlo o Filtro de Partículas enfocado en la estimación de los parámetros del modelo AR(1).

1. Inicialización

   - Suponga que se tienen N partículas $\{\theta_0^{(j)}\}_{j=1}^N = \{(\phi_0^{(j)}, \sigma_0^{2(j)})\}_{j=1}^N$ que representan la distribución inicial de los parámetros del modelo. En este caso particular consideramos las siguientes distribuciones iniciales para los parámetros:

   $$\begin{aligned} \{\phi_0^{(j)}\}_{j=1}^N &\sim \mathbb{N}(m_0, P_0)\mathbb{1}_{(-1,1)} \\ \{\sigma_0^{2(j)}\}_{j=1}^N &\sim IG(a_0, b_0), \end{aligned}$$

   con m_0, P_0, a_0, b_0 conocidos.

2. Para cada $t \geq 1$:

   ❖ Estimaciones puntuales a priori

   - Para cada partícula $j = 1, ..., N$ identifica las estimaciones puntuales a priori del estado:

$$\mu_{t+1}^{(j)} = \mathbb{E}(x_{t+1}|x_t^{(j)}, \theta_t^{(j)}) = \widehat{\phi}_{t+1}^{(j)} x_t \tag{3.1.6}$$

     Note que por la definición del modelo dinámico y el enfoque en la estimación de parámetros, la estimación puntual del estado (3.1.6) pasa a ser una estimación puntual a priori de la observación:

$$\mu_{t+1}^{(j)} = \mathbb{E}(y_{t+1}|y_t^{(j)}, \theta_t^{(j)}) = \widehat{\phi}_{t+1}^{(j)} y_t$$

   - Realice las estimaciones puntuales del parámetro utilizando la contracción del kernel propuesta por (Liu and West, 2001):

$$m_t^{(j)}(\theta) = a\theta_t^{(j)} + (1-a)\overline{\theta_t^{(j)}}.$$

     donde $a = \sqrt{1-h^2}$ se define como el factor de descuento de la función kernel y $\overline{\theta_t^{(j)}} = \left(\overline{\hat{\phi}_t^{(j)}}, \overline{\hat{\sigma}_t^{2(j)}}\right)$ es el vector de medias de los parámetros del modelo.

   ❖ Muestrea una índice auxiliar k del conjunto $\{1, ..., N\}$ con probabilidad proporcional a

$$\begin{aligned} w_{t+1}^{(j)} &\propto p(y_{t+1}|\mu_{t+1}^{(j)}, m_t^{(j)}(\theta)) \\ &= p(y_{t+1}|\widehat{\phi}_{t+1}^{(j)} y_t, \widehat{\sigma}_t^{(j)}) \sim N(\widehat{\phi}_{t+1}^{(j)} y_t, \widehat{\sigma}_t^{(j)}). \end{aligned}$$

   ❖ Para cada partícula j realice un muestreo de una nueva estimación del vector de parámetros $\theta_{t+1}^{(j)} = \left(\widehat{\phi}_{t+1}^{(j)}, \widehat{\sigma^2}_{t+1}^{(j)}\right)$ a través del suavizado de kernel (West, 1993b), desde una distribución normal con media $m_t^{(k)}(\theta)$ y varianza $h^2 V_t$:

$$\begin{aligned} \theta_{t+1}^{(j)} &\sim N(\theta_{t+1}^{(j)}|m_t^{(k)}(\theta), h^2 V_t) \\ \Leftrightarrow \left(\widehat{\phi}_{t+1}^{(j)}, \widehat{\sigma^2}_{t+1}^{(j)}\right) &\sim N\left(\left(\widehat{\phi}_{t+1}^{(j)}, \widehat{\sigma^2}_{t+1}^{(j)}\right)|m_t^{(k)}(\theta), h^2 V_t\right), \end{aligned}$$

   donde V_t corresponde a la matriz de covarianza de los parámetros θ.

- ❖ Guarde los valores estimados para los parámetros y repita el proceso a lo largo del tiempo con el propósito de actualizar la estimación de los parámetros a medida que se observan nuevos datos y_t.

El algoritmo planteado genera en cada tiempo t un vector de largo N con la estimación de los parámetros, donde se espera que la varianza del vector disminuya a medida que pase el tiempo, puesto que aprenderá de las observaciones y estimaciones previas.

3.2. Estimación Online para el Modelo Autorregresivo Irregular

Consideremos el modelo autorregresivo irregular:

$$y_{t_j} = \phi^{t_j - t_{j-1}} y_{t_{j-1}} + \sigma\sqrt{1 - \phi^{2(t_j - t_{j-1})}}\varepsilon_{t_j},$$

donde y_{t_j} corresponde a la observación medida en el tiempo t_j, y se considera t_j como una secuencia de tiempos de observación estrictamente creciente para $j = 1, \ldots, n$, $\phi \in (0, 1)$ corresponde al parámetro de la función de autocorrelación (ACF), σ es la desviación estándar para todo y_{t_j} y $\varepsilon_{t_j} \overset{iid}{\sim} RB(0, 1)$.

En este caso, el vector de parámetros fijos queda definido únicamente por $\theta = \phi$. Luego siguiendo la idea del modelo AR(1), la representación espacio - estado en términos de probabilidades para el modelo IAR queda definida por:

$$\begin{aligned} y_{t_j} &= x_{t_j} \\ x_{t_j} &\sim N(x_{t_j} | \phi^{\Delta t_j} x_{t_{j-1}}, \sigma^2(1 - \phi^{2\Delta t_j})), \end{aligned} \tag{3.2.1}$$

donde $\Delta t_j = t_j - t_{j-1}$.

Siguiendo la idea planteada para el modelo AR(1), consideramos la evolución artificial de los parámetros y suavizado de kernel para formar el algoritmo secuencial de Filtro de Partículas enfocado en la estimación del parámetro ϕ del modelo IAR.

1. Inicialización

❖ Suponga que se tienen N partículas $\{\theta_0^{(j)}\}_{j=1}^N = \{(\phi_0^{(j)}\}_{j=1}^N$ que representan la distribución inicial del parámetro autorregresivo del modelo. En este caso particular consideramos la siguiente distribución inicial para el parámetro:

$$\{\phi_0^{(j)}\}_{j=1}^N \sim \mathbb{N}(m_0, P_0)\mathbb{1}_{(0,1)}$$

con m_0, P_0 conocidos.

2. Para cada $t \geq 1$:

❖ Estimaciones puntuales a priori

- Para cada partícula $j = 1, ..., N$ identifica las estimaciones puntuales a priori de la observación (por definición del modelo dinámico y enfoque del proceso):

$$\mu_{t+1}^{(j)} = \mathbb{E}(y_{t+1}|y_t^{(j)}, \theta_{t_j}^{(j)}) = (\widehat{\phi}_{t+1}^{(j)})^{\Delta_{t_j}} y_{t_j}$$

- Realice las estimaciones puntuales del parámetro utilizando la contracción del kernel propuesta por (Liu and West, 2001):

$$m_t^{(j)}(\theta) = a\theta_t^{(j)} + (1-a)\overline{\theta_t^{(j)}}.$$

donde $a = \sqrt{1-h^2}$ se define como el factor de descuento de la función kernel y $\overline{\theta_t^{(j)}} = \hat{\phi}_t^{(j)}$ es el la media del parámetro modelo.

❖ Muestrea una índice auxiliar k del conjunto $\{1, ..., N\}$ con probabilidad proporcional a

$$\begin{aligned} w_{t+1}^{(j)} &\propto p(y_{t+1}|\mu_{t+1}^{(j)}, m_t^{(j)}(\theta)) \\ &= p(y_{t+1}|(\widehat{\phi}_{t+1}^{(j)})^{\Delta_{t_j}} y_t, \tau_t^{(j)}) \sim N((\widehat{\phi}_{t+1}^{(j)})^{\Delta_{t_j}} y_t, \tau_t^{(j)}), \end{aligned}$$

donde $\tau_t^{(j)} = \sigma_y \sqrt{\left(1 - (\hat{\phi}_t^{(j)})^{2\Delta t_j}\right)}$.

❖ Para cada partícula j realice un muestreo de un nuevo vector de parámetros $\theta_{t+1}^{(j)} = \widehat{\phi}_{t+1}^{(j)}$ a través del suavizado de kernel (West, 1993b), desde una distribución normal con media $m_t^{(k)}$ y varianza $h^2 V_t$:

$$\begin{aligned} \theta_{t+1}^{(j)} &\sim N\left(\theta_{t+1}^{(j)}|m_t^{(k)}(\theta), h^2 V_t\right) \\ \Leftrightarrow \widehat{\phi}_{t+1}^{(j)} &\sim N\left(\widehat{\phi}_{t+1}^{(j)}|m_t^{(k)}(\theta), h^2 V_t\right), \end{aligned}$$

donde V_t corresponde a la varianza del parámetro.

- ❖ Guarde los valores estimados para los parámetros y repita el proceso a lo largo del tiempo con el propósito de actualizar la estimación de los parámetros a medida que se observan nuevos datos y_t.

El algoritmo planteado genera en cada tiempo t un vector de largo N con la estimación del parámetro, donde se espera que la varianza del vector disminuya a medida que pase el tiempo, puesto que aprenderá de las observaciones y estimaciones previas.

3.3. Implementación en Software R

En la presente sección, se presenta la implementación de los métodos mencionados, incluyendo una explicación detallada de los argumentos necesarios para su ejecución y las salidas de las funciones desarrolladas. La versión del software R utilizada es la 4.2.0. Por otro lado, el computador utilizado para la ejecución de simulaciones y estimaciones posee las siguientes características:

- Procesador AMD® Ryzen 5 3500U 2100 Mhz
- Memoria RAM: Interna 8 GB 2400 MT/s
- Almacenamiento: SSD Interna 256 GB
- S.O: Windows® 11 64 Bits.

3.3.1. Simulación de Datos

Para la simulación de series de tiempo regulares e irregulares, se utilizó el paquete nativo de R "iAR"(v 1.2.0 , Elorrieta F. (2022)), el cual posee datasets, funciones para generar tiempos de observación y datos simulados de series de tiempo irregularmente observadas.
Dentro de las funciones existentes en el paquete, las principalmente utilizadas fueron las siguientes:

- `gentime`. Función que genera tiempos irregularmente espaciados a partir de una distribución seleccionada. Por defecto, utiliza una mezcla de distribu-

ciones exponenciales. La salida de la función es un vector que contiene los tiempos generados.

```
gentime(n, distribution="expmixture",lambda1=130,
        lambda2=6.5, p1=0.15, p2=0.85, a=0,b=1)
```

Donde los argumentos son:

- `n`: Número de tiempos a generar, debe ser un número entero positivo.
- `distribution`: Distribución de la cual se derivan los tiempos simulados. La distribución por defecto es `"expmixture"` la cual corresponde a una mezcla de distribuciones exponenciales. Las distribuciones alternativas son `"uniform"` , `"exponential"` y `"gamma"`.
- `lambda1`: Media de la primera distribución exponencial en la mezcla de distribuciones exponenciales.
- `lambda2`: Media de la segunda distribución exponencial en la mezcla de distribuciones exponenciales.
- `p1`: Peso de la primera distribución exponencial en la mezcla de distribuciones exponenciales.
- `p2`: Peso de la segunda distribución exponencial en la mezcla de distribuciones exponenciales.
- `a`: Parámetro de forma de una distribución gamma o límite inferior de una distribución uniforme.
- `b`: Parámetro de escala de una distribución gamma o límite superior de una distribución uniforme.

- `IARsample`. Función que simula un modelo de series temporales IAR a partir de tiempos generados previamente. La salida es una lista con dos vectores: `series` que corresponde a los datos simulados IAR y `times` los tiempos de observación.

```
IARsample(phi, st, n=100)
```

Donde los argumentos son:

- `phi`: Coeficiente ϕ del modelo IAR a simular, debe ser un número entre 0 y 1.

- `st`: Vector con los tiempos de observación (son válidos tiempos regular e irregularmente espaciados).
- `n`: Largo de la serie de tiempo, debe ser un número positivo.

Además, se desarrolla la función `IARPhi_sample` que corresponde a un caso especial la función `IARsample` cuya modificación permite que el argumento `phi` sea un vector, lo cual permite generar una serie de tiempo con cambio constante de parámetro a través del tiempo.

```
IARPhi_sample(phi, st, n)
```

Donde los argumentos son:

- `phi`: Vector que contiene los valores de ϕ con cambio constante.
- `st`: Vector con los tiempos de observación (son válidos tiempos regular e irregularmente espaciados).
- `n`: Largo de la serie de tiempo, debe ser un número positivo.

3.3.2. Estimación Online Modelo AR (1)

La función para realizar la estimación online del modelo AR(1) está basada en el método de Filtro de Partículas y fundamentada en la sección 3.1.

- `AR.LW`. Corresponde a una función que estima el parámetro ϕ del modelo AR(1) basado en el algoritmo de Liu and West como un método de Filtro de Partículas. La salida de la función será una lista que contendrá la estimación en cada tiempo del parámetro ϕ del modelo, la desviación estándar el proceso y los valores de la series predichos con la estimación del parámetro.

  ```
  AR.LW(y, N, m0, a0, b0, a)
  ```

  Donde los argumentos son:

  - `y`: Vector con las observaciones de la serie de tiempo.
  - `N`: Número de partículas que se desea utilizar, debe ser un número entero positivo.

- `m0`: Media de la distribución con la que se generarán las partículas iniciales para el parámetro ϕ.
- `a0`: Parámetro de forma de la distribución gamma inversa con la que se generarán las partículas iniciales para el parámetro σ.
- `b0`: Parámetro de escala de la distribución gamma inversa con la que se generarán las partículas iniciales para el parámetro σ.
- `a`: Factor de descuento para la contracción del kernel que evita la pérdida de información a lo largo del algoritmo, debe ser un número entre 0 y 1. El valor por defecto es 0.98.

3.3.3. Estimación Batch Modelo IAR

Para realizar la estimación de un modelo IAR simulado, se utilizará la estimación por máxima verosimilitud del modelo, disponible en el paquete iAR.

- `IARloglik`. Función que estima el modelo IAR mediante el método de estimación máximo verosímil. La salida será una lista que contendrá el parámetro ϕ del modelo y el valor del logaritmo de la verosimilitud negativa evaluada en el ϕ estimado

  ```
  IARloglik(y, st, delta=0, zero.mean=TRUE, standarized=TRUE)
  ```

  Donde los argumentos son:

  - `y`: Vector con las observaciones de la serie de tiempo.
  - `times`: Vector que contiene los tiempos de observación (son válidos tiempos regular e irregularmente espaciados).
  - `delta`: Vector con las desviaciones estándar de las mediciones del error.
  - `zero.mean`: Argumento lógico; `TRUE` indica que el vector `y` posee media cero, `FALSE` indica si el vector posee media diferente a 0.
  - `standarized`: Argumento lógico; `TRUE` indica que el vector `y` está estandarizado, `FALSE` indica que el vector `y` contiene las series temporales brutas.

3.3.4. Estimación Online Modelo IAR

La función para realizar la estimación online del modelo IAR está basada en el método de Filtro de Partículas y fundamentada en la sección 3.2.

- `IAR.LW`. Corresponde a una función que estima el parámetro ϕ del modelo autorregresivo irregular IAR y la predicción de observaciones basado en el algoritmo de Liu and West como un método de Filtro de Partículas. La salida de la función será un matriz que contendrá el percentil 5, 50 y 95 (columnas) asociado a la estimación en cada tiempo del parámetro ϕ del modelo y los valores predichos de las observación obtenidos con la estimación del parámetro en el tiempo respectivo.

  ```
  IAR.LW(y,times,N,m0,P0,a=0.98)
  ```

  Donde los argumentos son:

  - `y`: Vector con las observaciones de la serie de tiempo.
  - `times`: Vector con los tiempos de observación (son válidos tiempos regular e irregularmente espaciados).
  - `N`: Número de partículas que se desea utilizar, debe ser un número entero positivo.
  - `m0`: Media de la distribución con la que se generarán las partículas iniciales para el parámetro ϕ.
  - `P0`: Desviación estándar de la distribución con la que se generarán las partículas iniciales para el parámetro ϕ.
  - `a`: Factor de descuento para la contracción del kernel que evita la pérdida de información a lo largo del algoritmo, debe ser un número entre 0 y 1. El valor por defecto es 0.98.

Capítulo 4

Simulaciones

En este capítulo se presentan los tiempos utilizados para la creación de las series de tiempo simuladas, así como los resultados obtenidos a partir de las diversas simulaciones y experimentos realizados para evaluar el desempeño de los modelos basados en filtro de partículas propuestos. Se detallan las métricas utilizadas para medir la precisión y robustez de las estimaciones a través el método online, así como los análisis comparativos con la estimación batch máximo verosímil en diferentes escenarios. Los resultados se organizan en secciones que corresponden a los diferentes escenarios de prueba y parámetros estudiados, proporcionando una visión clara y comprensiva del comportamiento del modelo bajo distintas condiciones. Además, se incluyen tablas, gráficos y descripciones detalladas que facilitan la interpretación de los hallazgos y su relevancia en el contexto del problema investigado. Finalmente, se exponen resultados de la estimación online basada en filtro de partículas en bases de datos reales; para el caso regular se aplicará la estimación online en la serie de tiempo *Nilo* que presenta información acerca del caudal del río Nilo bajo una represa en Asuán, Egipto. Para el caso irregular se estudiarán datos astronómicos asociados a curvas de luz con distintas clasificaciones.

Los algoritmos basados en filtro de partículas para la estimación de parámetros de los modelos autorregresivos regulares e irregulares propuestos en las secciones 3.1 y 3.2 respectivamente, generan en cada tiempo t un vector de largo N (cantidad de partículas) con la estimación del parámetro de interés. En base a lo anterior, para efectos de estudio *se considera el percentil 50 (mediana) del vector como la estimación del parámetro en cada instante* t.

4.1. Simulación de Tiempos

Con el propósito de estudiar distintos escenarios que podrían afectar a la estimación, se simulan 5 tiempos con los que se crearán las series de tiempo para el estudio, cada una de ellas con diferentes espaciados entre pares de observación. Uno de los 5 tiempos generados corresponde al escenario regular, donde el espaciado entre observaciones se mantiene constante, mientras que los restantes provienen de distribuciones de probabilidad Uniforme, Gamma y mezcla de Exponenciales expuestas en el Anexo 7.1 que permiten obtener diferencias de distintas magnitudes entre una observación y otra.
Para la creación de estos tiempos se utiliza la función `gentime` expuesta en la sección 3.3.1.

1. **Tiempo Regular:** Con el propósito de simular el tiempo regular, es necesario que el intervalo de tiempo entre cada observación sea constante y positivo. Por simplicidad, este intervalo se fijará en 1. La generación de este intervalo temporal resultará en una secuencia simple de valores que van desde 1 hasta la longitud deseada de la serie, con incrementos de una unidad.

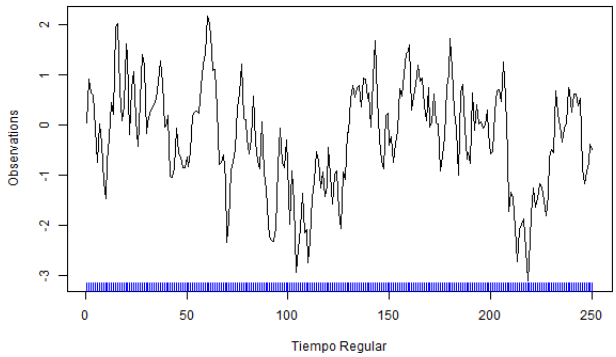


Figura 4.1: Proceso autorregresivo simulado utilizando tiempos regulares.

2. **Tiempo Uniforme(a=0, b=1):** Se produce una muestra aleatoria utilizando la distribución uniforme con los parámetros a=0 y b=1. Esto garantiza que la mínima diferencia posible a obtener sea el valor de a y la máxima diferencia sea el valor de b.

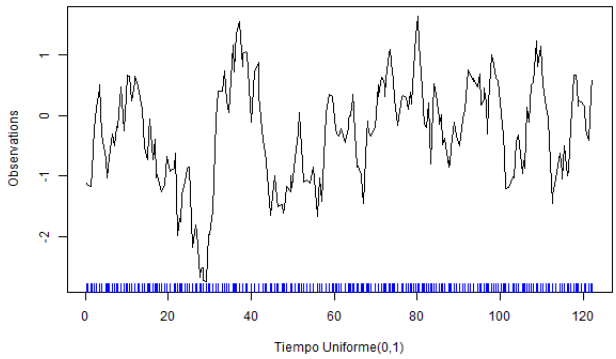


Figura 4.2: Proceso iAR simulado a partir de tiempos provenientes de una distribución uniforme de parámetros $a = 0$ y $b = 1$.

3. **Tiempo Gamma(α=3, λ=3):** Utilizando una distribución Gamma con parámetros de forma (α) y de escala (λ), ambos establecidos en 3, se genera una muestra aleatoria de tiempos. En este contexto, la diferencia entre los tiempos consecutivos puede variar entre 0 e infinito. Es importante resaltar que, debido a los parámetros mencionados, la esperanza de la distribución es igual a 1, lo que implica que las diferencias entre los tiempos serán en promedio cercanas a ese valor.

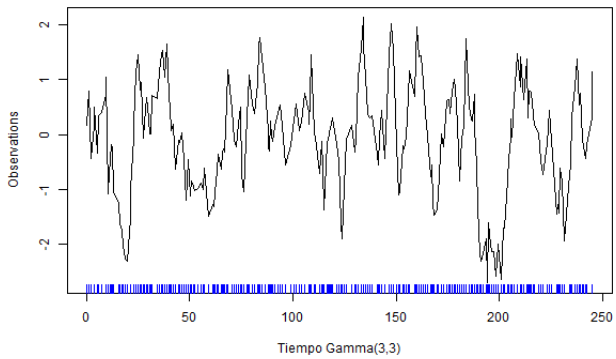


Figura 4.3: Proceso iAR simulado a partir de tiempos provenientes de una distribución gamma de parámetros $\alpha = 3$ y $\beta = 3$.

4. **Mezcla de Exponenciales($\lambda_1 = 130$, $\lambda_2 = 6.5$, p1 = 0.15, p2 = 0.85):** Se generan tiempos irregularmente espaciados utilizando una mezcla

de distribuciones exponenciales para su construcción. En este caso, los parámetros de las distribuciones exponenciales corresponden a $\lambda_1 = 130$ y $\lambda_2 = 6.5$, y los pesos asociados a cada distribución $p_1 = 0.15$, $p_2 = 0.85$. Los tiempos provenientes de una mezcla de exponenciales, tienden a tener grandes saltos entre una observación y otra, lo que para los casos de estudio resulta interesante y una posibilidad dentro de los casos reales.

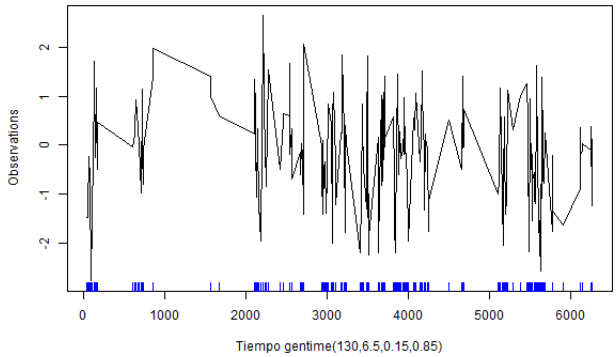


Figura 4.4: Proceso iAR simulado a partir de tiempos provenientes de una mezcla de distribuciones exponenciales de parámetros $\lambda_1 = 130$ y $\lambda_2 = 6.5$, con pesos asociados $p_1 = 0.15$ y $p_2 = 0.85$

5. **Mezcla de Exponenciales($\lambda_1 = 300$, $\lambda_2 = 10$, p1 = 0.1, p2 = 0.9):** Al igual que en el caso anterior, se generan tiempos irregularmente espaciados utilizando una mezcla de distribuciones exponenciales para su construcción. En este caso, los parámetros de las distribuciones exponenciales corresponden a $\lambda_1 = 300$ y $\lambda_2 = 10$, y los pesos asociados a cada distribución $p_1 = 0.1$, $p_2 = 0.9$. Con esta modificación en los parámetros es posible encontrar un espaciado mayor en los tiempos de observación, lo que generaría un escenario más agresivo.

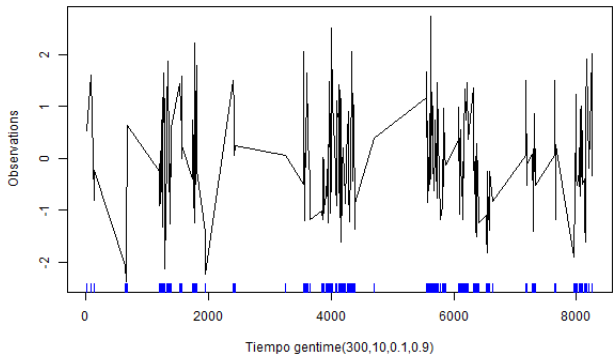


Figura 4.5: Proceso iAR simulado a partir de tiempos provenientes de una mezcla de distribuciones exponenciales de parámetros $\lambda_1 = 300$ y $\lambda_2 = 10$, con pesos asociados $p_1 = 0.1$ y $p_2 = 0.9$

4.2. Criterios de Evaluación

Con el propósito de evaluar la estimación que se tendrá para los modelos a estudiar, se establecen tanto métricas que nos permitirán obtener un valor numérico que mida la diferencia entre el valor predicho y las observaciones originales, como también métricas que midan la diferencia entre el parámetro original y estimado del modelo.

4.2.1. Mean Squared Errors

Mean Squared Error (MSE) o error cuadrático medio en español, es una métrica que se utiliza comúnmente para evaluar el desempeño de modelos matemáticos y estadísticos en la predicción o estimación de valores numéricos. El MSE es especialmente útil cuando se desea medir el grado de error o discrepancia entre los valores predichos por el modelo y los valores reales observados en un conjunto de datos. Su cálculo es el siguiente

$$MSE = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}, \tag{4.2.1}$$

donde y_i corresponde a la i-ésima observación, $\hat{y}_i$ corresponde a la i-ésima observación predicha y n corresponde al tamaño de la muestra.

4.2.2. Diferencia entre el parámetro real y estimado

Para comparar la diferencia que se produce en la estimación de un parámetro de un modelo y el parámetro real, se utilizará la el error absoluto medio (MAE):

$$MAE = Diff = \frac{\sum_{i=1}^{n} \left| \phi_i - \hat{\phi}_i \right|}{n}, \tag{4.2.2}$$

donde ϕ_i corresponde al i-ésimo parámetro real, $\hat{\phi}_i$ corresponde al i-ésimo parámetro estimado y n al tamaño de la muestra.

4.3. Modelo Autorregresivo Regular con Parámetro Fijo en el Tiempo

En primera instancia, se realiza un estudio del método online basado en filtro de partículas para la estimación de parámetros de distintos modelos autorregresivos regulares de orden 1 con el propósito de verificar la correcta estimación del algoritmo propuesto en escenarios con "menor complejidad" como antesala a la modificación realizada para el modelo irregular.
El experimento inicial consiste en llevar a cabo simulaciones de Monte Carlo enfocadas en la estimación del parámetro ϕ de un modelo autorregresivo de primer orden caracterizado por un parámetro constante a lo largo del tiempo. Dentro del marco de la estimación en línea, donde cada observación se examina de forma individual, a medida que llega la información, se prevé que en las primeras iteraciones las estimaciones no sean precisas debido a que estarán influenciadas por los valores iniciales aleatorios (partículas iniciales) de ϕ, sin embargo, conforme avancen las iteraciones se espera que esta estimación se aproxime progresivamente al valor original del parámetro ϕ.

A continuación se exponen gráficos y tablas con los resultados de 100 simulaciones de Monte Carlo (SMC), enfocadas en la estimación online del parámetro ϕ para

el modelo AR(1) con valores $\phi \in \{-0.9, -0.5, -0.3, 0.3, 0.5, 0.9\}$ y largo de serie $n = 500$. El método de estimación online basado en el filtro de partículas se ejecutó utilizando una cantidad de partículas $N = 1000$, el valor m_0 se inicializó como la estimación batch por máxima verosimilitud $\widehat{\phi}_{Batch}$ para cada modelo AR(1) simulado, $a_0 = b_0 = 1$ y $a = 0.98$.

Cabe destacar que el hiperparámetro m_0 corresponde a la media de la distribución con la que se generan las partículas iniciales del parámetro ϕ, por lo tanto, es válida su inicialización con cualquier número real. En esta ocasión particular, considera un conocimiento a priori de las series de tiempo a estudiar.

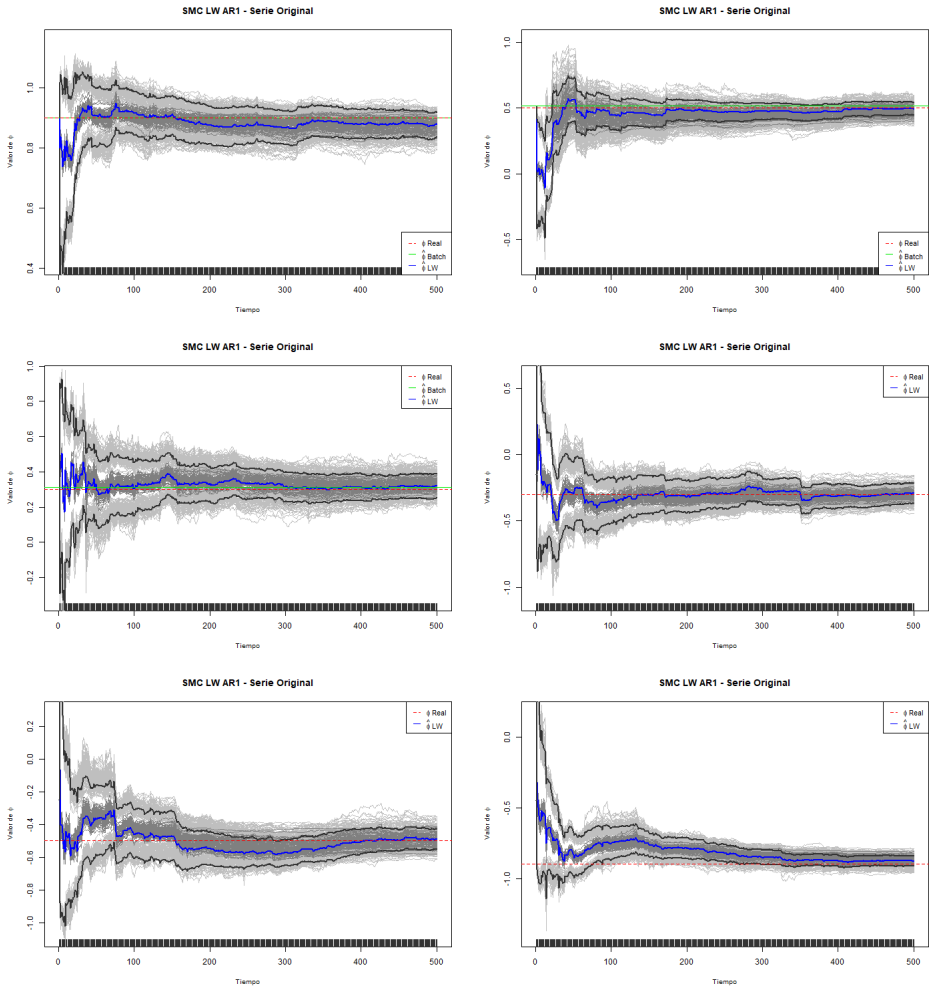


Figura 4.6: SMC para la estimación del parámetro ϕ de modelos AR(1) con valores de $\phi \in \{-0.9, -0.5, -0.3, 0.3, 0.5, 0.9\}$.

En los gráficos, se tiene el resultado de las 100 simulaciones de Monte Carlo para la estimación online a través del filtro de partícula. Las líneas grises más claras corresponden a los percentiles 5 y 95 de las iteraciones del filtro de partículas, mientras que las líneas grises más oscuras corresponden al percentil 50 de las iteraciones. Por otro lado líneas negras y azules más marcadas muestran el resultado de aplicar el filtro de partículas con una cantidad de partículas $N_p = 8000$. La línea roja corresponde al valor ϕ original y la línea verde presente en los casos con $\phi > 0$ es el resultado de la estimación Batch del parámetro.

Al analizar los gráficos para la estimación de los resultados, notamos que para las primeras iteraciones de la estimación, los percentiles 5, 50 y 95 se encuentran lejanos, indicando una gran variabilidad en el vector asociado a $\widehat{\phi}$. Lo anterior se explica debido a que las partículas de inicialización son aleatorias provenientes de una distribución (en este caso una distribución normal) y a medida que avanza el tiempo, el algoritmo estabiliza las estimaciones, reduciendo la variabilidad de la estimación final.

En lo siguiente se expone una tabla resumen con los resultados de las simulaciones de Monte Carlo para la estimación online (abreviado Onl en la tabla) del modelo AR(1) a través de filtro de partículas.

ϕ	$\widehat{\phi}$ Onl	SD $\widehat{\phi}$	MSE $\widehat{\phi}$	Diff $\widehat{\phi}$ Onl	$\widehat{\phi}_{250}$ Onl	Time Onl $[s]$
0.9	0.875	0.017	0.197	0.025	0.881	0.726
0.5	0.478	0.030	0.702	0.029	0.446	0.711
0.3	0.330	0.027	0.904	0.033	0.340	0.713
-0.3	-0.321	0.027	0.997	0.027	-0.378	0.777
-0.5	-0.420	0.028	0.623	0.080	-0.455	0.735
-0.9	-0.869	0.024	0.189	0.033	-0.822	0.709

Tabla 4.1: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo AR(1) bajo diferentes valores del parámetro ϕ.

Interpretando los resultados tabulados, se puede concluir que el método de estimación online a través de filtro de partículas logra con éxito la estimación del parámetro ϕ de las series evaluadas, ya que las estimaciones finales se asemejan

bastante al parámetro real de la serie de tiempo, de hecho, la diferencia entre el parámetro real y el estimado está en torno a valores entre 0.01 y 0.03, lo cual refleja una aproximación acertada. En cuanto al error cuadrático medio se observa que a medida que el valor del parámetro ϕ se acerca a 0, el MSE aumenta, lo cual se relaciona directamente al modelo autorregresivo, ya que las observaciones tienden a parecer un ruido blanco cuando el valor de ϕ tiende a 0. También se presenta el resultado de la estimación del parámetro a la mitad del proceso $\widehat{\phi}_{250}$, donde se puede ver que en ese tiempo se obtienen estimaciones aceptables del parámetro, lo cual da a entender que el método logra su objetivo final en pocas iteraciones, lo cual también se ve reflejado en los gráficos, ya que aproximadamente desde el tiempo 100 comienza a entregar estimaciones en el orden del parámetro.

Además, se realizó la estimación batch máxima verosímil para los modelos de prueba, de lo cual se tienen los siguientes resultados:

ϕ	-0.9	-0.5	-0.3	0.3	0.5	0.9
$\widehat{\phi}$ Online	-0.869	-0.420	-0.321	0.330	0.478	0.875
$\widehat{\phi}$ Batch	-0.885	-0.474	-0.282	0.312	0.519	0.899

Tabla 4.2: Estimaciones Batch y Online para el parámetro ϕ de modelos AR(1).

Del resultado previo, se observa que las estimaciones que se obtienen a través del método batch son más cercanas al valor real que las obtenidas por el método online, lo cual se debe a que se estudia una serie de tiempo que no presenta cambios en su comportamiento, el método más óptimo para su análisis es el batch.

4.4. Modelo Autorregresivo Irregular

En la presente sección se exponen los resultados obtenidos de las diversas simulaciones y pruebas realizadas en el estudio del algoritmo basado en filtro de partículas para la estimación del parámetro ϕ correspondiente al modelo autorregresivo irregularmente espaciado (IAR).

Para la realización de las simulaciones de los modelos, se generan distintas series de temporales $\{y_{t_1}, y_{t_2}, ..., y_{t_n}\}$ a partir de cada tiempo simulado presente en la Sección 4.1. Dentro de las pruebas realizadas se incluyen variaciones en la simulación de datos, estudiando tanto casos en los que el parámetro ϕ del modelo se mantiene constante como casos en los que dicho parámetro presenta cambios dentro de la misma serie temporal simulada, con el objetivo de evaluar la adaptabilidad, eficiencia y capacidad de predicción en escenarios desafiantes.

La implementación de este estudio se lleva a cabo principalmente en el software R, aunque también se presentan ciertos resultados obtenidos con Python para verificar la similitud de las estimaciones en ambos entornos. Para generar las simulaciones de las series de tiempo, se utiliza la función `IARsample(phi,st,n)` que pertenece al paquete "iAR". En los casos donde estudia un cambio constante en el parámetro del modelo se utilizará la función `IARPhi_sample(phi,n,st)` que corresponde a una modificación de la función anteriormente mencionada y permite ingresar un vector con cambios constantes en el parámetro como argumento para `phi`. Más detalles de las funciones a utilizar se encuentran presentes en la sección 3.3.1.

Debido al enfoque del filtro de partículas, el modelo planteado para la estimación online de parámetros asociados a modelos autorregresivos irregulares (sección 3.3.4) entrega estimaciones asociados al percentil 5, 50 y 95 de un vector de estimaciones del parámetro de tamaño N_p. *Para efectos de estudio, la presente sección será enfocada en los valores asociados al percentil 50 del vector de parámetros estimados.*

Con el objetivo de evaluar la estimación online a través del filtro de partículas propuesto, se realizan experimentos de Montecarlo (100 simulaciones) para los distintos casos de estudio; plasmando tablas con resultados promedios de los tiempos de cómputo, estimaciones del parámetro, diferencia del parámetro estimado con el parámetro real y cálculo del error cuadrático medio (MSE) sobre los valores predichos del modelo. Con el propósito de comparar los resultados que se obtienen al emplear metodologías batch y online, se realiza una estimación del parámetro del modelo autorregresivo irregular mediante el proceso batch que calcula el estimador máximo verosímil, el error cuadrático medio y la diferencia del parámetro real con el estimado a través de la función `IARloglik(y, st)` perteneciente al paquete

"iAR", donde `y` corresponde a la serie de tiempo y `st` a la secuencia de tiempos de las observaciones.

4.4.1. Modelo IAR con Parámetro Constante en el Tiempo

Como prueba inicial para el modelo IAR online se recurre al experimento "más simple", el cual consiste en simular un modelo autorregresivo irregular con el parámetro fijo a través del tiempo.
Bajo el contexto planteado, se espera que los resultados para la estimación online sean bastante cercanos a los valores provenientes de la estimación batch, dado que este último corresponde al modelo idóneo en el caso a prueba.

A continuación, se exponen gráficos y tablas con el resultado de las 100 simulaciones de Monte Carlo de 3 modelos autorregresivos irregulares generados a partir de distintos tiempos de observación. Un modelo se simuló con un parámetro $\phi = 0.9$, otro con parámetro $\phi = 0.5$ y por último se simula un modelo con parámetro $\phi = 0.3$.
En los gráficos se presenta la estimación online de las 100 SMC del parámetro basado en el filtro de partículas y la estimación batch máximo verosímil para la comparación gráfica de ambos métodos.
En las tablas con información, se muestra un resumen de los resultados de la SMC donde se incluirán valores del coeficiente estimado a través del filtro de partículas y máxima verosimilitud. Además, incluyen las métricas de MSE calculado a partir de las observaciones predichas por los modelos y Diff que corresponde a la diferencia del parámetro real con el parámetro estimado por ambos métodos a lo largo de la serie.

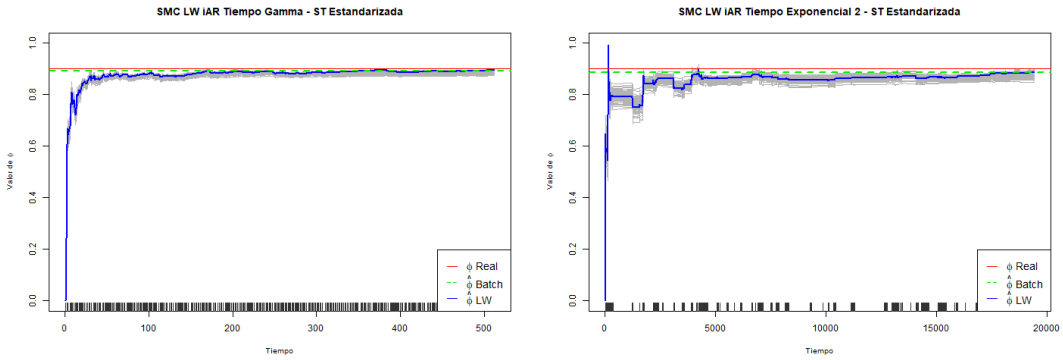
Los resultados de todos los experimentos realizados se encuentran en la sección 4.5.

4.4.1.1. Modelo IAR con Parámetro $\phi = 0.9$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares que cuentan con 500 observaciones y de parámetro fijo $\phi = 0.9$ a lo largo del tiempo; un modelo es generado a partir de un tiempo irregular que

sigue una distribución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales (M. Exp.) con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Para efectos del modelo online se asume que las observaciones se están actualizando constantemente en el tiempo, mientras que para el modelo batch se asume que la información está almacenada para su procesamiento completo.

A continuación, se presentan gráficos y tablas con los resultados obtenidos a partir de la simulación de Monte Carlo para el modelo IAR con un parámetro fijo $\phi = 0.9$.



(a) Tiempo Gamma (b) Tiempo Mezcla de Exponenciales

Figura 4.7: Estimación del parámetro para el modelo IAR con $\phi = 0.9$ constante y con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Los gráficos plasman los resultados de las 100 simulaciones de Monte Carlo para la estimación online a través del filtro de partículas. Las líneas grises corresponden a las estimaciones del valor $\phi = 0.9$ en cada iteración de la simulación con los parámetros de inicialización especificados, mientras que las líneas azules más marcadas muestran el resultado de aplicar el filtro de partículas con una cantidad de partículas $N_p = 8000$. La línea roja indica el valor ϕ original y por último la línea verde representa el valor estimado del parámetro a través del proceso batch máximo verosímil.

Seguidamente, en la tabla 4.3, se incluye un resumen de los resultados de la simulación de Monte Carlo de ambos modelos IAR respecto a la estimación del parámetro, su capacidad de predicción y la diferencia entre el parámetro real y el estimado a través del proceso.

Tabla 4.3: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con parámetro constante $\phi = 0.9$.

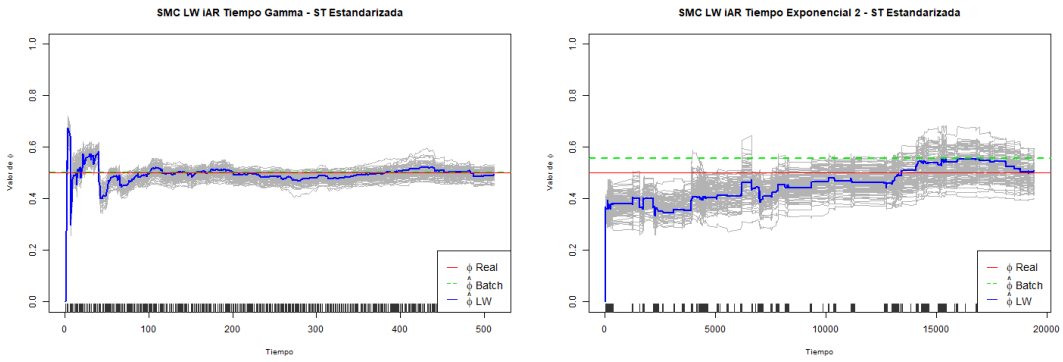
Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}_{250}$ **Onl**	$\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.888	0.005	0.012	0.204	0.893	0.878	0.893	0.225
M. Exp.	0.877	0.009	0.023	0.730	0.781	0.858	0.887	0.726

Gráficamente se aprecia que en los primeros tiempos de observación para el proceso de estimación online los valores estimados del parámetro $\widehat{\phi}$ se encuentran lejanos, lo cual se explica debido a que las partículas de inicialización del proceso son aleatorias y a medida que avanza el tiempo el algoritmo estabiliza las estimaciones, convergiendo al valor real del parámetro.
En la tabla de resultados se puede observar que el método de estimación online a través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.888$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.887$ para el modelo IAR con tiempo Mezcla de Exponenciales. La diferencia entre el parámetro real y el estimado, presentado en la métrica "Diff", las diferencias para ambos modelos son menores a 0.05 y son en su mayoría explicadas por las estimaciones en los primeros tiempos de observación, lo que representa una gran desempeño para la estimación del parámetro a lo largo del proceso.
Respecto a las predicciones que se entregan al emplear los dos métodos para la estimación (online y batch), ambos presentan valores para el MSE bastante similares, por un lado el método online presenta un valor para el MSE de 0.204 y 0.730 en los tiempos Gamma y M. Exp. respectivamente, mientras que los valores MSE para la estimación batch son de 0.225 para el tiempo Gamma y 0.726 para el tiempo M. Exp., de ello se desprende que en términos de predicción, los métodos presentan resultados muy similares.

4.4.1.2. Modelo IAR con Parámetro $\phi = 0.5$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares que cuentan con 500 observaciones y de parámetro fijo $\phi = 0.5$ a lo largo del tiempo; un modelo es generado a partir de un tiempo irregular que sigue una distribución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Para efectos del modelo online se asume que las observaciones se están actualizando a cada tiempo, mientras que para el modelo batch se asume que la información está almacenada para su procesamiento completo.

A continuación, se presentan gráficos y tablas con los resultados obtenidos a partir de la simulación de Monte Carlo para el modelo IAR con un parámetro fijo $\phi = 0.5$.



(a) Tiempo Gamma (b) Tiempo Exponencial

Figura 4.8: Estimación del parámetro para el modelo IAR con $\phi = 0.5$ constante y con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Seguidamente, en la tabla 4.4, se incluye un resumen de los resultados de la simulación de Monte Carlo de ambos modelos IAR respecto a la estimación del parámetro, su capacidad de predicción y la diferencia entre el parámetro real y el estimado a través del proceso.

Tabla 4.4: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con parámetro constante $\phi = 0.5$.

Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}_{250}$ **Onl**	$\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.493	0.016	0.014	0.665	0.923	0.484	0.500	0.667
M. Exp.	0.502	0.041	0.033	0.941	0.784	0.467	0.557	0.944

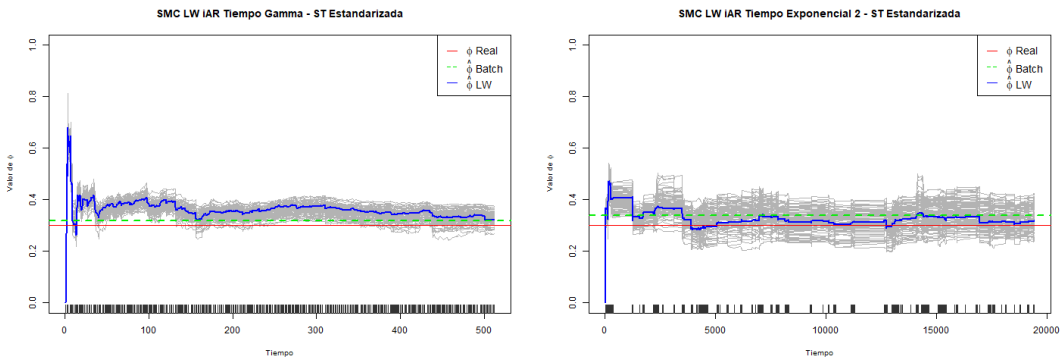
Al igual que en el caso anterior, gráficamente se aprecia que en los primeros tiempos de observación para el proceso de estimación online los valores estimados del parámetro $\widehat{\phi}$ se encuentran lejanos, lo cual se explica debido a que las partículas de inicialización del proceso son aleatorias y a medida que avanza el tiempo el algoritmo estabiliza las estimaciones, convergiendo al valor real del parámetro.
En la tabla de resultados se puede observar que el método de estimación online a través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.493$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.502$ para el modelo IAR con tiempo M. Exponenciales. En esta ocasión, tanto gráficamente como en la tabla, se aprecia que las simulaciones de Monte Carlo presentan una mayor desviación estándar en sus predicciones en comparación con el caso anterior ($\phi = 0.9$), lo cual a priori se puede explicar debido a que el valor de ϕ es menor y la componente de ruido del modelo IAR se hace más presente, sin embargo, las estimaciones siguen en línea con el parámetro real. Además, se evidencia que cuando el tiempo de simulación presenta mayor diferencia entre una observación y otra, como ocurre en el caso del tiempo derivado de una Mezcla de distribuciones Exponenciales, existe una mayor variabilidad en las estimaciones del parámetro.
La diferencia entre el parámetro real y el estimado, presentado en la métrica "Diff", las diferencias para ambos tiempos son menores a 0.05 y son en su mayoría explicadas por las estimaciones en los primeros tiempos de observación, lo que representa una gran desempeño para la estimación del parámetro a lo largo del proceso.
Respecto a las predicciones que se entregan al emplear los dos métodos para la estimación (online y batch), ambos presentan valores para el MSE bastante similares, por un lado el método online presenta un valor para el MSE de 0.665 y 0.941 en los tiempos Gamma y M. Exp. respectivamente, mientras que los valores MSE para la estimación batch son de 0.667 para el tiempo Gamma y 0.944 para el

tiempo M. Exp., de ello se desprende que en términos de predicción, los métodos presentan resultados muy similares.

4.4.1.3. Modelo IAR con Parámetro $\phi = 0.3$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares que cuentan con 500 observaciones y de parámetro fijo $\phi = 0.9$ a lo largo del tiempo; un modelo es generado a partir de un tiempo irregular que sigue una distribución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Para efectos del modelo online se asume que las observaciones se están actualizando a cada tiempo, mientras que para el modelo batch se asume que la información está almacenada para su procesamiento completo.

A continuación, se presentan gráficos y tablas con los resultados obtenidos a partir de la simulación de Monte Carlo para el modelo IAR con un parámetro fijo $\phi = 0.3$.



(a) Tiempo Gamma (b) Tiempo Exponencial

Figura 4.9: Estimación del parámetro para el modelo IAR con $\phi = 0.3$ constante y con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Seguidamente, en la tabla 4.5, se incluye un resumen de los resultados de la simulación de Monte Carlo de ambos modelos IAR respecto a la estimación del

parámetro, su capacidad de predicción y la diferencia entre el parámetro real y el estimado a través del proceso.

Tabla 4.5: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con parámetro constante $\phi = 0.3$.

Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}_{250}$ **Onl**	$\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.329	0.023	0.032	0.807	0.886	0.359	0.318	0.809
M. Exp.	0.334	0.041	0.043	0.964	0.806	0.321	0.338	0.965

Al igual que en el caso anterior, gráficamente se aprecia que en los primeros tiempos de observación para el proceso de estimación online los valores estimados del parámetro $\widehat{\phi}$ se encuentran lejanos, lo cual se explica debido a que las partículas de inicialización del proceso son aleatorias y a medida que avanza el tiempo el algoritmo estabiliza las estimaciones, convergiendo al valor real del parámetro.
En la tabla de resultados se puede observar que el método de estimación online a través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.329$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.334$ para el modelo IAR con tiempo M. Exponenciales. Al igual que en el caso anterior, tanto gráficamente como en la tabla, se aprecia que las simulaciones de Monte Carlo presentan una mayor desviación estándar en sus predicciones cuando se compara con el caso donde el parámetro real es $\phi = 0.9$, lo cual a priori se puede explicar debido a que el valor de ϕ es menor y la componente de ruido del modelo IAR se hace más presente, sin embargo, las estimaciones siguen en línea con el parámetro real. Además, también esperado del caso previo, se evidencia que cuando el tiempo de simulación presenta mayor diferencia entre una observación y otra, como ocurre en el caso del tiempo derivado de una Mezcla de distribuciones Exponenciales, existe una mayor variabilidad en las estimaciones del parámetro.
La diferencia entre el parámetro real y el estimado, presentado en la métrica "Diff", las diferencias para ambos tiempos son menores a 0.05 y son en su mayoría explicadas por las estimaciones en los primeros tiempos de observación, lo que representa una gran desempeño para la estimación del parámetro a lo largo del proceso.
Respecto a las predicciones que se entregan al emplear los dos métodos para

la estimación (online y batch), ambos presentan valores para el MSE bastante similares, por un lado el método online presenta un valor para el MSE de 0.807 y 0.964 en los tiempos Gamma y M. Exp. respectivamente, mientras que los valores MSE para la estimación batch son de 0.809 para el tiempo Gamma y 0.965 para el tiempo M. Exp., de ello se desprende que en términos de predicción, los métodos presentan resultados muy similares.

4.4.2. Modelo IAR con Cambio Abrupto en el Parámetro

En el modelo previo se asume un parámetro asociado al modelo constante, sin embargo, las series de tiempo pueden presentar cambios en su comportamiento asociado a diversos factores.
Con el propósito de abarcar posibles cambios estructurales que pudiesen presentar las series de tiempo y evaluar la adaptabilidad del modelo online propuesto ante estos cambios, el presente experimento consiste en generar modelos autorregresivos irregulares que tengan un cambio repentino en su parámetro. Por consiguiente, se generan modelos con 500 observaciones donde se mantendrá un parámetro ϕ_1 hasta la observación 250 y cambiará repentinamente a un valor ϕ_2 que se mantendrá por las 250 observaciones restantes. Con ello se pretende verificar que el método de estimación online sea capaz de detectar cambios en el comportamiento de la serie de mejor manera que el método batch.

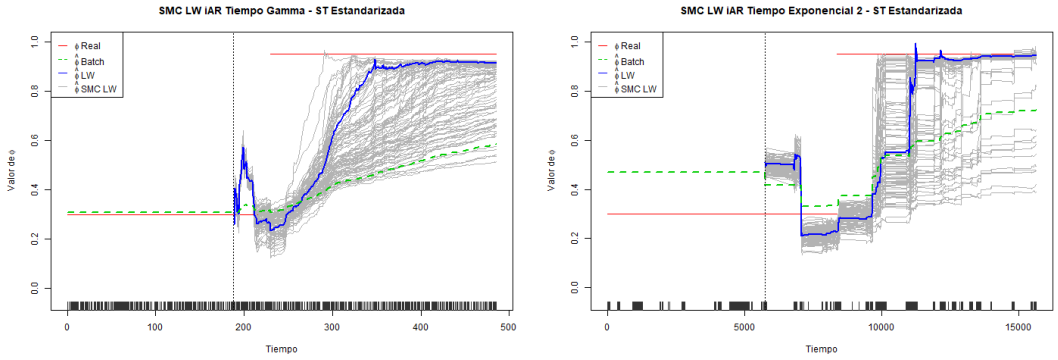
Al igual que en el caso de estudio anterior, se exponen gráficos y tablas con el resultado de las 100 simulaciones de Monte Carlo de 2 modelos autorregresivos irregulares generados a partir de distintos tiempos de observación. Un modelo se simuló con un parámetro inicial $\phi_1 = 0.3$, que cambia de manera repentina a un valor de $\phi_2 = 0.95$ y un segundo modelo se genera con un parámetro inicial $\phi_1 = 0.8$ y cambia súbitamente a un valor $\phi_2 = 0.3$.

En el presente experimento, de un total de 500 observaciones que tendrá el modelo IAR, se asume que las primeras 200 observaciones son conocidas y se encuentran almacenadas previamente, mientras que, las 300 restantes serán consideradas como información nueva que se actualiza constantemente.

En los gráficos se presenta la estimación online de las 100 SMC del parámetro basado en el filtro de partículas y la estimación batch máximo verosímil para la comparación gráfica de ambos métodos.
En las tablas con información, se muestra un resumen de los resultados de la SMC donde se incluirán valores del coeficiente estimado a través del filtro de partículas y máxima verosimilitud. Además, incluyen las métricas de MSE calculado a partir de las observaciones predichas por los modelos y Diff que corresponde a la diferencia del parámetro real con el parámetro estimado por ambos métodos a lo largo de la serie.

4.4.2.1. Modelo IAR Cambio Abrupto de Parámetro $\phi = 0.3$ a $\phi = 0.95$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares con cambio abrupto de parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$, donde un modelo es generado a partir de un tiempo irregular que sigue una distribución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Ambos modelos constan de 500 observaciones, de las cuales 200 están previamente almacenadas y 300 nuevas observaciones llegan, actualizando la información constantemente.



(a) Tiempo Gamma (b) Tiempo Exponencial

Figura 4.10: Estimación del parámetro para el modelo IAR con $\phi = 0.3$ constante y con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Tabla 4.6: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con cambio abrputo en el parámetro $\phi_1 = 0.3$ a $\phi_2 = 0.95$.

Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.829	0.113	0.278	0.326	0.470	0.519	0.459	0.367
M. Exp.	0.900	0.130	0.252	0.764	0.474	0.721	0.323	0.813

Como era de esperar, debido a la naturaleza del filtro de partículas, gráficamente se aprecia que en los primeros tiempos de iteración del método online, los valores estimados del parámetro $\widehat{\phi}$ se encuentran en la etapa de "aprendizaje" convergiendo progresivamente a los valores reales que se desean estimar.
En la tabla de resultados se puede observar que el método de estimación online a través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.829$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.9$ para el modelo IAR con tiempo M. Exponenciales.
Por otro lado, tanto en la gráfica como en la tabla de resultados, se aprecia que las simulaciones de Monte Carlo presentan una mayor variabilidad en las estimaciones del parámetro cuando se compara con el escenario donde el parámetro se mantuvo constante, entregando desviaciones estándar del orden de 0.1 en ambos tiempos, lo cual se debe a la mayor complejidad del escenario propuesto. Sin embargo, al analizar las diferencias entre el parámetro real y el estimado, presentados en la métrica "Diff" y los errores de predicción MSE asociados a ambos métodos utilizados para la estimación, se puede apreciar que se tienen mejores resultados en el proceso online basado en el filtro de partículas que en el método batch, evidenciando que el filtro de partículas logra percibir el cambio en el parámetro, se adapta de mejor forma al caso propuesto y realiza un mejor desempeño tanto en la estimación del parámetro como en la predicción de las observaciones.

Debido a la dispersión que se aprecia en los gráficos de la figura 4.10, se realiza un estudio complementario que consiste en un experimento de 50 simulaciones de Monte Carlo para la estimación online basada en el filtro de partículas. Este experimento utilizó una cantidad de partículas $N_p = 5000$ en el modelo IAR con cambio abrupto de parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$, con tiempo generado a partir de una mezcla de distribuciones Exponenciales (con parámetros previamente establecidos). A priori, se prevé que el presente caso, dada la mayor cantidad de

partículas a utilizar, aumente el tiempo de cómputo del método, pero se espera que disminuya la dispersión en las estimaciones.

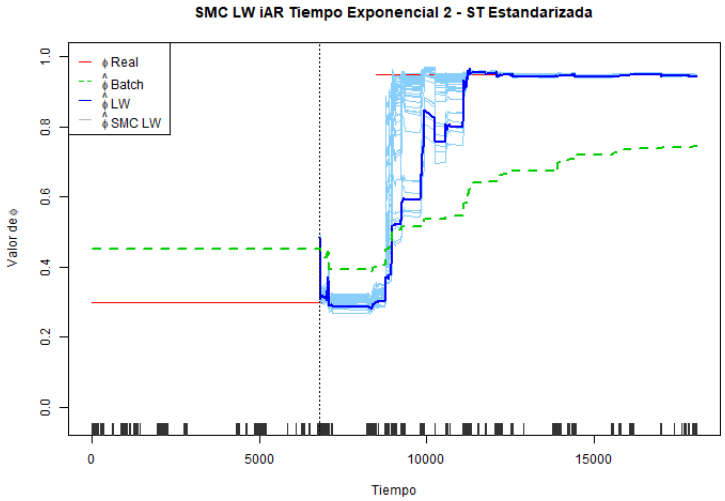


Figura 4.11: Estimación del parámetro utilizando una cantidad de partículas $N_p = 5000$ en el método online para el modelo IAR con cambio abrupto en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$ y con tiempos que siguen una mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

El gráfico presenta los resultados de las 50 simulaciones de Monte Carlo para la estimación online a través del filtro de partículas. Las líneas celestes corresponden a las estimaciones del valor ϕ en cada iteración de la simulación, mientras que la línea azul más marcadas es el resultado de aplicar el filtro de partículas con una cantidad de partículas $N_p = 8000$. La línea roja indica el valor ϕ original y por último la línea verde representa el valor estimado del parámetro a través del proceso batch máximo verosímil de manera iterativa.

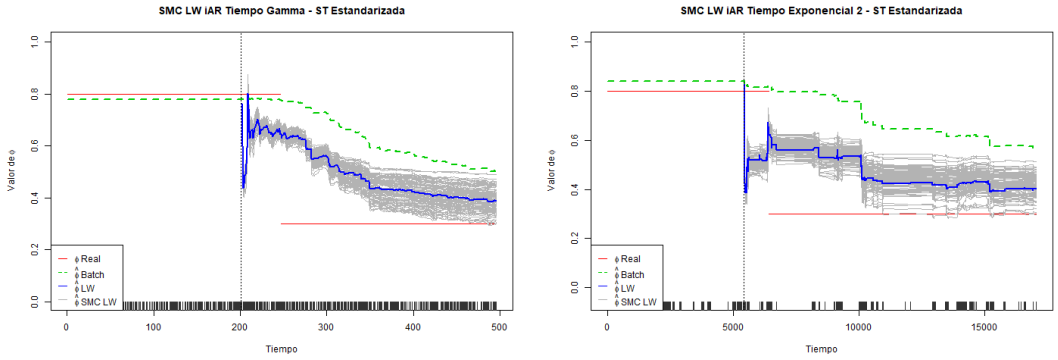
Tabla 4.7: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con cambio abrputo en el parámetro $\phi_1 = 0.8$ a $\phi_2 = 0.3$ utilizando una cantidad de partículas $N_p = 5000$.

Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Batch**
M. Exp.	0.946	0.002	0.063	0.702	0.938	0.763	0.270	0.780

Como se ha inferido previamente, el tiempo de cómputo incrementa desde 0.474 a 0.938 y se reduce de manera gráfica el ruido en las simulaciones, donde dicho fenómeno se refleja en la desviación estándar para las estimaciones del parámetro ϕ, con un valor en el orden de 0.002. En relación a la estimación del parámetro ϕ y su error asociado a las predicciones también se mejoraron los resultados, llegando a valores de $\widehat{\phi} = 0.946$ y MSE $= 0.702$.
En conclusión, al aumentar la cantidad de partículas a utilizar en el modelo online, podemos esperar tanto un aumento en el tiempo de cómputo del proceso, como una mejora en el desempeño del mismo, reflejado en las métricas de estudio.

4.4.2.2. Modelo IAR Cambio Abrupto de Parámetro $\phi = 0.8$ a $\phi = 0.3$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares con cambio abrupto de parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.3$, donde un modelo es generado a partir de un tiempo irregular que sigue una distribución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Ambos modelos constan de 500 observaciones, de las cuales 200 están previamente almacenadas y 300 nuevas observaciones llegan, actualizando la información constantemente.



(a) Tiempo Gamma (b) Tiempo Exponencial

Figura 4.12: Estimación del parámetro para el modelo IAR con cambio abrupto de parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.3$ con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Tabla 4.8: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con cambio abrputo en el parámetro $\phi_1 = 0.8$ a $\phi_2 = 0.3$.

Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.390	0.045	0.168	0.808	0.499	0.474	0.252	0.821
M. Exp.	0.417	0.042	0.188	0.881	0.434	0.579	0.317	0.895

Al igual que en caso previo, debido a la naturaleza del filtro de partículas, gráficamente se aprecia que en los primeros tiempos de iteración del método online, los valores estimados del parámetro $\widehat{\phi}$ se encuentran en la etapa de "aprendizaje" convergiendo progresivamente a los valores reales que se desean estimar.
En la tabla de resultados se puede observar que el método de estimación online a través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.39$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.417$ para el modelo IAR con tiempo M. Exponenciales.
Por otro lado, tanto en la gráfica como en la tabla de resultados, se aprecia que las simulaciones de Monte Carlo presentan una mayor variabilidad en las estimaciones del parámetro cuando se compara con el escenario donde el parámetro se mantuvo constante, pero menor que en el caso donde el cambio abrupto era hacia un valor mayor, entregando desviaciones estándar SD $\widehat{\phi}$ del orden de 0.45 en ambos tiempos, lo cual se debe a la mayor complejidad del escenario propuesto.
Al analizar las diferencias entre el parámetro real y el estimado, presentados en la métrica "Diff" y los errores de predicción MSE asociados a ambos métodos utilizados para la estimación, se puede apreciar que se tienen mejores resultados en el proceso online basado en el filtro de partículas que en el método batch, evidenciando que el filtro de partículas se adapta de mejor forma al caso propuesto y logra un mejor desempeño tanto en la estimación del parámetro como en la predicción de las observaciones.

4.4.3. Modelo IAR con Cambio Constante en el Parámetro

Con el propósito de abarcar posibles cambios estructurales que pudiesen presentar las series de tiempo y evaluar la adaptabilidad del modelo online propuesto ante estos cambios, el presente experimento consiste en el estudio del filtro de partículas en modelos autorregresivos irregulares que presenten un cambio constante en su

parámetro, es decir, se considera un modelo que tendrá inicialmente un parámetro ϕ_1 que aumenta o disminuye constantemente hasta llegar a un parámetro final ϕ_2. Por consiguiente, se generan modelos con 500 observaciones donde su parámetro inicial será un valor ϕ_1 y cambiará constantemente a un valor ϕ_2. Con ello se pretende verificar que el método de estimación online sea capaz de detectar cambios constantes en el comportamiento de la serie de mejor manera que el método batch.

Al igual que en el caso de estudio anterior, se exponen gráficos y tablas con el resultado de las 100 simulaciones de Monte Carlo de 2 modelos autorregresivos irregulares generados a partir de distintos tiempos de observación. Un modelo se simuló con un parámetro inicial $\phi_1 = 0.3$, que cambia de manera constante a un valor de $\phi_2 = 0.95$ y un segundo modelo se genera a partir de un parámetro inicial $\phi_1 = 0.8$ que cambia continuamente a un valor $\phi_2 = 0.3$.

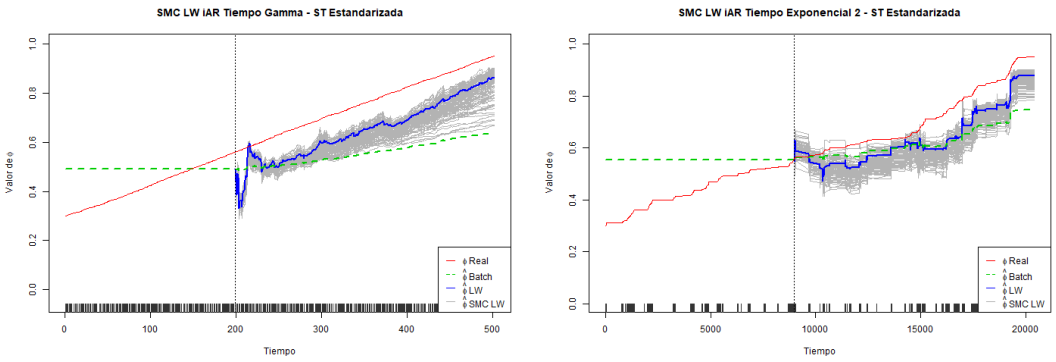
En el presente experimento, de un total de 500 observaciones que tendrá el modelo IAR, se asume que las primeras 200 observaciones son conocidas y se encuentran almacenadas previamente, mientras que, las 300 restantes serán consideradas como información nueva que se actualiza continuamente.

En los gráficos se presenta la estimación online de las 100 SMC del parámetro basado en el filtro de partículas y la estimación batch máximo verosímil para la comparación gráfica de ambos métodos.
En las tablas con información, se muestra un resumen de los resultados de la SMC donde se incluirán valores del coeficiente estimado a través del filtro de partículas y máxima verosimilitud. Además, incluyen las métricas de MSE calculado a partir de las observaciones predichas por los modelos y Diff que corresponde a la diferencia del parámetro real con el parámetro estimado por ambos métodos a lo largo de la serie.

4.4.3.1. Modelo IAR Cambio Constante de Parámetro $\phi_1 = 0.3$ a $\phi_2 = 0.95$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares con cambio constante en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$, donde un modelo es generado a partir de un tiempo irregular que sigue una distri-

bución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Ambos modelos constan de 500 observaciones, de las cuales 200 están previamente almacenadas y 300 nuevas observaciones llegan, actualizando la información constantemente



(a) Tiempo Gamma (b) Tiempo Exponencial

Figura 4.13: Estimación del parámetro para el modelo IAR con cambio constante de parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$ con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Tabla 4.9: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con cambio constante en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$.

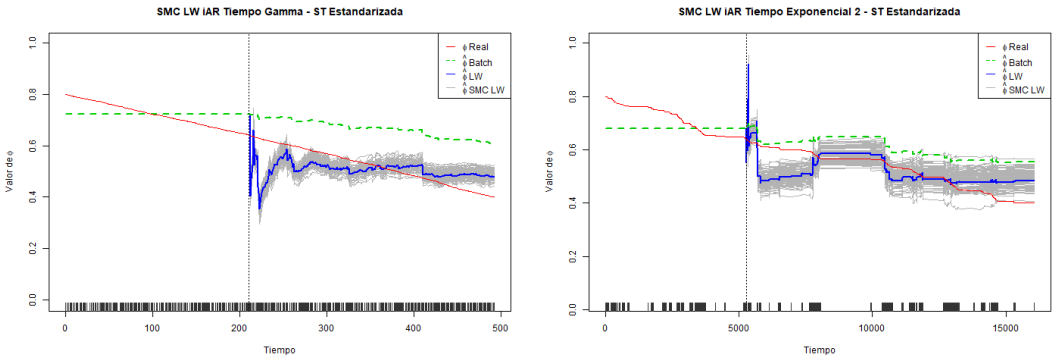
Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.836	0.058	0.131	0.422	0.398	0.637	0.200	0.431
M. Exp.	0.860	0.024	0.108	0.823	0.405	0.747	0.114	0.851

Gráficamente se aprecia ambos métodos de estimación logran detectar el cambio constante que el parámetro del modelo presenta, sin embargo, se observa que el método online basado en el filtro de partículas se desempeña ligeramente mejor que el método batch.
En la tabla de resultados se puede observar que el método de estimación online a

través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.836$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.86$ para el modelo IAR con tiempo M. Exponenciales, mientras que los valores estimados del parámetro en la última observación utilizando el método batch son de 0.637 para el modelo IAR con tiempo Gamma y 0.747 para el modelo IAR con tiempo M. Exponenciales, ratificando lo que gráficamente se puede interpretar.
Por otro lado, tanto en la gráfica como en la tabla de resultados, se aprecia que las simulaciones de Monte Carlo presentan una menor variabilidad en las estimaciones del parámetro cuando se compara con el escenario donde el parámetro presenta un cambio abrupto, entregando desviaciones estándar del orden de 0.05 para el tiempo Gamma y 0.02 para el tiempo M. Exponenciales, lo cual se debe a que el presente escenario es de "menor" complejidad en comparación al caso donde ocurre un cambio abrupto en el parámetro.
Al analizar las diferencias entre el parámetro real y el estimado, presentados en la métrica "Diff" y los errores de predicción MSE asociados a ambos métodos utilizados para la estimación, se puede apreciar que se tienen mejores resultados en el método online basado en el filtro de partículas que en el método batch, evidenciando que el filtro de partículas logra percibir el cambio constante en el parámetro, se adapta de mejor forma al caso propuesto y realiza un mejor desempeño tanto en la estimación del parámetro como en la predicción de las observaciones que el método batch.

4.4.3.2. Modelo IAR Cambio Constante de Parámetro $\phi_1 = 0.8$ a $\phi_2 = 0.4$

Los modelos que se presentan a continuación corresponden a modelos autorregresivos irregulares con cambio constante en el parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.4$, donde un modelo es generado a partir de un tiempo irregular que sigue una distribución Gamma(3,3) y el otro es generado a partir de una mezcla de distribuciones Exponenciales con $\lambda_1 = 300$ y $\lambda_2 = 10$ con pesos $p_1 = 0.1$ y $p_2 = 0.9$ asociados a cada distribución.
Ambos modelos constan de 500 observaciones, de las cuales 200 están previamente almacenadas y 300 nuevas observaciones llegan, actualizando la información constantemente



(a) Tiempo Gamma (b) Tiempo Exponencial

Figura 4.14: Estimación del parámetro para el modelo IAR con cambio constante de parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.4$ con tiempos que siguen una distribución Gamma(3,3) y mezcla de distribuciones Exponenciales con $\lambda_1 = 300, \lambda_2 = 10, p_1 = 0.1$ y $p_2 = 0.9$.

Tabla 4.10: Resultados medios para la estimación del parámetro, MSE, diferencia con el parámetro real y tiempo de cómputo para la prueba del modelo IAR con cambio constante en el parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.4$.

Tiempo	$\widehat{\phi}$ **Onl**	**SD** $\widehat{\phi}$	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**Time Onl** $[s]$	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Batch**
Gamma	0.484	0.016	0.056	0.591	0.393	0.608	0.145	0.607
M. Exp.	0.493	0.029	0.049	1.008	0.394	0.556	0.080	1.0125

Similar al caso previo, gráficamente se aprecia ambos métodos de estimación logran detectar el cambio constante que el parámetro del modelo presenta, sin embargo, se observa que el método online basado en el filtro de partículas se desempeña ligeramente mejor que el método batch.

En la tabla de resultados se puede observar que el método de estimación online a través del filtro de partículas presenta una estimación del parámetro en la última observación del orden de $\widehat{\phi} = 0.484$ para el modelo IAR con tiempo Gamma y $\widehat{\phi} = 0.493$ para el modelo IAR con tiempo M. Exponenciales, mientras que los valores estimados del parámetro en la última observación utilizando el método batch son de 0.608 para el modelo IAR con tiempo Gamma y 0.556 para el modelo IAR con tiempo M. Exponenciales, ratificando lo que gráficamente se puede interpretar.

Al analizar las diferencias entre el parámetro real y el estimado, presentados en la métrica "Diff" y los errores de predicción MSE asociados a ambos métodos utilizados para la estimación, se puede apreciar que se tienen mejores resultados en el método online basado en el filtro de partículas que en el método batch, evidenciando que el filtro de partículas logra percibir el cambio constante en el parámetro, se adapta de mejor forma al caso propuesto y realiza un mejor desempeño tanto en la estimación del parámetro como en la predicción de las observaciones que el método batch.

4.5. Resultados Generales

En este sección, Generalesse presentan los resultados generales de las distintas pruebas realizadas para los métodos de estimación online basada en el filtro de partículas y batch. Se adjuntan tablas resumen con los resultados provenientes de los experimentos de Monte Carlo de cada uno de los modelos AR e IAR simulados. Se incluyen medidas del error cuadrático medio (MSE) y diferencias del parámetro real estimado (Diff) a lo largo de la serie para comparar las predicciones y estimaciones de los métodos online a través del filtro de partículas y batch máximo verosímil. Posteriormente se mencionan los hallazgos más relevantes que se desprenden de cada caso estudiado, lo cual será de gran importancia para las conclusiones del problema de investigación.

4.5.1. Modelos con Parámetro Fijo

Para los casos en los que se tiene un modelo autorregresivo regular e irregular con un parámetro constante a través de la serie de tiempo, se presenta una tabla con los coeficientes del modelo estimado a partir de los métodos online y batch, junto con las medidas de MSE y Diff para comparar ambos desempeños.

Tabla 4.11: Resultados generales de distintos modelos autorregresivos con parámetro fijo $\phi = 0.9$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.885	0.890	0.015	0.010	0.209	0.210	0.565
Unif(0,1)	0.894	0.897	0.006	0.003	0.100	0.118	0.740
Gamma(3,3)	0.888	0.893	0.012	0.007	0.204	0.225	0.893
M.Exp.(130,6.5,0.15,0.85)	0.872	0.878	0.028	0.022	0.692	0.684	0.745
M.Exp.(300,10,0.1,0.9)	0.877	0.887	0.023	0.013	0.730	0.726	0.781

Tabla 4.12: Resultados generales de distintos modelos autorregresivos con parámetro fijo $\phi = 0.5$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.459	0.477	0.042	0.023	0.771	0.773	0.559
Unif(0,1)	0.450	0.454	0.050	0.046	0.520	0.523	0.712
Gamma(3,3)	0.493	0.500	0.014	0.000	0.665	0.667	0.923
M.Exp.(130,6.5,0.15,0.85)	0.418	0.461	0.082	0.039	0.915	0.916	0.766
M.Exp.(300,10,0.1,0.9)	0.502	0.557	0.033	0.057	0.941	0.944	0.784

Tabla 4.13: Resultados generales de distintos modelos autorregresivos con parámetro fijo $\phi = 0.3$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ Onl	$\widehat{\phi}$ Batch	Diff $\widehat{\phi}$ Onl	Diff $\widehat{\phi}$ Batch	MSE Onl	MSE Batch	Time Onl $[s]$
Regular	0.289	0.302	0.022	0.002	0.904	0.908	0.555
Unif(0,1)	0.347	0.349	0.047	0.049	0.583	0.588	0.710
Gamma(3,3)	0.329	0.318	0.032	0.018	0.807	0.809	0.886
M.Exp.(130,6.5,0.15,0.85)	0.424	0.423	0.124	0.123	0.910	0.913	0.933
M.Exp.(300,10,0.1,0.9)	0.334	0.338	0.043	0.038	0.964	0.965	0.806

A partir de los resultados de la prueba de parámetro constante bajo el contexto online, las conclusiones más importantes son las siguiente:

- ➢ El método de estimación batch máximo verosímil es más preciso en comparación a la estimación online a través de filtro de partículas, lo cual se debe principalmente al tiempo de aprendizaje que requiere en un inicio el método online para adaptarse a los valores de la serie que está evaluando. Lo anterior se ve reflejado en los valores para las métricas Diff de ambos modelos, siendo el método batch el que entrega menores índices.

- ➢ A pesar de que el método batch máximo verosímil sea el método ideal para casos en los que el parámetro se mantiene constante, las estimaciones del modelo online son bastante acertadas y cercanas tanto a la estimación batch como a los parámetros reales, validando la funcionalidad de la metodología.

- ➢ En cuanto a la medida del MSE para ambos modelos, se observa que el método de estimación online logra, en general, mejores predicciones que el método batch. Por otro lado, los resultados para la métrica aumentan a medida que el parámetro ϕ a estimar presenta valores más cercanos a 0, lo cual se explica por la definición del modelo, puesto que para valores para valores suficientemente pequeños del parámetro, el comportamiento de la serie se asemeja a un ruido blanco:

$$y_{t_j} = \phi^{t_j - t_{j-1}} y_{t_{j-1}} + \sigma\sqrt{1 - \phi^{2(t_j - t_{j-1})}}\varepsilon_{t_j} \xrightarrow[\phi \to 0]{} N(0, \sigma^2).$$

En el escenario de esta evaluación, el método online no supera en precisión a los resultados obtenidos mediante la estimación batch de máxima verosimilitud, sin embargo, el cuanto a las predicciones, el método online supera al método batch en escenarios donde los tiempos entre una observación y otra no resultan con

una gran distancia. Por lo tanto, en casos donde la serie temporal mantiene un patrón constante y se produce una actualización continua de la información, se recomienda utilizar la estimación por lotes de máxima verosimilitud si su enfoque es la estimación del parámetro.

4.5.2. Modelos con Cambio Abrupto en el Parámetro

Para los casos en los que se tiene un modelo autorregresivo regular e irregular con un cambio abrupto en el parámetro, se considera una serie de tiempo de 500 observaciones, de las cuales 200 se consideran previamente almacenadas y el cambio abrupto de parámetro ocurre en el tiempo 250. Se presentas tablas con los coeficientes del modelo estimado a partir de los métodos online y batch, junto con las medidas de MSE y Diff para comparar ambos desempeños.

Tabla 4.14: Resultados generales de distintos modelos autorregresivos con cambio abrupto en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.918	0.585	0.158	0.417	0.316	0.377	0.368
Unif(0,1)	0.971	0.676	0.094	0.332	0.125	0.153	0.476
Gamma(3,3)	0.829	0.519	0.278	0.459	0.326	0.367	0.470
M.Exp.(130,6.5,0.15,0.85)	0.952	0.753	0.125	0.286	0.599	0.680	0.461
M.Exp.(300,10,0.1,0.9)	0.900	0.721	0.252	0.323	0.764	0.813	0.474

Tabla 4.15: Resultados generales de distintos modelos autorregresivos con cambio abrupto en el parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.3$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.483	0.530	0.217	0.272	0.959	0.967	0.375
Unif(0,1)	0.383	0.436	0.150	0.211	0.634	0.648	0.458
Gamma(3,3)	0.390	0.474	0.168	0.252	0.808	0.821	0.499
M.Exp.(130,6.5,0.15,0.85)	0.481	0.580	0.197	0.284	1.012	1.020	0.443
M.Exp.(300,10,0.1,0.9)	0.417	0.579	0.188	0.317	0.881	0.895	0.434

A partir de los resultados de la prueba de cambio abrupto en el parámetro bajo el contexto online, las conclusiones más importantes son las siguiente:

- ➢ El método de estimación online a través de filtro de partículas presenta ventaja sobre el método batch, dado que queda en evidencia que es capaz de detectar cambios estructurales presentes en el comportamiento de la serie de tiempo y logra responder de mejor manera ante las actualización de información. Lo anterior se refleja en los resultados de las métricas Diff, donde el modelo online presenta menores índices en comparación a la metodología batch.

- ➢ En relación a las predicciones, el método online también presenta mejores predichos en comparación al método batch, lo cual se ve reflejado en las métricas MSE de los casos de estudio.

- ➢ No se logra visualizar una tendencia clara en cuanto a la estimación realizada ante un aumento o disminución de diferencias entre los pares de tiempos consecutivos, por lo tanto, los errores en las estimaciones son provocados por la aleatoriedad del propio enfoque, lo cual podría resultar provechoso al momento de su aplicación en datos reales ya que diferencia en los tiempos de observación no refleja una condicional al desempeño del modelo.

En el escenario de esta evaluación, el método online supera los resultados obtenidos mediante la estimación batch de máxima verosimilitud. Por lo tanto, en casos donde la serie temporal no mantiene un patrón constante y se puede observar algún cambio en la tendencia de esta, se recomienda utilizar la estimación online a través de filtro de partículas por sobre la batch, sin descartar esta última como una posible guía en los resultados.

4.5.3. Modelos con Cambio Constante en el Parámetro

Para los casos en los que se tiene un modelo autorregresivo regular e irregular con un cambio constante en el parámetro, ya sea en aumento o disminución, se considera una serie de tiempo de 500 observaciones, donde 200 se consideran previamente almacenadas y el cambio constante va desde un valor ϕ_1 al inicio de la serie de tiempo hasta llegar a un valor ϕ_2 al final de la misma. Se presentan tablas con los coeficientes del modelo estimado a partir de los métodos online y batch, junto con las medidas de MSE y Diff para comparar ambos desempeños.

Tabla 4.16: Resultados generales de distintos modelos autorregresivos con cambio constante en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ Onl	$\widehat{\phi}$ Batch	Diff $\widehat{\phi}$ Onl	Diff $\widehat{\phi}$ Batch	MSE Onl	MSE Batch	Time Onl $[s]$
Regular	0.815	0.556	0.167	0.300	0.287	0.298	0.377
Unif(0,1)	0.916	0.628	0.076	0.251	0.348	0.395	0.291
Gamma(3,3)	0.836	0.637	0.131	0.200	0.422	0.431	0.398
M.Exp.(130,6.5,0.15,0.85)	0.867	0.626	0.132	0.272	0.781	0.812	0.410
M.Exp.(300,10,0.1,0.9)	0.860	0.747	0.108	0.114	0.823	0.851	0.405

Tabla 4.17: Resultados generales de distintos modelos autorregresivos con cambio constante en el parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.4$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ Onl	$\widehat{\phi}$ Batch	Diff $\widehat{\phi}$ Onl	Diff $\widehat{\phi}$ Batch	MSE Onl	MSE Batch	Time Onl $[s]$
Regular	0.511	0.627	0.066	0.135	0.619	0.633	0.327
Unif(0,1)	0.473	0.561	0.060	0.121	0.485	0.487	0.395
Gamma(3,3)	0.484	0.608	0.056	0.145	0.591	0.607	0.393
M.Exp.(130,6.5,0.15,0.85)	0.575	0.673	0.094	0.195	0.868	0.879	0.399
M.Exp.(300,10,0.1,0.9)	0.493	0.556	0.049	0.080	1.008	1.012	0.394

A partir de los resultados de la prueba de cambio constante en el parámetro bajo el contexto online, las conclusiones más importantes son las siguiente:

- El método de estimación online a través de filtro de partículas presenta ventaja sobre el método batch. Lo anterior se refleja en los resultados de las métricas Diff, donde en todos los tiempos simulados el modelo online presenta menores índices en comparación a la metodología batch.

- En relación a las predicciones, el método online también presenta mejores predichos en comparación al método batch, lo cual se ve reflejado en las métricas MSE de los casos de estudio. Cabe destacar que el método online presenta resultados más ventajosos en los escenarios de aumento constante de parámetro, mientras que en los escenarios de disminución constante presenta una ventaja menos notoria.

- No se logra visualizar una tendencia clara en cuanto a la estimación realizada ante un aumento o disminución de diferencias entre los pares de tiempos consecutivos, por lo tanto, los errores en las estimaciones son provocados

por la aleatoriedad del propio enfoque, lo cual podría resultar provechoso al momento de su aplicación en datos reales ya que diferencia en los tiempos de observación no refleja una condicional al desempeño del modelo.

En el escenario presente, el método online supera los resultados obtenidos mediante la estimación batch de máxima verosimilitud. Por lo tanto, en casos donde la serie temporal no mantiene un patrón constante y se puede observar algún cambio en la tendencia de esta, se recomienda utilizar la estimación online a través de filtro de partículas por sobre la batch, sin descartar esta última como una posible guía o comparación en los resultados.

En general, las estimaciones realizadas por el método online van en línea e incluso mejoran en gran parte de las simulaciones a los resultados del método batch máximo verosímil, logrando captar los cambios estructurales y responder debidamente cuando la serie de tiempo lo amerita. Por otro lado, los resultados obtenidos al realizar la simulación en el lenguaje de programación Python (ver Anexo 7.4) se mantienen en general cercanos y en casos mejores a los entregados por el lenguaje R, por lo tanto, ambos lenguajes son válidos para realizar las simulaciones y aplicaciones del método online.

Capítulo 5

Aplicación en Datos Reales

5.1. Flujo del Río Nilo

Como primera aplicación, utilizaremos el set de datos *Nile* disponible en R. En la presente serie de tiempo, las observaciones corresponden a la medición anual del caudal del río Nilo (medido en 10^8 m^3) por debajo de la represa en Asuán, Egipto. El conjunto de datos contiene 100 observaciones regularmente obtenidas entre los años 1871 a 1920. La serie temporal del Nilo ha sido analizada en varios estudios anteriores para ilustrar técnicas de análisis de series temporales, ya que además de ser un caso real de estudio, presenta un punto de cambio cercano al año 1898, el cual se espera detectar el método de estimación propuesto.

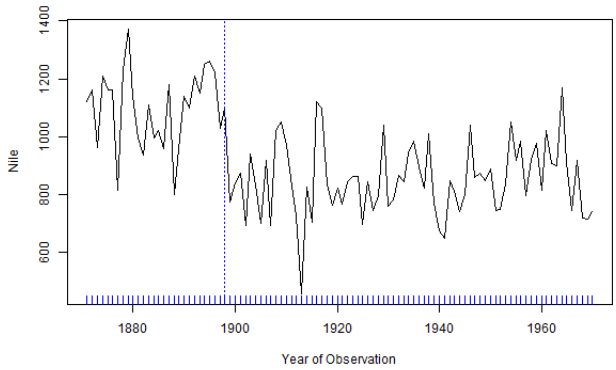


Figura 5.1: Serie de tiempo del caudal del río Nilo.

La figura 5.1 ilustra la serie de tiempo Nilo, donde se puede apreciar el decaimiento de la tendencia en las observaciones de la serie de tiempo a partir del año 1898.

Antes de implementar el método de estimación online basado en el filtro de partículas propuesto y el método batch máximo verosímil, se realiza un preprocesamiento de los datos con el propósito de garantizar una media constante y varianza igual a uno en el conjunto de datos.
A continuación, se presentan los resultados de las estimaciones realizadas.

(a) (b)

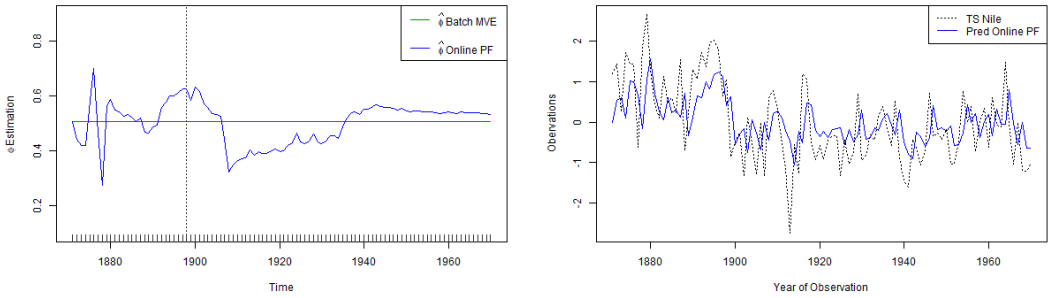


Figura 5.2: Estimación online del flujo del río Nilo. La figura (a) muestra la estimación del parámetro en cada punto de la serie de tiempo. La línea verde representa la estimación batch del modelo IAR, mientras que la línea azul representa la estimación del parámetro utilizando el modelo AR-PF. La línea vertical representa el año donde ocurre el punto de cambio. La figura (b) muestra la estimación de las observaciones utilizando el parámetro predicho en cada tiempo por el modelo AR-PF.

Tabla 5.1: Resultados de la estimación del parámetro para el flujo del río Nilo.

$\widehat{\phi}_{100}$ **Online**	**MSE Online**	$\widehat{\phi}$ **Batch**	**MSE Batch**
0.534	0.869	0.508	0.928

Al analizar los resultados, gráficamente se puede observar que la estimación del parámetro ϕ realizada por el método online basado en el filtro de partículas

detecta los cambios estructurales en la serie de tiempo, estimando valores entre 0.3 y 0.7 aproximadamente para el parámetro, donde la última estimación es del orden de $\widehat{\phi} = 0.53$. La estimación batch máxima verosímil por su parte entrega un valor único del orden de $\widehat{\phi} = 0.51$. Además, el método online logra responder al punto de cambio que a priori se conoce y hacia el final de la serie se acerca a la estimación batch. Por otro lado, respecto a los valores predichos del modelo, se observa que el método online presenta un valor para la métrica MSE igual a 0.869 menor que el MSE que se obtiene por la estimación batch (MSE batch = 0.928), por lo tanto, se puede concluir que el modelo ajustado por el método de filtro de partículas predice con mejor precisión las observaciones.

En lo siguiente, se presenta el análisis de residuos de los valores predichos por el modelo autorregresivo online basado en el filtro de partículas para evaluar la calidad y validez del modelo propuesto. Cabe destacar que el ajuste realizado por el método batch máximo verosímil cumple los supuestos de blancura para los residuos (Ver Anexo 7.5).

A continuación, en la figura 5.3 se expone un diagnóstico de los residuos, en el cual se muestran los residuos estandarizados a través del tiempo, la función de autocorrelación (ACF) asociada y los p-valores del estadístico de Ljung-Box que contrastan la dependencia de los datos.

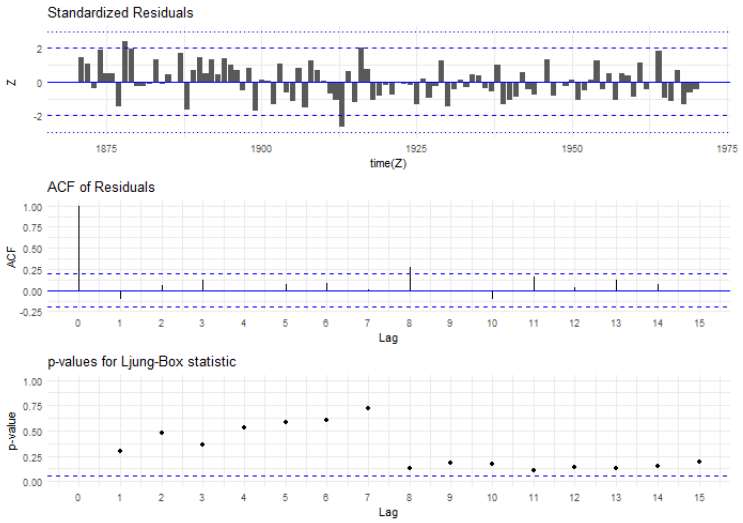


Figura 5.3: Diagnóstico de residuos provenientes de los valores predichos producto de la estimación online.

De acuerdo a lo que se observa la ACF, se interpreta que no existe correlación en los residuos, lo cual valida que no exista cierta relación entre errores que podría afectar en la validez del modelo. En complemento, dado los resultados en los p-valores del estadístico Ljung-Box, se puede inferir que los residuos son independientes entre sí; para validar lo que a priori se puede observar, se aplicó el test de hipótesis de Ljung-Box el cual entrega un $p - valor = 0.2998$, por lo tanto, considerando un nivel de significancia $\alpha = 0.05$, se acepta la hipótesis nula y se verifica que los residuos se distribuyen de forma independiente.

(a) (b)

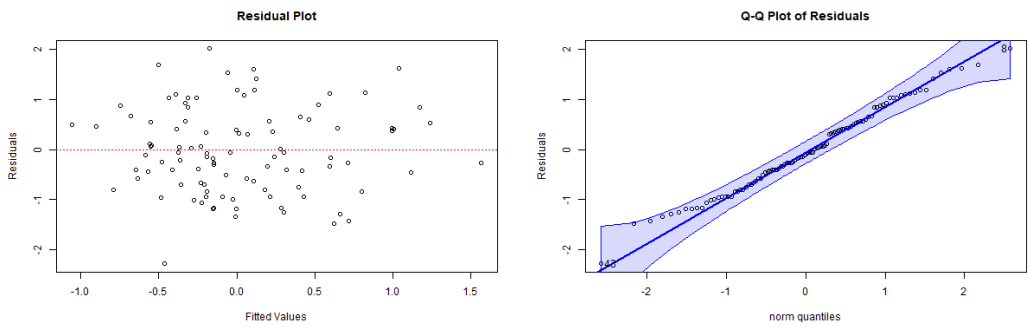


Figura 5.4: Residuos provenientes de los valores predichos producto de la estimación online. La figura (a) muestra la relación entre los valores predichos y los residuos calculados. La figura (b) se muestra el gráfico cuantil-cuantil (Q-Q) para los residuos.

Según lo observado en la figura 5.4a los residuos no presentan relación en su comportamiento con lo valores predichos y complementado a lo que se presenta en el QQ-Plot de la figura 5.4b se puede inferir que siguen una distribución Normal en su comportamiento. Para verificar la normalidad supuesta de en los residuos, se aplicó el test de Shapiro Wilk el cual entrega un $p - valor = 0.5236$, por lo tanto, considerando un nivel de significancia $\alpha = 0.05$, se acepta la hipótesis nula y se evidencia que los residuos siguen una distribución normal.

Finalmente, los residuos aprueban el test de blancura, por lo tanto, se valida el modelo junto a sus resultados, logrando estimar de manera online el flujo del río Nilo satisfactoriamente.

5.2. Curvas de Luz Atronómicas

5.2.1. Núcleo de Galaxia Activa - Curva ZTF18aaabbuy

Un Núcleo de Galaxia Activa (o AGN por su sigla en inglés) corresponde a una región extremadamente luminosa en el centro de la galaxia, que emite radiación y energía en múltiples longitudes de onda.La curva de luz ZTF18aaabbuy cuenta con 218 observaciones y se clasifica como un AGN.
Como suele ocurrir en los datos astronómicos, las observaciones no son capturadas de forma regular, por lo que corresponden a series de tiempo irregularmente espaciadas, caso ideal para poner a prueba el método de estimación online propuesto.

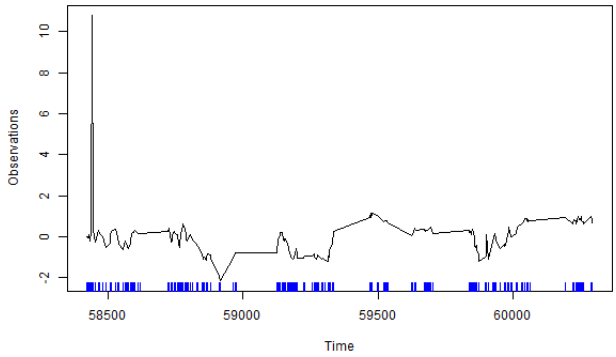


Figura 5.5: Curva de luz AGN ZTF18aaabbuy.

Dentro de lo que principalmente se puede observar en la serie son las diferencias entre las observaciones para cada tiempo, donde en un comienzo se presenta un salto en la curva y luego baja bruscamente, lo cual puede deberse a un cambio en el parámetro de la serie.

A continuación, se presentan los resultados de las estimaciones realizadas.

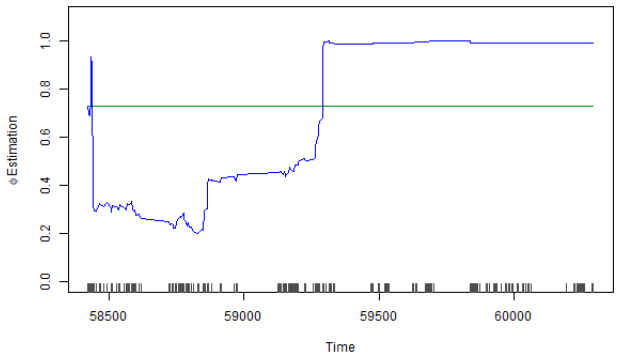


Figura 5.6: Estimación del parámetro de modelo IAR: Curva de luz AGN ZTF18aaabbuy.

La figura 5.6 se presenta los resultados para la estimación del parámetro de la curva de luz mediante la ejecución los modelos batch máximo verosímil (línea verde) y online basado en el filtro de partículas (línea azul). El método online se inicializó considerando una cantidad de partículas $N_p = 300$, un valor para el parámetro $a = 0.98$ y un valor m_0 igual al valor del parámetro $\widehat{\phi}$ estimado por la metodología batch.

Tabla 5.2: Resultados de la estimación del parámetro para la curva de luz AGN ZTF18aaabbuy.

$\widehat{\phi}_{218}$ **Online**	**MSE Online**	$\widehat{\phi}$ **Batch**	**MSE Batch**
0.9919	0.7514	0.728201	0.8299

Al analizar los resultados, se puede observar que la estimación del parámetro por máxima verosimilitud presenta un valor $\widehat{\phi} = 0.8299$, mientras que la estimación a través de filtro de partículas presenta una estimación del parámetro no constante a lo largo de la serie, donde en las primeras observaciones se percibe una caída en el parámetro, estimando un valor para $\widehat{\phi} \approx 0.3$ (posiblemente en respuesta al salto presentado en las observaciones) para luego comenzar a crecer y presentar un cambio abrupto hasta un valor $\widehat{\phi} \approx 0.99$ el cual pareciera mantenerse constante en lo restante de la serie, estimando un valor final de $\widehat{\phi}_{218} = 0.9919$.
En cuanto a la medida del MSE, se observa que el modelo online presenta un mejor índice en comparación al máximo verosímil (MSE Online = 0.75, MSE Batch =

0.83), por lo tanto, para la curva ZTF18aaabbuy, el modelo basado en filtro de partículas entrega predicciones más cercanas a las observaciones reales.

5.2.2. Objeto Cuasiestelar - Curva ZTF18acefhus

Un Objeto Cuasiestelar (o QSO por su sigla en inglés) es un tipo de fuente de radio cuasiestelar que corresponde a un tipo de AGN extremadamente luminosa impulsada por agujeros negros supermasivos. La curva de luz ZTF18acefhus cuenta con 145 observaciones y se clasifica como un QSO.
Como suele ocurrir en los datos astronómicos, las observaciones no son capturadas de forma regular, por lo que corresponden a series de tiempo irregularmente espaciadas, caso ideal para poner a prueba el método de estimación online propuesto.

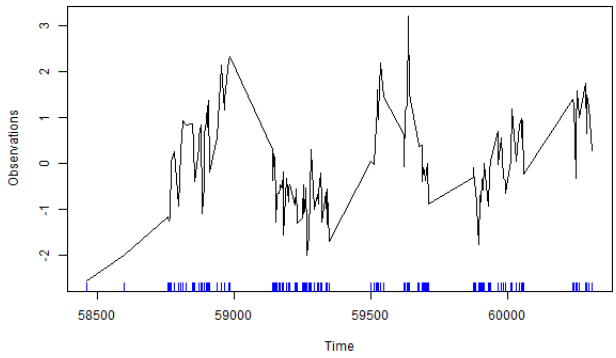


Figura 5.7: Curva de luz del QSO ZTF18acefhus.

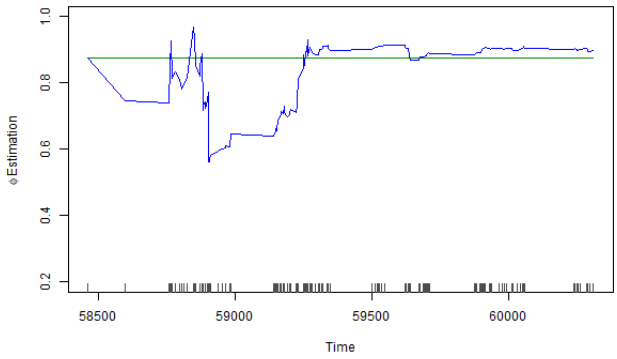


Figura 5.8: Estimación del parámetro de modelo IAR: Curva de luz QSO ZTF18acefhus.

La figura 5.8 se presenta los resultados para la estimación del parámetro de la curva de luz mediante la ejecución los modelos batch máximo verosímil (línea verde) y online basado en el filtro de partículas (línea azul). El método online se inicializó considerando una cantidad de partículas $N_p = 300$, un valor para el parámetro $a = 0.98$ y un valor m_0 igual al valor del parámetro $\widehat{\phi}$ estimado por la metodología batch.

A continuación, se presentan los resultados de las estimaciones realizadas.

Tabla 5.3: Resultados de la estimación del parámetro para la curva de luz QSO ZTF18acefhus.

$\widehat{\phi}_{145}$ **Online**	**MSE Online**	$\widehat{\phi}$ **Batch**	**MSE Batch**
0.8982	0.6069	0.8766	0.6136

Al analizar los resultados, se puede observar que la estimación del parámetro por máxima verosimilitud presenta un valor $\widehat{\phi} = 0.8766$, mientras que la estimación a través de filtro de partículas presenta una estimación del parámetro no constante a lo largo de la serie, donde en las primeras observaciones se percibe una un aumento y posteriormente una caída en el parámetro, entre los valores 0.9 y 0.6 aproximadamente. Posteriormente el parámetro comienza a aumentar hasta un valor $\widehat{\phi} \approx 0.85$ el cual tiende a acercarse al valor $\widehat{\phi}$ batch, estimando un valor final

de $\widehat{\phi}_{145} = 0.8982$.

En cuanto a la medida del MSE, se observa que el modelo online presenta un mejor índice en comparación al máximo verosímil, por lo tanto, para la curva ZTF18acefhus, el modelo basado en filtro de partículas entrega predicciones más cercanas a las observaciones reales.

Capítulo 6

Conclusiones

El proyecto se planteó como objetivo ampliar las herramientas matemáticas-estadísticas que permitan la caracterización y estimación de parámetros asociados a series de tiempo irregularmente espaciadas, las cuales se pueden encontrar en abundancia en la vida real. El objetivo principal era implementar un nuevo método para la estimación de parámetros de procesos irregulares basado en la metodología de filtro de partículas. Se buscaba lograr la implementación de un método online que sea capaz de responder a cambios estructurales presentes en los datos a medida que estos se analizaban.

En relación a los experimentos y simulaciones realizadas para los distintos modelos autorregresivos tanto regulares como irregulares bajo distintos parámetros y escenarios, se observa que usualmente el método de estimación online mediante filtro de partículas entrega una estimación cercana a los parámetros reales del modelo que se está evaluando, visibles en la métrica *Diff* (o Error Absoluto Medio) y MSE. En cuanto a las métricas que evalúan el desempeño de los modelos, no se nota una tendencia o relación entre sus resultados y la complejidad de los tiempos simulados para el estudio de los distintos casos, por lo tanto, el modelo basado en filtro de partículas propuesto no es sensible a las diferencias existentes entre cada instante de observación.

En el contexto de estudio donde el parámetro autorregresivo ϕ se mantiene constante, el método batch es más preciso, sin embargo, el método de filtro de partículas logra en general mejores predicciones en estas situaciones. En escenarios

donde el parámetro ϕ presenta aumentos constantes a lo largo de la serie de tiempo, el método online por filtro de partículas logra mejorar en promedio un 41 % y 4.96 % la precisión de la estimación y predicción de las observaciones, respectivamente, mientras que en escenarios de disminución constante de parámetro, el método online logra mejorar en promedio un 50 % y 1.38 % la precisión y predicción, respectivamente. Para escenarios donde el parámetro ϕ presenta un aumento abrupto en la serie de tiempo, el método online por filtro de partículas logra mejorar en promedio un 50 % y 12.72 % la precisión de la estimación y predicción de las observaciones, respectivamente, mientras que en escenarios de disminución constantes de bajada de parámetro, el método online logra mejorar en promedio un 50 % y 1.38 % la precisión y predicción, respectivamente.
En relación a los tiempos de cómputo del modelo online, su valor está directamente relacionado con el tamaño de la serie de tiempo a evaluar y a la cantidad de partículas escogidas para realizar las estimaciones. En los casos de estudio, donde se utilizaron 1000 partículas y se evaluaron modelos con 500 observaciones (casos donde el parámetro permanece constante) se promedió un tiempo de ejecución de 0.76 segundos, mientras que en modelos con 300 observaciones (casos donde el parámetro sufre variaciones) se promedió un tiempo de ejecución de 0.41 segundos.

En base a la evidencia anterior, el método online basado en filtro de partículas logra detectar cambios estructurales y adaptarse de manera efectiva a los distintos escenarios que se puedan presentar en modelos autorregresivos tanto regulares como irregulares. Aquellos escenarios donde mejor se comporta el método de estimación online por filtro de partículas son aquellos donde el parámetro se mantiene constante (a pesar que el método batch lo supere el precisión) y donde se presentan aumentos en el parámetro a lo largo de la serie de tiempo, sean constantes o abruptos, siendo el aumento abrupto el que presenta mayores mejoras en las métricas estudiadas versus el método batch por máxima verosimilitud. Por otro lado, a pesar de que se presentan mejoras en las métricas para los escenarios de disminución constante o abrupta en el parámetro en comparación al método batch, el método online tiende a reaccionar más lento, exponiendo una posible oportunidad de mejora para el tratamiento de estos casos.

En cuanto a las aplicaciones en los datos reales del modelo online propuesto, se puede observar un gran desempeño tanto para el caso regular como irregular,

donde se lograron mejores resultados que el modelo batch por máxima verosimilitud basándonos en la comparación de la medida del error cuadrático en ambas metodologías. Por otro lado, se destaca la validez del modelo autorregresivo en el caso regular puesto que las pruebas de blancura en los residuos se cumple satisfactoriamente.

En general, los resultados obtenidos muestran que este nuevo método de estimación online se posiciona como una herramienta y opción válida para el estudio de series de tiempo regulares como irregulares, al ofrecer una metodología basada en el filtro de partículas que aporta robustez y precisión a la hora de abordar este tipo de problemas. Su aplicación abre las puertas a un análisis más profundo y detallado en el campo de las series de tiempo irregularmente espaciadas, lo que constituye una contribución significativa al progreso del conocimiento en este campo específico, con un potencial impacto en la investigación y la comprensión en el ámbito de la astronomía.

Para estudios posteriores, podría resultar de interés implementar la extensión del modelo online basado en el filtro de partículas a modelos autorregresivos complejos irregularmente espaciados (CIAR) (Elorrieta et al., 2019), donde el parámetro del modelo extiende su dominio a valores entre $(-1, 1)$ y surge la evolución de un estado complejo no observado en tiempos irregulares.

Bibliografía

[1] M. J. Bayarri and J. O. Berger. The Interplay of Bayesian and Frequentist Analysis. *Statistical Science*, 19(1):58 – 80, 2004. doi: 10.1214/088342304000000116. URL https://doi.org/10.1214/088342304000000116.

[2] Sarah Benjelloun, Mohamed El Aissi, Loukili Yassine, Younes Lakhrissi, Safae Ali, Hiba Chougrad, and Abdessamad Boushaki. In *Big Data Processing: Batch-based processing and stream-based processing*, pages 1–6, 10 2020. doi: 10.1109/ICDS50568.2020.9268684.

[3] Ekaba Bisong. *Building Machine Learning and Deep Learning Models on Google Cloud Platform: A Comprehensive Guide for Beginners*. Apress, 2019. doi: 10.1007/978-1-4842-4470-8_15. URL https://doi.org/10.1007/978-1-4842-4470-8_15.

[4] Peter J. Brockwell and Richard A. Davis. *Introduction to Time Series and Forecasting*. Springer Texts in Statistics. Springer International Publishing, 2016. doi: 10.1007/978-3-319-29854-2. URL https://doi.org/10.1007/978-3-319-29854-2.

[5] Carlos M. Carvalho, Michael S. Johannes, Hedibert F. Lopes, and Nicholas G. Polson. Particle Learning and Smoothing. *Statistical Science*, 25(1):88 – 106, 2010. doi: 10.1214/10-STS325. URL https://doi.org/10.1214/10-STS325.

[6] Pierre Del Moral. Nonlinear filtering: Interacting particle resolution. *Comptes Rendus de l'Académie des Sciences - Series I - Mathematics*, 325(6):653–658, 1997. ISSN 0764-4442. doi: https://doi.org/10.1016/S0764-4442(97)84778-7. URL https://www.sciencedirect.com/science/article/pii/S0764444297847787.

[7] Arnaud Doucet, Nando Freitas, Kevin Murphy, and Stuart Russell. Sequential monte carlo methods in practice. 01 2013. doi: 10.1007/978-1-4757-3437-9_24.

[8] Felipe Elorrieta, Susana Eyheramendy, and Wilfredo Palma. Discrete-time autoregressive model for unequally spaced time-series observations. *Astronomy & Astrophysics*, 627:A120, jul 2019. doi: 10.1051/0004-6361/201935560. URL https://doi.org/10.1051%2F0004-6361%2F201935560.

[9] Palma W. Elorrieta F., Eyheramendy S. *AITS: Analysis of Irregular Time Series*, 2022. URL https://cran.r-project.org/web/packages/iAR/iAR.pdf.

[10] Susana Eyheramendy, Felipe Elorrieta, and Wilfredo Palma. An irregular discrete time series model to identify residuals with autocorrelation in astronomical light curves. *Monthly Notices of the Royal Astronomical Society*, 481 (4):4311–4322, 09 2018. ISSN 0035-8711. doi: 10.1093/mnras/sty2487. URL https://doi.org/10.1093/mnras/sty2487.

[11] Andrew Gelman, John B. Carlin, Hal S. Stern, and Donald B. Rubin. *Bayesian Data Analysis*. Chapman and Hall/CRC, 2nd ed. edition, 2004.

[12] R. Hogg and E. Tanis. *Probability and Statistical Inference*. Pearson, 2012.

[13] Steven C.H. Hoi, Jialei Wang, and Peilin Zhao. Libol: A library for online learning algorithms. *Journal of Machine Learning Research*, 15(15):495–499, 2014. URL http://jmlr.org/papers/v15/hoi14a.html.

[14] Jane Liu and Mike West. *Combined Parameter and State Estimation in Simulation-Based Filtering*, pages 197–223. Springer New York, New York, NY, 2001. ISBN 978-1-4757-3437-9. doi: 10.1007/978-1-4757-3437-9_10. URL https://doi.org/10.1007/978-1-4757-3437-9_10.

[15] A.F.M. Smith N.J. Gordon, D.J. Salmond. Novel approach to nonlinear/non-gaussian bayesian state estimation. *IEE Proceedings F (Radar and Signal Processing)*, 140:107–113(6), April 1993. ISSN 0956-375X. URL https://digital-library.theiet.org/content/journals/10.1049/ip-f-2.1993.0015.

[16] D. Peña and D.P.S. de Rivera. *Fundamentos de Estadística*. El Libro Universitario/Alianza Editorial Series. Alianza Editorial, S. A., 2001. ISBN 9788420686967. URL https://books.google.cl/books?id=mxoFqrH9m6EC.

[17] Michael K. Pitt and Neil Shephard. Filtering via simulation: Auxiliary particle filters. *Journal of the American Statistical Association*, 94(446):590–599, 1999. ISSN 01621459. URL http://www.jstor.org/stable/2670179.

[18] Simo Särkkä. *Bayesian Filtering and Smoothing*. Institute of Mathematical Statistics Textbooks. Cambridge University Press, 2013. doi: 10.1017/CBO9781139344203.

[19] J. Wakefield. *Bayesian and Frequentist Regression Methods*. Springer Series in Statistics. Springer New York, 2013. ISBN 9781441909251. URL https://books.google.cl/books?id=OUJEAAAAQBAJ.

[20] Larry Wasserman. *All of statistics : a concise course in statistical inference*. Springer, New York, 2010. ISBN 9781441923226 1441923225. URL http://www.amazon.de/All-Statistics-Statistical-Inference-Springer/dp/1441923225/ref=sr_1_2?ie=UTF8&qid=1356099149&sr=8-2.

[21] Mike West. Approximating posterior distributions by mixtures. 1993a.

[22] Mike West. Mixture models monte carlo bayesian updating and dynamic models. *Institute of Statistics Decision Sciences*, 1993b.

Capítulo 7

Anexo

7.1. Distribuciones de Probabilidad

7.1.1. Distribución Normal

Una variable aleatoria continua X posee una distribución normal de media μ y varianza σ^2 ($\sigma > 0$), cuya notación usual es $X \sim N(\mu, \sigma^2)$, cuando sigue la función de densidad:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) \tag{7.1.1}$$

para todo $x \in \mathbb{R}$, donde $\mathbb{E}(X) = \mu$ y $\mathbb{V}(X) = \sigma^2$.

7.1.2. Distribución Uniforme

Una variable aleatoria continua X sigue una distribución uniforme de parámetros a y b ($a < b$), cuya notación usual es $X \sim U(a, b)$, cuando sigue la función de densidad:

$$f(x) = \frac{1}{b-a} \mathbb{1}_{(a,b)}(x). \tag{7.1.2}$$

7.1.3. Distribución Gamma

Una variable aleatoria continua X sigue una distribución gamma de parámetros $k > 0$ y $\lambda > 0$, cuya notación usual es $X \sim Gamma(k, \lambda)$, cuando sigue la función

de densidad:

$$f(x) = \frac{\lambda^k}{\Gamma(k)} x^{k-1} e^{-\lambda x} \mathbb{1}_{\mathbb{R}^+}(x), \tag{7.1.3}$$

donde $\Gamma(\cdot)$ representa a la función Gamma.

7.1.4. Distribución Exponencial

Una variable aleatoria continua X sigue una distribución exponencial de parámetro $\lambda > 0$, cuya notación usual es $X \sim exp(\lambda)$, cuando sigue la función de densidad:

$$f(x) = \lambda e^{-\lambda x} \mathbb{1}_{\mathbb{R}^+}(x). \tag{7.1.4}$$

7.1.5. Mezcla de Distribuciones

Se dirá que una distribución es una mezcla de dos distribuciones cuando su función de distribución puede escribirse como

$$F(x) = (1 - \alpha)F_1(x) + \alpha F_2(x), \tag{7.1.5}$$

donde F_1 y F_2 son funciones de distribución y α un valor entre cero y uno que representa la probabilidad de que el elemento provenga de la distribución F_2 (16).

7.2. Código Filtro de Partículas - Modelos AR1

```
AR.LW  = function(y,Np=200,m0,a=0.98){
  sig  = 1/rgamma(Np,shape=1,scale=1)
  phis  = rtruncnorm(Np,-1,1,m0,sqrt(sig))
  n  = length(y)
  quants = array(0,c(n,3,3))
  h2 = 1-a^2
  pars = cbind(phis,log(sig))
  MSE = rep(0,n)
  #Init quants
  quants[1,1,] = rep(m0,3)
  quants[1,2,] = rep(mean(sig),3)
  for (t in 2:n){
    # Resampling
    mpar    = apply(pars,2,mean)
    vpar    = var(pars)
    ms      = a*pars+(1-a)*matrix(mpar,Np,2,byrow=T)
    weight  = dnorm(y[t],phis*y[t-1],sqrt(sig))
    k       = sample(1:Np,size=Np,replace=T,prob=weight)
    pars    = ms[k,] + matrix(rnorm(2*Np),Np,2)%*%chol(h2*
   vpar) #Paso 3
    phis   = pars[,1]
    sig   = exp(pars[,2])
    # Storing quantiles
    quants[t,1,] = quantile(phis,c(0.05,0.5,0.95))
    quants[t,2,] = quantile(sig,c(0.05,0.5,0.95))
    quants[t,3,] = quantile((phis)*y[t-1],c(0.05,0.5,0.95))
    MSE[t] <- sum((y[2:t]-quants[2:t,3,2])^2)/(t-1)
  }
  return(list(Param=quants[,1,],Sigma=quants[,2,], Pred =
   quants[,3,],MSE=MSE))
}
```

Listing 7.1: Código en R para estimación online de parámetros del modelo AR1.

7.3. Códigos Filtro de Partículas - Modelos IAR

7.3.1. Código en Lenguaje R

```
IAR.LW = function(y,times,N,m0,P0,a){
  n   = length(y)
  h2 = 1-a^2
  difer = diff(times)
  quants = array(0,c(n,2,3))
  MSE = rep(0,n)
  # Init Particles
  pars = matrix(NA, N, 1)
  phis = rtruncnorm(N,0,1,m0,P0)
  pars[, 1] <- phis
  #Init quants
  quants[1,1,] <- rep(m0,3)
  quants[1,2,] <- rep(abs(m0)^(difer[1])*y[1],3)
  for (t in 2:(n)){
    tau = sd(y)^2*(1-phis^(2*difer[t-1]))
    # Resampling
    mpar     = colMeans(pars)
    vpar     = var(pars)
    ms       = a*pars+(1-a)*matrix(mpar,N,1,byrow=T)
    weight   = dnorm(y[t],y[t-1]*phis^difer[t-1],sqrt(tau))
    k        = sample(1:N,size=N,replace=T,prob=weight)
    pars     <- ms[k,]+matrix(rnorm(N),N,1)%*%chol(h2*vpar)
    pars[pars < 0] = 0.0001
    pars[pars > 1] = 0.9999
    phis    <- pars[,1]
    # Storing quantiles
    quants[t,1,] <- quantile(phis,c(0.05,0.5,0.95))
    quants[t,2,] <- quantile(abs(phis)^(difer[t-1])*y[t-1],c
   (0.05,0.5,0.95))
    MSE[t] <- sum((y[2:t]-quants[2:t,2,2])^2)/(t-1)
  }
  return(list(Param=quants[,1,], Pred = quants[,2,], MSE =
   MSE))
```

```
}
```

Listing 7.2: Código en R para estimación online de parámetros del modelo IAR.

7.3.2. Código en Lenguaje Python

```
def IAR_LW(y,times,N,m0,P0,a):
    n = len(y)
    h2 = 1 - a**2
    difer = np.diff(times)
    quants = np.zeros((n, 2, 3))
    MSE = np.zeros(n)
    # Init Particles
    phis=truncnorm.rvs(a=(0-m0)/P0, b=(1-m0)/P0, loc=m0,
   scale=P0, size=N)
    pars = np.column_stack((phis,))
    # Init quants
    quants[0, 0, :] = np.repeat(m0,3)
    quants[0, 1, :] = np.repeat(np.abs(m0)**difer[1]*y[1],
   3)
    for t in range(1, n):
        tau = np.var(y) * (1 - phis**(2*difer[t-1]))
        # Resampling
        mpar = np.mean(pars)
        vpar = np.var(pars)
        ms = a * pars + (1-a) * np.tile(mpar, (N,1))
        weight = norm.pdf(y[t], loc=y[t-1]*phis**difer[t-1],
    scale=np.sqrt(tau))
        k = np.random.choice(N, size=N, replace=True, p=
   weight/np.sum(weight))
        pars = ms[k,:] + np.random.normal(size=(N, 1))*np.
   linalg.cholesky(np.array([[h2]])@np.array([[vpar]]))
        # Ensure pars is within bounds
        pars = np.clip(pars, 0.0001, 0.9999)
        phis = pars[:,0]
        # Storing quantiles
```

```
26          quants[t, 0, :] = np.quantile(phis, [0.05, 0.5,
    0.95])
27          quants[t, 1, :] = np.quantile(np.abs(phis)**(difer[t
    -1]) * y[t-1], [0.05, 0.5, 0.95])
28          MSE[t] = np.sum((y[0:t] - quants[0:t, 1, 1])**2) / t
29      return quants
```

Listing 7.3: Código en Python para estimación online de parámetros del modelo IAR.

7.4. Resultados Generales - Python

7.4.1. Modelos con Parámetro Fijo

Tabla 7.1: Resultados generales en **Python** de distintos modelos autorregresivos con parámetro fijo $\phi = 0.9$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ Onl	$\widehat{\phi}$ Batch	Diff $\widehat{\phi}$ Batch	MSE Onl	MSE Batch	Time Onl $[s]$
Regular	0.836	0.842	0.081	0.296	0.292	0.540
Unif(0,1)	0.888	0.884	0.012	0.116	0.116	0.644
Gamma(3,3)	0.898	0.904	0.036	0.767	0.766	0.708
M.Exp.(130,6.5,0.15,0.85)	0.904	0.907	0.012	0.607	0.607	0.631
M.Exp.(300,10,0.1,0.9)	0.894	0.895	0.013	0.661	0.658	0.654

Tabla 7.2: Resultados generales en **Python** de distintos modelos autorregresivos con parámetro fijo $\phi = 0.5$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ Onl	$\widehat{\phi}$ Batch	Diff $\widehat{\phi}$ Onl	MSE Onl	MSE Batch	Time Onl $[s]$
Regular	0.496	0.502	0.027	0.750	0.750	0.561
Unif(0,1)	0.513	0.503	0.039	0.457	0.455	0.598
Gamma(3,3)	0.455	0.603	0.126	0.982	0.979	0.681
M.Exp.(130,6.5,0.15,0.85)	0.483	0.518	0.052	0.883	0.883	0.670
M.Exp.(300,10,0.1,0.9)	0.419	0.454	0.099	0.944	0.943	0.625

Tabla 7.3: Resultados generales en **Python** de distintos modelos autorregresivos con parámetro fijo $\phi = 0.3$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.302	0.312	0.038	0.904	0.903	0.596
Unif(0,1)	0.316	0.309	0.043	0.615	0.613	0.597
Gamma(3,3)	0.366	0.506	0.060	0.988	0.987	0.674
M.Exp.(130,6.5,0.15,0.85)	0.296	0.301	0.054	0.922	0.923	0.737
M.Exp.(300,10,0.1,0.9)	0.263	0.242	0.050	0.971	0.971	0.647

7.4.2. Modelos con Cambio Abrupto en el Parámetro

Tabla 7.4: Resultados generales en **Python** de distintos modelos autorregresivos con cambio abrupto en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.960	0.739	0.069	0.191	0.249	0.233
Unif(0,1)	0.803	0.535	0.338	0.228	0.265	0.292
Gamma(3,3)	0.950	0.818	0.075	0.666	0.811	0.357
M.Exp.(130,6.5,0.15,0.85)	0.959	0.803	0.086	0.581	0.704	0.301
M.Exp.(300,10,0.1,0.9)	0.939	0.494	0.149	0.744	0.919	0.318

Tabla 7.5: Resultados generales en **Python** de distintos modelos autorregresivos con cambio abrupto en el parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.3$ para cada uno de los tiempos simulados

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.495	0.556	0.217	0.815	0.832	0.332
Unif(0,1)	0.512	0.501	0.231	0.613	0.615	0.341
Gamma(3,3)	0.449	0.590	0.184	1.016	1.030	0.343
M.Exp.(130,6.5,0.15,0.85)	0.365	0.535	0.129	0.972	0.986	0.378
M.Exp.(300,10,0.1,0.9)	0.432	0.593	0.197	0.918	0.931	0.337

7.4.3. Modelos con Cambio Constante en el Parámetro

Tabla 7.6: Resultados generales en **Python** de distintos modelos autorregresivos con cambio constante en el parámetro de $\phi_1 = 0.3$ a $\phi_2 = 0.95$

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.916	0.628	0.076	0.251	0.348	0.395	0.291
Unif(0,1)	0.815	0.556	0.167	0.300	0.287	0.298	0.377
Gamma(3,3)	0.836	0.637	0.131	0.200	0.422	0.431	0.398
M.Exp.(130,6.5,0.15,0.85)	0.867	0.626	0.132	0.272	0.781	0.812	0.410
M.Exp.(300,10,0.1,0.9)	0.860	0.747	0.108	0.114	0.823	0.851	0.405

Tabla 7.7: Resultados generales en **Python** de distintos modelos autorregresivos con cambio constante en el parámetro de $\phi_1 = 0.8$ a $\phi_2 = 0.4$

Tiempo	$\widehat{\phi}$ **Onl**	$\widehat{\phi}$ **Batch**	**Diff** $\widehat{\phi}$ **Onl**	**Diff** $\widehat{\phi}$ **Batch**	**MSE Onl**	**MSE Batch**	**Time Onl** $[s]$
Regular	0.512	0.609	0.061	0.116	0.652	0.664	0.310
Unif(0,1)	0.473	0.561	0.060	0.121	0.485	0.487	0.395
Gamma(3,3)	0.484	0.608	0.056	0.145	0.591	0.607	0.393
M.Exp.(130,6.5,0.15,0.85)	0.575	0.673	0.094	0.195	0.868	0.879	0.399
M.Exp.(300,10,0.1,0.9)	0.493	0.556	0.049	0.080	1.008	1.012	0.394

7.5. Residuos Nilo - Estimación Máxima Verosímil

➢ *p-valor* Test Shapiro Wilk: 0.5796

➢ *p-valor* Test Ljung-Box: 0.3116

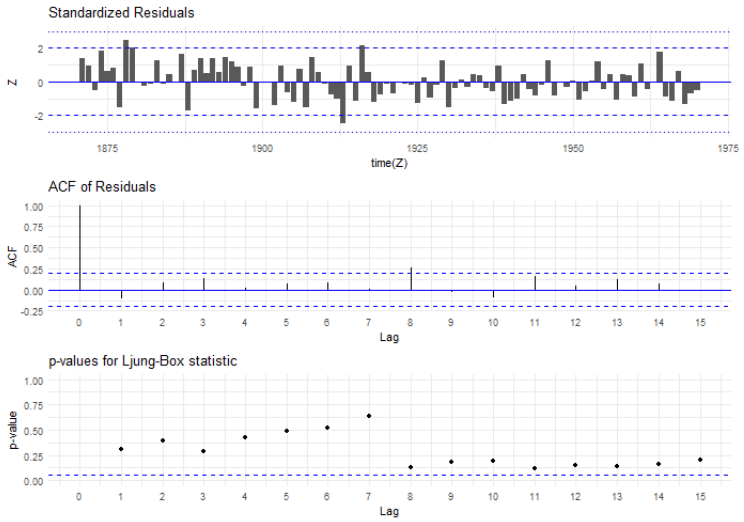


Figura 7.1: Diagnóstico de residuos provenientes de los valores predichos producto de la estimación por máxima verosimilitud.

(a) (b)

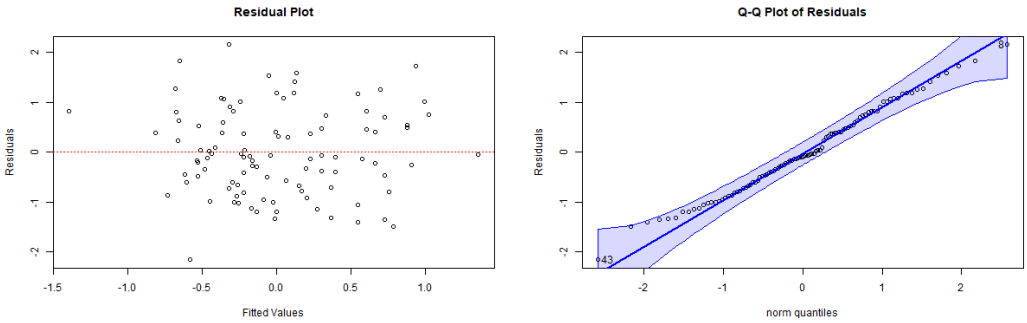


Figura 7.2: Residuos provenientes de los valores predichos producto de la estimación por máxima verosimilitud. La figura (a) muestra la relación entre los valores predichos y los residuos calculados. La figura (b) se muestra el gráfico cuantil-cuantil (Q-Q) para los residuos.